

Informe ID21I10297

Herrera A.; Muñoz M. & F. Zambrano

2025-04-09

Tabla de contenidos

Acerca del Informe	4
Prefacio	5
Introducción	6
I Metodología	8
1 Área de estudio	9
1.1 Tratamientos de riego deficitario	10
2 Parámetros fisiológicos	11
2.1 Potencial hídrico xilemático (Ψ_s) y fluorescencia	11
2.2 Punto de pérdida de turgor (TLP)	12
2.3 Presión de turgor en la hoja	13
3 Parámetros de producción y calidad	15
3.1 Cosecha y frutos	15
3.2 Producción y calidad	15
4 Modelado espacial diario de Ψ_s	17
4.1 Predictores espacio-temporales	17
Variables meteorológicas	17
Datos de teledetección y IVs	17
4.2 Modelos de machine learning	25
4.3 Evaluación e importancia de los modelos	26
5 Plataforma web SatOri	28
II Resultados	29
6 Parámetros fisiológicos	30
6.1 Fluorescencia	30
La Esperanza	30
Rio Claro	31

6.2	Potencial	33
	La Esperanza	33
	Rio Claro	33
6.3	LAI	35
	La Esperanza	35
	Rio Claro	35
6.4	Punto de pérdida de turgor (TLP)	38
	La Esperanza	39
	Rio Claro	40
	6.4.1 Tratamiento 0 (control)	40
	6.4.2 Tratamiento 1	40
	6.4.3 Tratamiento 2	41
	6.4.4 Tratamiento 3	41
	6.4.5 Tratamiento 4	42
6.5	Presión de turgor	45
	Clustering	45
	Limpieza de datos: eliminación de clusters	69
	Estandarización de clusters	93
	Datos preprocesados	117
7	Producción y calidad	181
7.1	Producción	181
	Peso total	181
	Densidad	181
7.2	Calidad	184
	Peso	184
	Calibre	184
	Color	187
	Contenido de azúcar	187
	Daño	187
8	Modelos predictivos de potencial	192
9	SatOri	196
	References	198

Acerca del Informe

Reporte general del proyecto ID21I10297, financiado por la Agencia Nacional de Investigación y Desarrollo (ANID) por medio del proyecto FONDEF IDEA 2021.

Este proyecto estuvo a cargo del director Dr. Francisco Zambrano Bigiarini de la Universidad Mayor.

Investigadores que participaron en el proyecto:

- Dr. Francisco Zambrano - Director - Centro Hemera UMayor
- Dra. Andrea Miyasaka Almeyda - Directora Alterna - Centro CGB UMayor
- Dr. Felipe de La Hoz - Investigador - Externo
- Paulina Vidal - Investigadora - Centro Hemera UMayor
- Idania Briceño - Investigadora - Centro Hemera UMayor

Además, trabajaron como asistentes de investigación los siguientes profesionales:

- Jesica Garrido - Centro Hemera UMayor
- Abel Herrera - Centro Hemera UMayor

Para revisar los procedimientos específicos empleados o analizar los resultados del proyecto durante la temporada 2022-2023 de manera independiente, se recomienda acceder al reporte fabricado por Muñoz M. en el siguiente [enlace](#).

Prefacio

Este informe presenta la metodología y los resultados obtenidos en el marco del proyecto **FONDEF ID21I10297**, en el cual se desarrolló *SatOri*, una aplicación para la optimización del riego en frutales, orientada a mejorar la resiliencia de la agricultura chilena frente al cambio climático. La plataforma modela el potencial hídrico xilemático (Ψ_s) con frecuencia diaria y resolución espacial, utilizando datos meteorológicos, imágenes satelitales Sentinel-2 y algoritmos de machine learning. El Ψ_s representa la respuesta hídrica de la planta frente a las condiciones ambientales y de manejo. Además, *SatOri* estima el umbral mínimo de Ψ_s que pueden alcanzar los árboles antes de comprometer su funcionamiento fisiológico, y a partir de este valor genera recomendaciones sectorizadas de riego, en formato de semáforo, para evitar caídas en la fotosíntesis y pérdidas productivas. El prototipo, fue desarrollado para dos huertos de cerezos propiedad de la compañía [Garcés Fruit](#): campos “La Esperanza” y “Río Claro” (ambos ubicados en la Región O’ Higgins).

Para incorporar variabilidad en los valores de Ψ_s , mejorar la predictibilidad del modelo y evaluar la respuesta fisiológica a distintos niveles de riego, se aplicaron cuatro tratamientos de riego deficitario controlado (RDC) en huertos comerciales de cerezo ubicados en La Esperanza y Río Claro, durante dos temporadas consecutivas (2022–2023 y 2023–2024). Para este fin se midieron tres variables fisiológicas: eficiencia fotosintética (F_v/F_m), potencial hídrico xilemático (Ψ_s) e índice de área foliar (LAI). Los resultados mostraron diferencias entre tratamientos y entre sitios. En general, los tratamientos RDC permitieron mantener valores estables de Φ_P cercanos a 0.8, evitar caídas severas de Ψ_s por debajo del umbral crítico y sostener un LAI adecuado durante el periodo de máximo crecimiento. Además, se estimó el punto de pérdida de turgor (TLP) mediante curvas presión-volumen, con valores más negativos en La Esperanza (-2.54 MPa) que en Río Claro (-2.20 MPa), reflejando una mayor tolerancia al estrés hídrico en el primer sitio.

Finalmente, aunque se evaluó la factibilidad de replicar los enfoques utilizados para el modelado del Ψ_s en la estimación horaria del turgor foliar, no fue posible utilizar los datos obtenidos a partir de sensores YARA-ZIM. La alta sensibilidad de los sensores generó variaciones en la magnitud de los registros tras cada recalibración, y el preprocesamiento necesario para estabilizar las series eliminó diferencias entre sensores, impidiendo un análisis confiable entre tratamientos y temporadas.

Introducción

El cambio global ha provocado una intensificación de la sequía en distintas áreas del mundo. Entre ellas, Chile Central se caracteriza por presentar un evento de Mega Sequía con pocos análogos en los últimos milenios, registrando desde el 2010 una secuencia ininterrumpida de años con déficits de lluvia promedio de un 20-40% (Garreaud et al. 2020). Este tipo de fenómenos puede llegar a tener importantes impactos en la disponibilidad de agua en cantidad y calidad necesaria para actividades agrícolas, pudiendo repercutir de manera significativa sobre factores sociales y económicos (Garreaud et al. 2020; Peña-Guerrero et al. 2020). Ante este escenario, se requieren estrategias de gestión del agua más eficientes que permitan a los productores agrícolas adaptarse a la variabilidad climática (Hurlbert y Gupta 2017).

En este contexto, el riego deficitario controlado (RDC) ha sido identificado como una estrategia eficaz para optimizar el uso del agua en cultivos perennes como los frutales, donde las opciones de adaptación son limitadas (Pechan et al. 2023). Esta práctica permite reducir el consumo hídrico sin afectar significativamente la producción ni la calidad de la cosecha, mejorando la eficiencia del recurso disponible (Victor Blanco et al. 2019; López-Olivari y Ortega-Klose 2021). Entre los frutales de exportación, el cerezo es el segundo producto de mayor valor en la agroindustria chilena, con más de 25.000 hectáreas bajo riego y un mercado aproximado de 1.560 millones de dólares (Carrasco-Benavides, Antunez-Quilobrán, et al. 2020; González 2022). La optimización del riego en este cultivo es fundamental para mejorar la sostenibilidad del sector y mantener su competitividad a nivel internacional. Para ello, el potencial hídrico xilemático del tallo (Ψ_s ; s por *steam* o tallo en inglés)—medido a mediodía—se ha establecido como un indicador confiable del estado hídrico de la planta, reflejando tanto las condiciones del suelo como la demanda atmosférica y la respuesta fisiológica del cultivo (Moriana et al. 2012; Naor 2000). Su medición tradicional, mediante cámaras de presión (Scholander et al. 1964), es laboriosa y poco escalable, lo que ha impulsado el desarrollo de métodos alternativos basados en sensores remotos y modelos predictivos (Jones 2004).

El turgor, o presión de turgencia, también es un indicador efectivo del estado hídrico de las plantas. Se define como la presión interna que ejerce el contenido celular contra la pared celular, resultado de la acumulación de agua en la vacuola (Halbritter et al. 2020). Esta presión es crucial para mantener la rigidez de las células vegetales, lo que lo convierte en un parámetro clave, junto con el potencial hídrico del tallo, para evaluar el estado hídrico de la planta. El turgor puede medirse mediante diversos métodos, siendo los sensores de turgor, como el ZIM, uno de los más empleados debido a su simplicidad y aplicabilidad a prácticamente todas las especies de hojas planas (Bader et al. 2014). A pesar de las limitaciones que presentan en condiciones de campo, su fiabilidad ha sido confirmada en numerosos estudios (Ali et al. 2023;

Fernández et al. 2011; Lee et al. 2012), lo que respalda su uso en la investigación del manejo del agua en cultivos.

Avances recientes en teledetección y aprendizaje automático han permitido estimar indirectamente el Ψ_s mediante el uso de datos espectrales y meteorológicos, ofreciendo una solución escalable para el manejo del riego en tiempo real (Carrasco-Benavides et al. 2022; Garofalo et al. 2023; Savchik, Nocco, y Kisekka 2025). Satélites como Sentinel-2 (S2), con su alta resolución espacial y frecuencia de revisita, permiten monitorear el estado hídrico de los cultivos a través de índices espectrales y térmicos, que actúan como proxies del estrés hídrico (Addabbo et al. 2016; Jamshidi, Zand-Parsa, y Niyogi 2021; Zhang et al. 2017). Estudios recientes han demostrado la viabilidad de predecir el Ψ_s en cultivos como almendros, olivos y cerezos mediante algoritmos de machine learning, como Random Forest y redes neuronales, alcanzando precisiones variables según las condiciones ambientales y las técnicas empleadas (Savchik, Nocco, y Kisekka 2025; Garofalo et al. 2023; Carrasco-Benavides et al. 2022).

El objetivo principal de esta investigación es optimizar el riego en cerezo, mejorando la eficiencia en el uso del agua mediante un diagnóstico continuo del estrés hídrico de las plantas, a través de la medición del potencial hídrico xilemático del tallo y el turgor de la hoja. Para ello, se plantean los siguientes objetivos específicos: (i) evaluar la respuesta de los cerezos a distintos tratamientos de riego deficitario controlado (RDC) mediante el monitoreo de parámetros fisiológicos (Ψ_s , fluorescencia, LAI), variables productivas y calidad de fruta; (ii) evaluar tres algoritmos de machine learning (Random Forest, XGBoost y SVM) para el modelado del Ψ_s , integrando datos de Sentinel-2 y datos meteorológicas; (iii) desarrollar un prototipo de servicio web (*SatOri*) que proporcione predicciones de la variación espaciotemporal del Ψ_s y recomendaciones de riego en tiempo real; y (iv) evaluar la factibilidad de replicar los enfoques utilizados para el Ψ_s en la estimación de turgor de manera horaria.

Parte I

Metodología

1 Área de estudio

El estudio se llevó a cabo en cultivos de cerezos (*Prunus avium* L., variedad Regina) ubicados en dos predios pertenecientes a la propiedad de la compañía [Garcés Fruit](#): campos “La Esperanza” y “Río Claro” (ambos ubicados en la Región O’ Higgins; Figura 1.1a y Figura 1.1b). En cada uno de ellos se seleccionó una parcela, la cual fue a su vez subdividida en 5 grupos. Esta unidad experimental estuvo constituida por 40 árboles agrupados en 8 filas y 5 columnas (400 m²). Todas las unidades presentaron las mismas condiciones de fertilización, poda, control de malezas y de plagas, las cuales se ajustaron a los estándares y prácticas habituales de Garcés Fruit, siendo la principal diferencia entre ellos el tratamiento de irrigación aplicado.

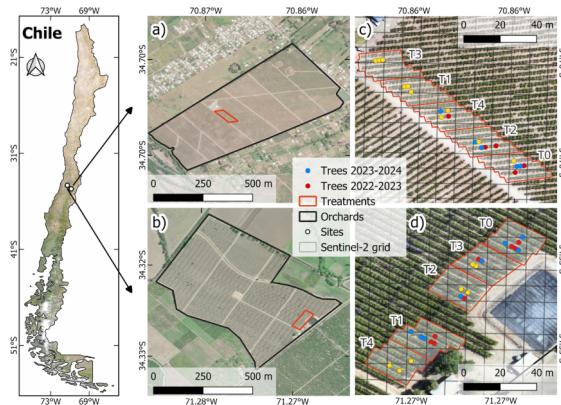


Figura 1.1: Área de estudio. El mapa a la izquierda muestra la ubicación de los huertos en la región central de Chile. Los mapas a la derecha muestran los huertos en (a) Río Claro y (b) La Esperanza, y (c) y (d) representan los tratamientos de riego (T0, T1, T2, T3, T4). Los puntos rojos y azules representan los árboles experimentales seleccionados para las temporadas 2022-2023 y 2023-2024, respectivamente, mientras que los puntos amarillos indican los árboles seleccionados para ambas temporadas.

El clima de la región es mediterráneo (Csb según la clasificación de Beck et al. (2018)), con precipitaciones moderadas que oscilan entre 200 y 500 mm año¹ en los últimos 10 años. Las lluvias se concentran en invierno, seguido de una estación seca prolongada de 7 a 8 meses (Chile 2025). Cada huerto cuenta con una estación meteorológica privada ubicada a 0.6 km del centro en Río Claro y 1.4 km del centro en La Esperanza, respectivamente.

1.1 Tratamientos de riego deficitario

Para aumentar la variabilidad del estado hídrico de las plantas, se implementaron cinco tratamientos diferentes de reposición de riego en cada huerto. La cantidad de riego se gestionó utilizando el ET0 y Ψ_s como referencias. Los tratamientos de riego fueron T1, T2, T3 y T4, siendo T1 el menos restrictivo y T4 el más restrictivo en cuanto al suministro de agua (Figura 1.1c y Figura 1.1d). Además, se estableció un tratamiento control (T0), el cual recibió el riego estándar proporcionado por el productor local. Cada parcela de tratamiento contuvo 60 árboles y abarcó un área de 0.048 ha. Los tratamientos se aplicaron durante las temporadas consecutivas de crecimiento 2022–2023 y 2023–2024. No obstante, en la segunda temporada no se aplicaron los tratamientos T1 a T4 en La Esperanza, ya que los resultados obtenidos en la temporada anterior no mostraron un impacto significativo de los tratamientos de restricción hídrica. La Figura 1.2 ilustra la profundidad acumulada de agua (mm) para cada tratamiento durante el riego, así como el porcentaje relativo a ET0.

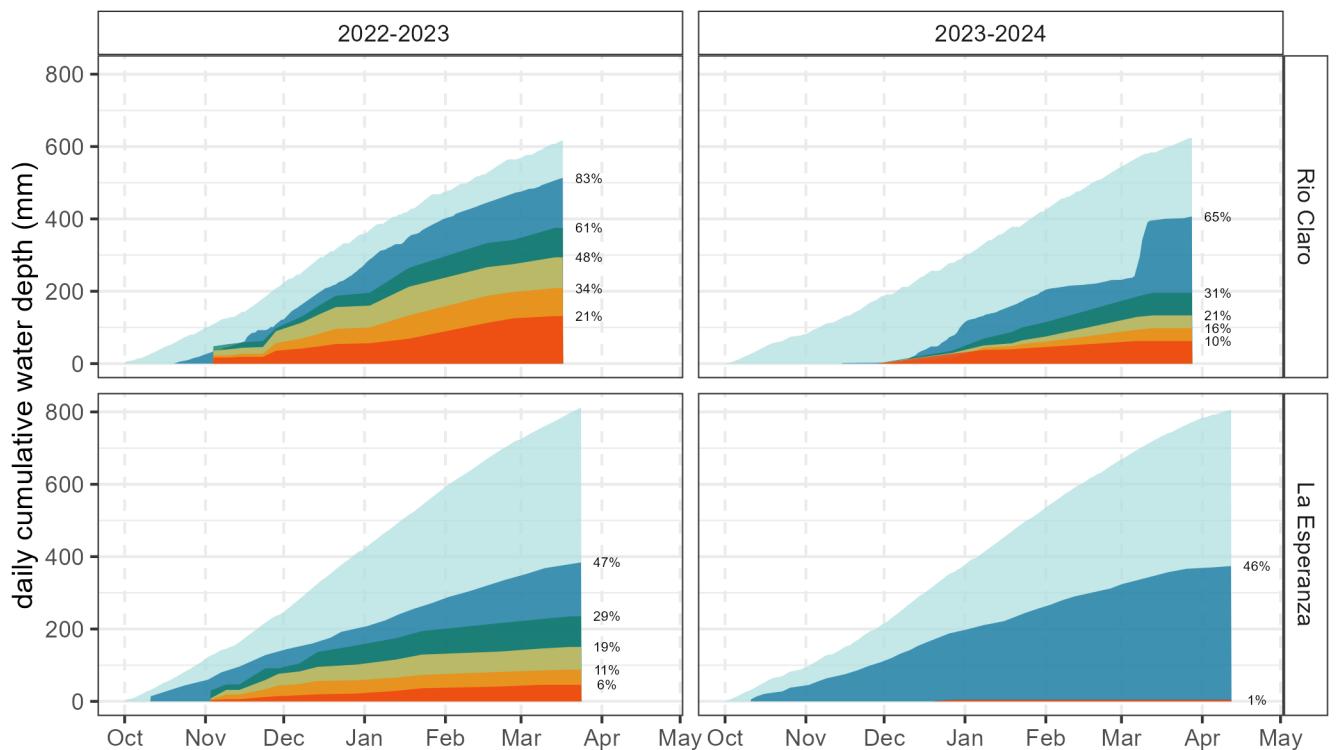


Figura 1.2: Variación de la profundidad acumulada diaria de agua (mm) aplicada por riego por tratamiento en comparación con la evapotranspiración de referencia (ET0). El punto de inicio para la acumulación de ET0 corresponde al primer día de riego para cada huerto y temporada.

2 Parámetros fisiológicos

2.1 Potencial hídrico xilemático (Ψ_s) y fluorescencia

Posterior a la instalación del sistema de riego diferenciado, se seleccionaron tres árboles por tratamiento (un total de 15 árboles por campo), teniendo en consideración el efecto de borde, esto con el propósito de monitorear en el tiempo el estatus hídrico de cada planta (tres réplicas por tratamiento). Para ello se emplearon 2 indicadores: (1) **Potencial hídrico xilemático de tallo al mediodía (Ψ_s)**; cuyas mediciones son consideradas el proxy más preciso del estado hídrico para los cerezos dulces (Víctor Blanco et al. 2019; Victor Blanco et al. 2019; Carrasco-Benavides, Meza, et al. 2020; Carrasco-Benavides, Antunez-Quilobrán, et al. 2020; E et al. 2023). (2) **Fluorescencia**; el cual constituye un indicador de eficacia de la actividad e integridad de la fotosíntesis y el contenido de la clorofila; lo que permite estudiar mecanismos de respuesta ante condiciones de estrés hídrico (Linke, Herppich, y Geyer 2010; Jiménez-Suancha, S., y Balaguera-López 2015).

Para la medición de estos indicadores se realizaron visitas quincenales a cada campo. En lo que respecta a la medición de Ψ_s , la misma se realizó sobre muestras de hojas colectadas entre 12:00-14:00 h provenientes de cada una de los 15 árboles monitoreados. En cada caso, se seleccionaron hojas maduras y en buen estado, ubicadas en el tercio medio del árbol, con orientación este y cercanas al tronco (McCutchan y Shackel 2019; Marsal et al. 2010; Víctor Blanco et al. 2019). Antes de ser cortadas, cada una de ellas fue envuelta por un período de 30 min en bolsas de papel de aluminio, a modo de lograr bloquear la transpiración y la radiación solar. Posterior a este período, cada hoja fue cortada por el pecíolo y colocada al interior de la cámara Scholander conectada a un cilindro de nitrógeno (Modelo 3000, Soil Moisture Equipment, Santa Barbara, CA, EEUU), donde se aplicó presión negativa hasta observar gotas de agua en el extremo del pecíolo cortado, registrándose la cantidad de megapascales (MPa) necesarios para extraer la primera gota de jugo xilemático.

En lo que respecta a la medición de la fluorescencia, se usó el fluorómetro PAR-FluorPen FP 110/D (PSI, Czech), empleando el método de transitorios de fluorescencia OJIP. Este método permitió obtener diferentes parámetros de rendimiento cuántico de la actividad fotosintética en el PSII y evaluar el potencial impacto del riego deficitario sobre este proceso (Küpper et al. 2019). Para obtener una medida de los parámetros de fluorescencia de la clorofila, el fluorómetro consta de un medidor de luz integrado para lecturas digitales directas de la radiación fotosintéticamente activa en el rango 400 a 700 nm. Para lograr una emisión de fluorescencia roja, es necesario exponer a la luz, hojas que previamente se encontraban

adaptadas a la oscuridad (Moreno, Vela, y O Salcedo Alvarez 2008). Con este fin, el equipo consta de unos dispositivos o “clips”, que se colocan en la hoja previamente y que permiten bloquear todo acceso de luz a una porción de la misma. En nuestro caso, se utilizaron 4 clips por árbol del muestreo, los cuales fueron colocados entre las 11:00-13:00 h, seleccionando hojas que se encontrasen maduras, en buen estado, dentro del tercio medio del árbol y orientadas directamente al sol. Pasado el período de adaptación a la oscuridad (20 minutos), se procedió a hacer las mediciones directas con el fluorómetro, el cual dispone de una memoria interna que permite almacenar los datos de manera secuencial. A efecto de los análisis, se utilizó la M+axioma Eficiencia Quántica del Fotosistema II o F_v/F_m .

2.2 Punto de pérdida de turgor (TLP)

El punto de pérdida de turgor (TLP, por sus siglas en inglés) se define como el valor de potencial hídrico en el que la presión de turgor en las células se reduce a cero, lo que indica el inicio del colapso celular por déficit hídrico (Halbritter et al. 2020). Este punto se determinó a partir de la presión osmótica previa al inicio de la fase lineal de deshidratación en la curva presión-volumen (Tyree y Hammel 1972). Las curvas presión-volumen describen la relación entre Ψ_s y el contenido relativo de agua (RWC) de una hoja durante un proceso controlado de deshidratación, y permiten estimar otros parámetros fisiológicos como el potencial osmótico a plena turgencia (Ψ_o) y el módulo de elasticidad celular (ε) (Meinzer et al. 2016).

Las curvas se generaron midiendo el Ψ_s mediante una cámara de presión de Scholander, utilizando hojas recolectadas antes de las 12:00 h (coinciéndiendo con el punto de máxima demanda hídrica), asegurando mayor turgencia, según la metodología propuesta por Halbritter et al. (2020). Las muestras se envolvieron en plástico, colcandole papel higiénico hidratado en el peciolo cortado y se refrigeraron para minimizar pérdidas de agua. Cada muestra se pesó antes y después de cada medición de Ψ_s , insertándose en la cámara con el corte expuesto y aplicando presión gradual (0.1 bar/seg) hasta observar exudación de agua. Tras cada medición, las muestras se secaron al aire, repitiendo el proceso cada 2–5 minutos inicialmente y luego cada 15 minutos–2 horas hasta obtener 6–8 puntos en la zona lineal de la curva. El contenido relativo de agua (RWC) se calculó como:

$$[(peso_{fresco} - peso_{seco}) / (peso_{turgente} - peso_{seco})] \times 100$$

, donde el peso fresco fue el peso después de cada medición de Ψ_s , el peso turgente el inicial y el peso seco tras secado a 70°C por 72 h. Los datos se graficaron como $1/\Psi_s$ vs $RWD = (100 - RWC)$, determinándose el punto de pérdida de turgencia (TLP) como el último punto de la curva de Ψ_s en función del RWD antes de comenzar su fracción lineal, como se muestra en la Figura 2.1.

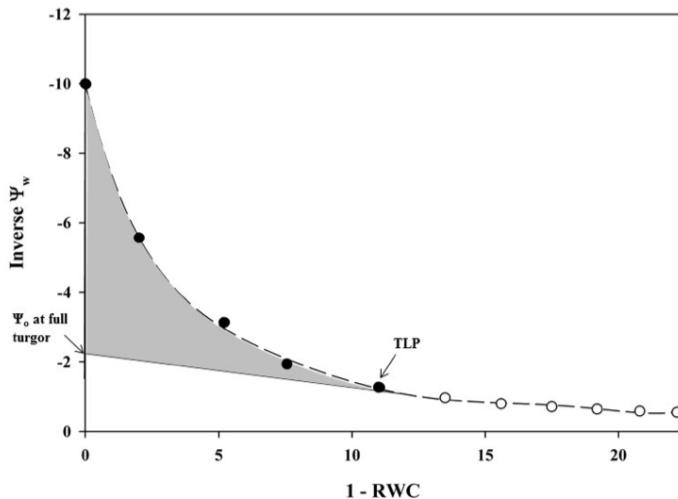


Figura 2.1: Ejemplo de una curva presión-volumen. Los círculos llenos representan las primeras 5 mediciones iterativas: los círculos abiertos representan las últimas 6 mediciones. La porción lineal (línea sólida) muestra el potencial osmótico (Ψ_o), la porción curva (línea discontinua) es el potencial hídrico antes del punto de pérdida de turgencia (TLP), y el área sombreada es el potencial de turgencia (Ψ_p). Fuente: Halbritter et al. (2020).

2.3 Presión de turgor en la hoja

La presión de turgor foliar fue monitoreada mediante sensores YARA ZIM, los cuales consisten en dos pequeños imanes que se sujetan a ambos lados de una hoja y registran valores cada 15 minutos en unidades de kPa. Se instaló un transmisor por árbol en los mismos tres árboles seleccionados por tratamiento, y en cada uno se colocaron dos sensores. La instalación siguió un protocolo estandarizado que consideró hojas maduras (no jóvenes), sanas, sin heridas, limpias, orientadas hacia el este y ubicadas en la mitad superior del árbol. Además, se evitó posicionar los sensores sobre la nervadura central para asegurar una lectura estable. Debido a la alta sensibilidad del sistema frente a perturbaciones físicas (como viento, caída de hojas o contacto accidental), fue necesario realizar recalibraciones manuales en múltiples ocasiones a lo largo de la temporada.

Dado que la magnitud y el rango de los valores registrados varía incluso entre la misma hoja después de la recalibración, se implementó un procedimiento de preprocessamiento basado en tres etapas Figura 2.2: filtrado, agrupamiento y modelado. En primer lugar, se eliminaron los registros inconsistentes según tres criterios: (i) estabilidad en la serie de tiempo (diferencias estandarizadas < 1), (ii) correlaciones esperadas con la temperatura del aire y el déficit de presión de vapor (positiva y negativa, respectivamente), y (iii) una correlación mínima de 0.5 con al menos una de estas variables. Luego, los datos fueron agrupados por sitio, temporada

y sensor, resumiendo cada día mediante la mediana, el valor máximo y el mínimo, y se aplicó el algoritmo DBSCAN para identificar patrones coherentes. Finalmente, se ajustaron modelos lineales entre los valores de turgor y los dos primeros componentes principales (PC1 y PC2), a partir de los cuales se generó una serie modelada que fue escalada para su análisis y comparación.

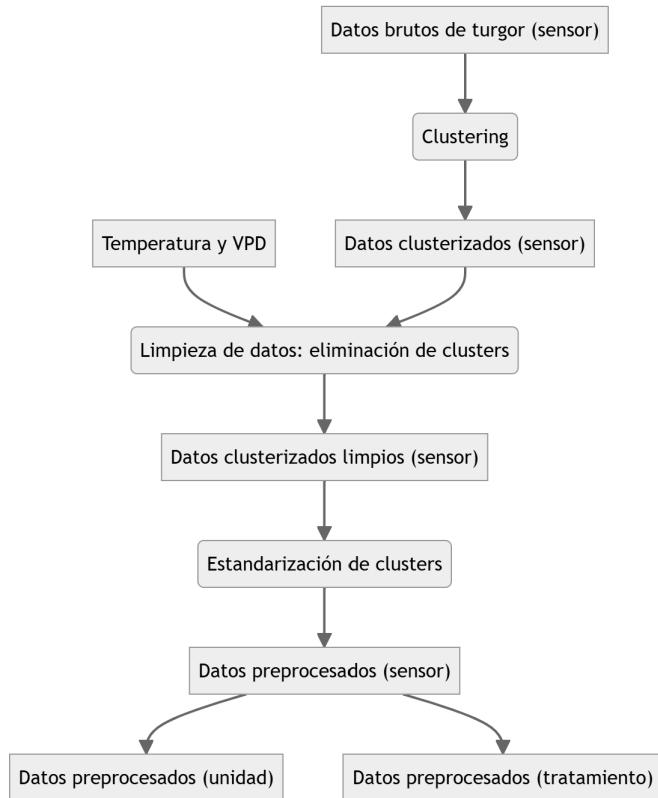


Figura 2.2: Preprocesamiento de datos de presión de turgor foliar. Los cuadros con vértices rectos representan datos, mientras que los redondeados los procesos utilizados

3 Parámetros de producción y calidad

3.1 Cosecha y frutos

Las cosechas se llevaron a cabo siguiendo el cronograma y la planificación de Garcés Fruit. Las mismas se realizaron el 12/12 del 2022 y 2023 en el campo La Esperanza y el 21/12 del 2022 en el campo Río Claro. En estas fechas, se recolectó la totalidad de los frutos para los mismos tres árboles por tratamiento seleccionados para muestrear los parámetros fisiológicos. Posteriormente, utilizando una balanza electrónica modelo SF-400 (peso máximo 10kg), se colectó al azar el equivalente de un 1kg de cerezas por cada árbol, los cuales fueron almacenados en envases plásticos y refrigerados en coolers para su posterior traslado al laboratorio.

Una vez en el laboratorio, las muestras de 1 Kg de cerezas por árbol fueron almacenadas en un refrigerador a 4°C. En un plazo menor de 72 h cada una de ellas fue analizada para evaluar la calidad de fruto, de manera de evitar degradaciones relacionadas con el tiempo de almacenamiento. Para ello, se tomó una submuestra al azar de 20 cerezas por árbol, siguiendo una metodología similar a Víctor Blanco et al. (2019) , para un total de 60 cerezas por tratamiento. La única condición para que una cereza fuese seleccionada, es que la misma se encuentre en buen estado, esto para disminuir la probabilidad de desviaciones relacionadas con daños experimentados durante el traslado e incurrir en el error de medir cerezas defectuosas.

3.2 Producción y calidad

Para determinar la producción de los cerezos, se midieron dos variables: el *peso total* y *densidad*. El peso total (kg) se obtuvo mediante el pesaje directo de la producción de cada árbol en campo, utilizando una balanza digital modelo ACS-30 LED con una capacidad máxima de 30 kg. Por otro lado, la densidad de producción (frutos/kg) se determinó dividiendo el conteo total de cerezas recolectadas entre el peso total correspondiente.

Las muestras de 1 kg de cada árbol almacenadas y refrigeradas fueron examinadas de manera meticulosa en su totalidad, contabilizando aquellas cerezas que presentarán deformaciones y defectos en su forma o superficie, tales como pitting, pudrición, fisuras pronunciadas, sobremaduración, daños en la piel, palidez y frutos dobles. Se guardó registro fotográfico de las cerezas identificadas con daños para su posterior revisión y categorización en el laboratorio. Para esta caracterización se usó como base la [guía Australian Cherry Quality Guide](#)

Por el otro lado, la calidad de las frutas se evaluó considerando las siguientes variables asociadas a los estándares comerciales: peso por unidad (gr), calibre (diametro; mm) y color. Para medir peso (gr) se utilizó una balanza analítica de laboratorio, mientras que para estimar el calibre se empleó un pie de metro digital (0-150 mm). En lo que respecta al color, se siguió la [carta de color](#) y la metodología recomendada por el Instituto Nacional de Tecnología Agropecuaria (INTA). Para ello se empleó una escala numérica del 1-6 , la cual variaba desde un rojo pálido (1) a un caoba oscuro (6). Finalmente, de cada sub-muestra se seleccionaron al azar 5 cerezas adicionales (15 por tratamientos), con las mismas se procedió a medir concentración de sólidos solubles (grados brix) utilizando para ello el refractómetro ATC (Brix 0-32) (Víctor Blanco et al. 2019).

4 Modelado espacial diario de Ψ_s

4.1 Predictores espacio-temporales

Variables meteorológicas

Las variables meteorológicas utilizadas en el desarrollo del modelo de Ψ_s se obtuvieron a partir de estaciones meteorológicas automáticas en ambos huertos, las cuales registraron datos cada 15 minutos utilizando el modelo ATMOS-41 del grupo METER. Estas variables fueron temperatura (T), humedad relativa (HR), déficit de presión de vapor (VPD), precipitación (PP) y evapotranspiración de referencia ($ET0$).

4.1.0.1 Temperatura

4.1.0.2 Humedad Relativa

4.1.0.3 Déficit de presión de vapor (VPD)

4.1.0.4 Evapotranspiración de referencia (ET0)

4.1.0.5 Precipitación

Además de las variables meteorológicas, también se recopilaron datos de humedad del suelo. Para esto, se utilizaron sensores de humedad del suelo Water Scout SM100 (Spectrum Technologies, Inc.), los cuales miden en tiempo real el contenido volumétrico de agua (VWC). Estos sensores se instalaron a 15 cm de profundidad bajo cada árbol de los tratamientos.

4.1.0.6 Temporada 2022-2023

4.1.0.7 Temporada 2023-2024

Datos de teledetección y IVs

Para obtener variabilidad espacial en el modelamiento de Ψ_s , se utilizó información satelital a partir del satélite Sentinel-2 (S2). La misión S2 consta de dos satélites idénticos, S2A y

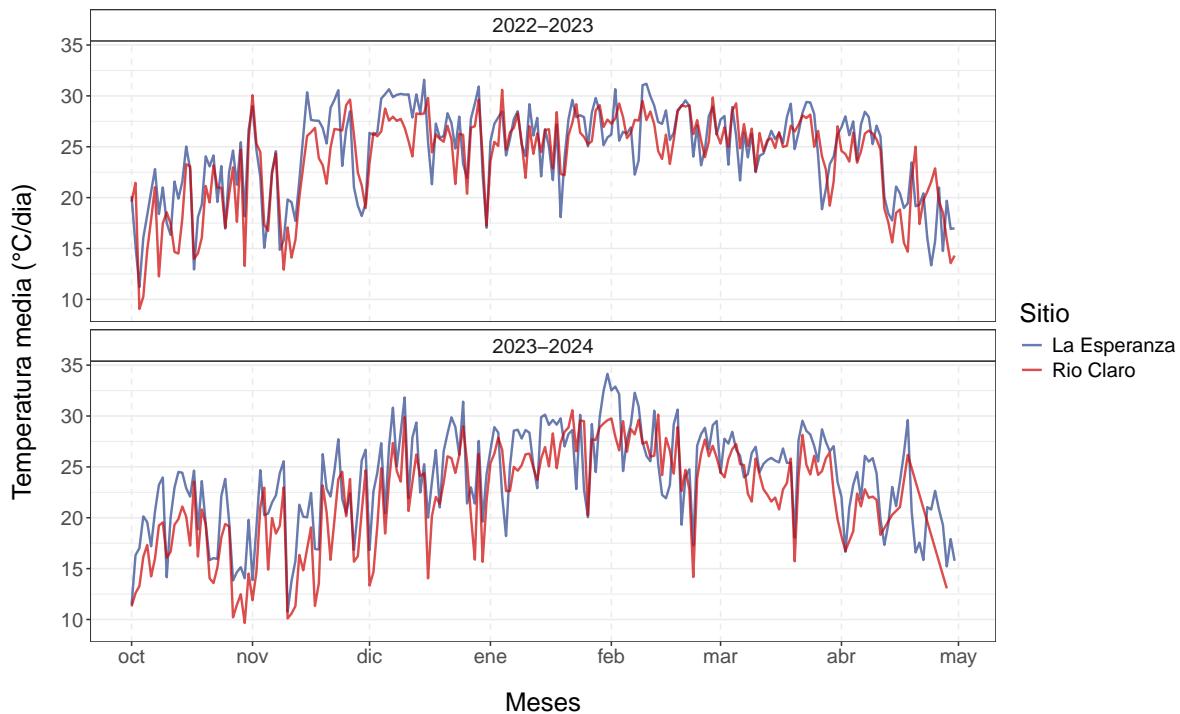


Figura 4.1: Variación de la temperatura media diaria ($^{\circ}\text{C}$) del medio día en La Esperanza y Río Claro durante las temporadas 2022-2023 y 2023-2024.

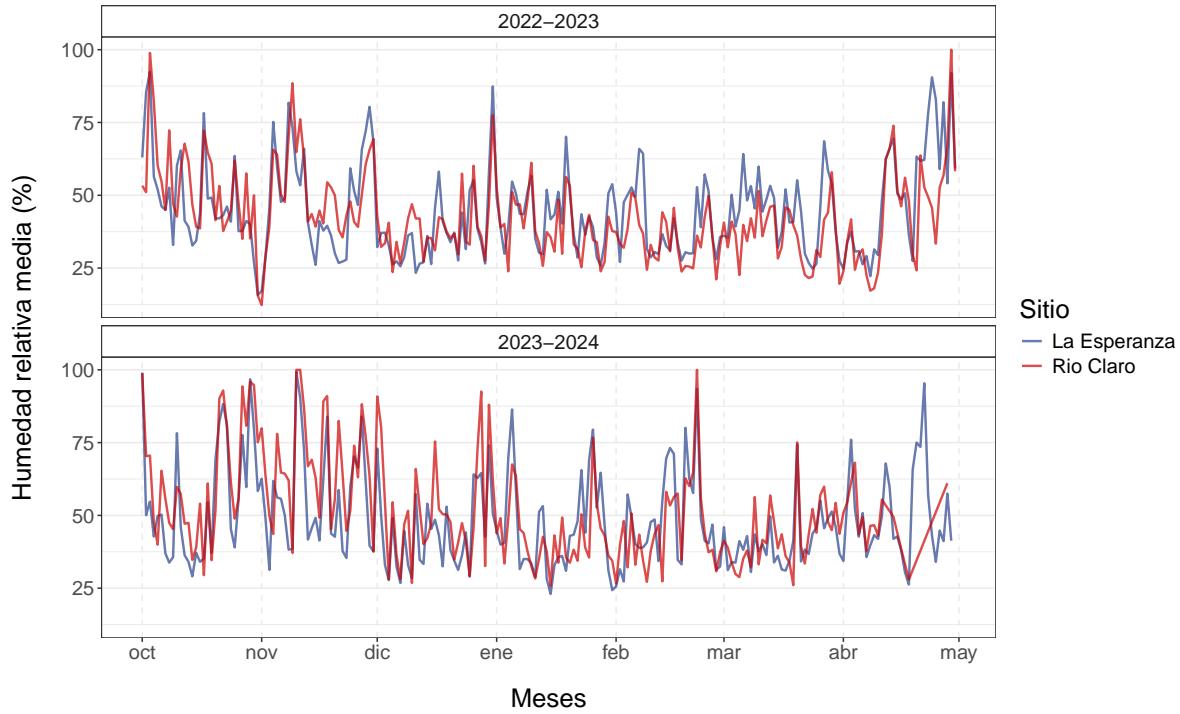


Figura 4.2: Variación de la humedad relativa media diaria (%) del medio día en La Esperanza y Río Claro durante las temporadas 2022-2023 y 2023-2024.

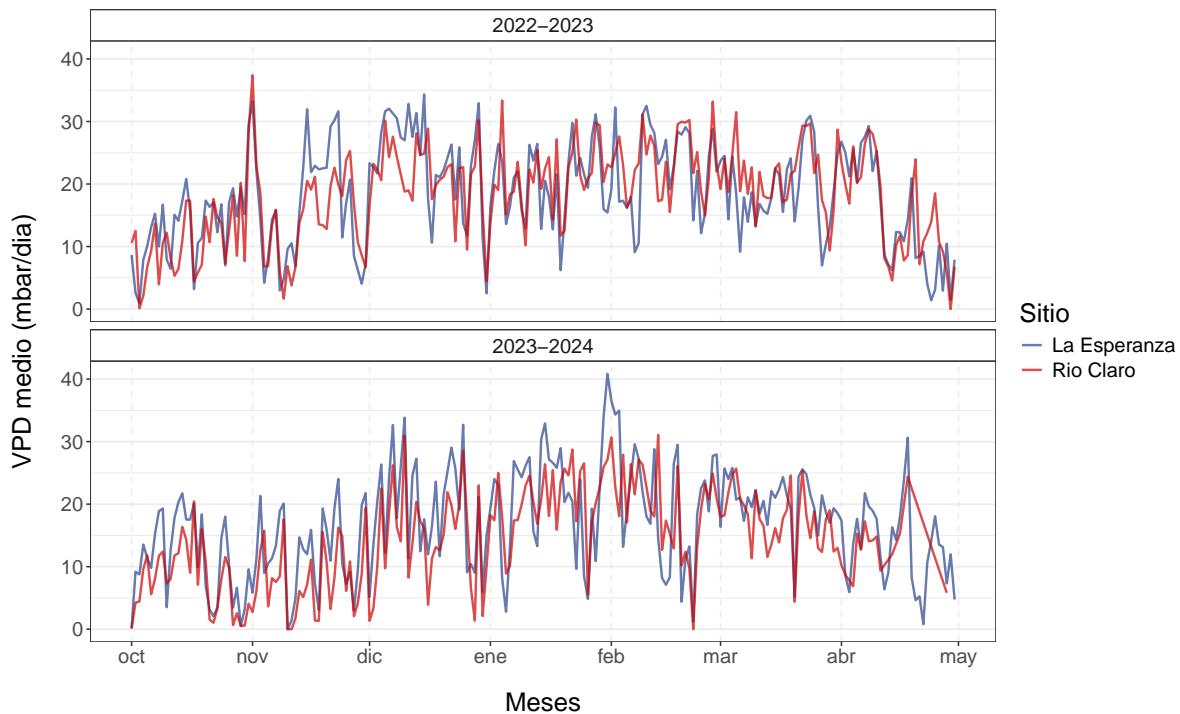


Figura 4.3: Variación del VPD medio (mbar/dia) del medio día en La Esperanza y Río Claro durante las temporadas 2022-2023 y 2023-2024.

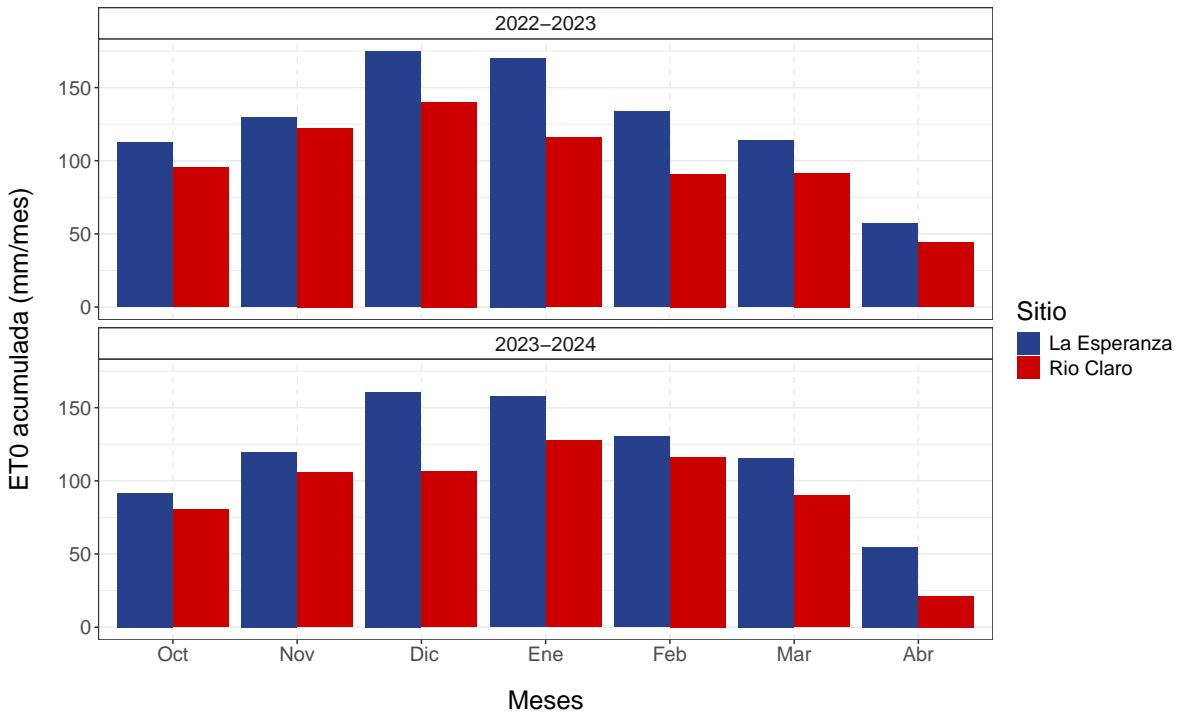


Figura 4.4: Variación de la evapotranspiración de referencia acumulada mensual (mm) en La Esperanza y Río Claro durante las temporadas 2022-2023 y 2023-2024.

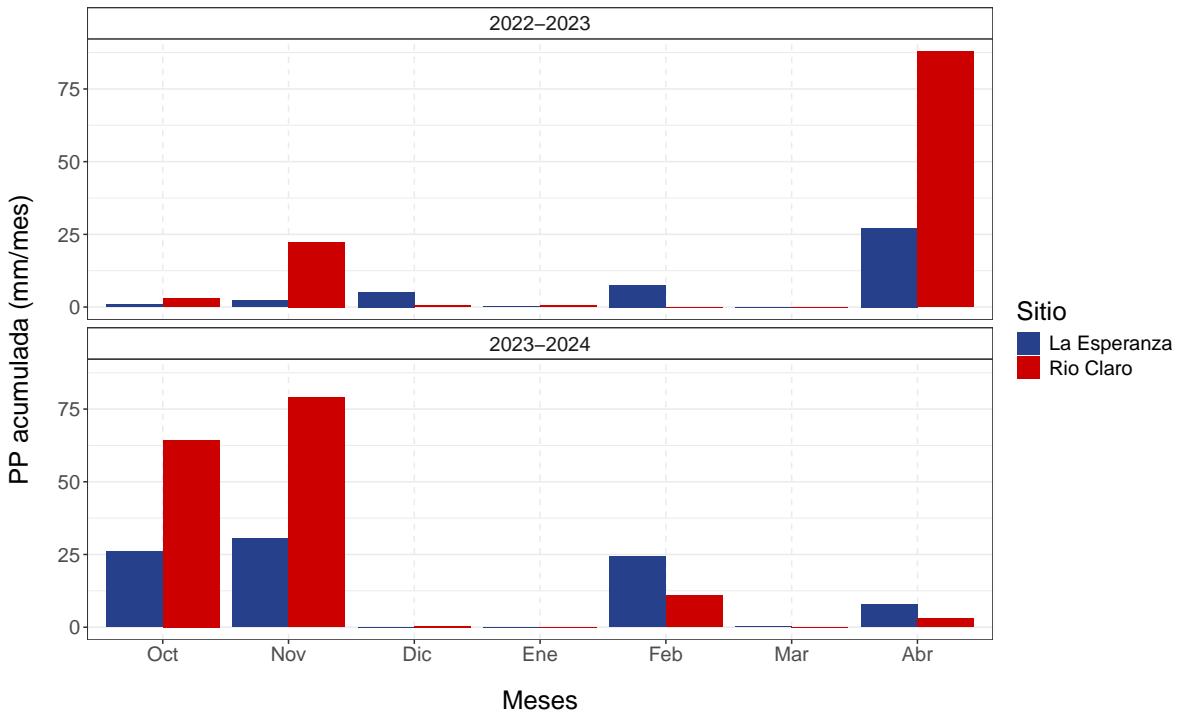
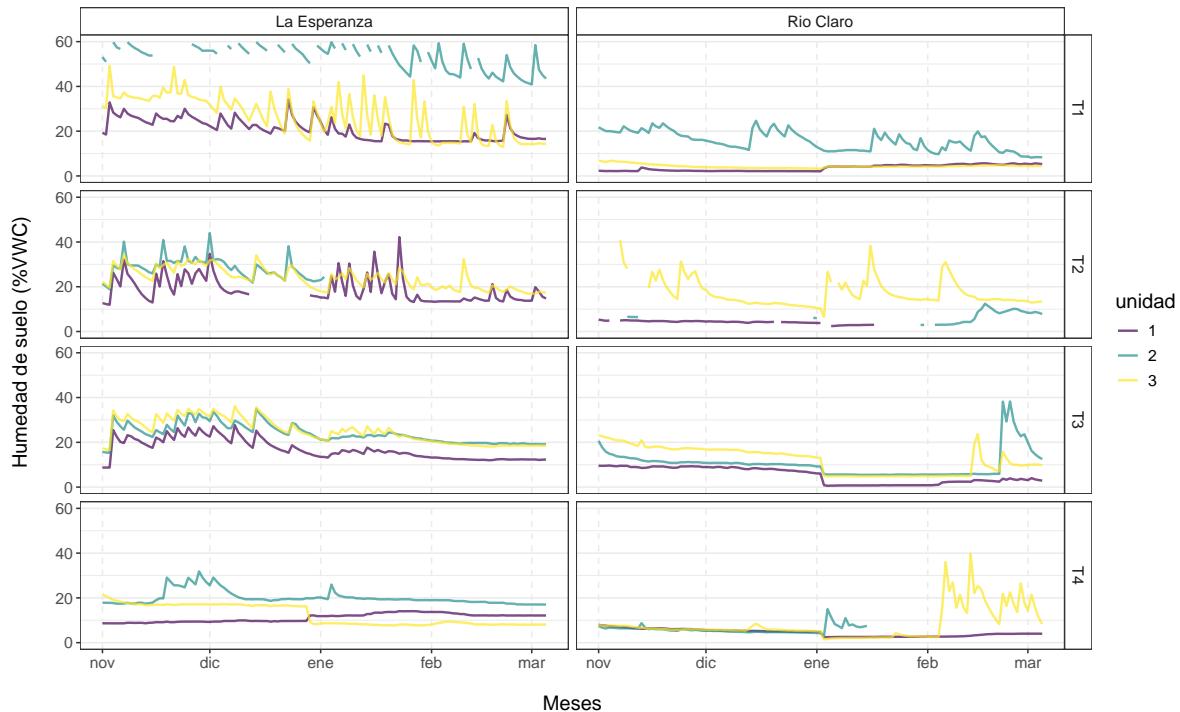


Figura 4.5: Variación de la precipitación acumulada mensual (mm) en La Esperanza y Río Claro durante las temporadas 2022-2023 y 2023-2024.



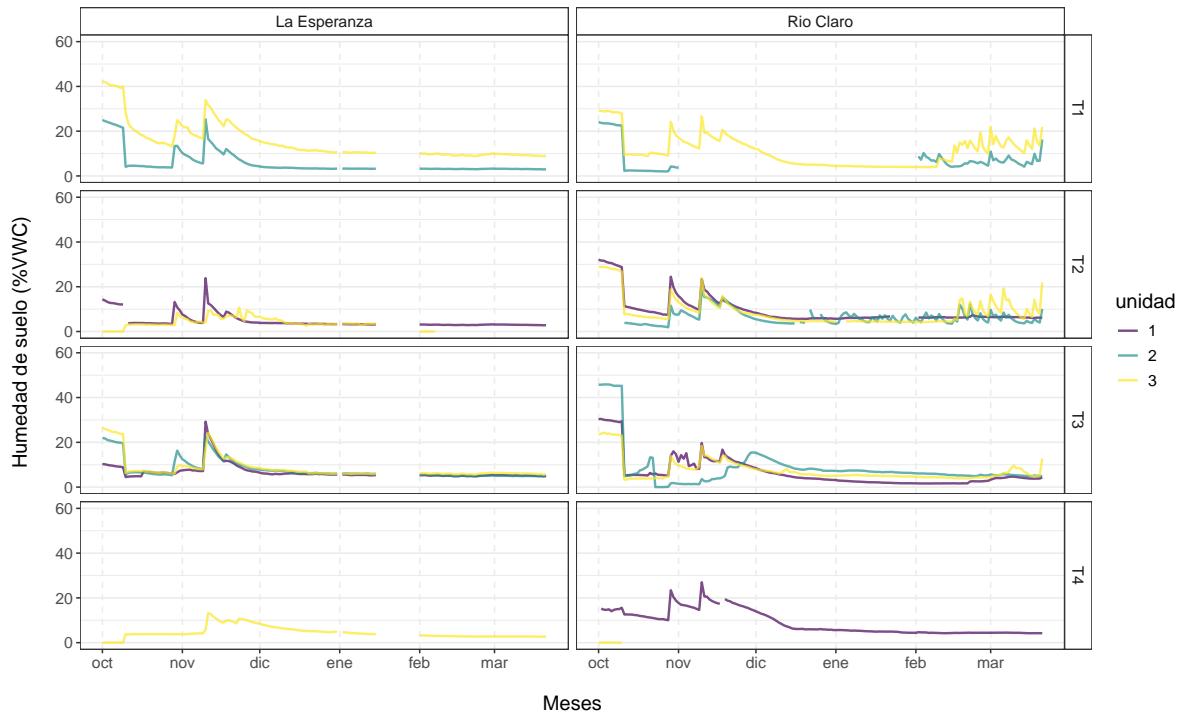


Figura 4.7: Variación de la humedad de suelo media (%VWC) al medio día en La Esperanza y Río Claro en los distintos tratamientos durante la temporada 2023-2024.

S2B, ambos equipados con un sensor multiespectral que cuenta con 13 bandas espectrales que cubren las regiones visible, infrarrojo cercano e infrarrojo de onda corta, con resoluciones espaciales de 10, 20 y 60 m (ver Tabla S2). En este estudio, utilizamos un total de 106 imágenes S2 (A/B): 54 para la temporada 2022-2023 y 52 para la 2023-2024, capturadas entre octubre y mayo en ambos huertos (cuadrícula T19HCB para La Esperanza y T19HBB para Río Claro). Las imágenes se obtuvieron de la colección corregida atmosféricamente S2 Level-2A de Planetary Computer (Microsoft Open Source et al. 2022), con una frecuencia de 5 días y aproximadamente a las 14:30 hora local (UTC-4). Una máscara fue aplicada basándose en la capa de clasificación de escena (SCL) para los valores correspondientes a “Cloud Shadows,” “Cloud Medium Probability,” y “Cloud High Probability.”

A partir de estos datos de S2, se derivaron dieciséis índices de vegetación (IVs) relacionados con la condición de las plantas vigor, estrés, funcionalidad fotosintética y contenido hídrico. De estos, nueve índices no incorporaron información del red-edge (borde rojo), calculándose exclusivamente con bandas espectrales del visible, infrarrojo cercano (NIR) e infrarrojo de onda corta (SWIR): NDVI, EVI, GCI, NDWI, NBR, NDMI, MSI, NMDI y DWSI. Por otro lado, siete índices —CLR, Clg, NDRE1, NDRE2, NDCI, mSR705 y RESI— se obtuvieron mediante las bandas del red-edge. Todos los índices fueron calculados a partir de las imágenes preprocesadas de las bandas de S2, generándose series temporales para cada IV en ambos huertos y temporadas.

Para reconstruir las series temporales (ej. en zonas afectadas por nubosidad), se aplicó un suavizado mediante regresión polinomial local (LOESS) (Cleveland 1979). El método LOESS se configuró con un parámetro de suavizado (span) de 0.3, obteniéndose así series diarias continuas y suavizadas para cada índice, las cuales posteriormente fueron extraídas para cada árbol medido. Se llevó a cabo un análisis de correlación para evaluar la relación entre estas series suavizadas y los valores observados de Ψ_s . El coeficiente de correlación de Pearson (r) fue calculado diariamente para cada árbol, huerto y temporada, utilizando exclusivamente correlaciones significativas ($p\text{-value} < 0.05$) para el cálculo de los valores promedio.

4.2 Modelos de machine learning

Para modelar el Ψ_s , se evaluaron tres algoritmos de machine learning:

- **Extreme Gradient Boosting** (XGBoost; Chen y Guestrin (2016))
- **Random Forest**(RF; Tin Kam Ho (1995))
- **Support vector Machine** (SVM; Cortes y Vapnik (1995))

Los dos primeros métodos se basan en árboles de decisión, mientras que el tercero utiliza vectores de soporte. Estos modelos fueron seleccionados por ser considerados de vanguardia, requerir un número reducido de muestras de entrenamiento (en comparación con redes neuronales) y ofrecer interpretabilidad. Todos los algoritmos pueden emplearse tanto para clasificación como para regresión. En este estudio, se realizó un análisis de regresión, utilizando

el Ψ_s como variable respuesta y 21 predictores: cinco meteorológicos y 16 índices de vegetación (IVs).

El conjunto de datos incluyó mediciones de 26 fechas en la temporada 2022–2023 y 34 en la 2023–2024 (total: 60 fechas). Para cada fecha, se tomaron 30 mediciones (15 por huerto: Río Claro y La Esperanza), lo que resultó en un total de 883 observaciones. El proceso de modelado siguió las siguientes etapas:

- **Preparación y división de datos:** Segmentación del conjunto de datos en subconjuntos de entrenamiento y prueba.
- **Optimización de hiperparámetros:** Ajuste de los parámetros de los algoritmos utilizando el conjunto de entrenamiento.
- **Remuestreo:** Evaluación de la confiabilidad del modelo e identificación de las variables más relevantes para estimar Ψ_s .
- **Validación:** Evaluación del rendimiento del modelo con métricas de desempeño.

Se entrenaron los tres modelos utilizando dos esquemas de división (Figura 4.8): uno que consideró una división aleatoria de datos de entrenamiento y prueba (*rnd_split*) y otro que utilizó fechas independientes para entrenamiento y prueba (*tme_split*). En ambos casos, se seleccionó el 75% de los datos para entrenamiento y el 25% para prueba. Se aplicaron tres tipos de preprocesamiento a los datos de entrenamiento: i) eliminación de predictores con valores constantes (variables de varianza cero); ii) normalización de predictores (media cero y desviación estándar uno); y iii) una versión del modelo que empleó Partial Least Squares (PLS) para reducir la dimensionalidad, utilizando las cinco componentes principales como predictores. Como resultado, se usaron modelos con predictores normalizados y otros con las componentes principales de PLS.

Para ajustar los parámetros de los modelos (XGBoost, RF, SVM), se empleó optimización de hiperparámetros. Se definieron rangos para cada parámetro y se utilizaron cinco folds de validación cruzada para ambos esquemas de división (*rnd_split* y *tme_split*). La optimización evaluó diez combinaciones de parámetros por modelo. El rendimiento se midió con las métricas R^2 , RMSE (root-mean-square error) y MAE (mean absolute error). Finalmente, los modelos se clasificaron según el RMSE más bajo y el R^2 más alto, seleccionándose aquellos con mejor desempeño.

4.3 Evaluación e importancia de los modelos

Para evaluar el rendimiento de los modelos, se aplicó remuestreo (resampling) sobre el conjunto de entrenamiento en ambos esquemas de división (*rnd_split* y *tme_split*). Se utilizaron cinco particiones y se calcularon las métricas R^2 , MAE (Error Absoluto Medio) y RMSE (Raíz del Error Cuadrático Medio) para cada una de estas.

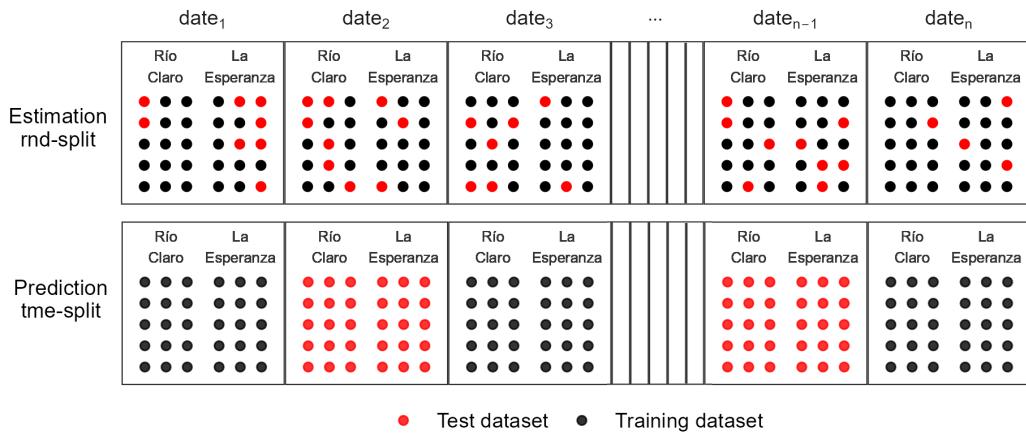


Figura 4.8: Esquemas de división utilizados para agrupar los conjuntos de entrenamiento y prueba: división aleatoria (`rnd_split`) y división temporal independiente (`tme_split`).

En cuanto a la importancia de variables, el modelo de Bosques Aleatorios (RF) empleó un método de permutación *out-of-bag* en cada árbol, permutando los predictores y calculando el error cuadrático medio para cada instancia. Para XGBoost, se estimó la contribución fraccional de cada variable según la ganancia total en las divisiones donde participó. En el caso de SVM, se calcularon puntuaciones de importancia basadas en permutaciones (para más detalles, véase Greenwell y Boehmke (2020)).

5 Plataforma web *SatOri*

A partir del modelo de estimación espacio-temporal del potencial hídrico xilemático, se diseñó un prototipo de plataforma web denominada *SatOri*, orientada a la optimización del riego en los huertos de cerezos de los campos Río Claro y La Esperanza. Con el modelo de estimación espacial y temporal del potencial hídrico como base, y considerando los umbrales TLP previamente definidos, se desarrolló la plataforma utilizando el lenguaje de programación R y las plataformas [Github](#) y [Shinyapps](#).

La plataforma *SatOri* fue implementada mediante el paquete {shiny} de R. En términos operativos, la descarga y el procesamiento automatizado de los datos satelitales y meteorológicos se gestionaron a través de *Github Actions*, que permiten la actualización diaria de los datos de los huertos, de acuerdo con su disponibilidad. Estos datos, provenientes de fuentes satelitales (como las imágenes de Sentinel-2) y meteorológicas, son procesados para suavizar los índices de vegetación. Posteriormente, se aplicó el modelo de machine learning para estimar el potencial hídrico xilemático de cada día, permitiendo a la plataforma ofrecer recomendaciones sobre el tiempo de riego requerido para cada sector.

El sistema de riego en los huertos está segmentado en sectores, por lo que la plataforma *SatOri* adaptó las recomendaciones de riego a esta estructura. Para ello, el valor estimado del potencial hídrico xilemático fue promediado para cada sector y comparado con los valores de umbral establecidos (TLP). En función de esta comparación, se definieron tres zonas de estado hídrico para cada sector de riego: verde, amarillo y naranja. La zona verde corresponde a situaciones en las que el potencial hídrico se encuentra por encima del umbral más un factor de seguridad, lo que representa un estado adecuado de abastecimiento hídrico. La zona amarilla se asocia a un estado intermedio, donde el potencial hídrico se ubica entre el umbral y el umbral más el factor de seguridad, activando una recomendación de riego basada en la evapotranspiración de cultivo de los últimos dos días. Finalmente, la zona naranja representa condiciones por debajo del umbral, lo que activa una recomendación de riego más intensiva, basada en los últimos cinco días de evapotranspiración, con el objetivo de promover una recuperación rápida del estado hídrico.

Parte II

Resultados

6 Parámetros fisiológicos

Los siguientes gráficos muestran la distribución durante el mes, para cada tratamiento, sitio y temporada, de los tres parámetros fisiológicos seleccionados del estudio. Estos fueron la Máxima Eficiencia Quántica del Fotosistema II (F_v/F_m), el Potencial Hídrico Xilemático (Ψ_s) y el Índice de Área Foliar (LAI).

6.1 Fluorescencia

La Esperanza

En la Figura 6.1, se muestran los valores de la eficiencia máxima del fotosistema II (F_v/F_m) durante las temporadas 2022-2023 y 2023-2024 en La Esperanza. Durante ambas temporadas, los valores de F_v/F_m se mantuvieron en torno a 0.8, con algunas fluctuaciones destacadas. En la primera temporada, a mediados de noviembre, todos los tratamientos presentaron una disminución abrupta en sus valores de F_v/F_m , alcanzando 0.5 en T0, T1 y T4. Después, los valores aumentaron rápidamente, superando el 0.8 y alcanzando un pico de 0.85 hacia finales de noviembre. Posteriormente, los valores disminuyeron ligeramente hasta 0.75 y se mantuvieron estables entre 0.7 y 0.8 hasta el final de la temporada. Sin embargo, en T0 se observaron caídas más pronunciadas, alcanzando los 0.65 en dos momentos clave: mediados de enero y principios de marzo. Estos descensos no se presentaron en los otros tratamientos, los cuales mostraron un comportamiento más estable a lo largo de la temporada (salvo en T3 alcanzando ~ 0.7 en ese mismo periodo). En la temporada 2023-2024, el patrón fue muy similar, aunque los tratamientos con riego deficitario controlado (RDC) mostraron valores más bajos en noviembre (llegando a 0.6), mientras que T0 se mantuvo en 0.75. En diciembre y mayo, los valores de F_v/F_m superaron los 0.8 con mayor frecuencia, alcanzando hasta 0.85, mientras que la disminución de enero también fue evidente, con valores cayendo a 0.65 en T0, de forma similar a lo observado en la temporada anterior.

Estos resultados indican que los valores de F_v/F_m en La Esperanza se mantuvieron cercanos a 0.8 durante la mayor parte de las temporadas, con fluctuaciones relacionadas con el estrés hídrico y las condiciones climáticas. Las caídas pronunciadas en T0, especialmente durante enero y marzo, sugieren un estrés hídrico más intenso en estos períodos. Los tratamientos con RDC mostraron mayor estabilidad en la eficiencia fotosintética en comparación con T0, lo que podría reflejar una mejor adaptación a las variaciones de disponibilidad de agua. Este comportamiento es coherente con las etapas fenológicas del cultivo, como la fase de rápido

crecimiento y maduración de los frutos, que incrementa la demanda de agua y la actividad fotosintética (Carrasco-Benavides, Meza, et al. 2020).

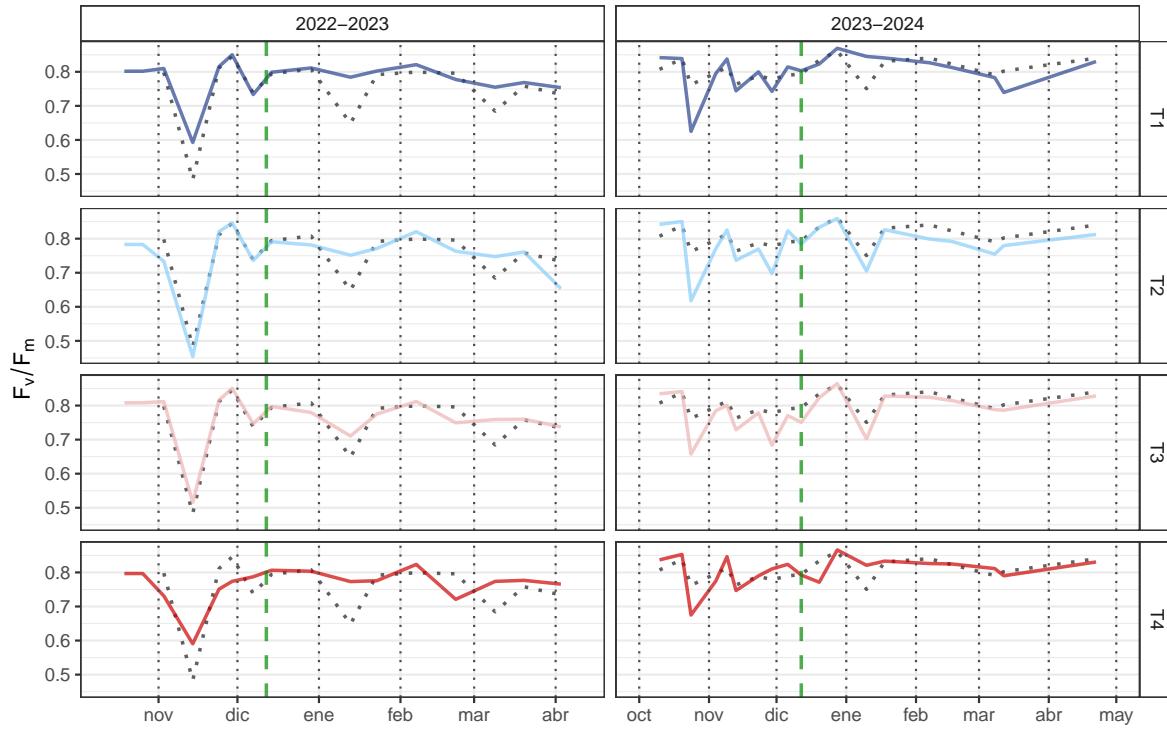


Figura 6.1: Dinámica de la máxima eficiencia quántica del fotosistema II (Φ_{P0}) media de cada tratamiento según temporada en La Esperanza. En cada panel, se encuentra la comparación entre el tratamiento control T0 (línea negra punteada) y el tratamiento con RDC respectivo (línea sólida a color). La línea segmentada horizontal verde indica la fecha de cosecha en cada temporada.

Rio Claro

En Rio Claro (Figura 6.2) durante la primera temorada, los valores de eficiencia fotosintética mostraron un comportamiento similar a La Esperanza durante el aumento de noviembre, seguido por una caída abrupta a finales de mes. En este caso, T0 presentó una disminución considerable en su valor hasta alcanzar $F_v/F_m \sim 0.6$, mientras que los tratamientos RDC (T1, T2, T3 y T4) también mostraron una disminución, aunque menos pronunciada. En particular, T3 y T4 no descendieron por debajo de 0.75, con T3 manteniéndose cercano a 0.8 en todo momento. Posteriormente, se observó un aumento abrupto en los valores, alcanzando un F_v/F_m de 0.8 en todos los tratamientos hacia la fecha de cosecha en diciembre, seguida de una disminución gradual. Esta disminución fue más marcada en los tratamientos RDC en comparación con T0, con T2 mostrando un comportamiento particular al presentar un valle

en principios de febrero antes de aumentar nuevamente para seguir la misma dinámica de T0. Los demás tratamientos disminuyeron a un ritmo similar al de T0 pero con valores algo más bajos.

En la segunda temporada, el comportamiento de F_v/F_m fue diferente. A pesar de la disminución en noviembre, esta fue mucho más leve, con una caída de solo 0.07. Después de un pequeño pico en diciembre, los valores se mantuvieron estables entre 0.8 y 0.85 durante el resto de la temporada, sin descender por debajo de 0.7. Cabe destacar que durante esta temporada, la cosecha se atrasó, lo que significó que las plantas y frutos no estuvieron expuestos a las lluvias de noviembre y diciembre, lo que probablemente influenció en la estabilidad de los valores. Este comportamiento contrastó con el de la primera temporada, donde las variaciones fueron más pronunciadas y los valores fluctuaron más entre los tratamientos.

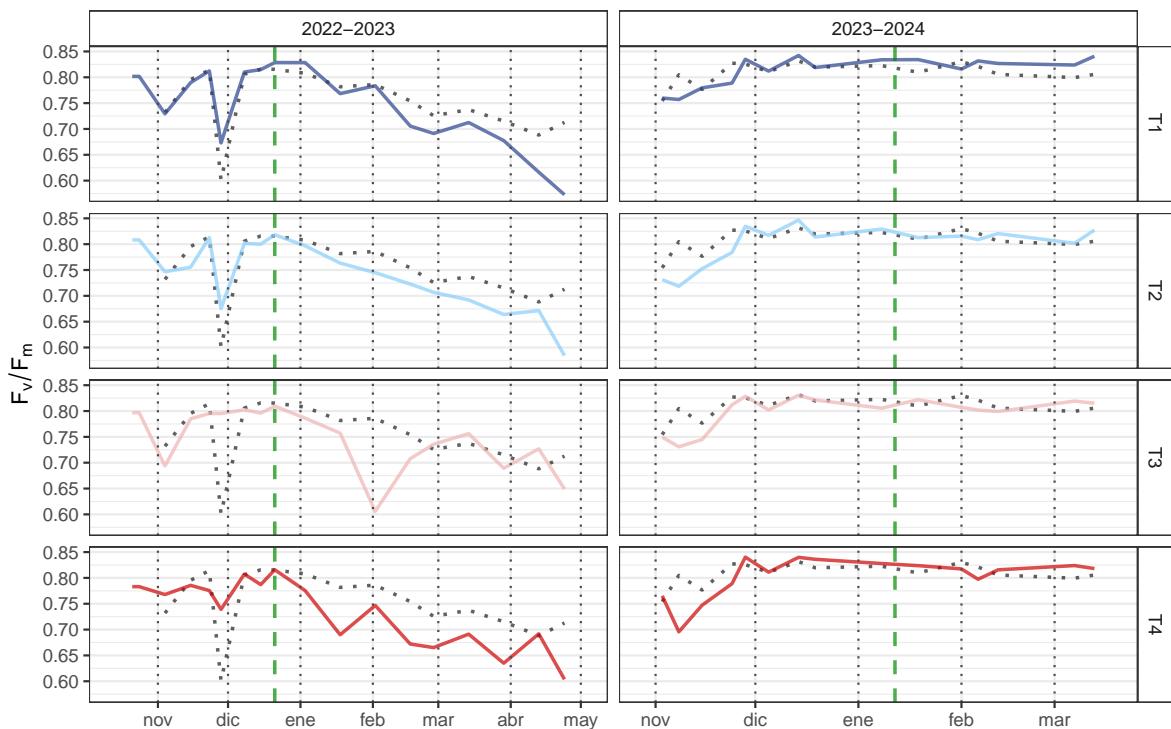


Figura 6.2: Dinámica de la máxima eficiencia quántica del fotosistema II (Φ_{P_0}) media de cada tratamiento según temporada en Río Claro. En cada panel, se encuentra la comparación entre el tratamiento control T0 (línea negra punteada) y el tratamiento con RDC respectivo (línea sólida a color). La línea segmentada horizontal verde indica la fecha de cosecha en cada temporada.

6.2 Potencial

La Esperanza

En la Figura 6.3 se muestran las dinámicas del potencial hídrico (Ψ_s) en La Esperanza durante las temporadas 2022–2023 y 2023–2024. En ambas, los tratamientos con riego deficitario controlado (RDC) presentaron un comportamiento general similar al control (T0), particularmente durante los eventos de caída y aumento abrupto en noviembre, probablemente asociados a lluvias o nubosidad. A partir de finales de octubre y hasta comienzos de diciembre, se observó una disminución sostenida de Ψ_s , que llevó a los cultivos desde condiciones sin estrés ($\Psi_s > -1 \text{ MPa}$) hacia niveles de estrés hídrico moderado ($-1 \text{ MPa} > \Psi_s > -1.5 \text{ MPa}$) (Carrasco-Benavides, Meza, et al. 2020; Carrasco-Benavides et al. 2022; E et al. 2023). Este período coincide con la etapa de rápido crecimiento y maduración de frutos, reportada en Chile para la variedad Regina desde la segunda quincena de noviembre (Arribillaga 2013; Avium 2021), y caracterizada por una mayor actividad fotosintética y demanda hídrica (Yoon y Richter 1990). Luego de la cosecha, todas las series mostraron una recuperación parcial del Ψ_s , seguida de una disminución que alcanzó su punto más bajo entre enero y febrero, en concordancia con el aumento de temperatura. Posteriormente, el potencial hídrico aumentó progresivamente hacia el final de la temporada.

Durante 2022–2023, los tratamientos T1, T2 y T4 cruzaron el umbral de estrés severo ($-1.5 \text{ MPa} > \Psi_s > -2 \text{ MPa}$) en enero, además de marzo en T4 y desde mediados de febrero en T2. En 2023–2024, en cambio, ningún tratamiento superó dicho umbral. En ambas temporadas, T2 presentó los valores más bajos de Ψ_s , con diferencias de hasta 0.25–0.4 MPa respecto a T0 hacia el final del período evaluado. Este patrón indica una mayor sensibilidad al déficit hídrico bajo este tratamiento, con menor capacidad de recuperación. En general, las trayectorias temporales de los tratamientos RDC fueron paralelas a las de T0, aunque con valores levemente inferiores ($\sim 0.1 \text{ MPa}$), especialmente en T2. La recuperación observada tras los mínimos de enero-febrero refuerza la influencia de la variabilidad térmica y climática en la dinámica hídrica de los cultivos.

Rio Claro

En Rio Claro (Figura 6.4), durante la temporada 2022–2023, todos los tratamientos comenzaron sin estrés hídrico significativo. Sin embargo, a partir de comienzos de noviembre, se produjo una caída abrupta en los valores de potencial hídrico, lo que llevó a todos los tratamientos a entrar en condiciones de estrés severo ($\Psi_s < -1.5 \text{ MPa}$). A partir de ese momento, todos los tratamientos se recuperaron parcialmente, alcanzando condiciones de estrés moderado (Ψ_s entre -1.5 MPa y -2 MPa). No obstante, a partir de la cosecha a finales de diciembre, los tratamientos con riego deficitario controlado (RDC) volvieron a caer en condiciones de estrés severo y permanecieron en ese estado hasta el final de la temporada. En cambio, T0, aunque estuvo en estrés moderado durante gran parte de la temporada, también experimentó un

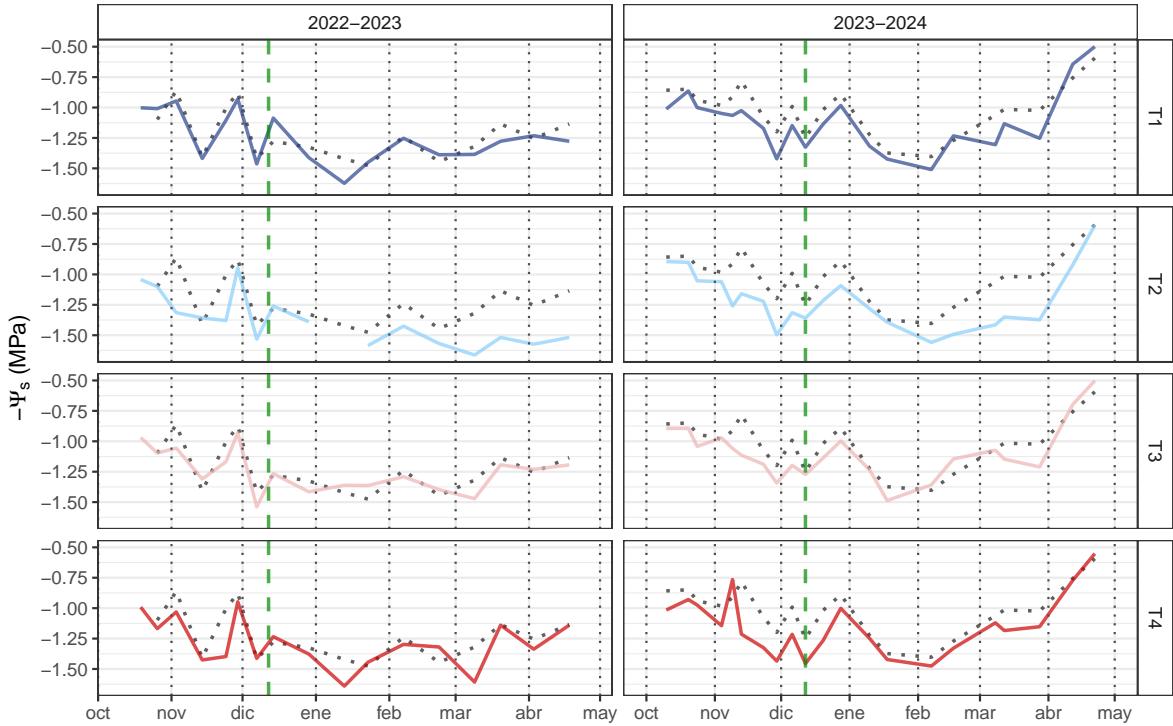


Figura 6.3: Dinámica del potencial hídrico xilemático al medio día (Ψ_s) medio de cada tratamiento según temporada en La Esperanza. En cada panel, se encuentra la comparación entre el tratamiento control T0 (línea negra punteada) y el tratamiento con RDC respectivo (línea sólida a color). La línea segmentada horizontal verde indica la fecha de cosecha en cada temporada.

descenso a estrés severo a partir de febrero, permaneciendo en esa condición hasta el final de la temporada. La diferencia más pronunciada entre T0 y los tratamientos RDC se observó en T3, donde, justo después de la cosecha en enero, se alcanzó una diferencia de hasta 1.75 MPa.

En la temporada 2023-2024, los tratamientos con RDC mostraron un comportamiento más similar al de T0. Durante la fase inicial, todos los tratamientos experimentaron una disminución en el potencial hídrico, coincidiendo con la floración y la producción de frutos, con un pico de disminución en diciembre. A diferencia de T0, que no descendió del umbral de estrés severo en ningún momento, los tratamientos con RDC llegaron a valores de hasta -2.5 MPa, entrando en condiciones de estrés severo. T0 también alcanzó el umbral de -2.5 MPa en su punto más bajo en febrero, después de haber comenzado a disminuir en enero, pero se mantuvo en condiciones de estrés moderado hasta mediados de enero, cuando la cosecha provocó una caída hacia el estrés severo, aunque se recuperó hacia finales de la temporada, con un regreso a condiciones de estrés moderado a finales de marzo. Por otro lado, los tratamientos RDC aumentaron gradualmente sus valores de potencial tras alcanzar los puntos más bajos en enero-febrero, sin llegar a experimentar la recuperación tan pronunciada observada en T0.

6.3 LAI

La Esperanza

La Figura 6.5 muestra los resultados del comportamiento del *LAI* en ambos sitios durante las dos temporadas. Para la temporada 2022-2023, los datos fueron tomados de febrero a mayo, mientras que en la temporada 2023-2024 se registraron durante toda la temporada. En la temporada 2022-2023 en La Esperanza, los valores de *LAI* se mantuvieron estables desde febrero hasta mayo, con una disminución suave hacia abril debido a la pérdida de hojas. Estos valores fueron más bajos que los observados en febrero de la temporada 2023-2024. En esta última, las diferencias entre tratamientos fueron sutiles, con los RDC mostrando una diferencia máxima de 1 de *LAI* en T2 en ciertos períodos. En la temporada 2023-2024, se observó un comportamiento de aumento del *LAI* en todos los tratamientos hasta la cosecha, con un incremento que osciló entre 2 y 5 unidades, seguido de una estabilización hasta el final de la temporada, lo cual es consistente con el crecimiento vegetativo de los cerezos.

Río Claro

Para Río Claro (Figura 6.6), en la temporada 2022-2023, los valores también fueron más bajos, mostrando un comportamiento similar al de La Esperanza, con una disminución suave en la misma época pero con un pico importante durante febrero. En la temporada 2023-2024, el patrón fue casi idéntico al de La Esperanza, con un aumento del *LAI* que varió entre 2 y 4 unidades. Sin embargo, en Río Claro se observaron diferencias más marcadas entre los

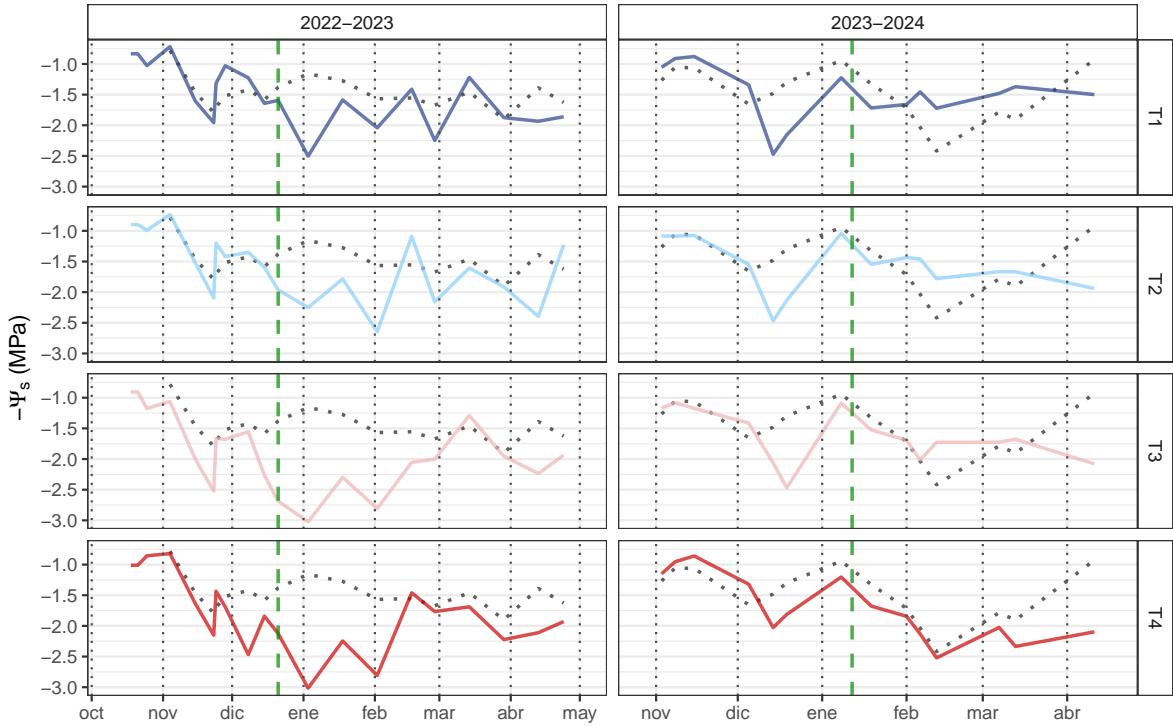


Figura 6.4: Dinámica del potencial hídrico xilemático al medio día (Ψ_s) medio de cada tratamiento según temporada en Río Claro. En cada panel, se encuentra la comparación entre el tratamiento control T0 (línea negra punteada) y el tratamiento con RDC respectivo (línea sólida a color). La línea segmentada horizontal verde indica la fecha de cosecha en cada temporada.

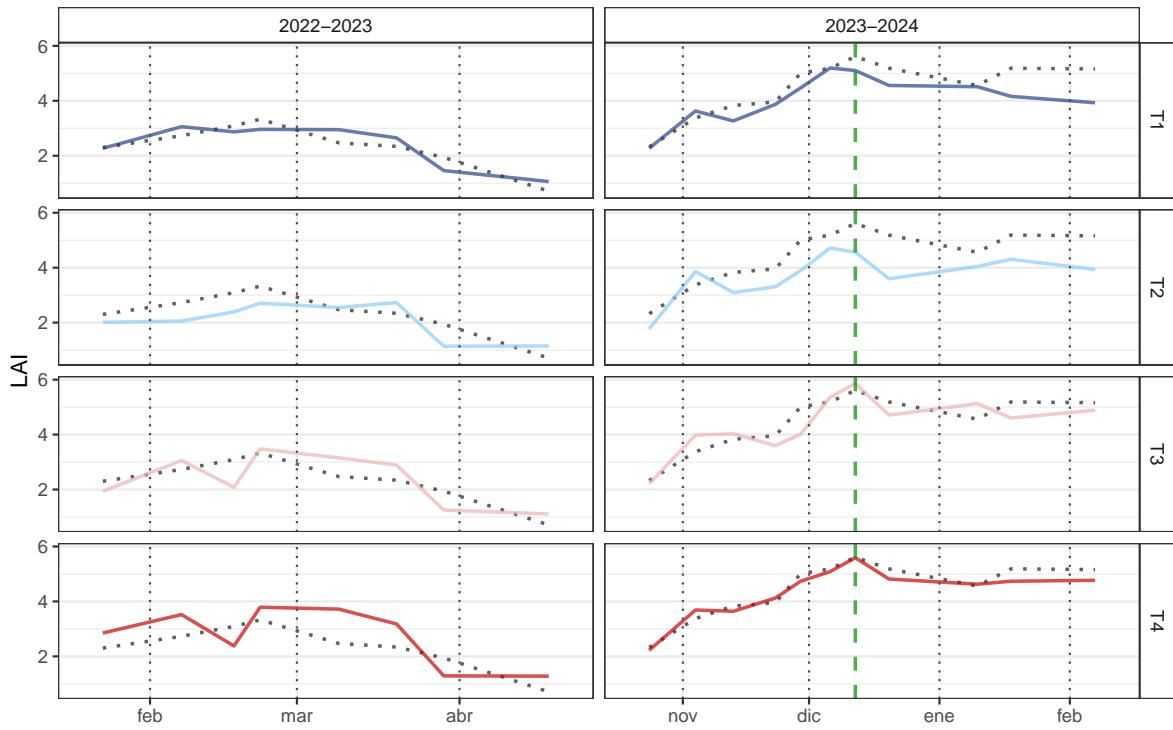


Figura 6.5: Dinámica del LAI de cada tratamiento según temporada en La Esperanza. En cada panel, se encuentra la comparación entre el tratamiento control T0 (línea negra punteada) y el tratamiento con RDC respectivo (línea sólida a color). La línea segmentada horizontal verde indica la fecha de cosecha en cada temporada.

tratamientos RDC y T0, especialmente en diciembre, donde las diferencias alcanzaron hasta 1.5 de LAI en T2 y T3 en comparación con T0. Además, todos los tratamientos experimentaron una disminución abrupta a partir de febrero, lo que coincidió con la caída de hojas en este sitio y temporada.

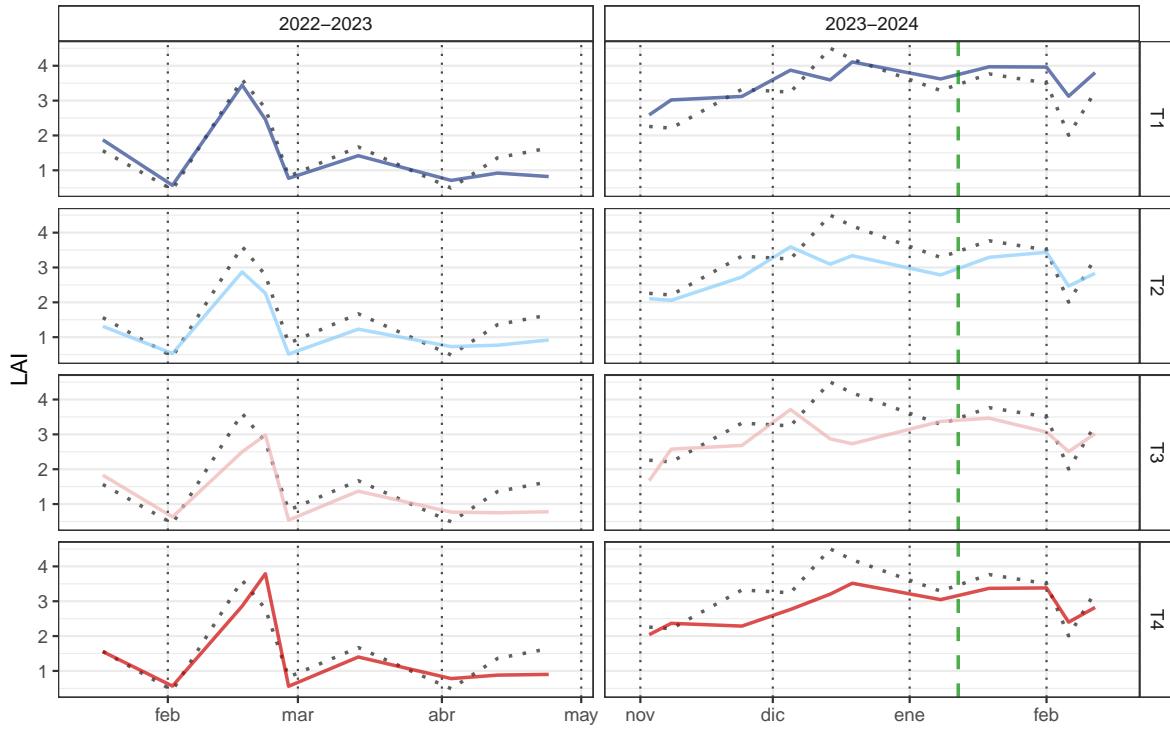


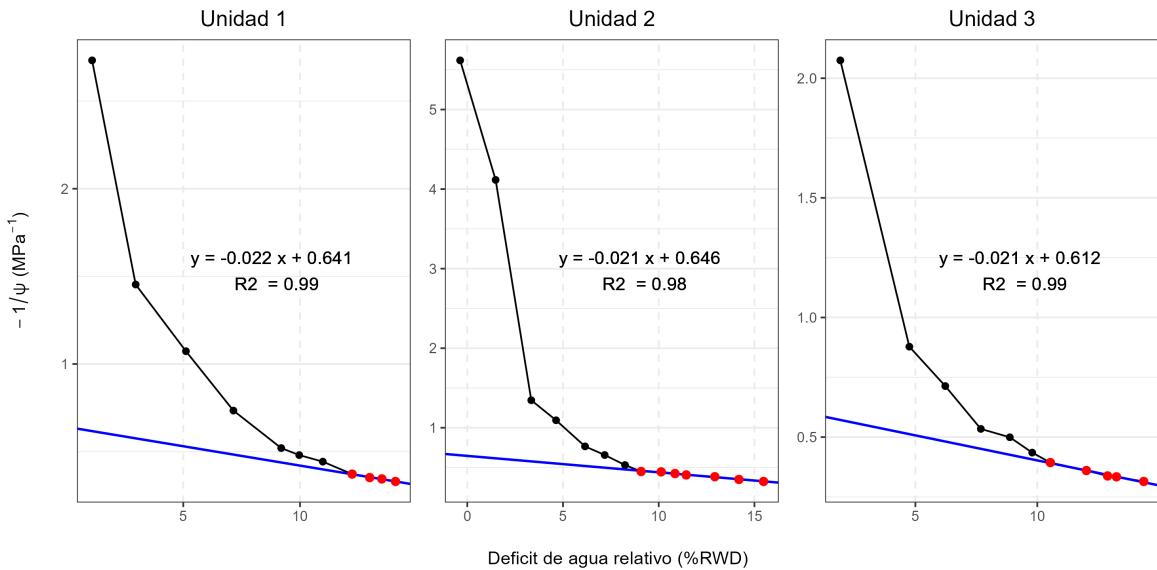
Figura 6.6: Dinámica del LAI medio de cada tratamiento según temporada en Río Claro. En cada panel, se encuentra la comparación entre el tratamiento control T0 (línea negra punteada) y el tratamiento con RDC respectivo (línea sólida a color). La línea segmentada horizontal verde indica la fecha de cosecha en cada temporada.

6.4 Punto de pérdida de turgor (TLP)

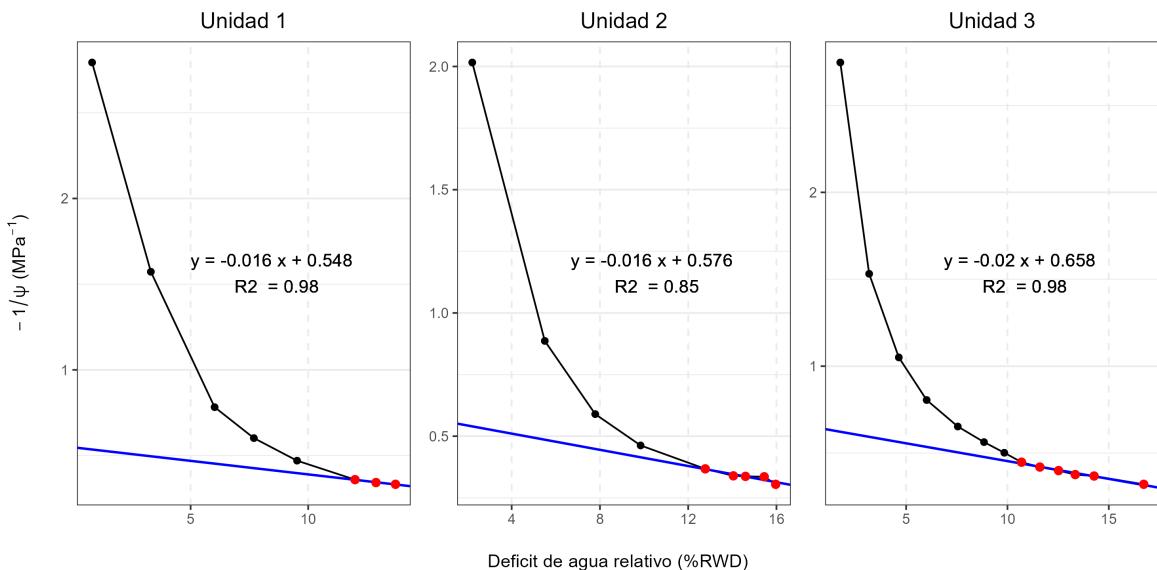
Las siguientes figuras muestran los resultados de las curvas Presión-Volumen obtenidas de las mediciones de Ψ_s y el peso de las hojas.

La Esperanza

6.4.0.1 Tratamiento 0

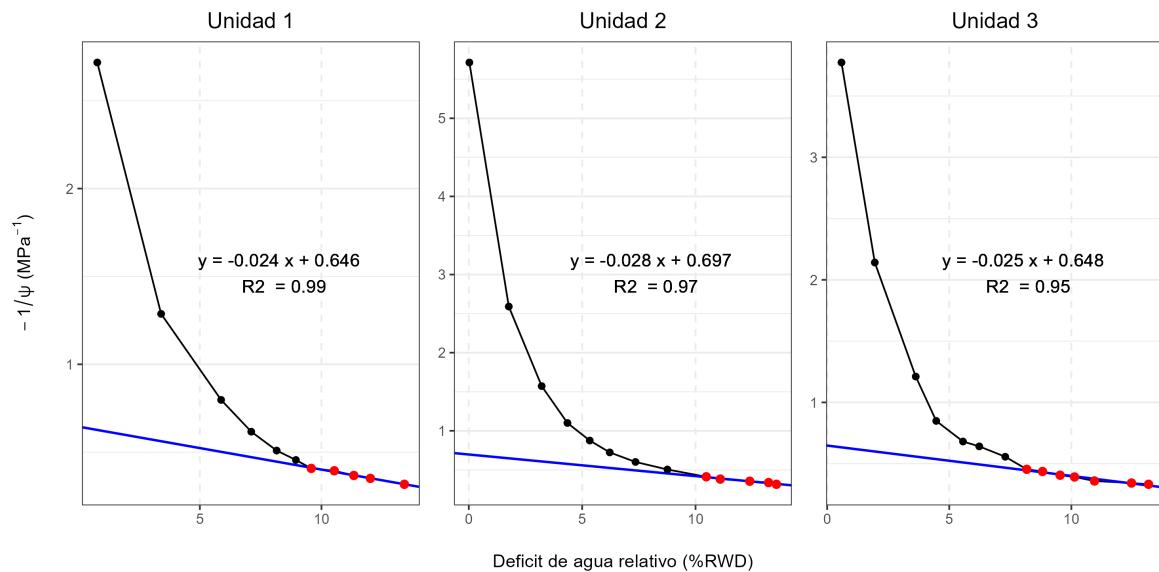


6.4.0.2 Tratamiento 4

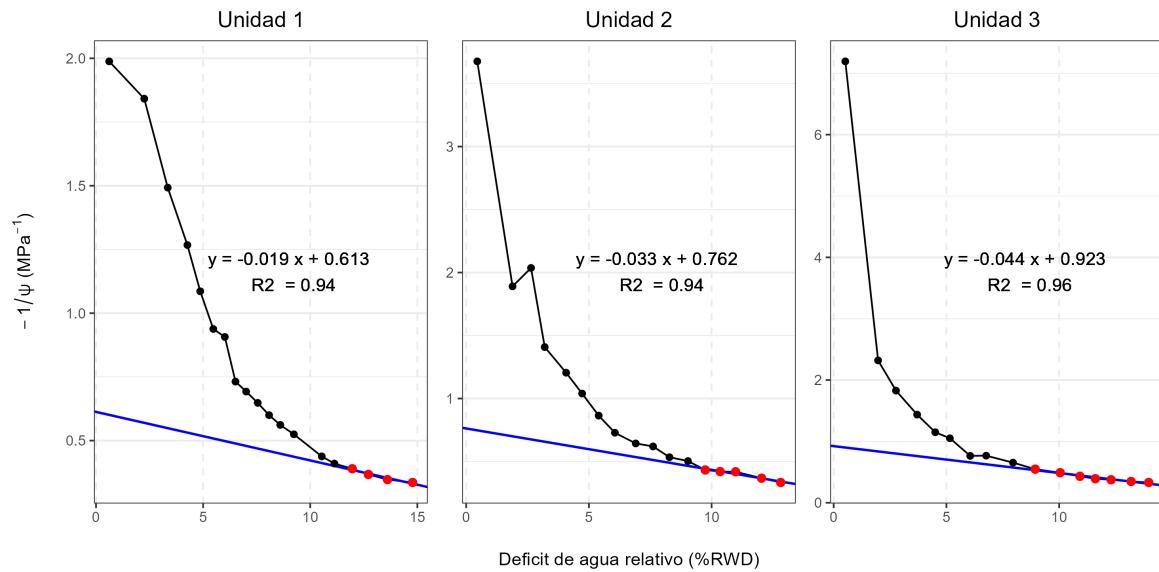


Rio Claro

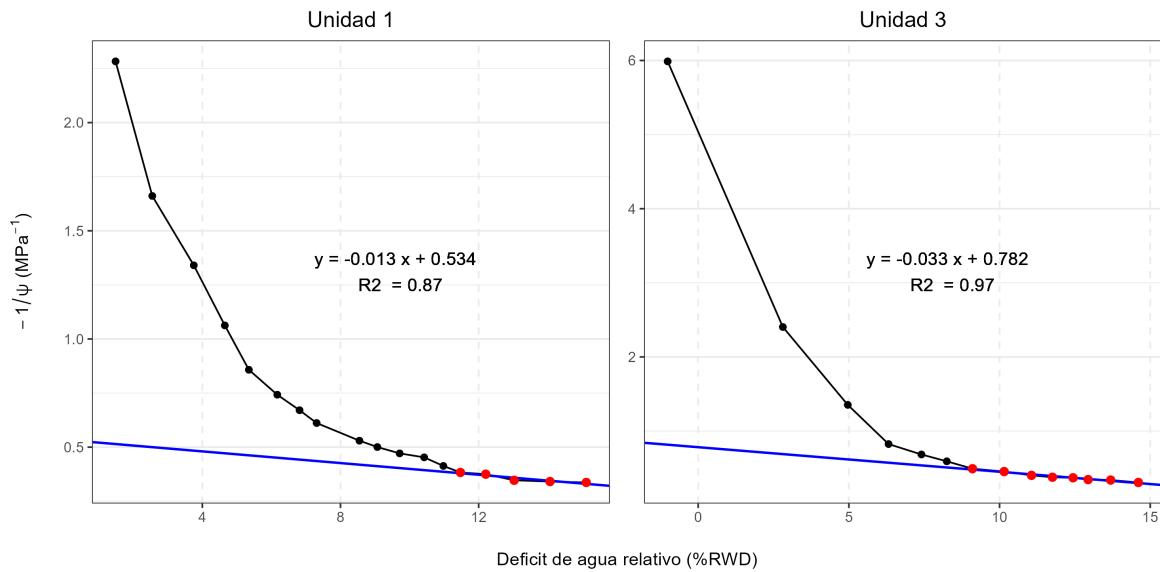
6.4.1 Tratamiento 0 (control)



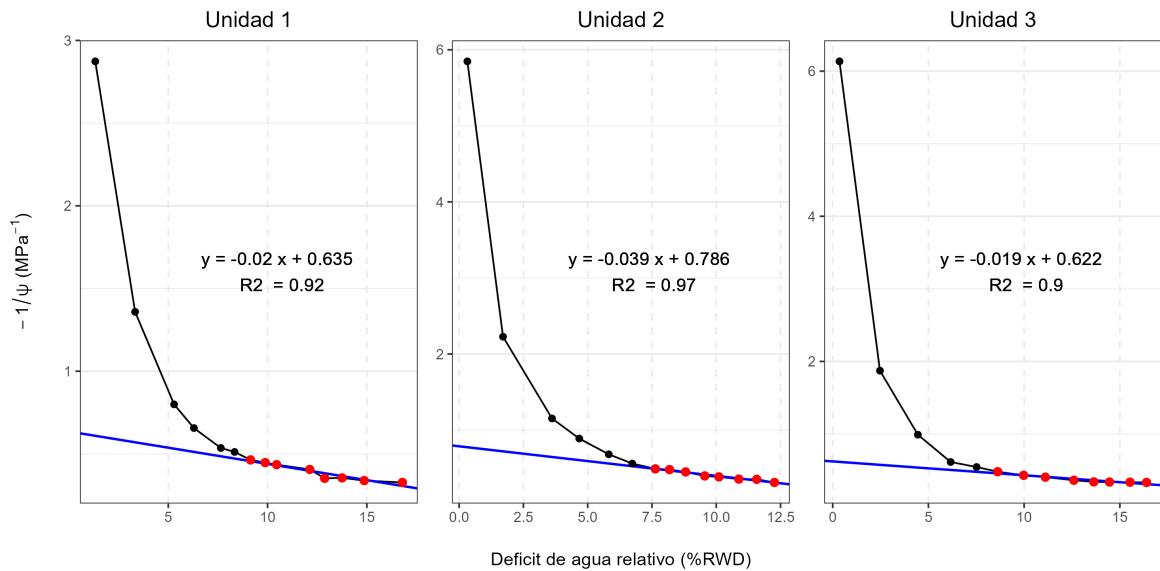
6.4.2 Tratamiento 1



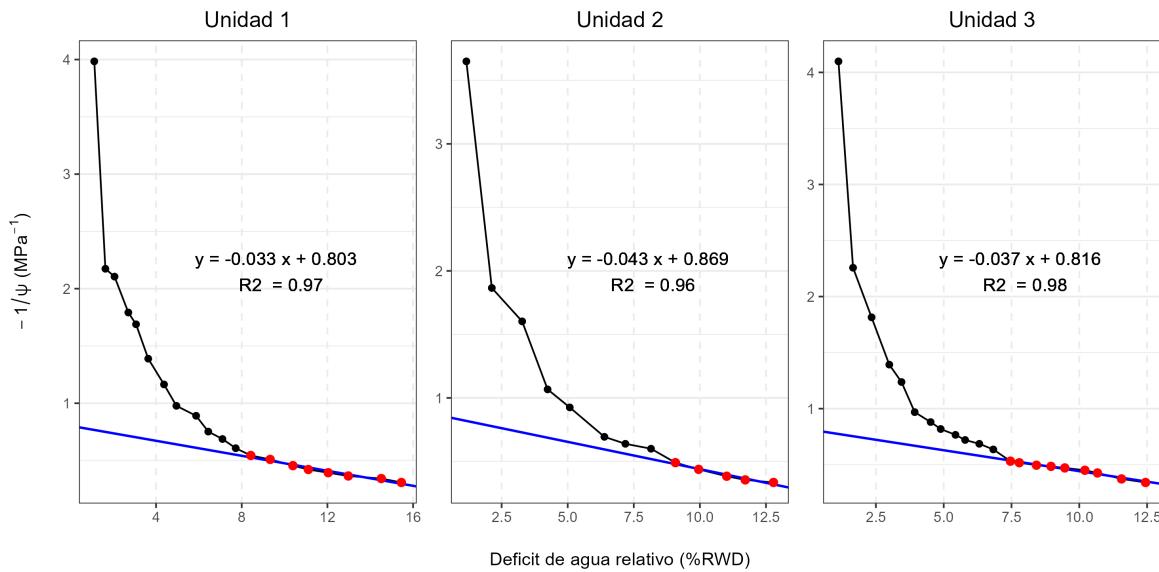
6.4.3 Tratamiento 2



6.4.4 Tratamiento 3



6.4.5 Tratamiento 4



En la Figura 6.7 se pueden observar los puntos de pérdida de turgor (TLP) obtenidos a partir de las estas curvas PV. Los resultados muestran un TLP promedio de -2.54 MPa en La Esperanza y -2.20 MPa en Río Claro, lo que indica una diferencia en la capacidad de las plantas para mantener la turgencia entre ambos sitios. En La Esperanza, los valores de TLP fueron similares entre los tratamientos, con T0 y T4 registrando -2.48 y -2.60 MPa, respectivamente. En Río Claro, se encontraron más diferencias entre los tratamientos, con todos los valores menos negativos que el control T0 (-2.38 MPa), destacando T4 con el valor menos negativo (-1.95 MPa), lo que sugiere una mayor vulnerabilidad al estrés hídrico en ese tratamiento.

Combinando observaciones en terreno de potencial, y el punto de perdida de turgor obtenido a partir de las curvas presión-volumen ($TLP_{la_esperanza} = -2.54$ MPa; $TLP_{rio_claro} = -2.2$ MPa; Figura 6.8) se puede observar que este punto de estrés hídrico se alcanzó mayoritariamente en los meses de enero y febrero en el campo de Río Claro, durante la temporada 2022-2023. Además, en el mismo contexto se puede observar tendencias a la disminución de potencial para los tratamientos de estrés hídrico más severos (T3 y T4). Por el contrario, en La Esperanza no se observan disminuciones importantes de potencial, respecto al punto de pérdida de turgor, mientras que tampoco se aprecian diferencias a simple vista entre las dinámicas temporales de los tratamientos.

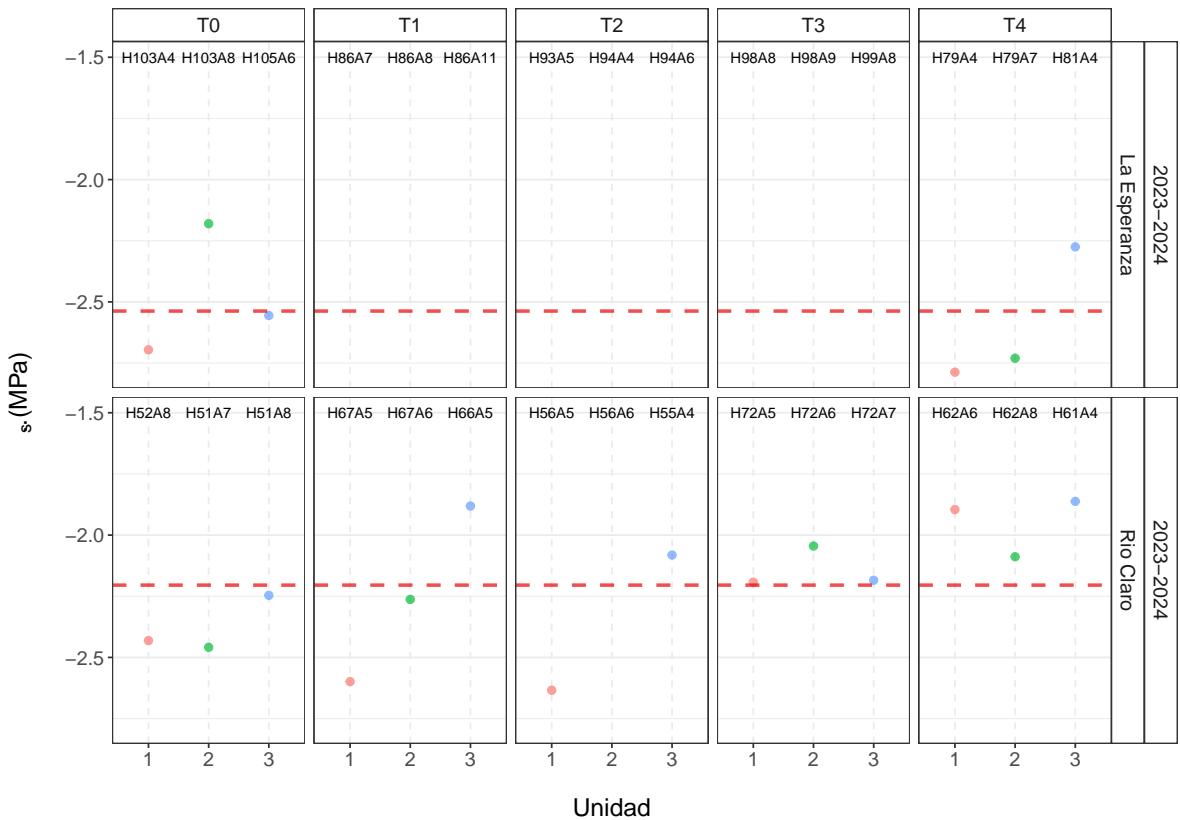


Figura 6.7: Punto de pérdida de turgor (TLP) por unidad (árbol), según tratamiento y sitio para al temporada 2023-2024. Las líneas rojas segmentadas indican el promedio de TLP para cada sitio.

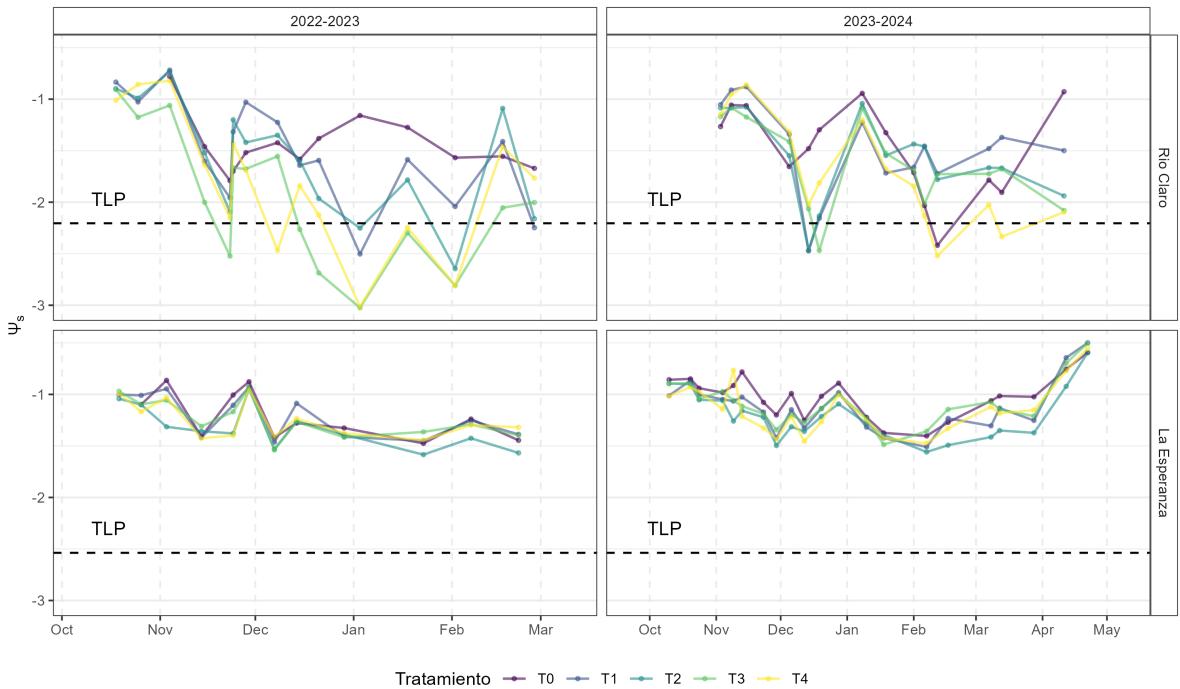


Figura 6.8: Series temporales de potencial hídrico xilemático según temporada (2022-2023; 2023-2024), sitio y tratamientos (T0 a T4). La unidad indica cada árbol por tratamiento (tres por tratamiento), mientras que la línea segmentada indica el punto de pérdida de turgor para cada sitio.

6.5 Presión de turgor

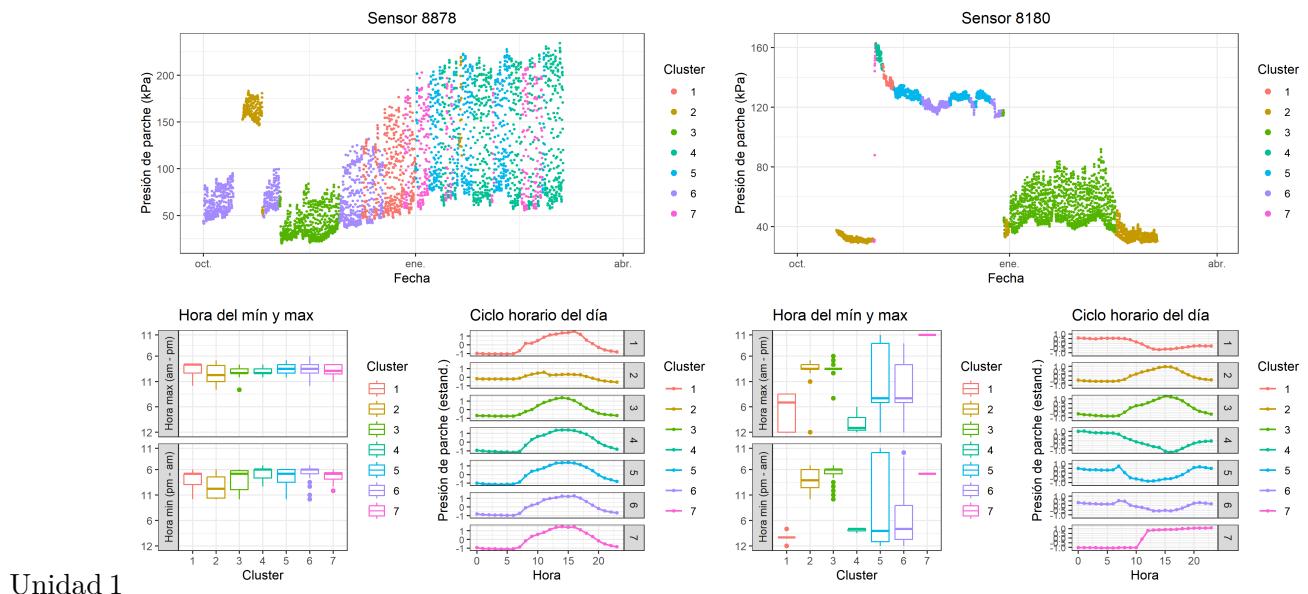
A pesar de la metodología de preprocesamiento propuesta para solucionar la variabilidad en la magnitud de datos después de la recalibración, finalmente no fue posible utilizar los valores obtenidos de turgor. La necesidad de estandarización y modelado para corregir las inconsistencias terminó eliminando la magnitud de los valores y las diferencias entre unidades, lo que impidió un análisis adecuado de las variaciones de turgor entre tratamientos y temporadas. De todas formas, a continuación se presentan los resultados obtenidos de cada proceso.

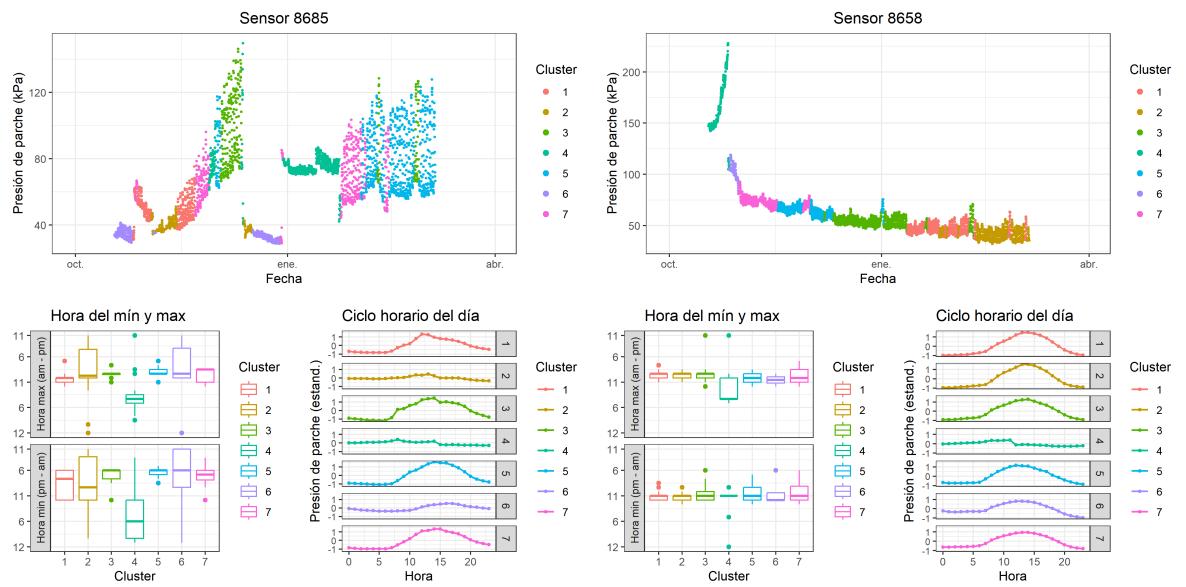
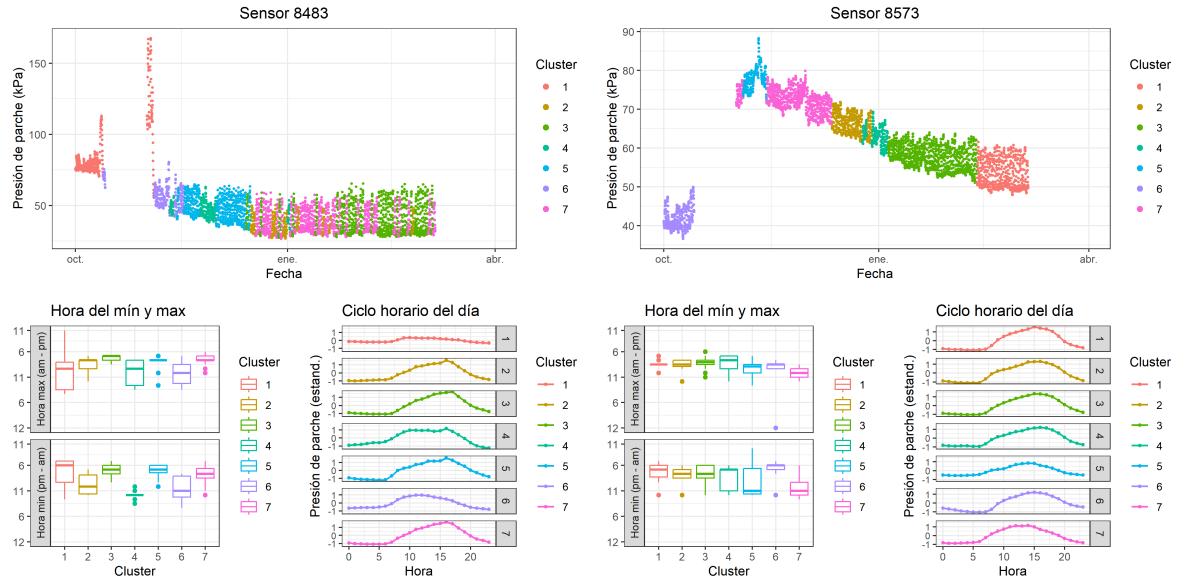
Clustering

A continuación, se muestran las series temporales de turgor diferenciadas por clúster, así como la distribución de las horas de turgor mínimo y máximo para cada uno de ellos, junto con su ciclo horario diario, abarcando todos los sensores en todas las unidades durante las temporadas 2022-2023 y 2023-2024.

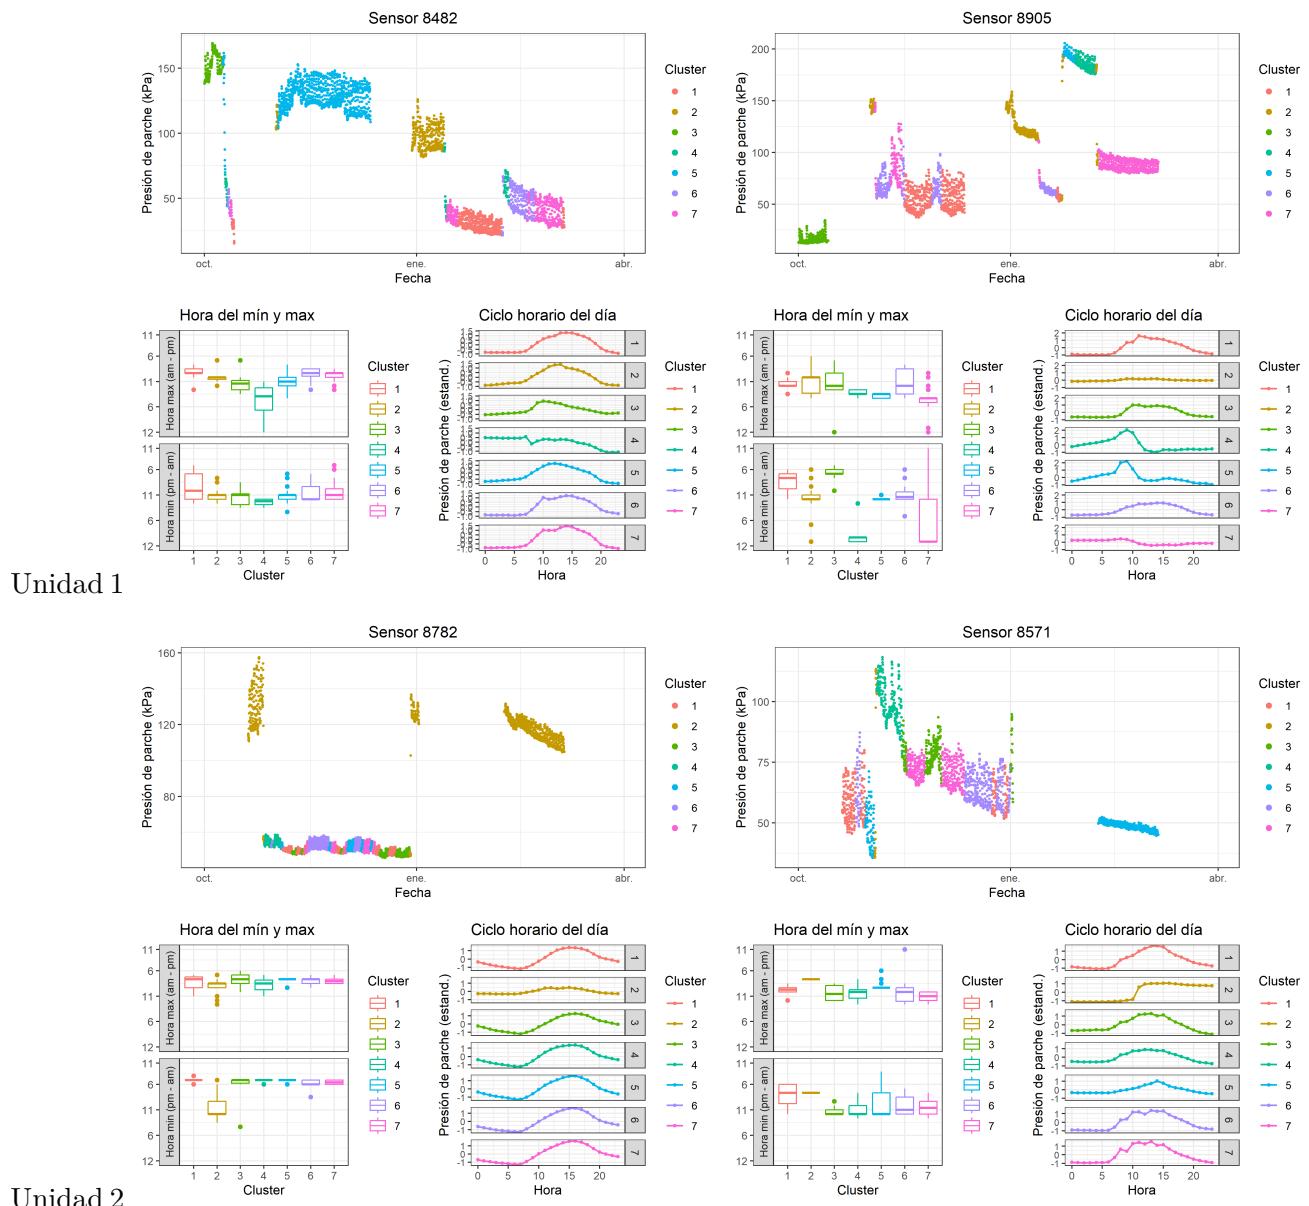
La Esperanza

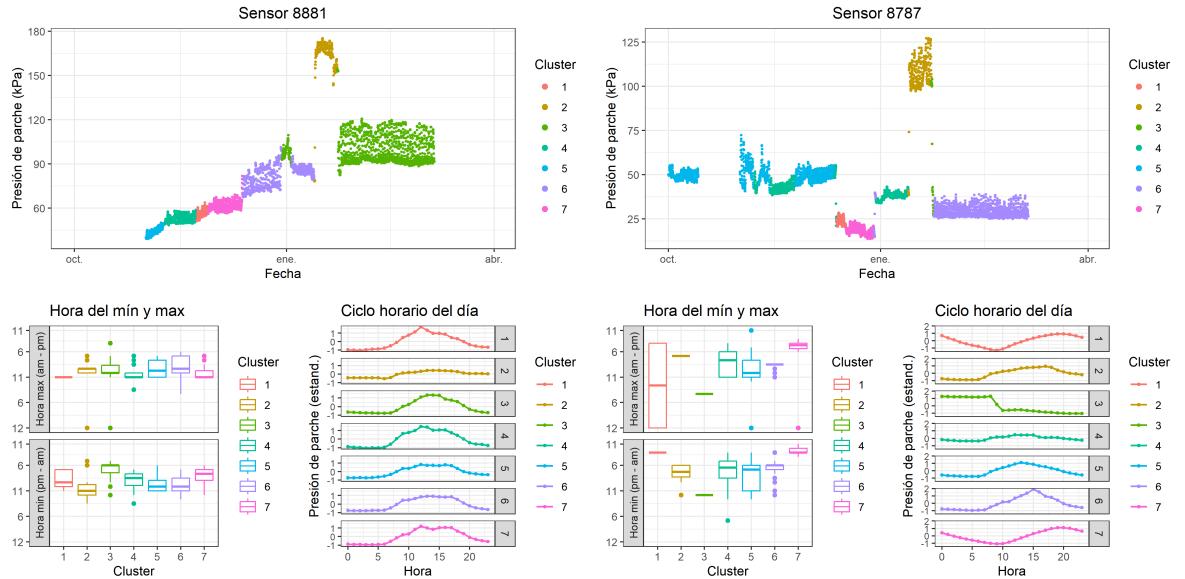
6.5.0.1 T1 (2022-2023)





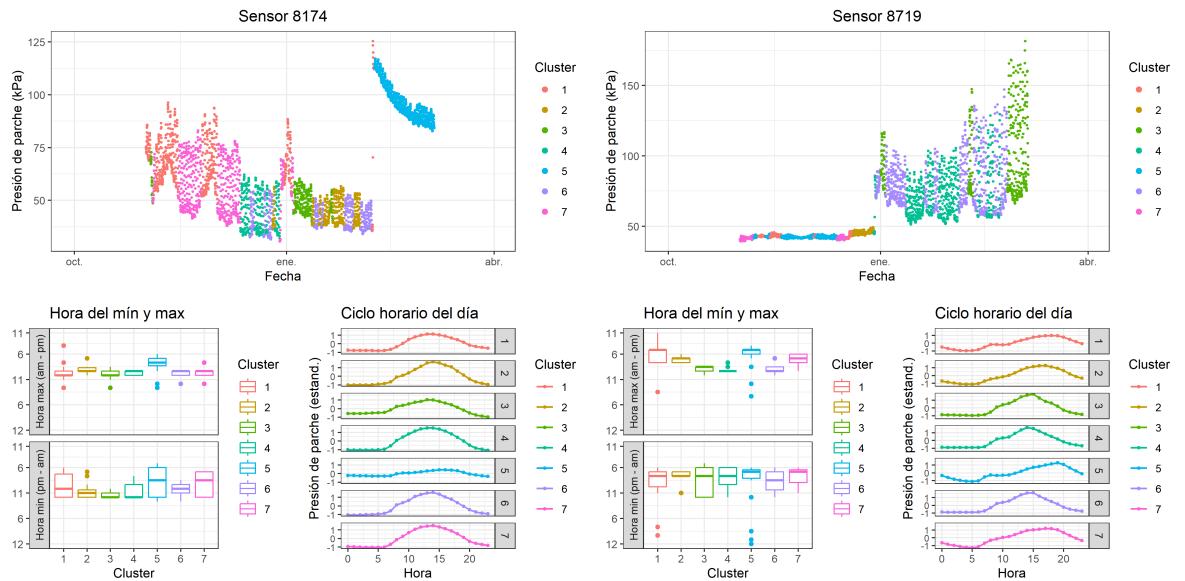
6.5.0.2 T2 (2022-2023)



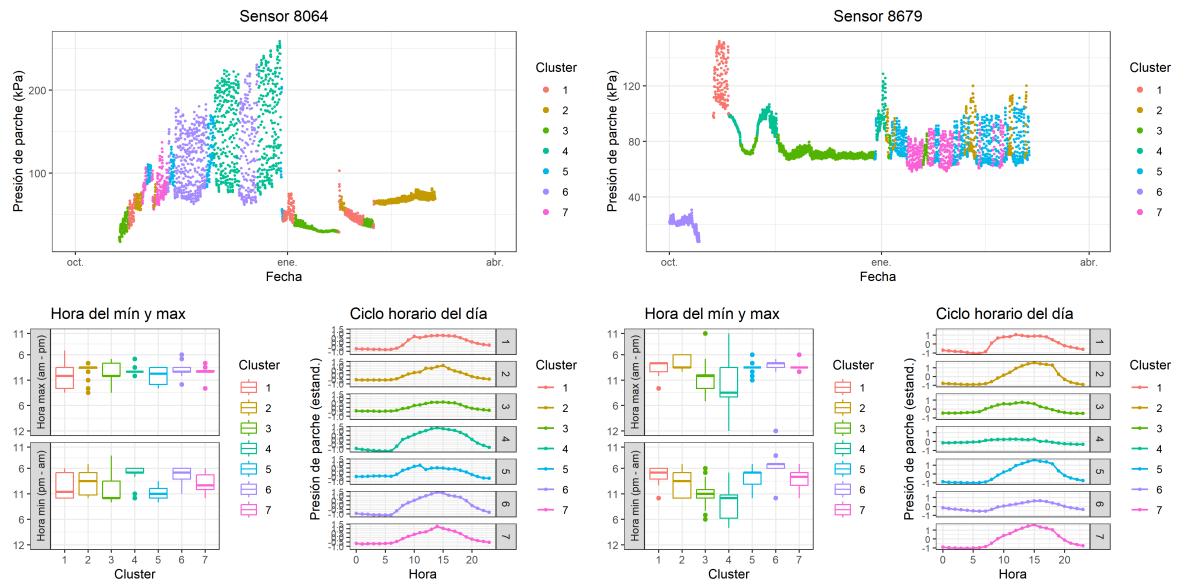
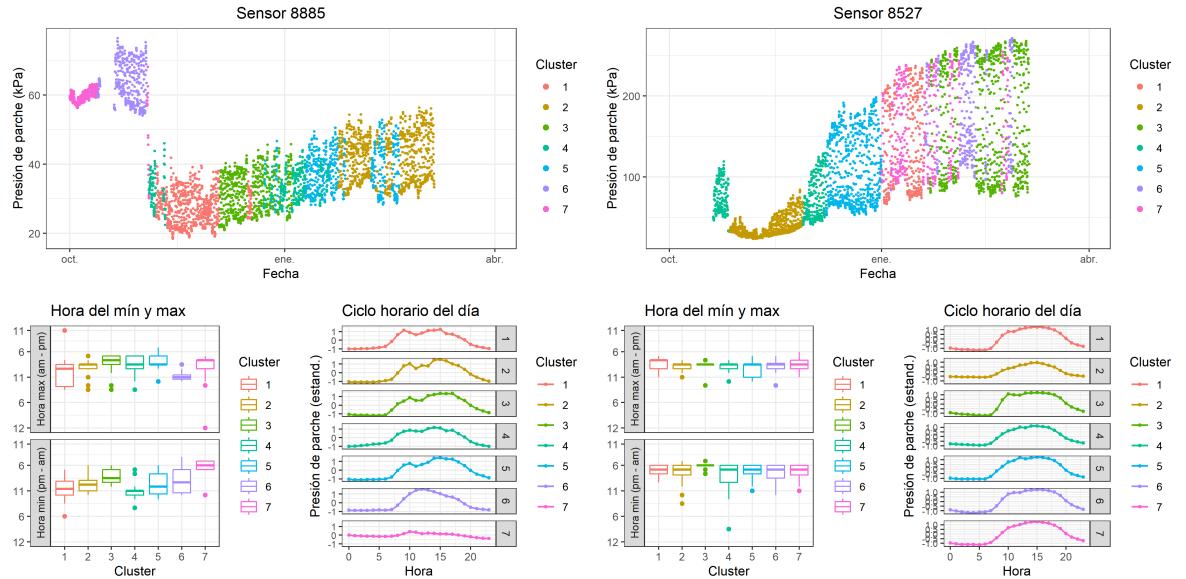


Unidad 3

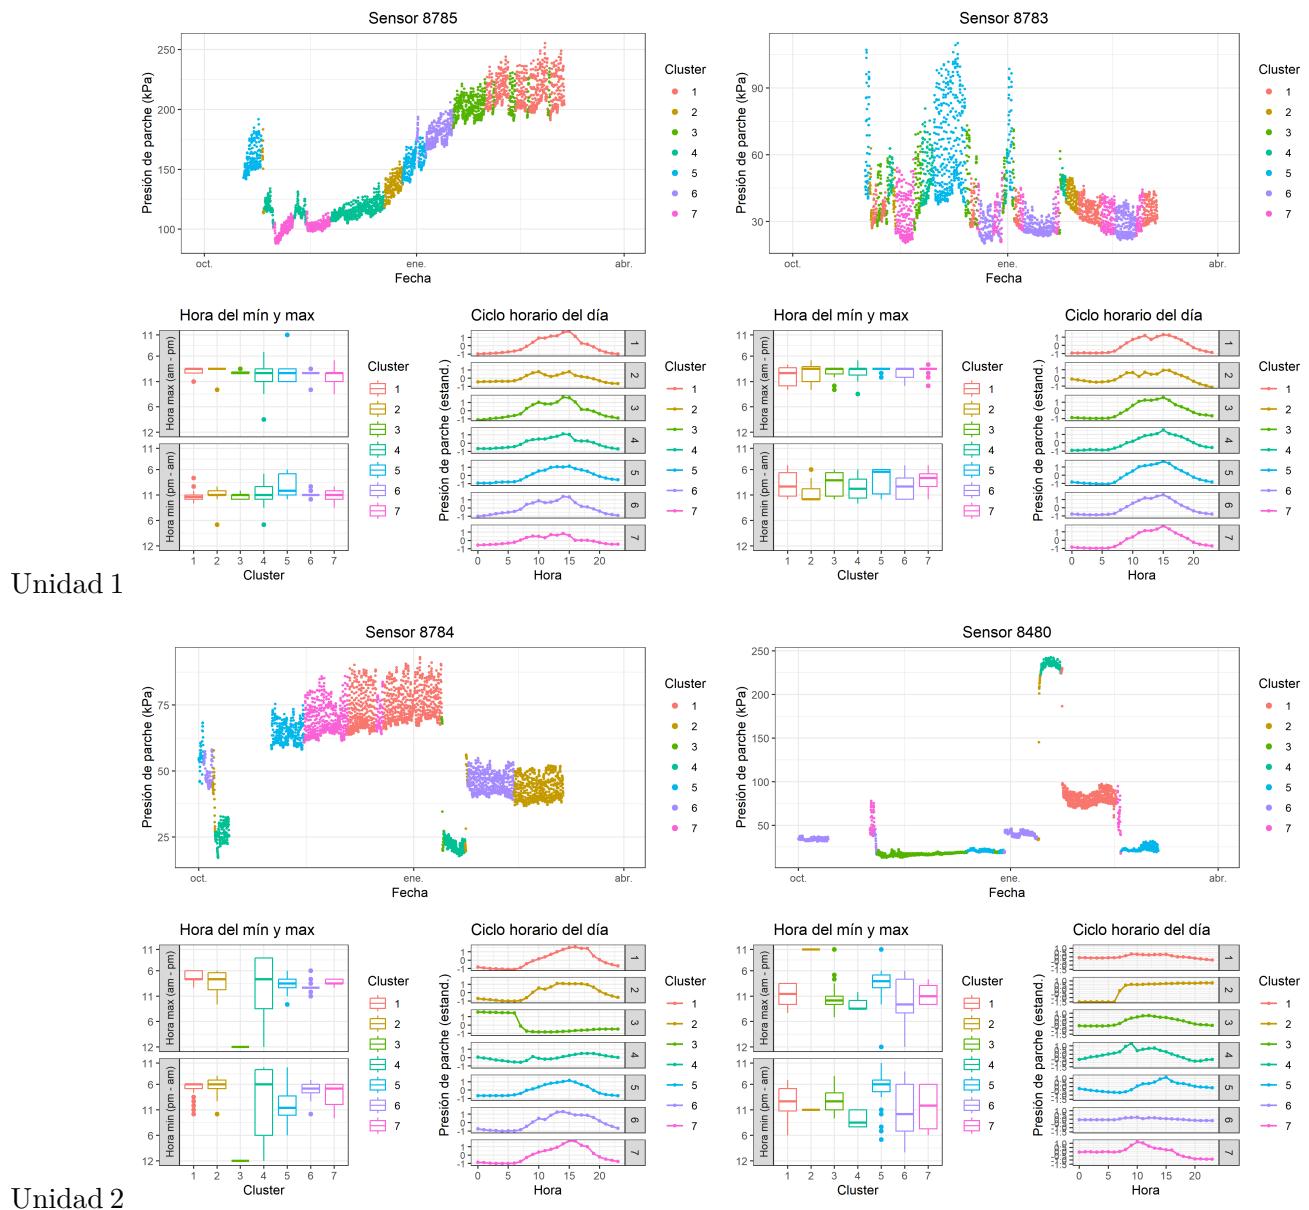
6.5.0.3 T3 (2022-2023)

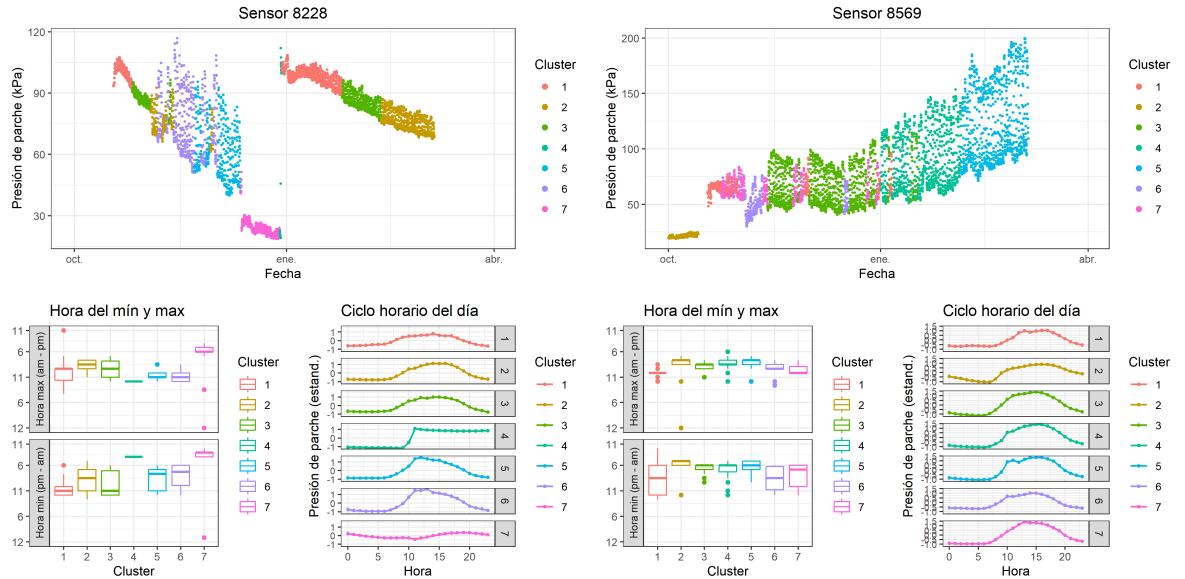


Unidad 1



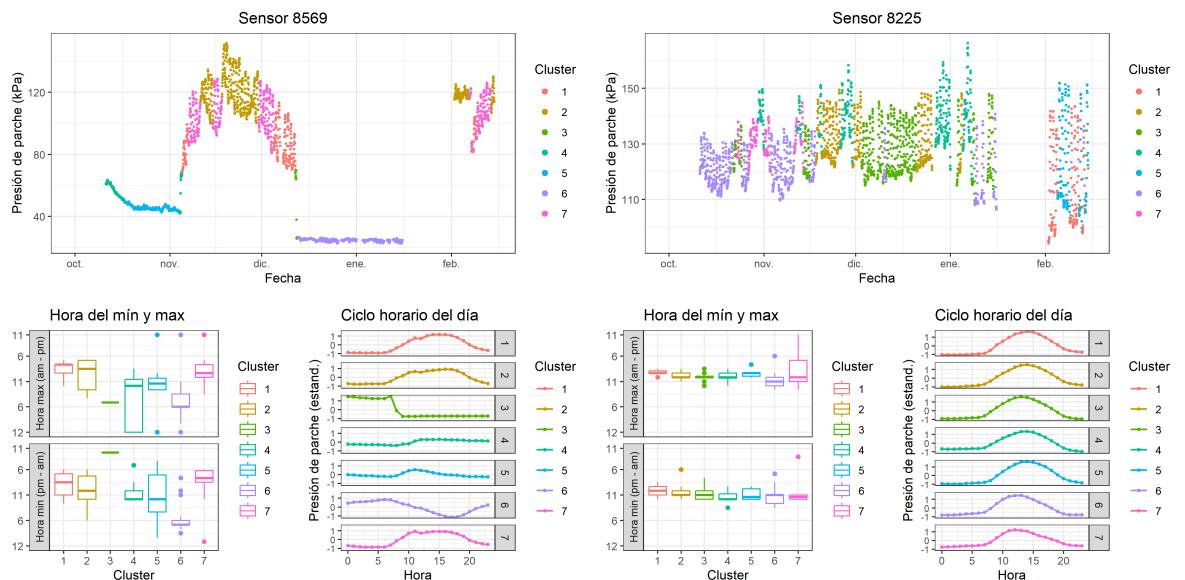
6.5.0.4 T4 (2022-2023)



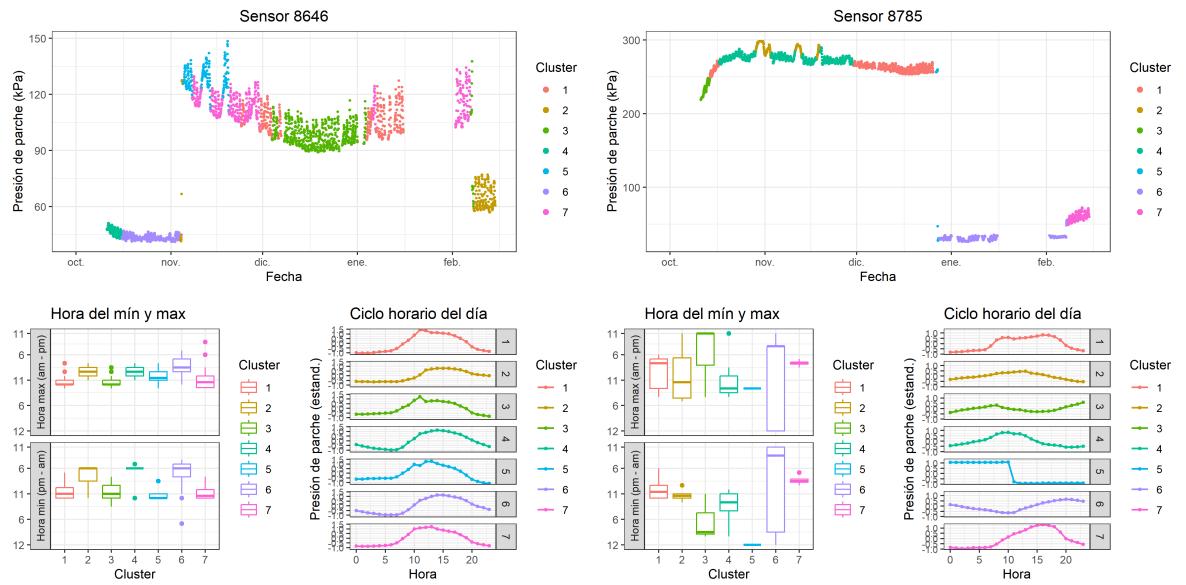
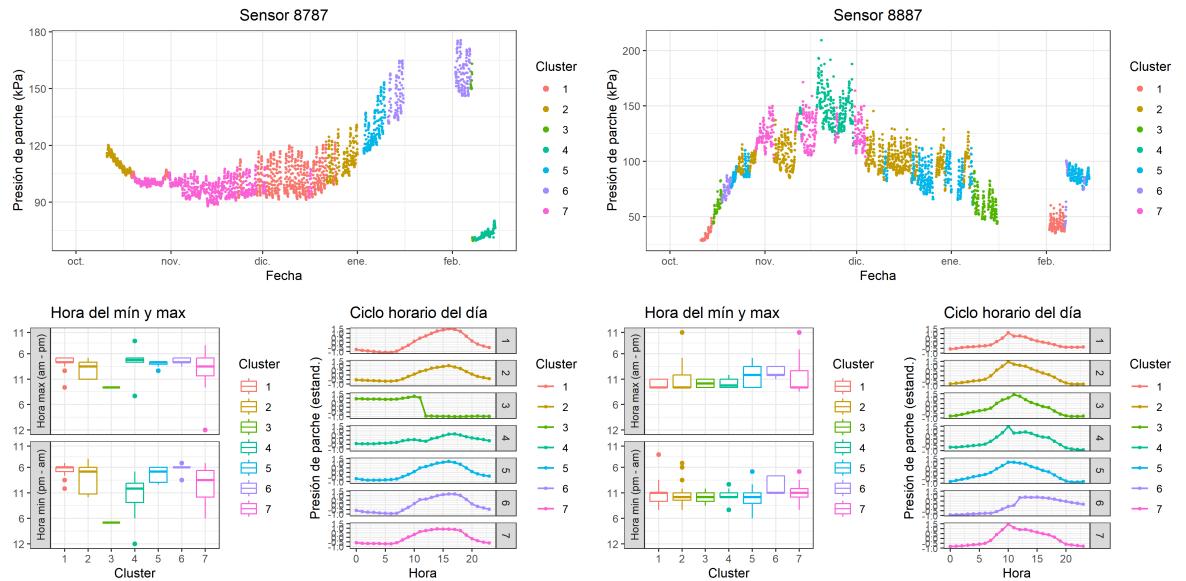


Unidad 3

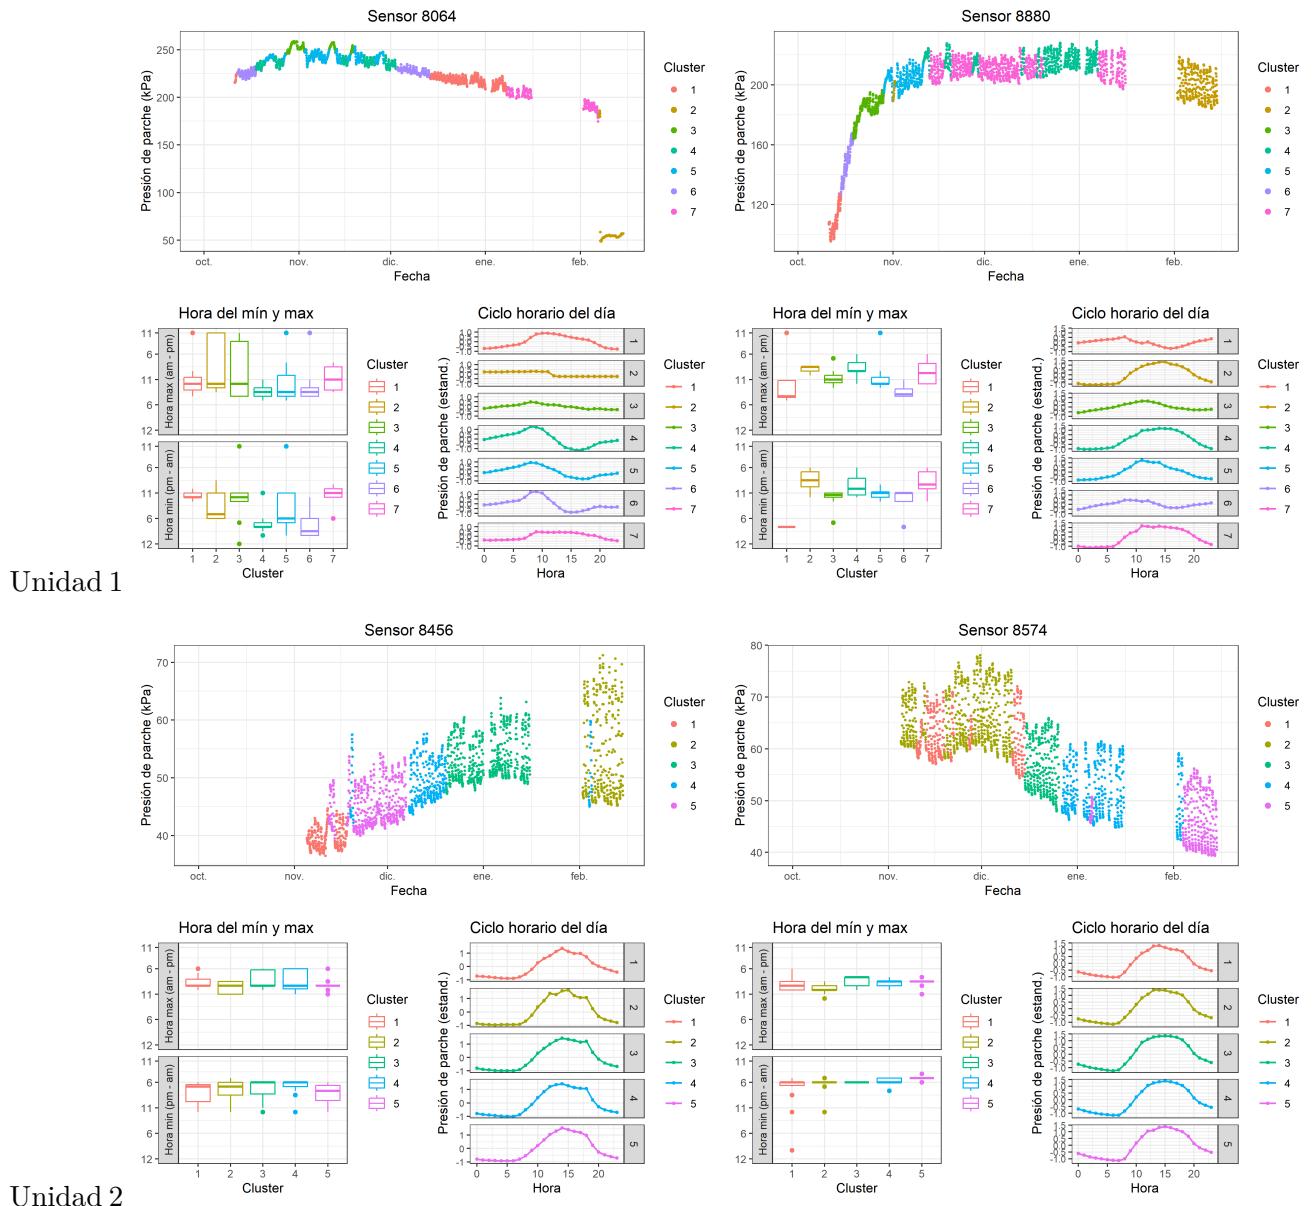
6.5.0.5 T1 (2023-2024)

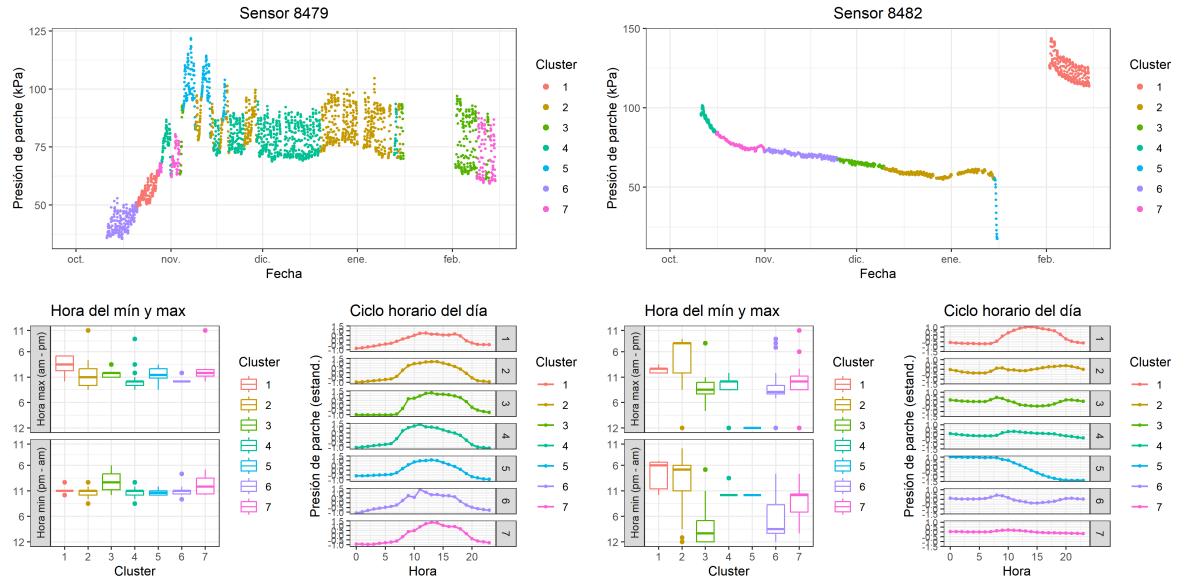


Unidad 1

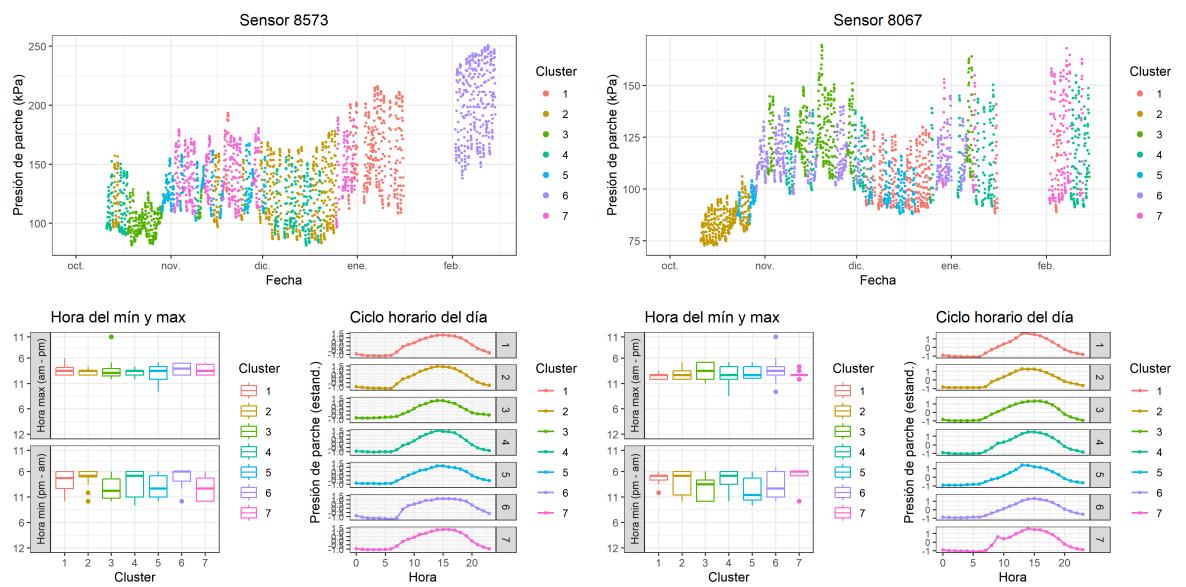


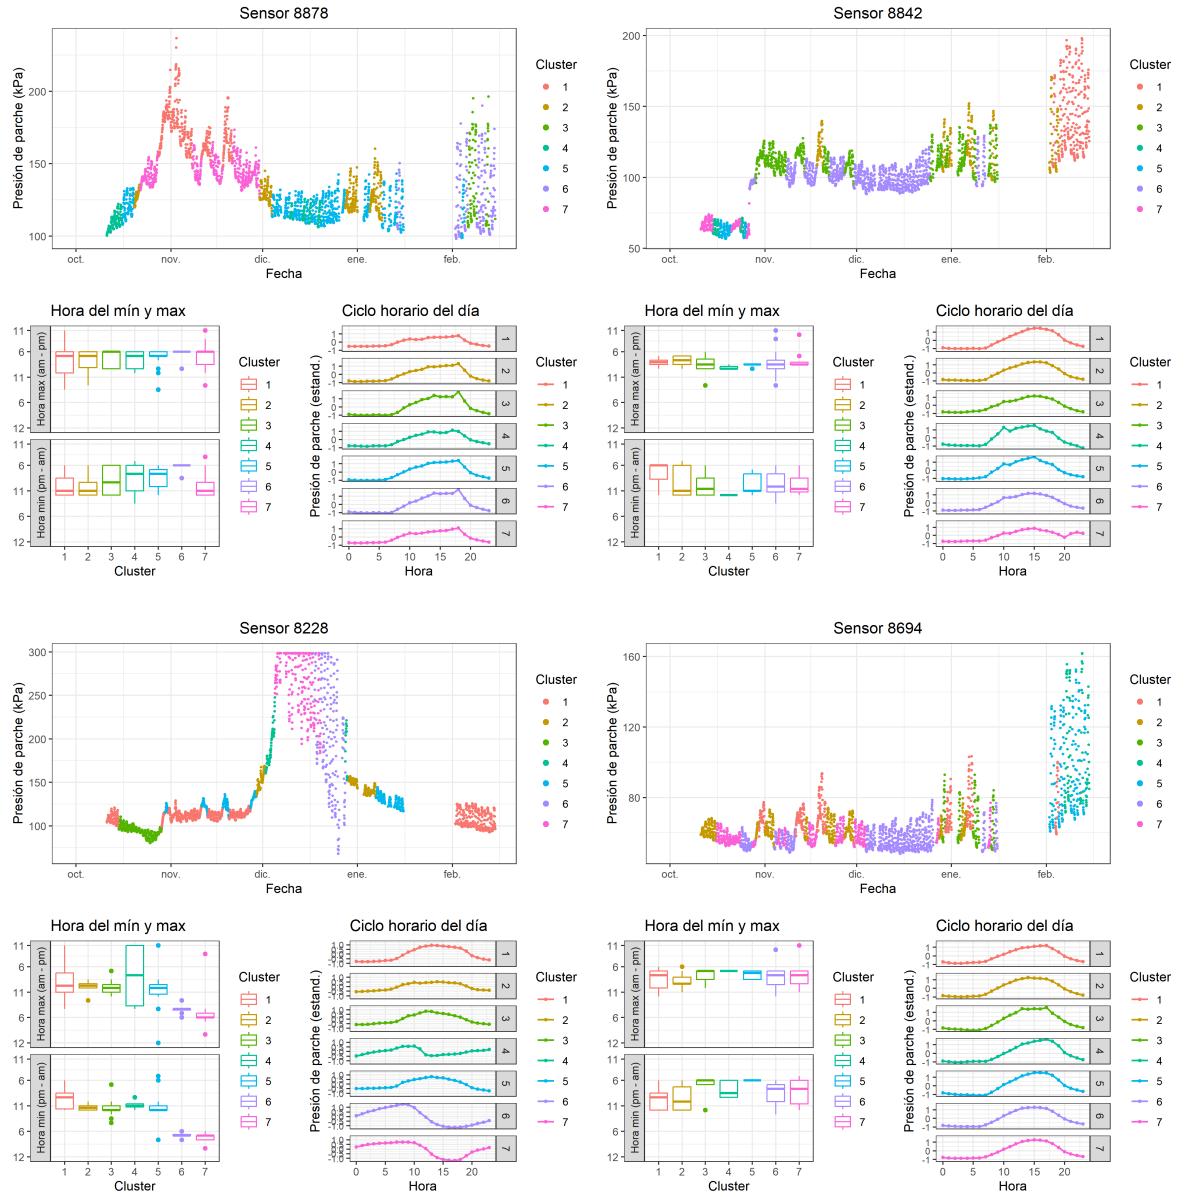
6.5.0.6 T2 (2023-2024)



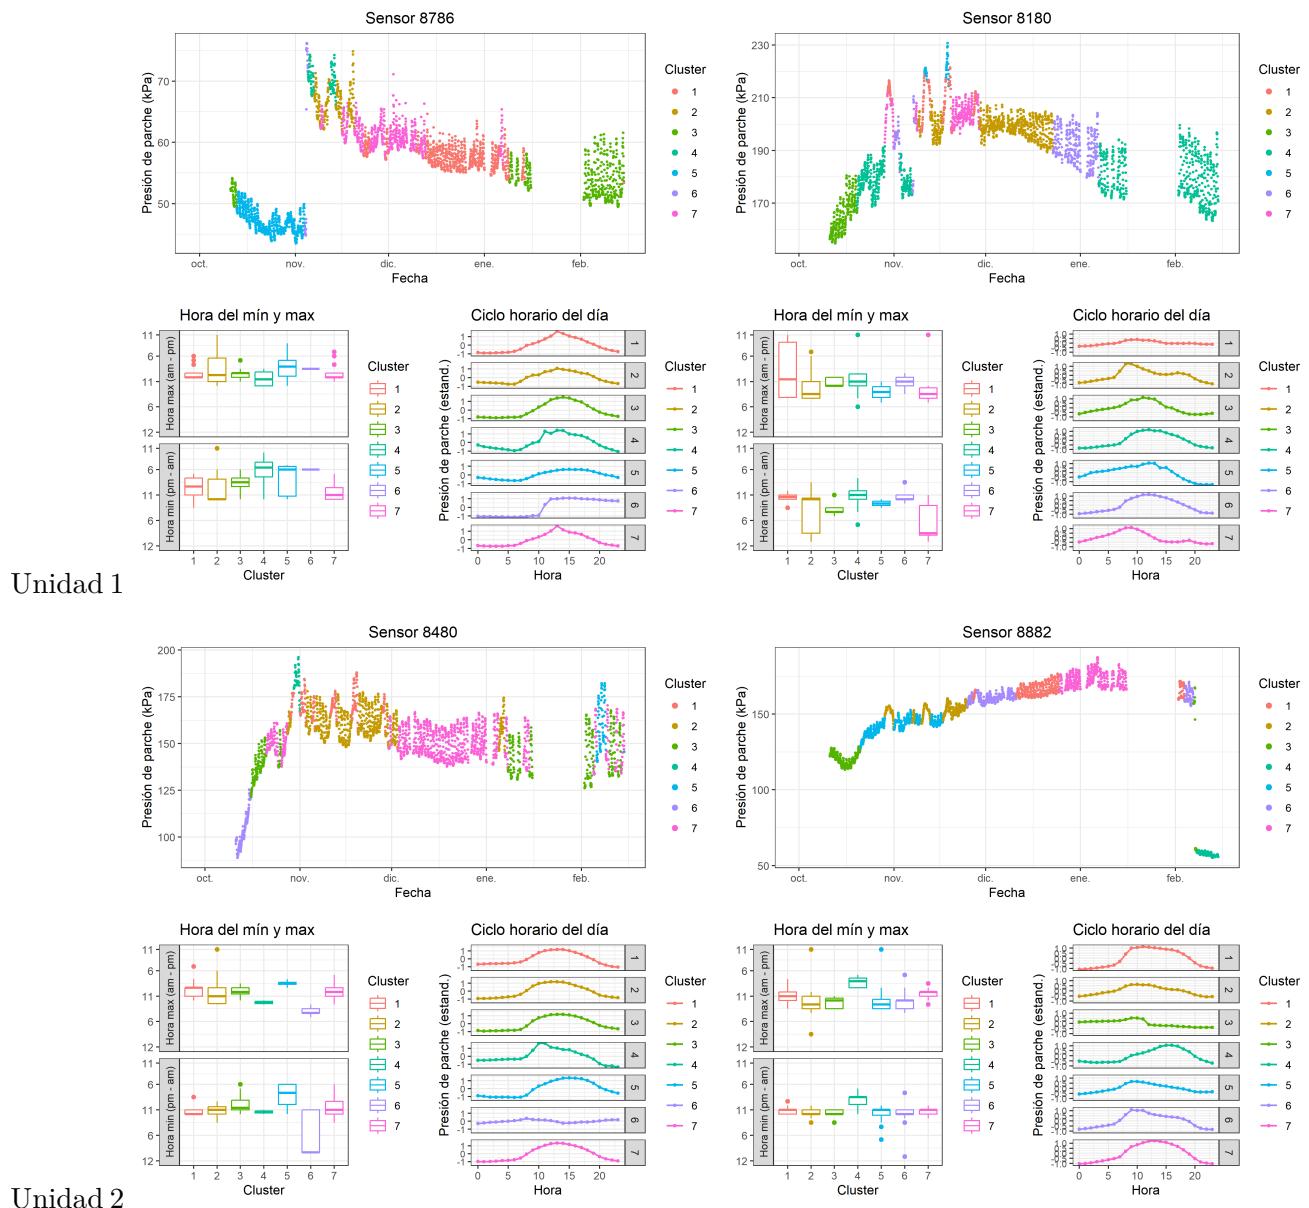


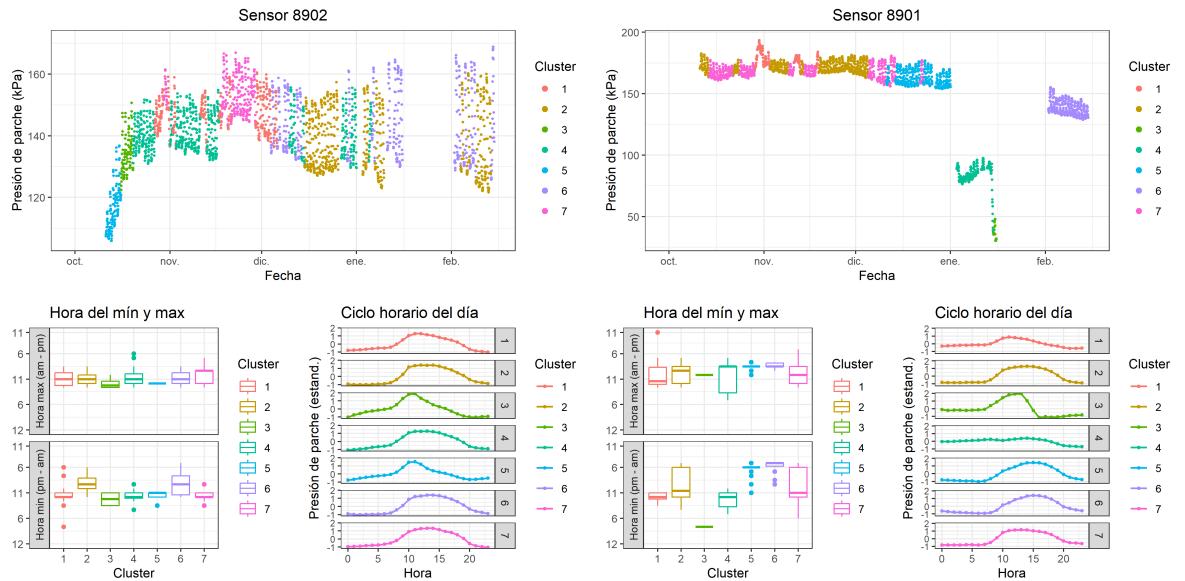
6.5.0.7 T3 (2023-2024)





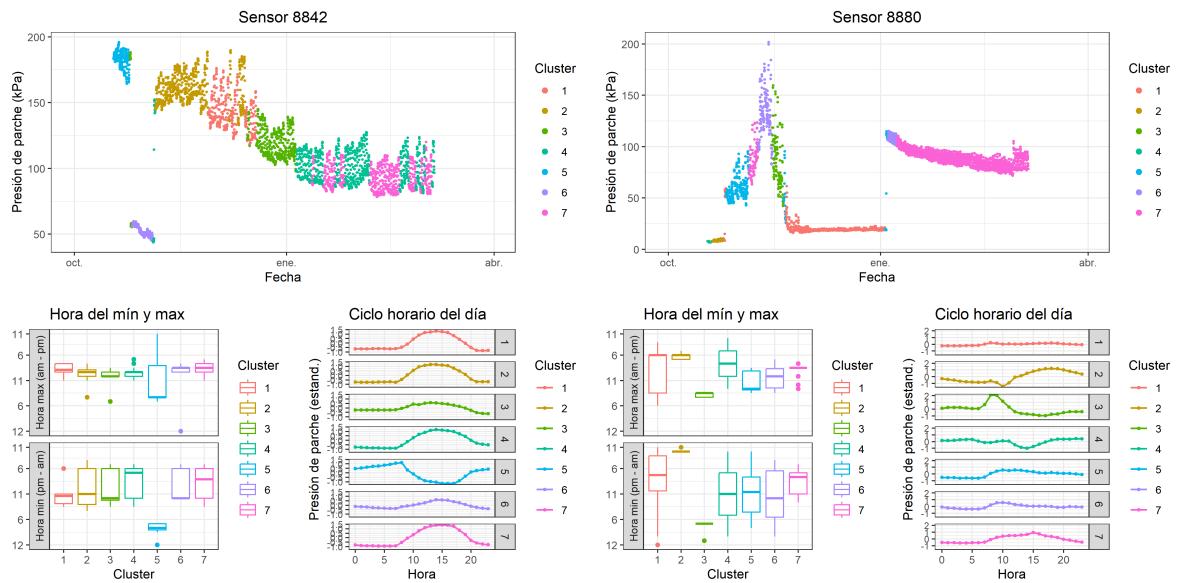
6.5.0.8 T4 (2023-2024)

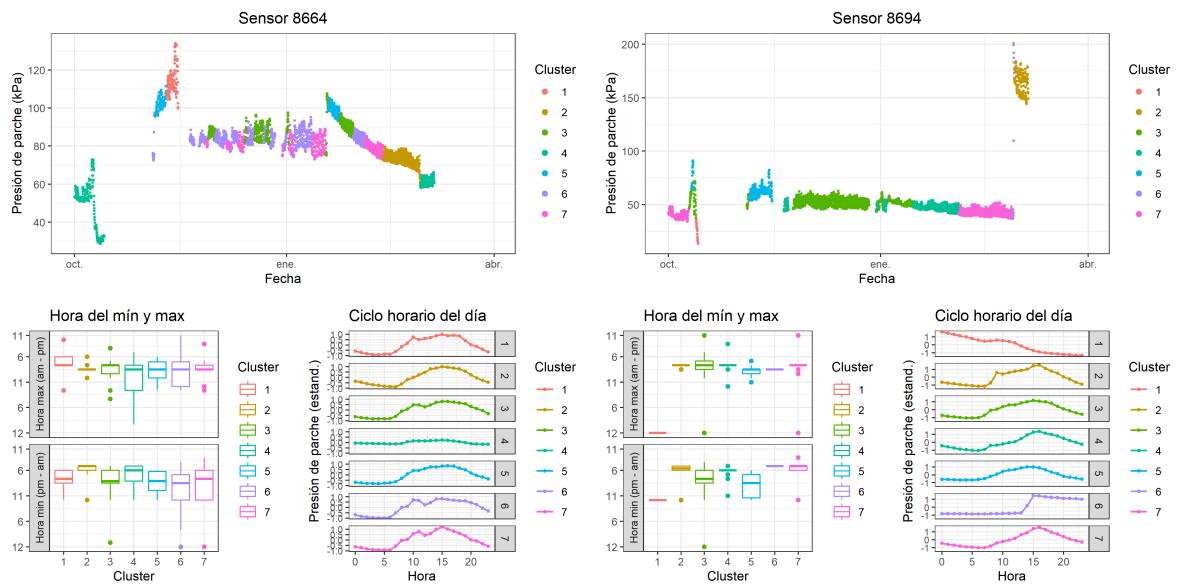
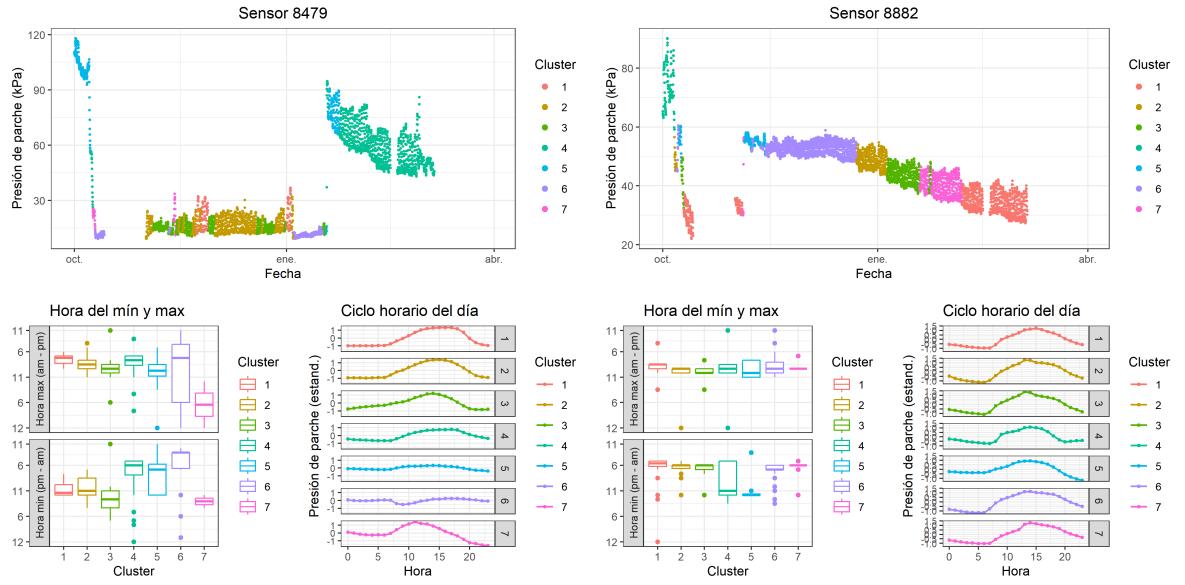




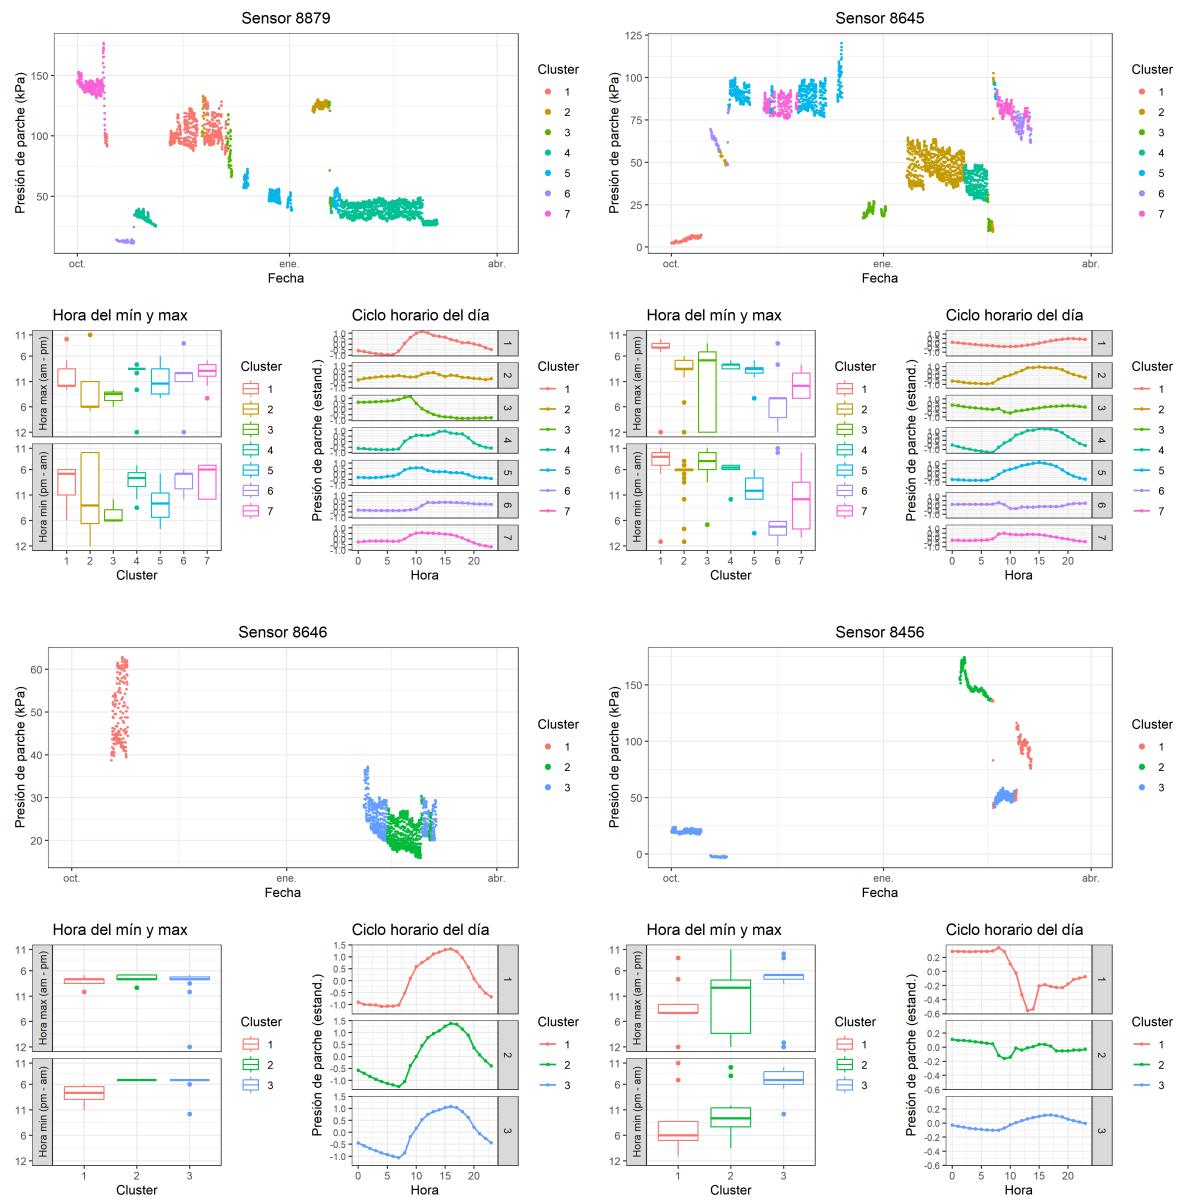
Rio Claro

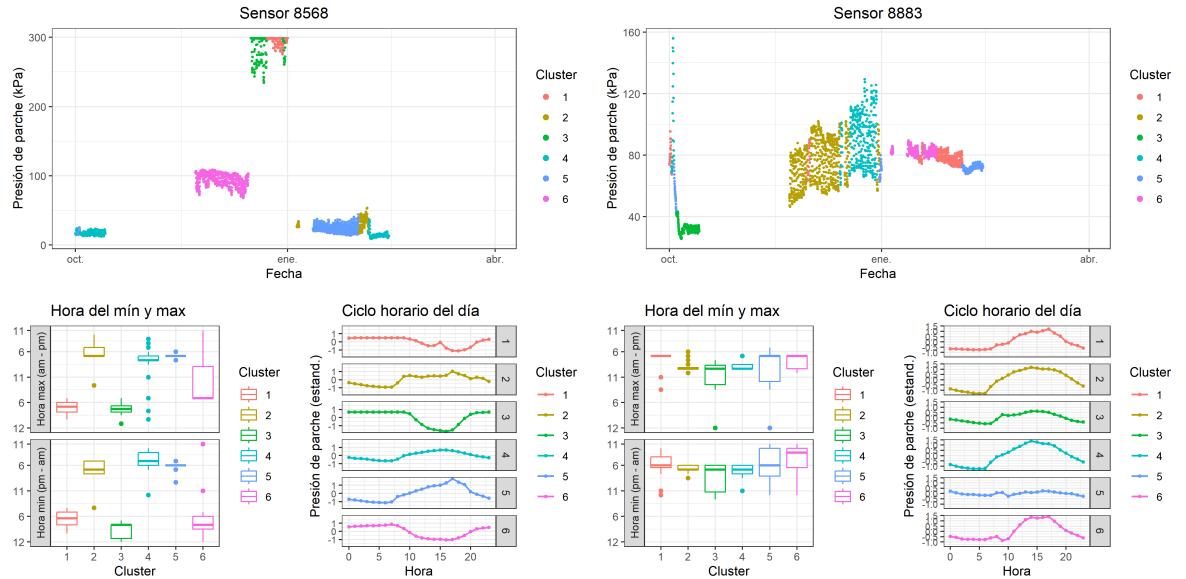
6.5.0.9 T1 (2022-2023)



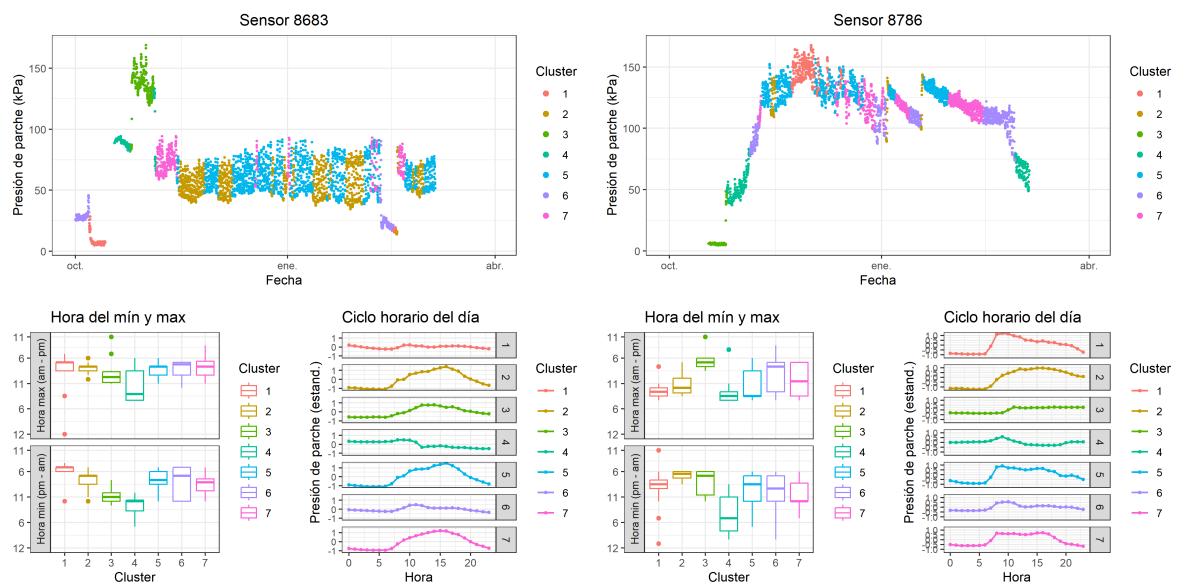


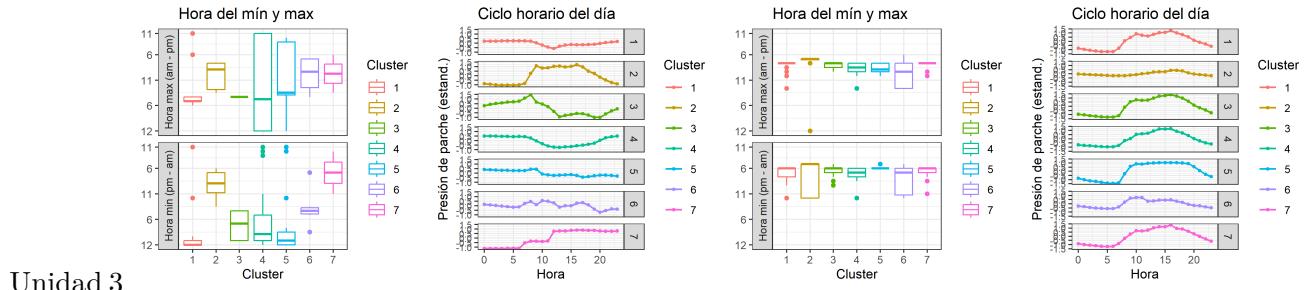
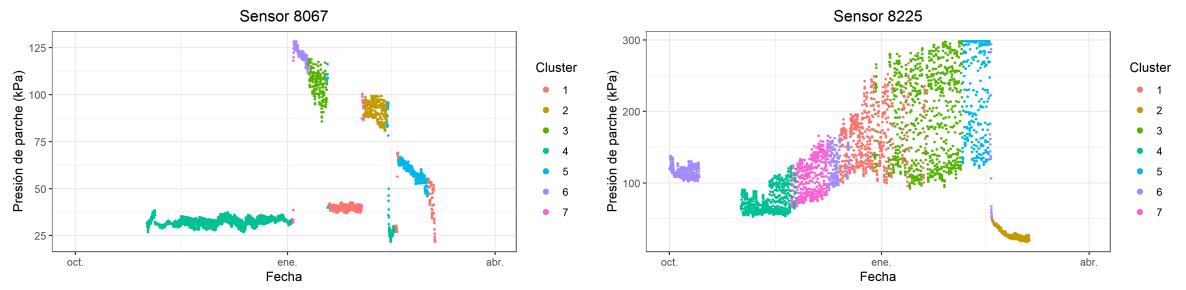
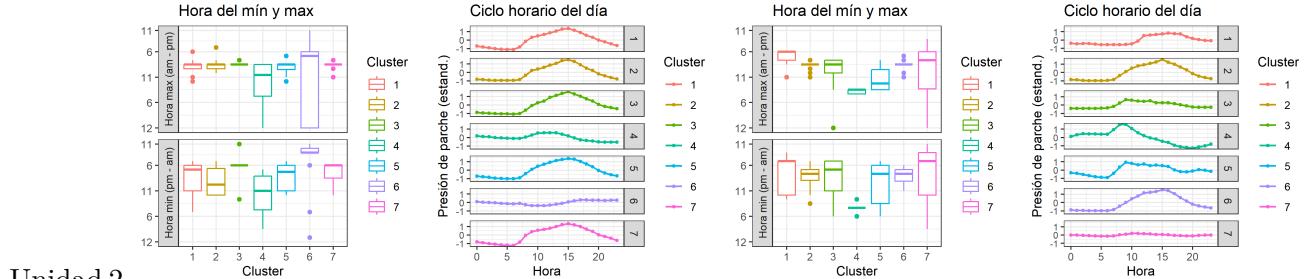
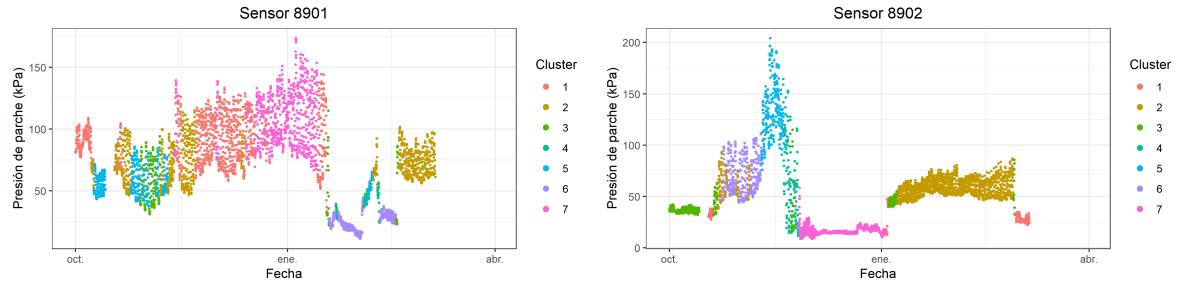
6.5.0.10 T2 (2022-2023)



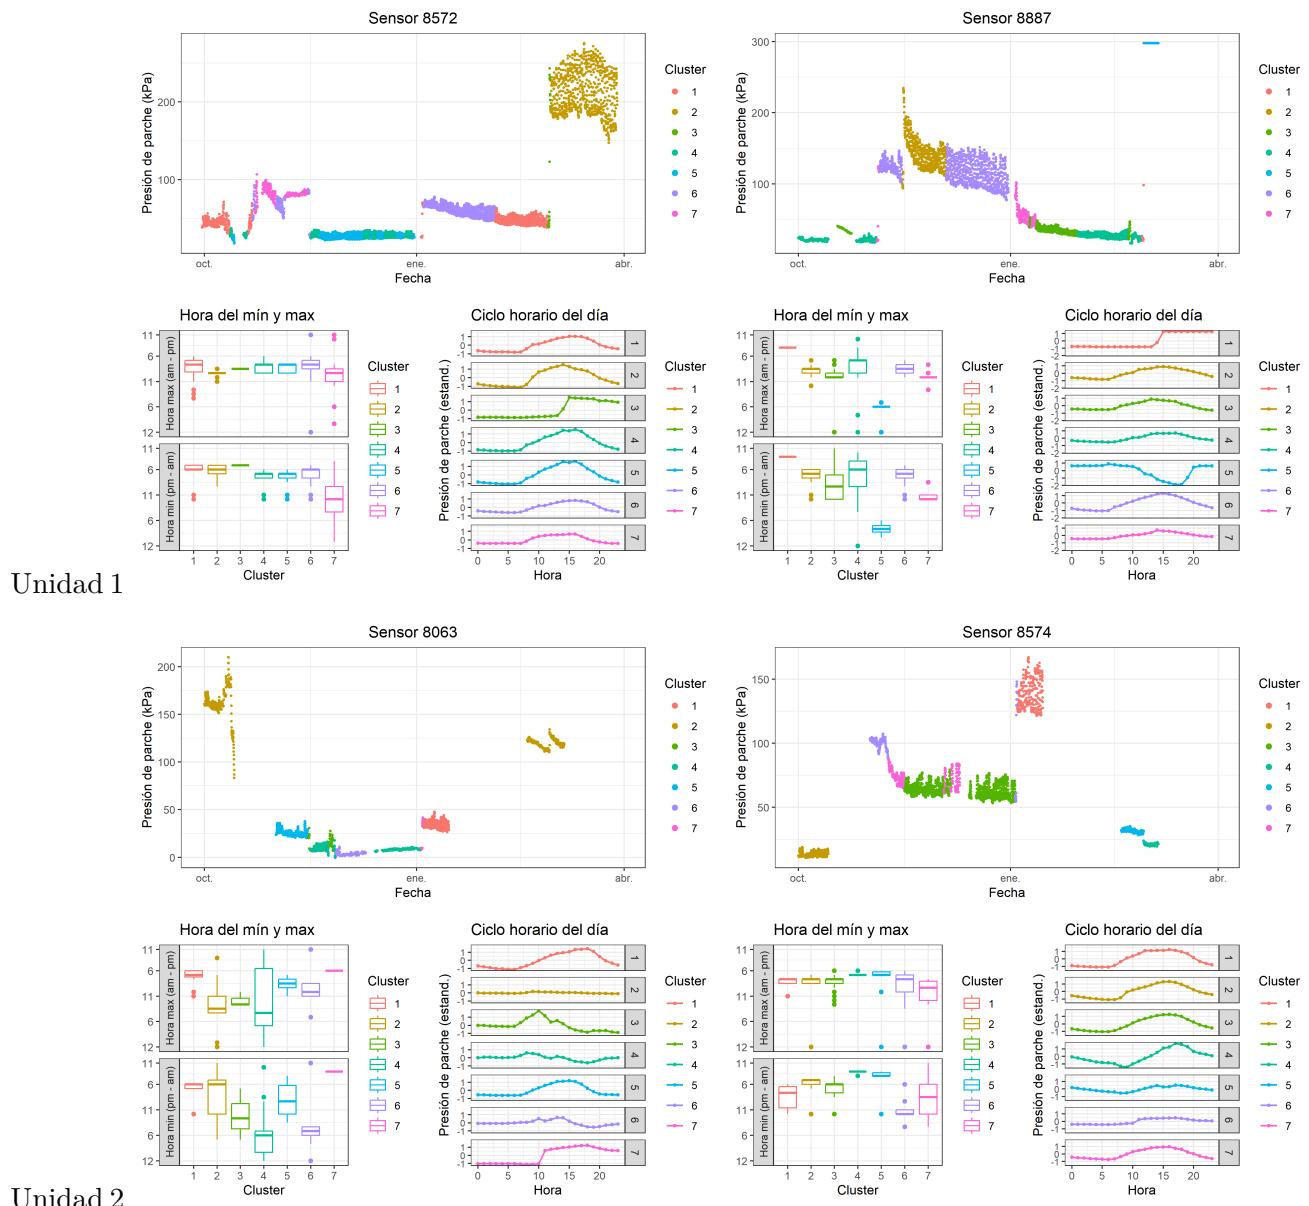


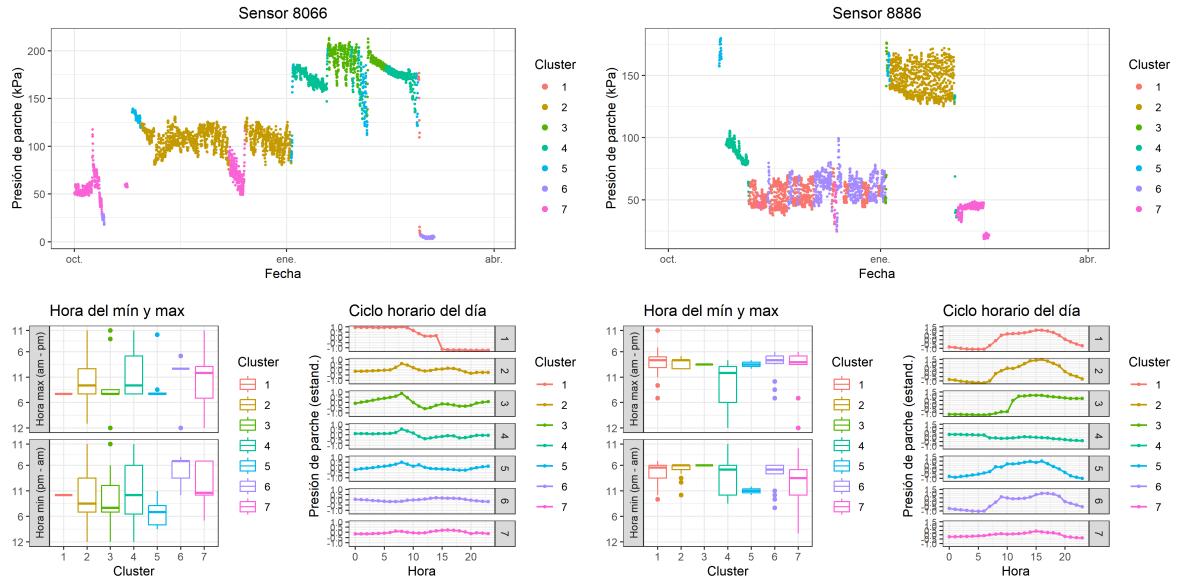
6.5.0.11 T3 (2022-2023)





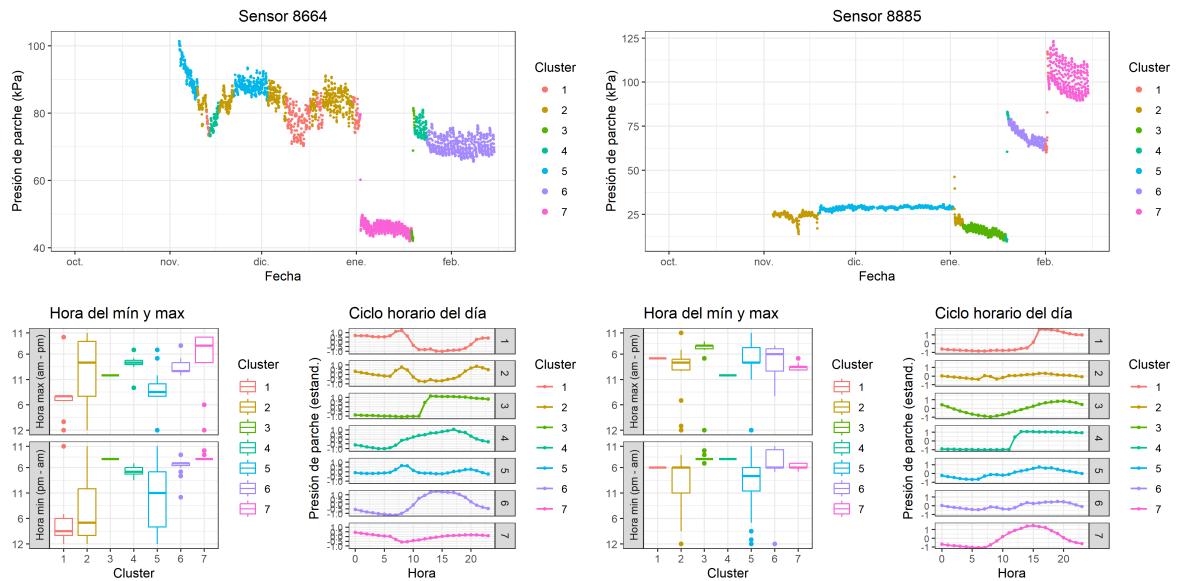
6.5.0.12 T4 (2022-2023)



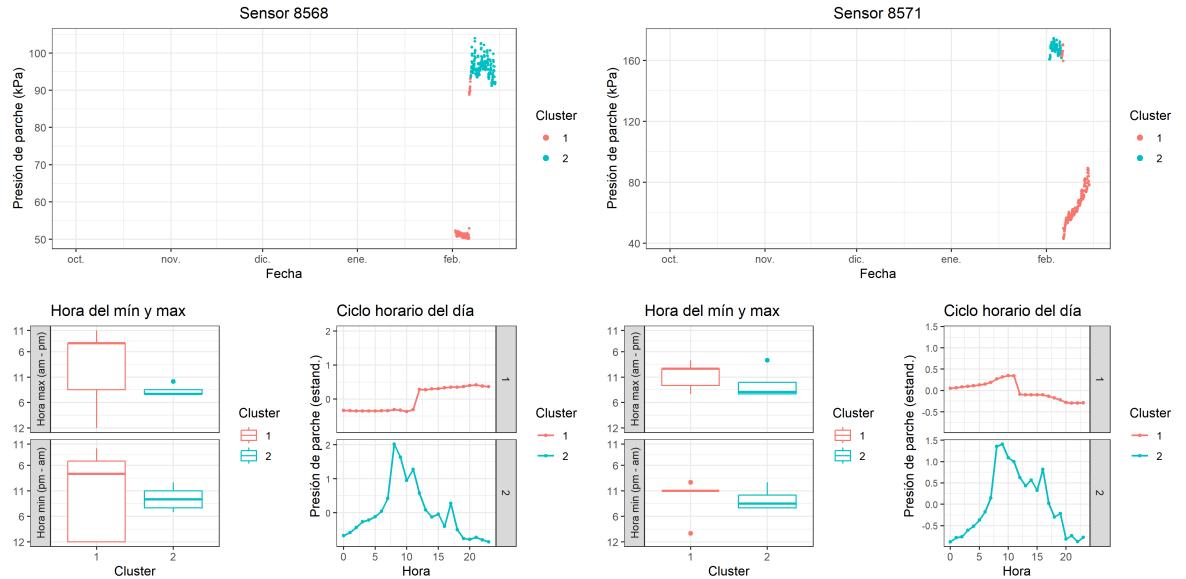


Unidad 3

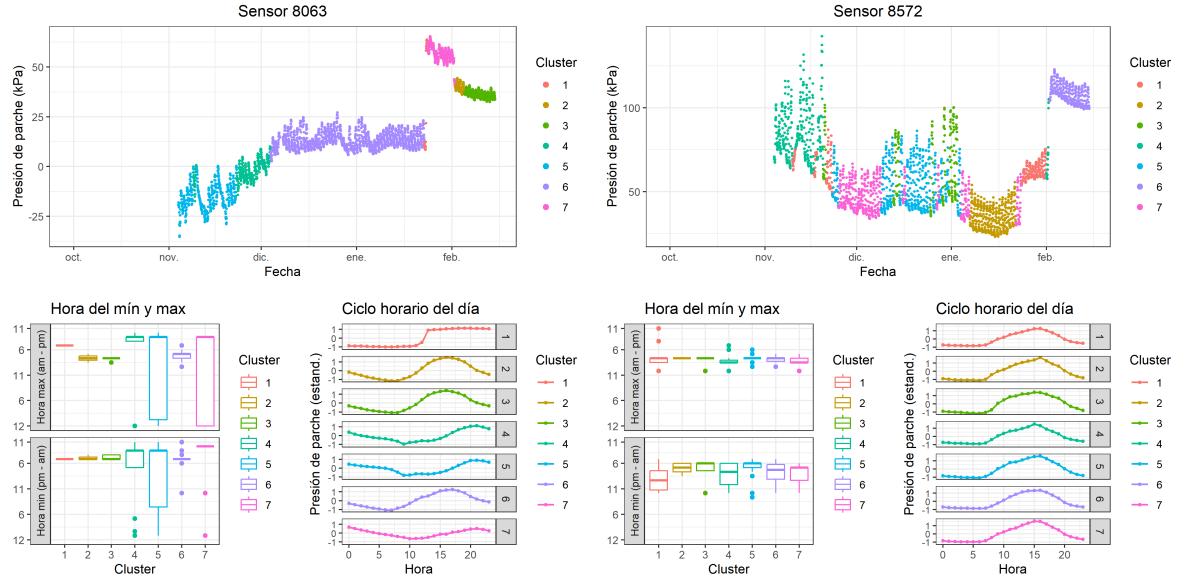
6.5.0.13 T1 (2023-2024)



Unidad 1

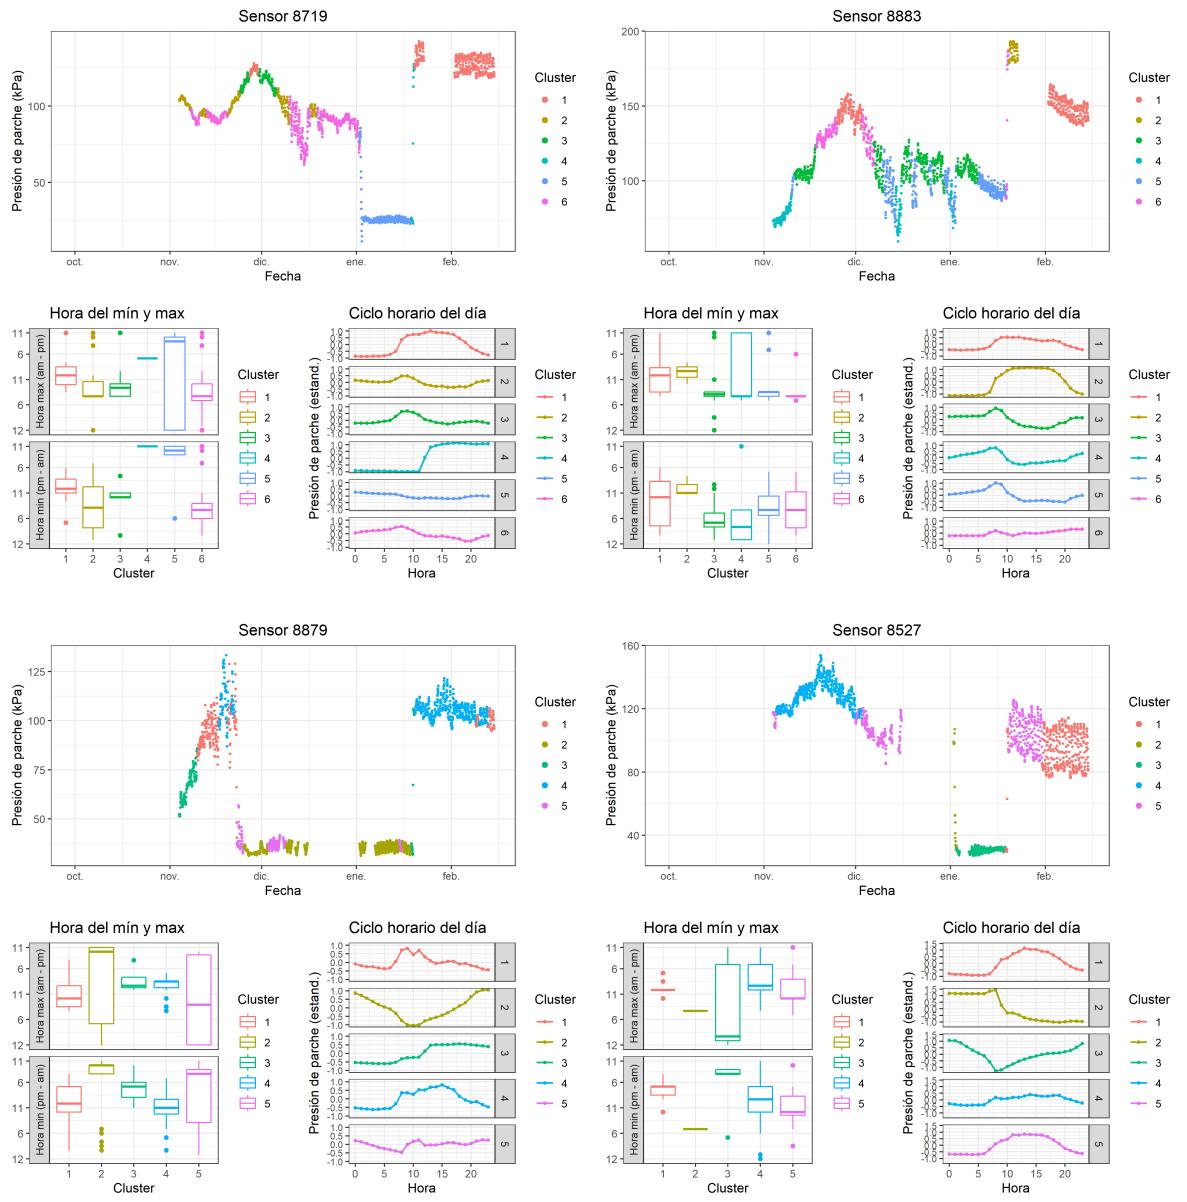


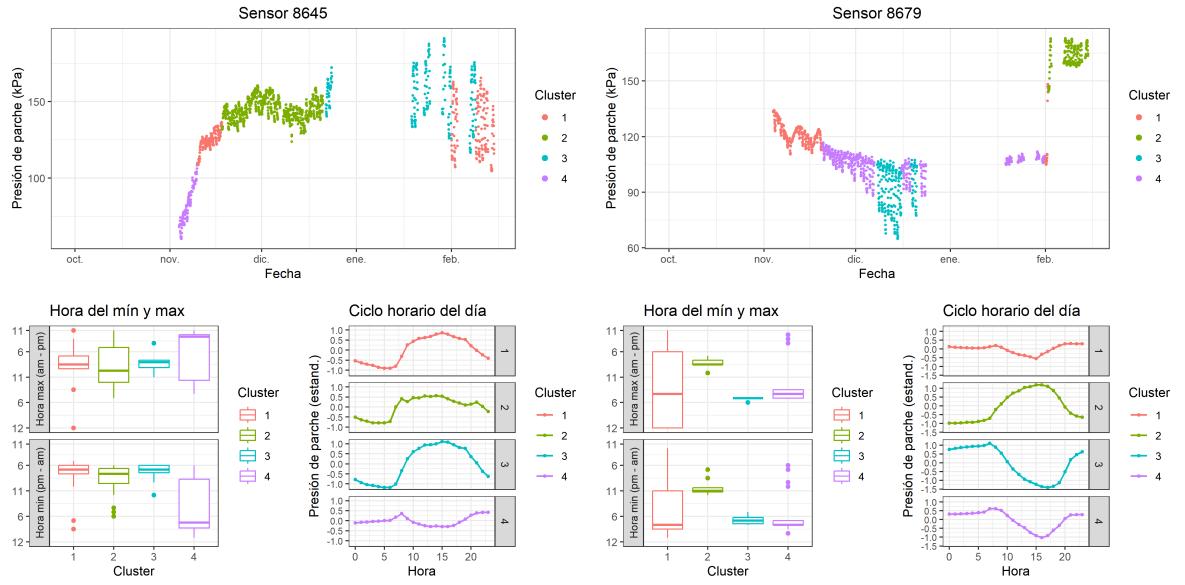
Unidad 2



Unidad 3

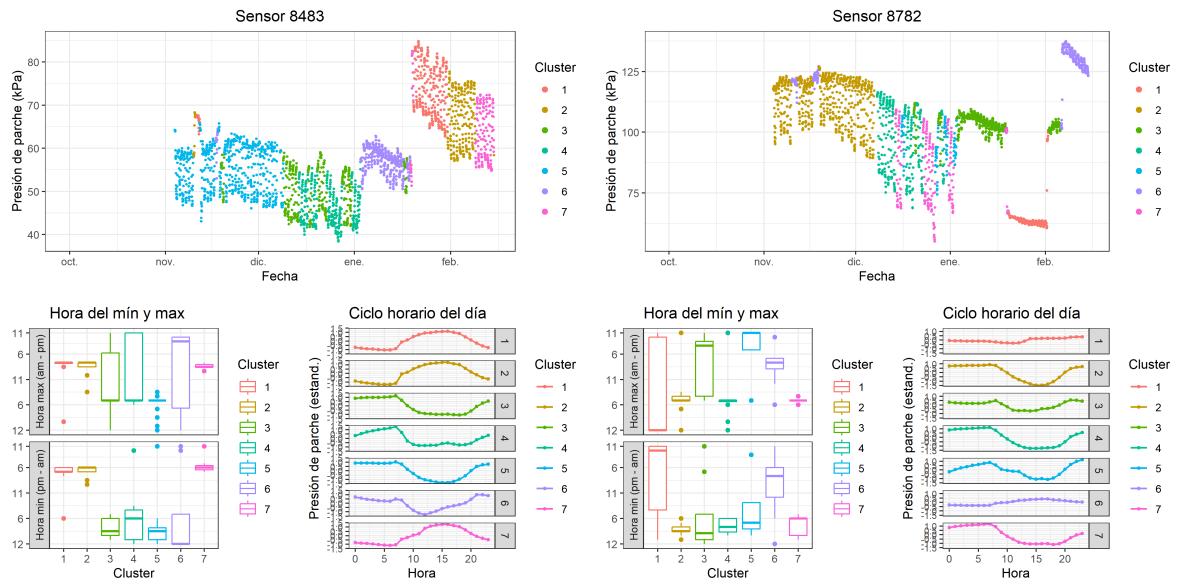
6.5.0.14 T2 (2023-2024)



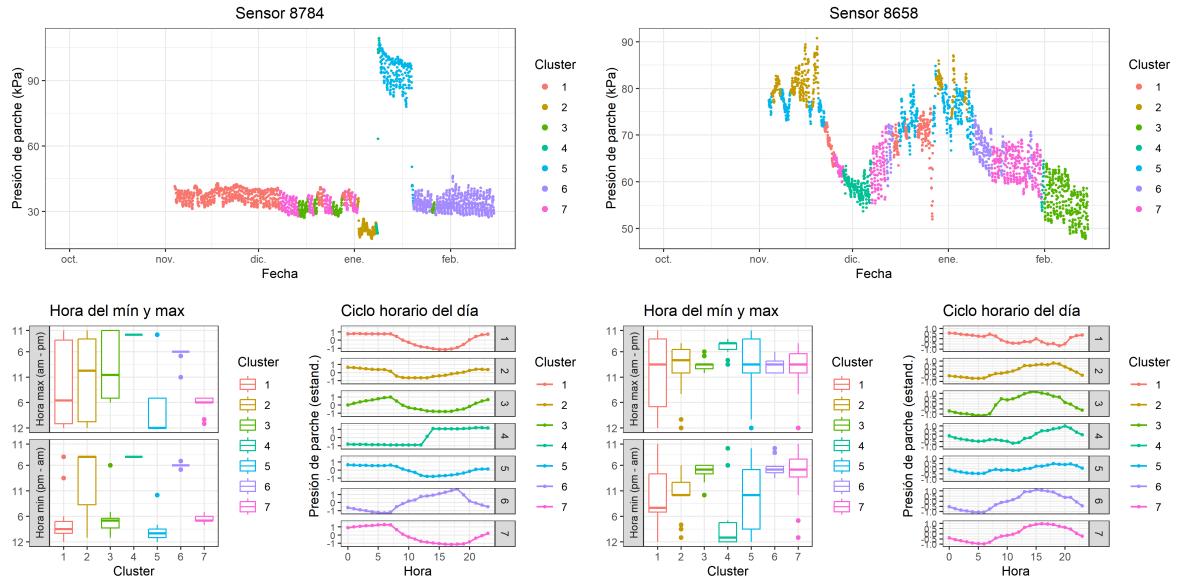


Unidad 3

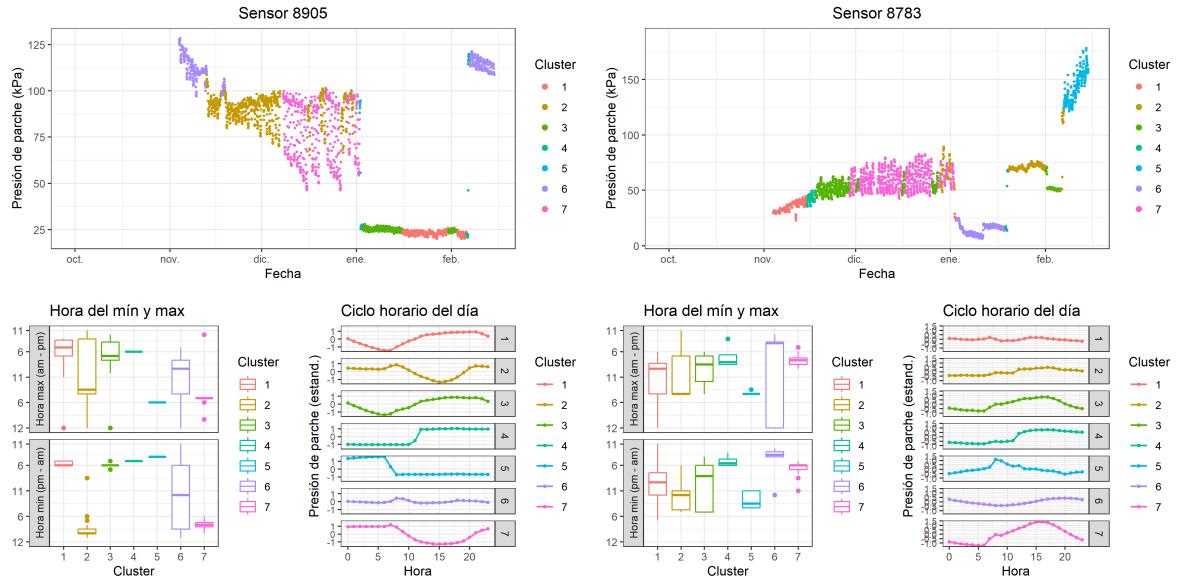
6.5.0.15 T3 (2023-2024)



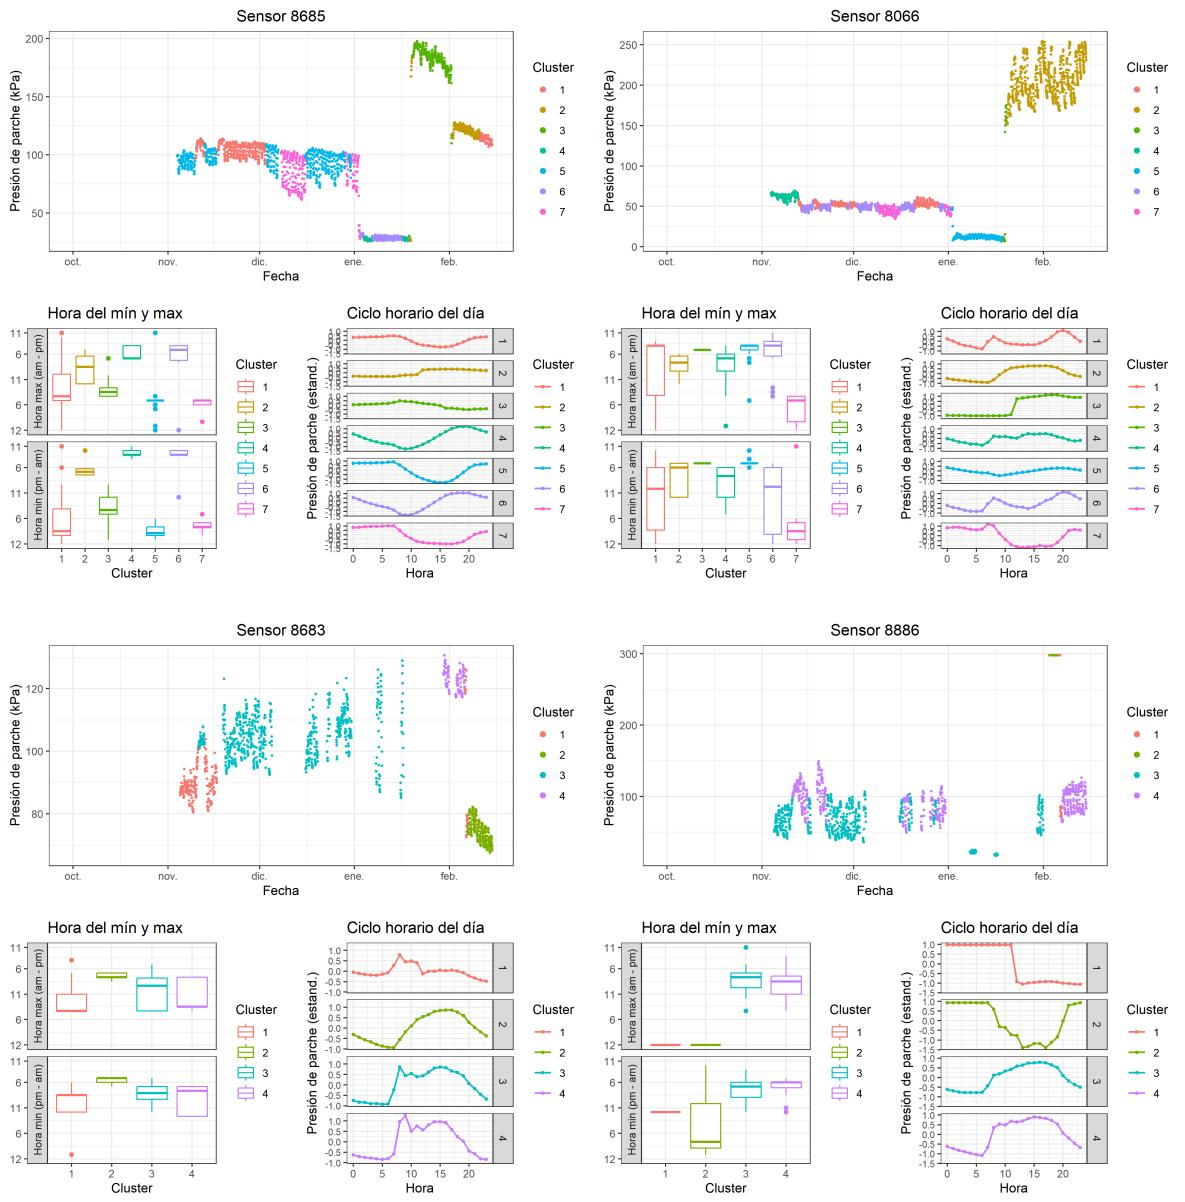
Unidad 1

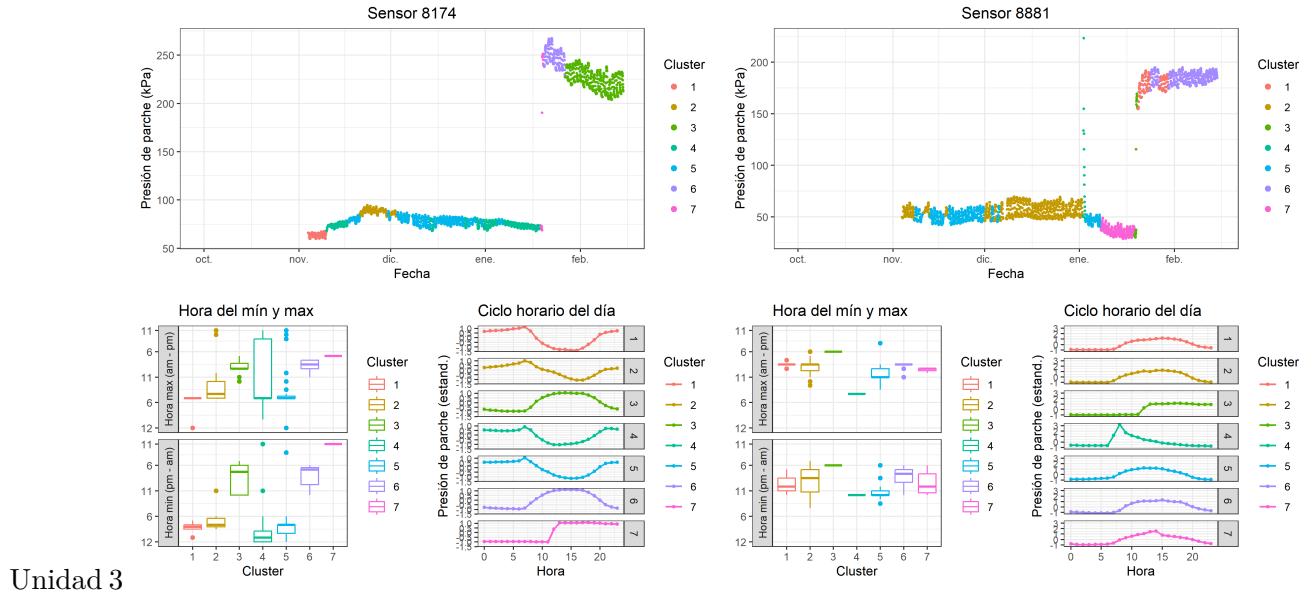


Unidad 2



6.5.0.16 T4 (2023-2024)





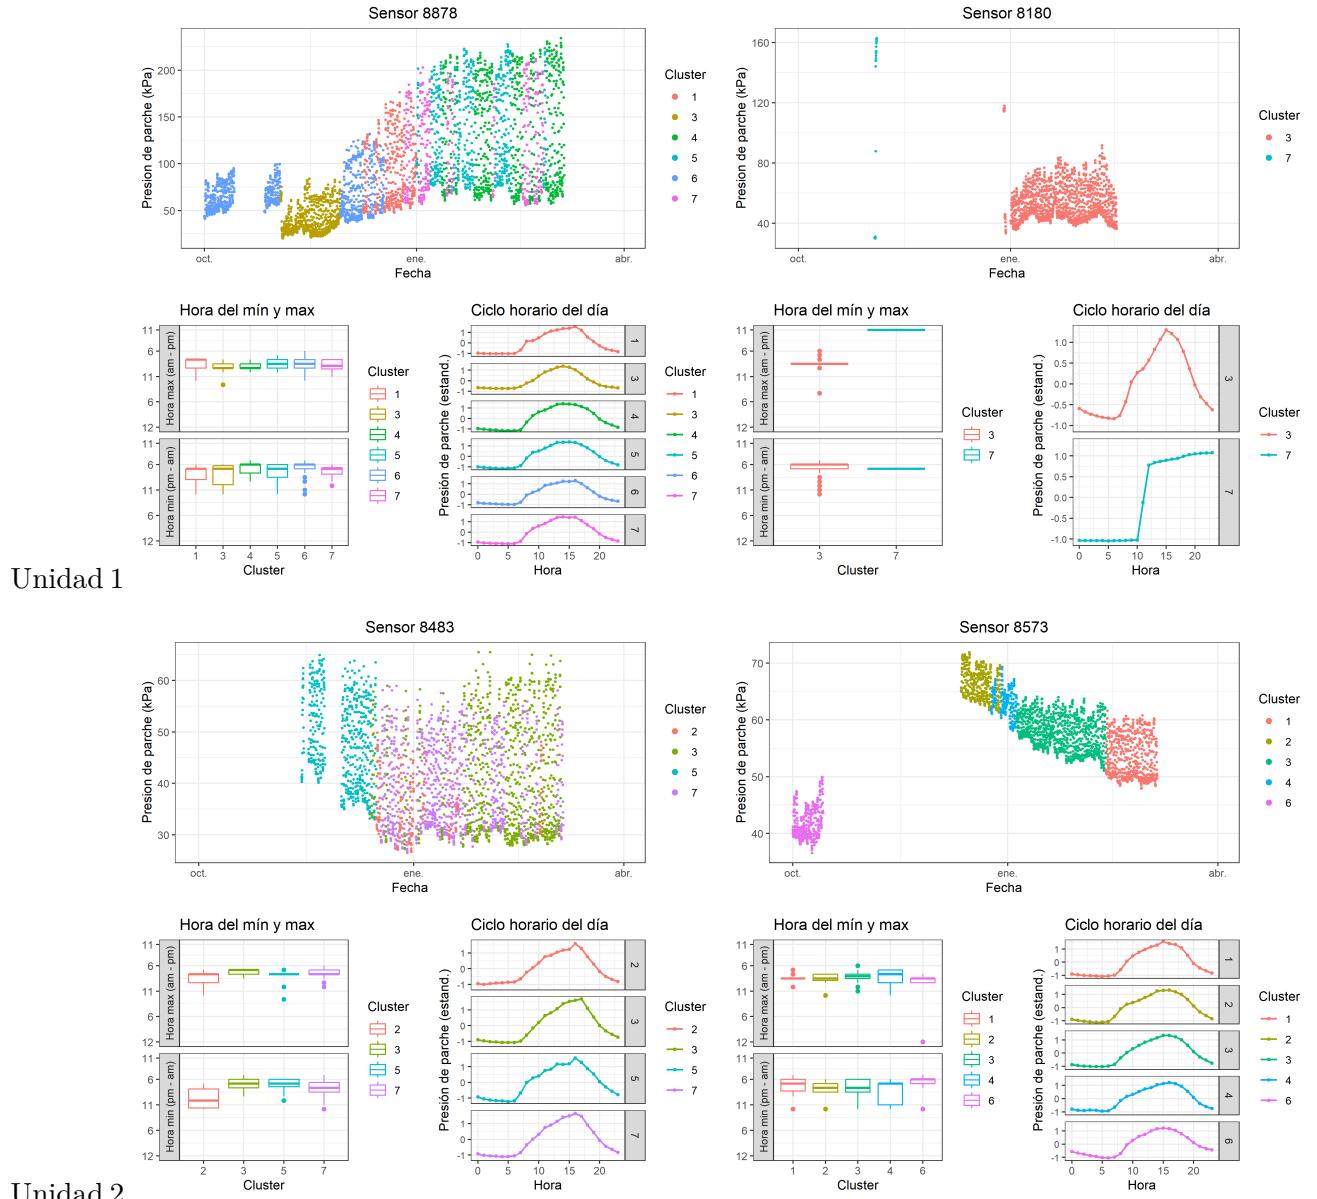
Unidad 3

Limpieza de datos: eliminación de clusters

Para limpiar los datos de turgor, se emplearon series temporales de VPD y temperatura provenientes de las estaciones meteorológicas de los dos sitios de estudio. Se procedió a calcular el coeficiente de correlación entre cada cluster y los valores de VPD y temperatura respecto al tiempo (escala horaria) y el sitio. Se obtuvo un coeficiente de correlación promedio en relación con ambas variables, y se estableció un umbral de corte de $r > 0.5$. Aquellos clusters de turgor cuyo promedio de correlación resultó menor a 0.5 fueron descartados.

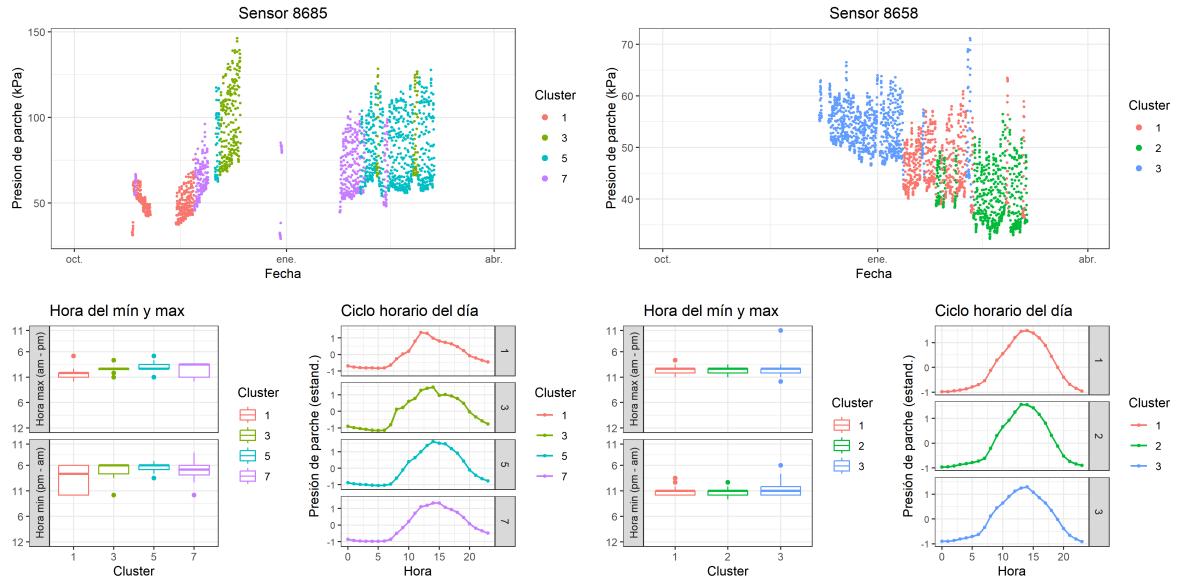
La Esperanza

6.5.0.1 T1 (2022-2023)



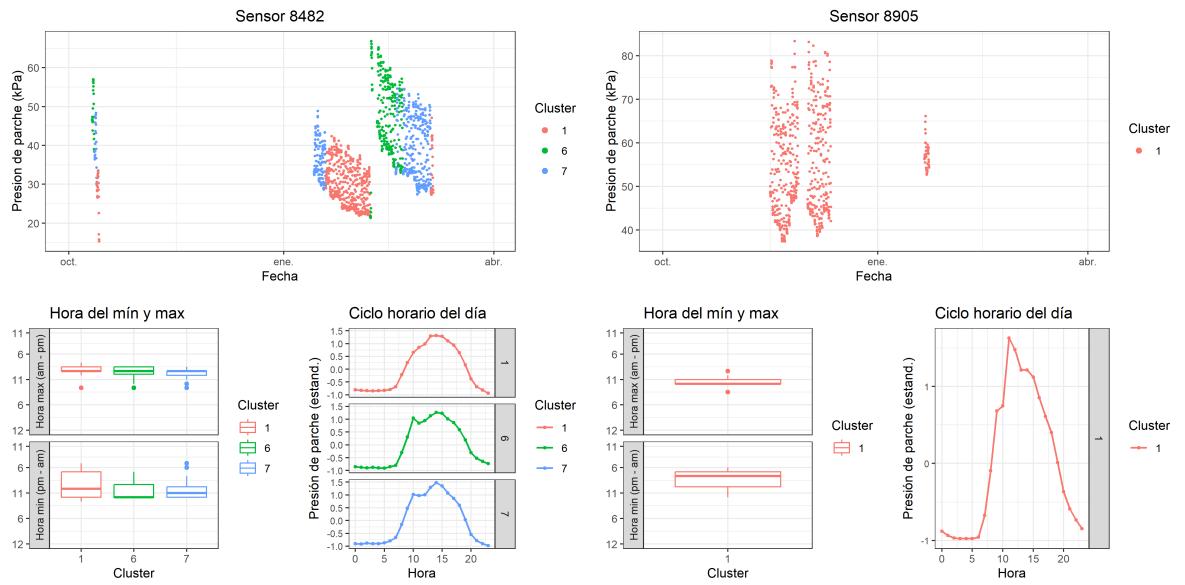
Unidad 1

Unidad 2

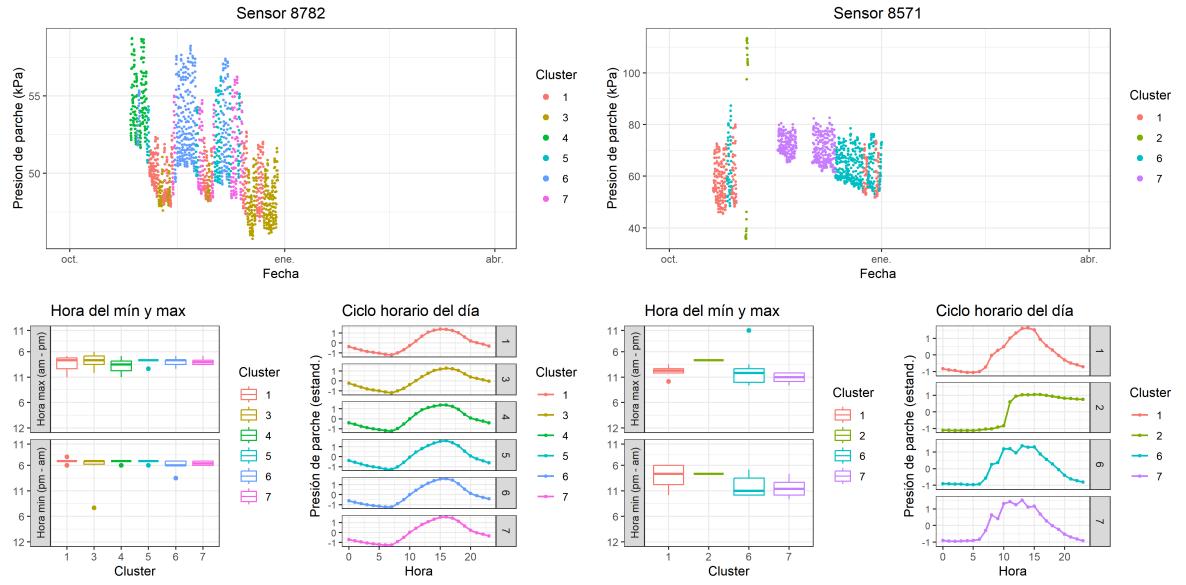


Unidad 3

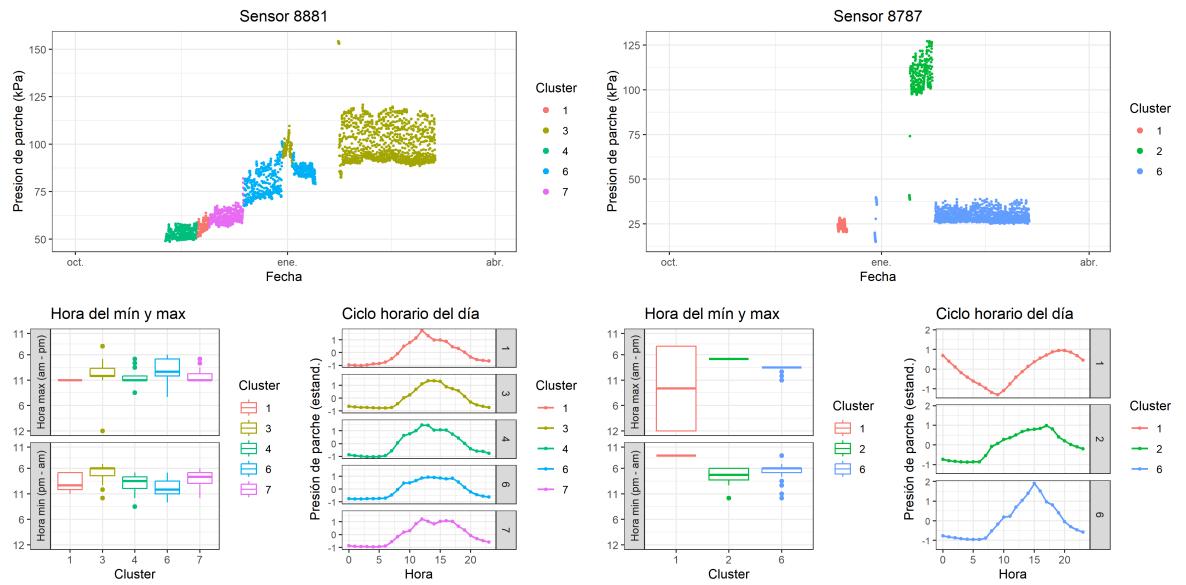
6.5.0.2 T2 (2022-2023)



Unidad 1

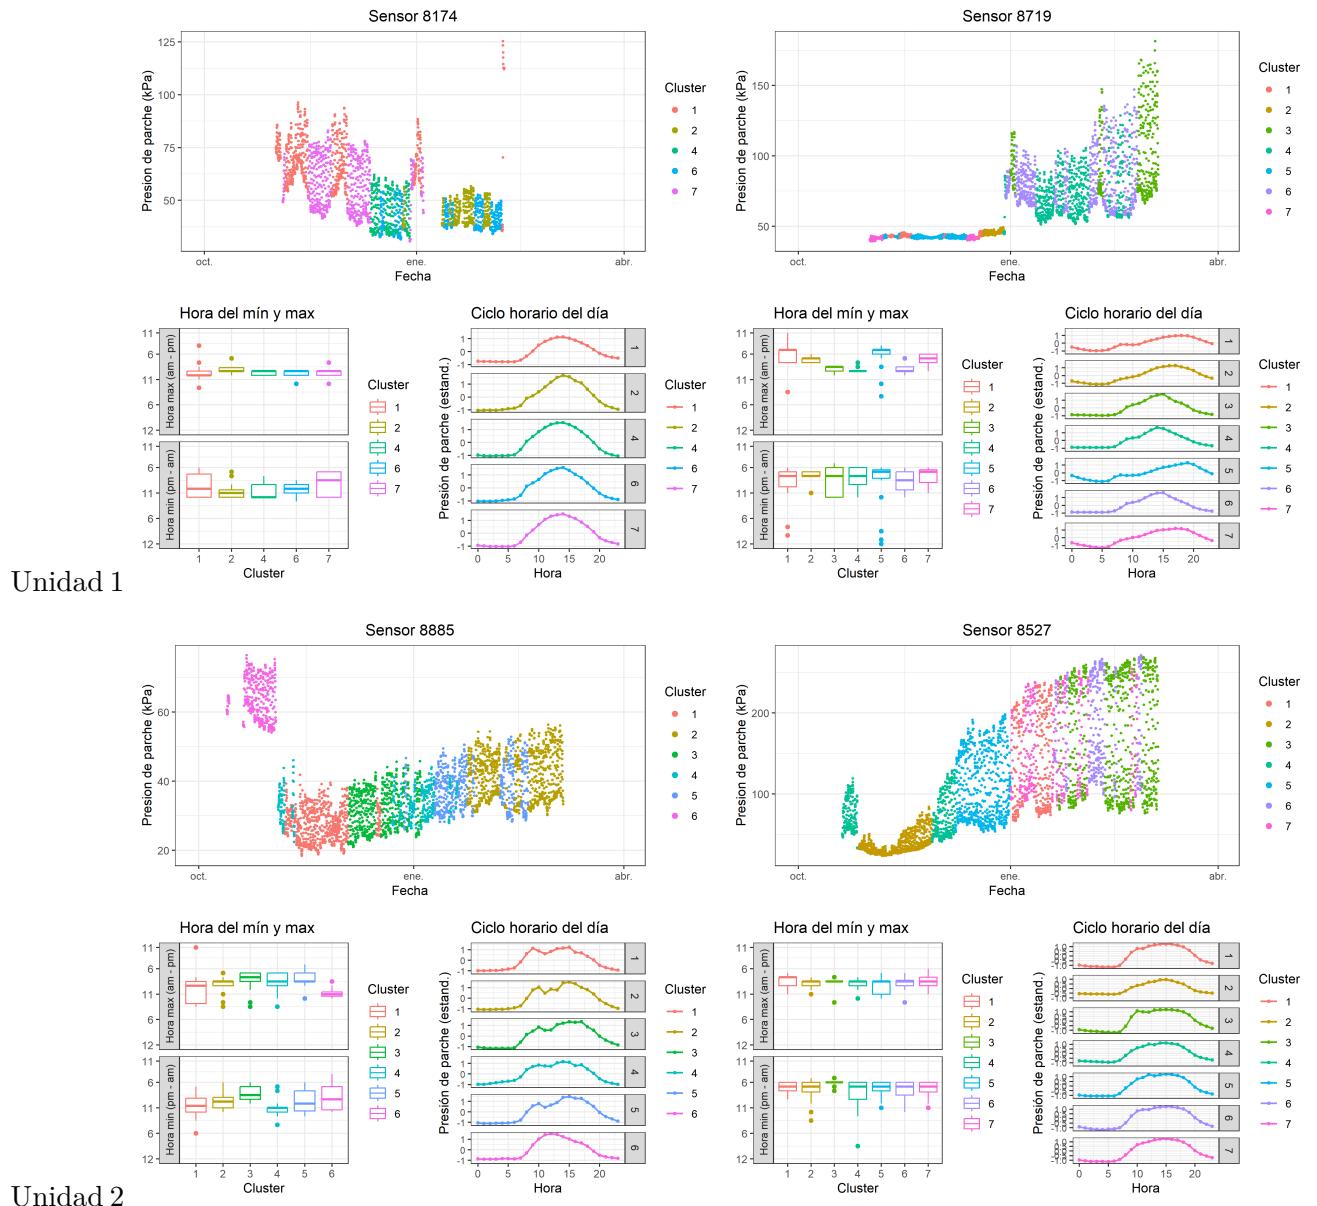


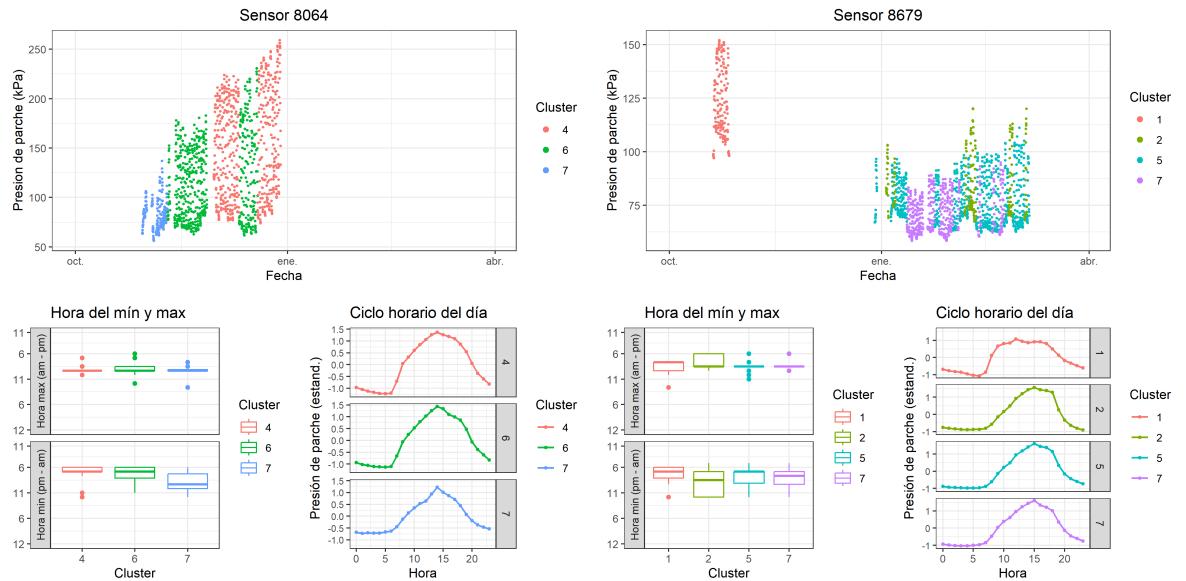
Unidad 2



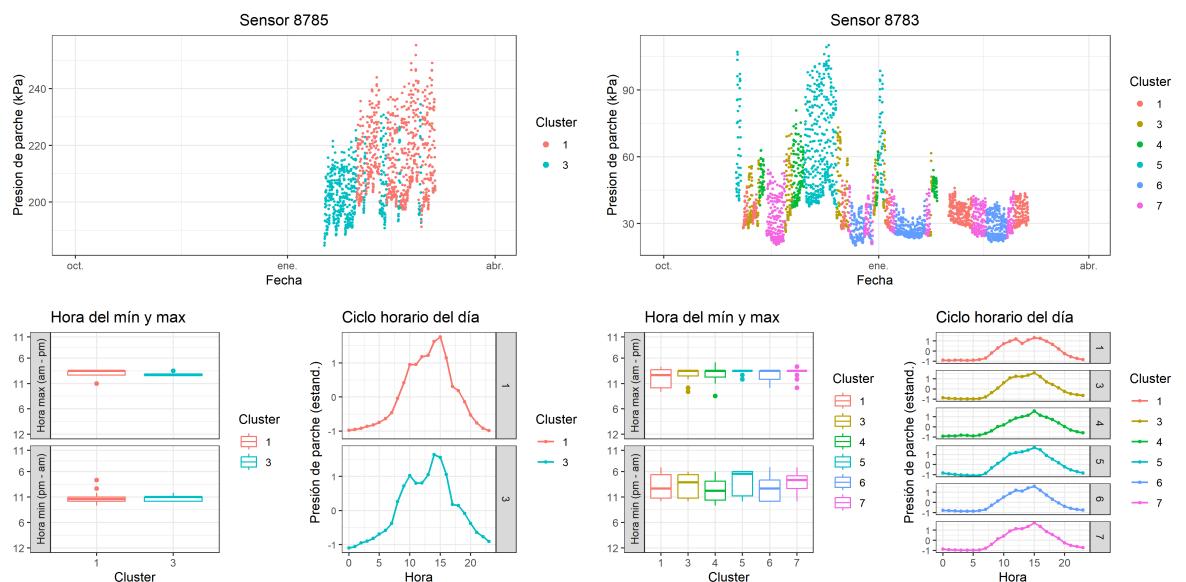
Unidad 3

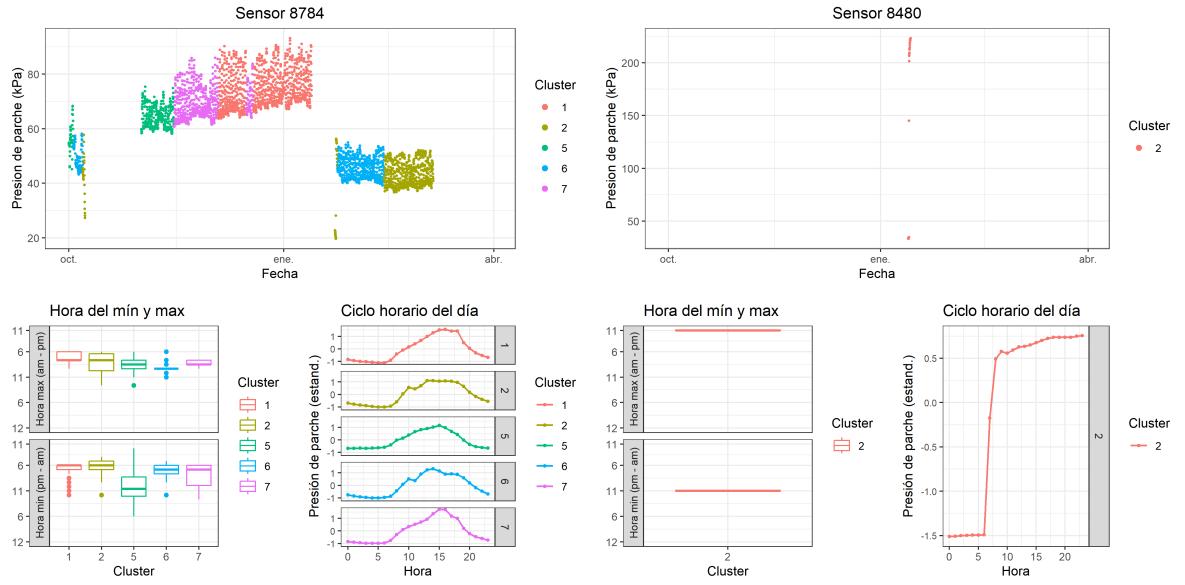
6.5.0.3 T3 (2022-2023)



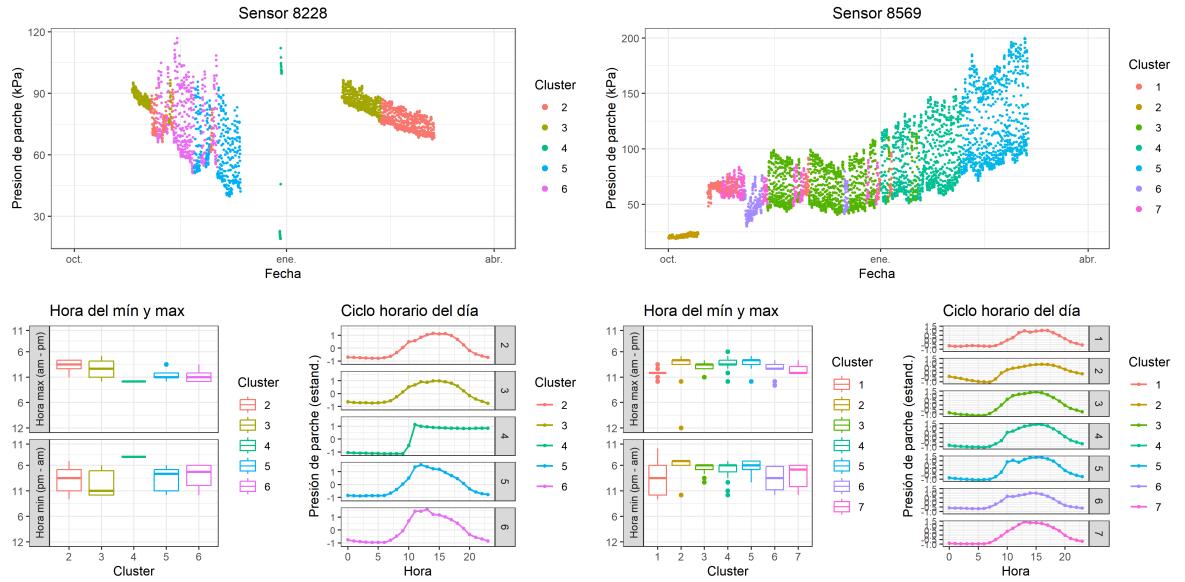


6.5.0.4 T4 (2022-2023)

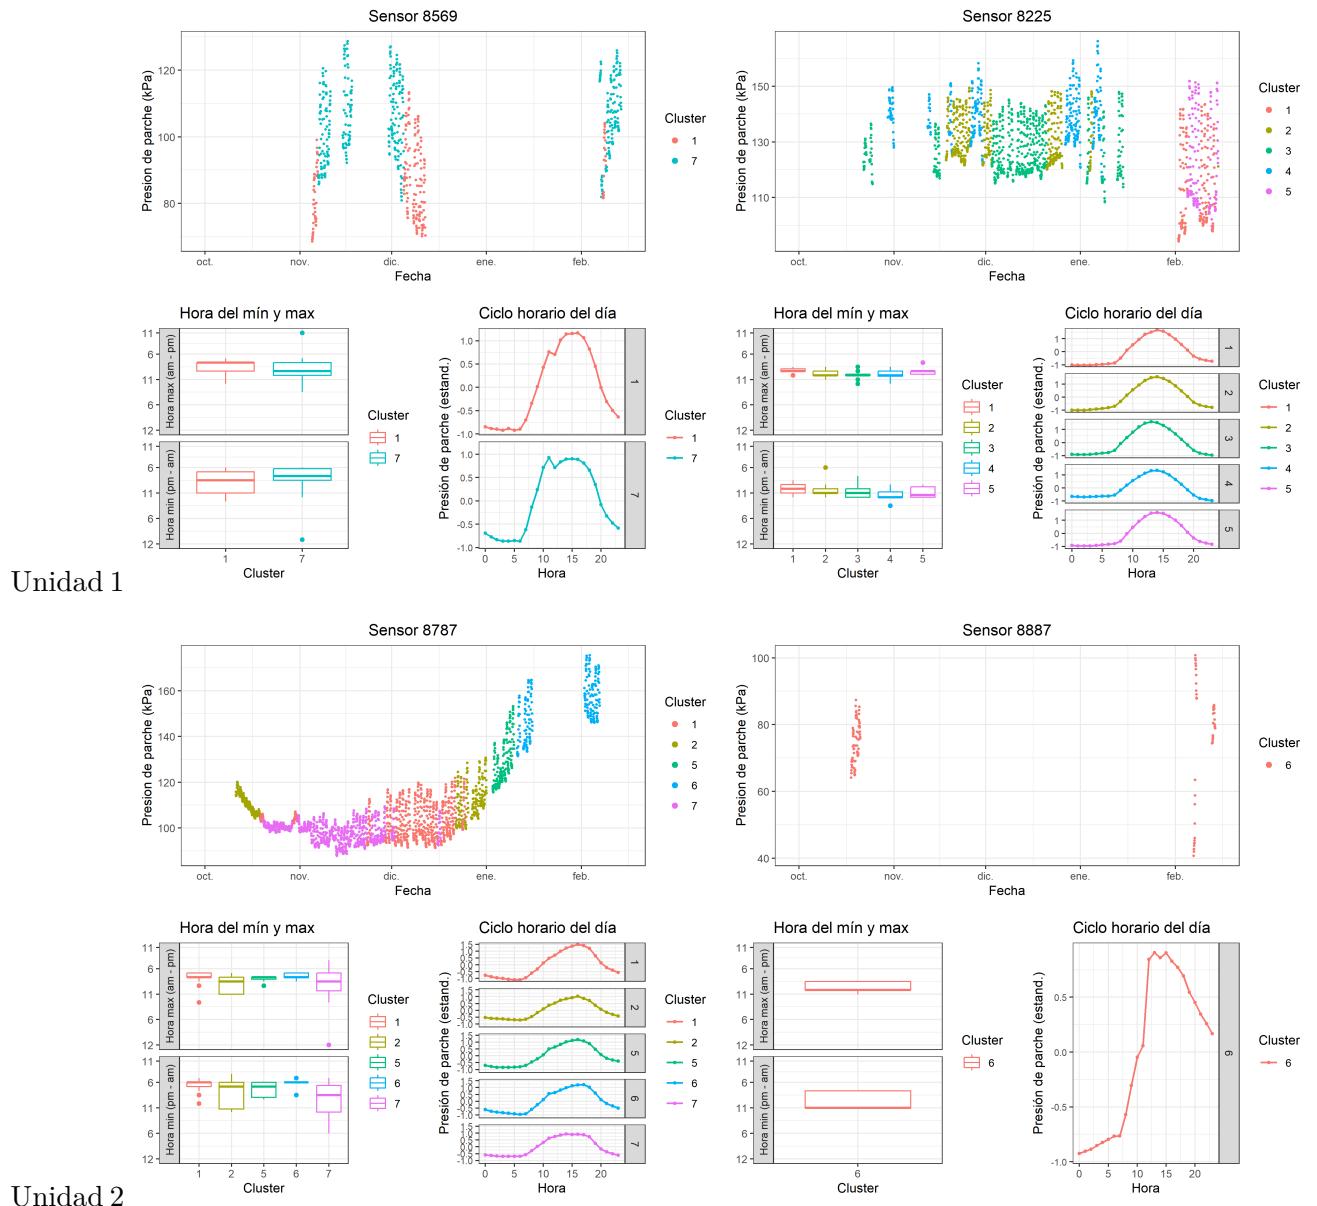


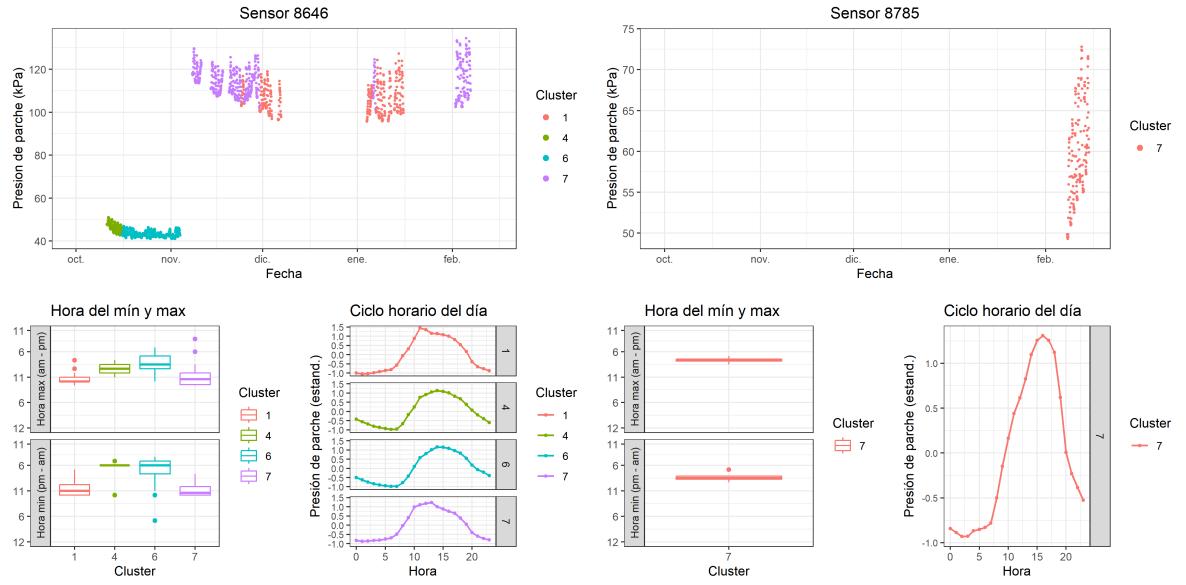


Unidad 2

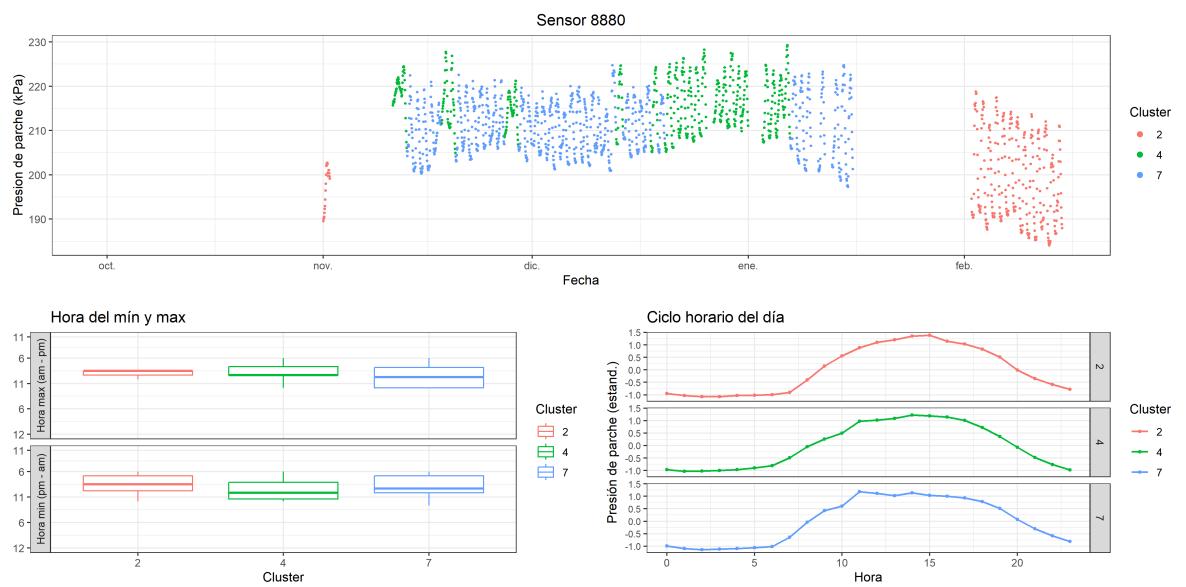


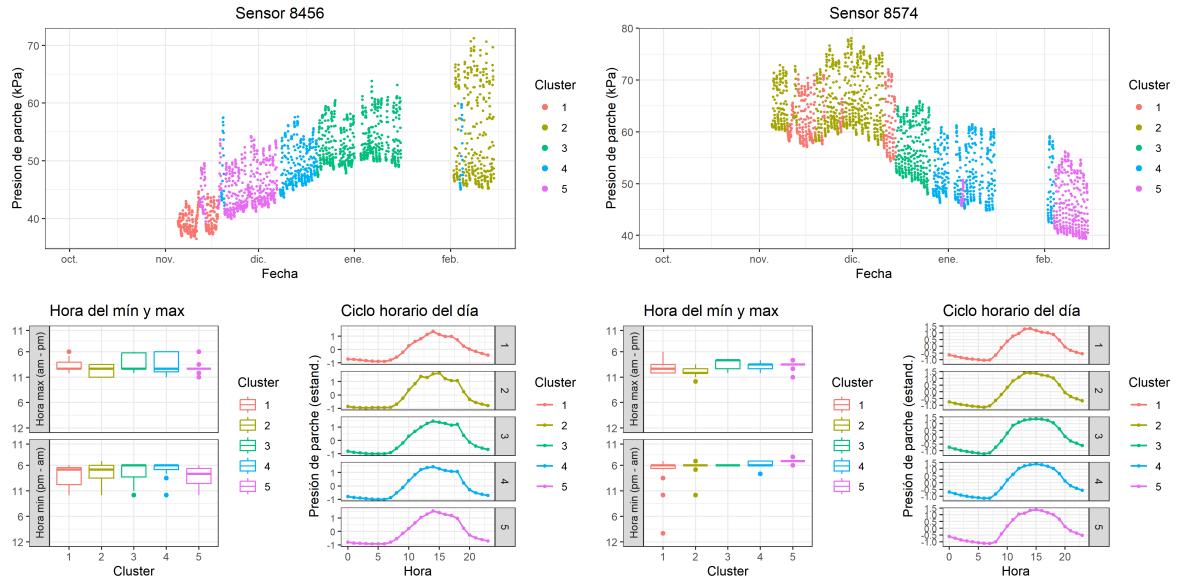
6.5.0.5 T1 (2023-2024)



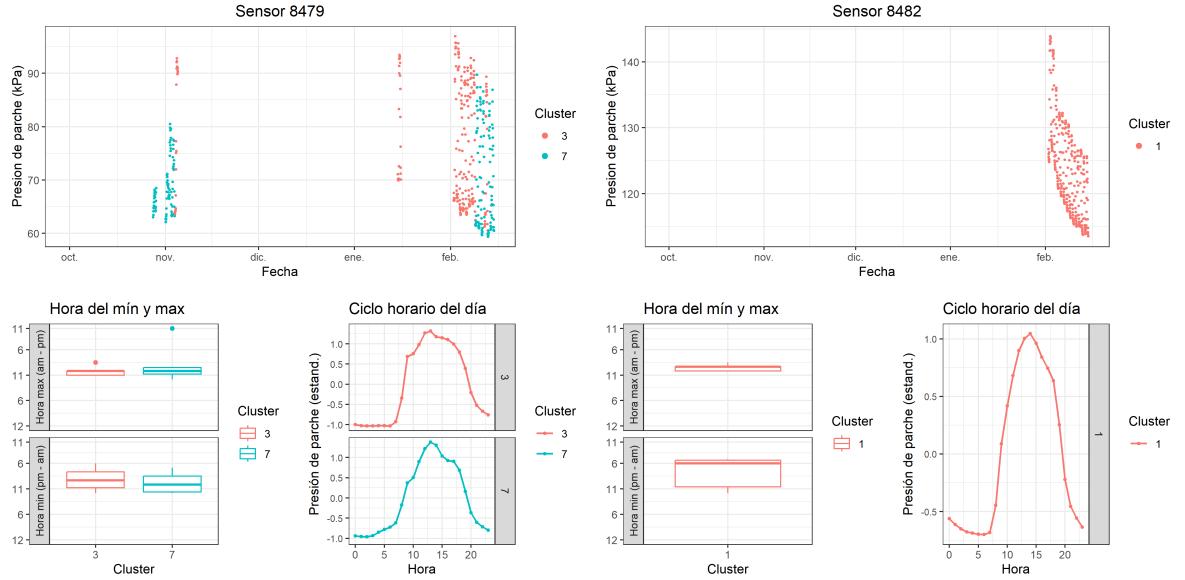


6.5.0.6 T2 (2023-2024)



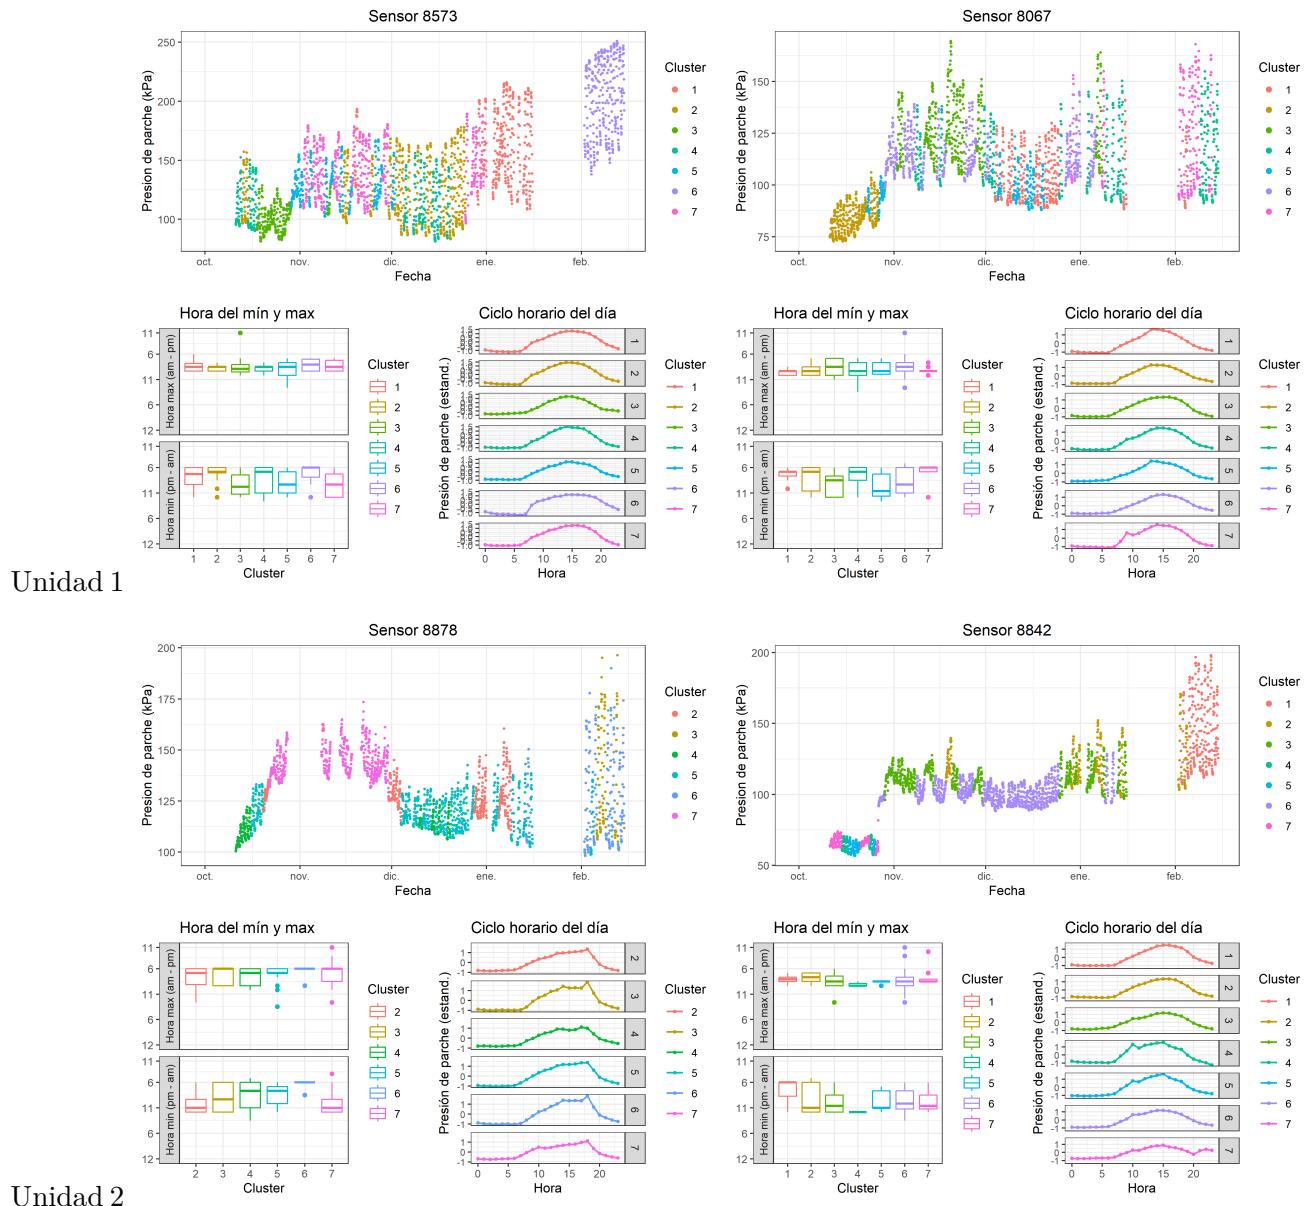


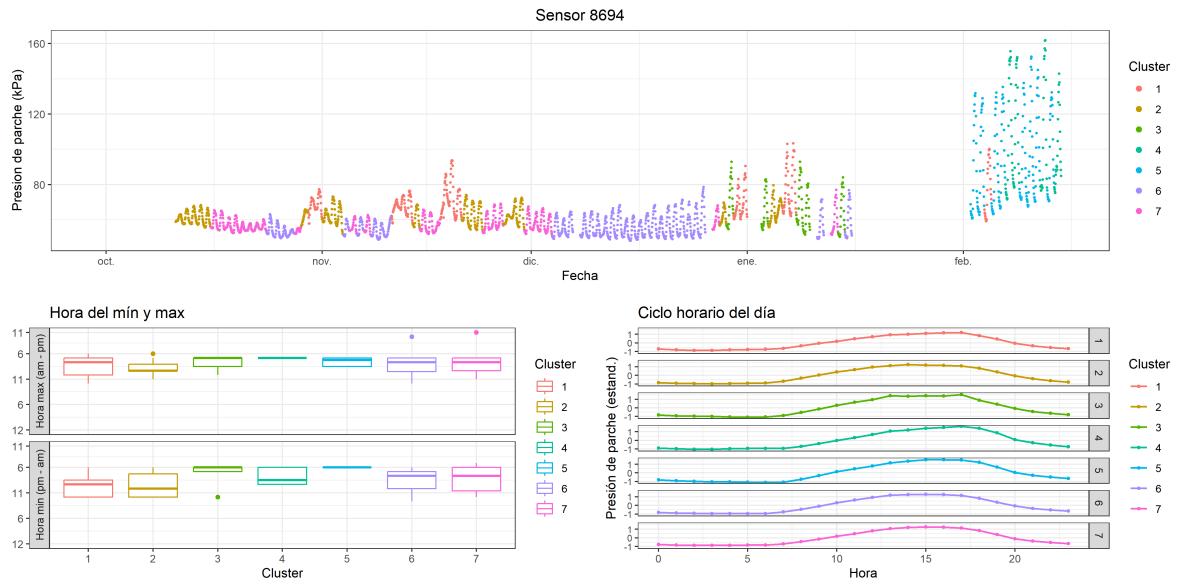
Unidad 2



Unidad 3

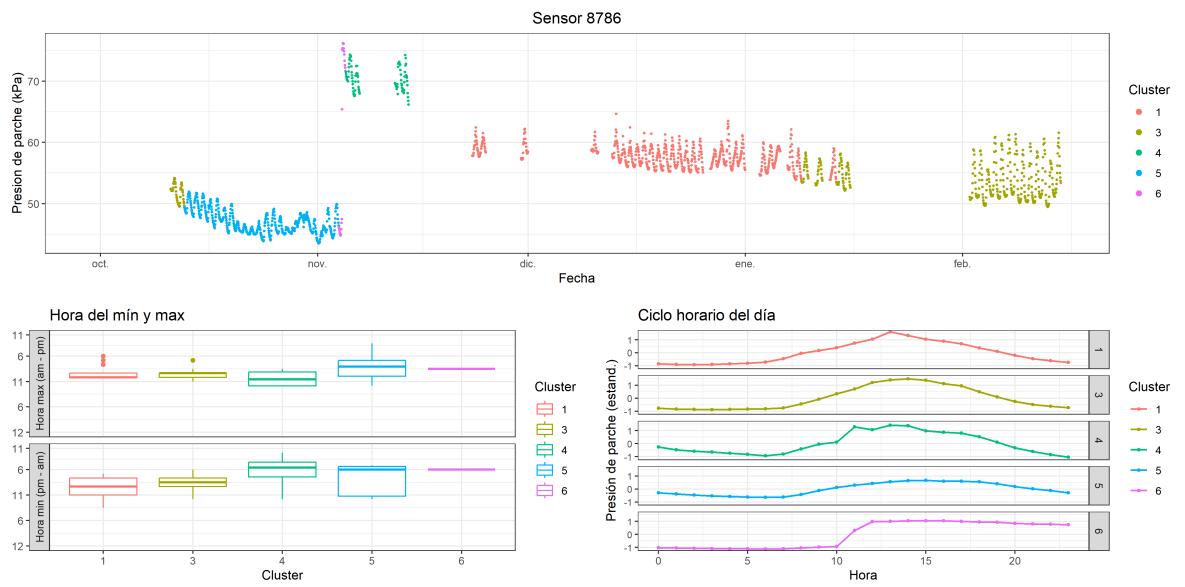
6.5.0.7 T3 (2023-2024)



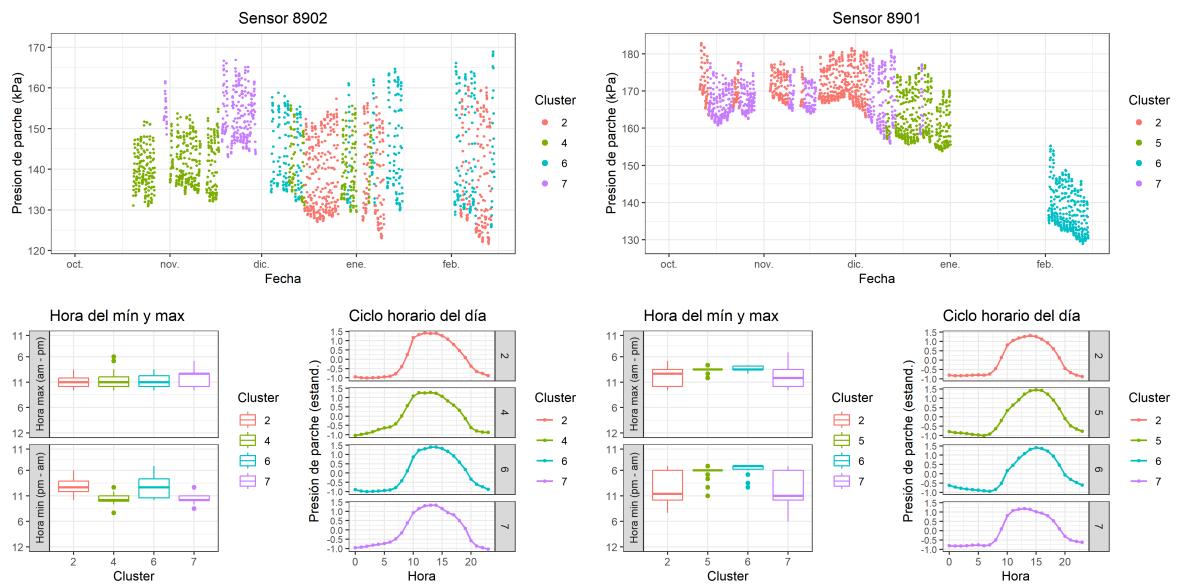
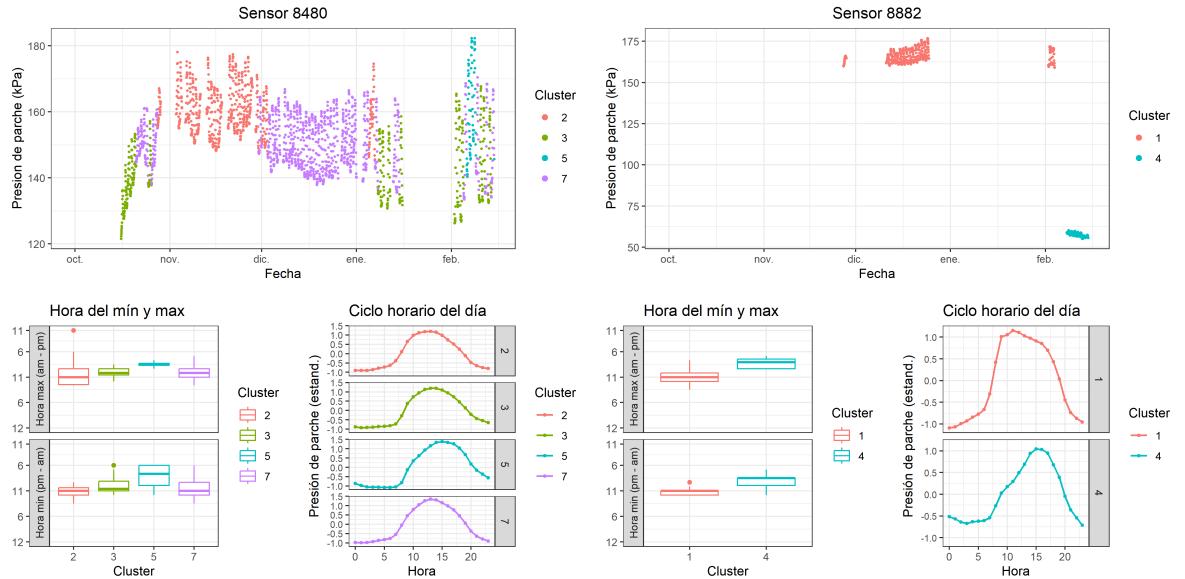


Unidad 3

6.5.0.8 T4 (2023-2024)

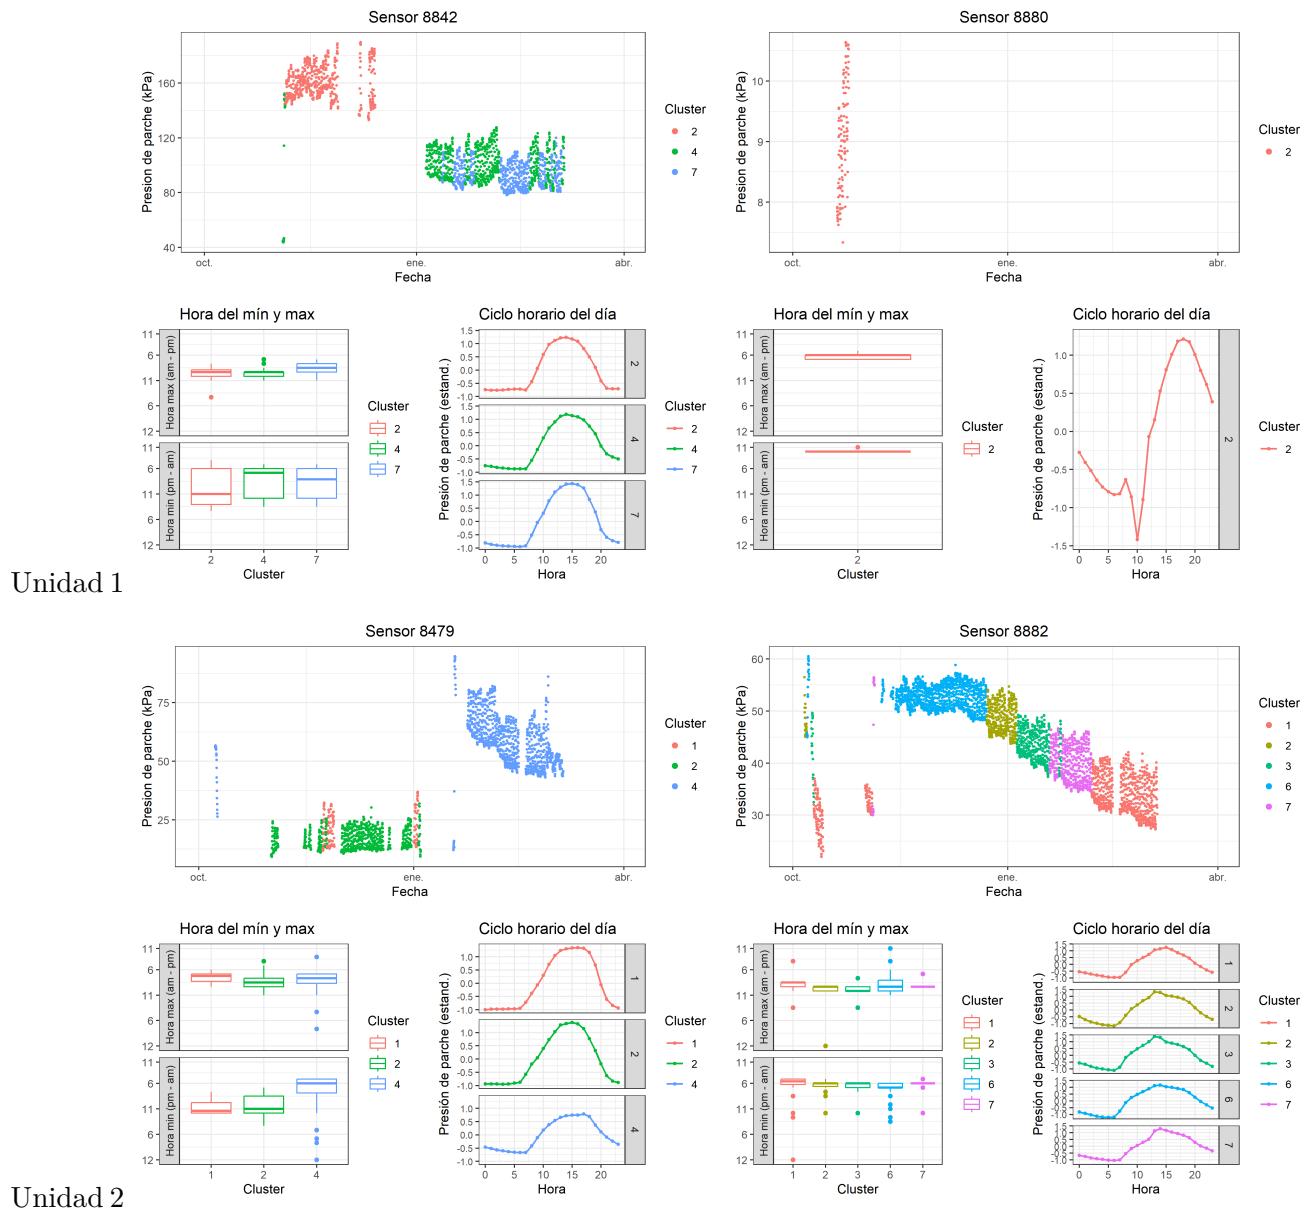


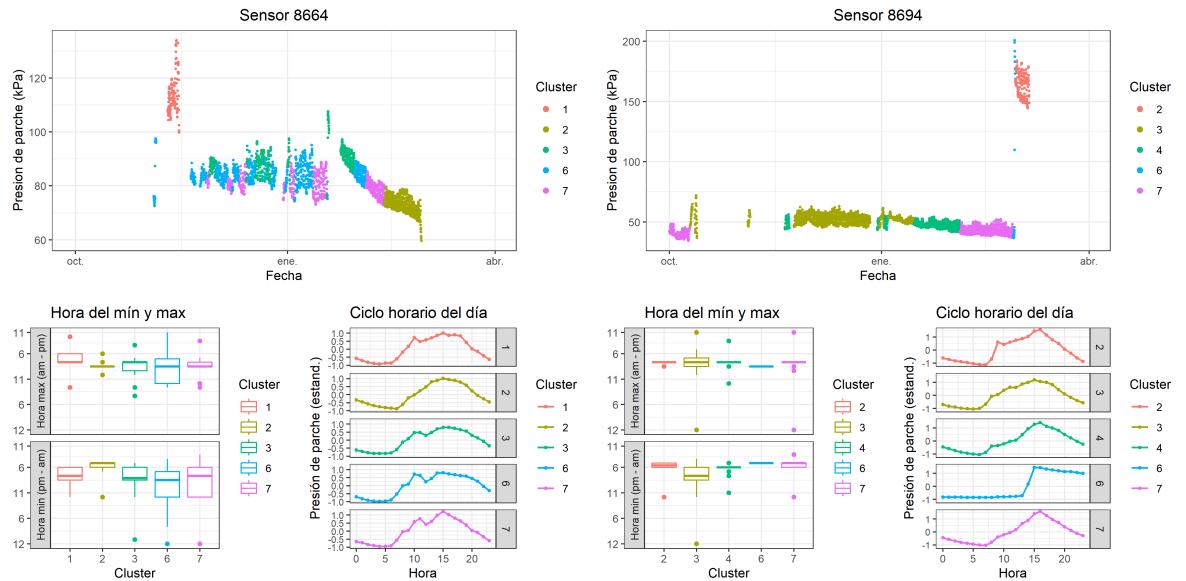
Unidad 1



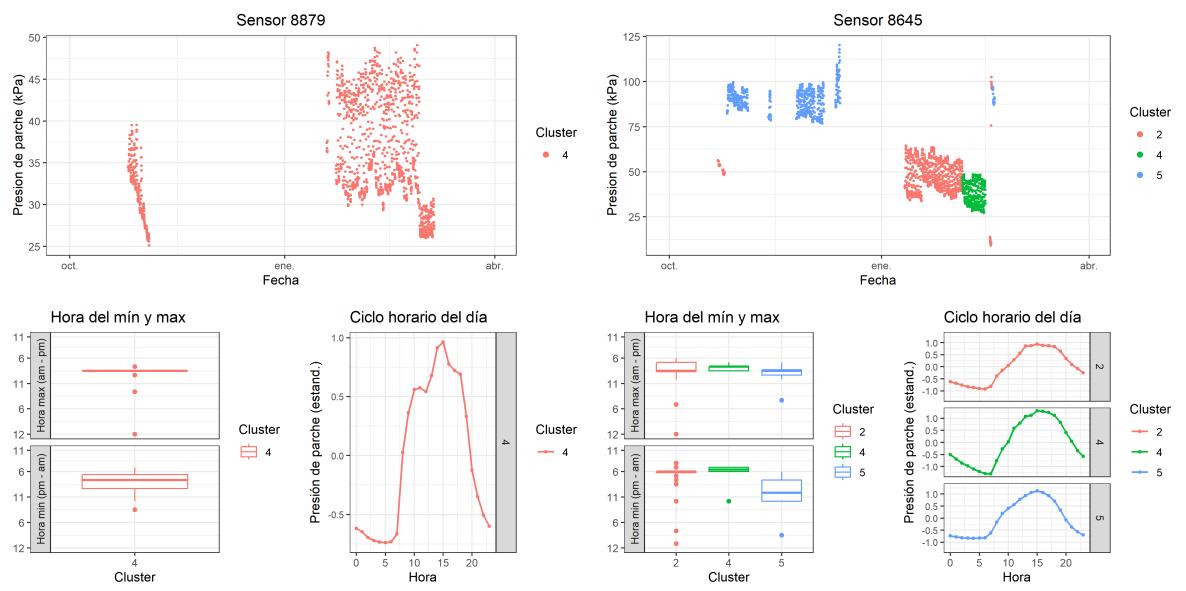
Rio Claro

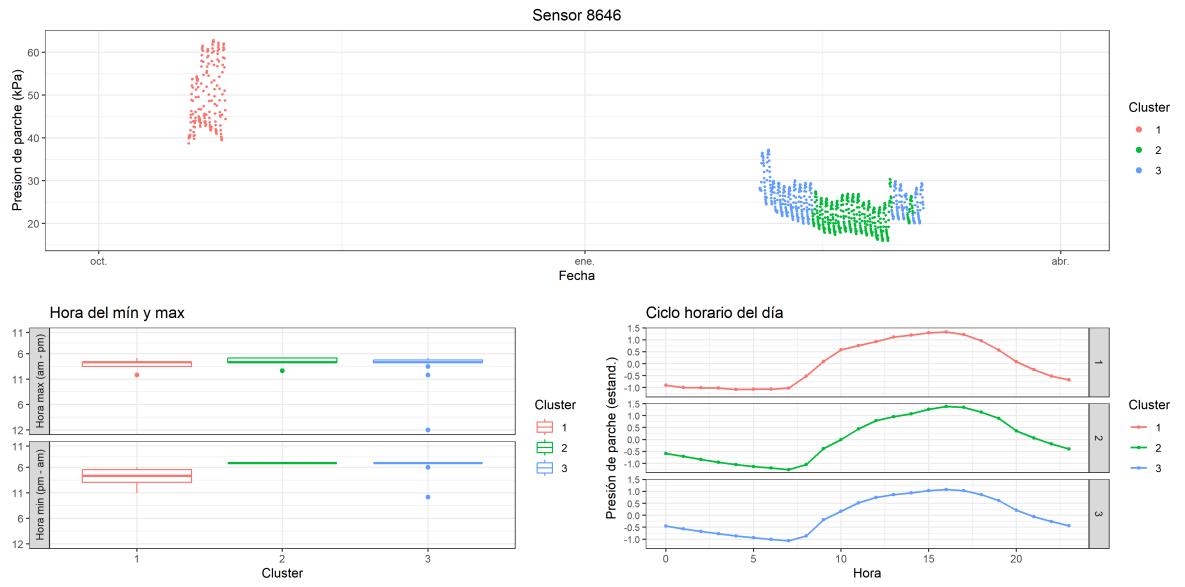
6.5.0.9 T1 (2022-2023)



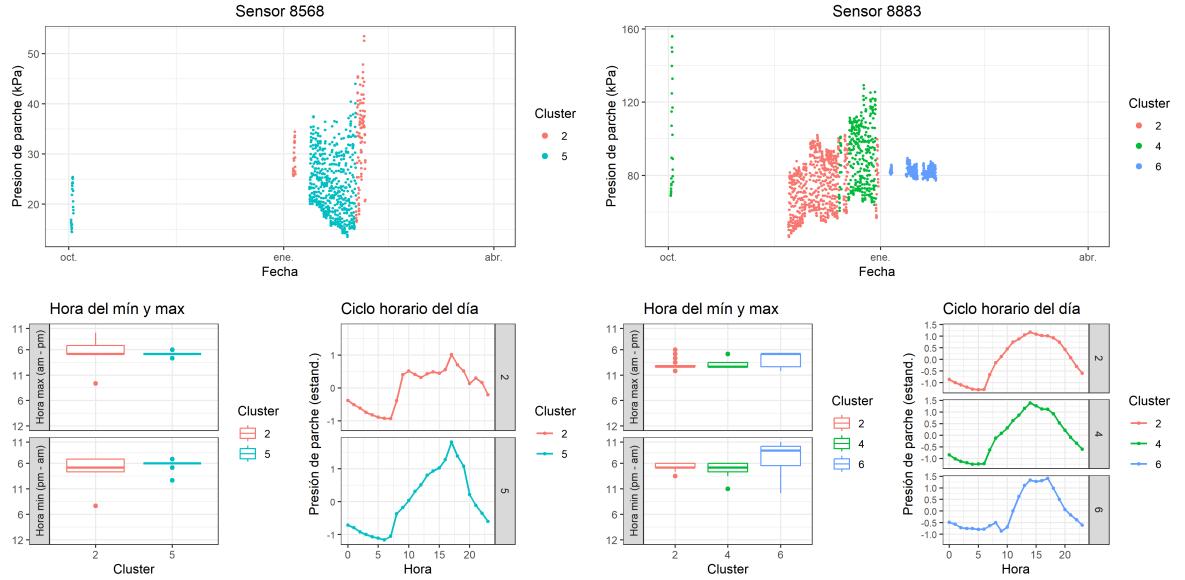


6.5.0.10 T2 (2022-2023)



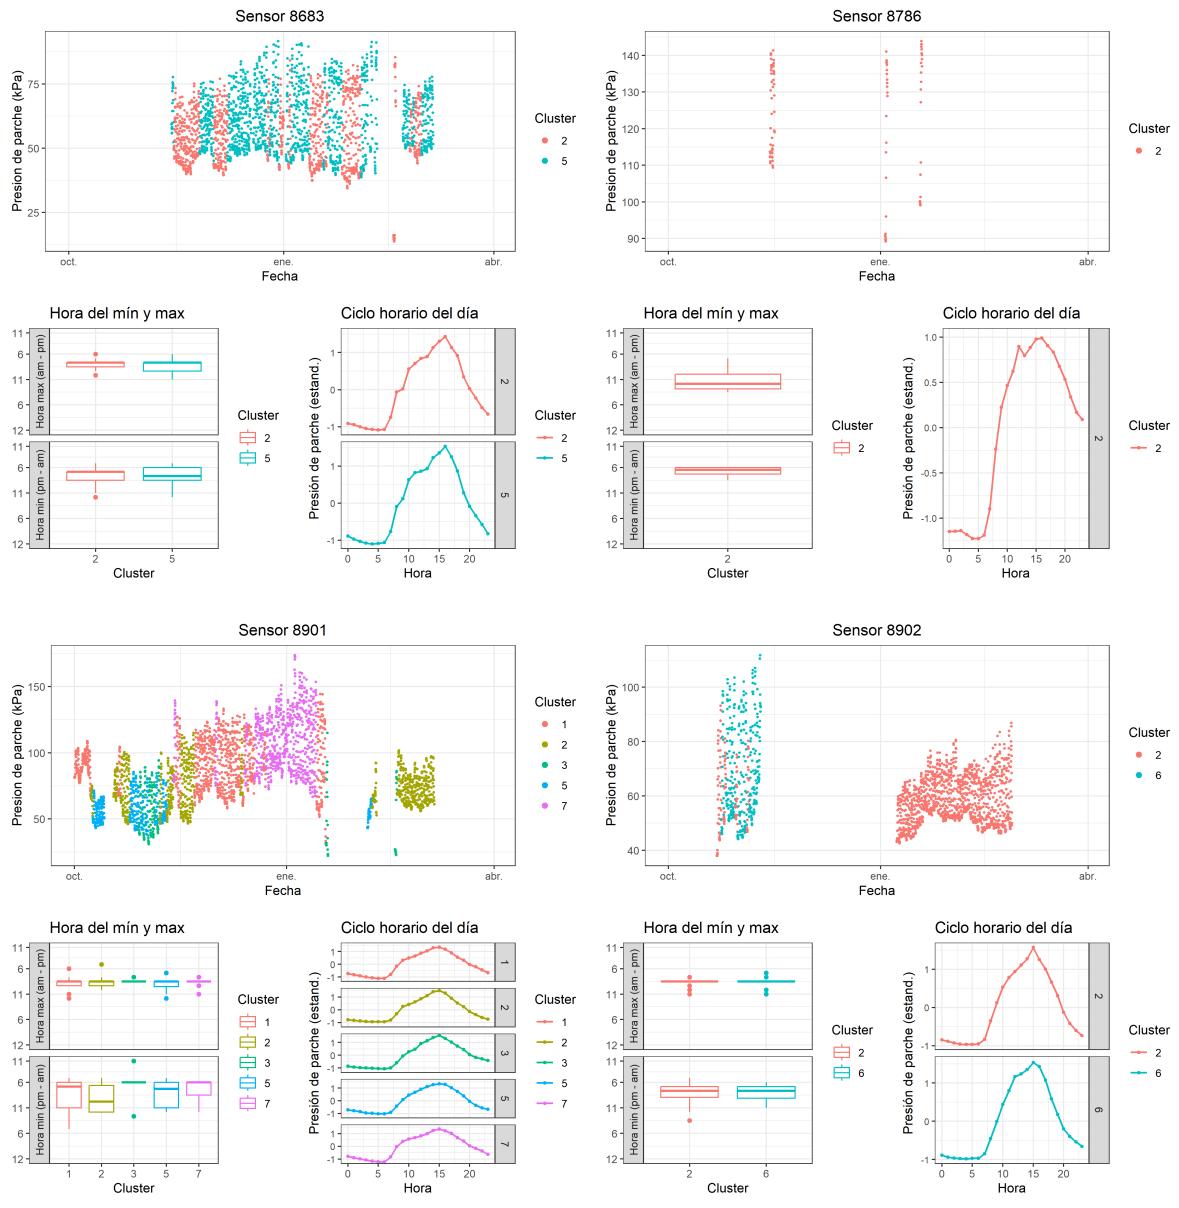


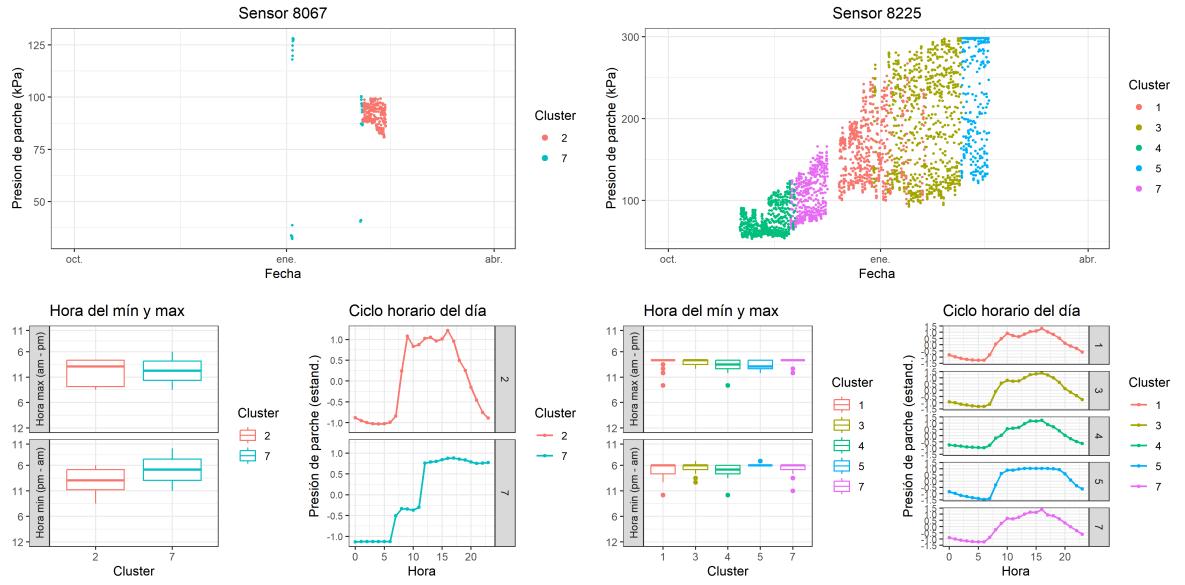
Unidad 2



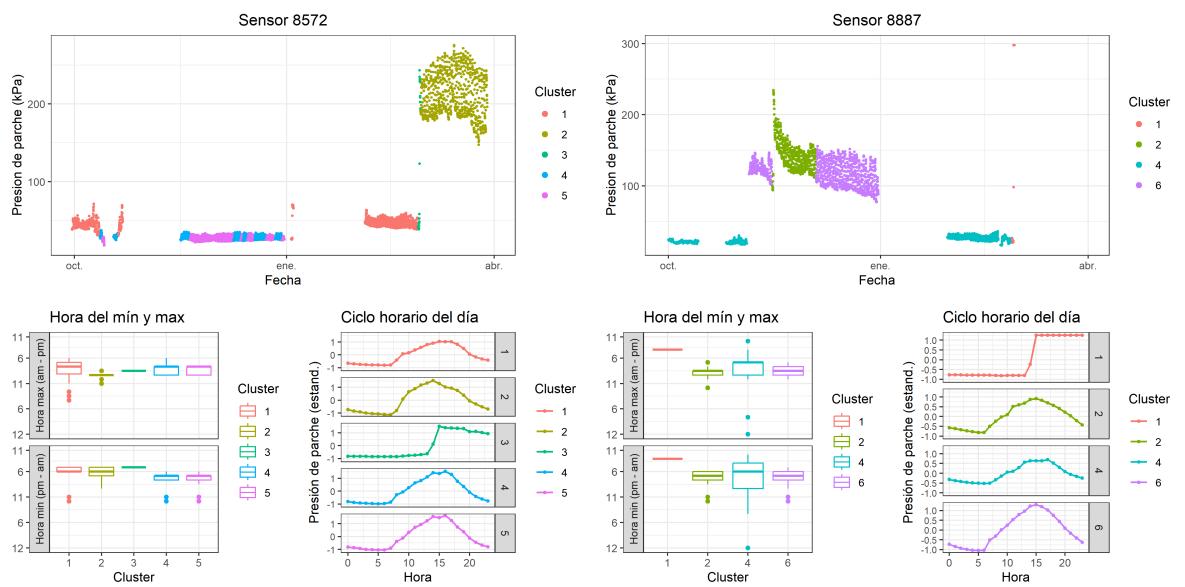
Unidad 3

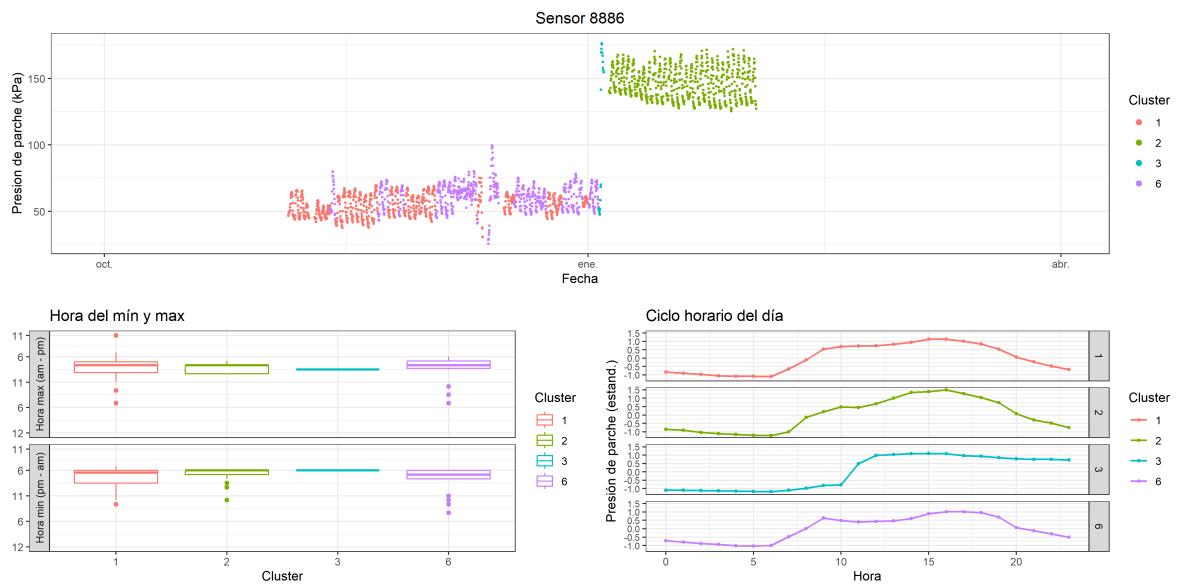
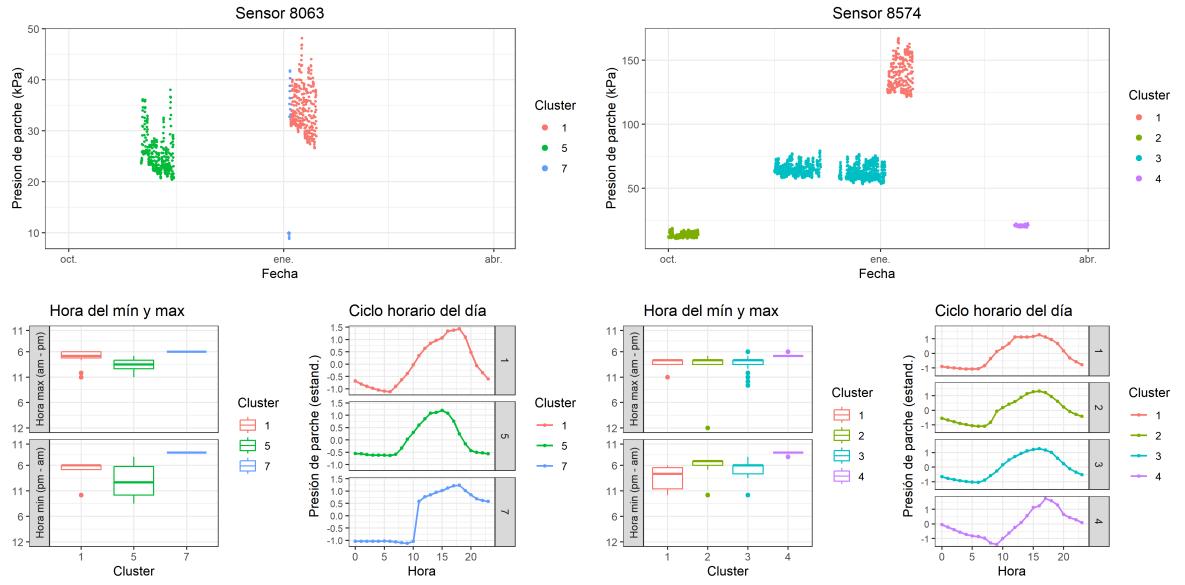
6.5.0.11 T3 (2022-2023)



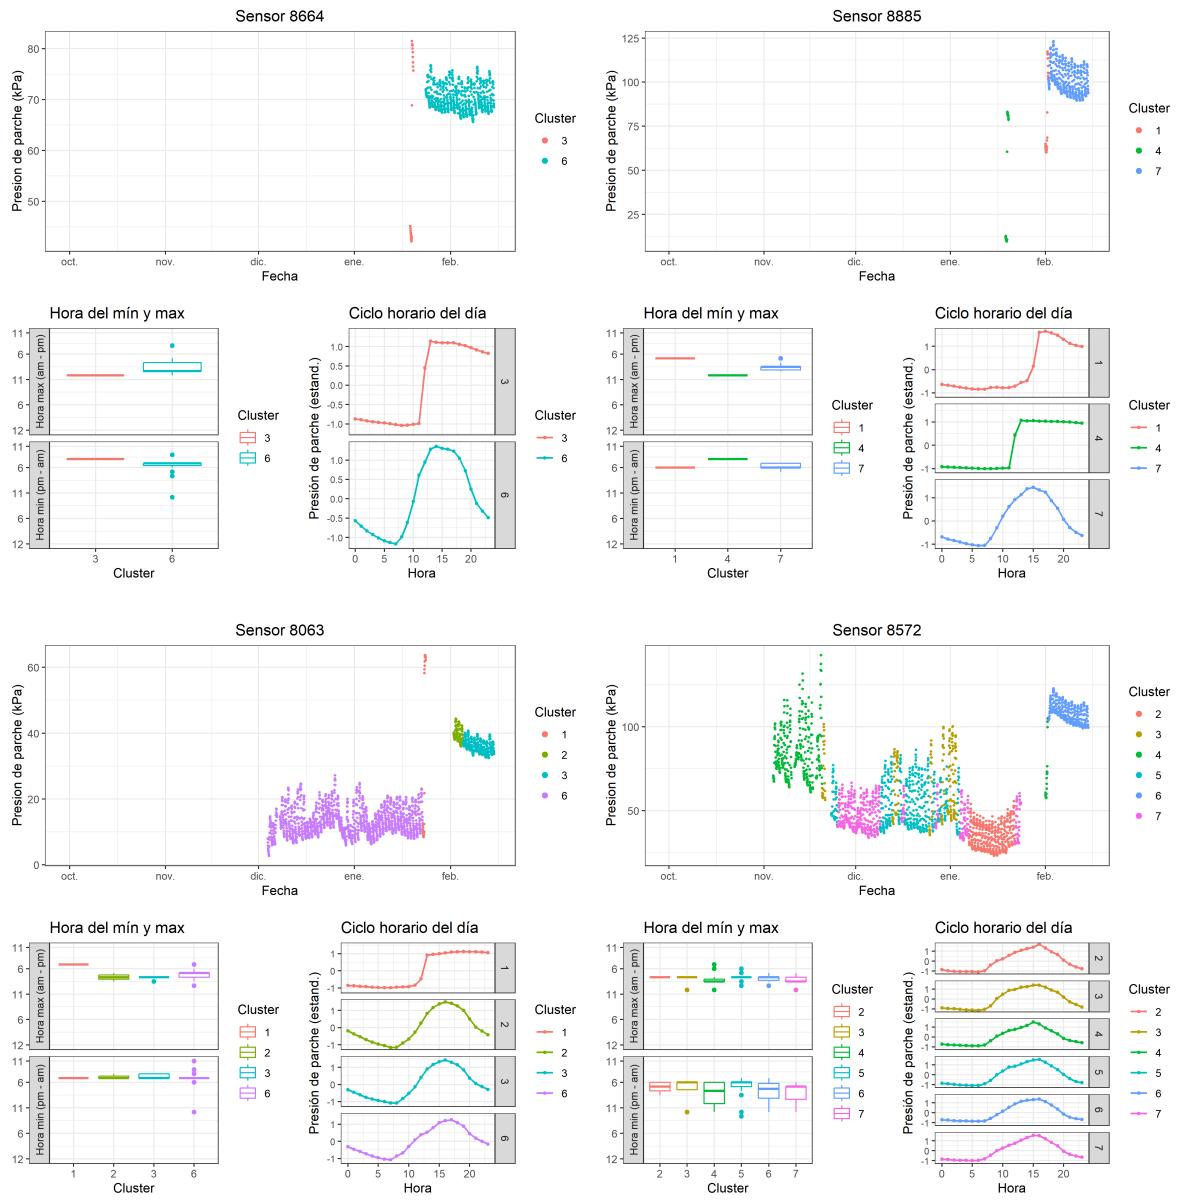


6.5.0.12 T4 (2022-2023)

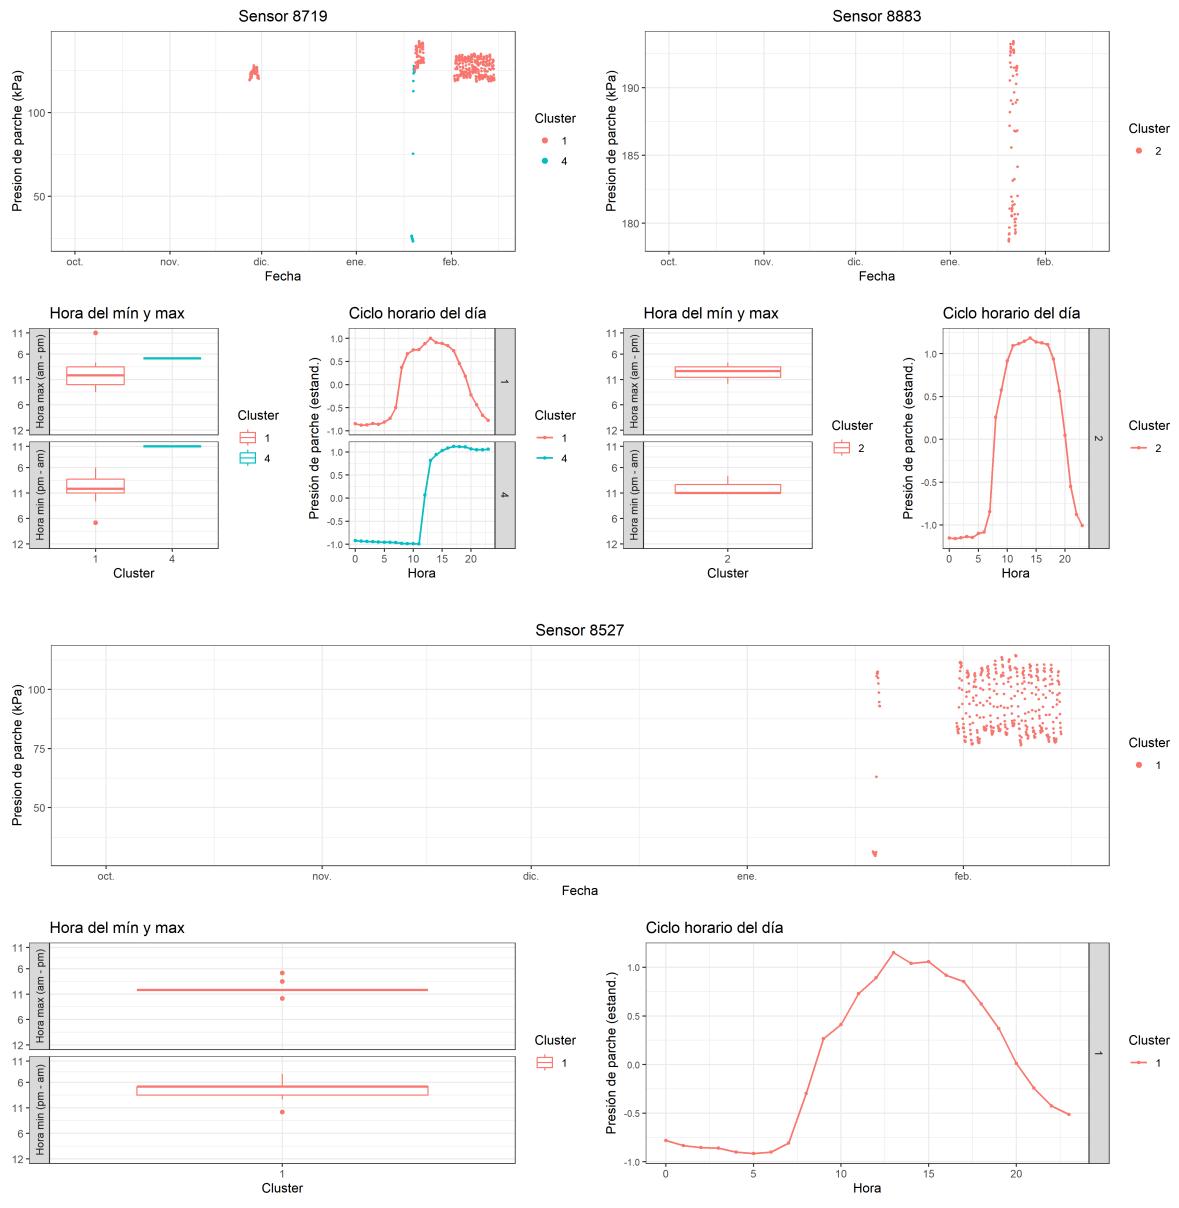


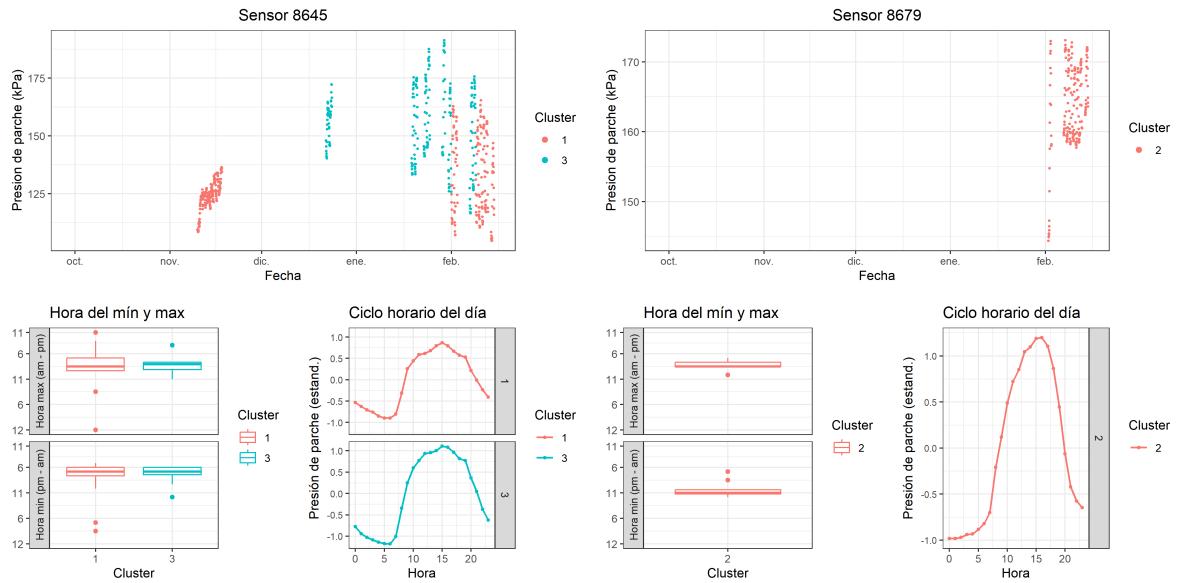


6.5.0.13 T1 (2023-2024)



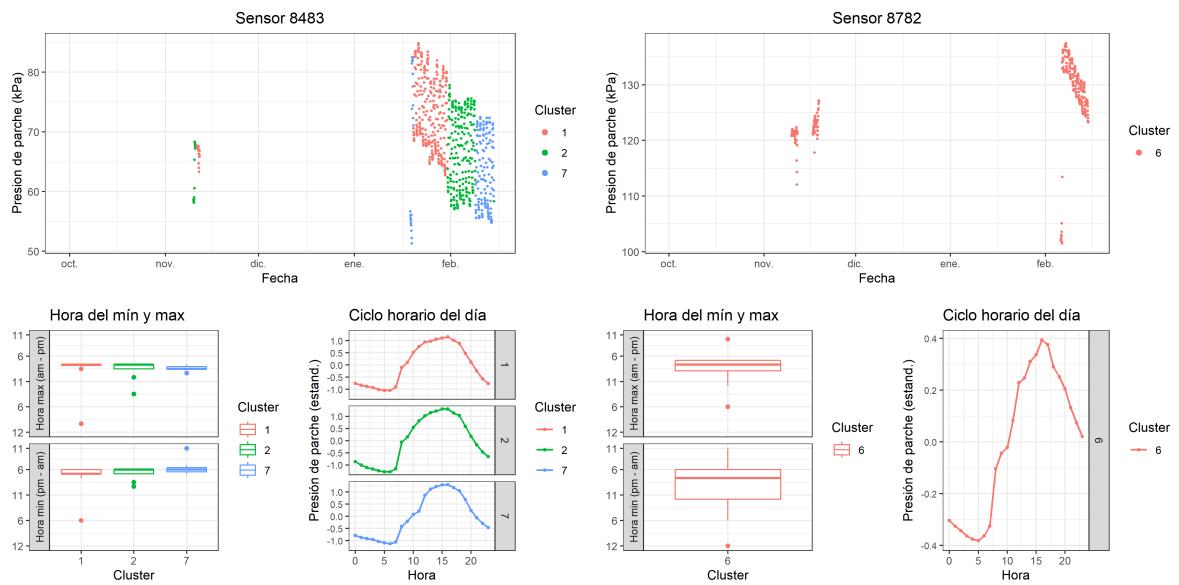
6.5.0.14 T2 (2023-2024)



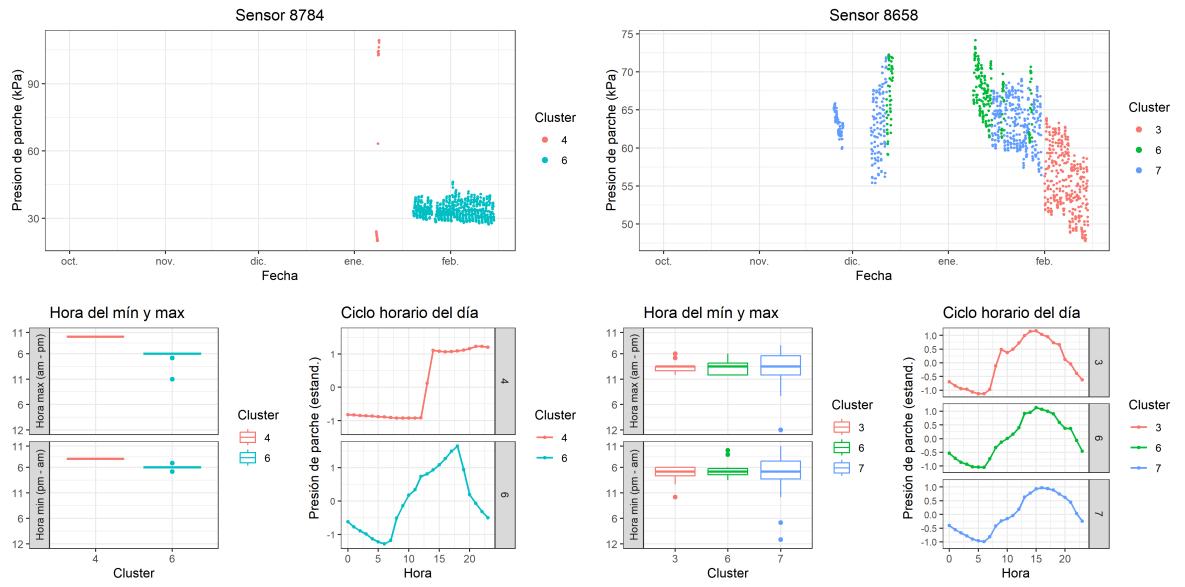


Unidad 3

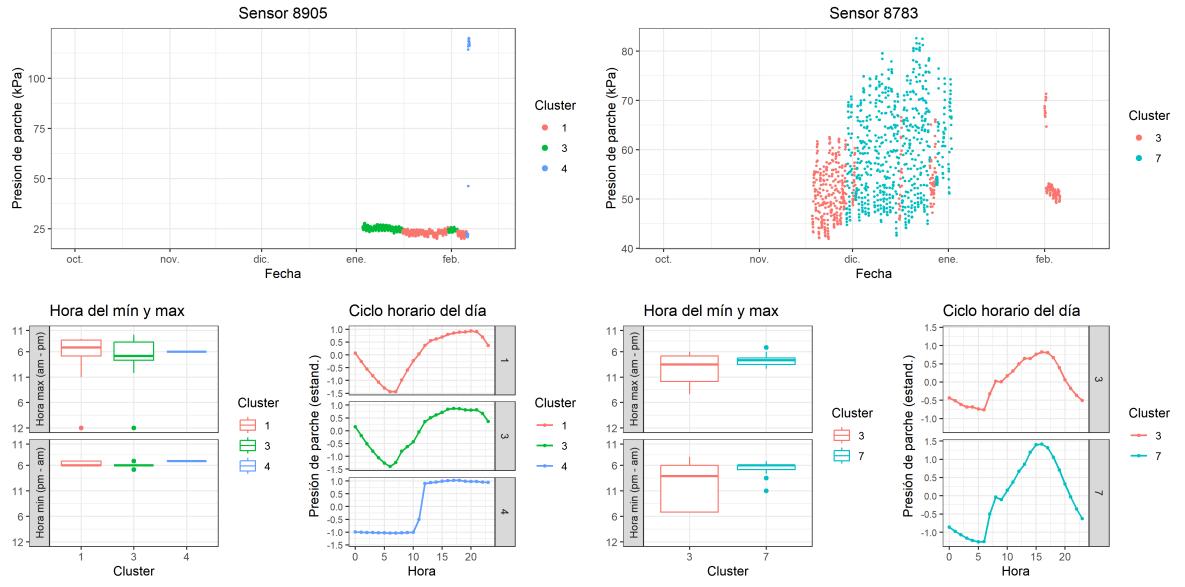
6.5.0.15 T3 (2023-2024)



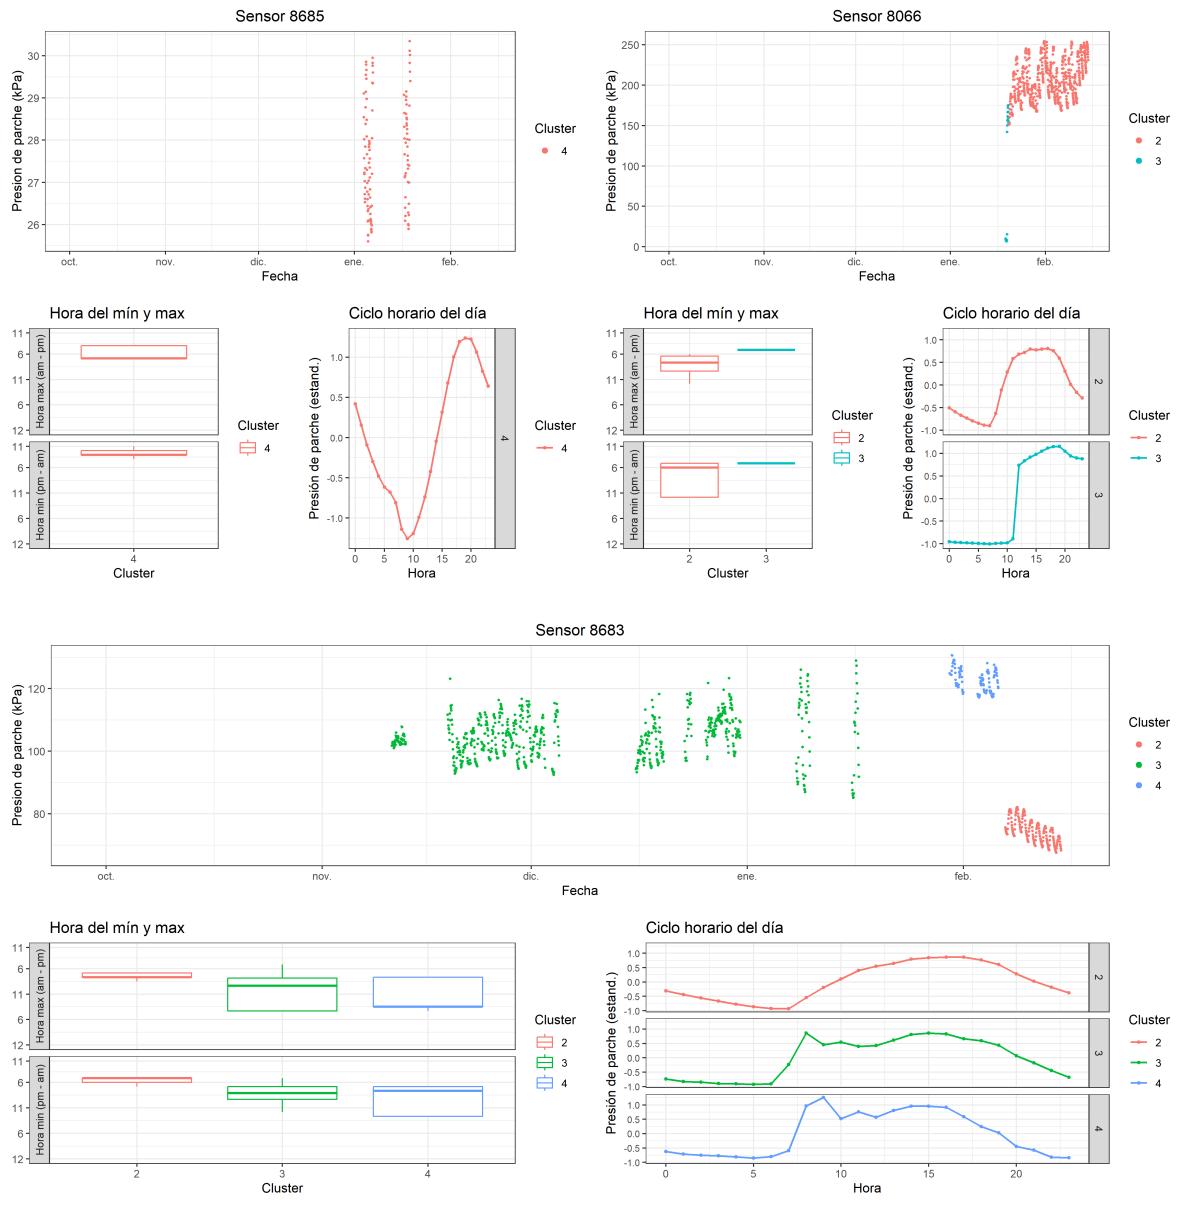
Unidad 1

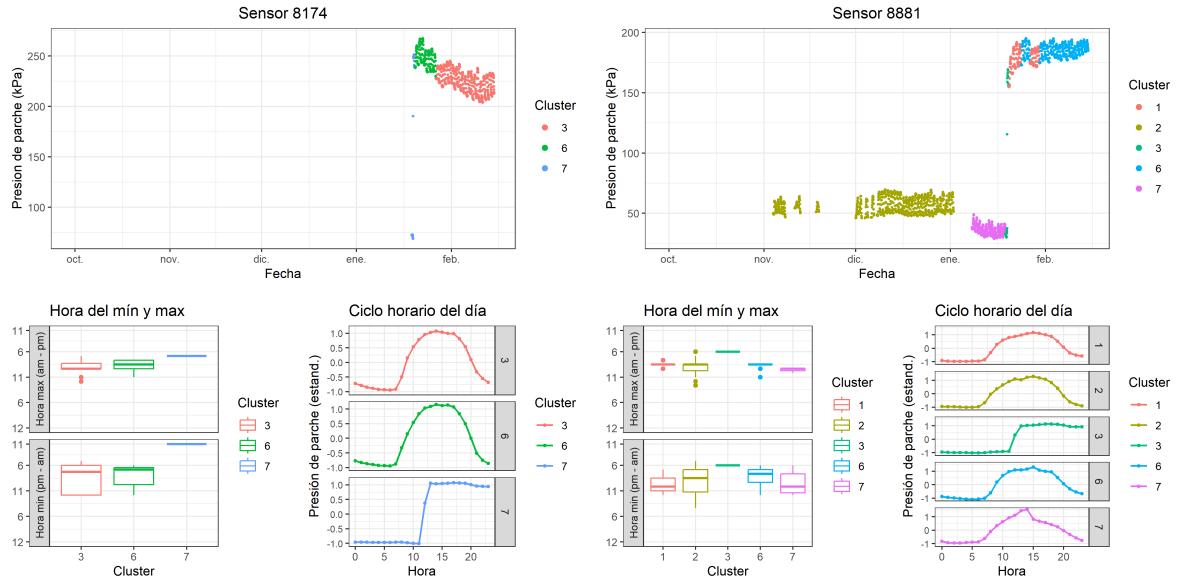


Unidad 2



6.5.0.16 T4 (2023-2024)





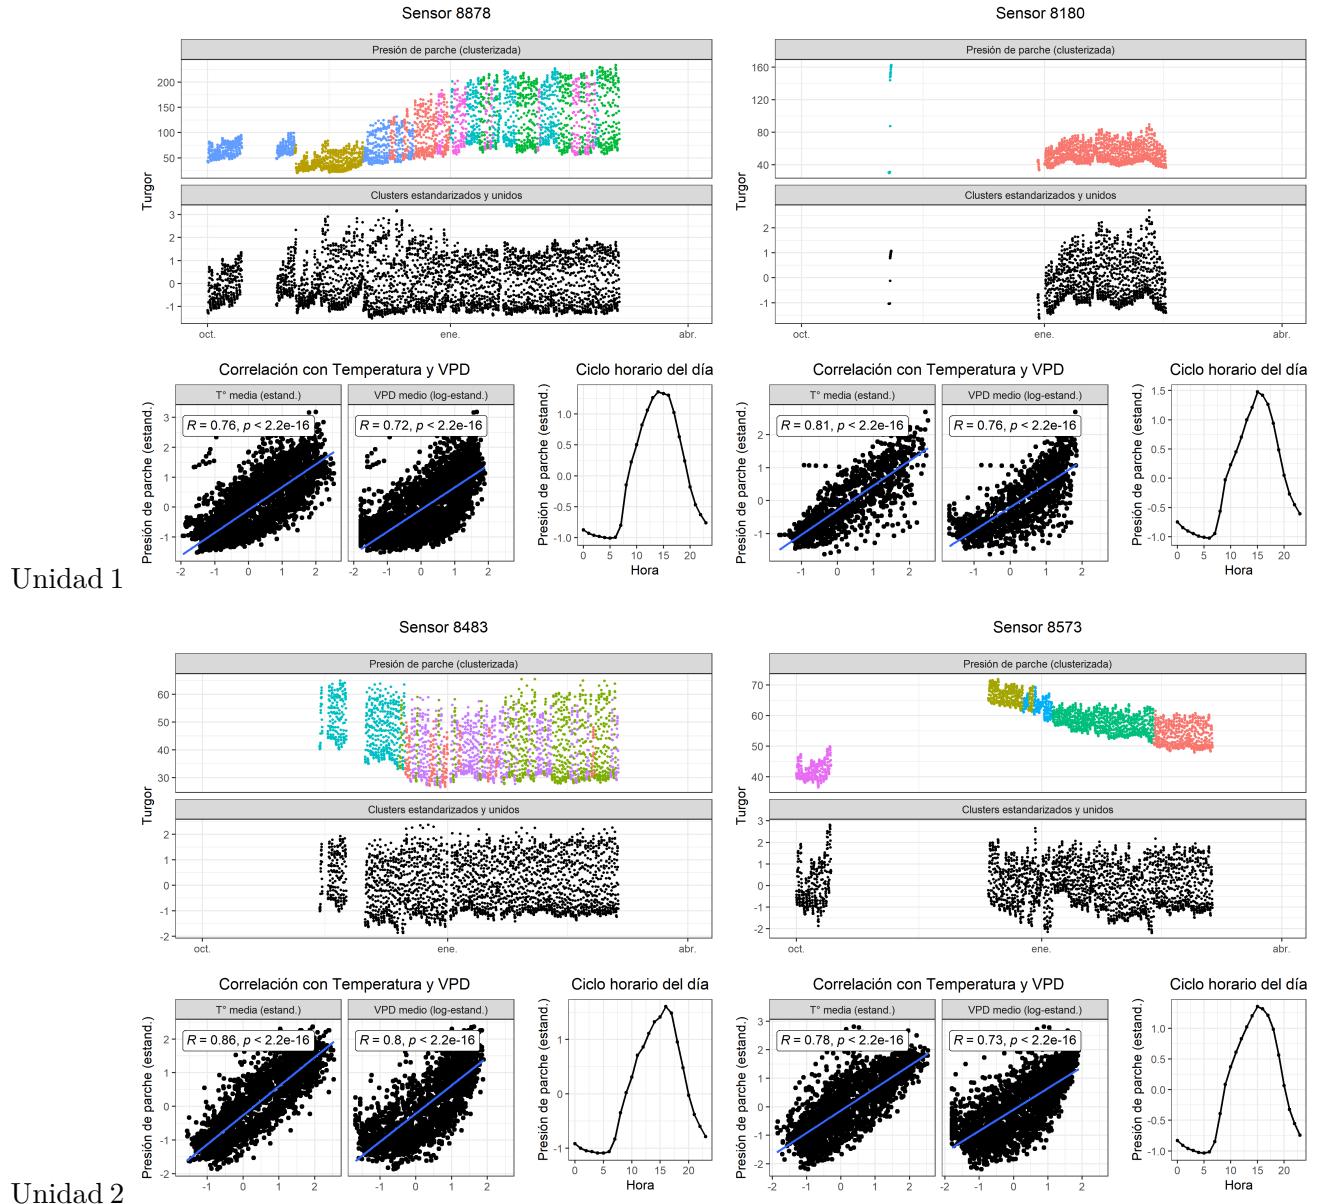
Unidad 3

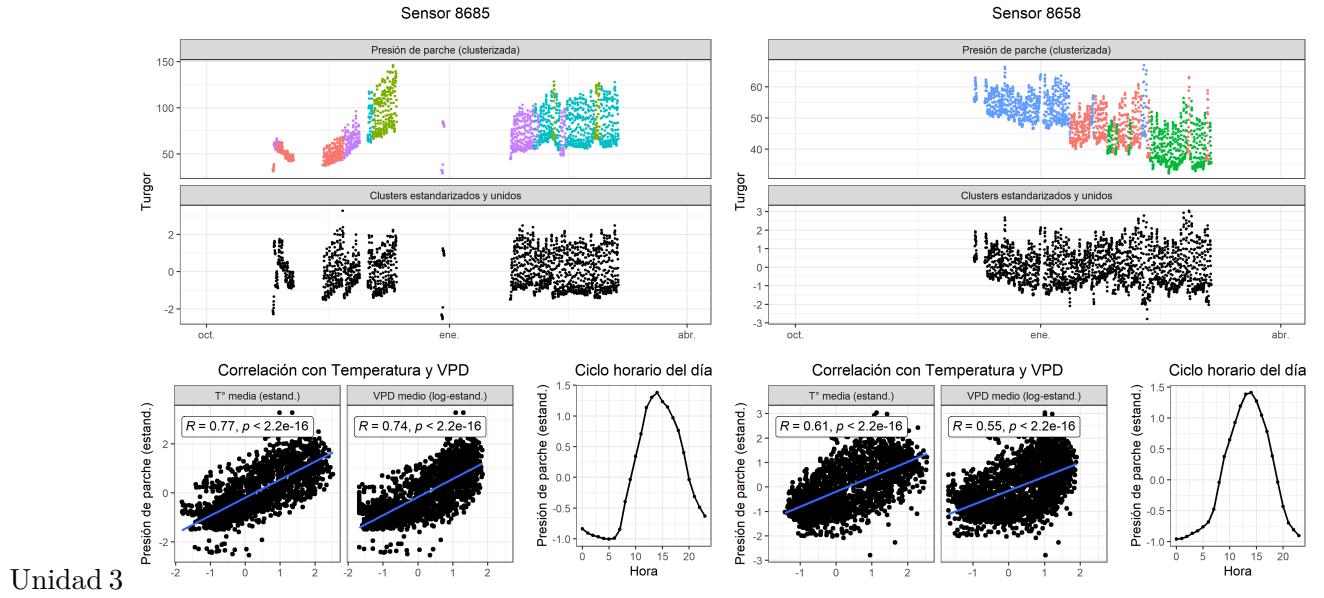
Estandarización de clusters

Para generar series únicas continuas por sensor (i.e. disminuir las discordancias entre períodos de recalibración de los sensores), se realizó una estandarización de cada cluster, lo cual significó una unificación las series temporales de estos a nivel de sensor. A continuación se muestran dichas series resultantes, además de su correlación con temperatura y VPD, y el ciclo horario del día.

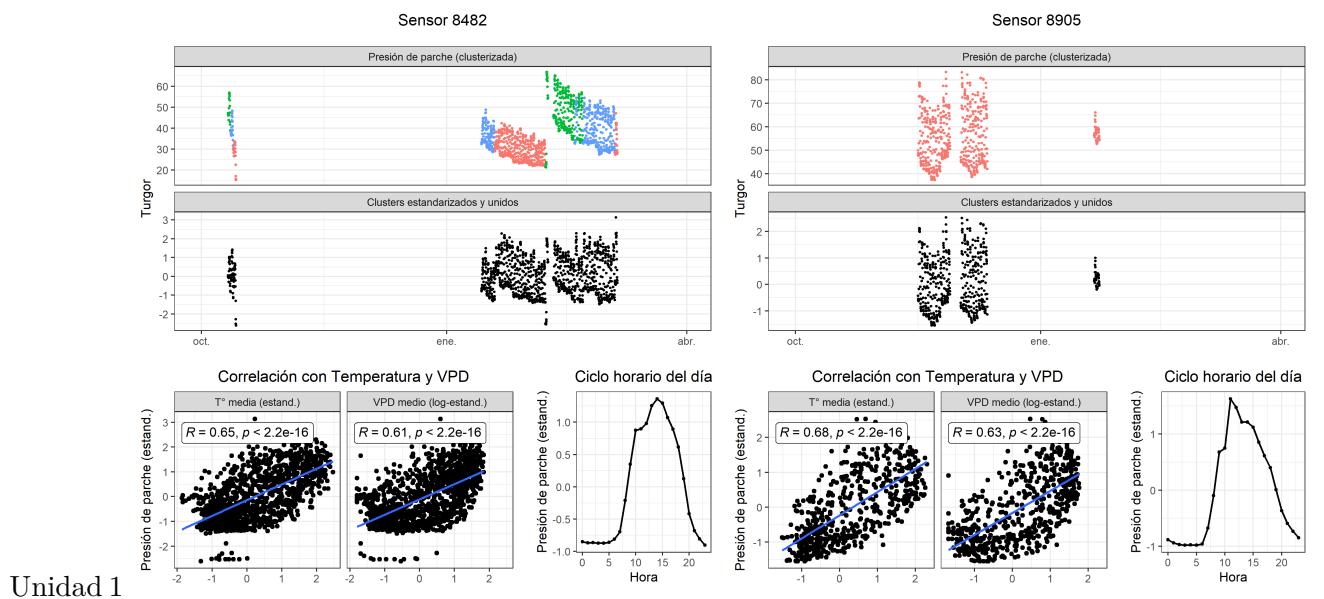
La Esperanza

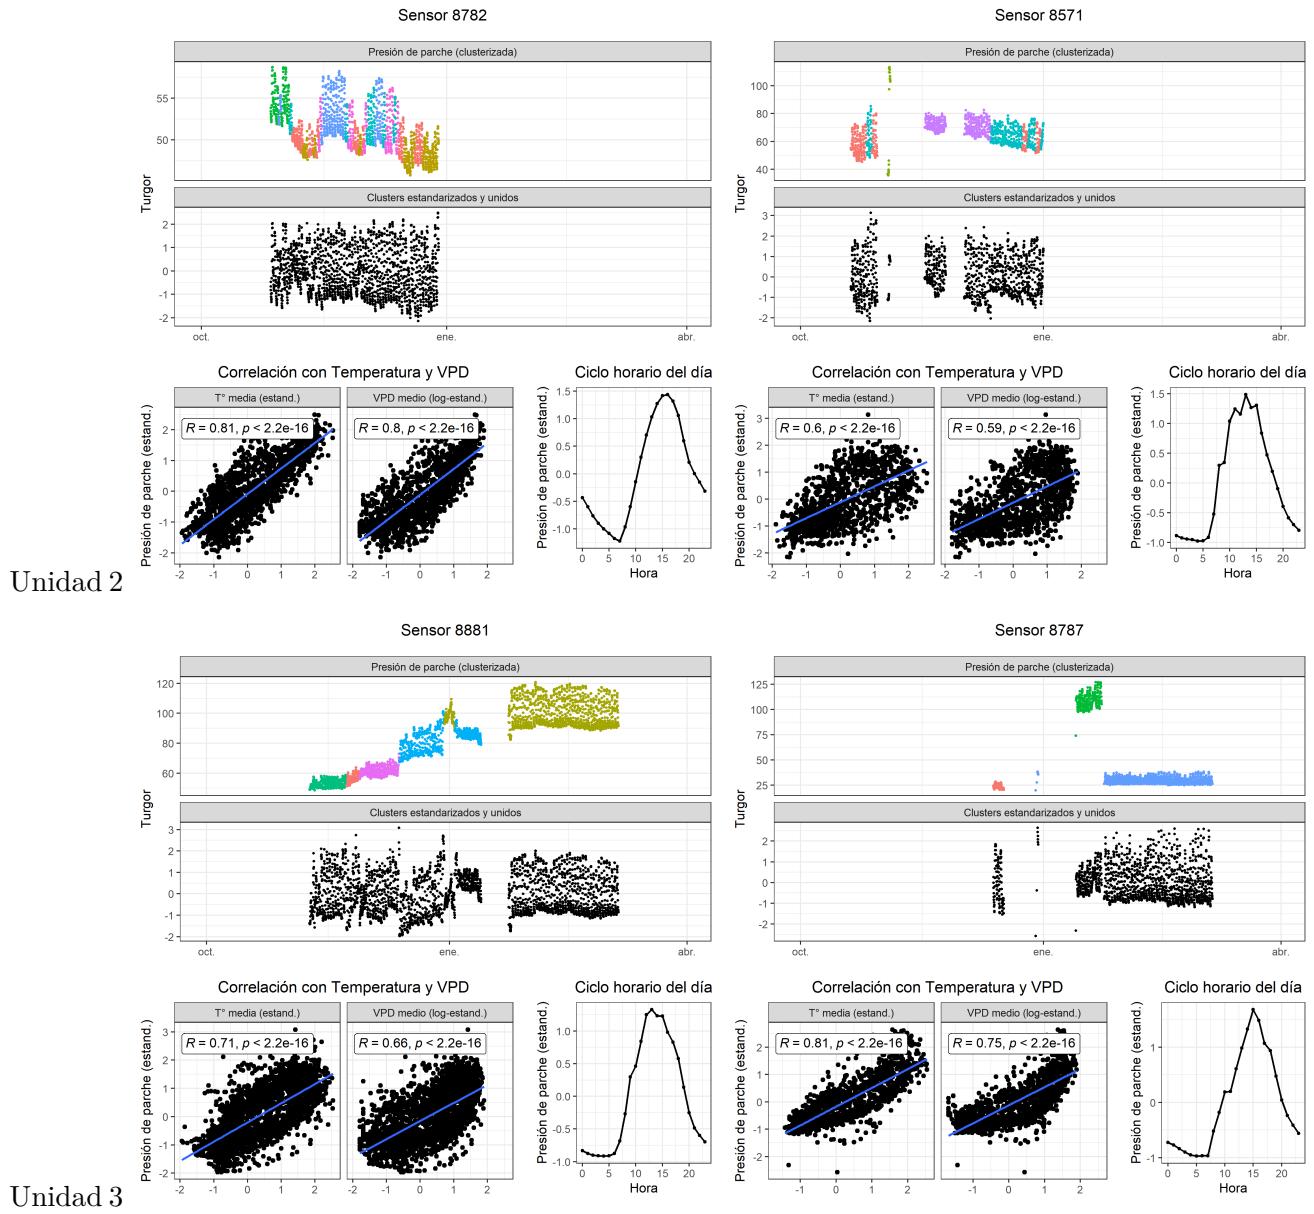
6.5.0.1 T1 (2022-2023)



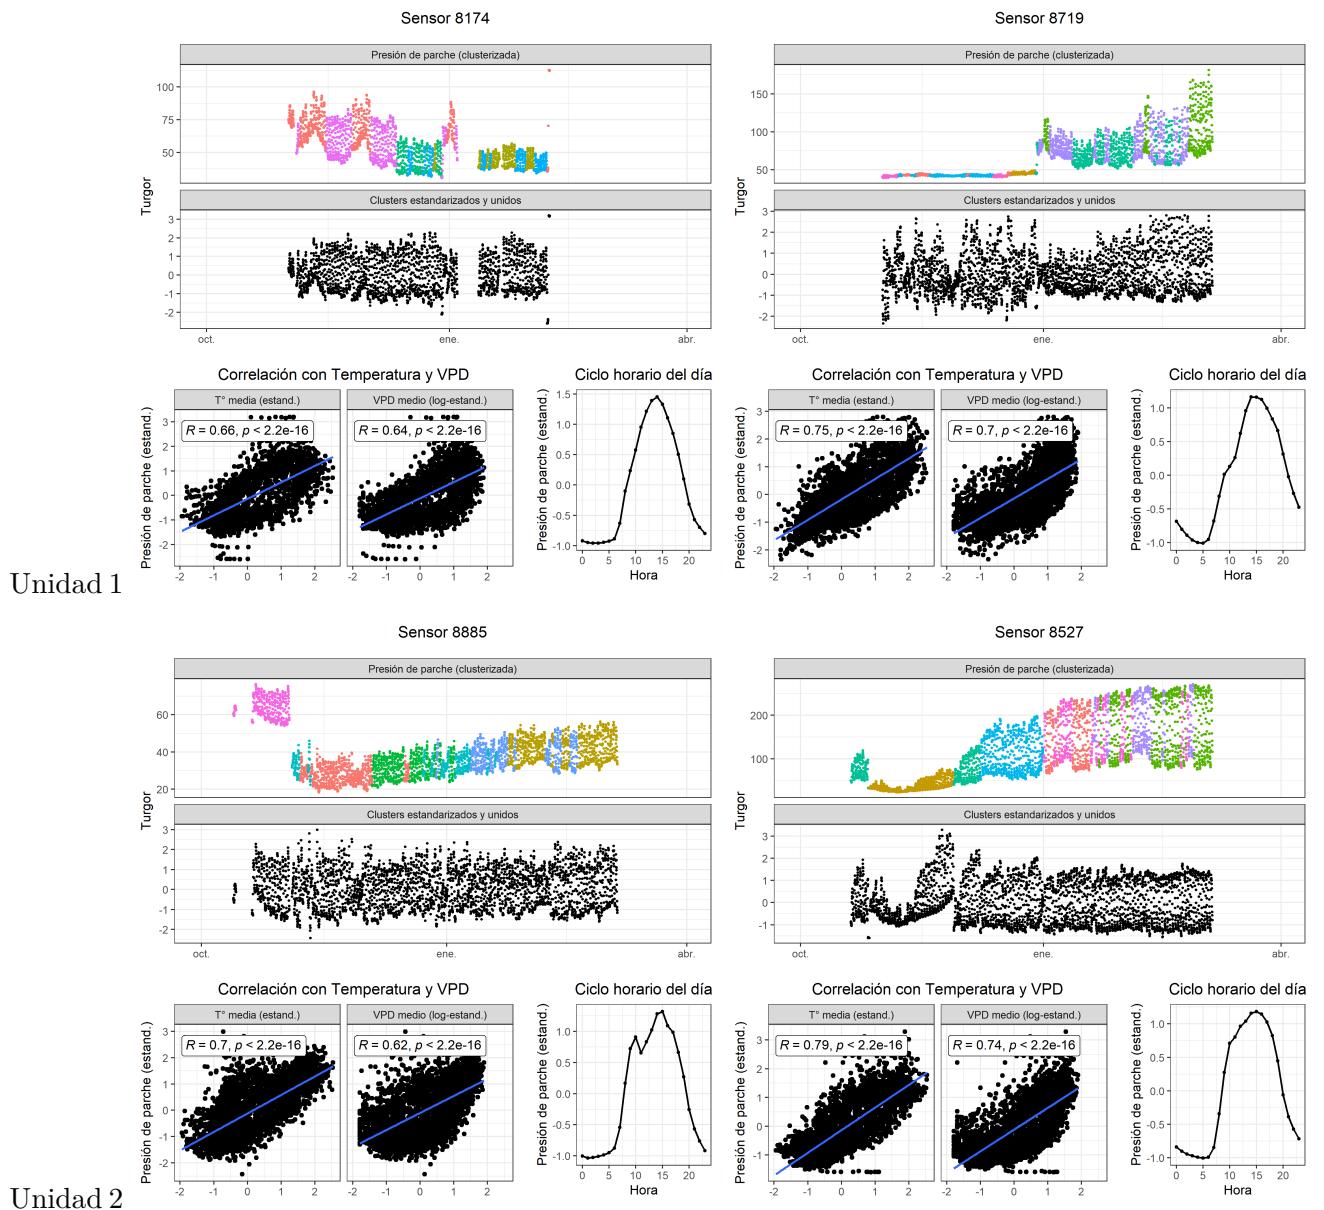


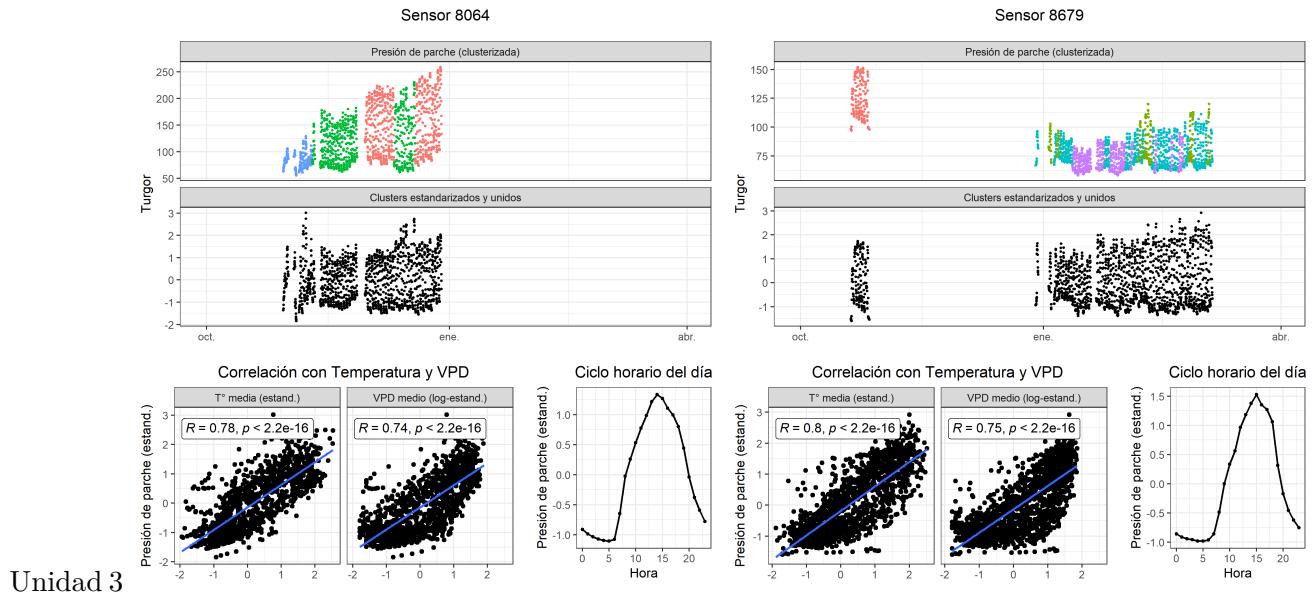
6.5.0.2 T2 (2022-2023)



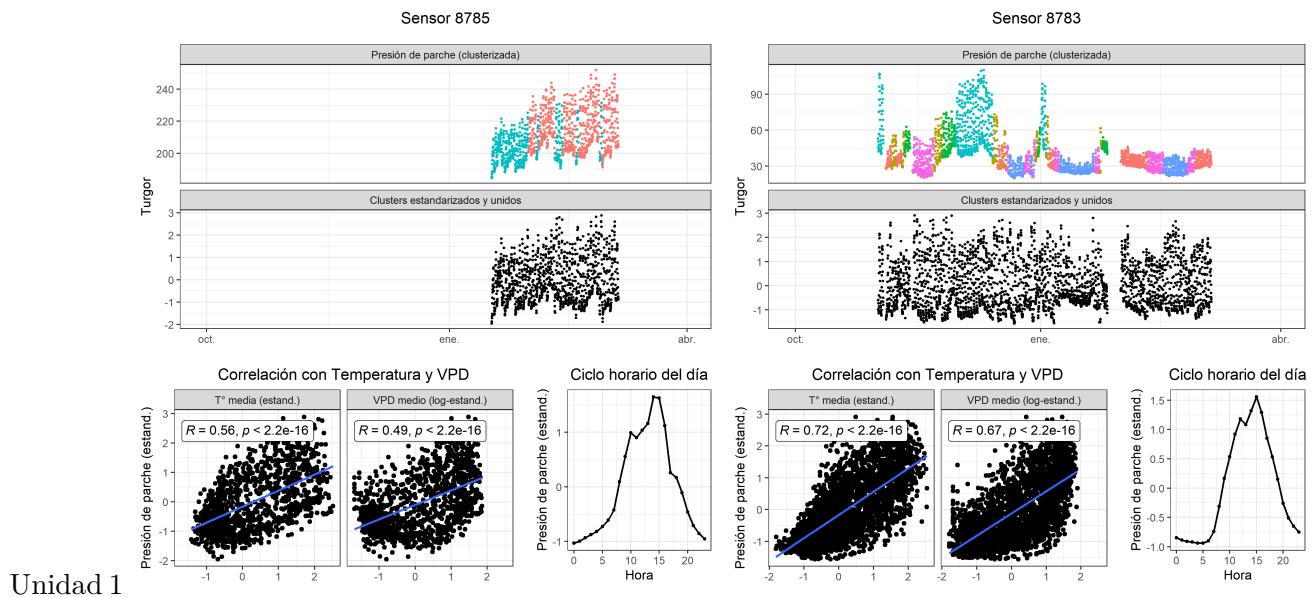


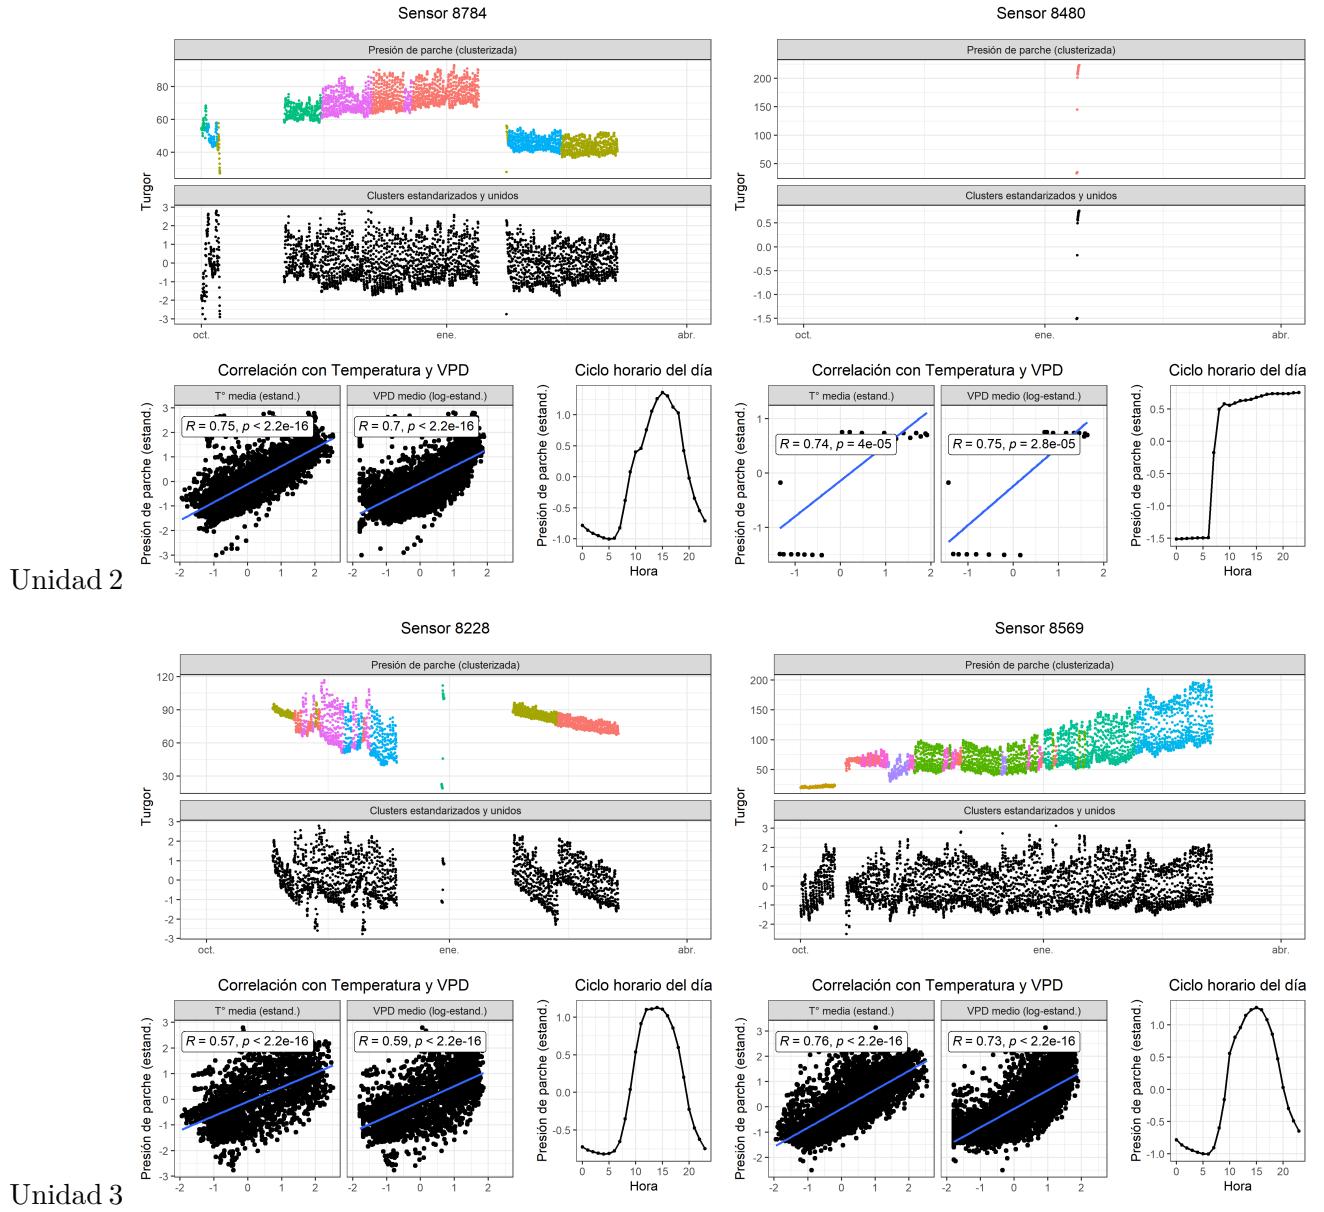
6.5.0.3 T3 (2022-2023)



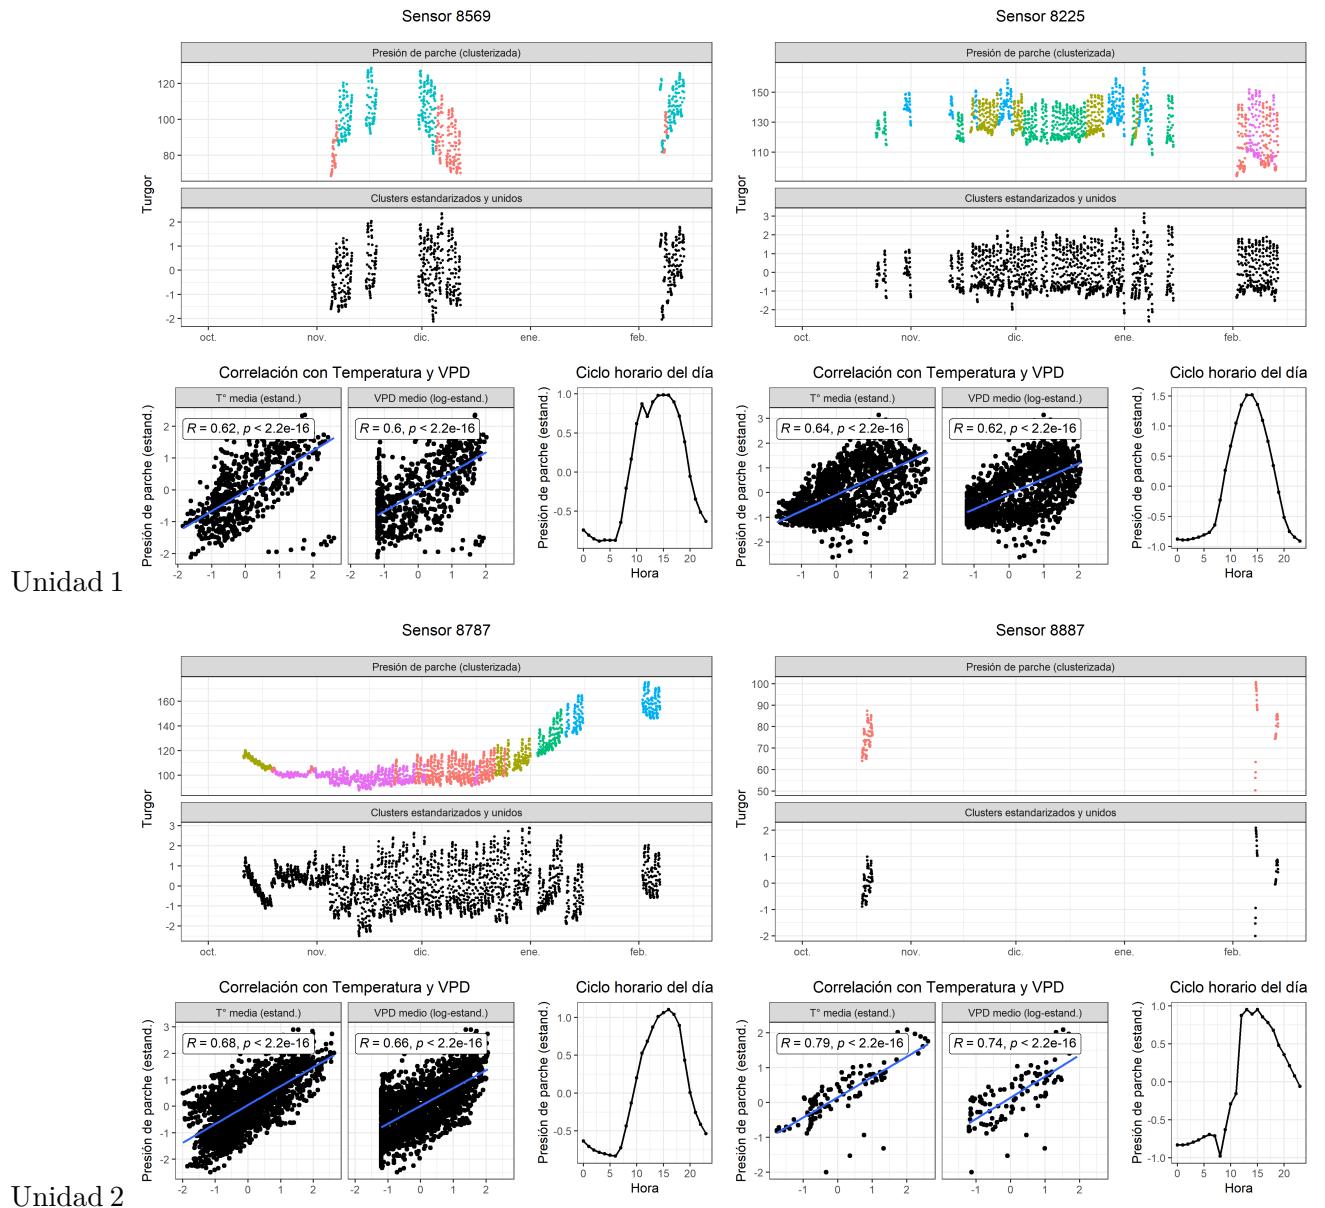


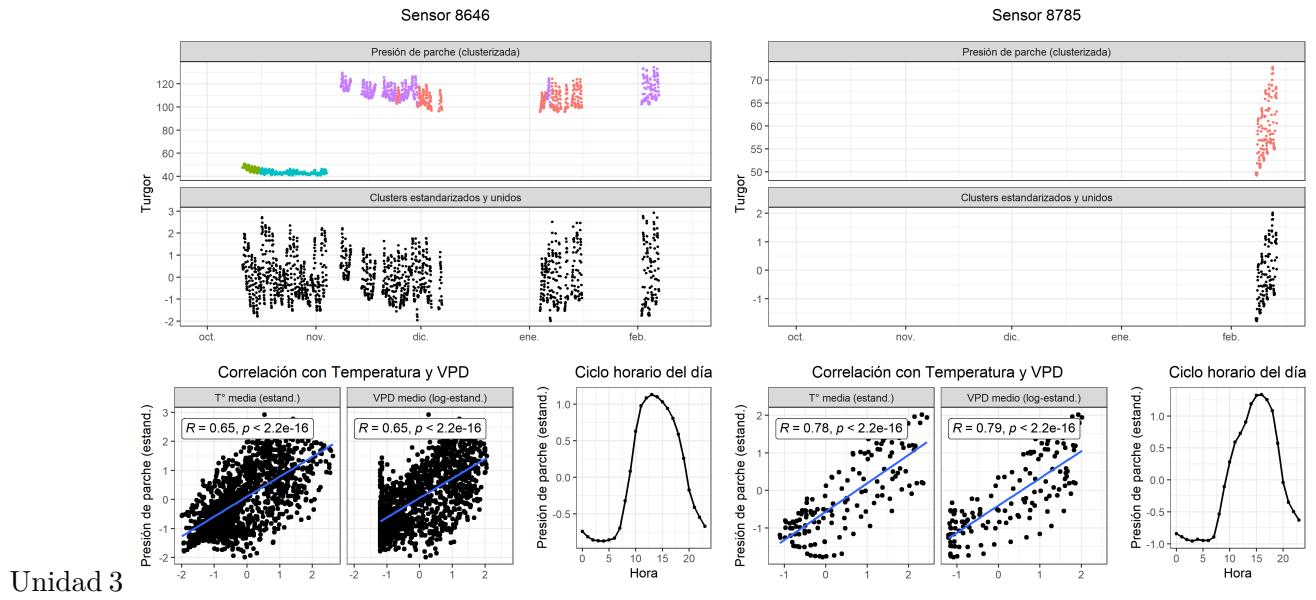
6.5.0.4 T4 (2022-2023)



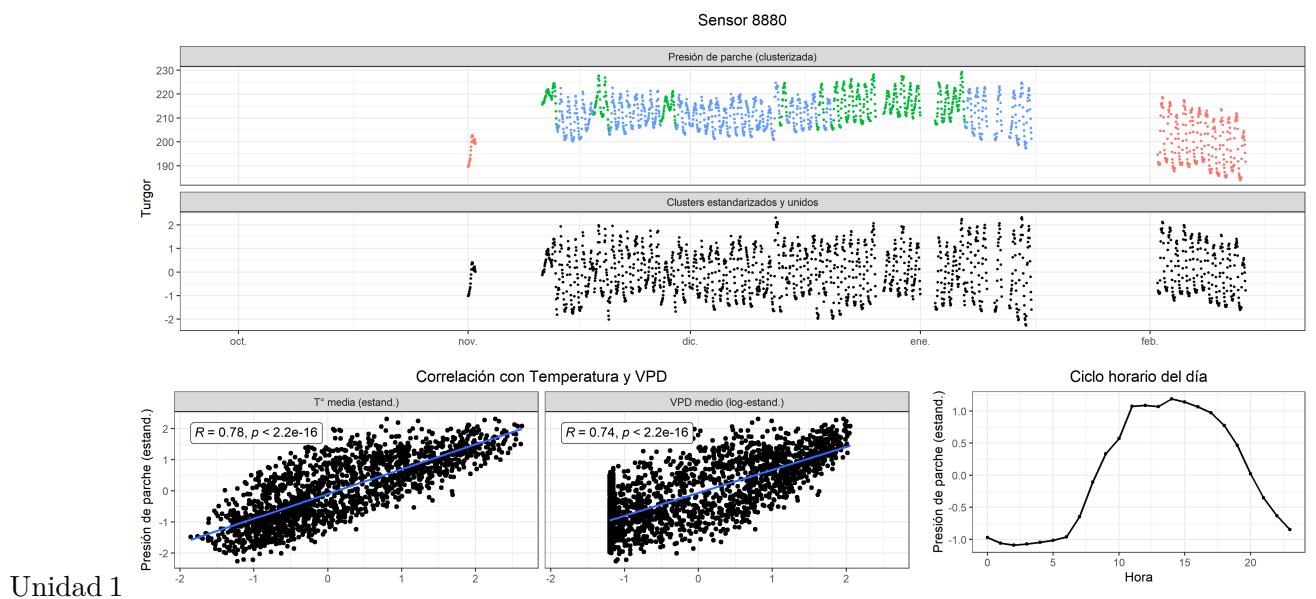


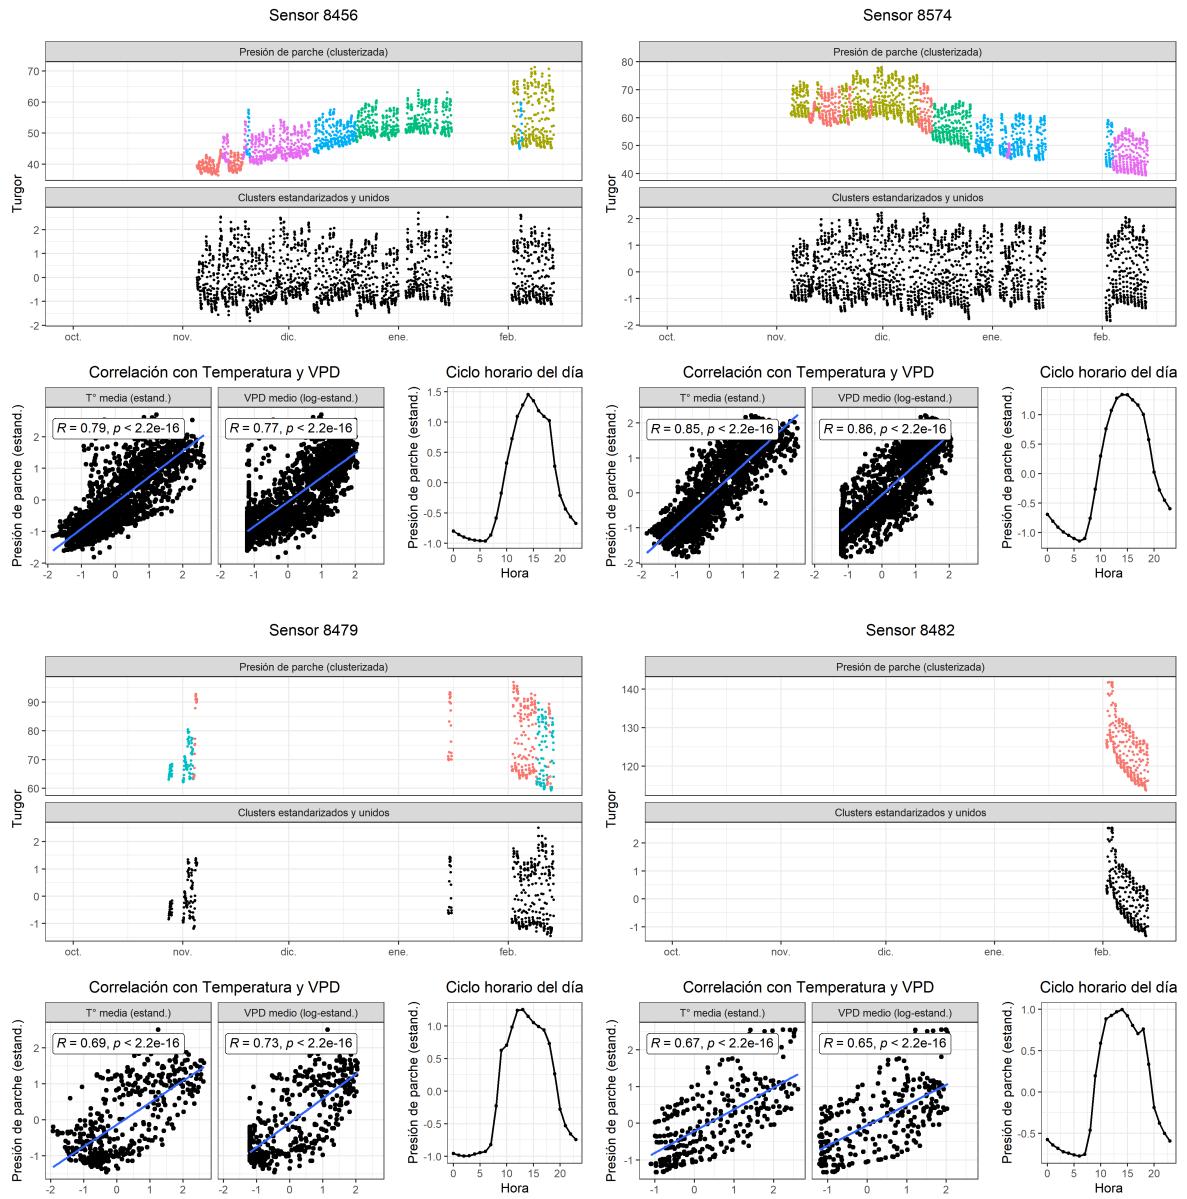
6.5.0.5 T1 (2023-2024)



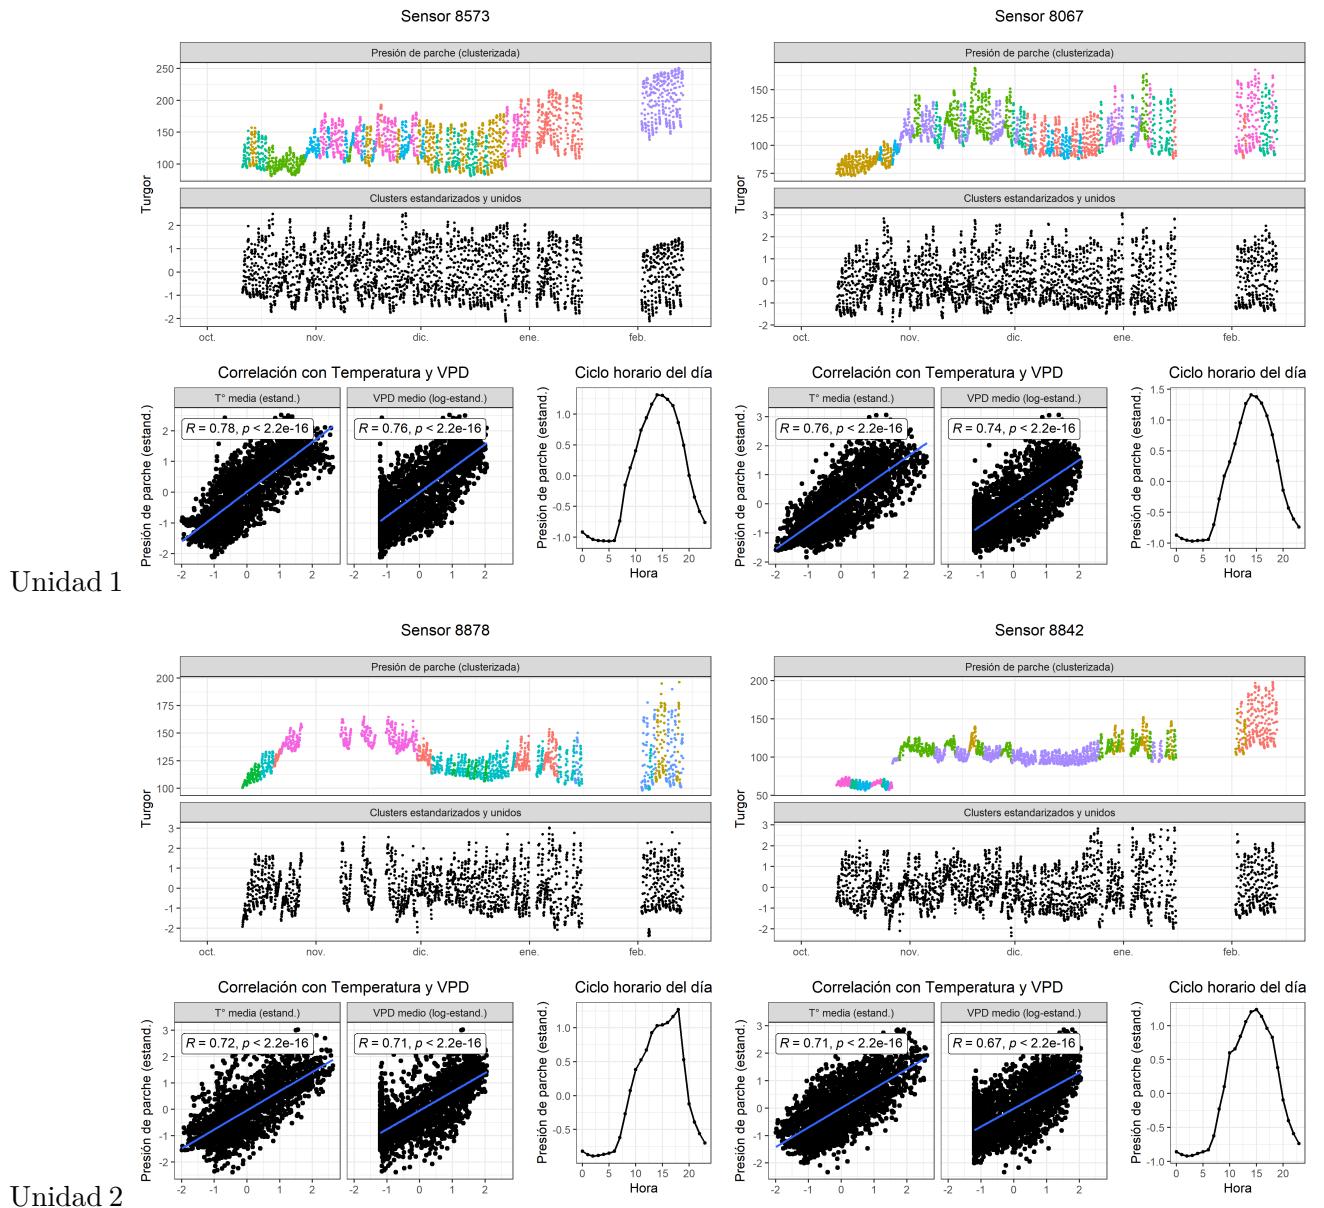


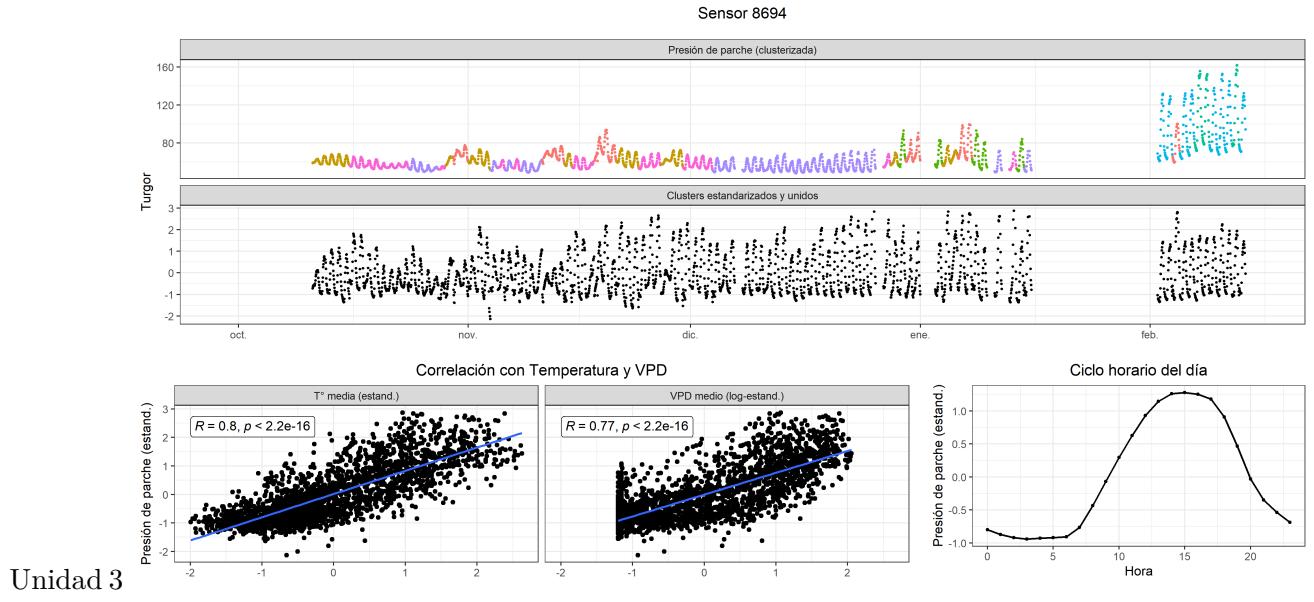
6.5.0.6 T2 (2023-2024)



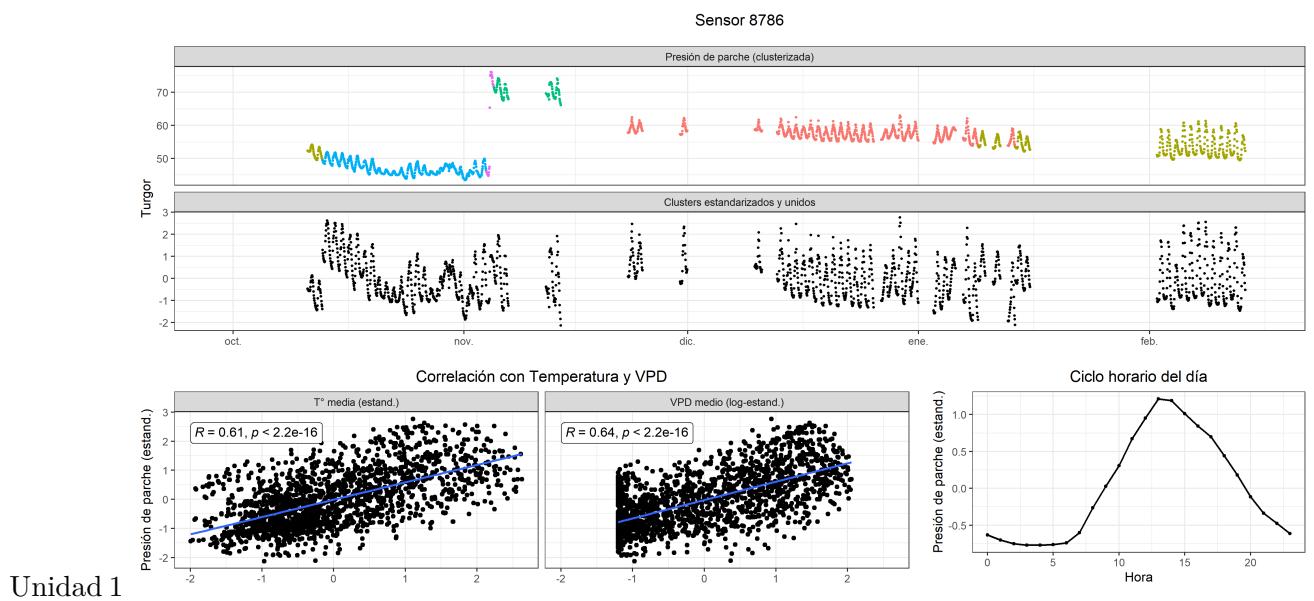


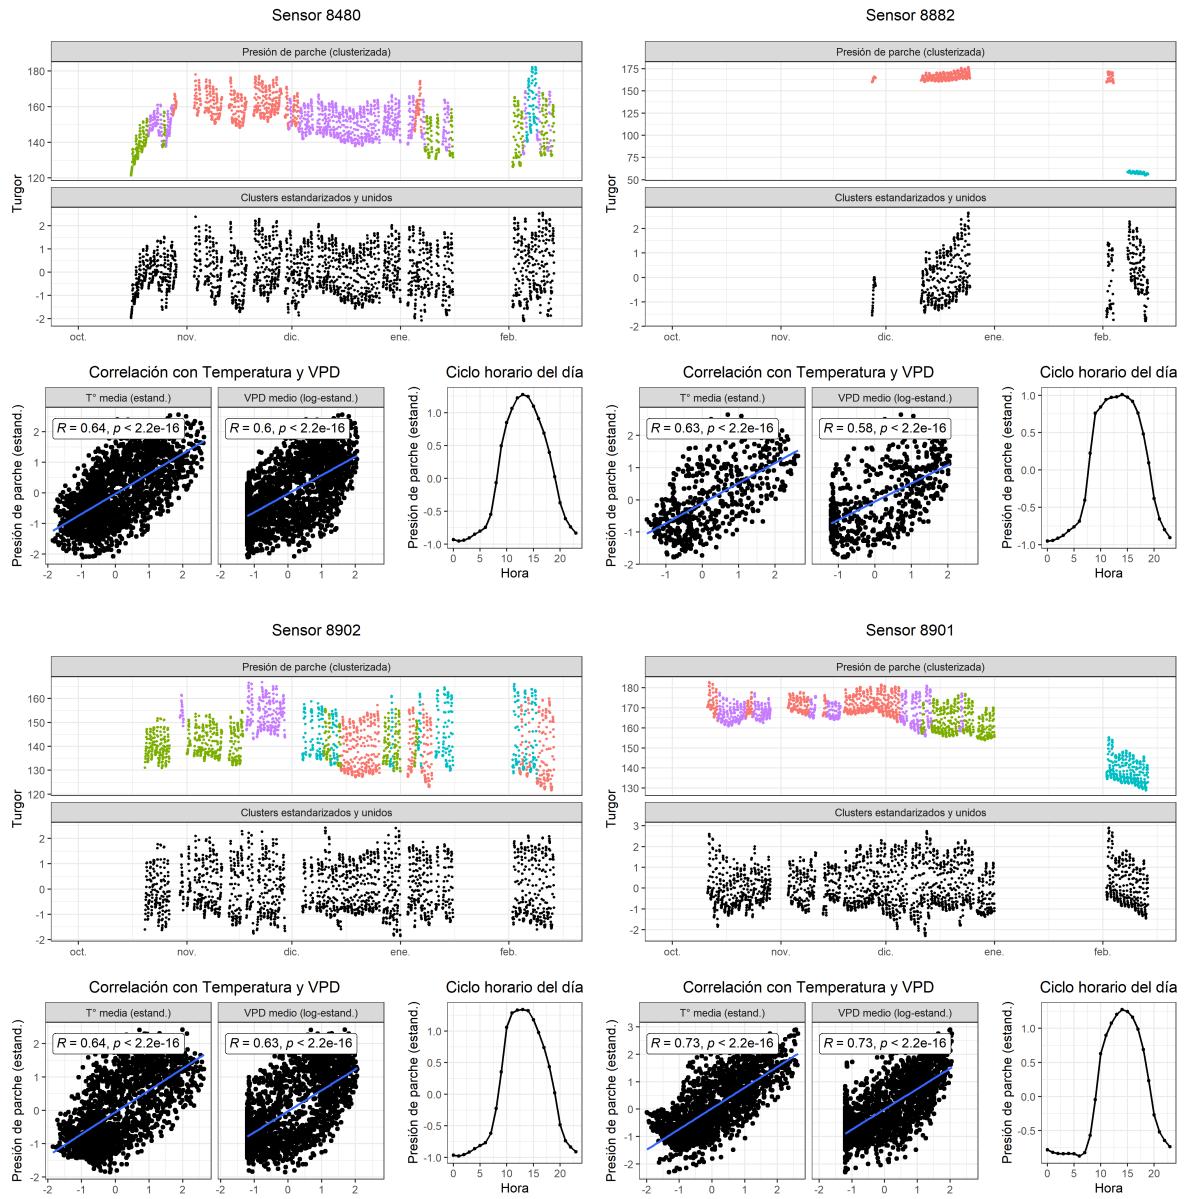
6.5.0.7 T3 (2023-2024)





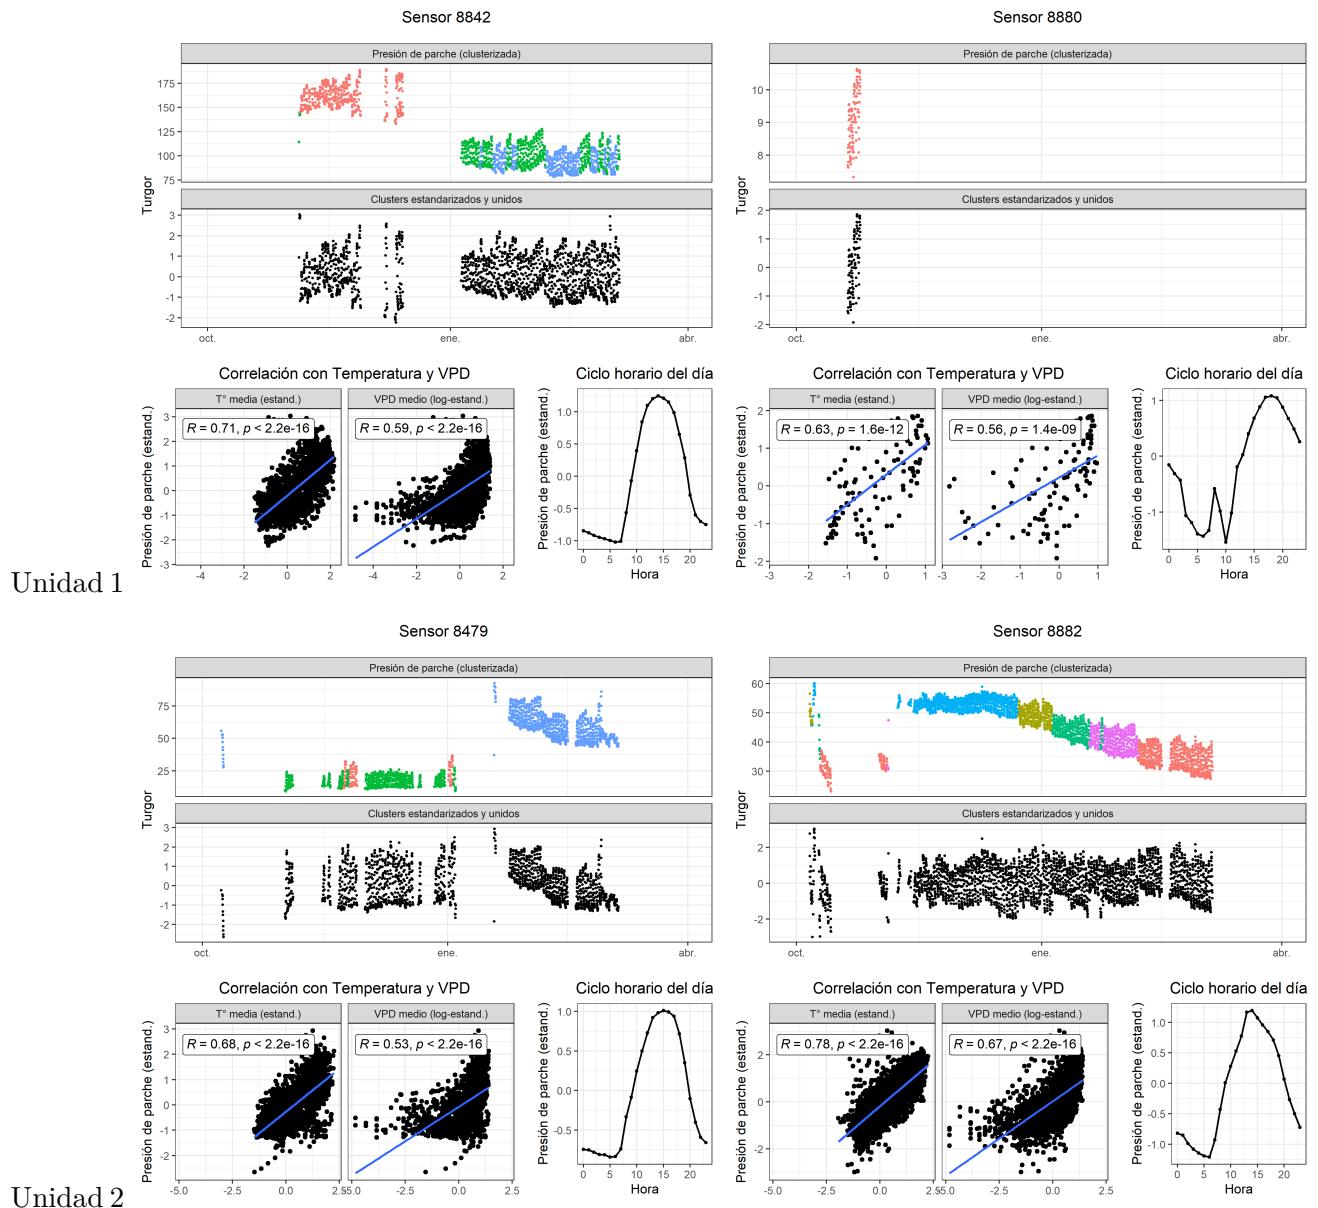
6.5.0.8 T4 (2023-2024)

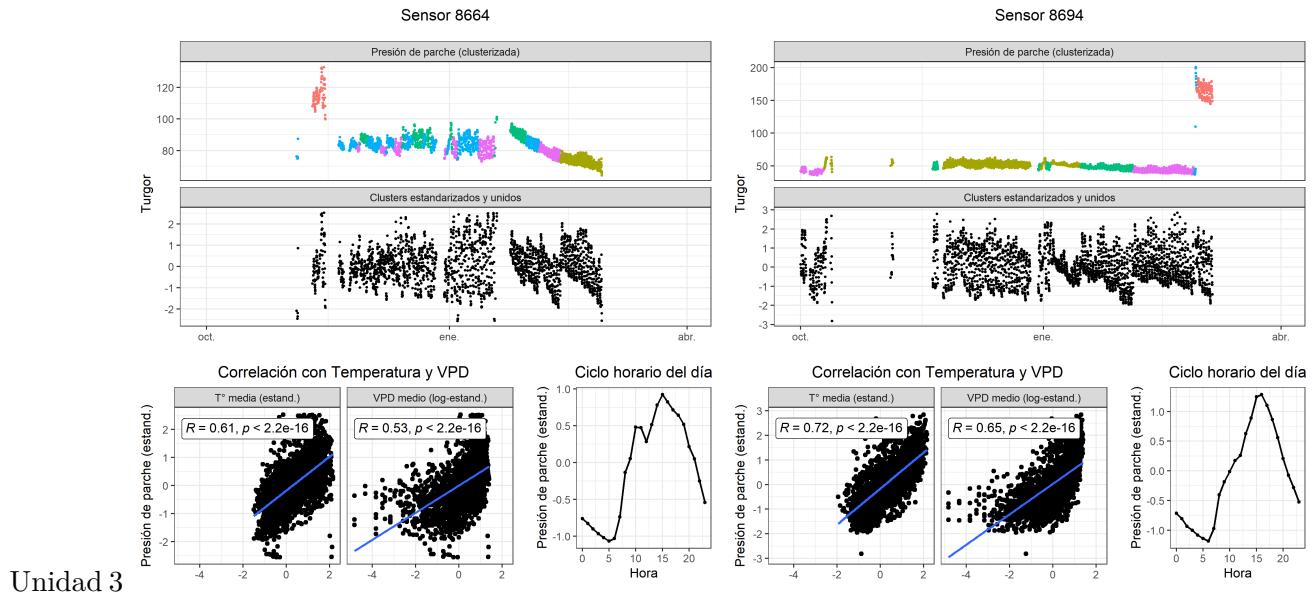




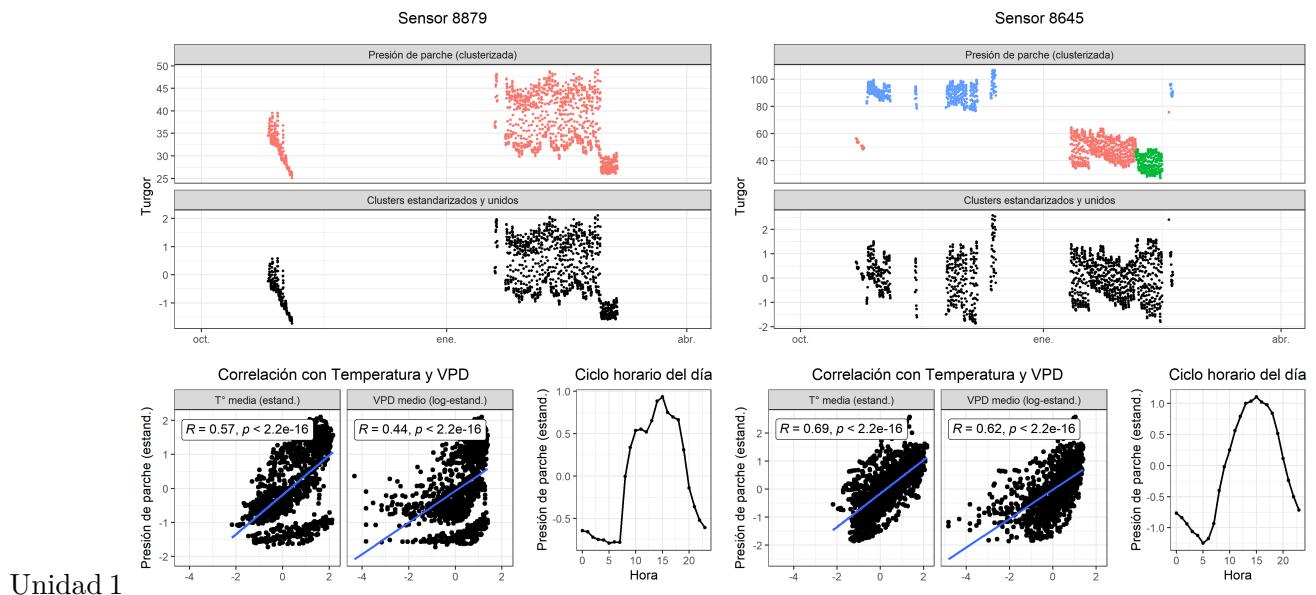
Rio Claro

6.5.0.9 T1 (2022-2023)

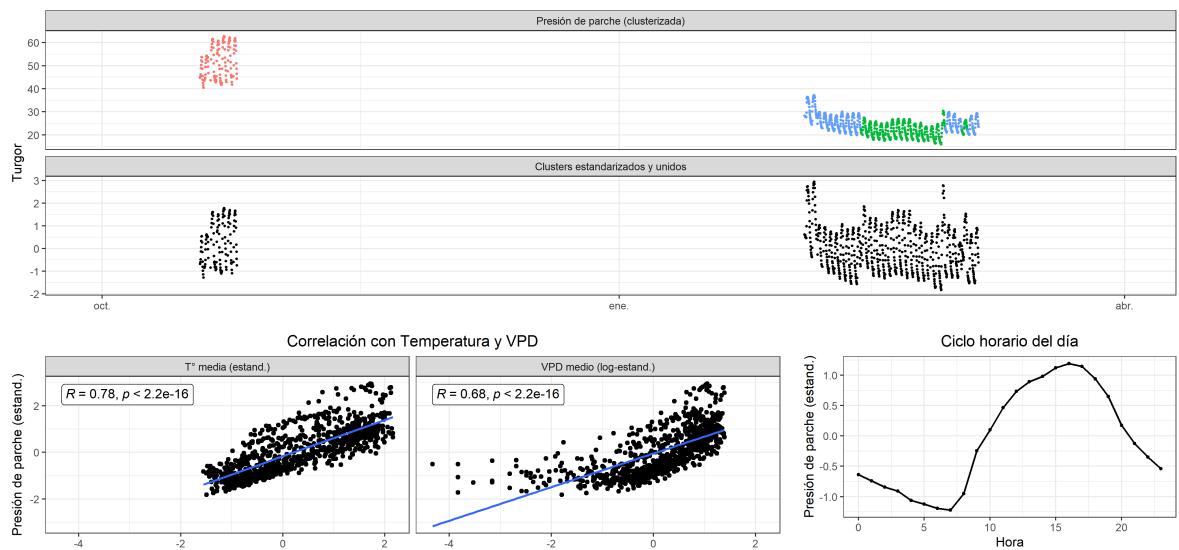




6.5.0.10 T2 (2022-2023)

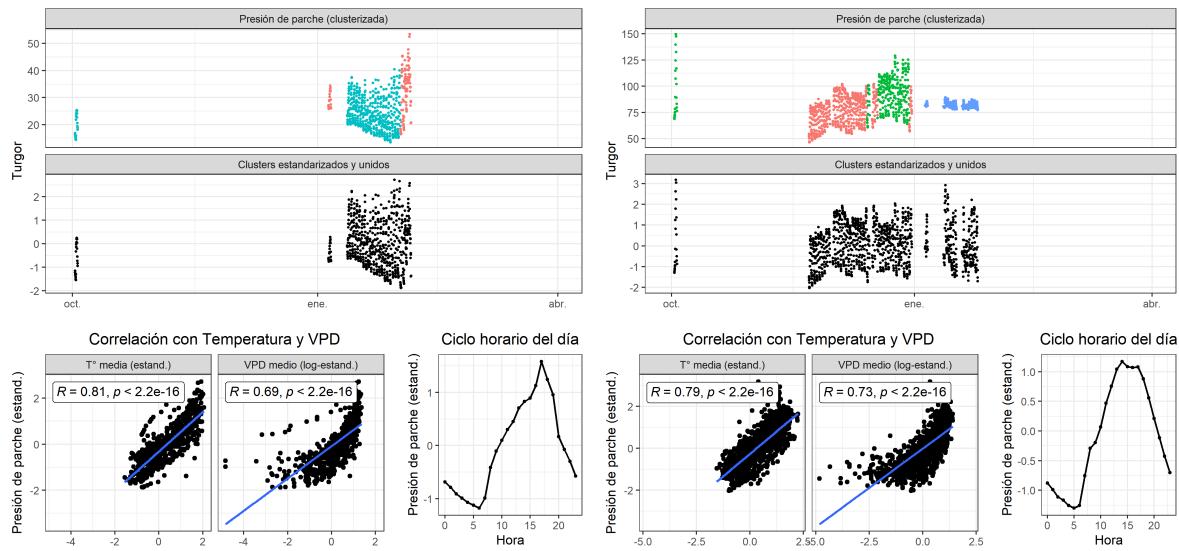


Sensor 8646



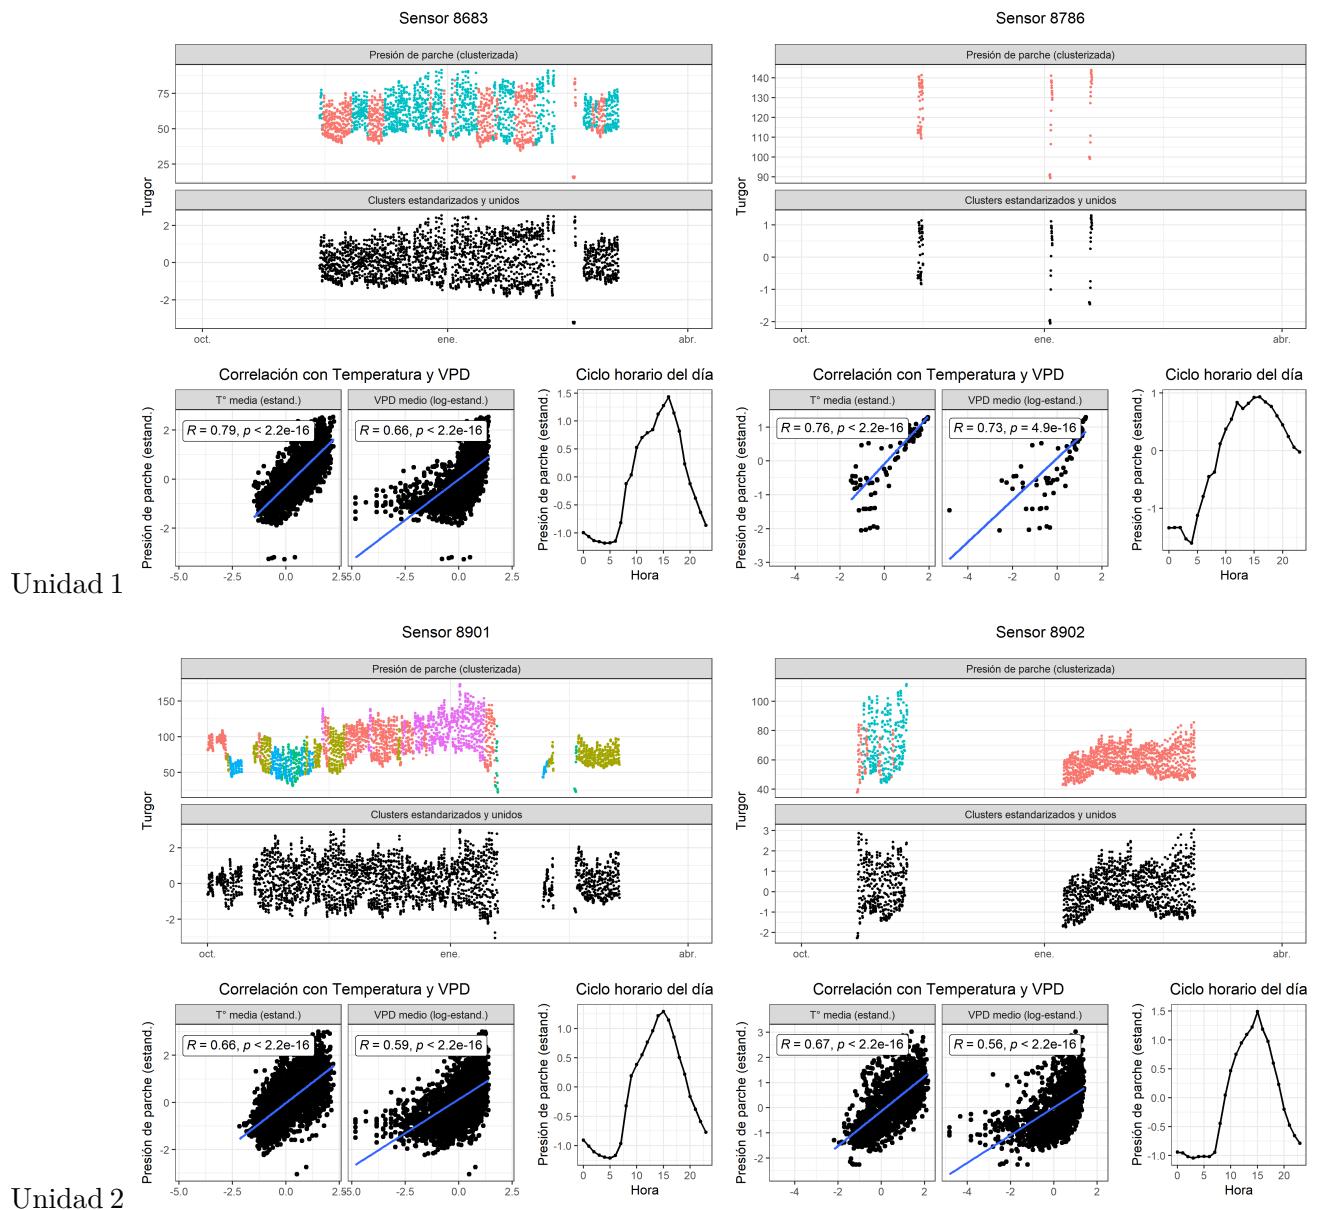
Unidad 2

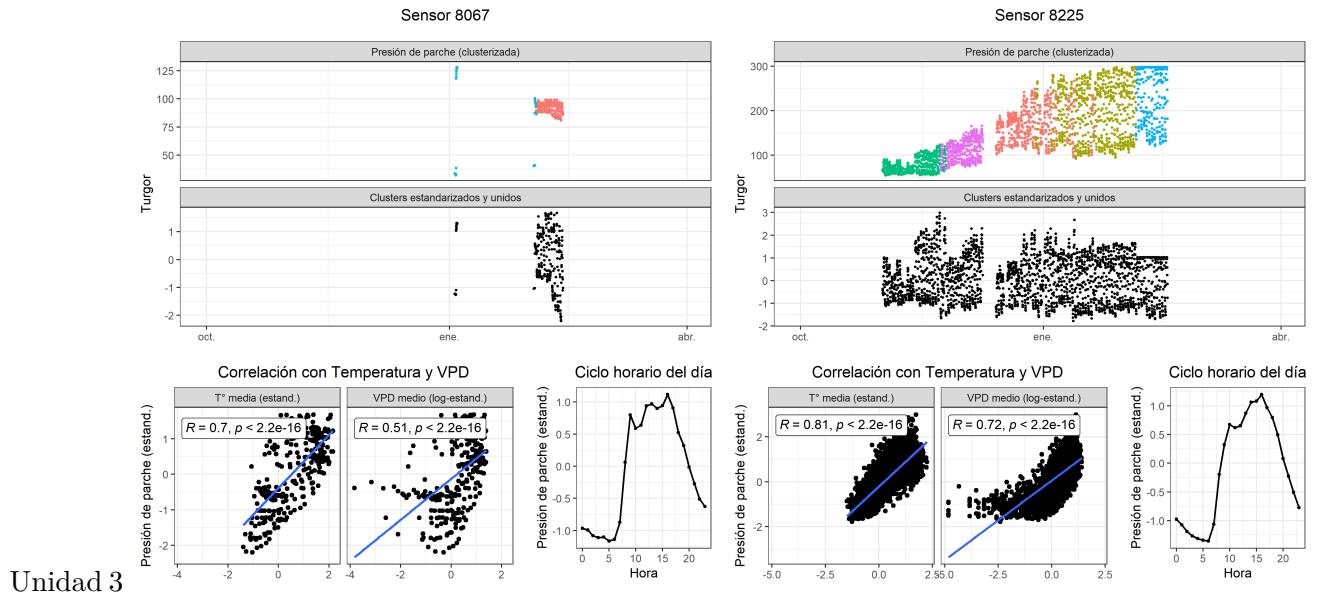
Sensor 8568



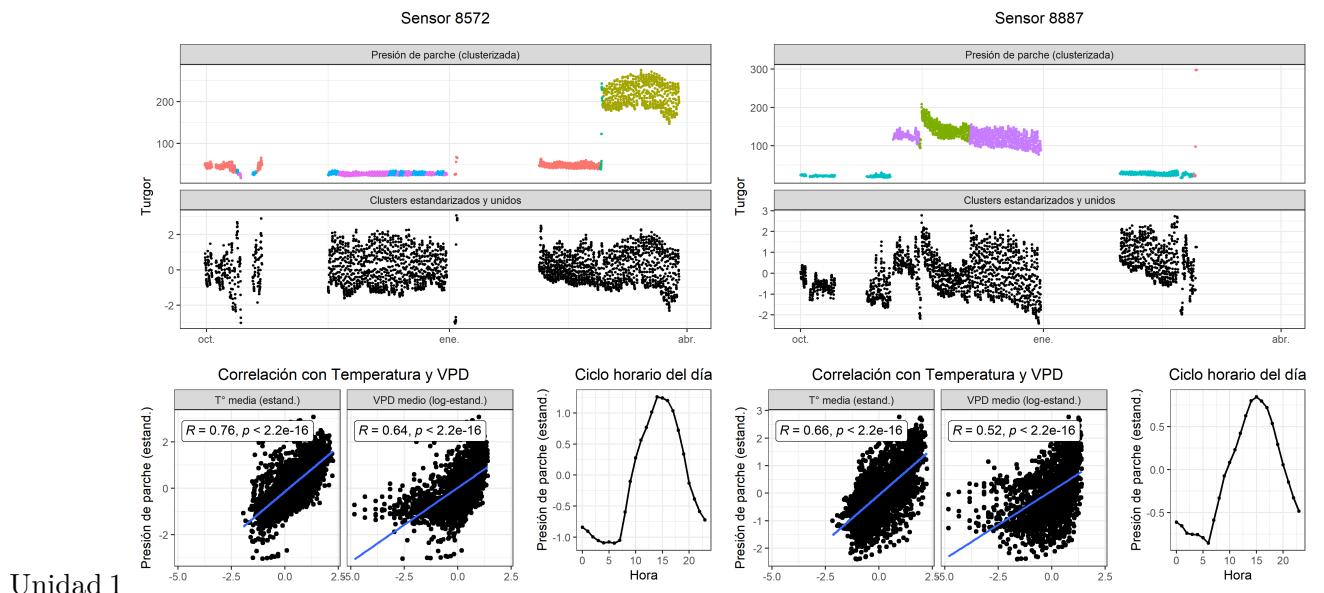
Unidad 3

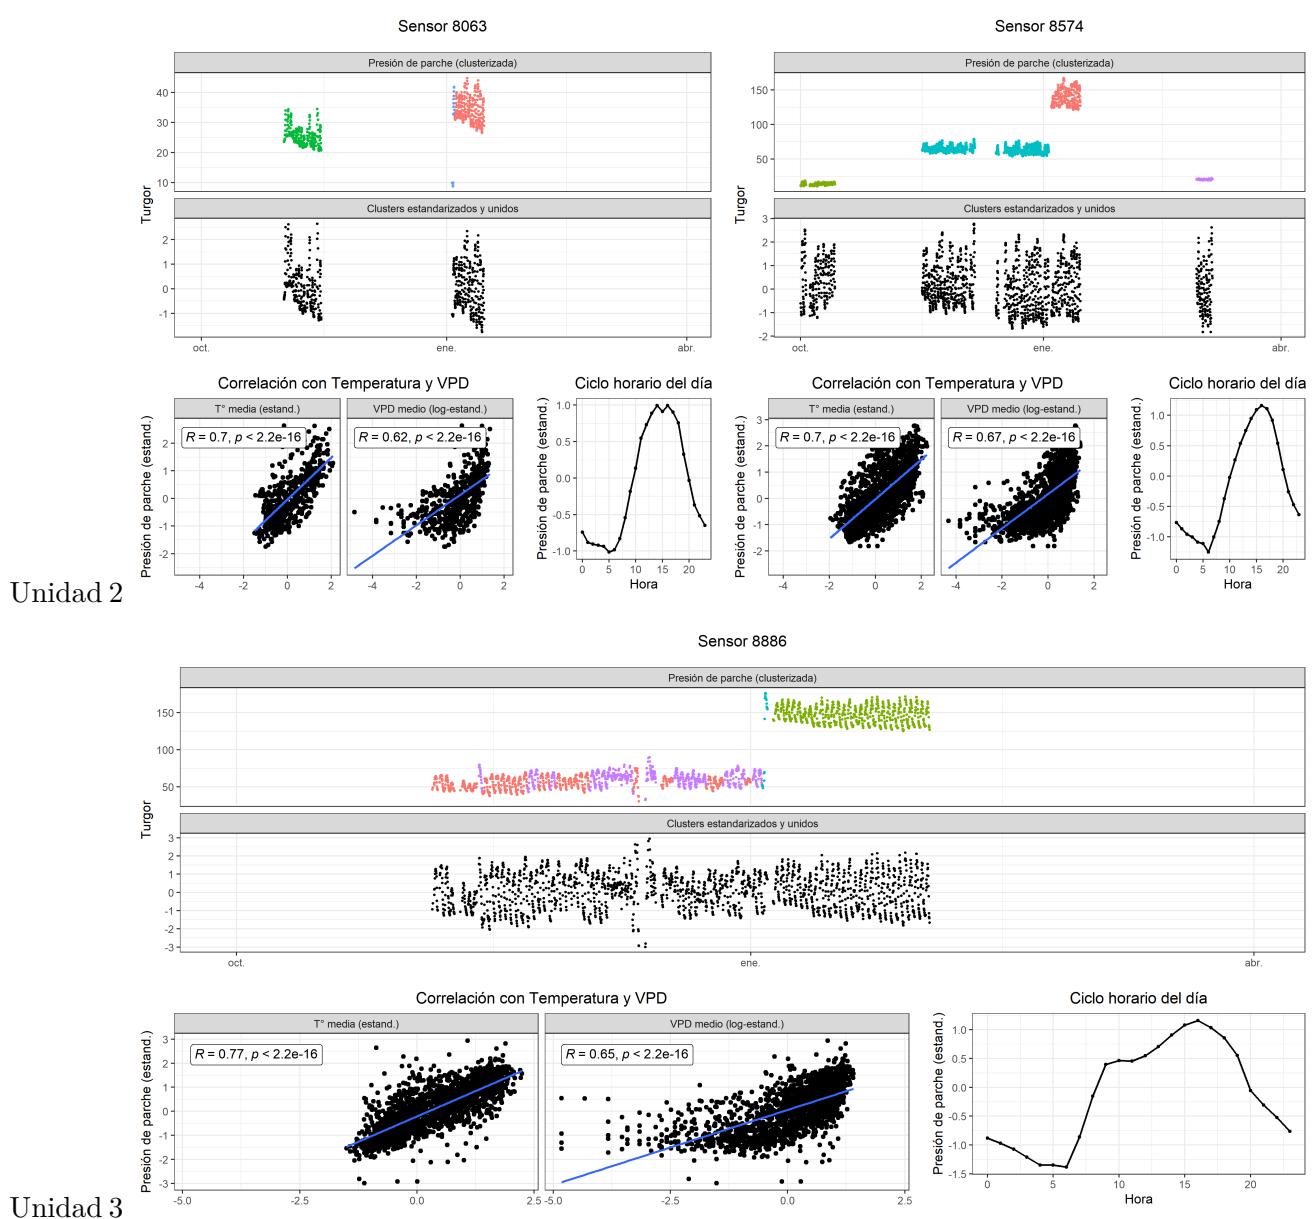
6.5.0.11 T3 (2022-2023)



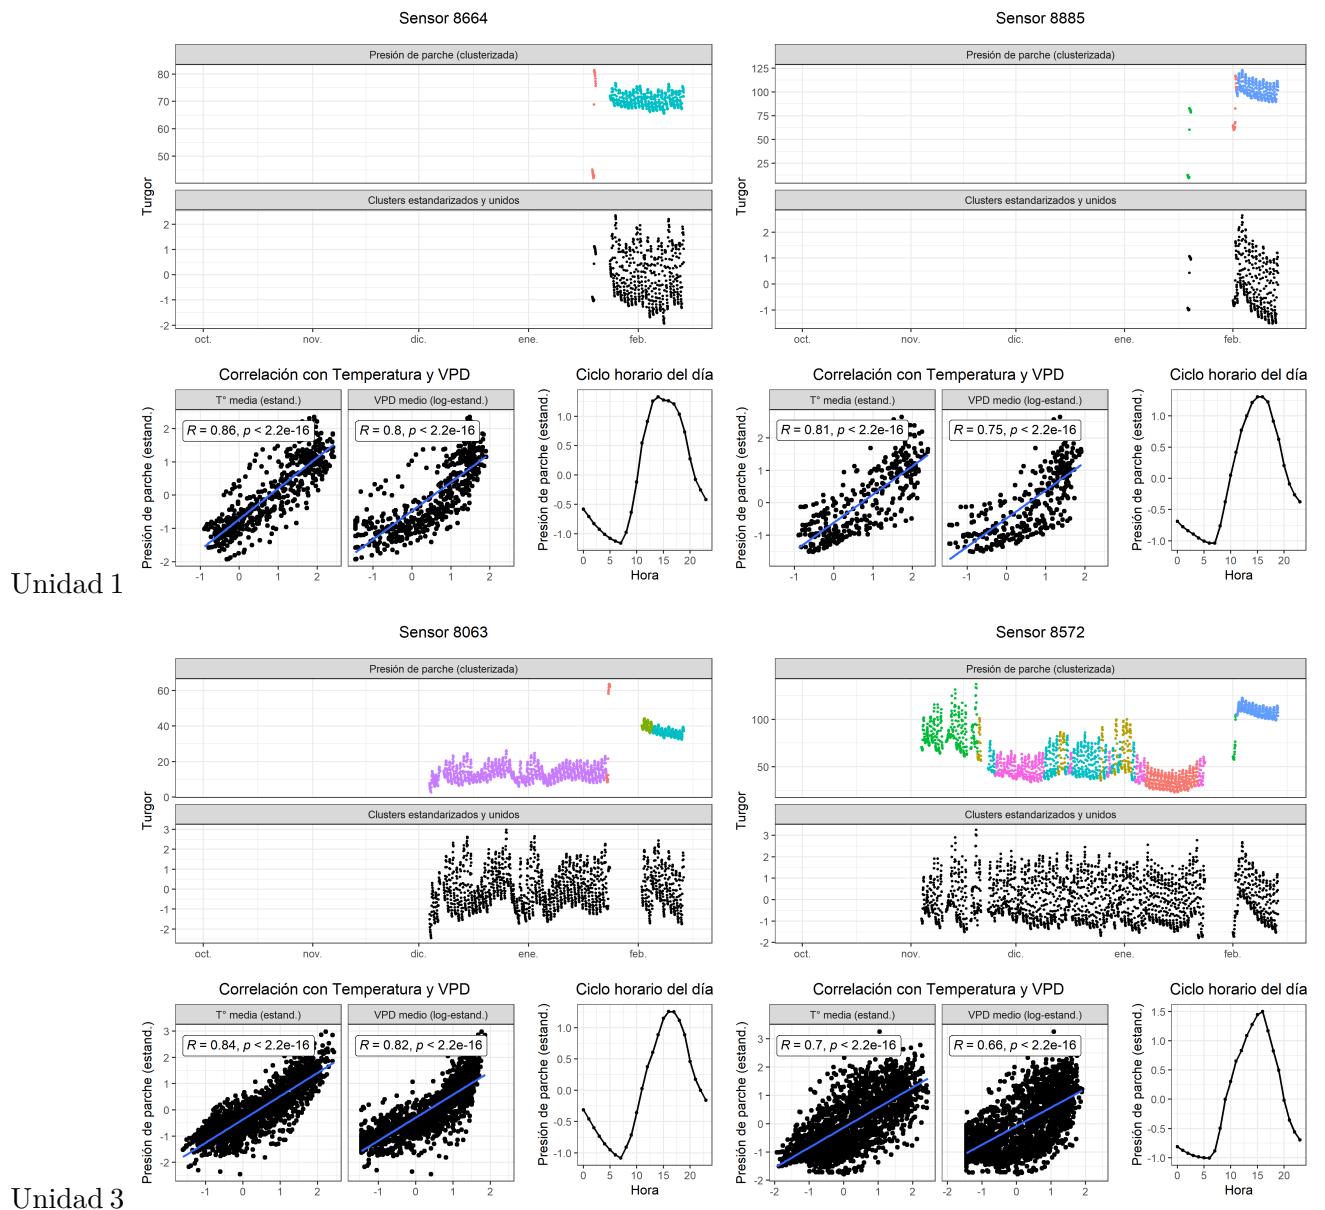


6.5.0.12 T4 (2022-2023)

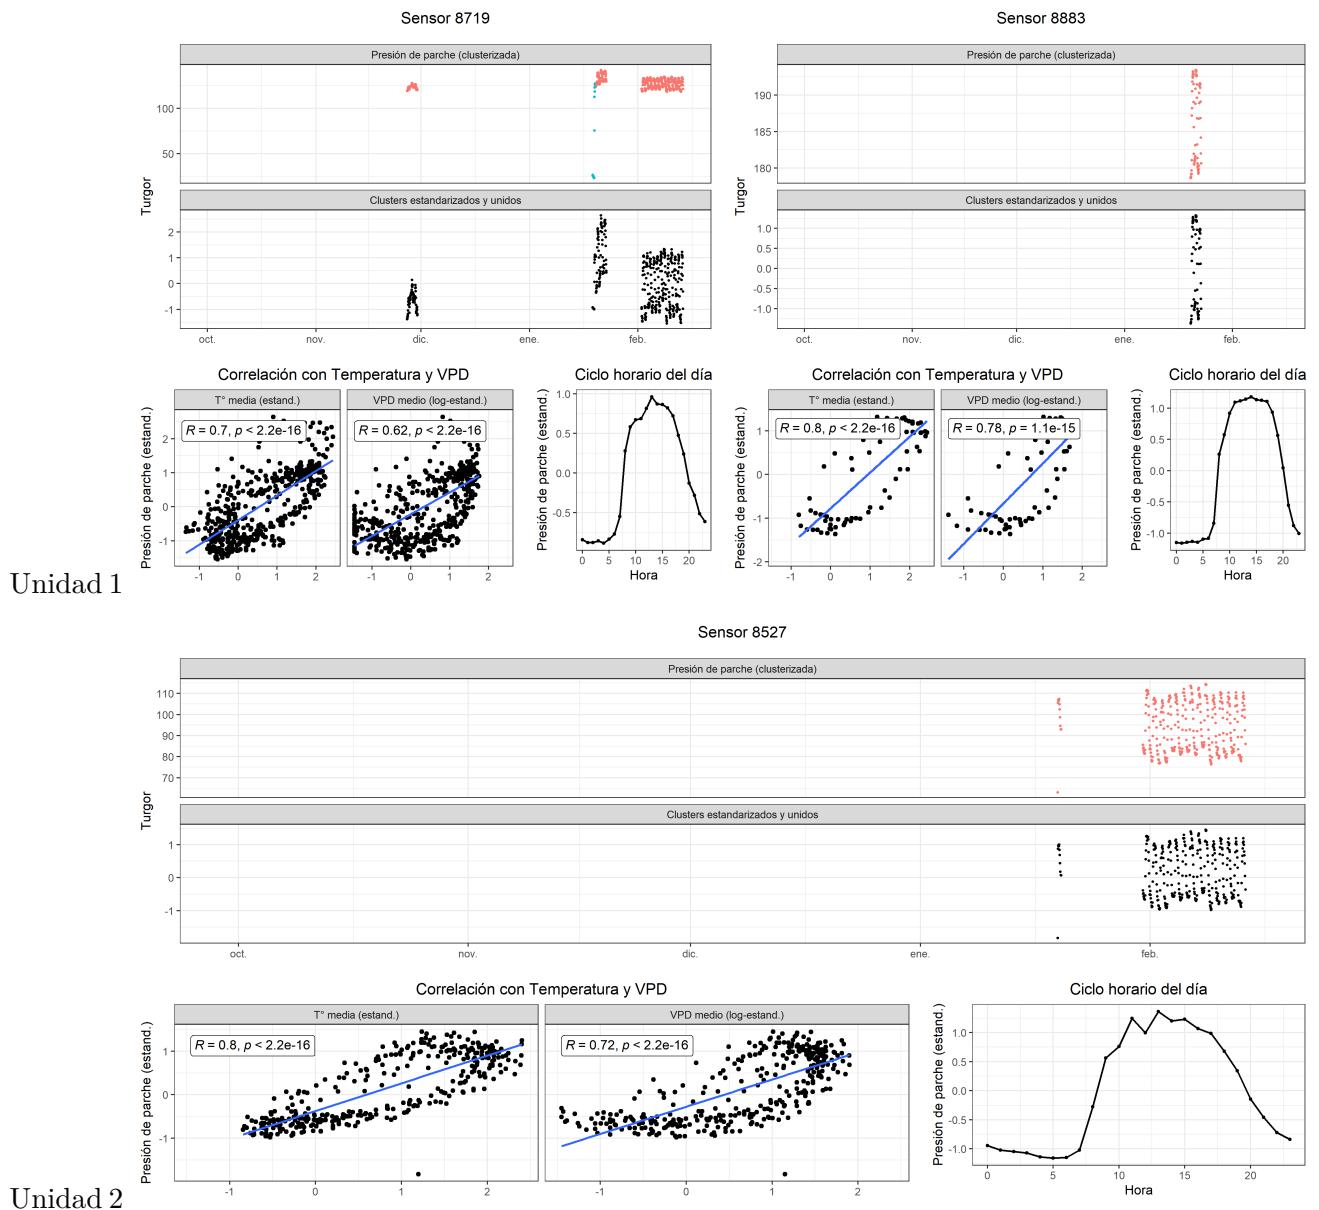


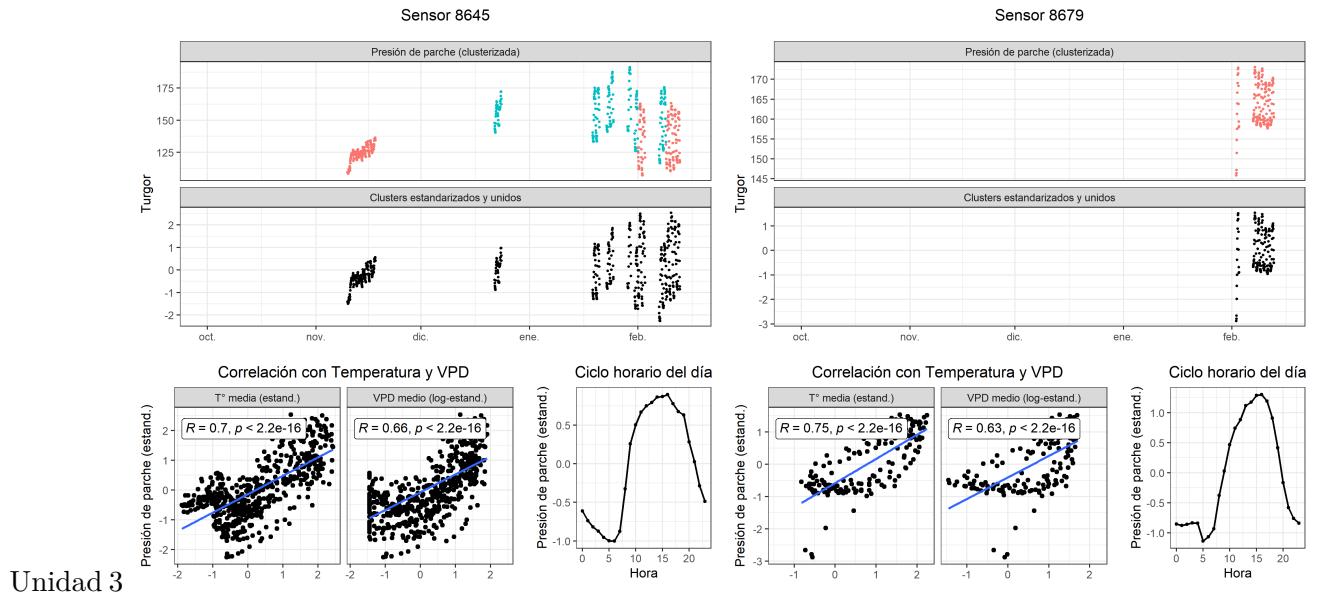


6.5.0.13 T1 (2023-2024)

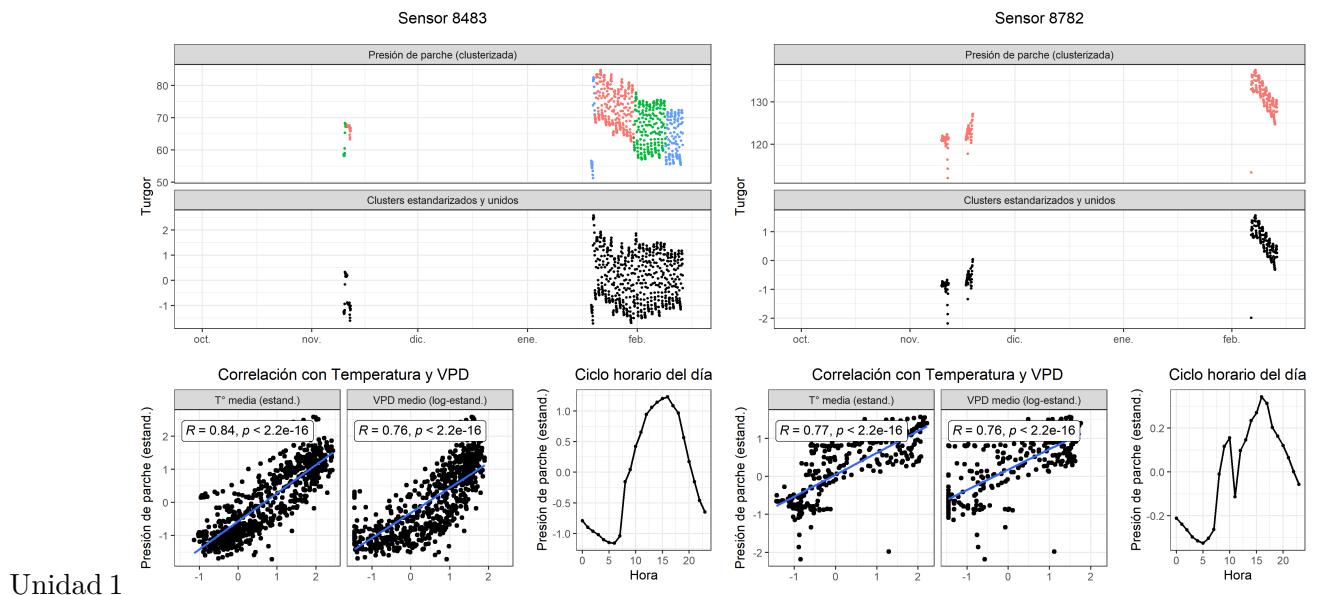


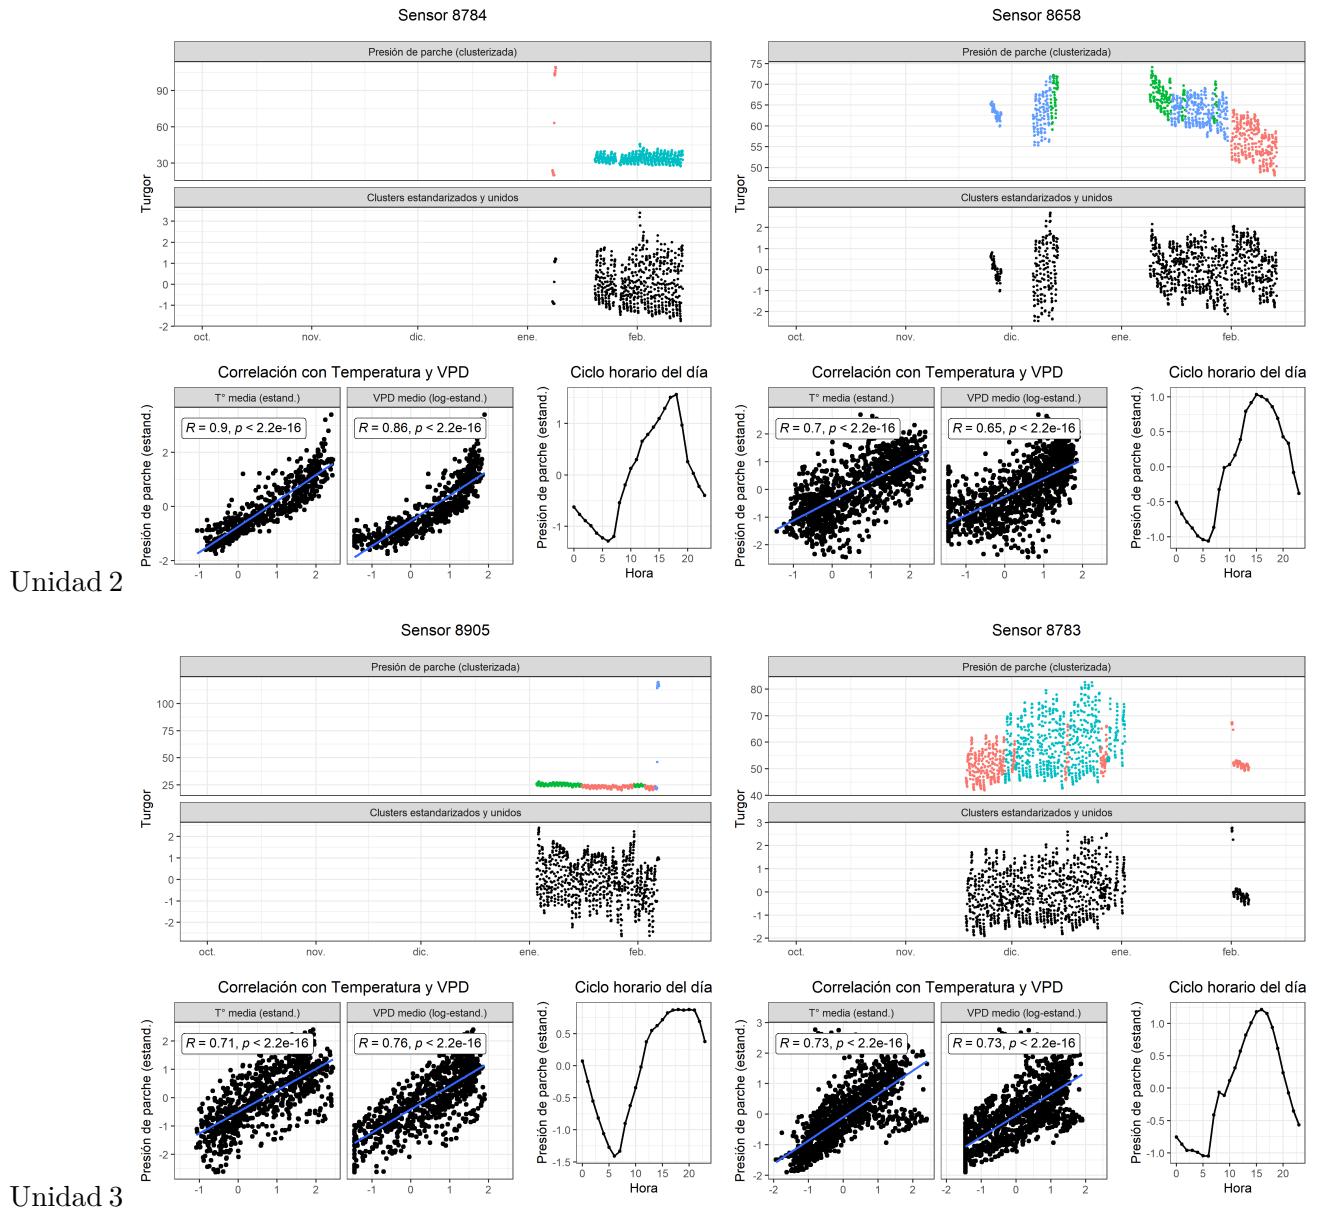
6.5.0.14 T2 (2023-2024)



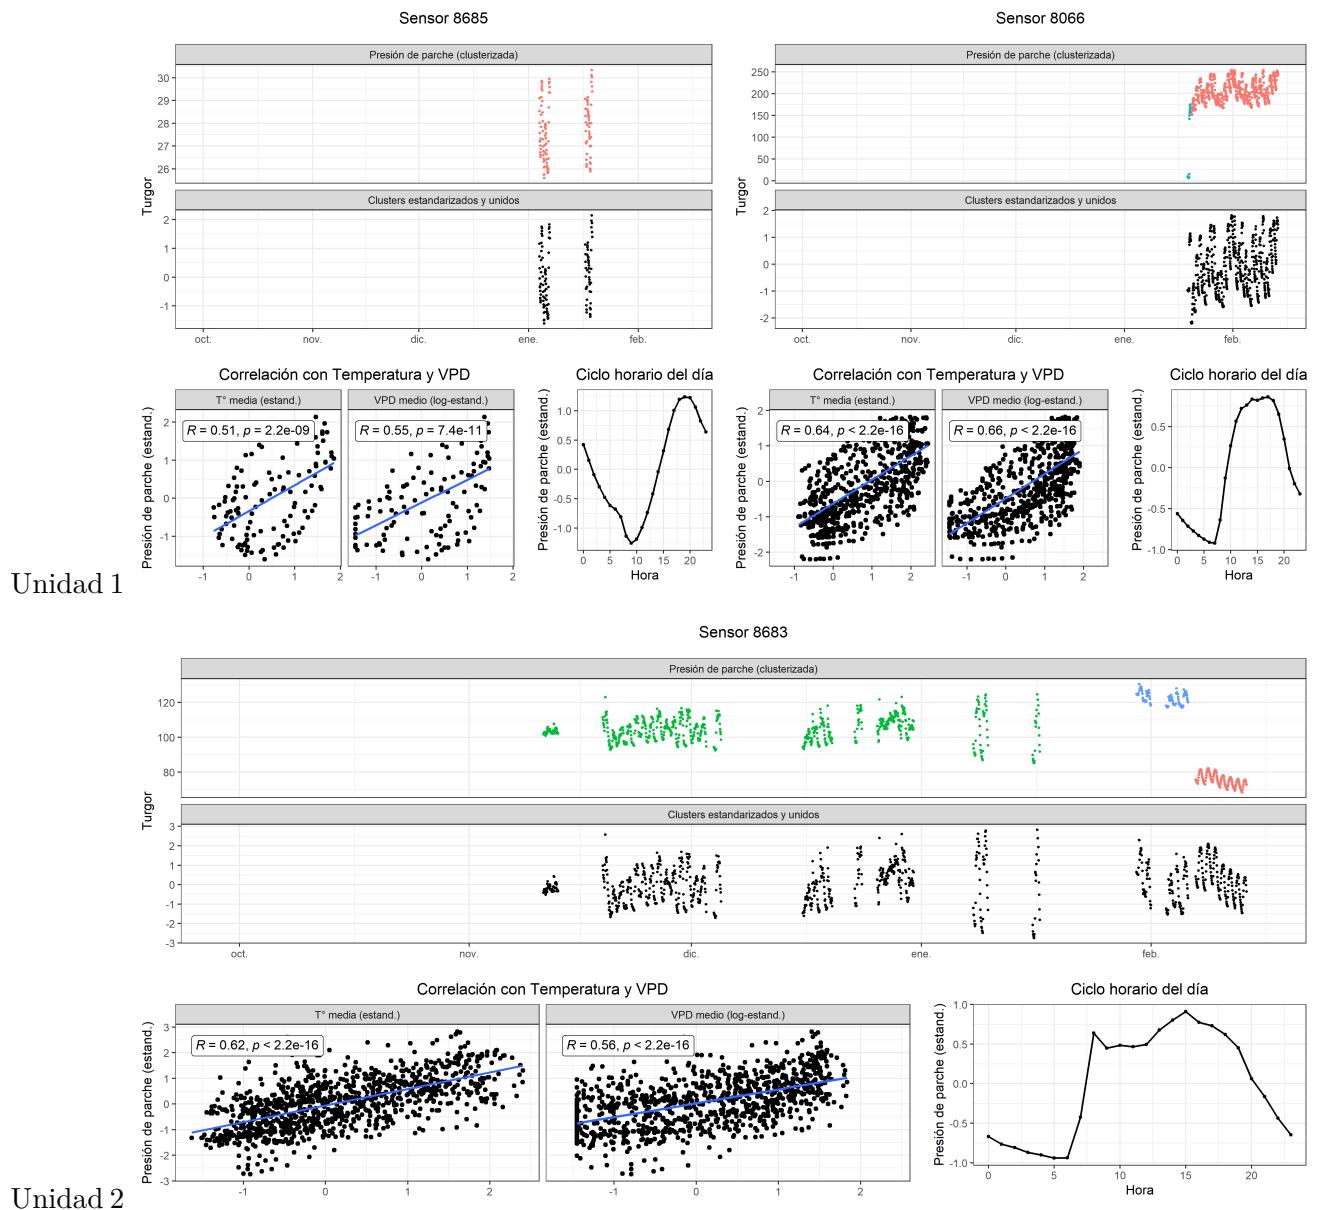


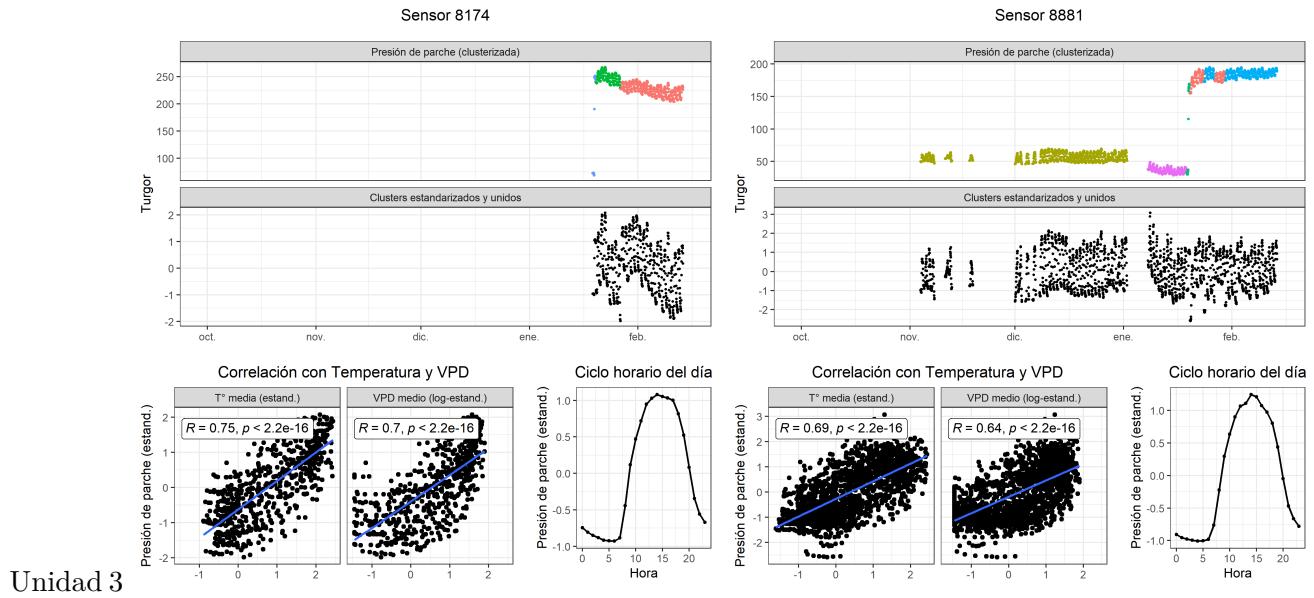
6.5.0.15 T3 (2023-2024)





6.5.0.16 T4 (2023-2024)





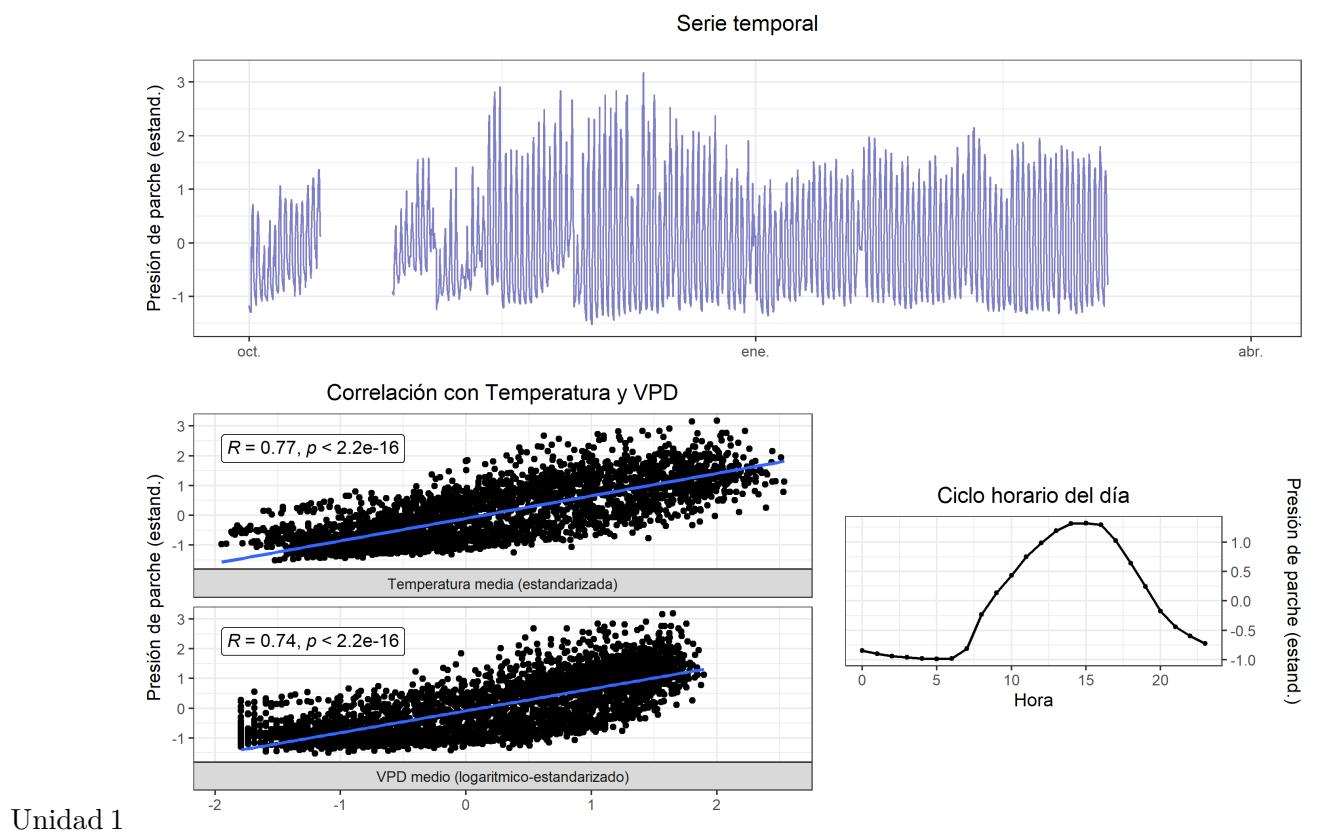
Datos preprocesados

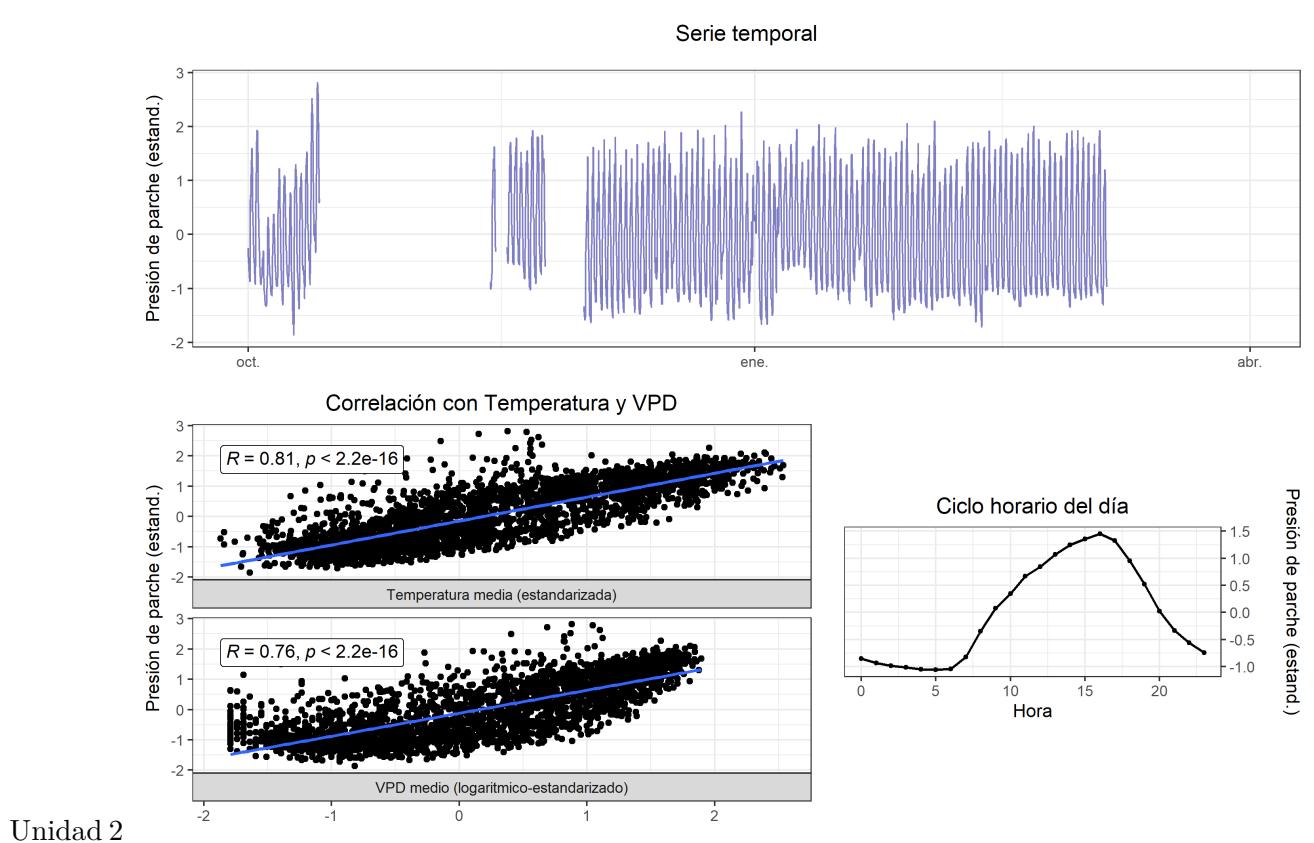
A nivel de unidad

Para obtener el turgor preprocesado por árbol según tratamiento, se promediaron las series de los sensores por cada unidad, obteniendo una serie única para cada árbol de los tratamientos.

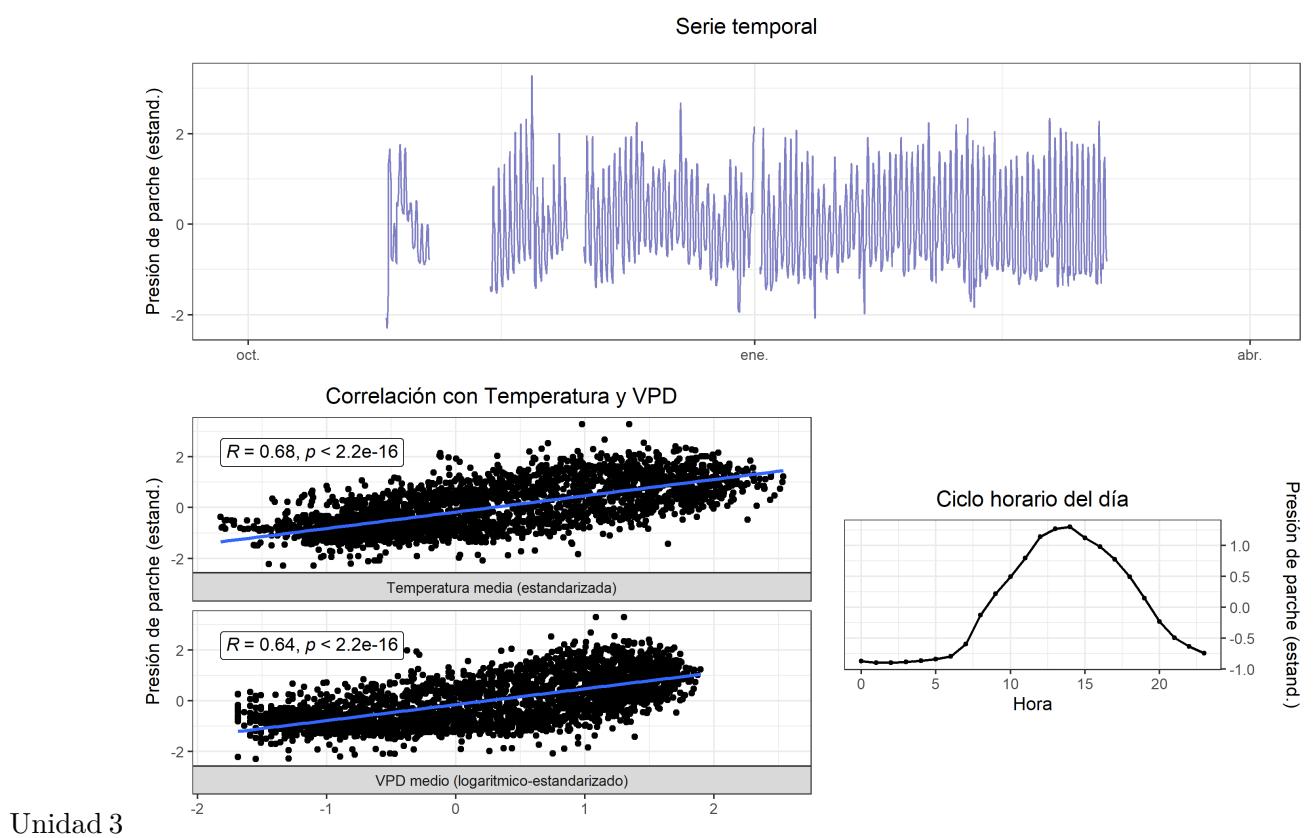
6.5.0.0.1 * La Esperanza

6.5.0.1 T1 (2022-2023)

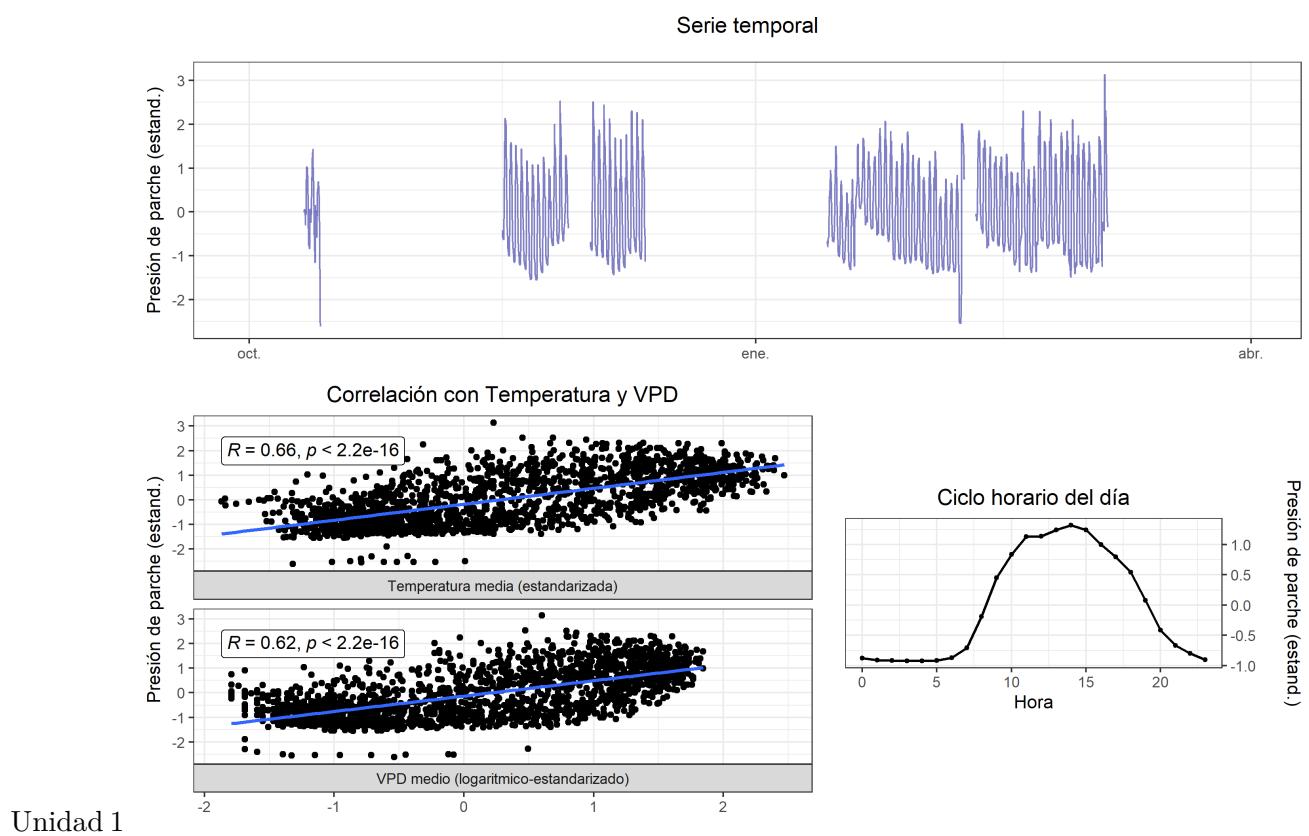


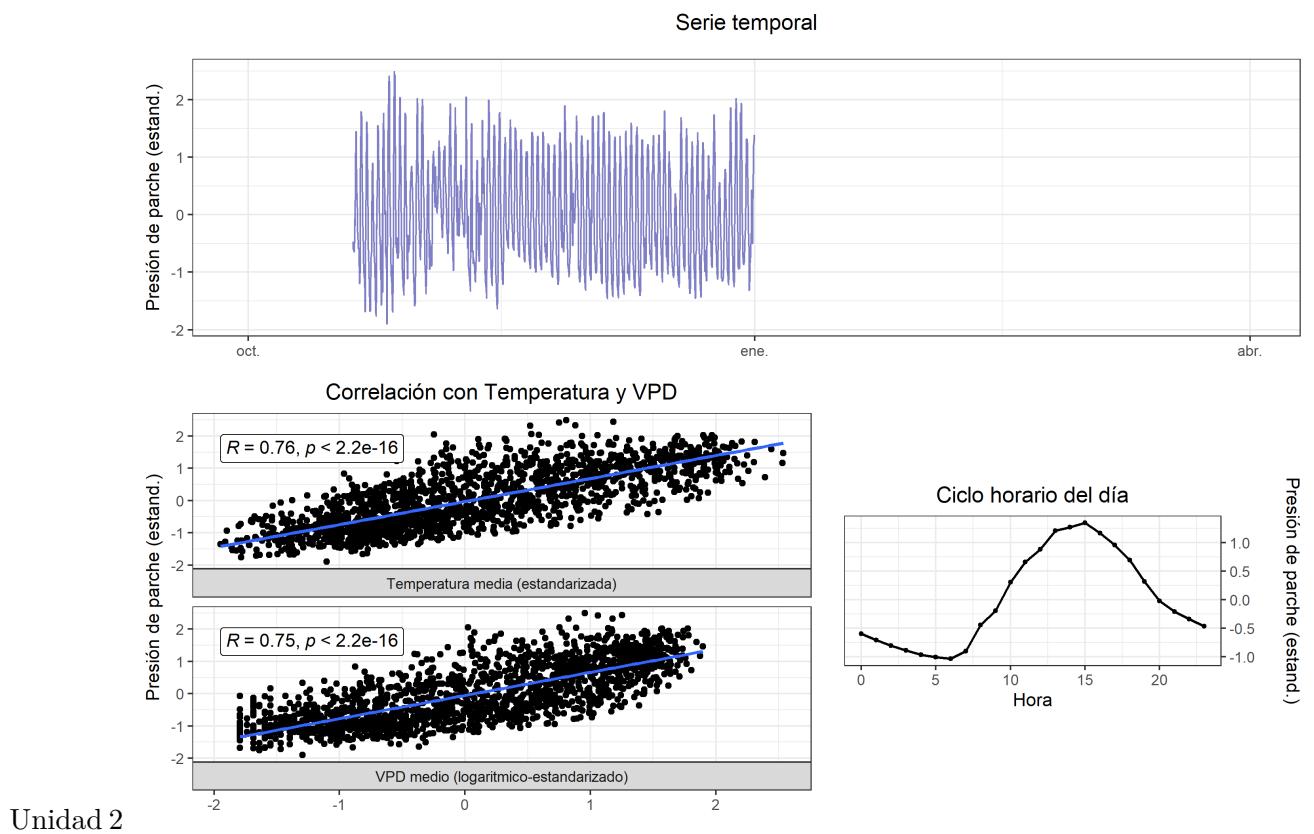


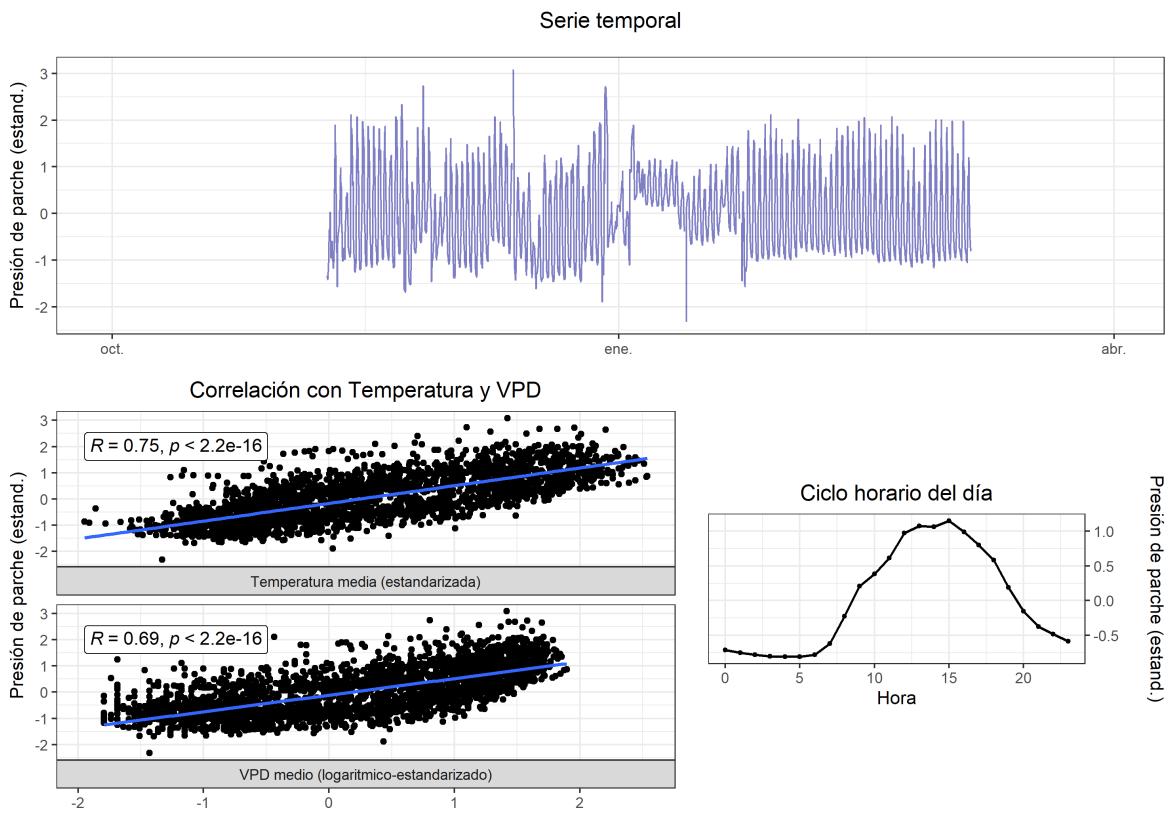
Unidad 2



6.5.0.2 T2 (2022-2023)

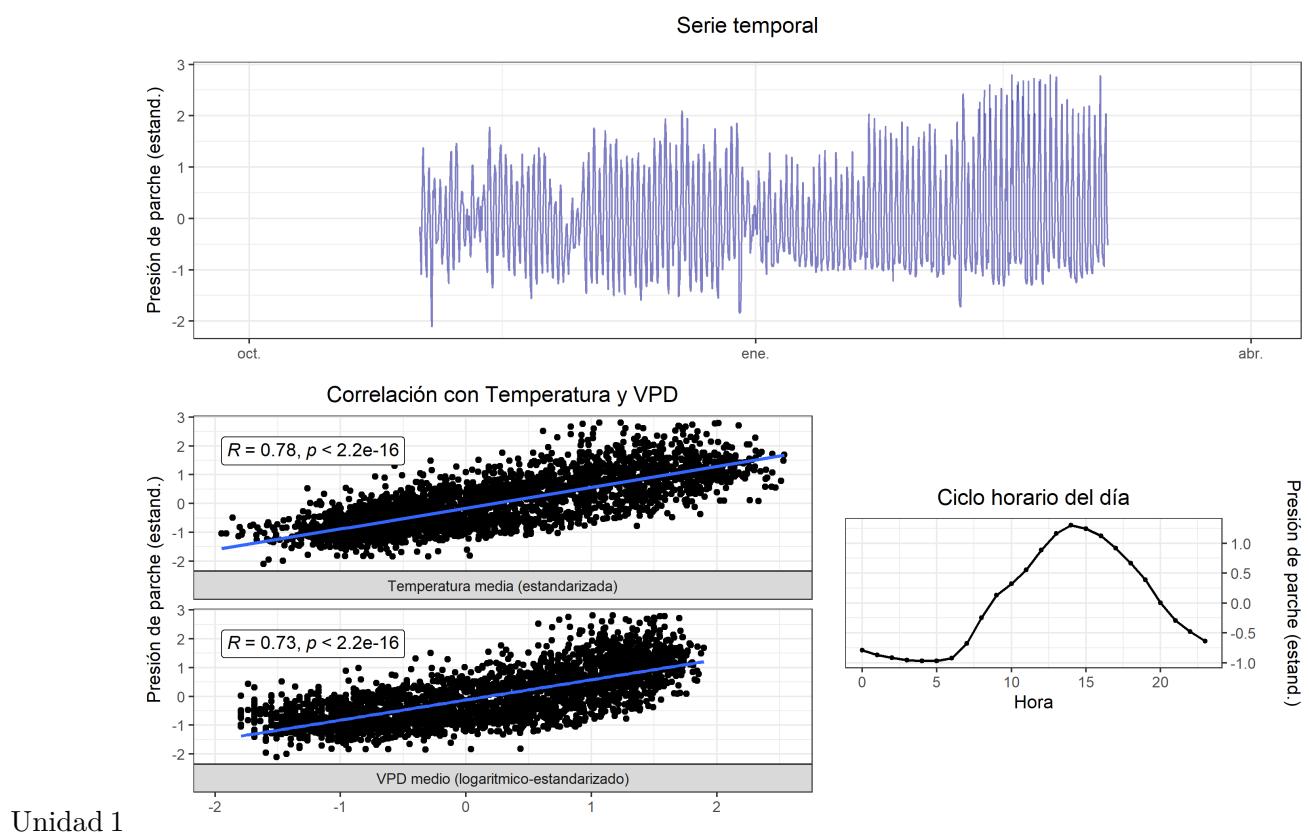


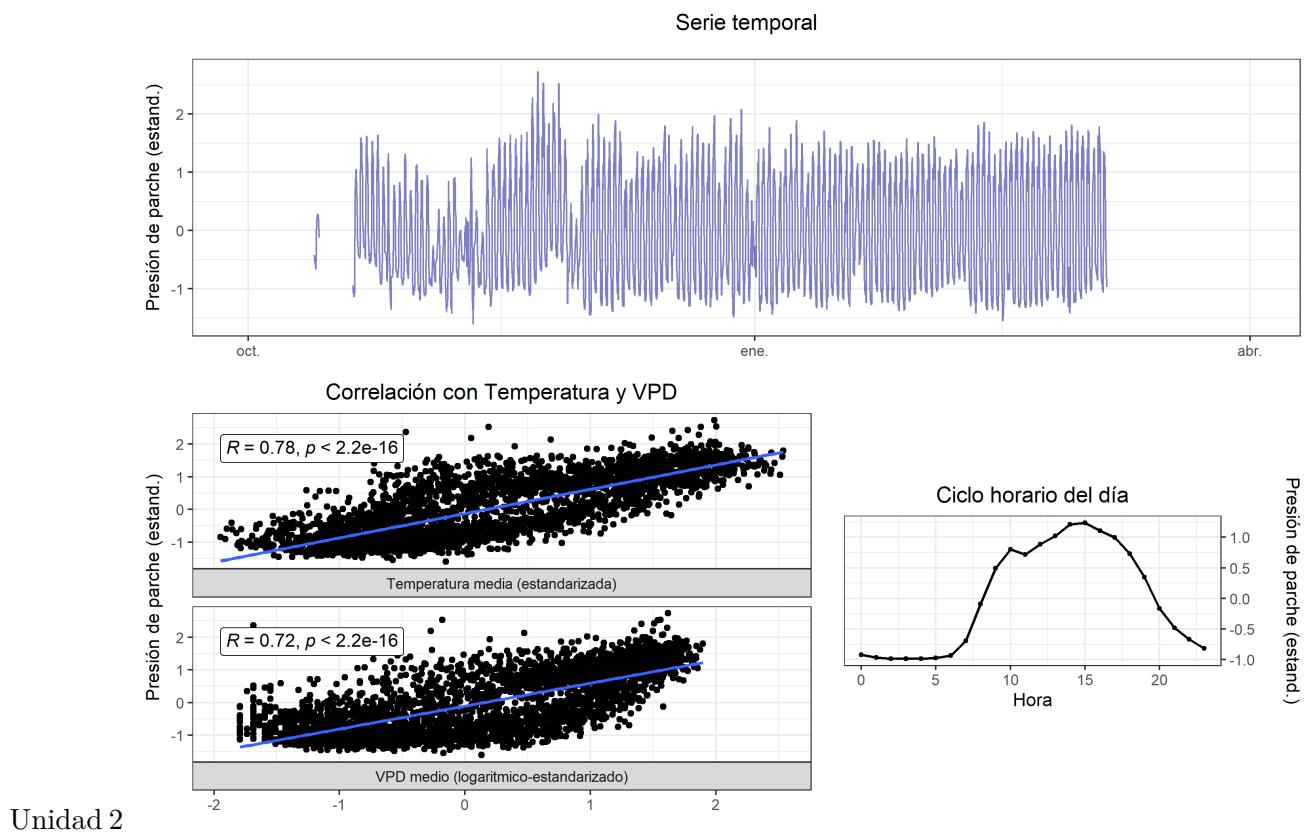


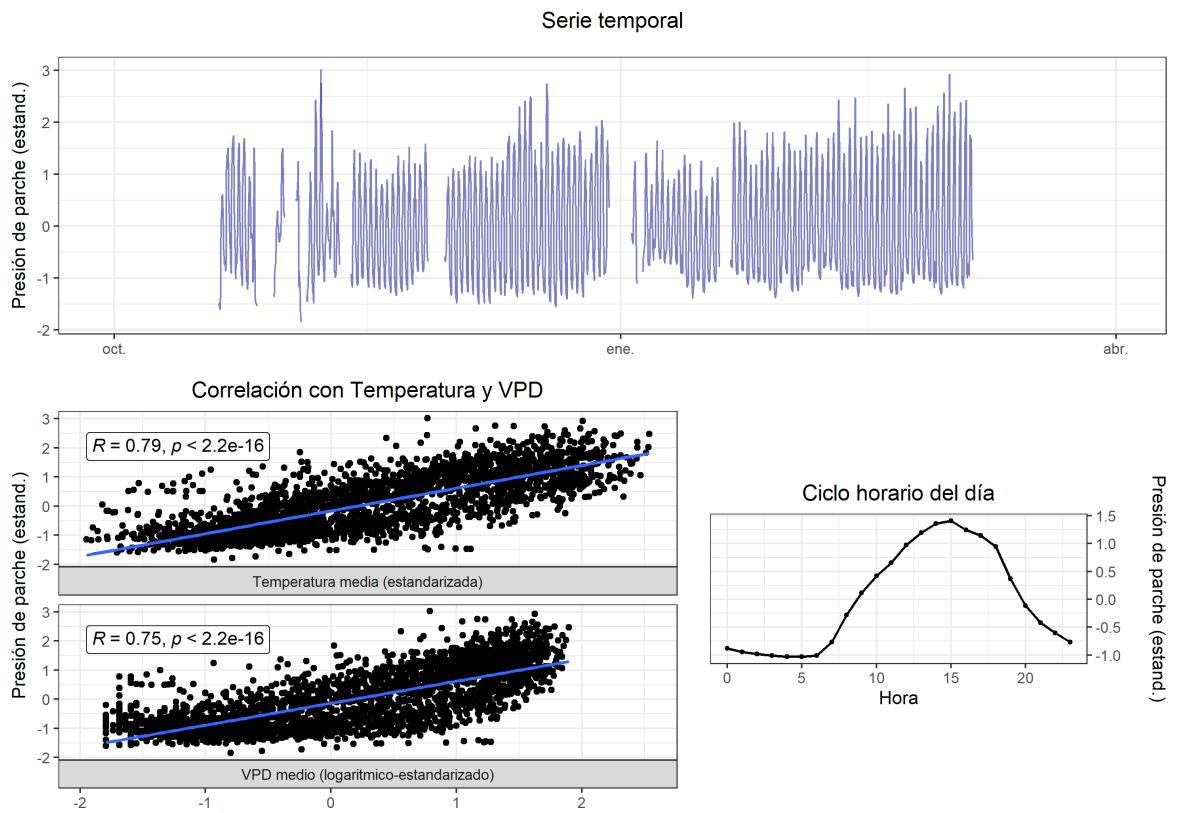


Unidad 3

6.5.0.3 T3 (2022-2023)

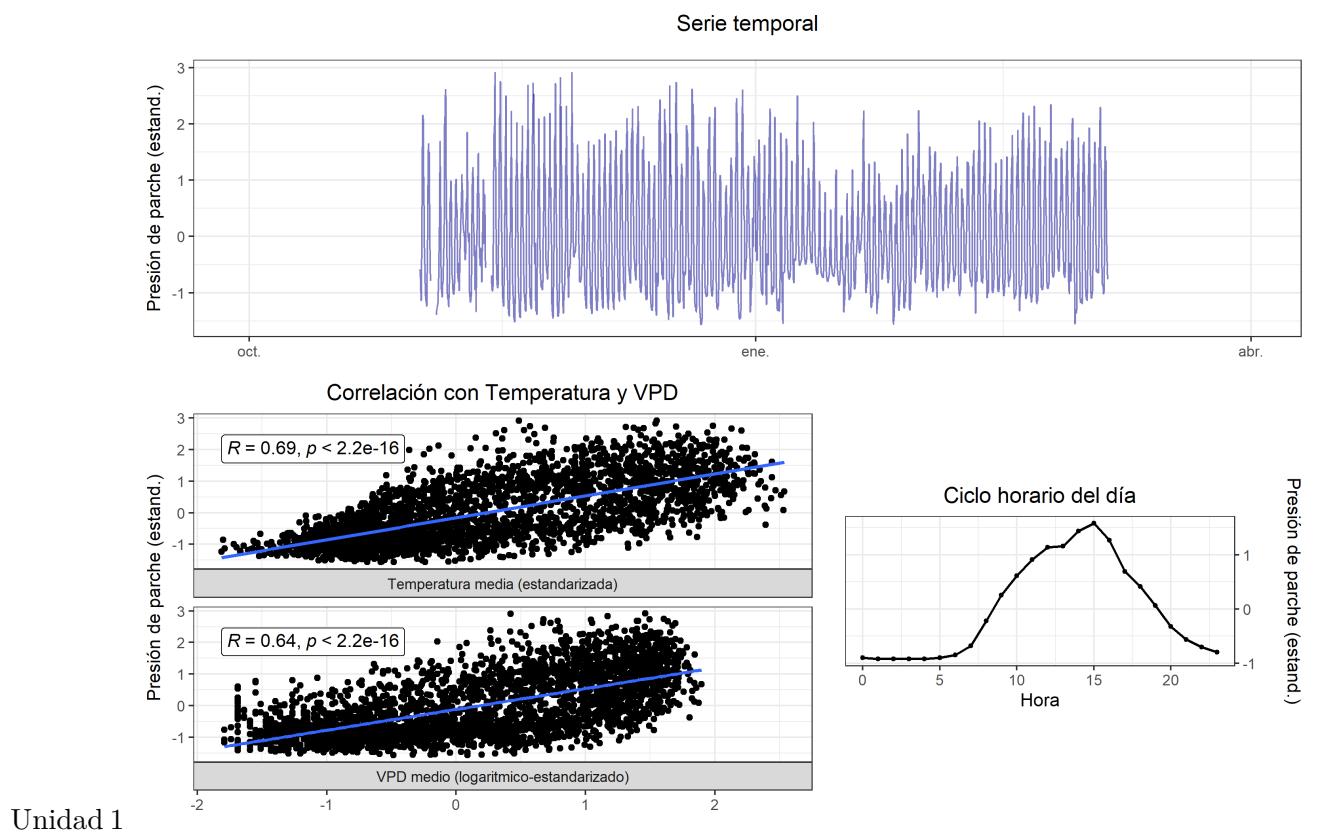


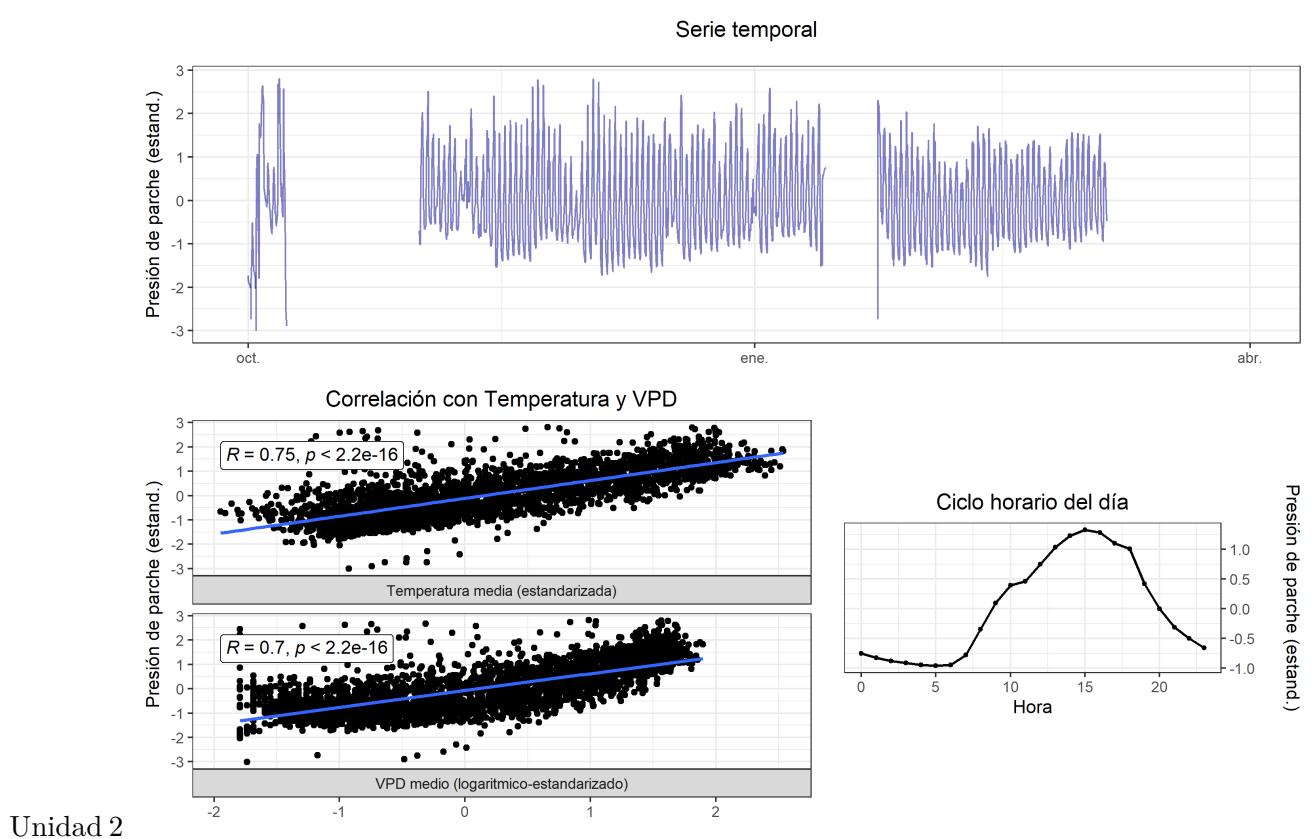




Unidad 3

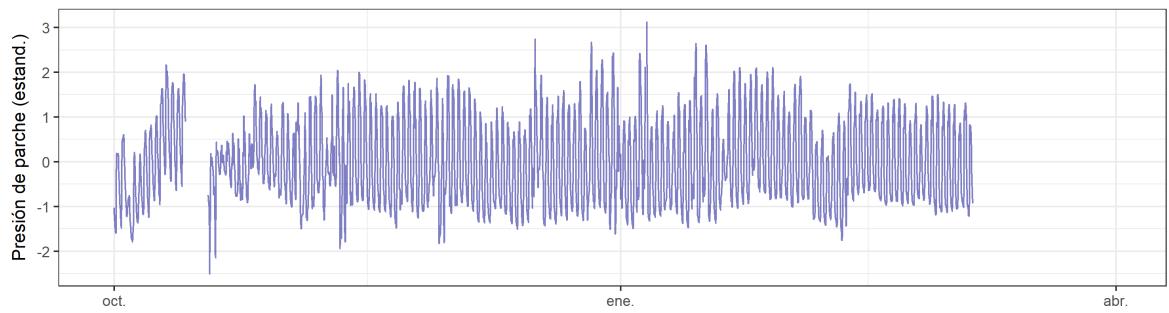
6.5.0.4 T4 (2022-2023)



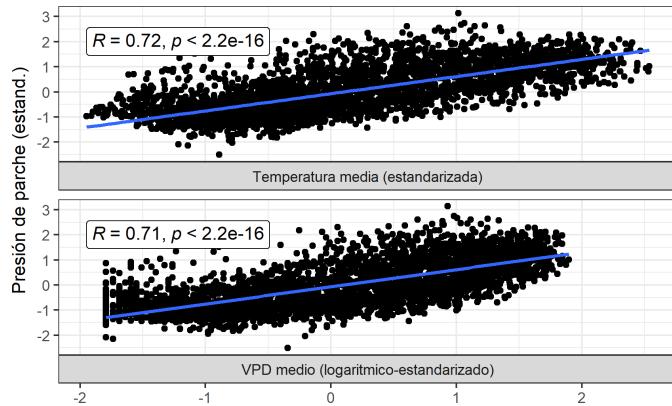


Unidad 2

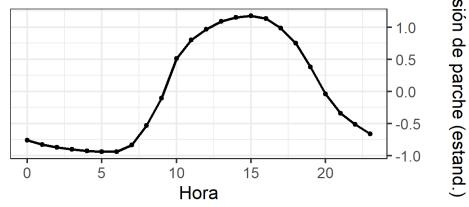
Serie temporal



Correlación con Temperatura y VPD

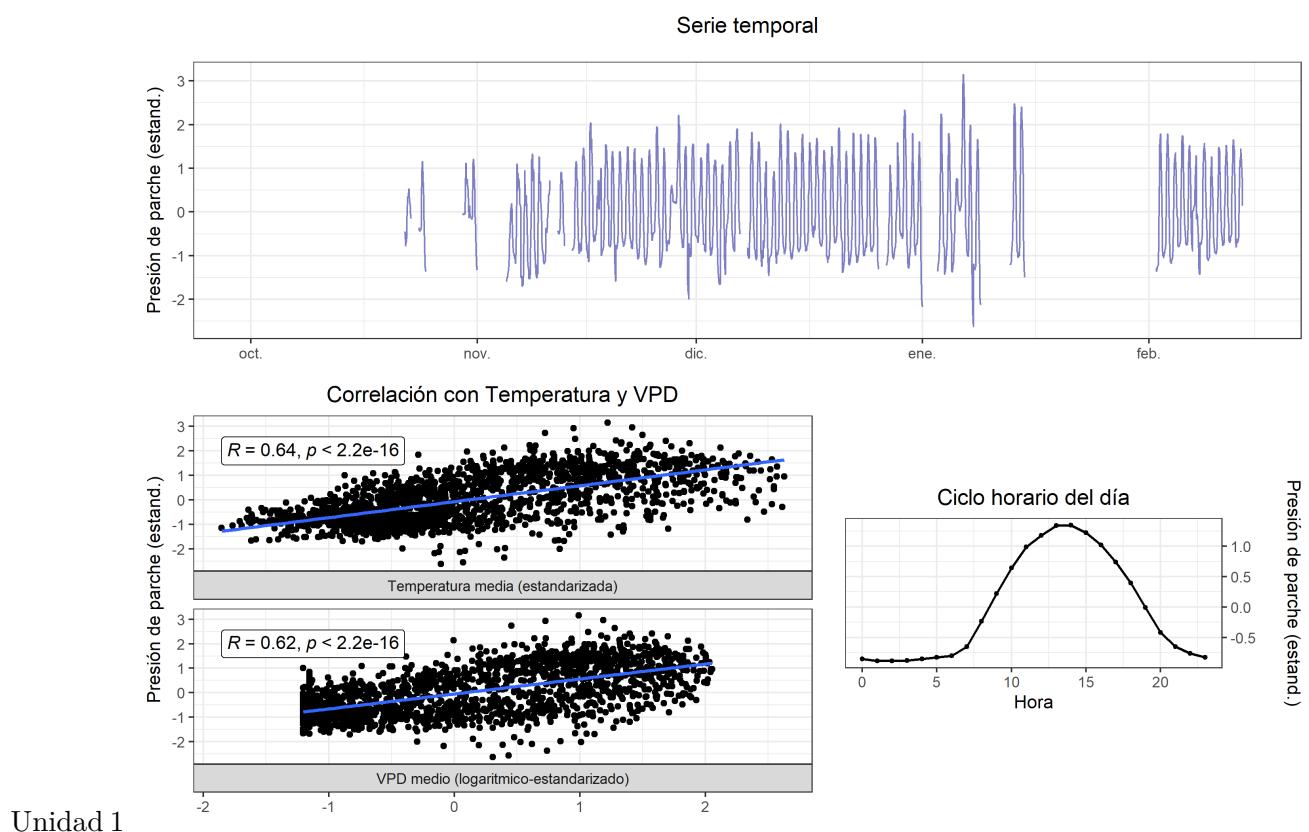


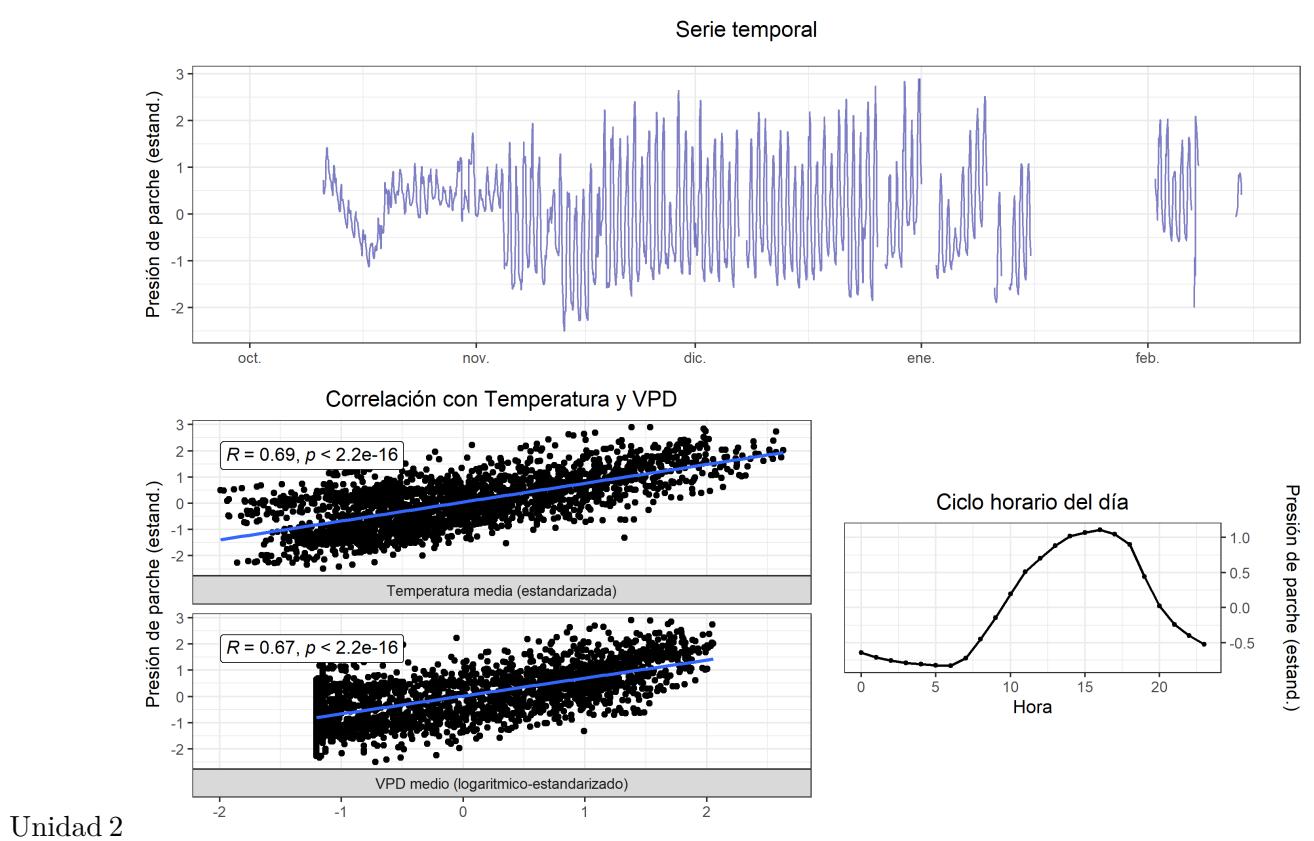
Ciclo horario del día



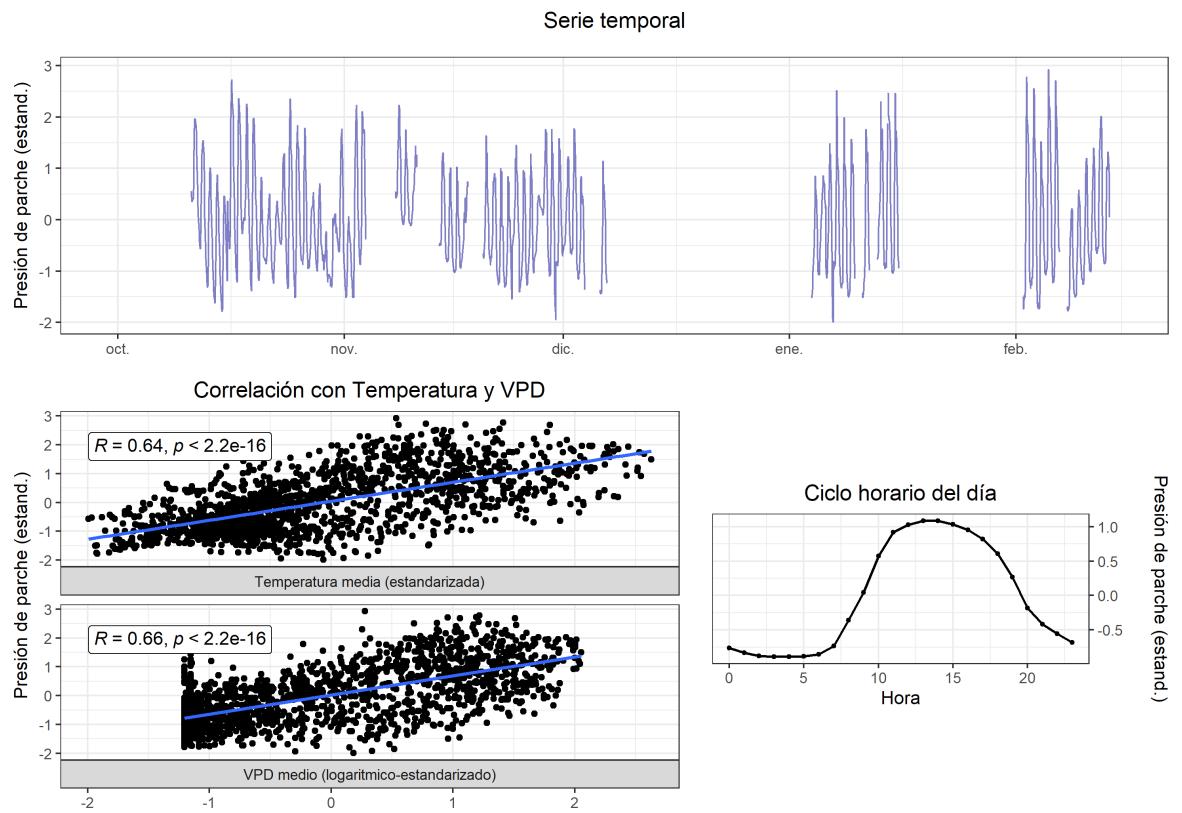
Unidad 3

6.5.0.5 T1 (2023-2024)



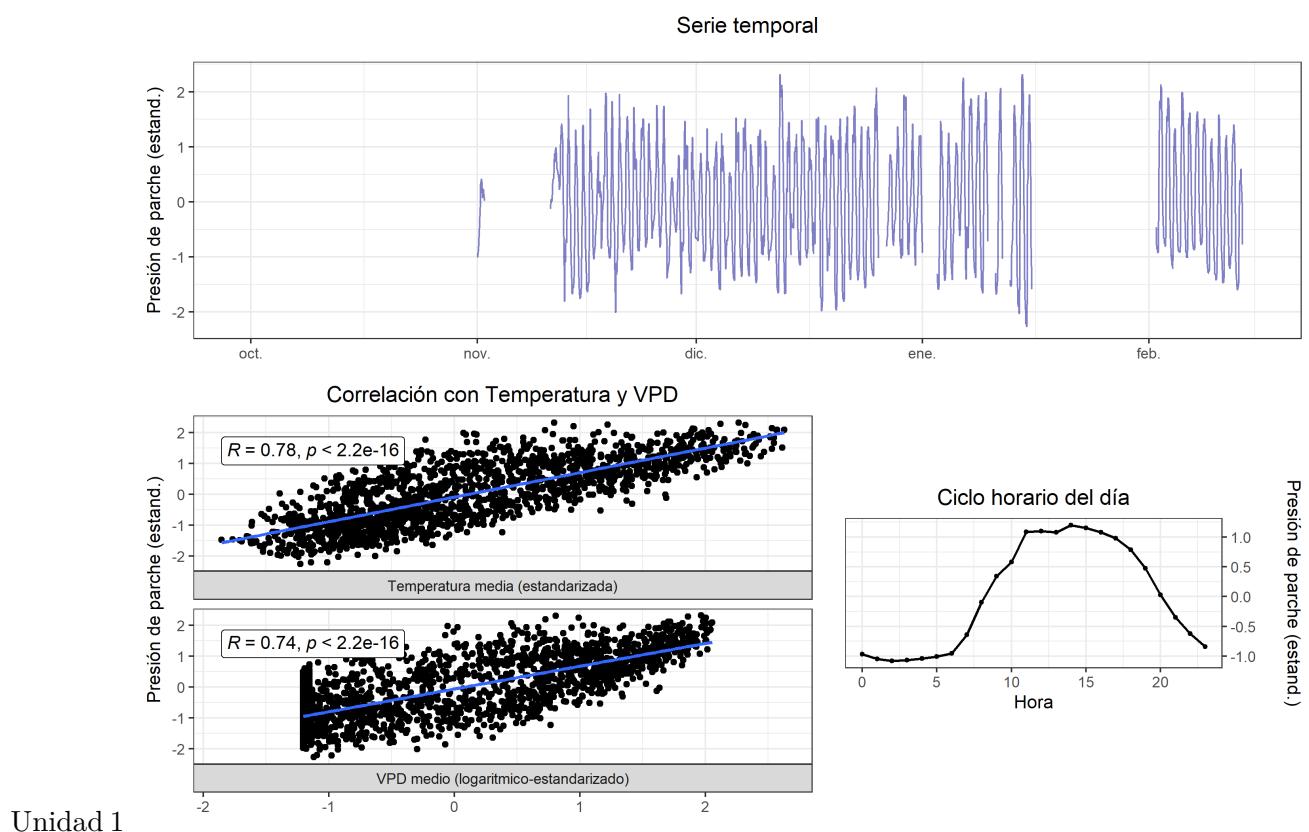


Unidad 2

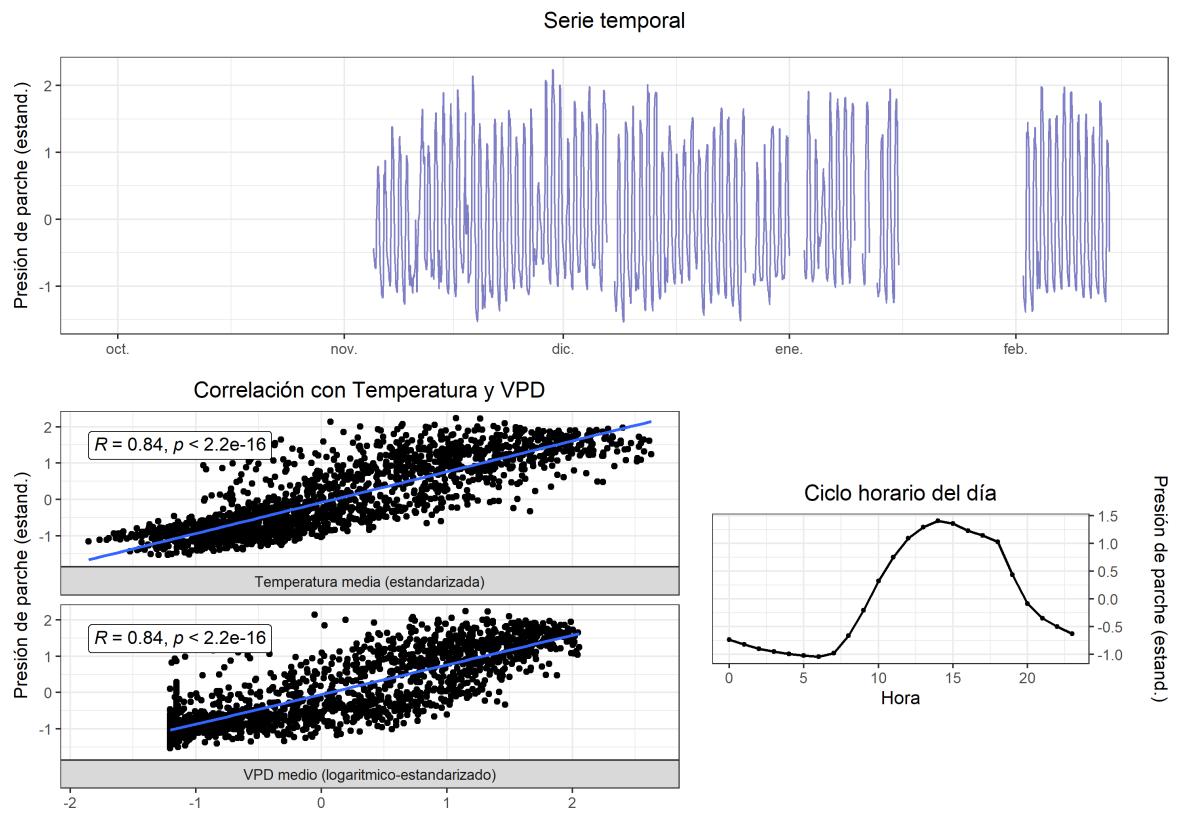


Unidad 3

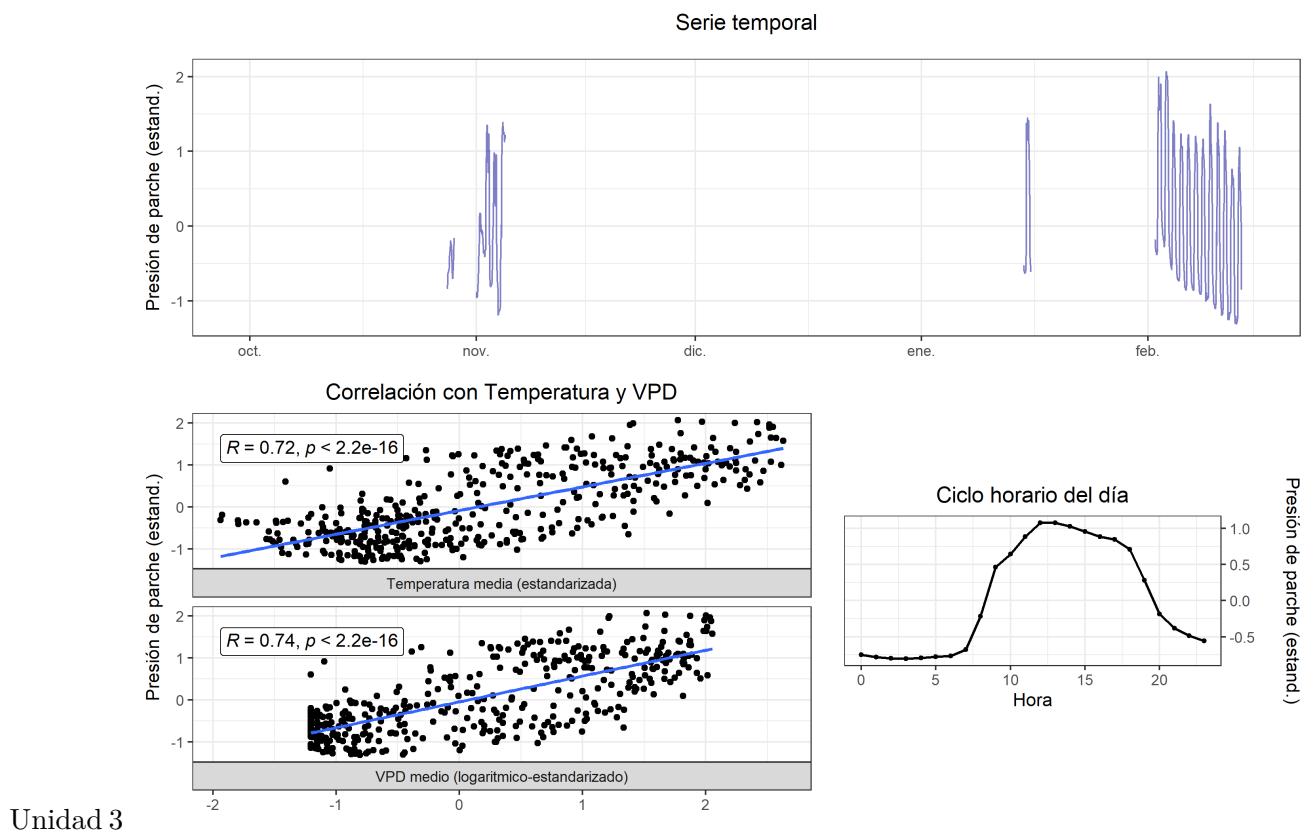
6.5.0.6 T2 (2023-2024)



Unidad 1

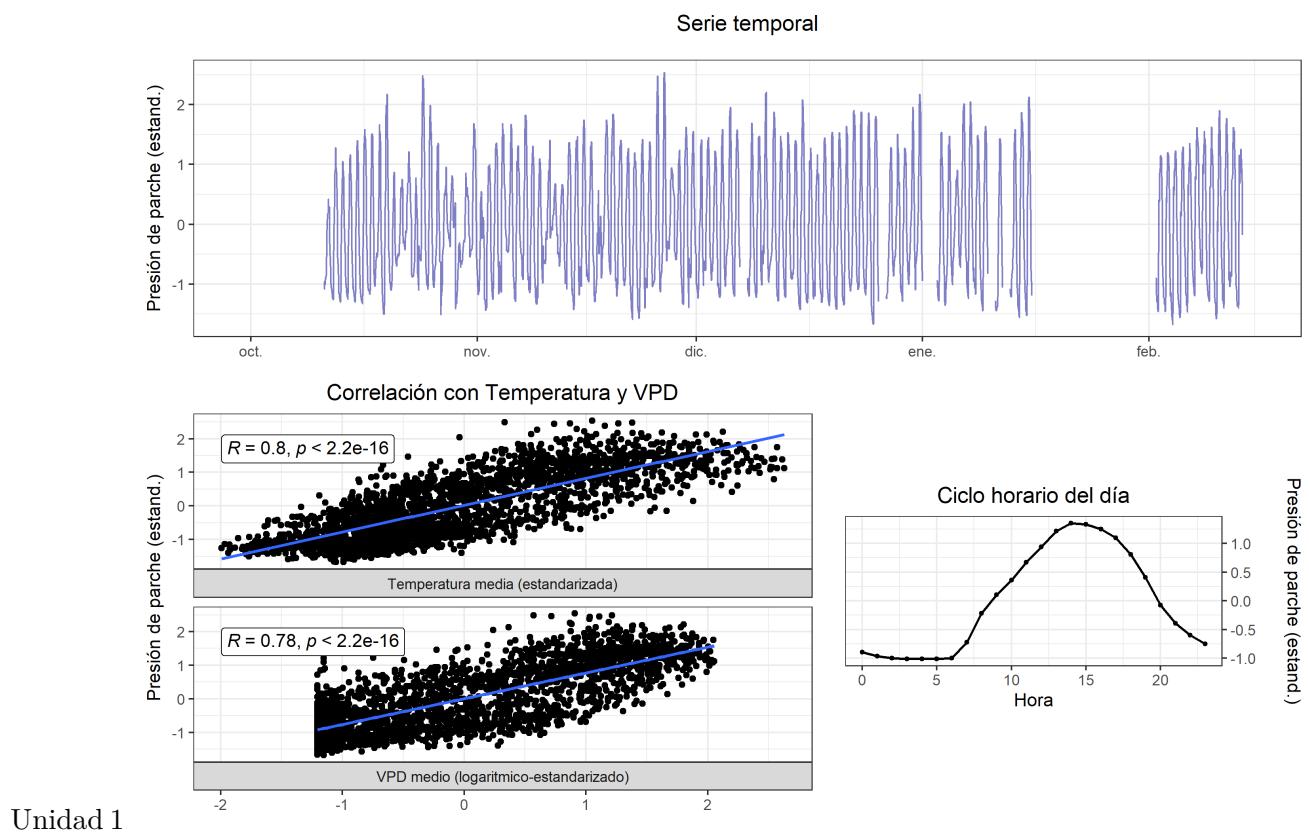


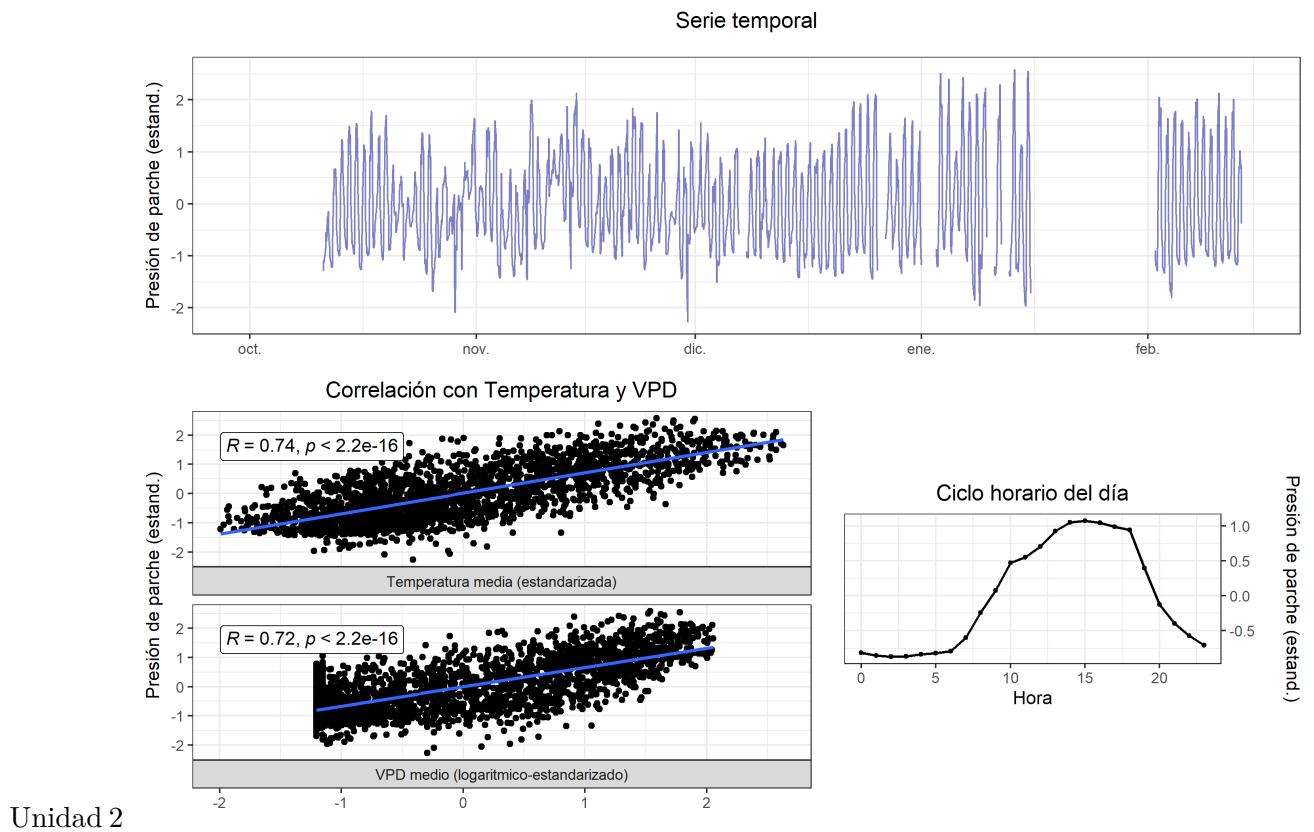
Unidad 2



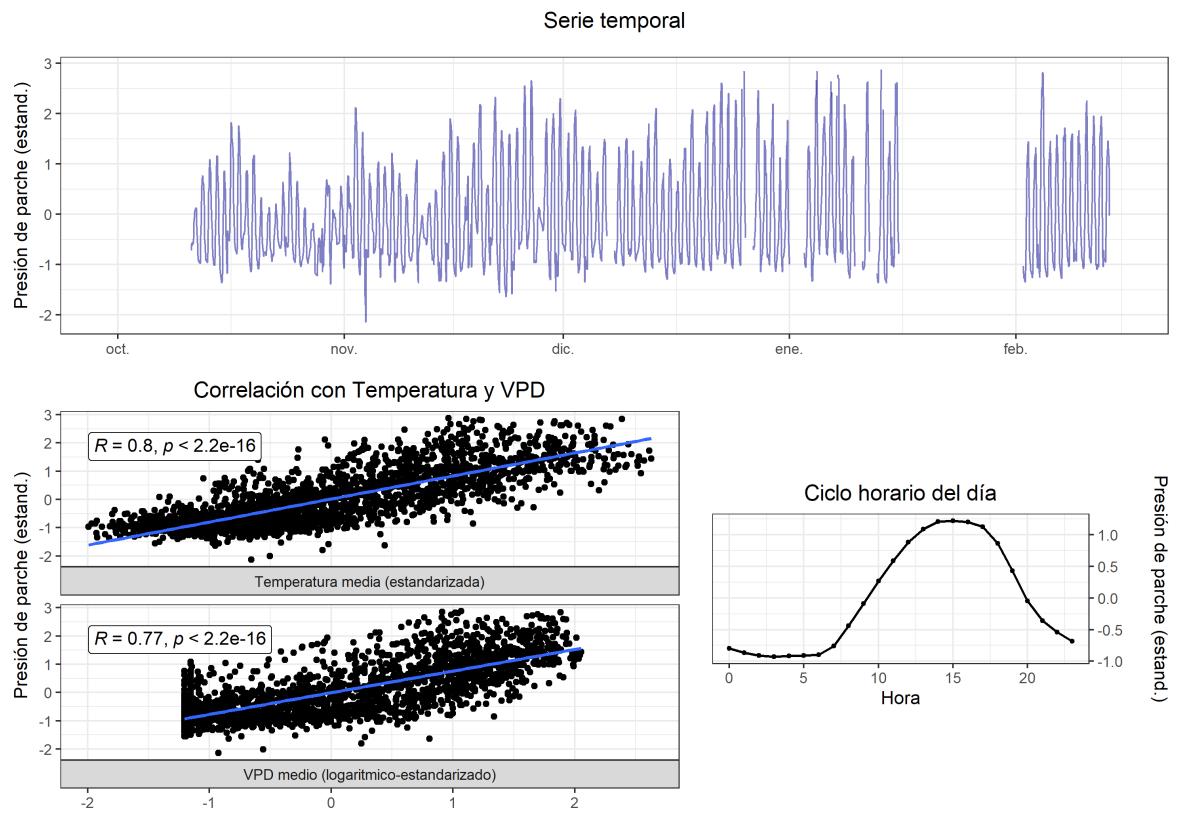
Unidad 3

6.5.0.7 T3 (2023-2024)



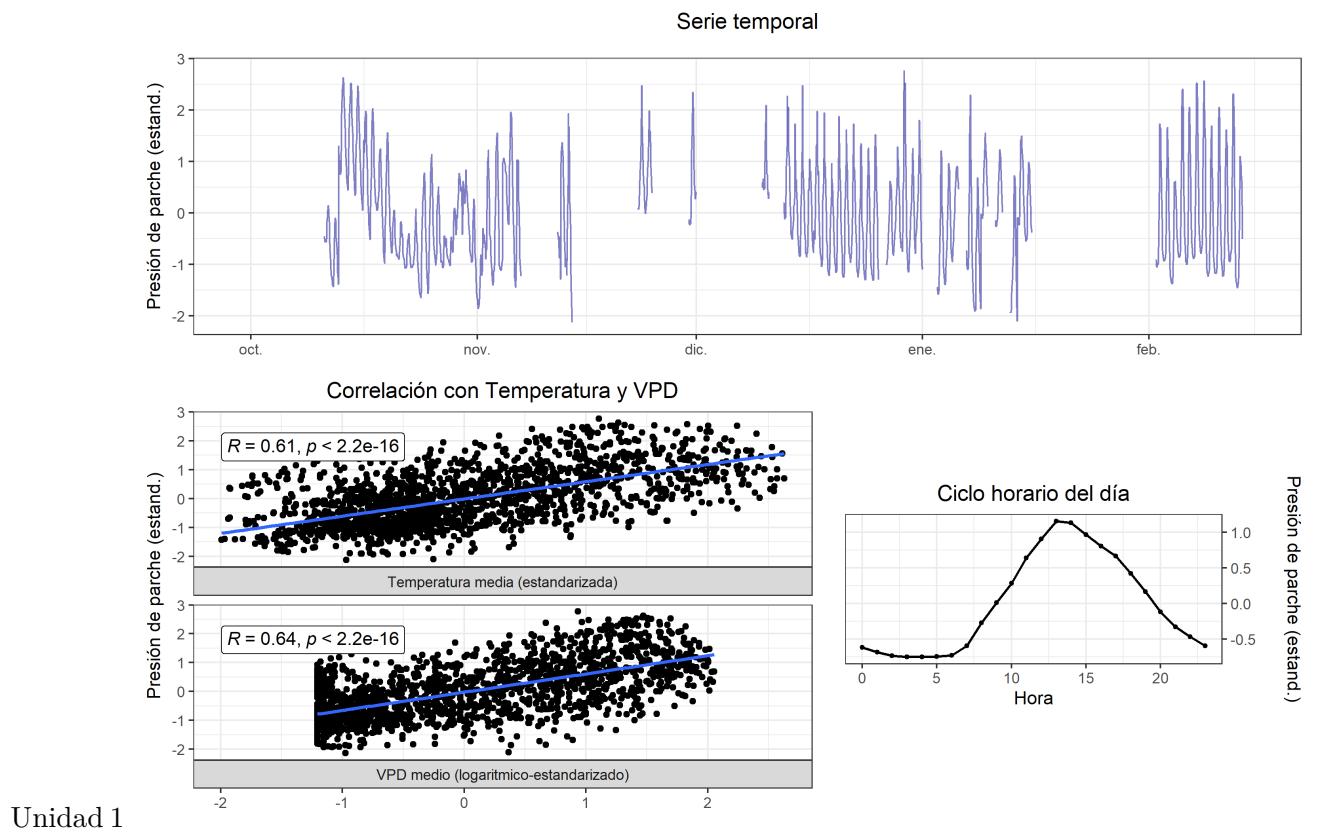


Unidad 2

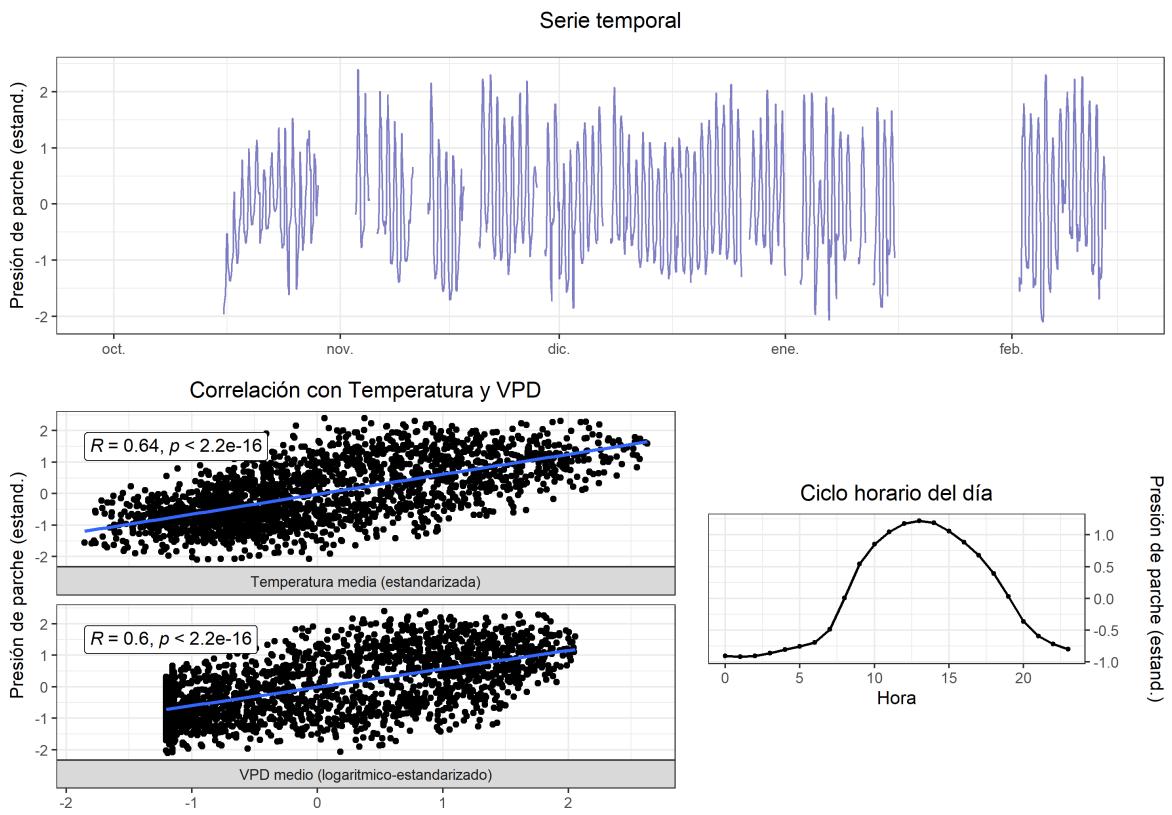


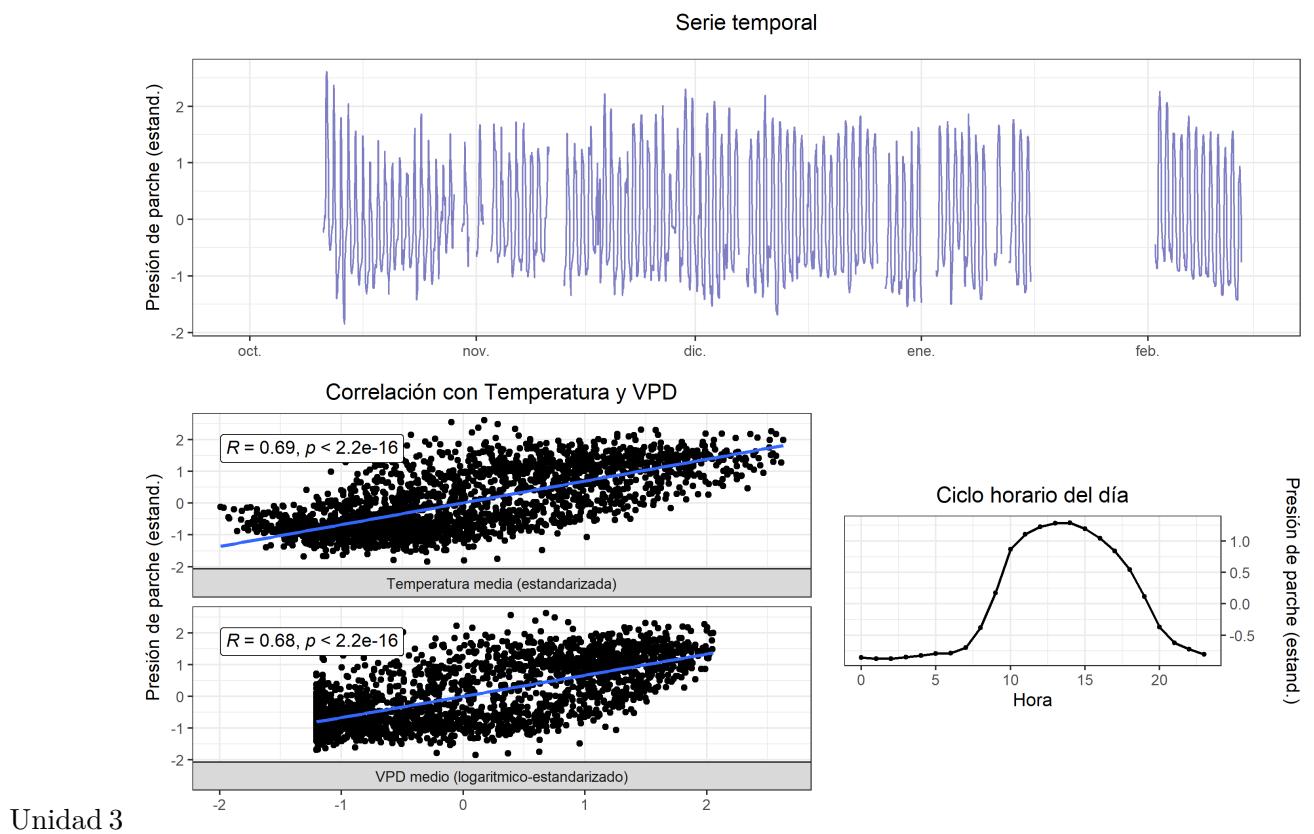
Unidad 3

6.5.0.8 T4 (2023-2024)



Unidad 2

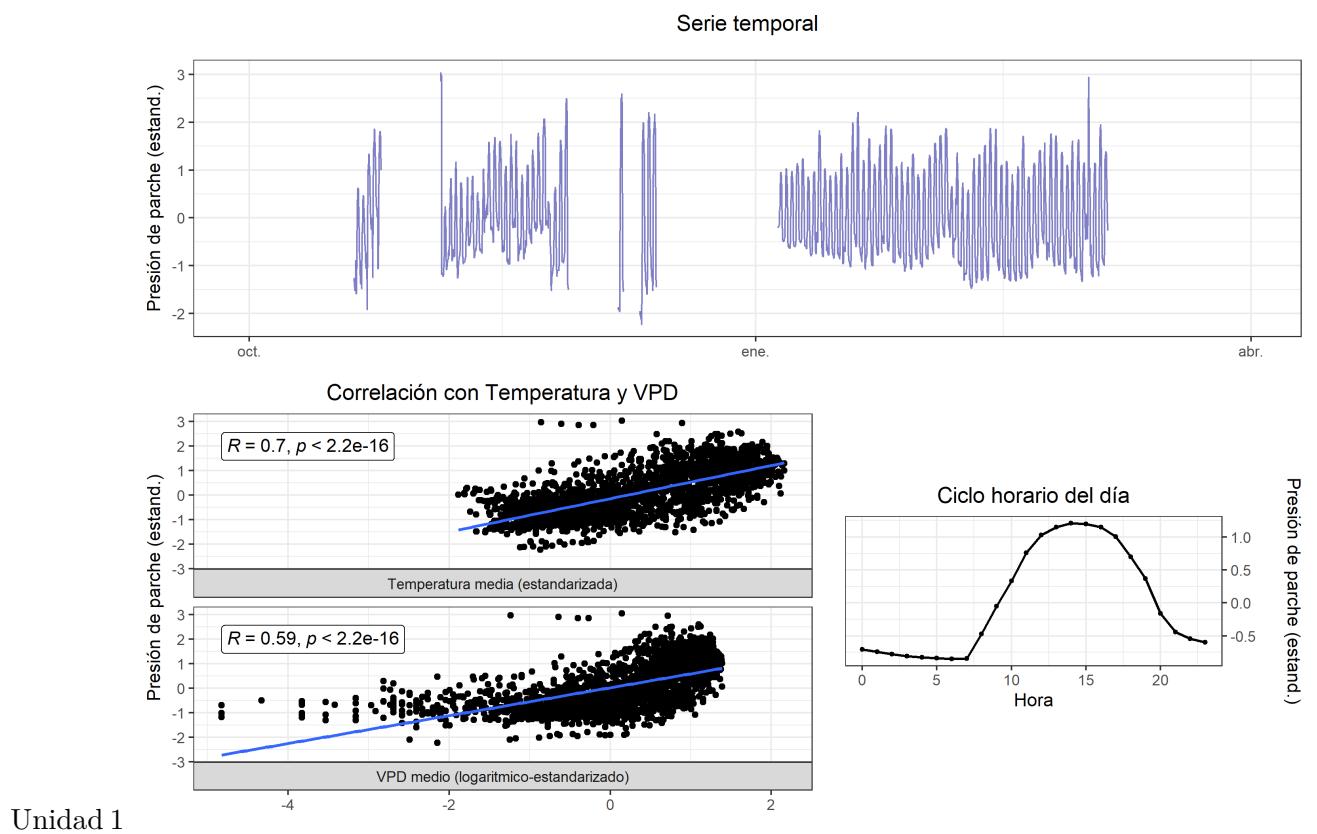


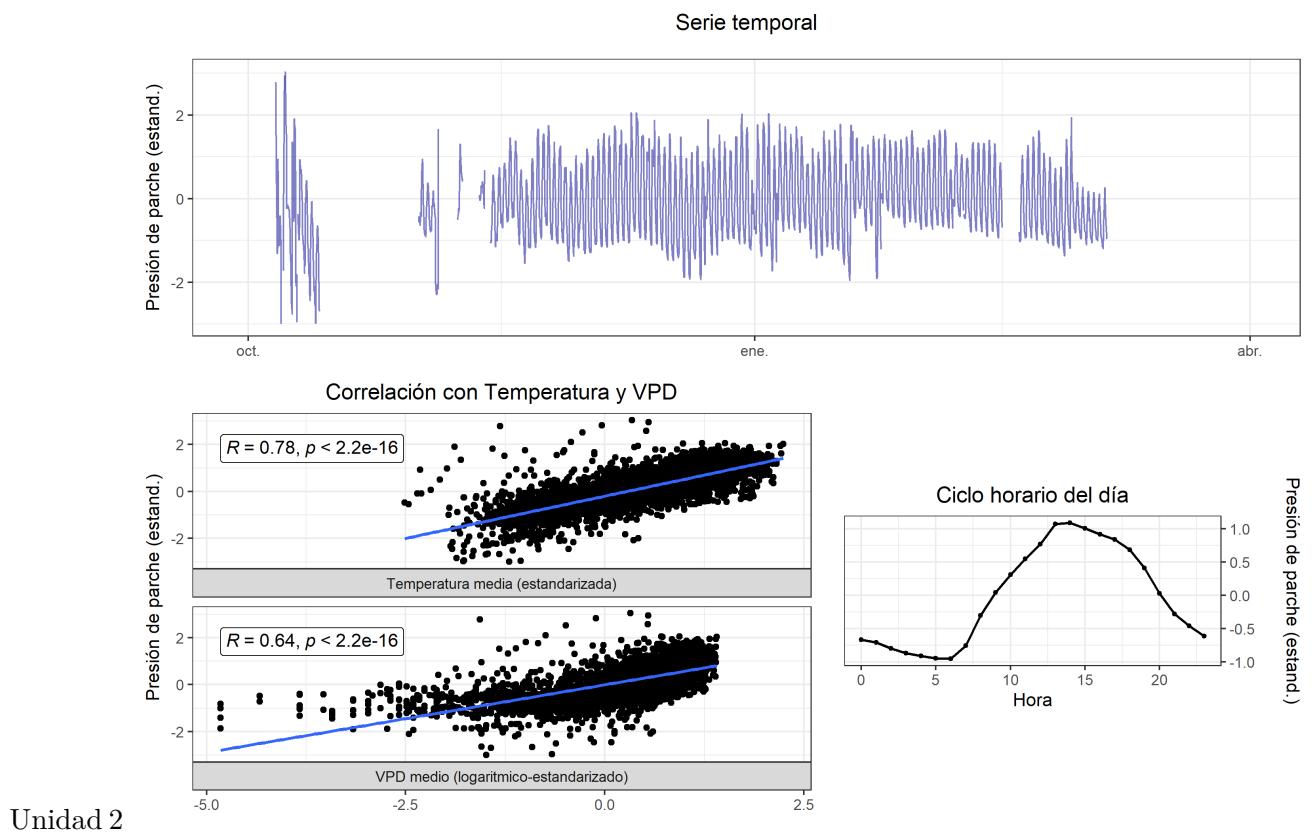


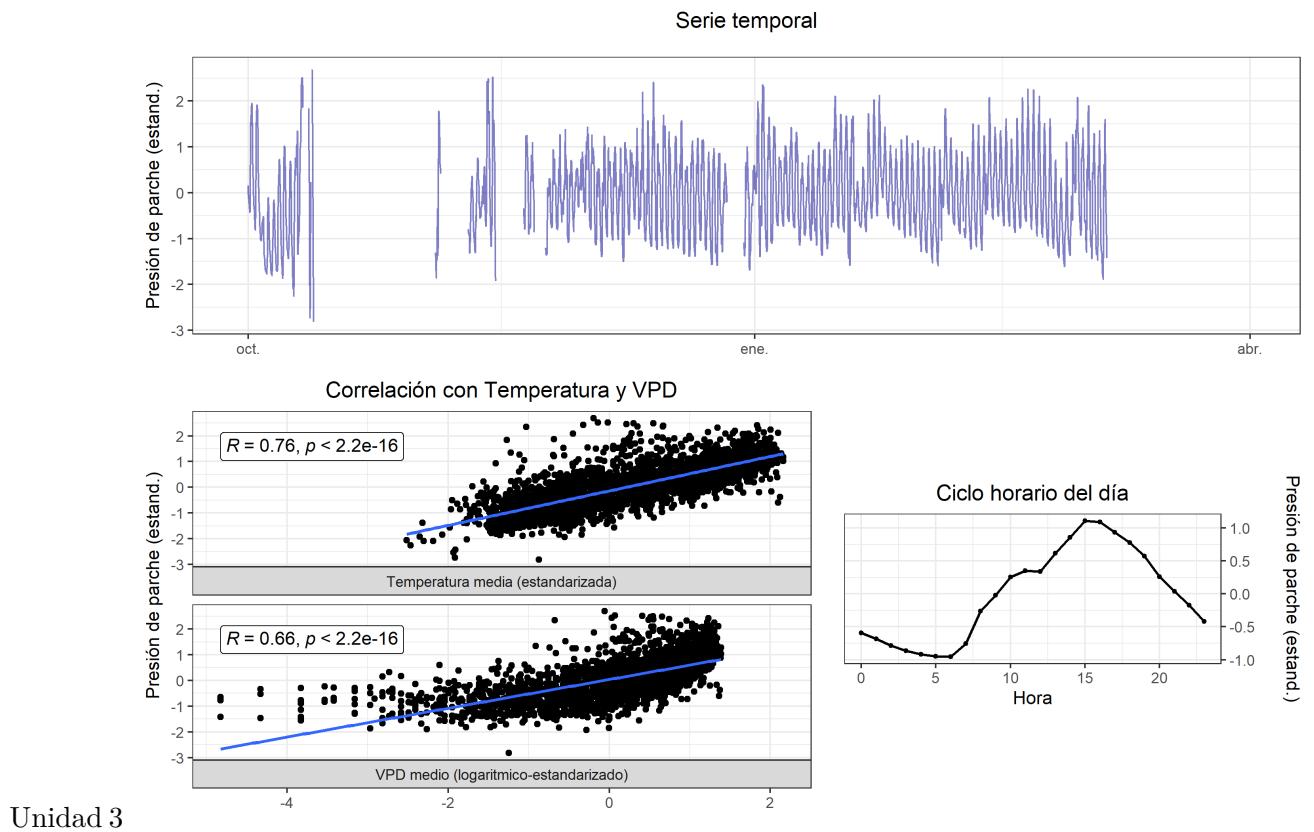
Unidad 3

6.5.0.8.1 * Rio Claro

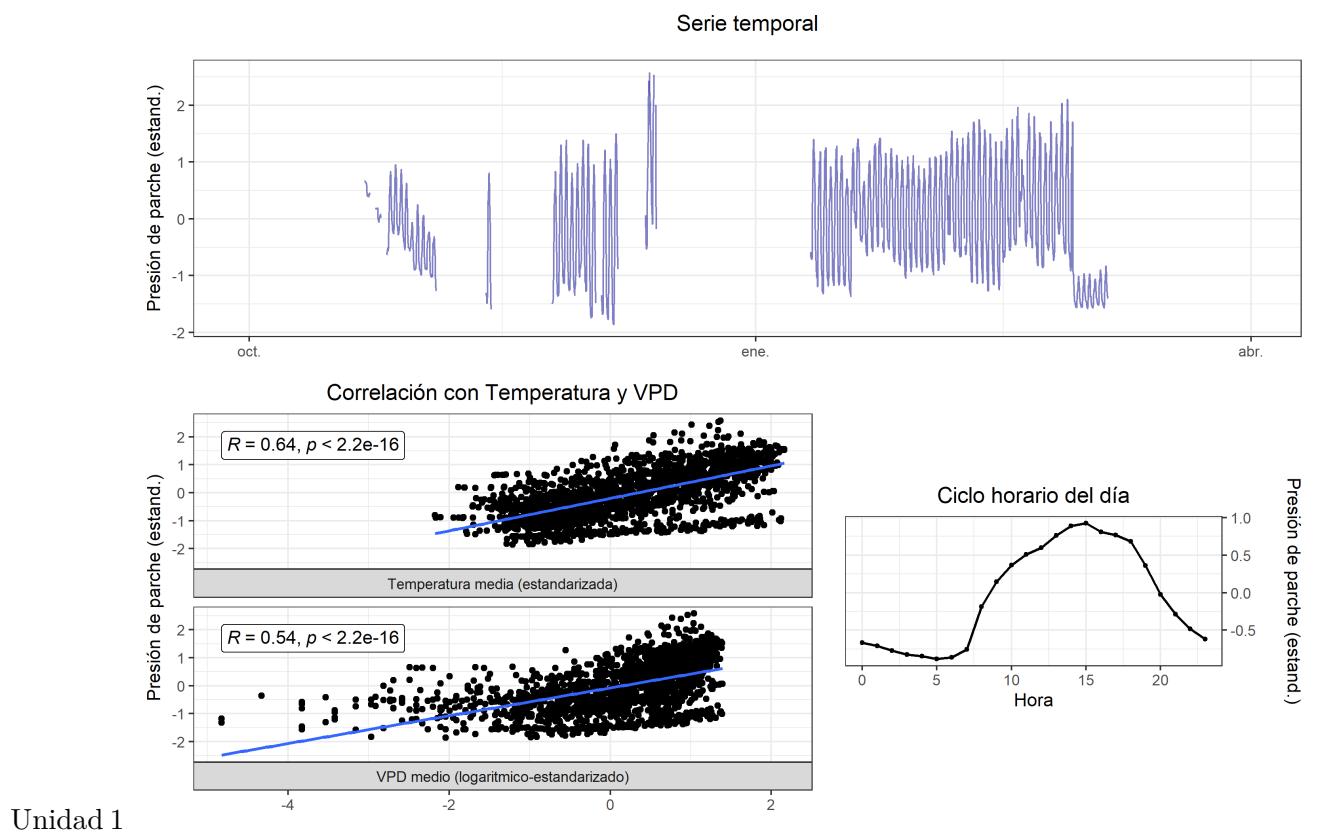
6.5.0.9 T1 (2022-2023)



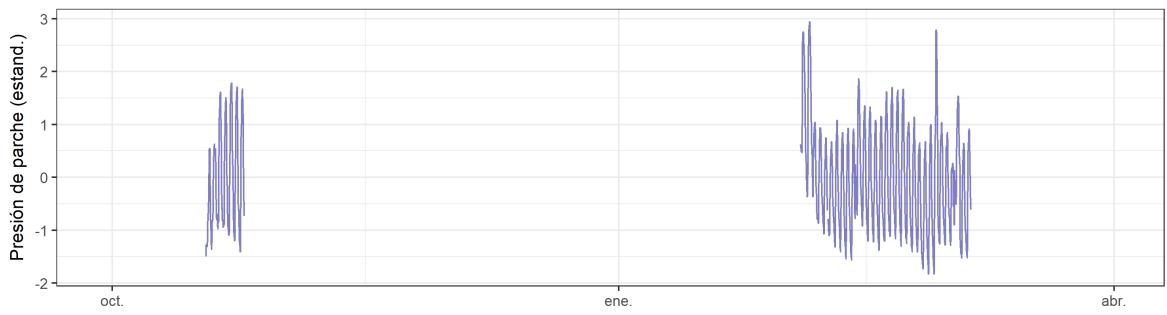




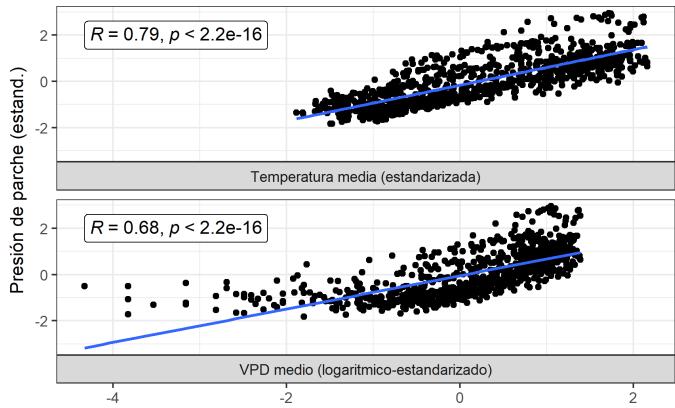
6.5.0.10 T2 (2022-2023)



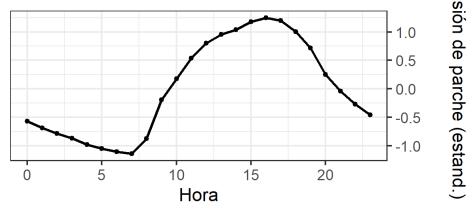
Serie temporal



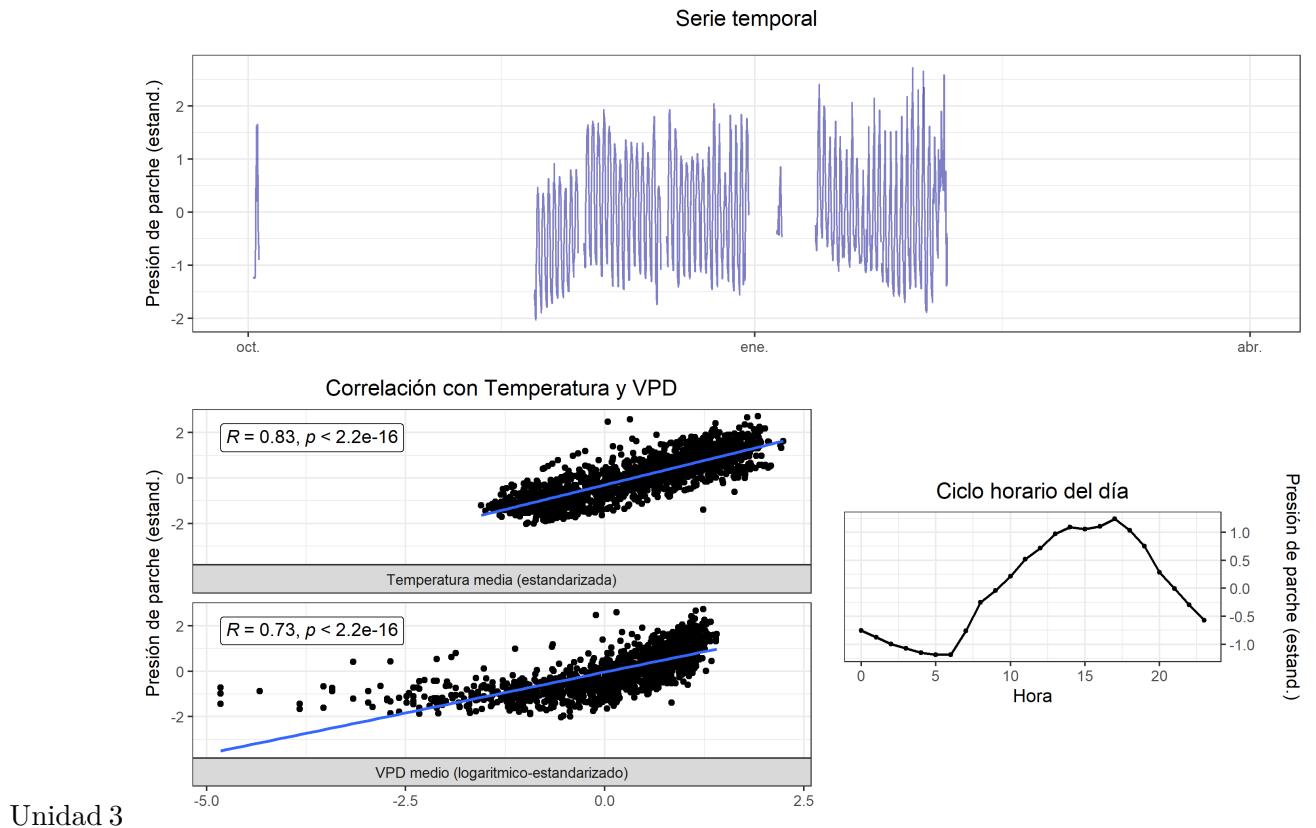
Correlación con Temperatura y VPD



Ciclo horario del día

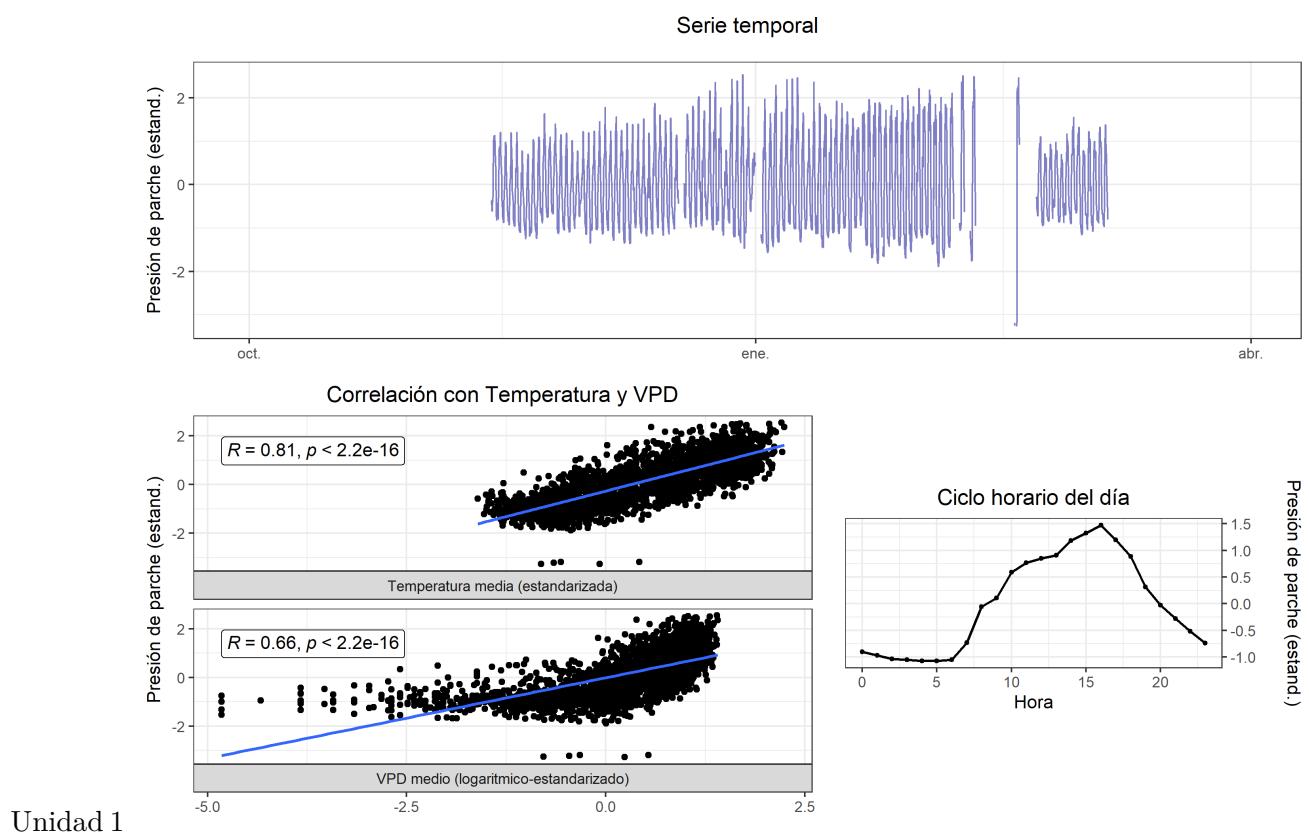


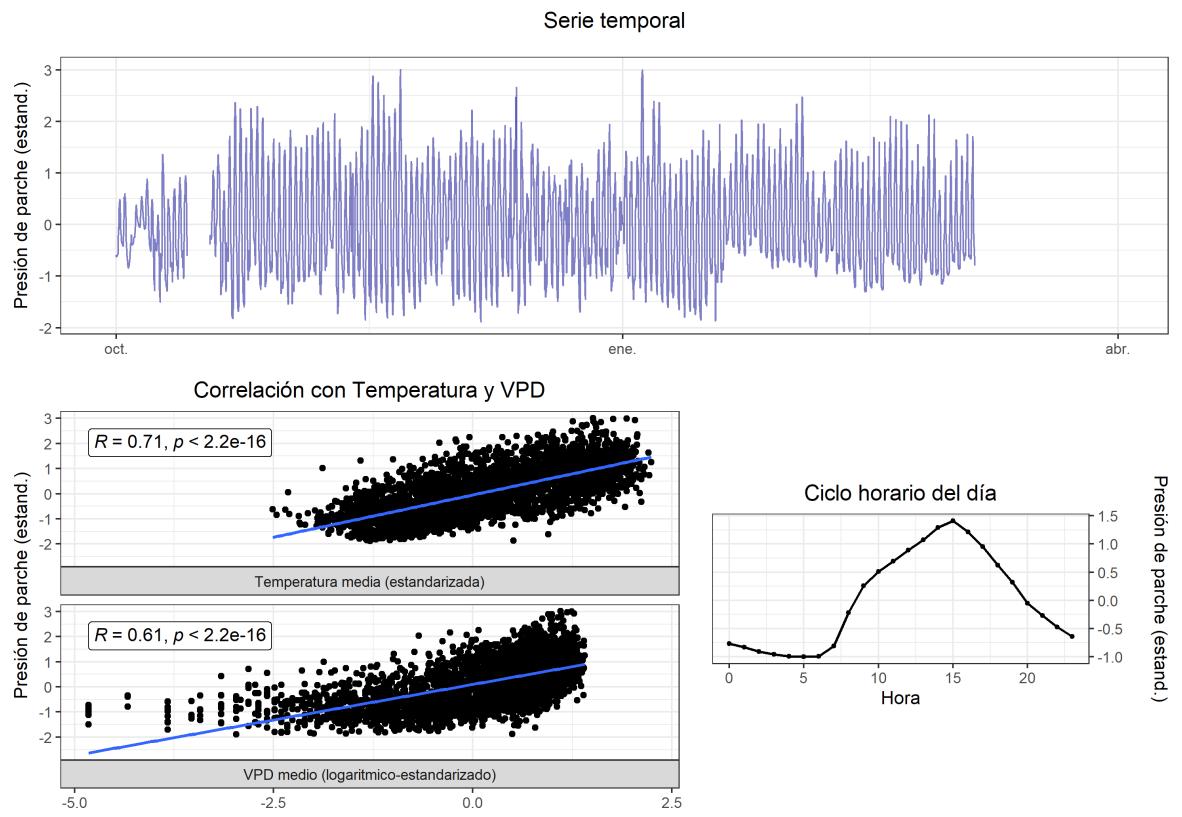
Unidad 2

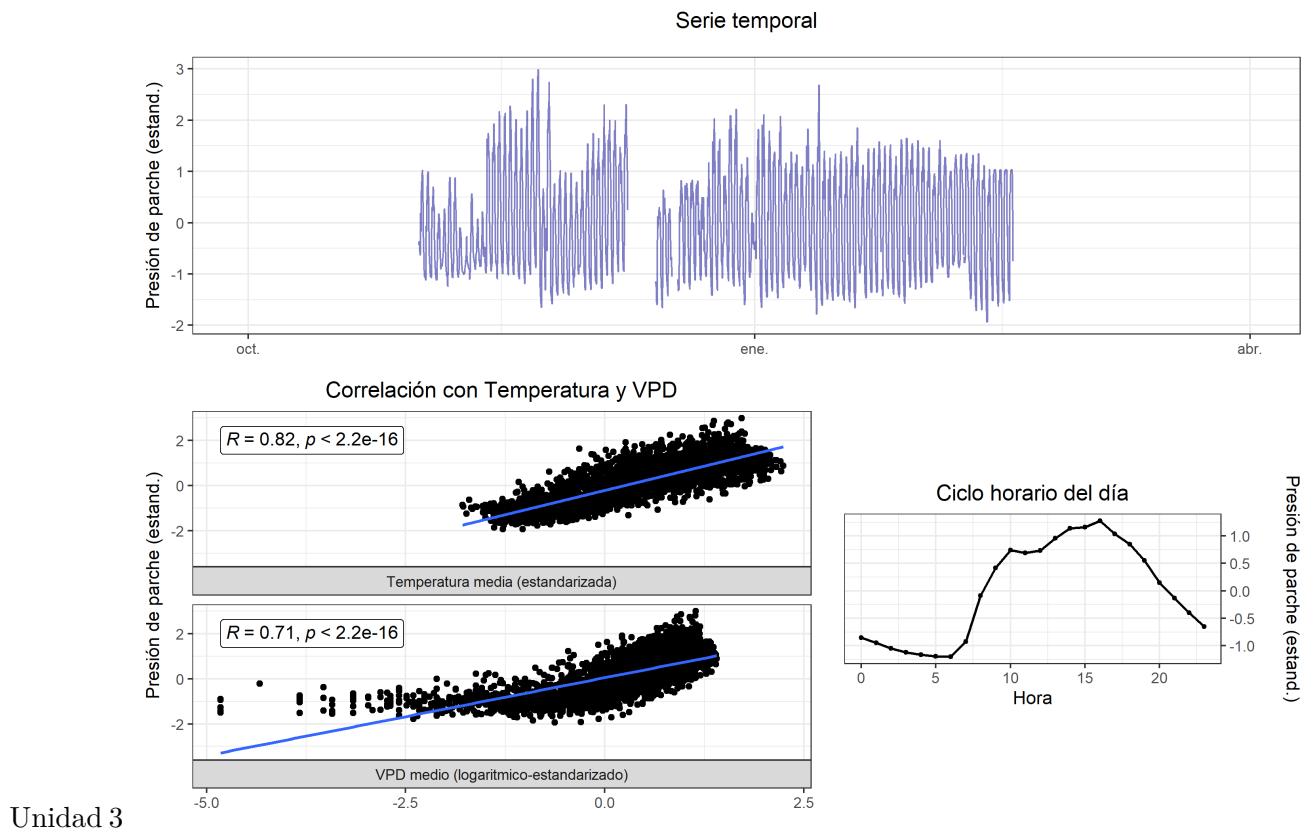


Unidad 3

6.5.0.11 T3 (2022-2023)

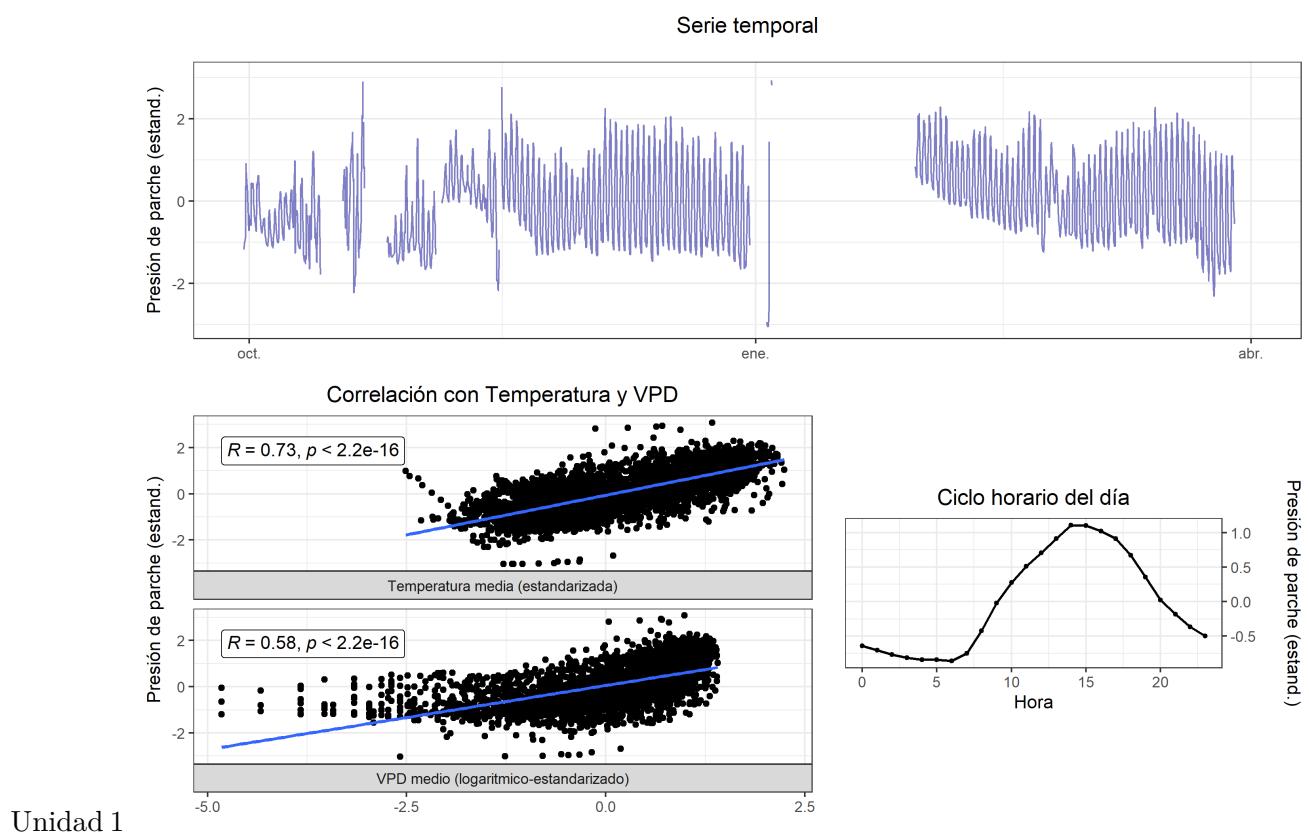


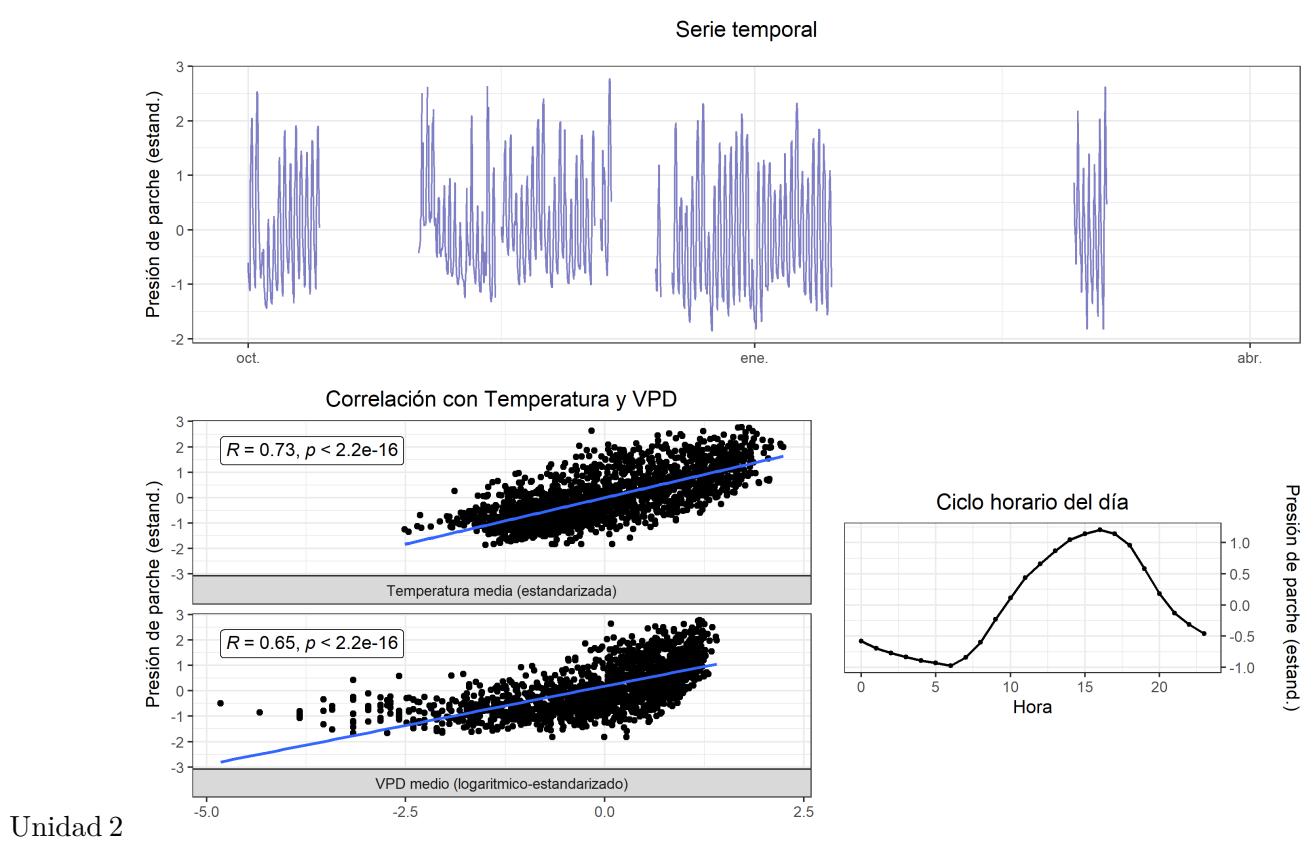


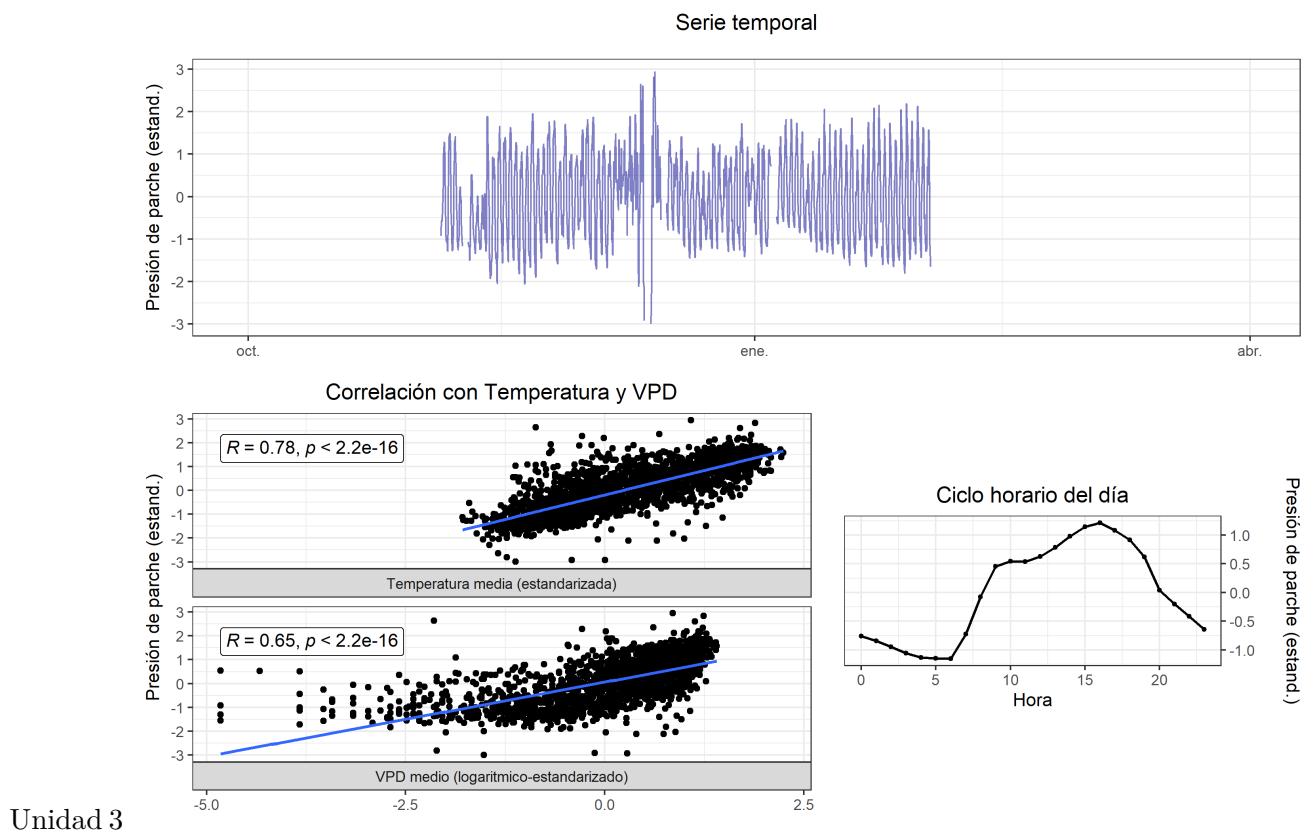


Unidad 3

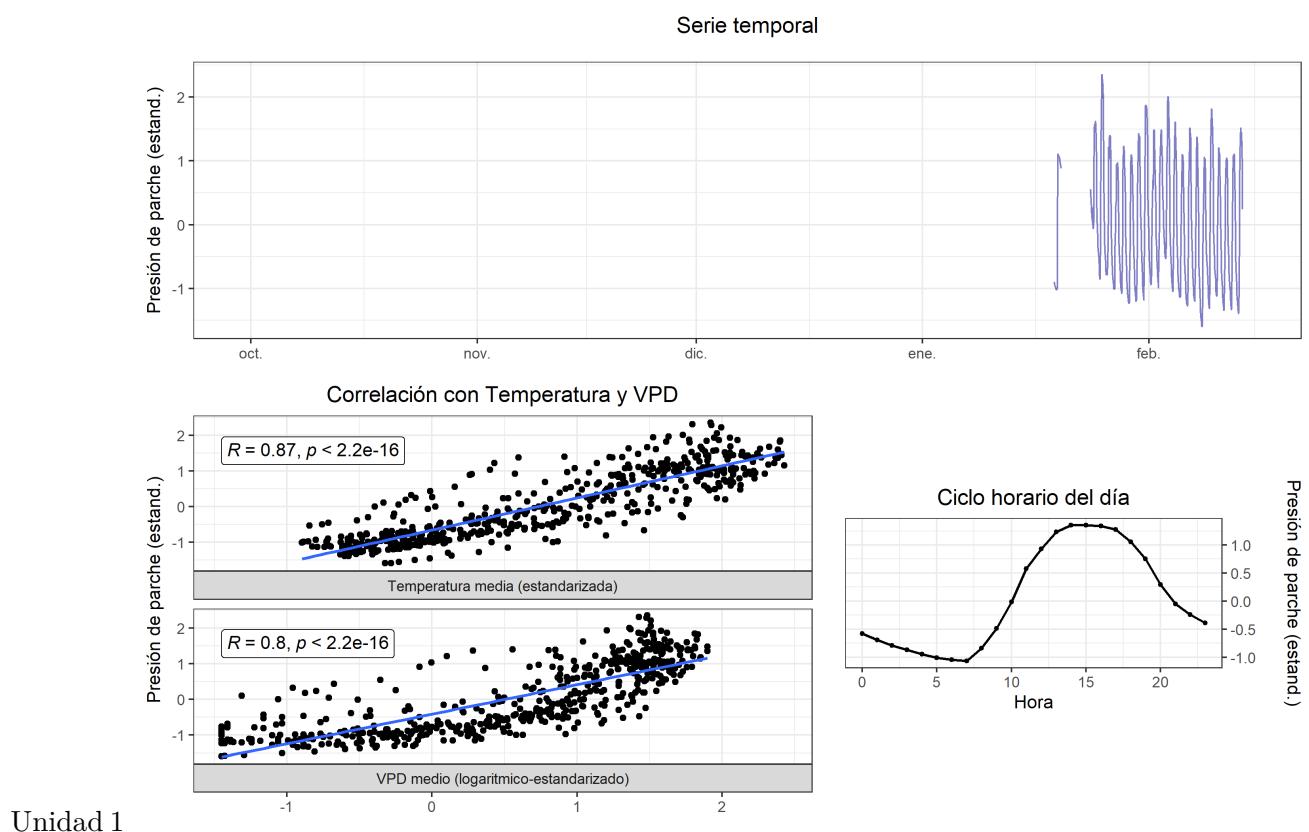
6.5.0.12 T4 (2022-2023)



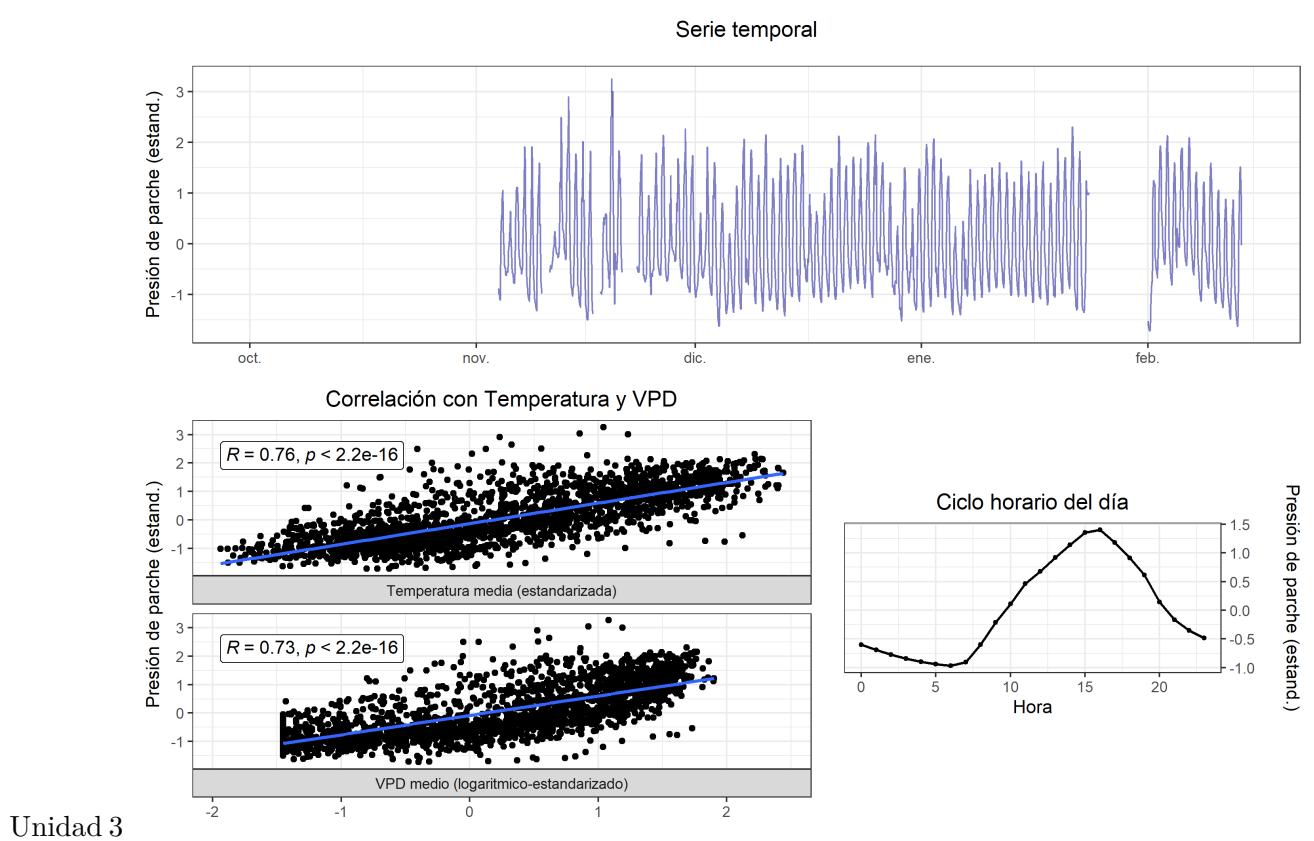




6.5.0.13 T1 (2023-2024)

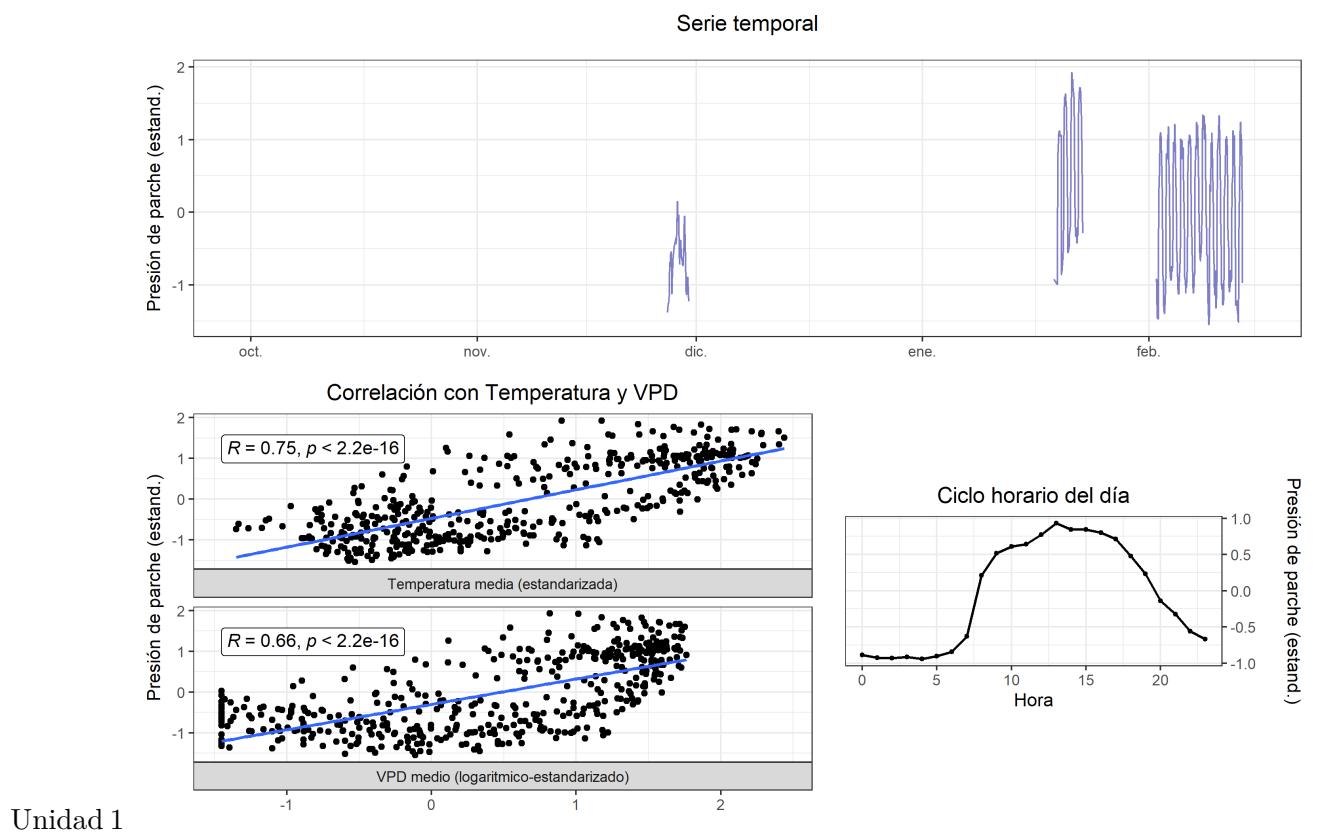


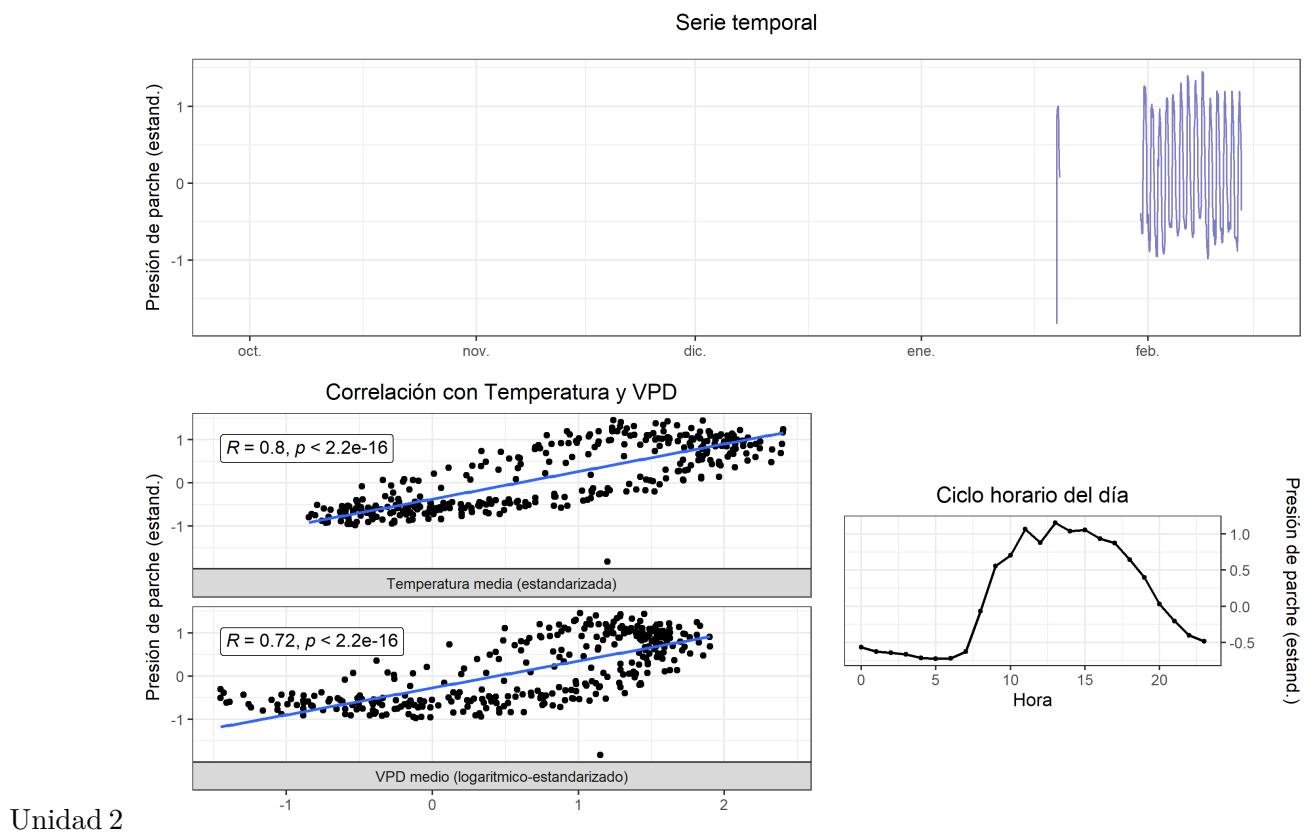
Unidad 1

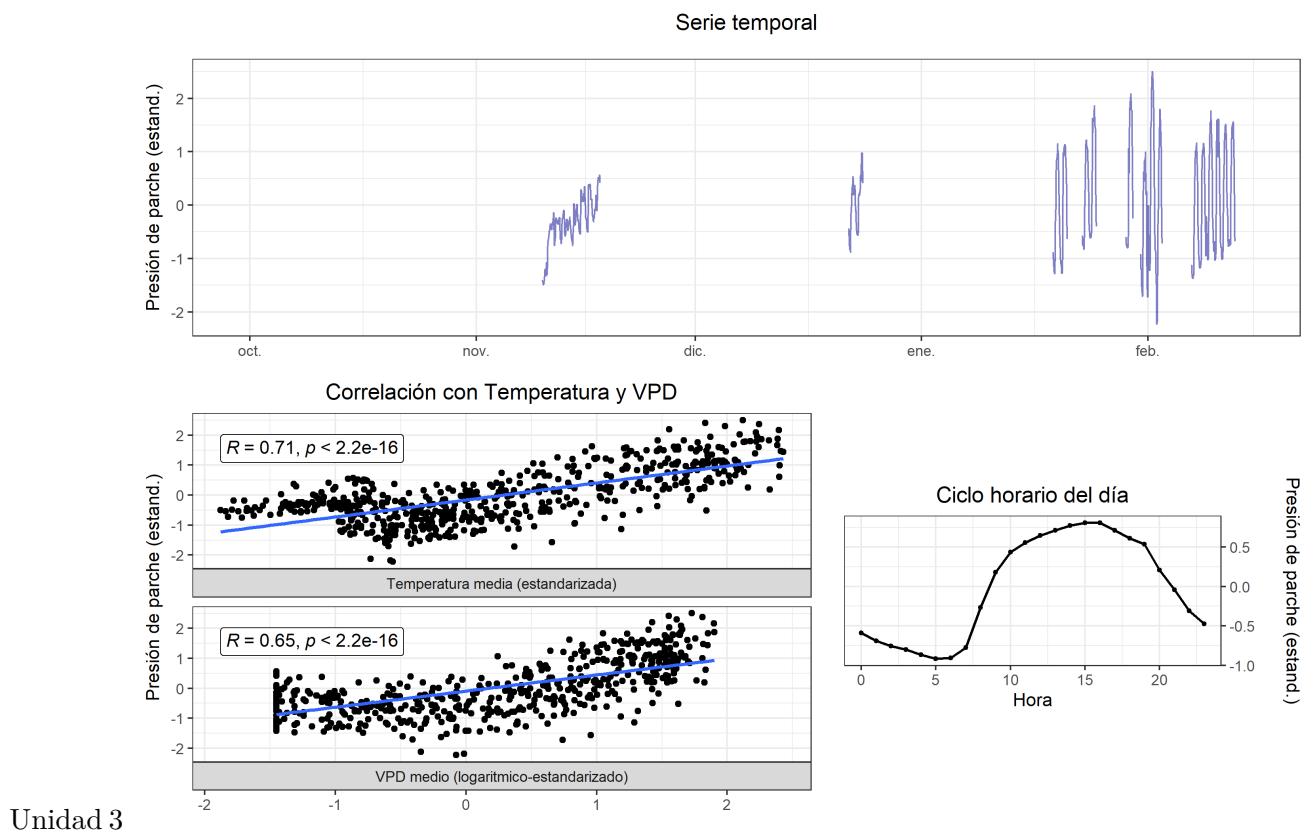


Unidad 3

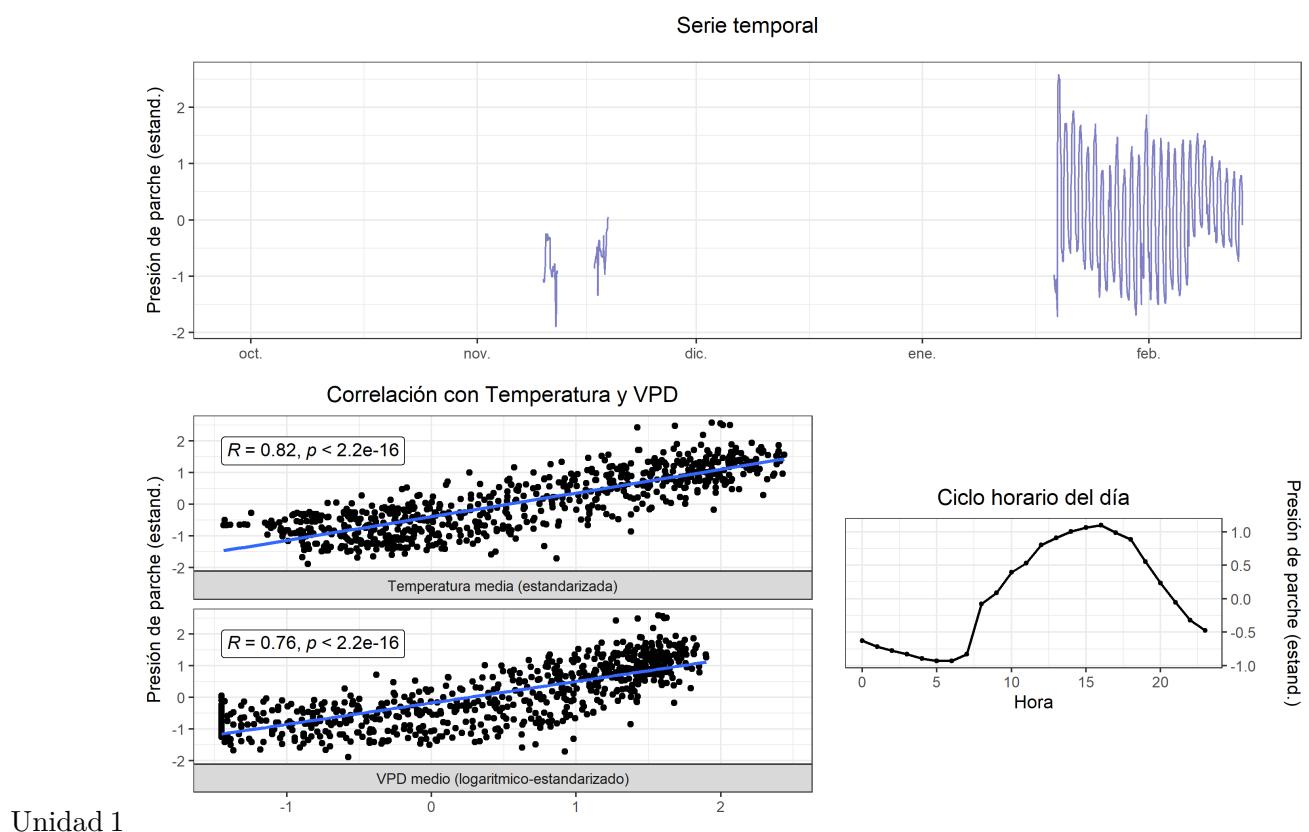
6.5.0.14 T2 (2023-2024)

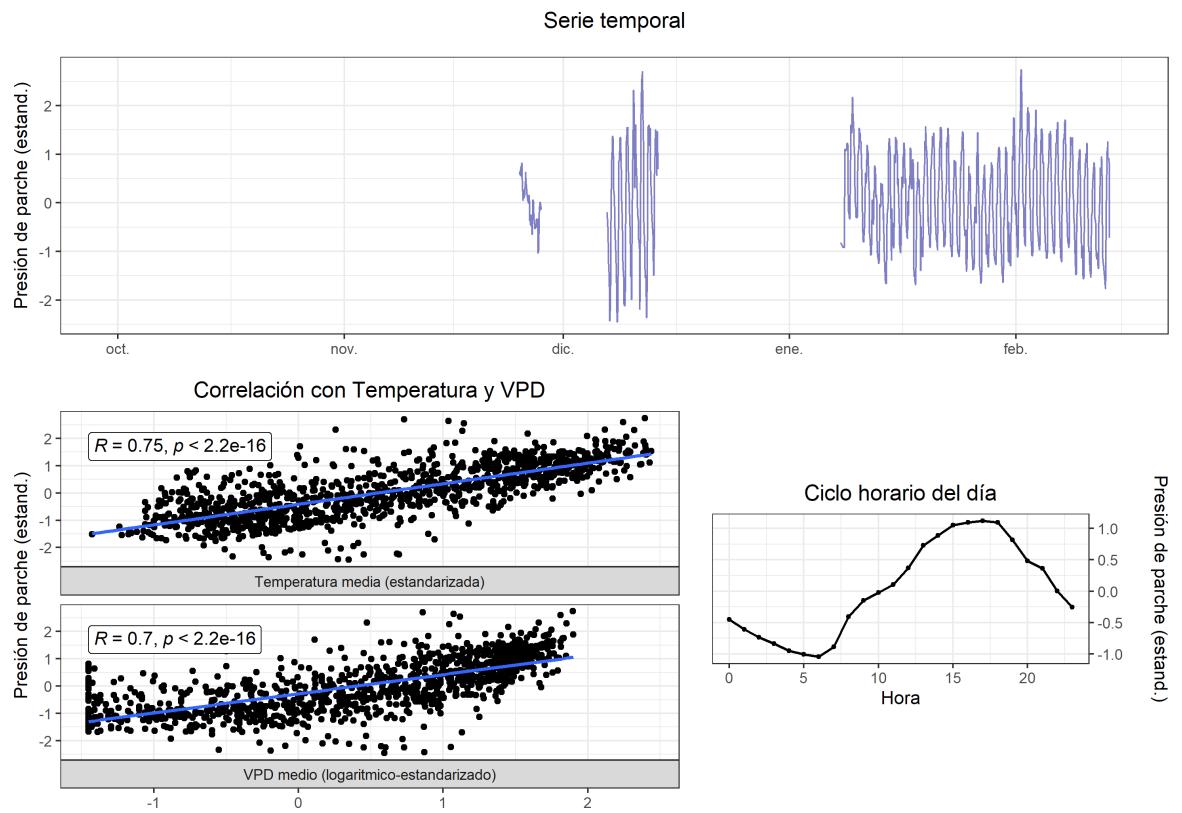




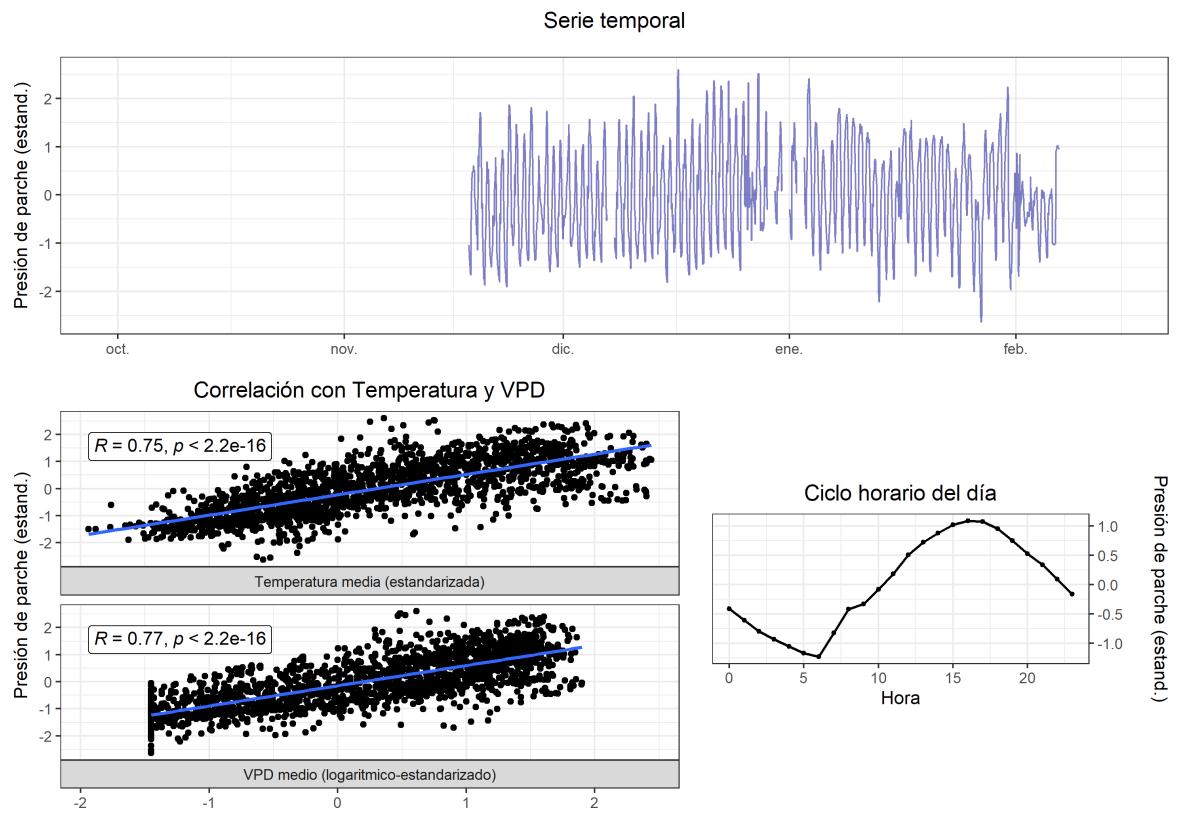


6.5.0.15 T3 (2023-2024)



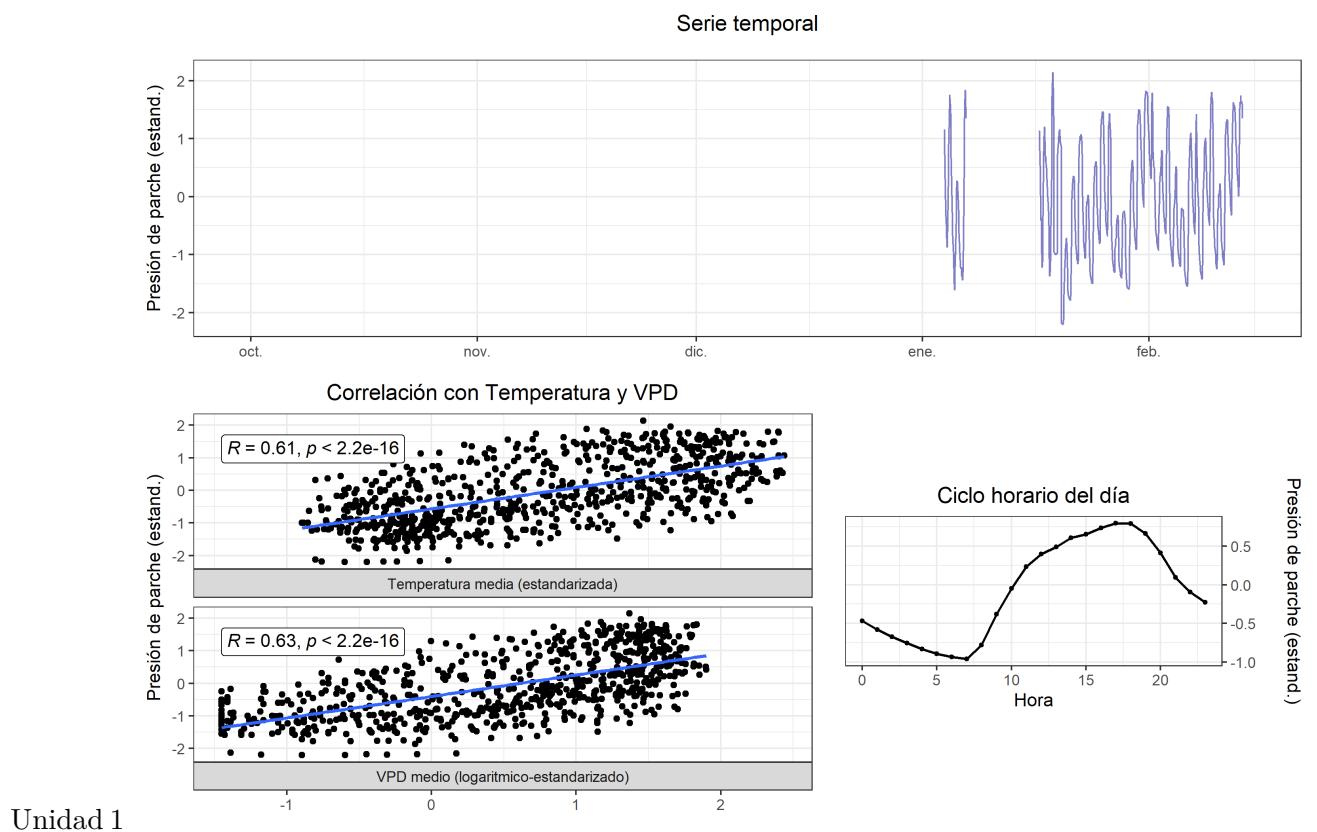


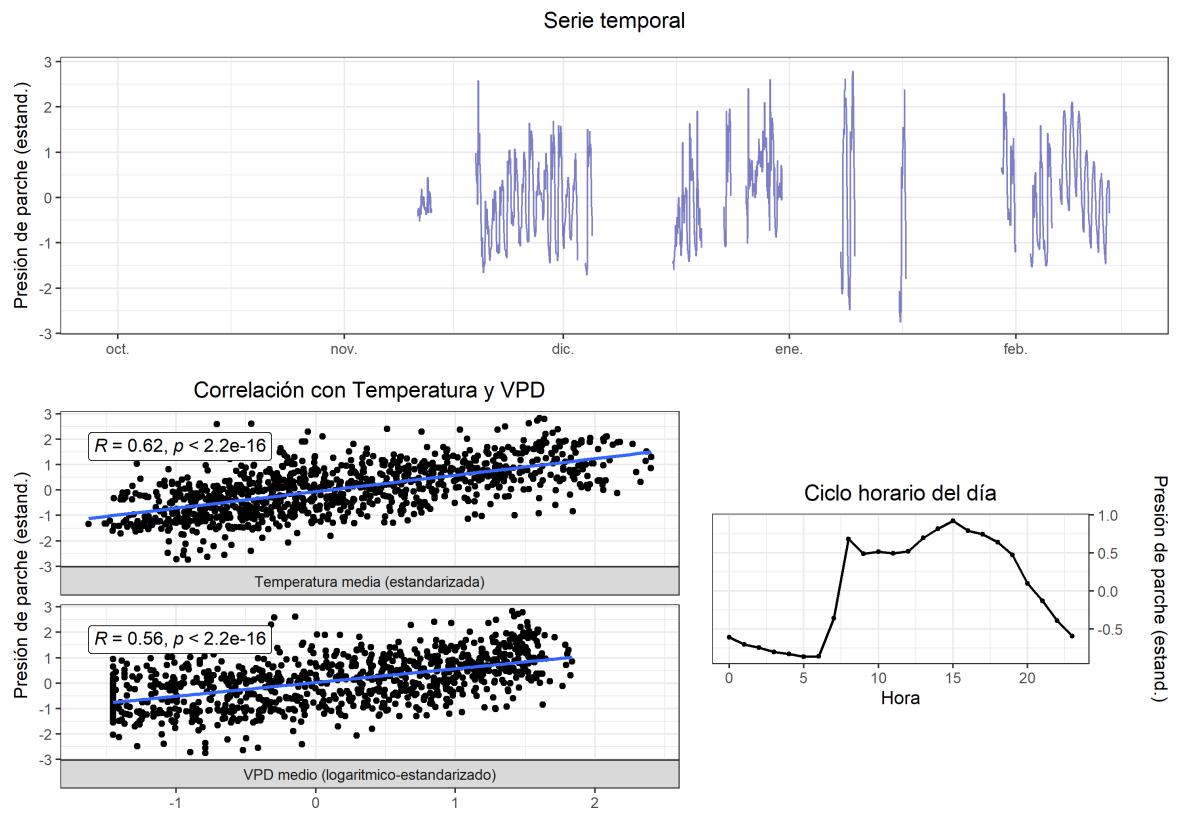
Unidad 2



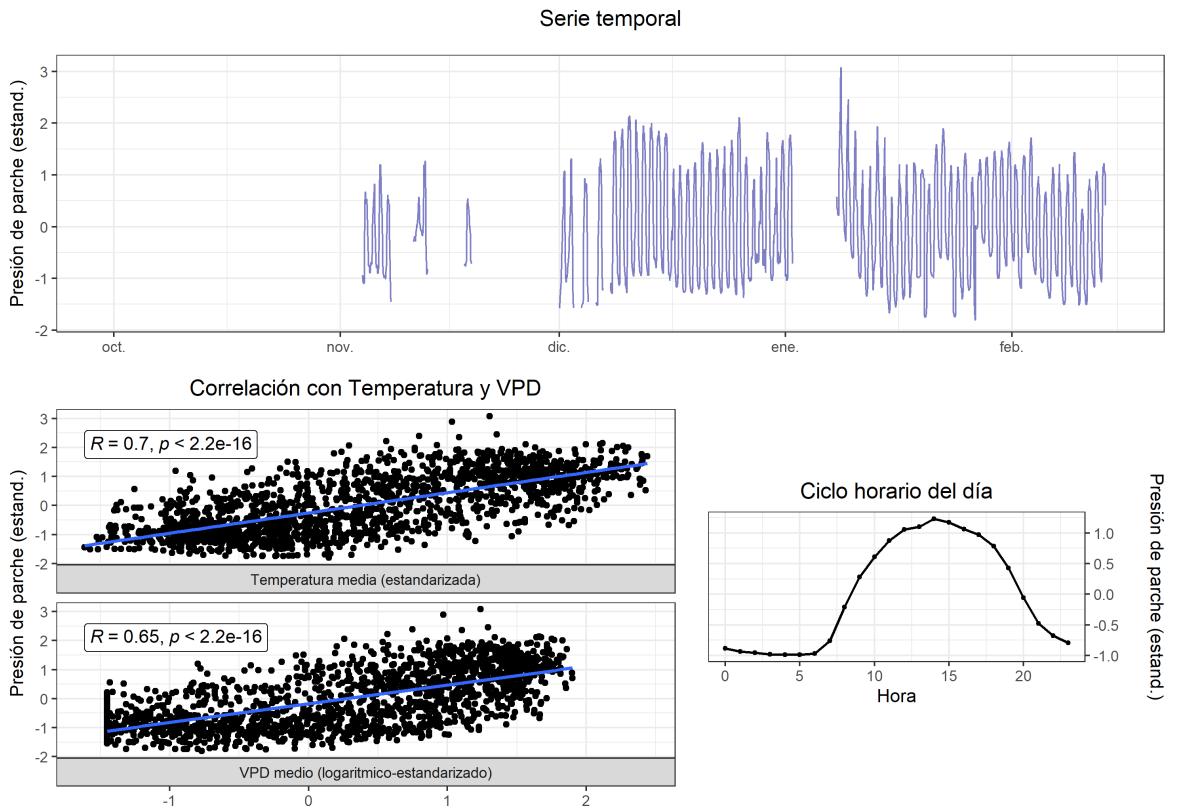
Unidad 3

6.5.0.16 T4 (2023-2024)





Unidad 2

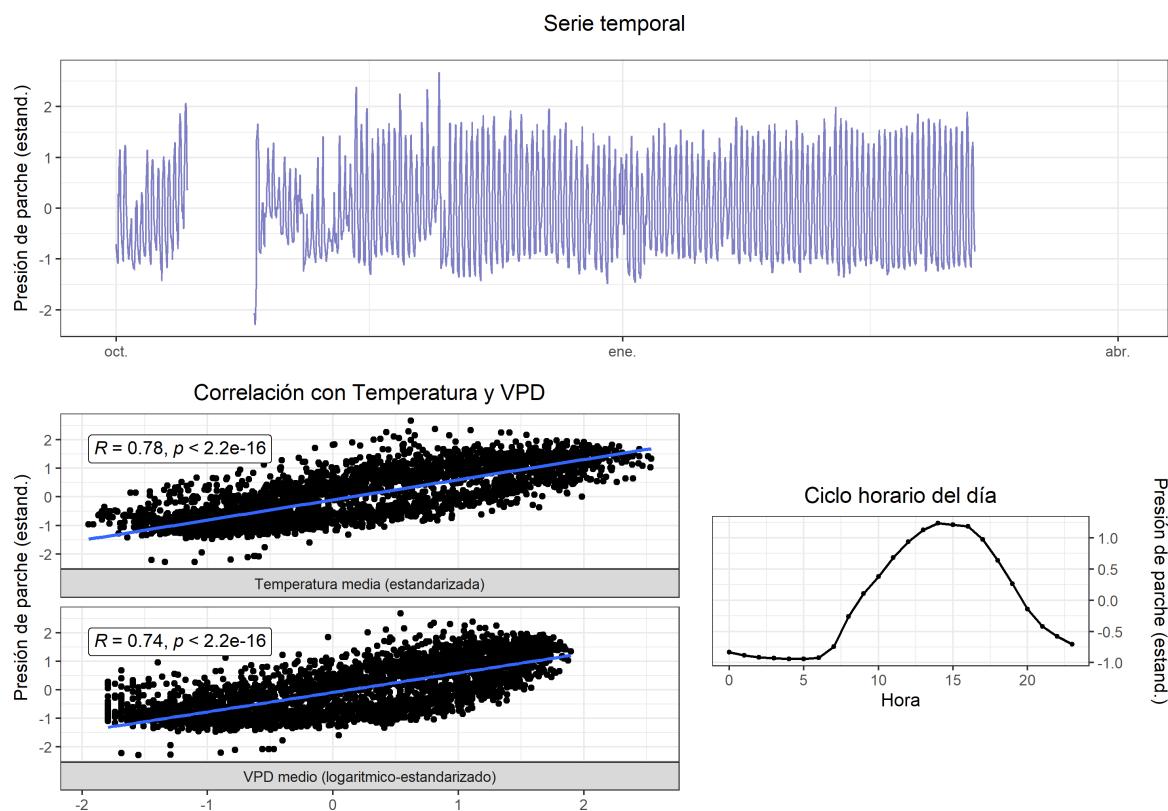


A nivel de tratamiento

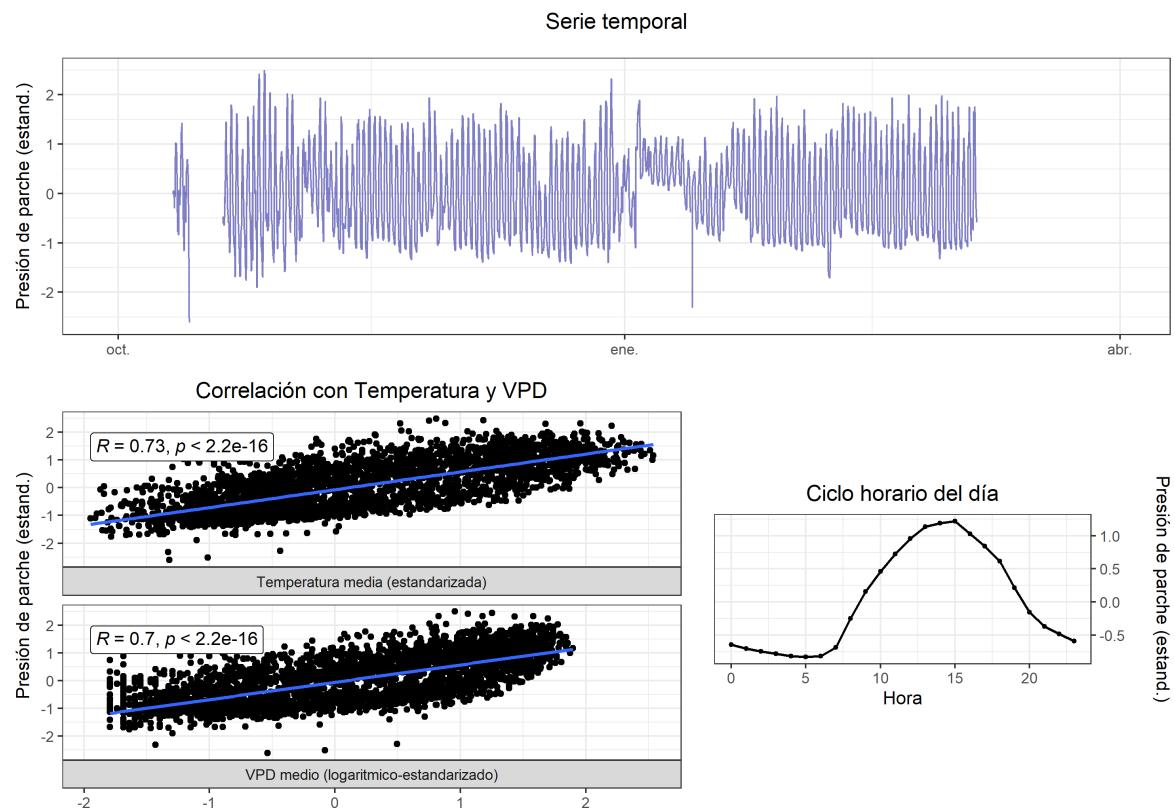
Para obtener el turgor preprocesado a nivel de tratamiento, se promediaron las series promediadas de cada unidad según tratamiento, obteniendo una serie única para cada tratamiento de en ambos sitios.

6.5.0.16.1 * La Esperanza

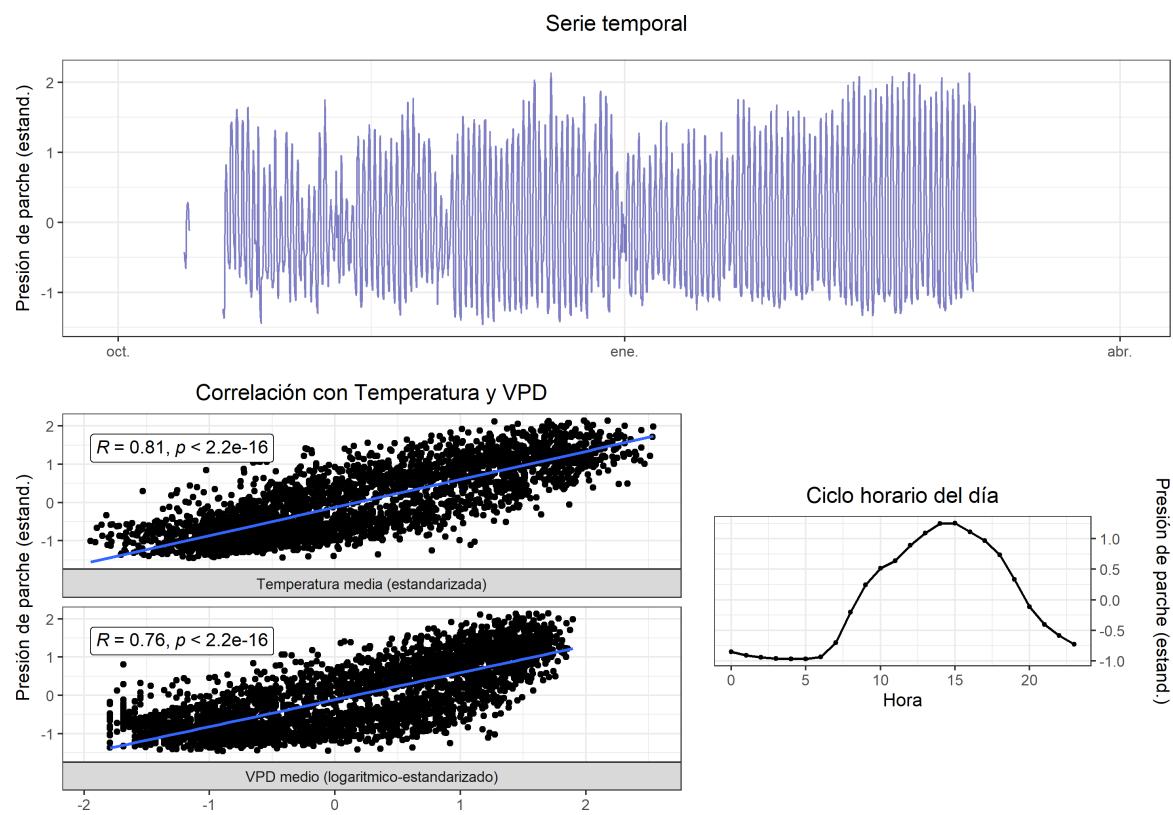
6.5.0.17 T1 (2022-2023)



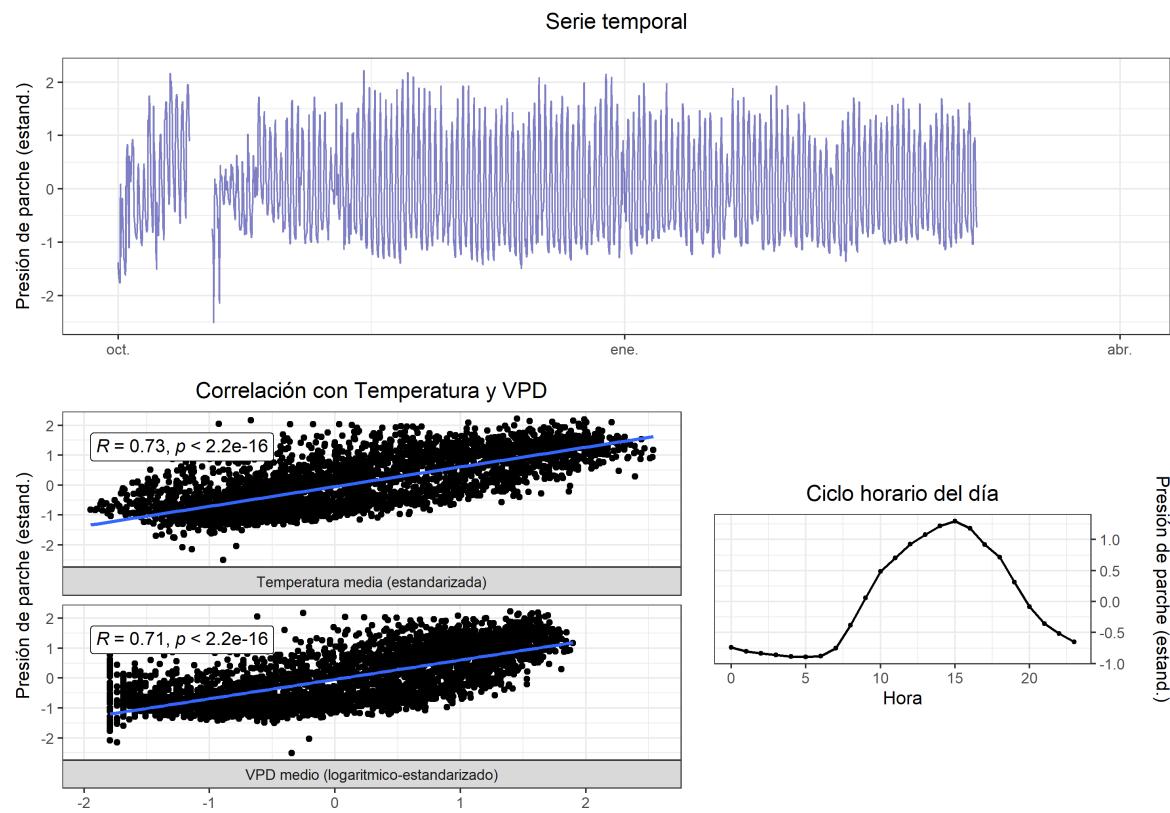
6.5.0.18 T2 (2022-2023)



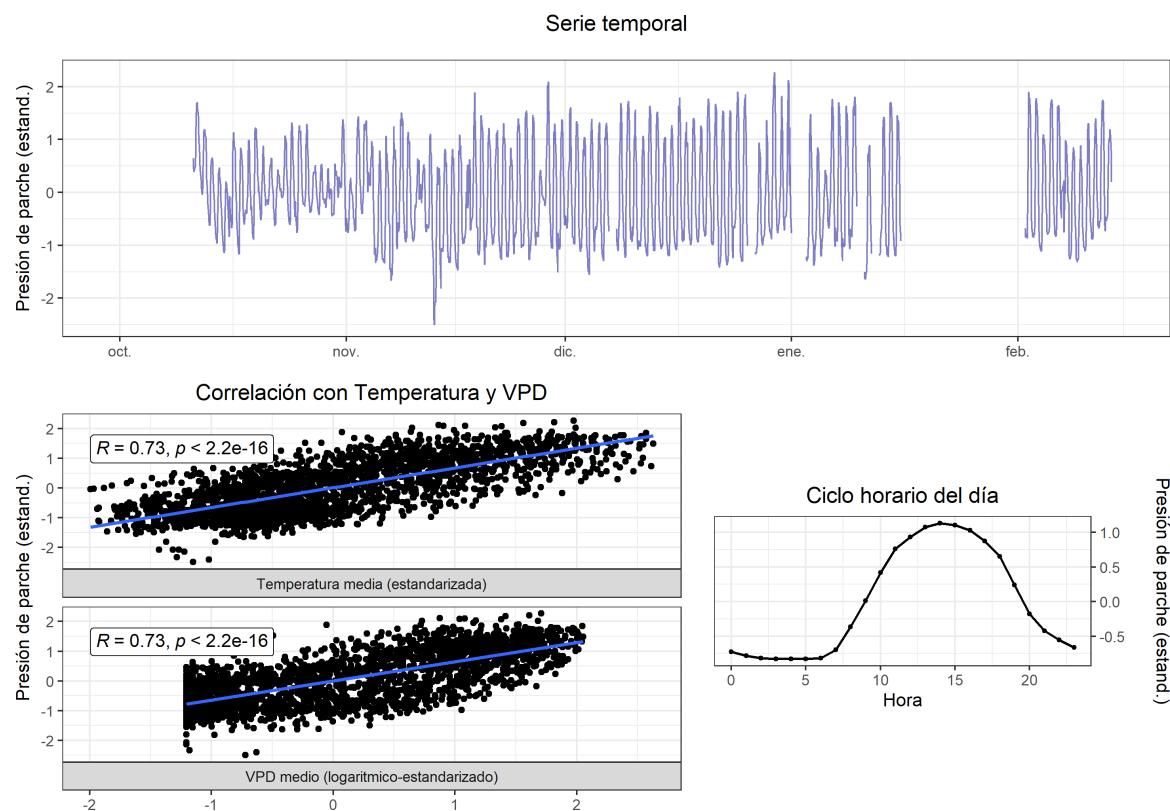
6.5.0.19 T3 (2022-2023)



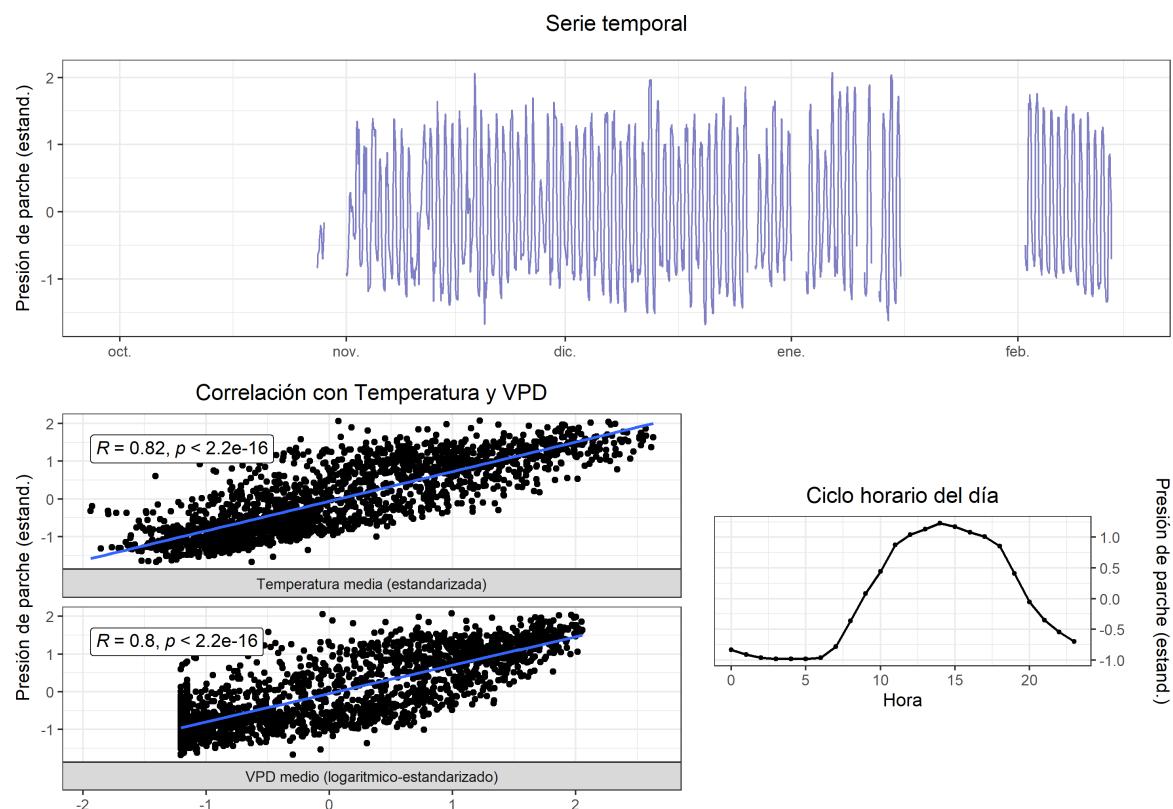
6.5.0.20 T4 (2022-2023)



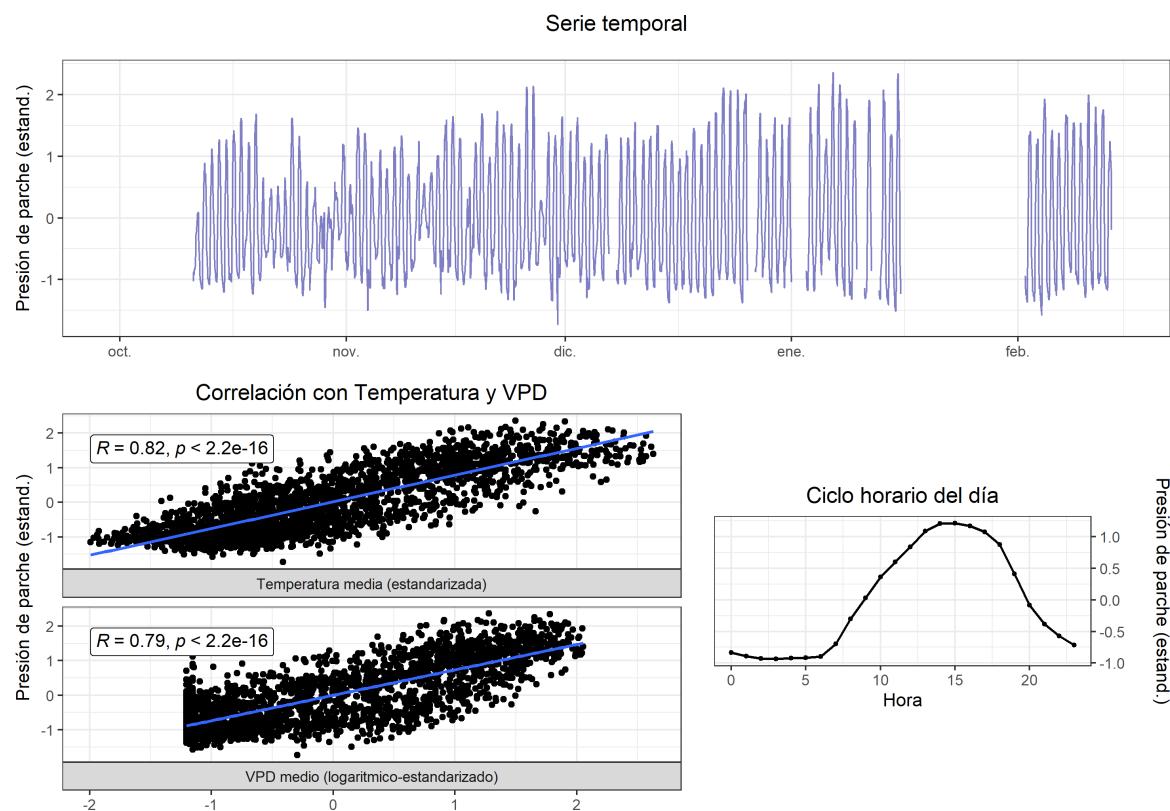
6.5.0.21 T1 (2023-2024)



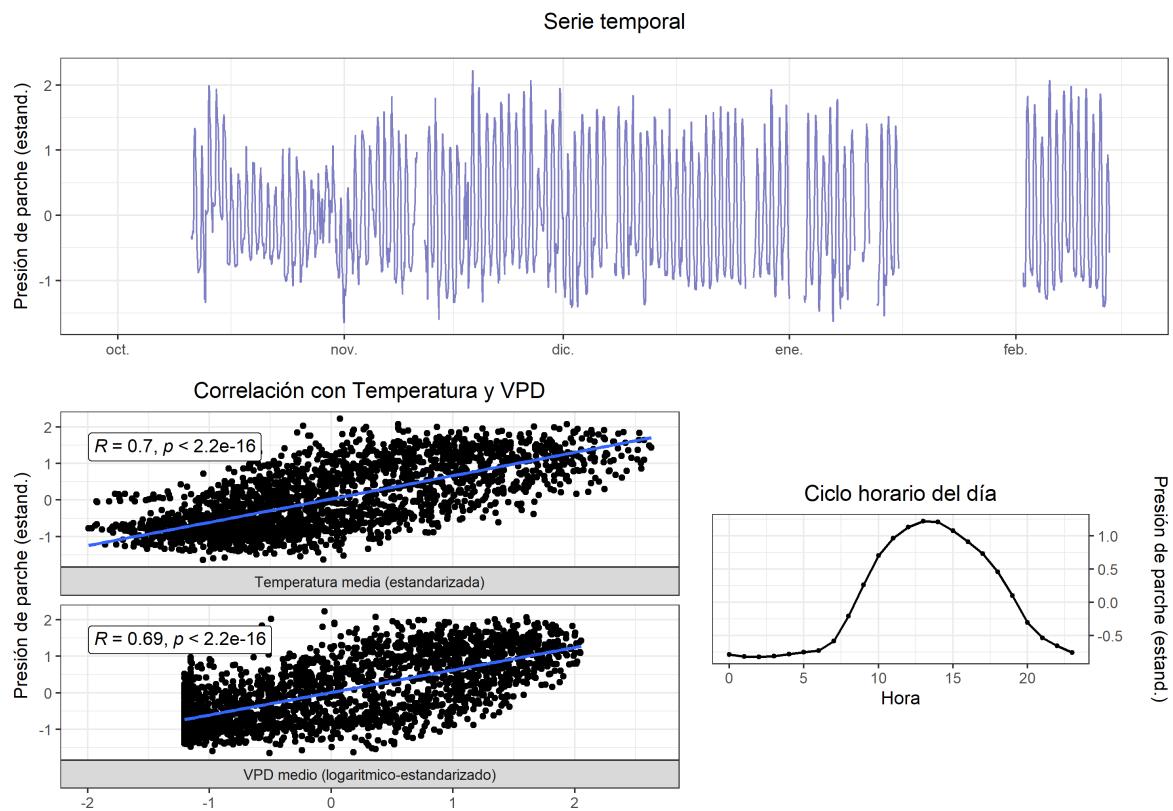
6.5.0.22 T2 (2023-2024)



6.5.0.23 T3 (2023-2024)

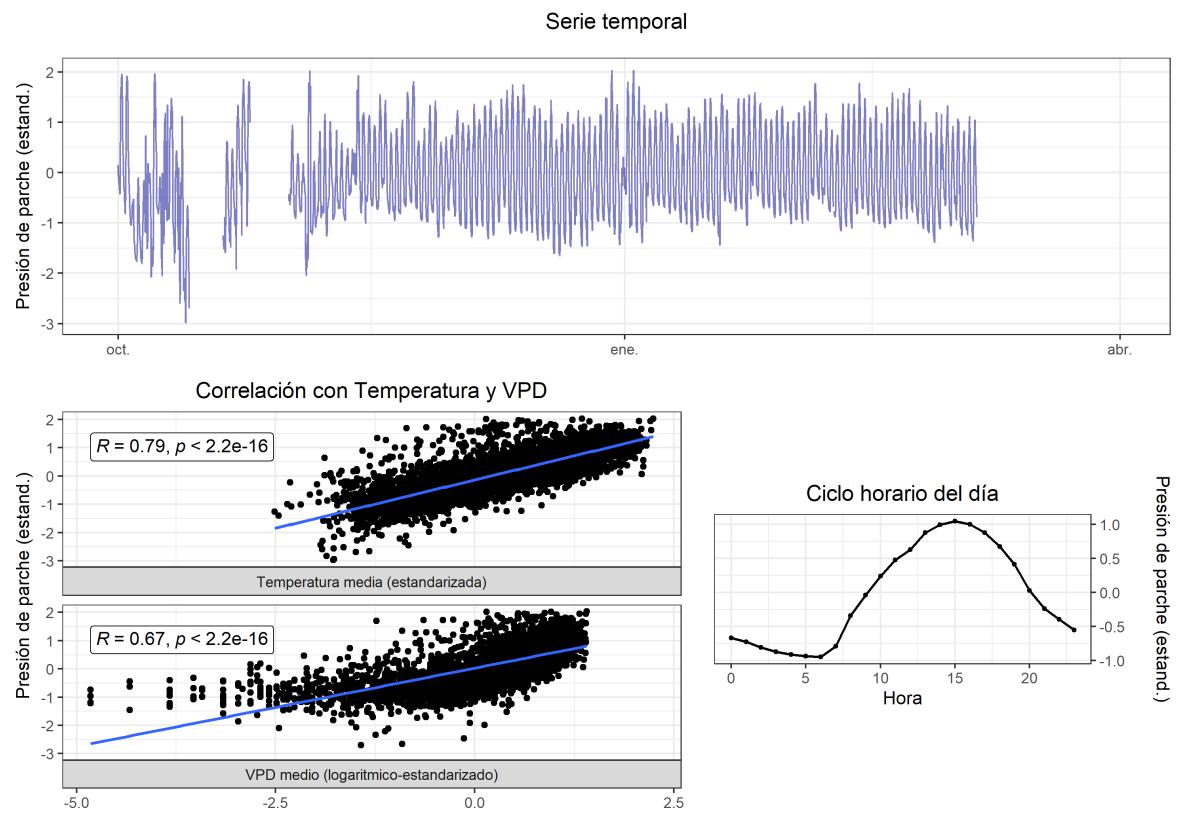


6.5.0.24 T4 (2023-2024)

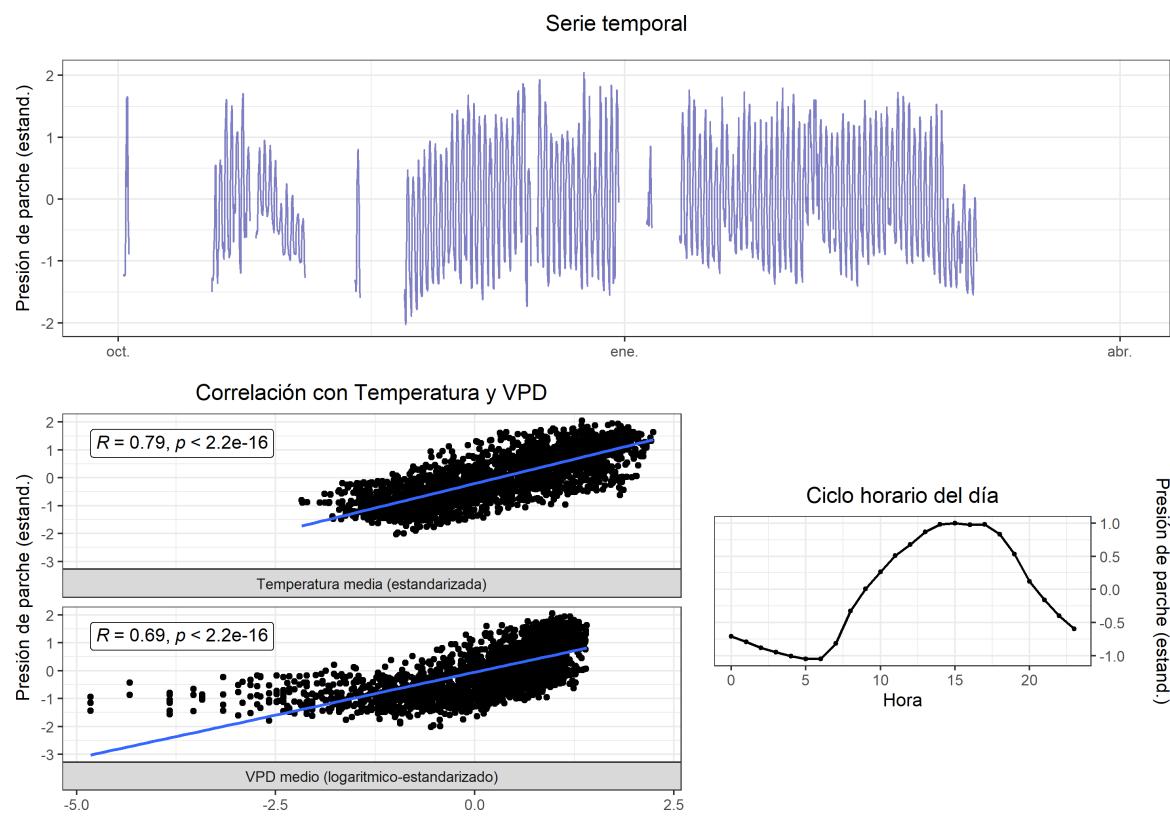


6.5.0.24.1 * Rio Claro

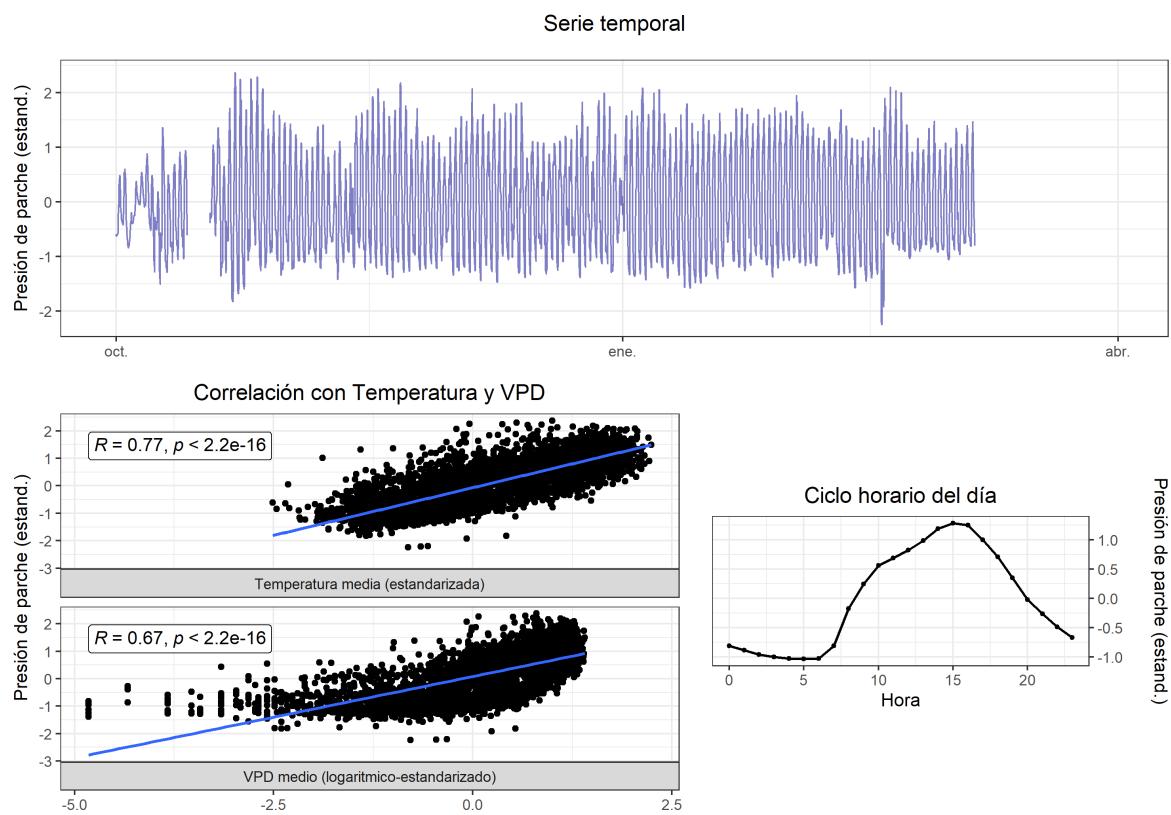
6.5.0.25 T1 (2022-2023)



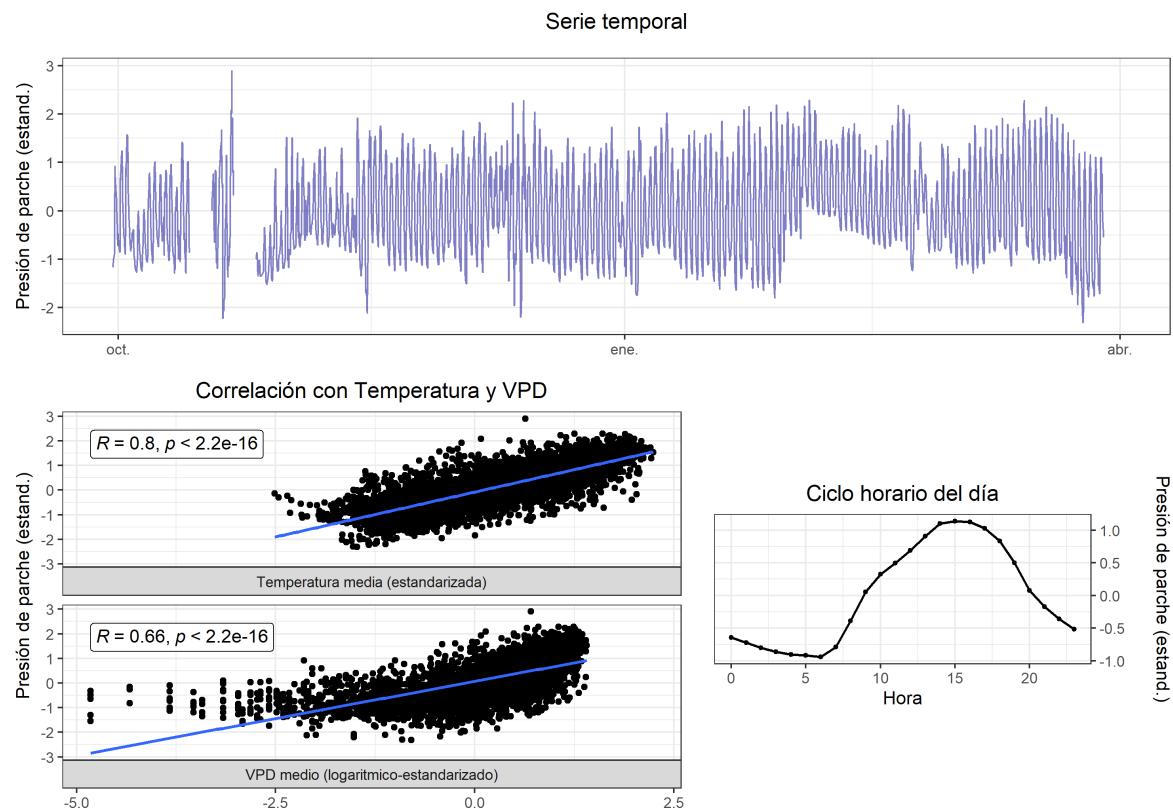
6.5.0.26 T2 (2022-2023)



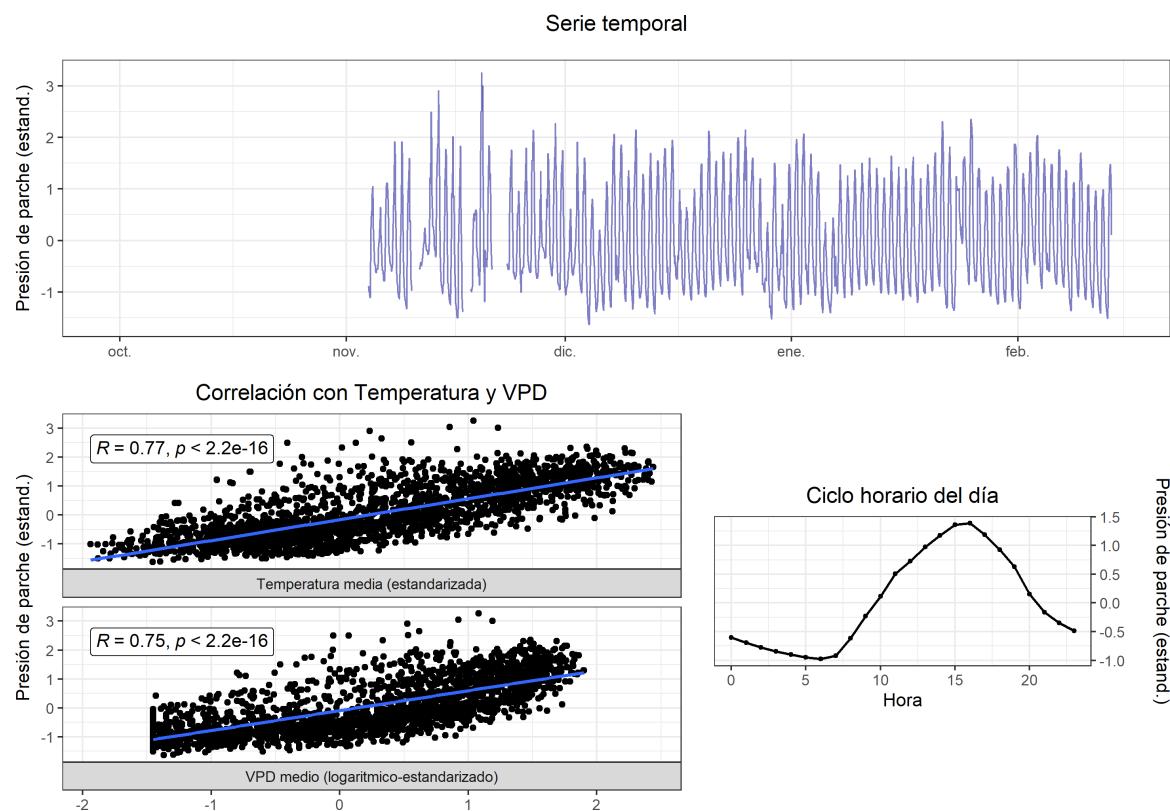
6.5.0.27 T3 (2022-2023)



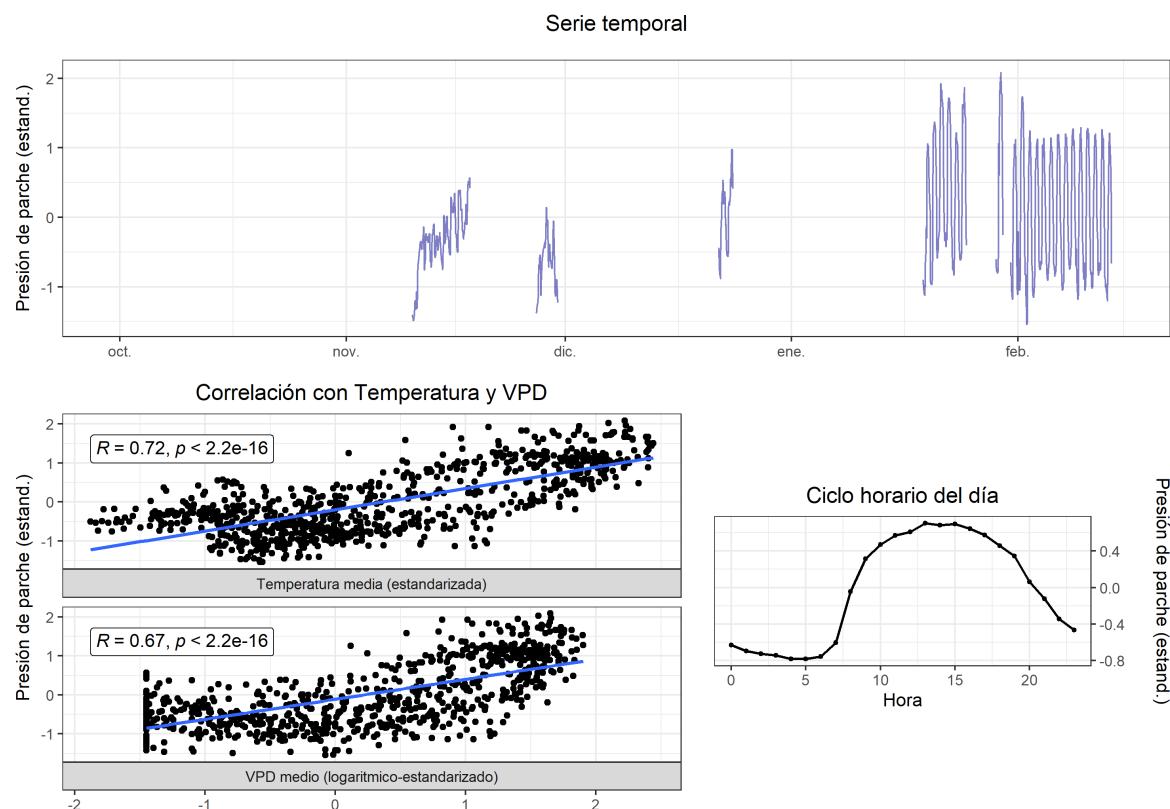
6.5.0.28 T4 (2022-2023)



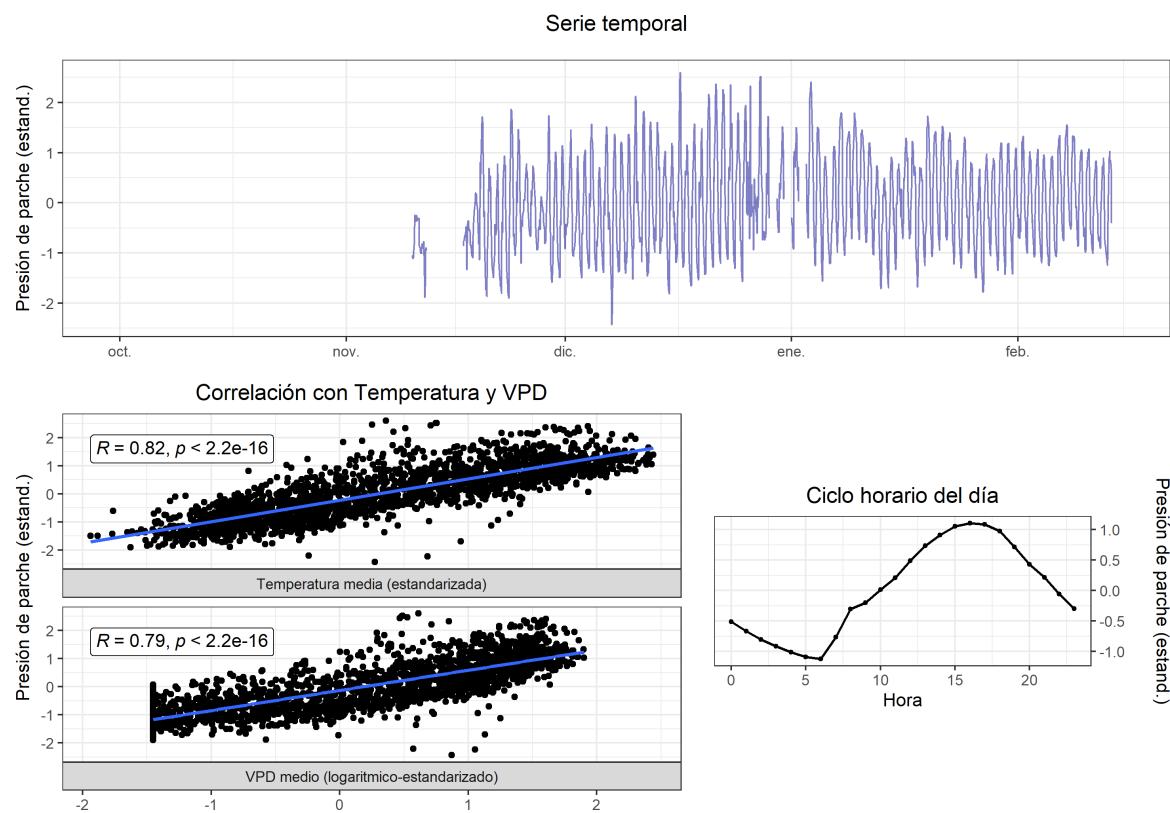
6.5.0.29 T1 (2023-2024)



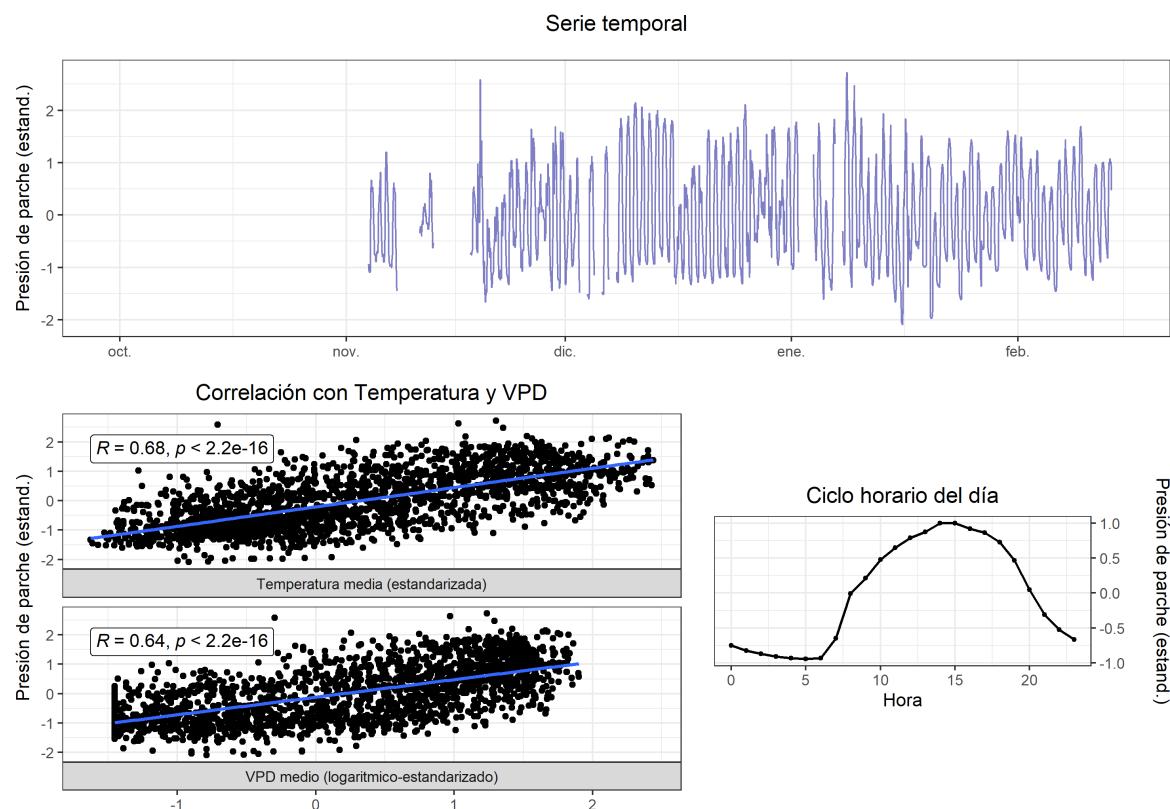
6.5.0.30 T2 (2023-2024)



6.5.0.31 T3 (2023-2024)



6.5.0.32 T4 (2023-2024)



7 Producción y calidad

7.1 Producción

Peso total

La Figura 7.1 muestra el peso total de los árboles según tratamiento, sitio y temporada, evidenciando diferencias tanto entre sitios como entre temporadas. En La Esperanza, no se observaron diferencias significativas entre tratamientos en ninguna de las dos temporadas. En 2022-2023, T4 presentó el mayor peso (17 kg), seguido por T0 (16.4 kg), mientras que T1 registró el menor valor (10.5 kg), con una diferencia de 5.83 kg respecto a T0. En 2023-2024, los valores fueron menores en general, con T3 alcanzando el mayor peso (6.18 kg) y T4 el menor (5.18 kg), situándose 0.59 kg por debajo de T0 (5.78 kg). En Río Claro, T2 mostró el mayor peso total (16.9 kg), superando en 0.76 kg a T0 (16.1 kg), mientras que T4 presentó el menor valor (11.9 kg), siendo 4.16 kg inferior a T0. En esta localidad, solo T2 y T4 fueron significativamente diferentes entre sí. A nivel temporal, en La Esperanza, el peso total del árbol fue significativamente menor en la segunda temporada en todos los tratamientos, reflejando una disminución generalizada en el rendimiento.

Densidad

La Figura 7.2 muestra la densidad de frutos por kilogramo según tratamiento, sitio y temporada, sin diferencias significativas entre tratamientos dentro de cada sitio y temporada, excepto en La Esperanza, donde T4 presentó una mayor densidad en la segunda temporada. En La Esperanza 2022-2023, T4 tuvo la menor densidad (89 frutos/kg), 4 frutos menos que T0 (93 frutos/kg), mientras que T2 alcanzó el mayor valor (98 frutos/kg), seguido por T3. En 2023-2024, los valores fueron similares, con T2 registrando la menor densidad (91 frutos/kg, apenas 1 fruto/kg menos que T0) y T1 la mayor (105 frutos/kg). En Río Claro, T0 mostró la menor densidad (97 frutos/kg), seguido por T4 (114 frutos/kg), mientras que T3 alcanzó el mayor valor (185 frutos/kg), superando en 88 frutos/kg a T0. A nivel temporal, solo en T4 de La Esperanza se observó un aumento significativo en la segunda temporada, lo que sugiere una mayor cantidad de frutos por kilogramo en ese tratamiento.

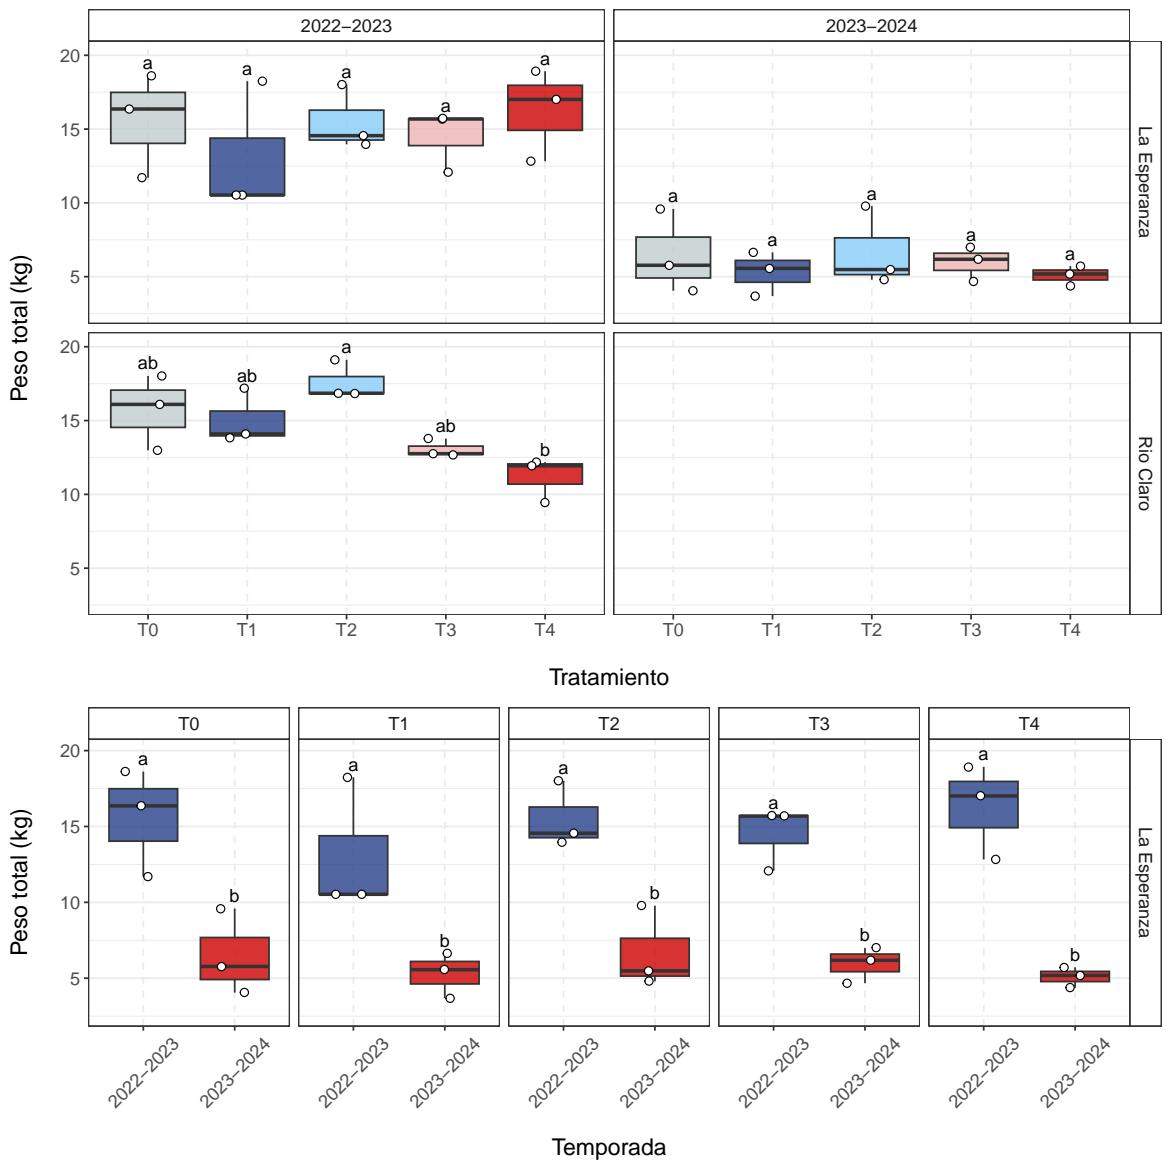


Figura 7.1: Comparación del peso total de producción por unidad de árbol (kg) según tratamiento, sitio y temporada.

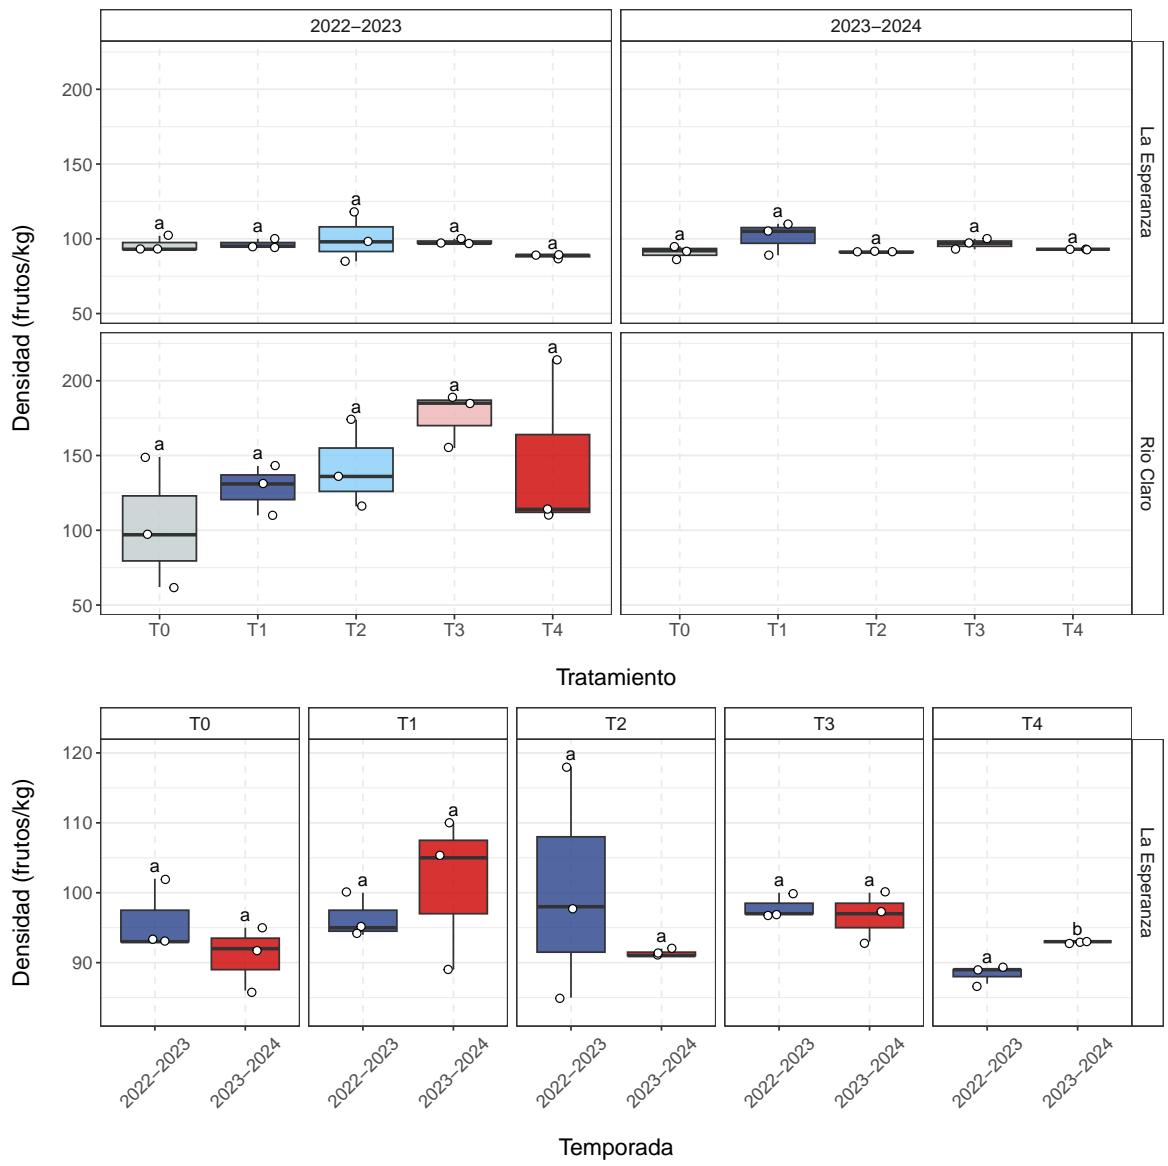


Figura 7.2: Comparación de la densidad de producción por unidad de árbol (frutos/kg) según tratamiento, sitio y temporada.

7.2 Calidad

Peso

La Figura 7.3 muestra la distribución del peso por unidad de cereza según tratamiento, sitio y temporada, evidenciando diferencias significativas entre tratamientos y un mejor desempeño en La Esperanza respecto a Río Claro. En La Esperanza (2022-2023), T4 presentó la mayor mediana (11.7 g), superando en 1 g al control T0 (10.7 g), mientras que T2 tuvo la menor (10 g); todos los tratamientos superaron el estándar comercial XL (6 g), con un 95-100% de frutos en esta categoría. En 2023-2024, T0 alcanzó la mediana más alta (11.2 g), seguido de T2 (11 g), manteniéndose todos los tratamientos sobre la talla XL (95-100% XL). En contraste, Río Claro (2022-2023) mostró un menor rendimiento, con T3 registrando la mediana más baja (5.85 g) y solo un 38.3% de frutos talla XL, mientras que T0 alcanzó 10.8 g y 90% XL. En esta localidad y temporada, se observaron las únicas diferencias significativas entre tratamientos, donde todos presentaron valores significativamente menores que T0 y, además, T3 fue significativamente menor que el resto. En La Esperanza, las diferencias entre temporadas fueron menos marcadas, con T2 mostrando un incremento en 2023-2024. Estos resultados reflejan la influencia del tratamiento y la localidad en la calidad de la cosecha, con un rendimiento consistentemente superior en La Esperanza.

Calibre

La Figura 7.4 muestra el calibre de los frutos por tratamiento, sitio y temporada. En La Esperanza 2022–2023, T2 presentó el menor diámetro (mediana = 25 mm), siendo significativamente inferior a todos los tratamientos, mientras que T4 alcanzó el mayor calibre (27 mm), siendo superior a T3, pero no difirió significativamente de T0 ni T1. Durante 2023–2024, los valores se incrementaron levemente: T1 presentó la menor mediana (27 mm), 0.7 mm por debajo de T0 (27.7 mm), y T4 la más alta (27.8 mm), mostrando diferencias significativas solo con T3. En ambos años, los frutos de T4 destacaron por mantener consistentemente el 100% de frutos dentro de los estándares comerciales L (22 mm) y XL (24 mm). En contraste, T2 mostró en 2022–2023 un 5% de frutos fuera del estándar mínimo, con apenas un 76.7% dentro del calibre XL. En Río Claro, todos los tratamientos difirieron significativamente entre sí, excepto T2 y T4. T0 presentó el mayor calibre (27.2 mm), mientras que T3 fue el más bajo (21.4 mm), con el 68.3% de frutos por debajo de la medida L y solo el 6.67% cumpliendo la XL. Temporalmente, en La Esperanza, T0, T2 y T4 mostraron un aumento significativo de calibre en 2023–2024 respecto a la temporada anterior, reforzando la mejora en la proporción de frutos comerciales, especialmente en T2, donde la proporción de calibre XL aumentó de 76.7% a 95%.

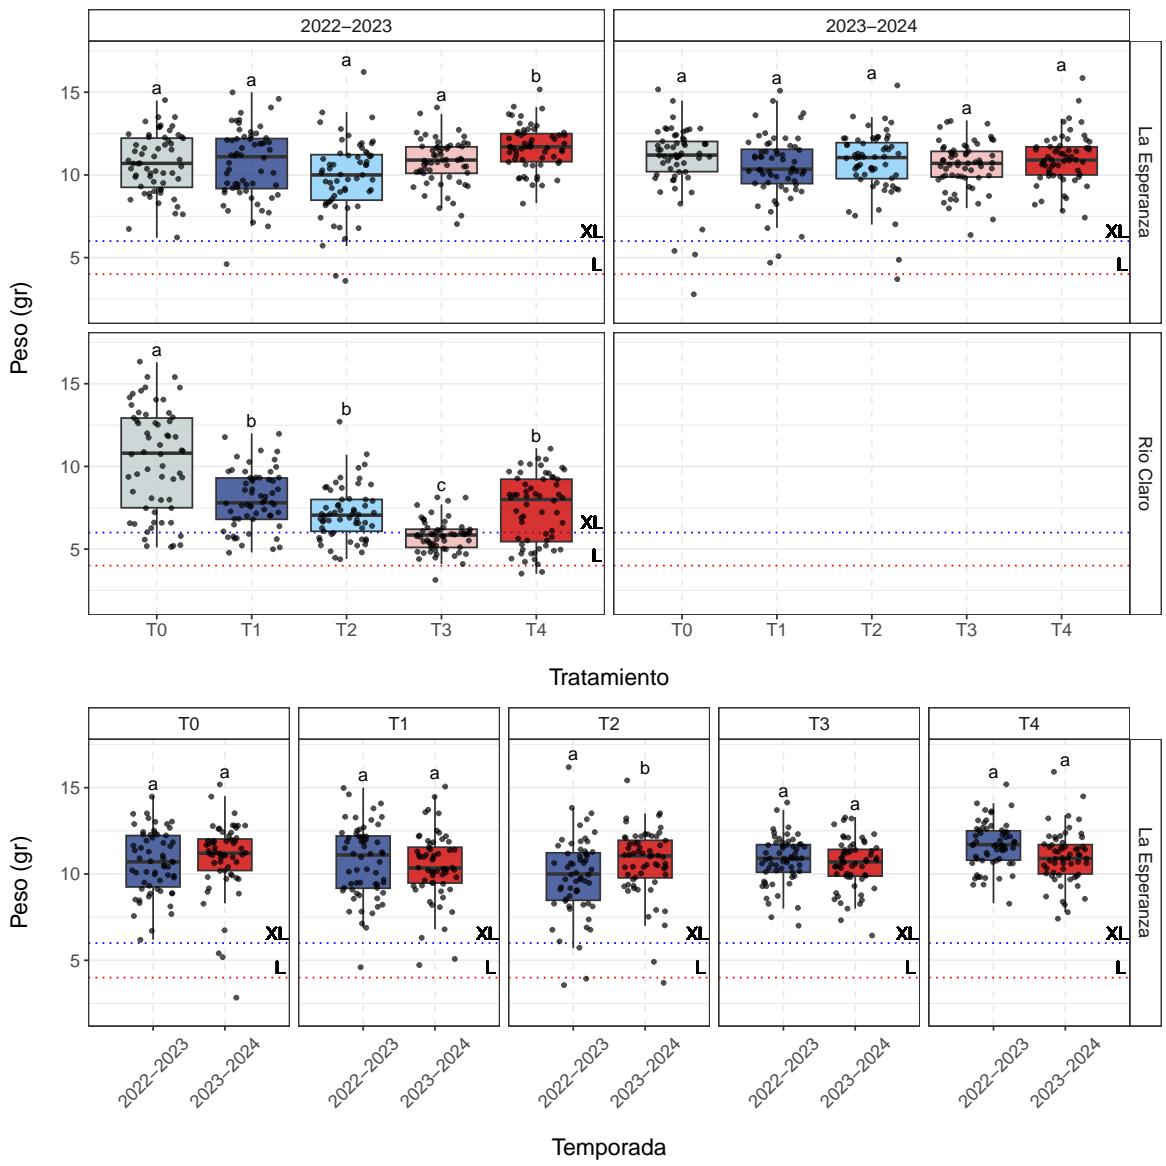


Figura 7.3: Comparación del peso de una unidad de cereza (gr) según tratamiento, sitio y temporada.

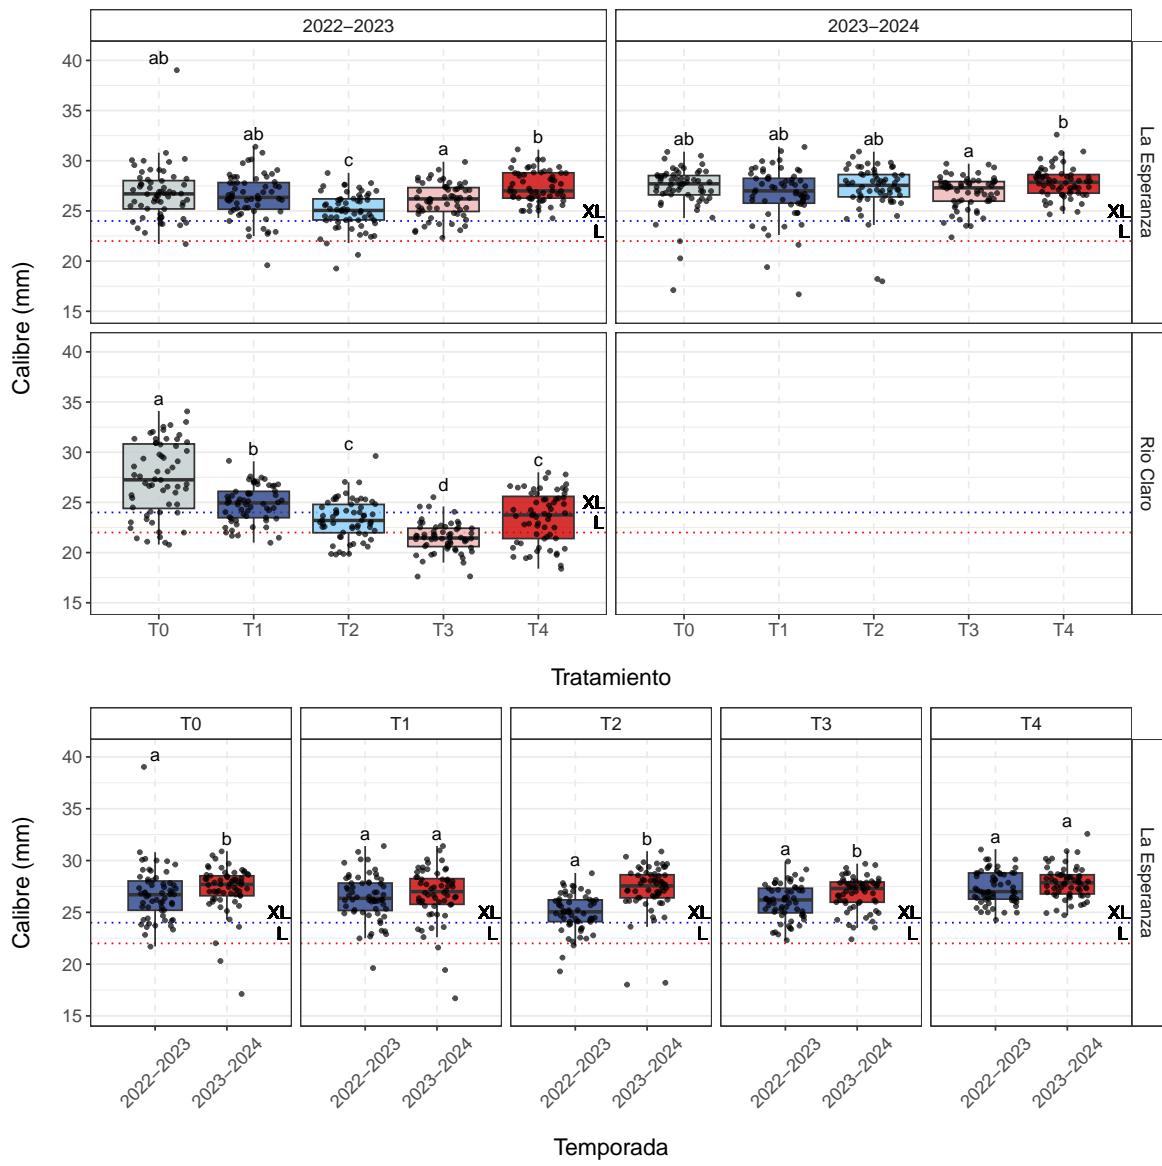


Figura 7.4: Comparación del calibre de una unidad de cereza (mm) por tratamiento según sitio y temporada.

Color

La Figura 7.5 presenta la distribución del color de las cerezas por tratamiento, sitio y temporada, en una escala de 1 a 6 donde los valores entre 4 y 5 (tonalidad caoba) corresponden a la categoría de mayor valoración comercial. En La Esperanza 2022–2023, T2 y T3 mostraron las medianas más bajas (4.5), siendo T2 significativamente inferior a todos los tratamientos salvo T3. En contraste, T4 alcanzó una mediana de 5, siendo significativamente superior a T2 pero no diferente de T0 ni T1. Las proporciones de frutos en categoría caoba fueron altas en todos los tratamientos (71.7–88.3%), destacando T4 con 88.3%. En 2023–2024, la mediana se redujo a 4 en la mayoría de los tratamientos, excepto T2 (4.5), que fue significativamente superior a T0 y T4. A pesar de esto, T2 alcanzó el mayor porcentaje de frutos caoba (90%), mientras que T0 y T4 descendieron a 51.7% y 56.7%, respectivamente. En Río Claro, T0 y T1 presentaron la mayor mediana (5), siendo significativamente superiores a T2, T3 y T4 (4.5). La proporción de frutos caoba fue superior al 70% en todos los tratamientos, con T2 alcanzando el 91.7%. Al comparar entre temporadas en La Esperanza, todos los tratamientos excepto T2 presentaron una disminución significativa en el color, indicando una pérdida general de tonalidad caoba en 2023–2024.

Contenido de azúcar

La concentración de sólidos solubles en cerezas se presenta en la Figura 7.6, considerando como referencia comercial óptima el rango de 19–20 °Brix. En La Esperanza 2022–2023, todos los tratamientos superaron la mediana de T0 (19.2), destacando T3 con 22.8 °Brix, que fue significativamente mayor que T0 y T4. La mayor proporción de frutos dentro del rango óptimo se observó en T4 (40%), seguido de T1 (26.7%), mientras que T3, pasando del rango óptimo, presentó solo un 13.3%. En la temporada 2023–2024, nuevamente todos los tratamientos superaron a T0 (21.4 °Brix), con T3 alcanzando la mayor mediana (23.8 °Brix), sin diferencias estadísticas entre tratamientos. No obstante, la proporción de frutos dentro del rango óptimo fue baja en todos los casos (<14%). En Río Claro, T4 tuvo la mayor mediana (22.4 °Brix), 3.4 °Brix superior a T0 (19 °Brix), mientras que T2 fue el más bajo (17.4 °Brix). Tampoco se encontraron diferencias significativas entre tratamientos. Comparando entre temporadas en La Esperanza, ningún tratamiento presentó diferencias significativas, aunque en todos los casos las medianas fueron más altas en 2023–2024.

Daño

El porcentaje de frutas dañadas por tratamiento, sitio y temporada se muestra en la Figura 7.7. En La Esperanza 2022–2023, la mediana más alta fue en T2 (21.2%), superior a T0 (12.9%), mientras que el menor valor correspondió a T4 (5.62%). En la temporada 2023–2024, T3 alcanzó el mayor valor (38%) y T4 el menor (26.9%). En ambos casos no se encontraron diferencias significativas entre tratamientos. En Río Claro, el mayor valor se observó en

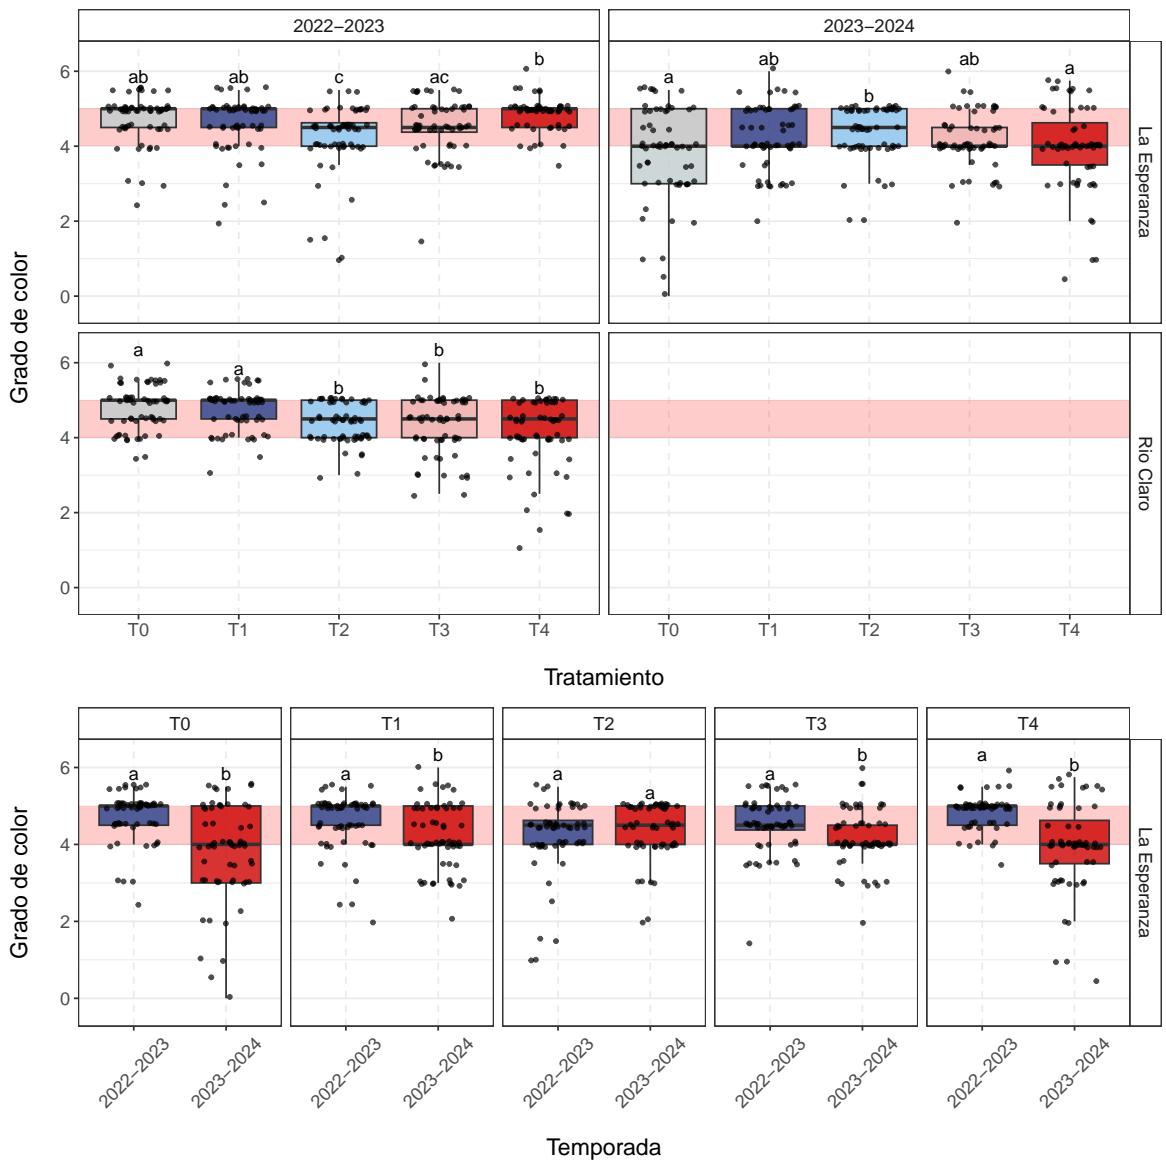


Figura 7.5: Comparación del color de una unidad de cereza según tratamiento, sitio y temporada.

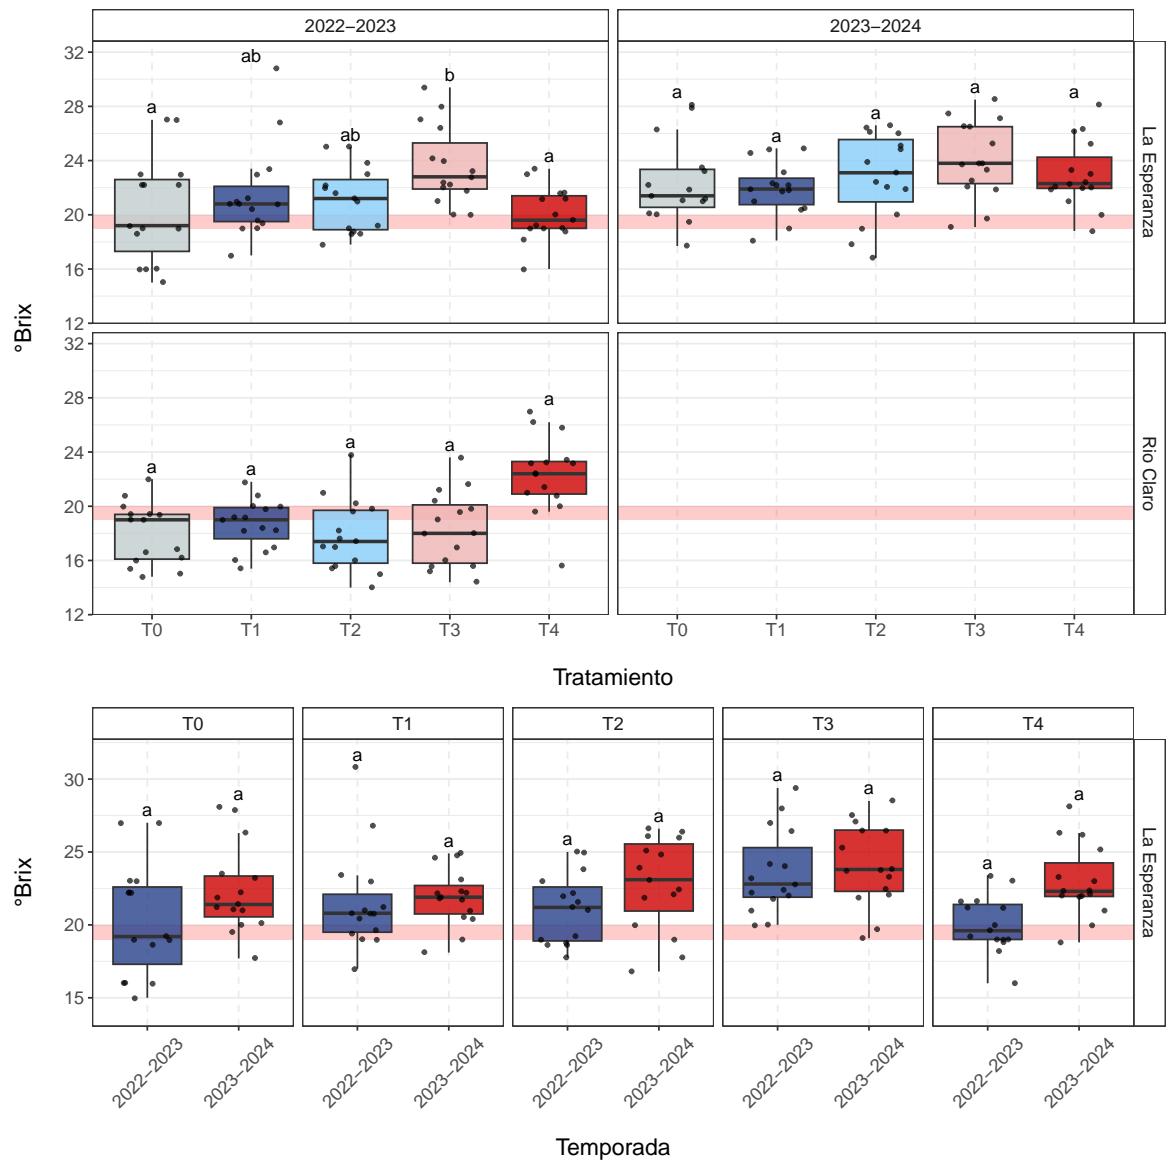


Figura 7.6: Comparación de la concentración de sólidos solubles ($^{\circ}$ brix) de una unidad de cereza según tratamiento, sitio y temporada.

T4 (16.4%), superior a T0 (11.3%), y el menor en T1 (8.4%), sin diferencias estadísticas. Comparando entre temporadas en La Esperanza, todos los tratamientos presentaron porcentajes significativamente mayores de fruta dañada en 2023–2024. Cabe señalar que cada tratamiento se basó en tres muestras ($n = 3$), lo que representa una única proporción por tratamiento a partir del kilo de muestra por árbol, lo que puede haber influido en la detección de diferencias significativas.

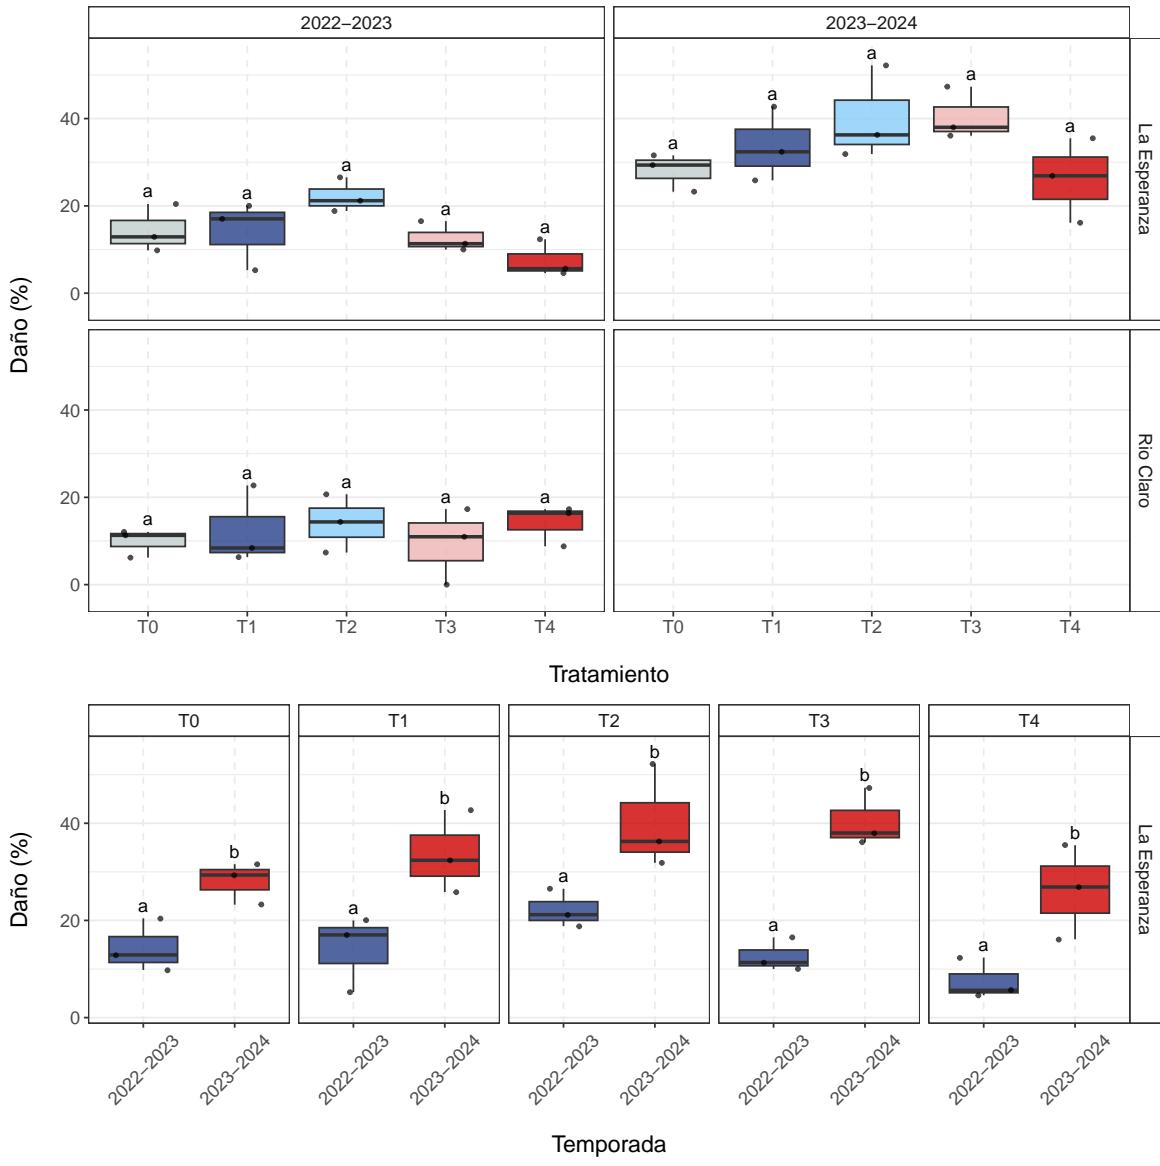


Figura 7.7: Comparación del porcentaje de daño (%) según tratamiento, sitio y temporada.

8 Modelos predictivos de potencial

La Figura 8.1 muestra el ranking de R^2 para cada uno de los doce modelos entrenados con remuestreo (tres algoritmos, dos esquemas de partición y con o sin análisis de componentes principales por mínimos cuadrados parciales). El ranking basado en la métrica RMSE mostró un comportamiento equivalente. Con rnd_split, los valores de R^2 oscilaron entre 0.45 y 0.8, mientras que con tme_split disminuyeron a un rango entre 0.25 y 0.52. En el caso de rnd_split, los algoritmos XGBoost y RF alcanzaron los valores más altos de R^2 , con una media de 0.77 y 0.76, respectivamente, seguidos por SVM con un R^2 de 0.68. En tme_split, la diferencia de R^2 entre modelos fue menor en comparación con aquellos entrenados con rnd_split. Los tres modelos que alcanzaron el mayor R^2 bajo tme_split fueron XGBoost, pls_SVM (entrenado con los cinco componentes principales obtenidos mediante análisis de mínimos cuadrados parciales como predictores) y SVM, con valores cercanos a 0.45. Se seleccionaron los tres modelos con mayor desempeño según la evaluación con remuestreo por esquema de partición, en adelante denominados RF, XGBoost y SVM.

La Figura 8.2 muestra las once variables más importantes en el rendimiento del modelo. En los dos esquemas de división, los datos meteorológicos, específicamente ET0, VPD y temperatura, tienen la mayor importancia y alcanzan su peso máximo. En el modelo SVM, la RH es el único predictor en el rnd_split, mientras que en el tme_split, RH, VPD y temperatura son los predictores de mayor importancia. Los predictores derivados de S2 ocupan el segundo lugar después de los datos meteorológicos. En el rnd_split, MSI, DWSI, mSR705, NDMI y NMDI son los predictores más relevantes para RF y XGBoost. Al considerar el tme_split, MSI, DWSI y NDMI son las variables que más contribuyen al rendimiento del modelo. En el caso del modelo SVM para tme_split, el parámetro biofísico CCC tiene la mayor importancia. Como era de esperar, los predictores de S2 más relacionados con Ψ_s fueron aquellos que utilizan la longitud de onda SWIR, que es la región espectral más sensible al agua.

Después de la evaluación por remuestreo, entrenamos los modelos en el conjunto de datos de prueba. En el rnd_split, el R^2 fue de 0.76, 0.76 y 0.62 para XGBoost, RF y SVM, respectivamente (Figura 8.3). El RMSE estuvo entre 0.24 MPa (XGBoost y RF) y 0.3 MPa (SVM). En el rnd_split, RF y XGBoost mejoran significativamente en comparación con SVM. Cuando se entrenaron en el tme_split, el rendimiento de los modelos disminuyó en comparación con los entrenados con rnd_split. Entre ellos, los modelos se comportaron de manera similar, con un R^2 de 0.59 para los tres modelos. El RMSE fue de entre 0.36 MPa para XGBoost y 0.39 MPa para SVM. En la Figura 8.3, se puede observar que el error (observado menos estimado) aumenta para valores menores a -1.5 MPa, lo que corresponde a menos puntos. Así, los modelos no cuentan con suficientes datos para mejorar su rendimiento. La razón de la menor cantidad

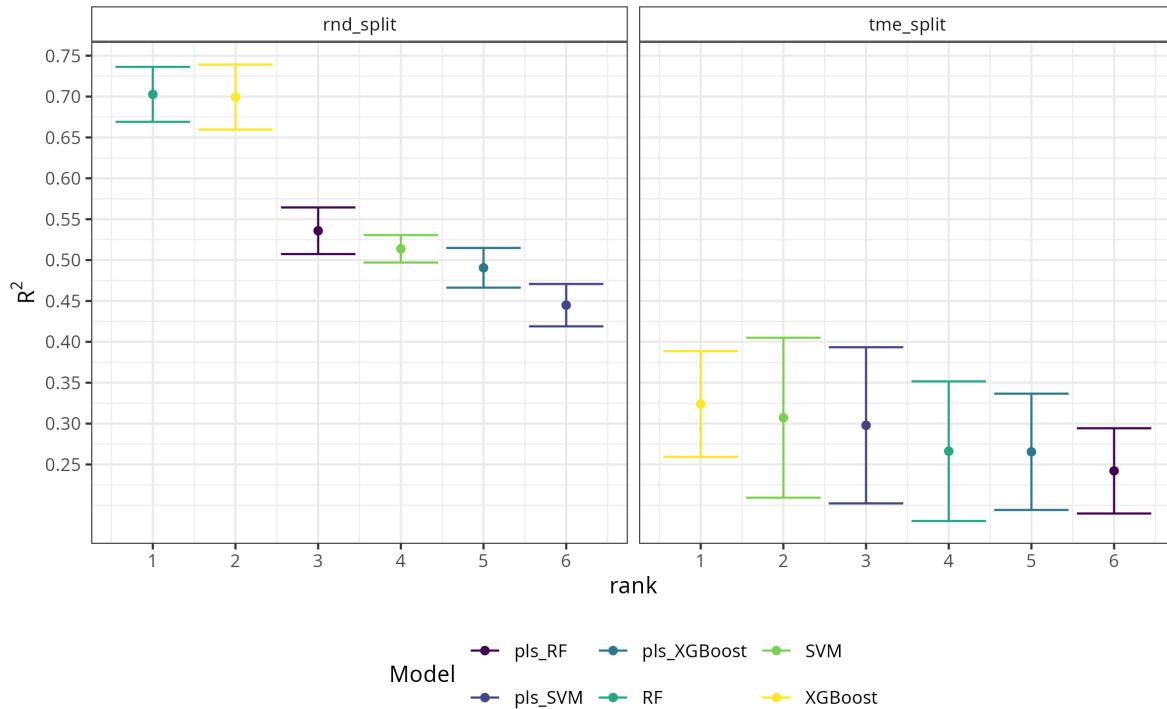


Figura 8.1: Ranking de modelos de aprendizaje automático en el remuestreo según la métrica R^2 . Los modelos son Random Forest (RF), Extreme Gradient Boosting (XGBoost) y Support Vector Machines (SVM). El acrónimo “pls” junto al nombre del modelo indica el uso de mínimos cuadrados parciales (partial least squares). Cada panel corresponde a un esquema de partición: división aleatoria (rnd_split) y división independiente del tiempo (tme_split).

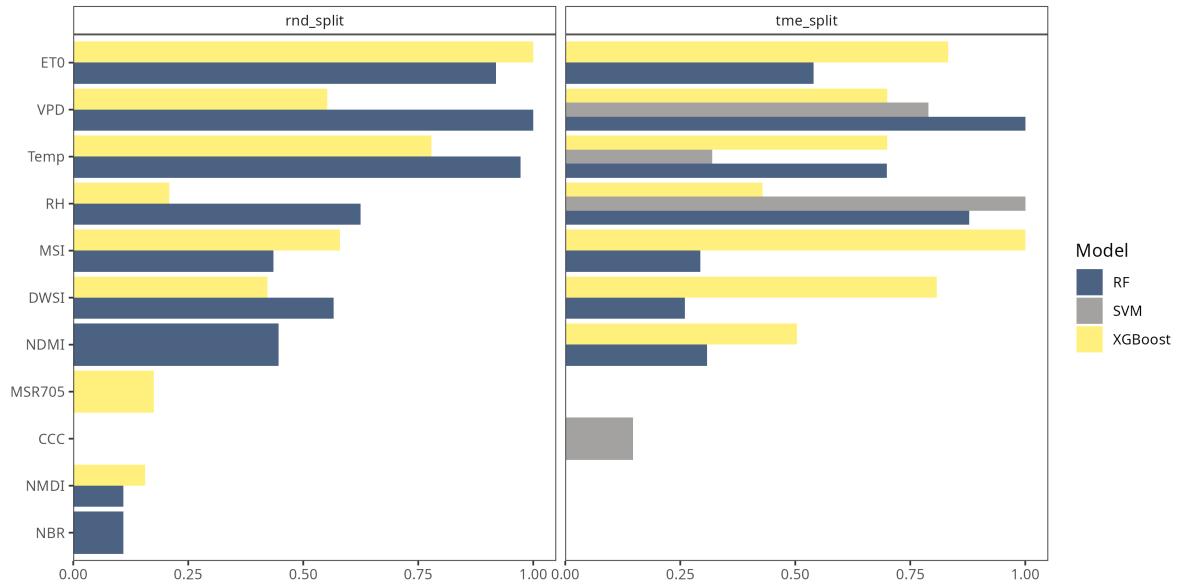


Figura 8.2: Importancia de las variables escalada (0–1) por modelos de aprendizaje automático: random forest (RF), extreme gradient boosting (XGBoost) y support vector machines (SVM); para los dos esquemas de división: división aleatoria (rnd_split) y división independiente del tiempo (tme_split).

de datos en este rango es que corresponde a niveles más altos de estrés hídrico. El estrés crítico puede llevar al cierre estomático de las plantas, lo que puede afectar tanto la producción como la calidad.

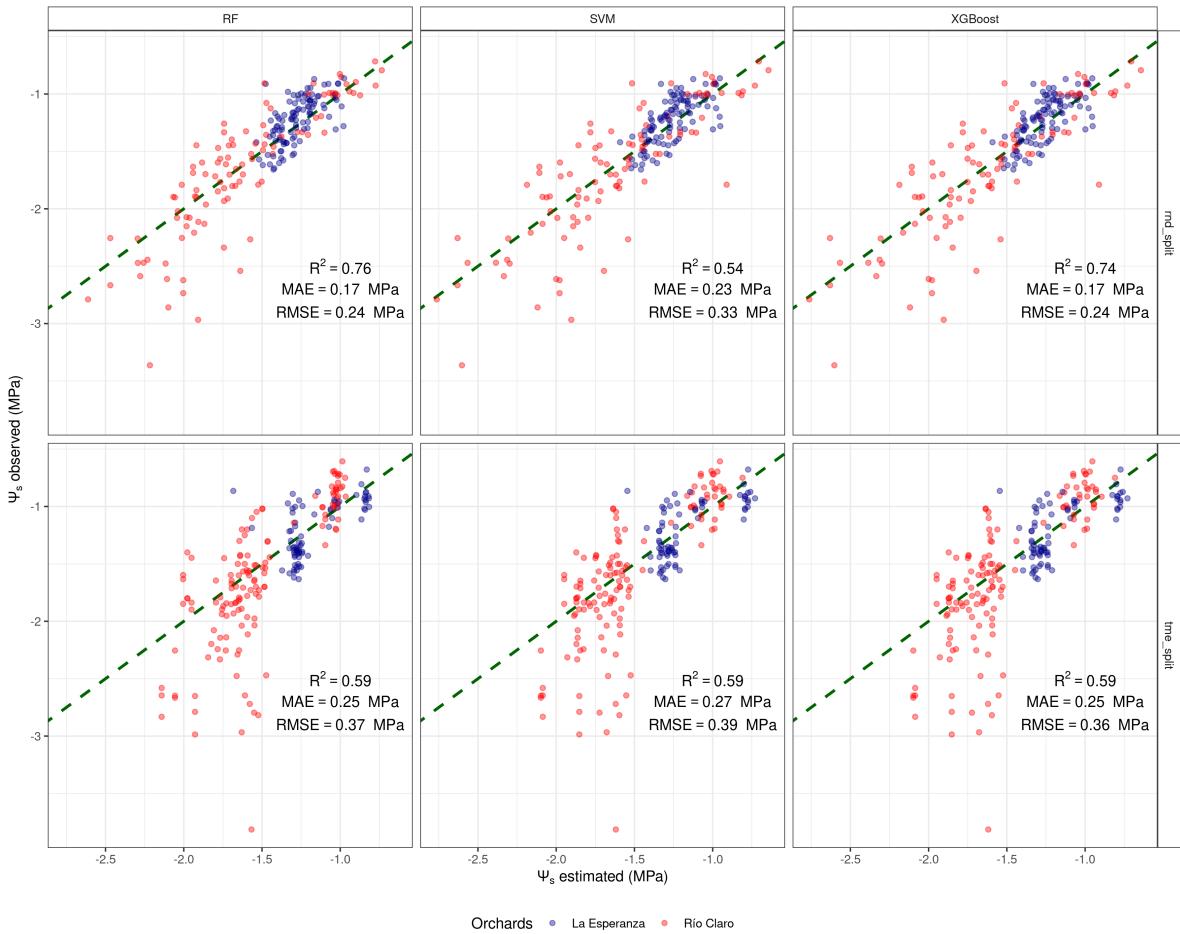


Figura 8.3: Valores predichos en el conjunto de datos de prueba versus valores observados de potencial hídrico en el tallo (Ψ_s) para los huertos de La Esperanza y Río Claro. Los paneles verticales corresponden al modelo de aprendizaje automático: random forest (RF), extreme gradient boosting (XGBoost) y support vector machines (SVM). Los paneles horizontales corresponden a los esquemas de división: división aleatoria (rnd_split) y división independiente del tiempo (tme_split). Las métricas de rendimiento utilizadas son el coeficiente de determinación (R^2), el error absoluto medio (MAE) y el error cuadrático medio (RMSE).

9 SatOri

En la Figura 9.1 se muestra el dashboard de inicio de la plataforma SatOri. En él, se distinguen dos pestañas: “Panel” y “Resumen Temporada”. La Fig. 1 se encuentra desplegando las opciones de la pestaña “Panel”.



Figura 9.1: Dashboard ejemplo de la plataforma SatOri, pestaña “Panel”.

En los botones que se encuentran en la parte izquierda de la pantalla, el usuario puede seleccionar el huerto que quiere revisar, la temporada, y la fecha específica; para poder visualizar el potencial.

El mapa visualizará el potencial del huerto seleccionado y para el día seleccionado. En el mapa se puede pinchar en alguno de los sectores de riego. Al pinchar en alguno, los gráficos que se encuentran a la derecha, mostrarán los datos de potencial para dicho sector. La linea en rojo que se muestra, corresponde a los valores de potencial de los últimos siete días. Los colores, verde, amarillo y rojo, indican los diferentes niveles de estado hídrico que pueda alcanzar el sector. En el ejemplo, se ve que la línea para el sector de riego seleccionada se encuentra en verde por lo tanto no es necesario regar.

En el caso que la linea roja llegué a la zona de color amarillo, la plataforma dará un aviso de que es necesario regar e indicara el tiempo de riego para cada sector.

Por otra parte, en la parte superior de la aplicación, se muestra un resumen de cuantos sectores de riego están en verde, amarillo y rojo.

La Fig. 2 muestra la plataforma en la pestaña “Panel”. En este caso se muestra un mapa ampliado con el detalle de la variación del potencial hídrico xilemático durante toda la temporada para los sectores de riego.



Figura 9.2: Figura 2: Dashboard ejemplo plataforma SatOri, pestaña “Resumen Temporada”.

Se puede acceder a la plataforma por medio de la página web de difusión del proyecto <https://s4tori.cl> o directamente por medio del link <https://s4tori.cl/app>.

References

- Addabbo, Pia, Mariano Focareta, Salvo Marcuccio, Claudio Votto, y Silvia Liberata Ullo. 2016. «Contribution of Sentinel-2 data for applications in vegetation monitoring». *ACTA IMEKO* 5 (2): 44. https://doi.org/10.21014/acta_imeko.v5i2.352.
- Ali, Olivier, Ibrahim Cheddadi, Benoit Landrein, y Yuchen Long. 2023. «Revisiting the relationship between turgor pressure and plant cell growth». *New Phytologist* 238 (1): 62-69. <https://doi.org/10.1111/nph.18683>.
- Arribillaga, Diego. 2013. «Manejo de pre y post cosecha del cultivo del cerezo (*Prunus avium* L.) en Chile Chico, región de Aysén». INIA.
- Avium, Equipo Técnico. 2021. «Reportes Fenológicos. TP2021-22». AVIUM.
- Bader, Martin K.-F., Wilhelm Ehrenberger, Rebecca Bitter, Jason Stevens, Ben P. Miller, Jerome Chopard, Simon Rüger, et al. 2014. «Spatio-temporal water dynamics in mature *Banksea menziesii* trees during drought». *Physiologia Plantarum* 152 (2): 301-15. <https://doi.org/10.1111/ppl.12170>.
- Beck, Hylke E., Niklaus E. Zimmermann, Tim R. McVicar, Noemi Vergopolan, Alexis Berg, y Eric F. Wood. 2018. «Present and future Köppen-Geiger climate classification maps at 1-km resolution». *Scientific Data* 5 (1): 180214. <https://doi.org/10.1038/sdata.2018.214>.
- Blanco, Víctor, Ginés Benito Martínez-Hernández, Francisco Artés-Hernández, Pedro José Blaya-Ros, Roque Torres-Sánchez, y Rafael Domingo. 2019. «Water relations and quality changes throughout fruit development and shelf life of sweet cherry grown under regulated deficit irrigation». *Agricultural Water Management* 217. <https://doi.org/10.1016/j.agwat.2019.02.028>.
- Blanco, Victor, Roque Torres-Sánchez, Pedro José Blaya-Ros, Alejandro Pérez-Pastor, y Rafael Domingo. 2019. «Vegetative and reproductive response of “Prime Giant” sweet cherry trees to regulated deficit irrigation». *Scientia Horticulturae* 249. <https://doi.org/10.1016/j.scienta.2019.02.016>.
- Carrasco-Benavides, Marcos, Javiera Antunez-Quilobrán, Antonella Baffico-Hernández, Carlos Ávila-Sánchez, Samuel Ortega-Farías, Sergio Espinoza, John Gajardo, Marco Mora, y Sigfredo Fuentes. 2020. «Performance assessment of thermal infrared cameras of different resolutions to estimate tree water status from two cherry cultivars: An alternative to midday stem water potential and stomatal conductance». *Sensors (Switzerland)* 20. <https://doi.org/10.3390/s20123596>.
- Carrasco-Benavides, Marcos, Claudia González, Eden Tongson, Antonella Baffico-Hénandez, Carlos Ávila-Sánchez, Marcos Mora, y Sigfredo Fuentes. 2022. «Water status estimation of cherry trees using infrared thermal imagery coupled with supervised machine learning modeling». *Computers and Electronics in Agriculture* 200 (septiembre).

- Carrasco-Benavides, Marcos, Sergio Espinoza Meza, Jeissy Olguín-Cáceres, Diego Muñoz-Concha, Eduardo von Bennewitz, Carlos Ávila-Sánchez, y Samuel Ortega-Farías. 2020. «Effects of regulated post-harvest irrigation strategies on yield, fruit quality and water productivity in a drip-irrigated cherry orchard». *New Zealand Journal of Crop and Horticultural Science* 48. <https://doi.org/10.1080/01140671.2020.1721544>.
- Chen, Tianqi, y Carlos Guestrin. 2016. «XGBoost: A Scalable Tree Boosting System». En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-94. San Francisco California USA: ACM. <https://doi.org/10.1145/2939672.2939785>.
- Chile, Dirección Meteorológica de. 2025. «Portal de Servicios Meteorológicos». <https://www.meteochile.gob.cl/PortalDMC-web/index.xhtml>.
- Cleveland, William S. 1979. «Robust Locally Weighted Regression and Smoothing Scatterplots». *Journal of the American Statistical Association* 74 (368): 829-36. <https://doi.org/10.1080/01621459.1979.10481038>.
- Cortes, Corinna, y Vladimir Vapnik. 1995. «Support-vector networks». *Machine Learning* 20 (3): 273-97. <https://doi.org/10.1007/BF00994018>.
- E, Houghton, Bevandick K, Neilsen D, Hannam K, y Nelson L. 2023. «Effects of postharvest deficit irrigation on sweet cherry (*Prunus avium*) in five Okanagan Valley, Canada, orchards: II. Phenology, cold hardiness, fruit yield, and quality». *Canadian Journal of Plant Science* 100 (enero): 1-17.
- Fernández, J. E., C. M. Rodriguez-Dominguez, A. Perez-Martin, U. Zimmermann, S. Rüger, M. J. Martín-Palomo, J. M. Torres-Ruiz, et al. 2011. «Online-monitoring of tree water stress in a hedgerow olive orchard using the leaf patch clamp pressure probe». *Agricultural Water Management* 100 (1): 25-35. <https://doi.org/10.1016/j.agwat.2011.08.015>.
- Garofalo, Simone Pietro, Vincenzo Giannico, Leonardo Costanza, Salem Alhajj Ali, Salvatore Camposeo, Giuseppe Lopriore, Francisco Pedrero Salcedo, y Gaetano Alessandro Vivaldi. 2023. «Prediction of Stem Water Potential in Olive Orchards Using High-Resolution Planet Satellite Images and Machine Learning Techniques». *Agronomy* 14 (1): 1. <https://doi.org/10.3390/agronomy14010001>.
- Garreaud, René D., Juan P. Boisier, Roberto Rondanelli, Aldo Montecinos, Hector H. Sepúlveda, y Daniel Veloso-Aguila. 2020. «The Central Chile Mega Drought (2010–2018): A climate dynamics perspective». *International Journal of Climatology* 40. <https://doi.org/10.1002/joc.6219>.
- González, Manuel. 2022. «La inserción comercial chilena en China: El caso de las cerezas». Universidad de Chile.
- Greenwell, Brandon, M., y Bradley Boehmke C. 2020. «Variable Importance Plots—An Introduction to the vip Package». *The R Journal* 12 (1): 343. <https://doi.org/10.32614/RJ-2020-013>.
- Halbritter, Aud H., Amy Eycott, Sabine Reinsch, y Hans De Boeck. 2020. «The handbook for standardised field and laboratory measurements in terrestrial climate-change experiments and observational studies (ClimEx)». *Methods in Ecology and Evolution* 11 (1): 22-37.
- Hurlbert, Margot, y Joyeeta Gupta. 2017. «The adaptive capacity of institutions in Canada, Argentina, and Chile to droughts and floods». *Regional Environmental Change* 17. <https://doi.org/10.1007/s10100-017-1232-0>.

- //doi.org/10.1007/s10113-016-1078-0.
- Jamshidi, Sajad, Shahrokh Zand-Parsa, y Dev Niyogi. 2021. «Assessing Crop Water Stress Index of Citrus Using In-Situ Measurements, Landsat, and Sentinel-2 Data». *International Journal of Remote Sensing* 42 (5): 1893-1916. <https://doi.org/10.1080/01431161.2020.1846224>.
- Jiménez-Suancha, Sonia Constanza, Oscar Humberto Álvarado S., y Helber Enrique Balaguera-López. 2015. «Fluorescencia como indicador de estrés en *< i>Helianthus annuus* L. Una revisión». *Revista Colombiana de Ciencias Hortícolas* 9. <https://doi.org/10.17584/rcch.2015v9i1.3753>.
- Jones, H. G. 2004. «Irrigation scheduling: advantages and pitfalls of plant-based methods». *Journal of Experimental Botany* 55 (407): 2427-36. <https://doi.org/10.1093/jxb/erh213>.
- Küpper, Hendrik, Zuzana Benedikty, Filis Morina, Elisa Andresen, Archana Mishra, y Martin Trtílek. 2019. «Analysis of OJIP Chlorophyll Fluorescence Kinetics and QA Reoxidation Kinetics by Direct Fast Imaging». *Plant Physiology* 179 (febrero): 369-81.
- Lee, Kang M., Steven M. Driever, Ep Heuvelink, Simon Rüger, Ulrich Zimmermann, Arie De Gelder, y Leo F. M. Marcelis. 2012. «Evaluation of diel patterns of relative changes in cell turgor of tomato plants using leaf patch clamp pressure probes». *Physiologia Plantarum* 146 (4): 439-47. <https://doi.org/10.1111/j.1399-3054.2012.01637.x>.
- Linke, Manfred, Werner B. Herppich, y Martin Geyer. 2010. «Green peduncles may indicate postharvest freshness of sweet cherries». *Postharvest Biology and Technology* 58. <https://doi.org/10.1016/j.postharvbio.2010.05.014>.
- López-Olivari, R., y F. Ortega-Klose. 2021. «Response of red clover to deficit irrigation: dry matter yield, populations, and irrigation water use efficiency in southern Chile». *Irrigation Science* 39. <https://doi.org/10.1007/s00271-020-00693-0>.
- Marsal, Jordi, G. Lopez, J. del Campo, M. Mata, A. Arbones, y J. Girona. 2010. «Postharvest regulated deficit irrigation in 'Summit' sweet cherry: Fruit yield and quality in the following season». *Irrigation Science* 28. <https://doi.org/10.1007/s00271-009-0174-z>.
- McCutchan, Harold, y K. A. Shackel. 2019. «Stem-water Potential as a Sensitive Indicator of Water Stress in Prune Trees (*Prunus domestica* L. cv. French)». *Journal of the American Society for Horticultural Science* 117. <https://doi.org/10.21273/jashs.117.4.607>.
- Meinzer, Frederick C., David R. Woodruff, Danielle E. Marias, Duncan D. Smith, Katherine A. McCulloh, Ava R. Howard, y Alicia L. Magedman. 2016. «Mapping "hydroscapes" along the iso- to anisohydric continuum of stomatal regulation of plant water status». Editado por Josep Penuelas. *Ecology Letters* 19 (11): 1343-52. <https://doi.org/10.1111/ele.12670>.
- Microsoft Open Source, Matt McFarland, Rob Emanuele, Dan Morris, y Tom Augspurger. 2022. «microsoft/PlanetaryComputer: October 2022». Zenodo. <https://zenodo.org/record/7261897>.
- Moreno, González, Perales Vela, y Martha O Salcedo Alvarez. 2008. «LA FLUORESCENCIA DE LA CLOROFILA a COMO HERRAMIENTA EN LA INVESTIGACIÓN DE EFECTOS TÓXICOS EN EL APARATO FOTOSINTÉTICO DE PLANTAS Y ALGAS». *Revista de Educación Bioquímica* 27.
- Morianas, A., D. Pérez-López, M. H. Prieto, M. Ramírez-Santa-Pau, y J. M. Pérez-Rodriguez. 2012. «Midday stem water potential as a useful tool for estimating irrigation requirements

- in olive trees». *Agricultural Water Management* 112 (septiembre): 43-54. <https://doi.org/10.1016/j.agwat.2012.06.003>.
- Naor, A. 2000. «MIDDAY STEM WATER POTENTIAL AS A PLANT WATER STRESS INDICATOR FOR IRRIGATION SCHEDULING IN FRUIT TREES». *Acta Horticulturae*, n.º 537 (octubre): 447-54. <https://doi.org/10.17660/ActaHortic.2000.537.52>.
- Pechan, Paul, Fabian Obster, Marchioro Linda, y Bohle Heidi. 2023. «Climate change impact on fruit farm operations in Chile and Tunisia.Climate change impact on fruit farm operations in Chile and Tunisia.» *AgriRxiv*, enero.
- Peña-Guerrero, M. D., A. Nauditt, C. Muñoz-Robles, L. Ribbe, y F. Meza. 2020. «Drought impacts on water quality and potential implications for agricultural production in the Maipo River Basin, Central Chile». *Hydrological Sciences Journal* 65. <https://doi.org/10.1080/02626667.2020.1711911>.
- Savchik, Peter, Mallika Nocco, y Isaya Kisekka. 2025. «Mapping almond stem water potential using machine learning and multispectral imagery». *Irrigation Science* 43 (1): 105-20. <https://doi.org/10.1007/s00271-024-00932-8>.
- Scholander, P. F., H. T. Hammel, E. A. Hemmingsen, y E. D. Bradstreet. 1964. «HYDROSTATIC PRESSURE AND OSMOTIC POTENTIAL IN LEAVES OF MANGROVES AND SOME OTHER PLANTS». *Proceedings of the National Academy of Sciences* 52 (1): 119-25. <https://doi.org/10.1073/pnas.52.1.119>.
- Tin Kam Ho. 1995. «Random decision forests». En *Proceedings of 3rd International Conference on Document Analysis and Recognition*, 1:278-82. Montreal, Que., Canada: IEEE Comput. Soc. Press. <https://doi.org/10.1109/ICDAR.1995.598994>.
- Tyree, M. T., y H. T. Hammel. 1972. «The Measurement of the Turgor Pressure and the Water Relations of Plants by the Pressure-bomb Technique». *Journal of Experimental Botany* 23 (1): 267-82. <https://doi.org/10.1093/jxb/23.1.267>.
- Yoon, Tae Myung, y Hanno Richter. 1990. «Seasonal changes in stomatal responses of sweet cherry and plum to water status in detached leaves». *Physiologia Plantarum* 80. <https://doi.org/10.1111/j.1399-3054.1990.tb05673.x>.
- Zhang, Tianxiang, Jinya Su, Cunjia Liu, Wen-Hua Chen, Hui Liu, y Guohai Liu. 2017. «Band selection in sentinel-2 satellite for agriculture applications». En *2017 23rd International Conference on Automation and Computing (ICAC)*, 1-6. Huddersfield, United Kingdom: IEEE. <https://doi.org/10.23919/IConAC.2017.8081990>.