

Informe ID21I10297

M. Abel Herrera y Francisco Zambrano

2025-04-05

Tabla de contenidos

Acerca del Informe	8
Prefacio	9
Introducción	10
I Materiales y métodos	12
1 Área de estudio	13
1.1 Tratamientos de riego deficitario	14
2 Datos	15
2.1 In-situ	15
2.1.1 Potencial hídrico xilemático y fluorescencia	15
2.1.2 Producción y calidad de la fruta	16
2.2 Remotos	16
2.2.1 Sentinel 2	16
3 Producción y parámetros de calidad de la fruta	18
4 Modelado espacial diario de Ψ_s	19
4.1 Predictores espacio-temporales	19
4.1.1 Variables meteorológicas	19
4.1.2 Índices vegetacionales	27
4.2 Modelos de machine learning	27
4.3 Evaluación e importancia de los modelos	29
II Resultados y análisis	30
5 Producción y calidad	31
5.1 Producción	31
5.1.1 Peso total	31
5.1.2 Densidad	31

5.2	Calidad	34
5.2.1	Peso	34
5.2.2	Calibre	34
5.2.3	Color	37
5.2.4	Contenido de azucar	37
5.2.5	Daño	37
6	Parámetros fisiológicos	42
6.1	Fluorescencia	42
7	Series temporales	43
8	Distribución por mes	44
8.1	Potencial	44
9	Series temporales	46
10	Distribución por mes	47
10.1	LAI	47
11	Series temporales	49
12	Distribución por mes	50
13	Curvas Presión-volumen	51
13.1	La Esperanza	52
13.1.1	Tratamiento 0 (control)	52
13.1.2	Tratamiento 4	53
13.2	Rio Claro	54
13.2.1	Tratamiento 0 (control)	54
13.2.2	Tratamiento 1	55
13.2.3	Tratamiento 2	56
13.2.4	Tratamiento 3	57
13.2.5	Tratamiento 4	58
14	Punto de pérdida de turgor	60
III	Preprocesamiento de datos de turgor	62
15	Clustering	66
15.1	La Esperanza	66
16	T1 (2022-2023)	67

17 T2 (2022-2023)	69
18 T3 (2022-2023)	71
19 T4 (2022-2023)	73
20 T1 (2023-2024)	75
21 T2 (2023-2024)	77
22 T3 (2023-2024)	79
23 T4 (2023-2024)	81
23.1 Rio Claro	82
24 T1 (2022-2023)	83
25 T2 (2022-2023)	85
26 T3 (2022-2023)	87
27 T4 (2022-2023)	89
28 T1 (2023-2024)	91
29 T2 (2023-2024)	93
30 T3 (2023-2024)	95
31 T4 (2023-2024)	97
32 Limpieza de datos: eliminación de clusters	99
32.1 La Esperanza	99
33 T1 (2022-2023)	100
34 T2 (2022-2023)	102
35 T3 (2022-2023)	104
36 T4 (2022-2023)	106
37 T1 (2023-2024)	108
38 T2 (2023-2024)	110
39 T3 (2023-2024)	112

40 T4 (2023-2024)	114
40.1 Rio Claro	115
41 T1 (2022-2023)	116
42 T2 (2022-2023)	118
43 T3 (2022-2023)	120
44 T4 (2022-2023)	122
45 T1 (2023-2024)	124
46 T2 (2023-2024)	125
47 T3 (2023-2024)	127
48 T4 (2023-2024)	129
49 Estandarización de clusters	131
49.1 La Esperanza	131
50 T1 (2022-2023)	132
51 T2 (2022-2023)	134
52 T3 (2022-2023)	136
53 T4 (2022-2023)	138
54 T1 (2023-2024)	140
55 T2 (2023-2024)	142
56 T3 (2023-2024)	144
57 T4 (2023-2024)	146
57.1 Rio Claro	147
58 T1 (2022-2023)	148
59 T2 (2022-2023)	150
60 T3 (2022-2023)	152
61 T4 (2022-2023)	154

62 T1 (2023-2024)	156
63 T2 (2023-2024)	157
64 T3 (2023-2024)	159
65 T4 (2023-2024)	161
66 Datos preprocesados	163
66.1 A nivel de unidad	163
66.1.1 La Esperanza	163
67 T1 (2022-2023)	164
68 T2 (2022-2023)	167
69 T3 (2022-2023)	170
70 T4 (2022-2023)	173
71 T1 (2023-2024)	176
72 T2 (2023-2024)	179
73 T3 (2023-2024)	182
74 T4 (2023-2024)	185
74.0.1 Rio Claro	187
75 T1 (2022-2023)	188
76 T2 (2022-2023)	191
77 T3 (2022-2023)	194
78 T4 (2022-2023)	197
79 T1 (2023-2024)	200
80 T2 (2023-2024)	202
81 T3 (2023-2024)	205
82 T4 (2023-2024)	208
82.1 A nivel de tratamiento	210
82.1.1 La Esperanza	210

83 T1 (2022-2023)	211
84 T2 (2022-2023)	212
85 T3 (2022-2023)	213
86 T4 (2022-2023)	214
87 T1 (2023-2024)	215
88 T2 (2023-2024)	216
89 T3 (2023-2024)	217
90 T4 (2023-2024)	218
91 T1 (2022-2023)	219
92 T2 (2022-2023)	220
93 T3 (2022-2023)	221
94 T4 (2022-2023)	222
95 T1 (2023-2024)	223
96 T2 (2023-2024)	224
97 T3 (2023-2024)	225
98 T4 (2023-2024)	226
IV Modelo de potencial y SatOri	227
99 Modelos predictivos de potencial	228
100SatOri	232
100.1Descripción general	232
100.2Diseño de la aplicación	232
100.2.1 Funcionamiento de la aplicación	232
100.3Dashboard de la plataforma	233
100.4Acceso a la plataforma	234
References	235

Acerca del Informe

Reporte general del proyecto ID21I10297, financiado por la Agencia Nacional de Investigación y Desarrollo (ANID) por medio del proyecto FONDEF IDEA 2021.

Este proyecto estuvo a cargo del director Dr. Francisco Zambrano Bigiarini de la Universidad Mayor.

Investigadores que participaron en el proyecto:

- Dr. Francisco Zambrano - Director - Centro Hemera UMayor
- Dra. Andrea Miyasaka Almeyda - Directora Alterna - Centro CGB UMayor
- Dr. Felipe de La Hoz - Investigador - Externo
- Paulina Vidal - Investigadora - Centro Hemera UMayor
- Idania Briceño - Investigadora - Centro Hemera UMayor

Además, trabajaron como asistentes de investigación los siguientes profesionales:

- Jesica Garrido - Centro Hemera UMayor
- Abel Herrera - Centro Hemera UMayor

Prefacio

Este informe presenta metodología y los resultados obtenidos en el marco del proyecto FONDEF ID21I10297. En este proyecto se desarrolló **SatOri**, una aplicación para la optimización de riego en frutales. La que contribuye a la adaptación al cambio climático de la agricultura chilena.

SatOri desarrolló un modelo para la estimación espacial con frecuencia diaria del potencial hídrico xilemático (Ψ_x). El Psi_x permite monitorear la respuesta de la planta a las condiciones medio ambientales y de abastecimiento hídrico. Se utilizaron algoritmos de machine learning, datos meteorológicos y de imágenes satelitales Sentinel-2, para el desarrollo del modelo.

Por otra parte, **SatOri** calcula el nivel de Psi_x mínimo que pueden alcanzar los árboles. De esta manera establece un semáforo de acuerdo a este umbral y a los resultados del modelo. Indicando al agricultor cuánto es el tiempo de riego que debe suministrar cada sector, para que no se vea afectado el aparato fotosintético de la planta y así no haya merma en la producción y calidad de la fruta.

Introducción

El cambio global ha provocado una intensificación de la sequía en distintas áreas del mundo. Entre ellas, Chile Central se caracteriza por presentar un evento de Mega Sequía con pocos análogos en los últimos milenios, registrando desde el 2010 una secuencia ininterrumpida de años con déficits de lluvia promedio de un 20-40% (Garreaud et al. 2020). Este tipo de fenómenos puede llegar a tener importantes impactos en la disponibilidad de agua en cantidad y calidad necesaria para actividades agrícolas, pudiendo repercutir de manera significativa sobre factores sociales y económicos (Garreaud et al. 2020; Peña-Guerrero et al. 2020). Ante este escenario, se requieren estrategias de gestión del agua más eficientes que permitan a los productores agrícolas adaptarse a la variabilidad climática (Hurlbert y Gupta 2017).

En este contexto, el riego deficitario controlado (RDC) ha sido identificado como una estrategia eficaz para optimizar el uso del agua en cultivos perennes como los frutales, donde las opciones de adaptación son limitadas (Pechan et al. 2023). Esta práctica permite reducir el consumo hídrico sin afectar significativamente la producción ni la calidad de la cosecha, mejorando la eficiencia del recurso disponible (Victor Blanco et al. 2019; López-Olivari y Ortega-Klose 2021). Entre los frutales de exportación, el cerezo es el segundo producto de mayor valor en la agroindustria chilena, con más de 25.000 hectáreas bajo riego y un mercado aproximado de 1.560 millones de dólares (Carrasco-Benavides, Antunez-Quilobrán, et al. 2020; González 2022). La optimización del riego en este cultivo es fundamental para mejorar la sostenibilidad del sector y mantener su competitividad a nivel internacional. Para ello, el potencial hídrico del xilema (Ψ_s) —medido a mediodía (Ψ_s)— se ha establecido como un indicador confiable del estado hídrico de la planta, reflejando tanto las condiciones del suelo como la demanda atmosférica y la respuesta fisiológica del cultivo (Moriana et al., 2012; Naor, 2000). Su medición tradicional, mediante cámaras de presión (Scholander et al., 1964), es laboriosa y poco escalable, lo que ha impulsado el desarrollo de métodos alternativos basados en sensores remotos y modelos predictivos (Jones, 2004).

Avances recientes en teledetección y aprendizaje automático han permitido estimar indirectamente el Ψ_s mediante el uso de datos espectrales y meteorológicos, ofreciendo una solución escalable para el manejo del riego en tiempo real (Carrasco-Benavides et al., 2022; Garofalo et al., 2023; Savchik et al., 2024). Satélites como Sentinel-2 (S2), con su alta resolución espacial y frecuencia de revisita, permiten monitorear el estado hídrico de los cultivos a través de índices espectrales y térmicos, que actúan como proxies del estrés hídrico (Addabbo et al., 2016; Jamshidi et al., 2021; Zhang et al., 2017). Estudios recientes han demostrado la viabilidad de predecir el Ψ_s en cultivos como almendros, olivos y cerezos mediante algoritmos de machine learning, como Random Forest y redes neuronales,

alcanzando precisiones variables según las condiciones ambientales y las técnicas empleadas (Savchik et al., 2024; Garofalo et al., 2023; Carrasco-Benavides et al., 2022).

La presente investigación tiene como objetivo principal desarrollar un prototipo de servicio web (SatOri) para la optimización del riego en cerezo, integrando datos de Sentinel-2 y estaciones meteorológicas para predecir la variación espaciotemporal del Ψ_s . Para ello, se plantean los siguientes objetivos específicos: (i) evaluar tres algoritmos de machine learning (Random Forest, XGBoost y SVM) utilizando estrategias de validación temporal y espacial; (ii) implementar el modelo de mejor desempeño en una plataforma web que entregue recomendaciones de riego en tiempo real; y (iii) evaluar la respuesta de los cerezos a distintos tratamientos de RDC mediante el monitoreo de parámetros fisiológicos (Ψ_s , conductancia estomática), variables productivas (rendimiento) y calidad de fruta (calibre, apariencia, sólidos solubles). Este enfoque integral no solo busca mejorar la sostenibilidad del recurso hídrico, sino también validar estrategias de RDC que mantengan la competitividad del sector cerecero frente a los desafíos climáticos actuales.

Parte I

Materiales y métodos

1 Área de estudio

El estudio se llevó a cabo en cultivos de cerezos (*Prunus avium* L., variedad Regina) ubicados en dos predios pertenecientes a la propiedad de la compañía [Garcés Fruit](#): campos “La Esperanza” y “Río Claro” (ambos ubicados en la Región O’ Higgins; Figura 1.1a y Figura 1.1b). En cada uno de ellos se seleccionó una parcela, la cual fue a su vez subdividida en 5 grupos. Esta unidad experimental estuvo constituida por 40 árboles agrupados en 8 filas y 5 columnas (400 m²). Todas las unidades presentaron las mismas condiciones de fertilización, poda, control de malezas y de plagas, las cuales se ajustaron a los estándares y prácticas habituales de Garcés Fruit, siendo la principal diferencia entre ellos el tratamiento de irrigación aplicado.

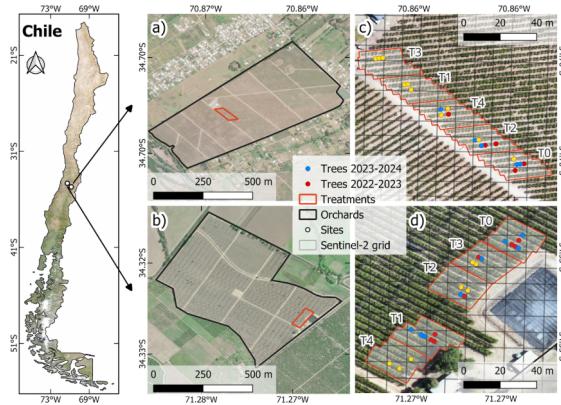


Figura 1.1: Área de estudio. El mapa a la izquierda muestra la ubicación de los huertos en la región central de Chile. Los mapas a la derecha muestran los huertos en (a) Río Claro y (b) La Esperanza, y (c) y (d) representan los tratamientos de riego (T0, T1, T2, T3, T4). Los puntos rojos y azules representan los árboles experimentales seleccionados para las temporadas 2022-2023 y 2023-2024, respectivamente, mientras que los puntos amarillos indican los árboles seleccionados para ambas temporadas.

El clima de la región es mediterráneo (tipo Csb según la clasificación de Beck et al., 2018), con precipitaciones moderadas que oscilan entre 200 y 500 mm año⁻¹ en los últimos 10 años. Las lluvias se concentran en invierno, seguido de una estación seca prolongada de 7 a 8 meses (DMC, 2024). Cada huerto cuenta con una estación meteorológica privada ubicada a 0.6 km del centro en Río Claro y 1.4 km del centro en La Esperanza, respectivamente.

1.1 Tratamientos de riego deficitario

Para aumentar la variabilidad del estado hídrico de las plantas, se implementaron cinco tratamientos diferentes de reposición de riego en cada huerto. La cantidad de riego se gestionó utilizando el ET₀ y Ψ_s como referencias. Los tratamientos de riego fueron T₁, T₂, T₃ y T₄, siendo T₁ el menos restrictivo y T₄ el más restrictivo en cuanto al suministro de agua (Figura 1.1c y Figura 1.1d). Además, se estableció un tratamiento control (T₀), el cual recibió el riego estándar proporcionado por el productor local. Cada parcela de tratamiento contuvo 60 árboles y abarcó un área de 0.048 ha. Los tratamientos se aplicaron durante las temporadas consecutivas de crecimiento 2022–2023 y 2023–2024. No obstante, en la segunda temporada no se aplicaron los tratamientos T₁ a T₄ en La Esperanza, ya que los resultados obtenidos en la temporada anterior no mostraron un impacto significativo de los tratamientos de restricción hídrica. La Figura 1.2 ilustra la profundidad acumulada de agua (mm) para cada tratamiento durante el riego, así como el porcentaje relativo a ET₀.

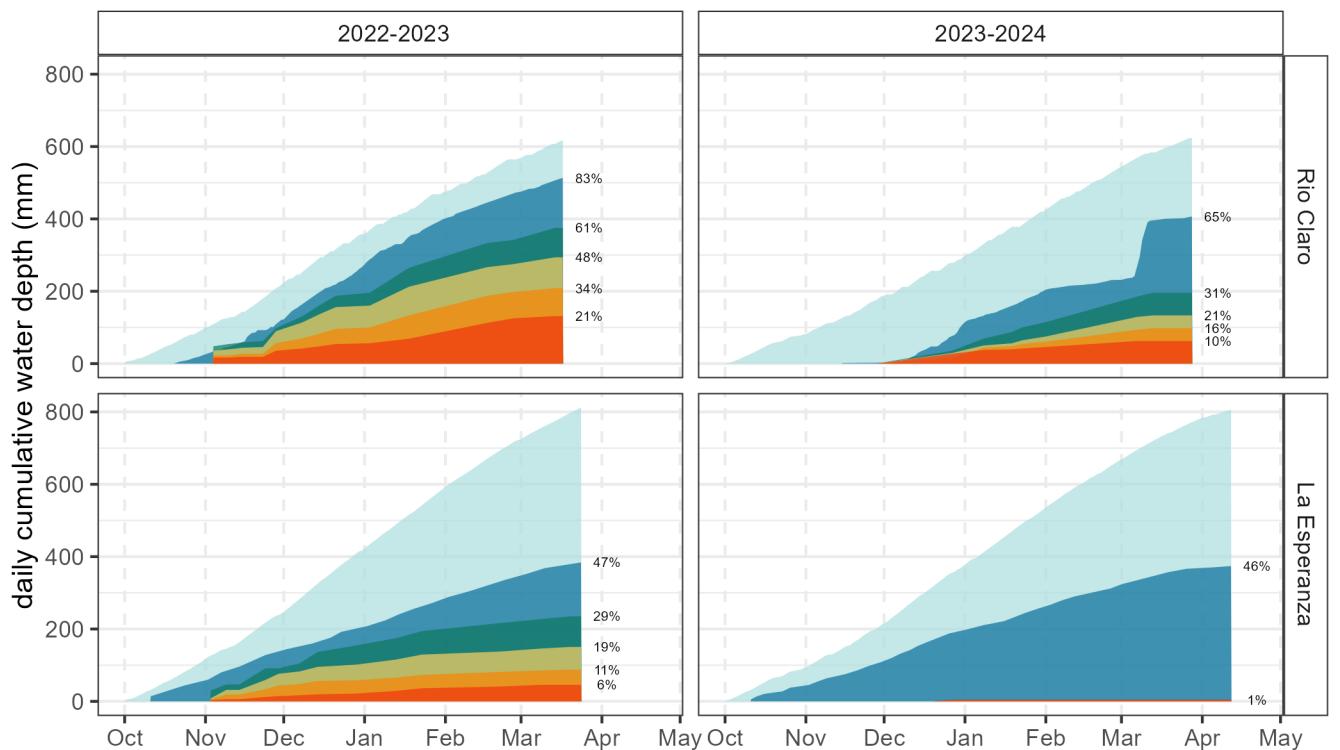


Figura 1.2: Variación de la profundidad acumulada diaria de agua (mm) aplicada por riego por tratamiento en comparación con la evapotranspiración de referencia (ET₀). El punto de inicio para la acumulación de ET₀ corresponde al primer día de riego para cada huerto y temporada.

2 Datos

2.1 In-situ

2.1.1 Potencial hídrico xilemático y fluorescencia

Posterior a la instalación del sistema de riego diferenciado, se seleccionaron 3 árboles por tratamiento (un total de 15 árboles por campo), teniendo en consideración el efecto de borde, esto con el propósito de monitorear en el tiempo el estatus hídrico de cada planta (3 réplicas por tratamiento). Para ello se emplearon 2 indicadores: (1) Potencial hídrico xilemático al mediodía; cuyas mediciones son consideradas el proxy más preciso del estado hídrico para los cerezos dulces (Víctor Blanco et al. 2019; Victor Blanco et al. 2019; Carrasco-Benavides, Meza, et al. 2020; Carrasco-Benavides, Antunez-Quilobrán, et al. 2020; E et al. 2023). (2) Fluorescencia; el cual constituye un indicador de eficacia de la actividad e integridad de la fotosíntesis y el contenido de la clorofila; lo que permite estudiar mecanismos de respuesta ante condiciones de estrés hídrico (Linke, Herppich, y Geyer 2010; Jiménez-Suancha, S., y Balaguera-López 2015).

Para medición de los indicadores anteriormente mencionados se realizaron visitas quincenales a cada campo. En lo que respecta a la medición del potencial hídrico xilemático (Ψ_s), la misma se realizó sobre muestras de hojas colectadas entre 12:00-14:00 h provenientes de cada una de los 15 árboles monitoreados. En cada caso, se seleccionaron hojas maduras y en buen estado, ubicadas en el tercio medio del árbol, con orientación este y cercanas al tronco (McCutchan y Shackel 2019; Marsal et al. 2010; Víctor Blanco et al. 2019). Antes de ser cortadas, cada una de ellas fue envuelta por un período de 30 min en bolsas de papel de aluminio, a modo de lograr bloquear la transpiración y la radiación solar. Posterior a este período, cada hoja fue cortada por el pecíolo y colocada al interior de la cámara Scholander conectada a un cilindro de nitrógeno (Modelo 3000, Soil Moisture Equipment, Santa Barbara, CA, EEUU), donde se aplicó presión negativa hasta observar gotas de agua en el extremo del pecíolo cortado, registrándose la cantidad de megapascales (MPa) necesarios para extraer la primera gota de jugo xilemático.

En lo que respecta a la medición de la fluorescencia, se usó el fluorómetro PAR-FluorPen FP 110/D (PSI, Czech), empleando el método de transitorios de fluorescencia OJIP. Este método permitió obtener diferentes parámetros de rendimiento cuántico de la actividad fotosintética en el PSII y evaluar el potencial impacto del riego deficitario sobre este proceso (Küpper et al. 2019). Para obtener una medida de los parámetros de fluorescencia de la clorofila,

el fluorómetro consta de un medidor de luz integrado para lecturas digitales directas de la radiación fotosintéticamente activa en el rango 400 a 700 nm. Para lograr una emisión de fluorescencia roja, es necesario exponer a la luz, hojas que previamente se encontraban adaptadas a la oscuridad (Moreno, Vela, y O Salcedo Alvarez 2008). Con este fin, el equipo consta de unos dispositivos o “clips”, que se colocan en la hoja previamente y que permiten bloquear todo acceso de luz a una porción de la misma. En nuestro caso, se utilizaron 4 clips por árbol del muestreo, los cuales fueron colocados entre las 11:00-13:00 h, seleccionando hojas que se encontrasen maduras, en buen estado, dentro del tercio medio del árbol y orientadas directamente al sol. Pasado el período de adaptación a la oscuridad (20 minutos), se procedió a hacer las mediciones directas con el fluorómetro, el cual dispone de una memoria interna que permite almacenar los datos de manera secuencial. A efecto de los análisis se utilizaron los siguientes indicadores: F_v/F_m o Φ_{P_0} (máxima eficiencia quántica del Fotosistema II), F_o (valor mínimo de fluorescencia) y F_v/F_o (razón entre fluorescencia máxima y mínima)

2.1.2 Producción y calidad de la fruta

Las cosechas se llevaron a cabo siguiendo el cronograma y la planificación de Garcés Fruit. Las mismas se realizaron el 12/12 del 2022 y 2023 en el campo La Esperanza y el 21/12 del 2022 en el campo Río Claro. En ambos casos, se recolectó la totalidad de los frutos de los 15 árboles que componían el muestreo (3 réplicas por tratamiento). Posteriormente, utilizando una balanza electrónica modelo SF-400 (peso máximo 10kg), se colectó al azar el equivalente de un 1kg de cerezas por cada árbol, los cuales fueron almacenados en envases plásticos y refrigerados en coolers para su posterior traslado al laboratorio.

Una vez en el laboratorio, las muestras de 1 Kg de cerezas por árbol fueron almacenadas en un refrigerador a 4°C. En un plazo menor de 72 h cada una de ellas fue analizada para evaluar la calidad de fruto, de manera de evitar degradaciones relacionadas con el tiempo de almacenamiento. Para ello, se tomó una submuestra al azar de 20 cerezas por árbol, siguiendo una metodología similar a Víctor Blanco et al. (2019), para un total de 60 cerezas por tratamiento. La única condición para que una cereza fuese seleccionada, es que la misma se encuentre en buen estado, esto para disminuir la probabilidad de desviaciones relacionadas con daños experimentados durante el traslado e incurrir en el error de medir cerezas defectuosas.

2.2 Remotos

2.2.1 Sentinel 2

La misión S2 consta de dos satélites idénticos, S2A y S2B, ambos equipados con un sensor multiespectral que cuenta con 13 bandas espectrales que cubren las regiones visible, infrarrojo cercano e infrarrojo de onda corta, con resoluciones espaciales de 10, 20 y 60 m (ver Tabla S2).

En este estudio, utilizamos un total de 106 imágenes S2 (A/B): 54 para la temporada 2022-2023 y 52 para la 2023-2024, capturadas entre octubre y mayo en ambos huertos (cuadrícula T19HCB para La Esperanza y T19HBB para Río Claro). Las imágenes se obtuvieron de la colección corregida atmosféricamente S2 Level-2A de Planetary Computer (Microsoft Open Source et al., 2022), con una frecuencia de 5 días y aproximadamente a las 14:30 hora local (UTC-4). Una máscara fue aplicada basándose en la capa de clasificación de escena (SCL) para los valores correspondientes a “Cloud Shadows,” “Cloud Medium Probability,” y “Cloud High Probability.”

3 Producción y parámetros de calidad de la fruta

Para determinar la producción de los cerezos, se midieron dos variables: el peso total de la cosecha y la densidad de frutos. El peso total (kg) se obtuvo mediante el pesaje directo de la producción de cada árbol en campo, utilizando una balanza digital modelo ACS-30 LED con una capacidad máxima de 30 kg. Por otro lado, la densidad de frutos (frutos/kg) se determinó dividiendo el conteo total de cerezas recolectadas entre el peso total correspondiente.

Las muestras de 1 kg de cada árbol almacenadas y refrigeradas fueron examinadas de manera meticulosa en su totalidad, contabilizando aquellas cerezas que presentarán deformaciones y defectos en su forma o superficie, tales como pitting, pudrición, fisuras pronunciadas, sobremaduración, daños en la piel, palidez y frutos dobles. Se guardó registro fotográfico de las cerezas identificadas con daños para su posterior revisión y categorización en el laboratorio. Para esta caracterización se usó como base la guía Australian Cherry Quality Guide (disponible: <https://www.cherrygrowers.org.au>).

Por el otro lado, la calidad de las frutas se evaluó considerando las siguientes variables asociadas a los estándares comerciales: peso por unidad (gr), calibre (diametro; mm) y color. Para medir peso (gr) se utilizó una balanza analítica de laboratorio, mientras que para estimar el calibre se empleó un pie de metro digital (0-150 mm). En lo que respecta al color, se siguió la carta de color y la metodología recomendada por el Instituto Nacional de Tecnología Agropecuaria (INTA) (disponible en: <https://inta.gob.ar/documentos/carta-de-color-y-calibre-para-la-cosecha-de-cerezas>). Para ello se empleó una escala numérica del 1-6 , la cual variaba desde un rojo pálido (1) a un caoba oscuro (6). Finalmente, de cada sub-muestra se seleccionaron al azar 5 cerezas adicionales (15 por tratamientos), con las mismas se procedió a medir concentración de sólidos solubles (grados brix) utilizando para ello el refractómetro ATC (Brix 0-32) (Víctor Blanco et al. 2019).

4 Modelado espacial diario de Ψ_s

4.1 Predictores espacio-temporales

4.1.1 Variables meteorológicas

Las variables meteorológicas utilizadas en el desarrollo del modelo de potencial hídrico xilemático (Ψ_s) se obtuvieron a partir de estaciones meteorológicas automáticas en ambos huertos, las cuales registraron datos cada 15 minutos utilizando el modelo ATMOS-41 del grupo METER. Estas variables fueron temperatura (T°), humedad relativa (HR), déficit de presión de vapor (VPD), precipitación (PP) y evapotranspiración de referencia (ET0).

4.1.1.1 Temperatura

4.1.1.2 Humedad Relativa

4.1.1.3 Déficit de presión de vapor (VPD)

4.1.1.4 Evapotranspiración de referencia (ET0)

4.1.1.5 Precipitación

Además de las variables meteorológicas, también se recopilaron datos de humedad del suelo. Para esto, se utilizaron sensores de humedad del suelo Water Scout SM100 (Spectrum Technologies, Inc.), los cuales miden en tiempo real el contenido volumétrico de agua (VWC). Estos sensores se instalaron a 15 cm de profundidad bajo cada árbol de los tratamientos.

4.1.1.6 Temporada 2022-2023

4.1.1.7 Temporada 2023-2024

Para revisar los procedimientos específicos empleados o analizar los resultados de la temporada 2022-2023 de manera independiente, se recomienda acceder al reporte completo en el siguiente [enlace](#).

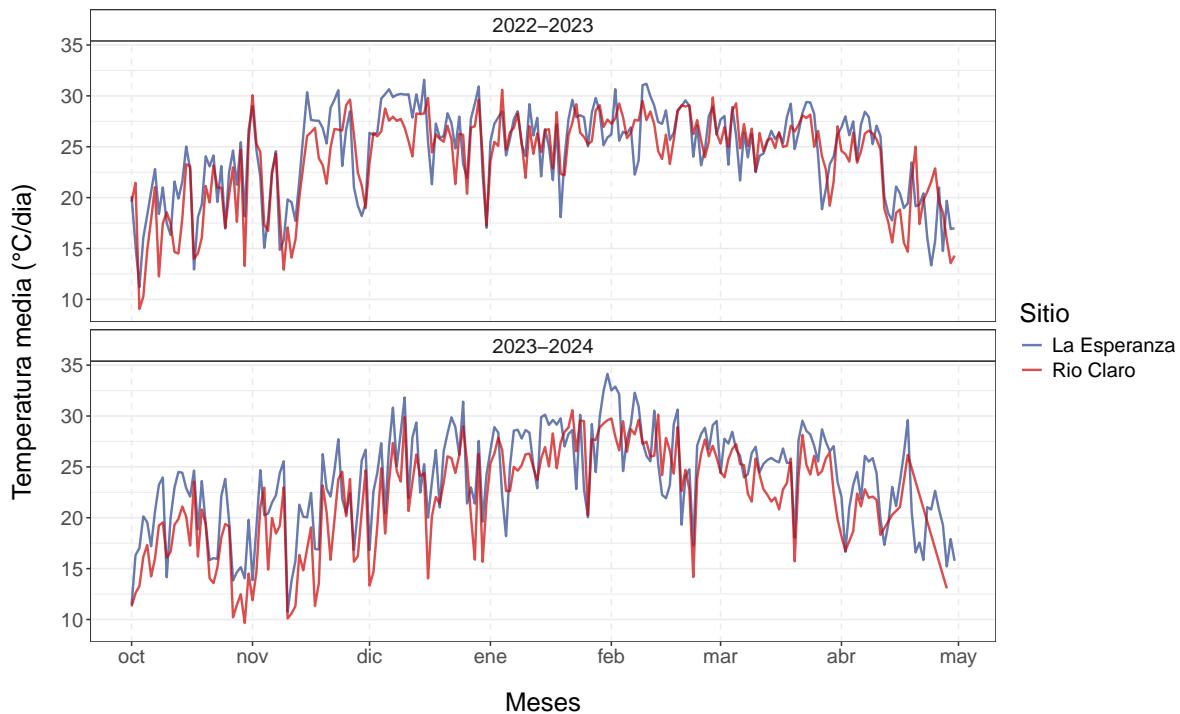


Figura 4.1: Variación de la temperatura media diaria ($^{\circ}\text{C}$) del medio día en La Esperanza y Río Claro durante las temporadas 2022-2023 y 2023-2024.

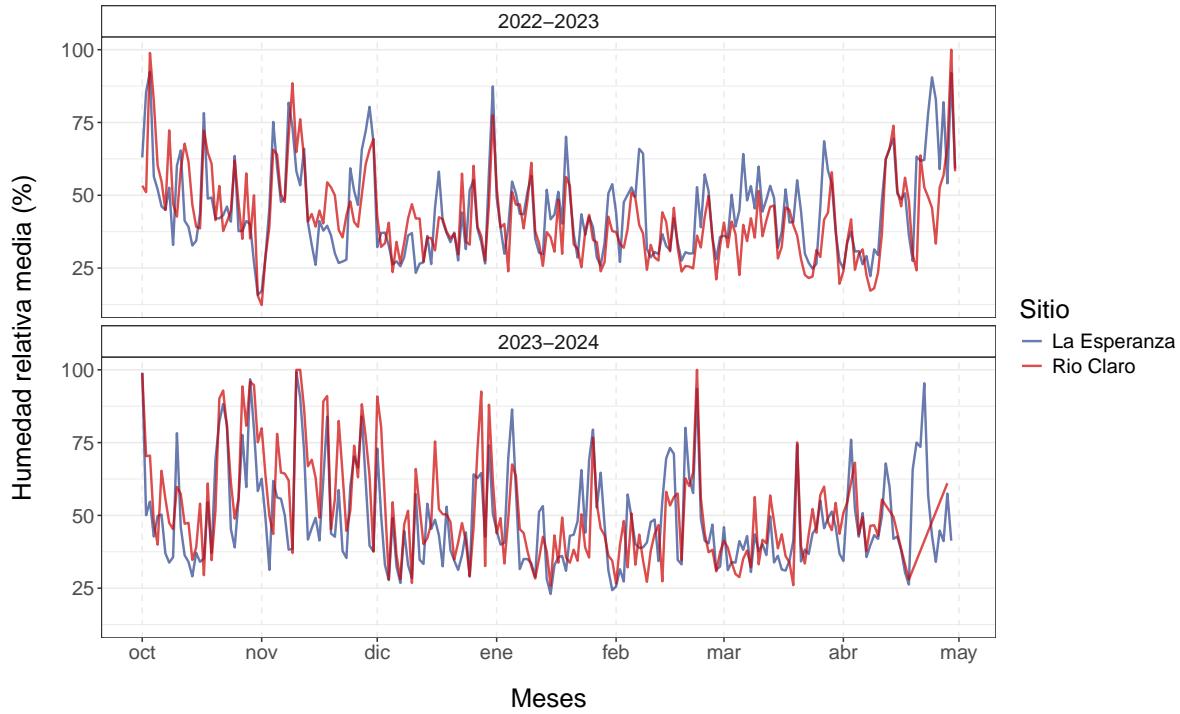


Figura 4.2: Variación de la humedad relativa media diaria (%) del medio día en La Esperanza y Río Claro durante las temporadas 2022-2023 y 2023-2024.

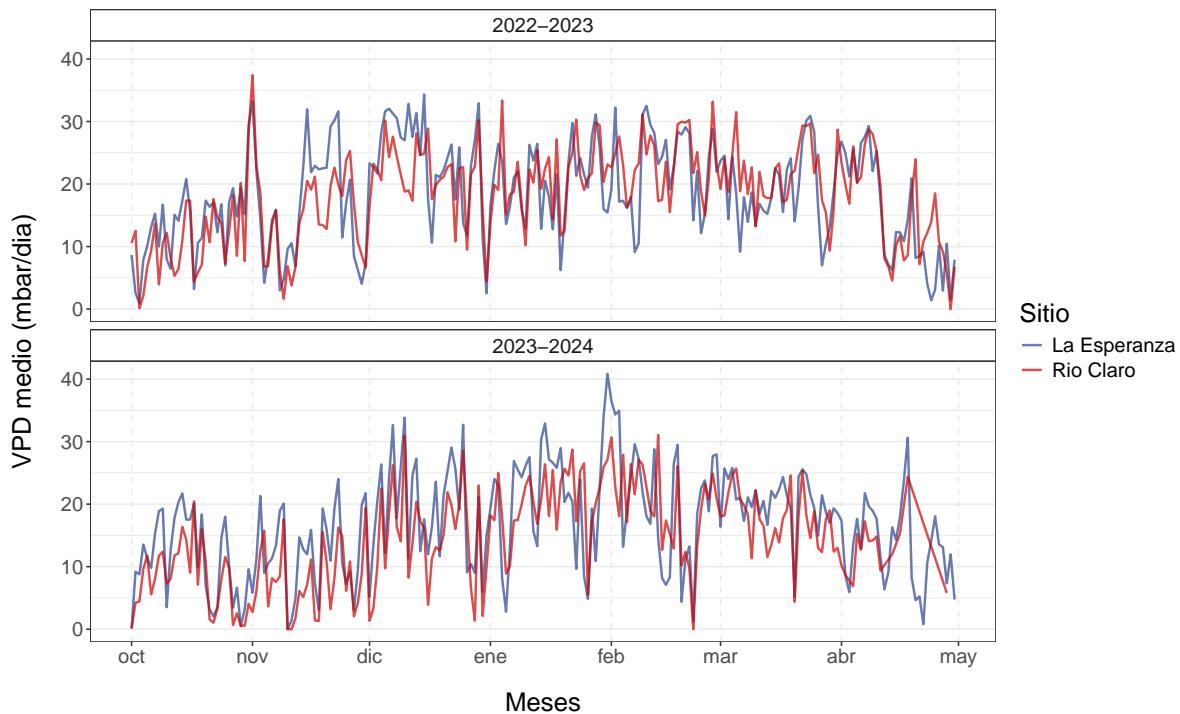


Figura 4.3: Variación del VPD medio (mbar/dia) del medio día en La Esperanza y Río Claro durante las temporadas 2022-2023 y 2023-2024.

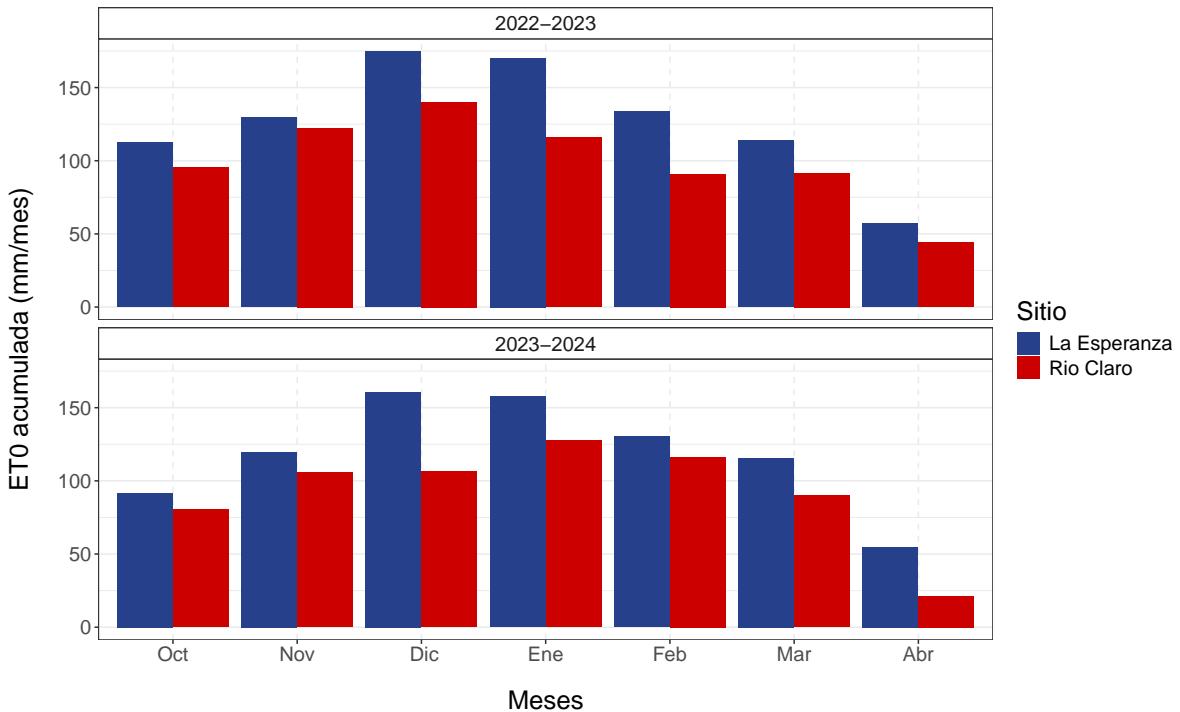


Figura 4.4: Variación de la evapotranspiración de referencia acumulada mensual (mm) en La Esperanza y Río Claro durante las temporadas 2022-2023 y 2023-2024.

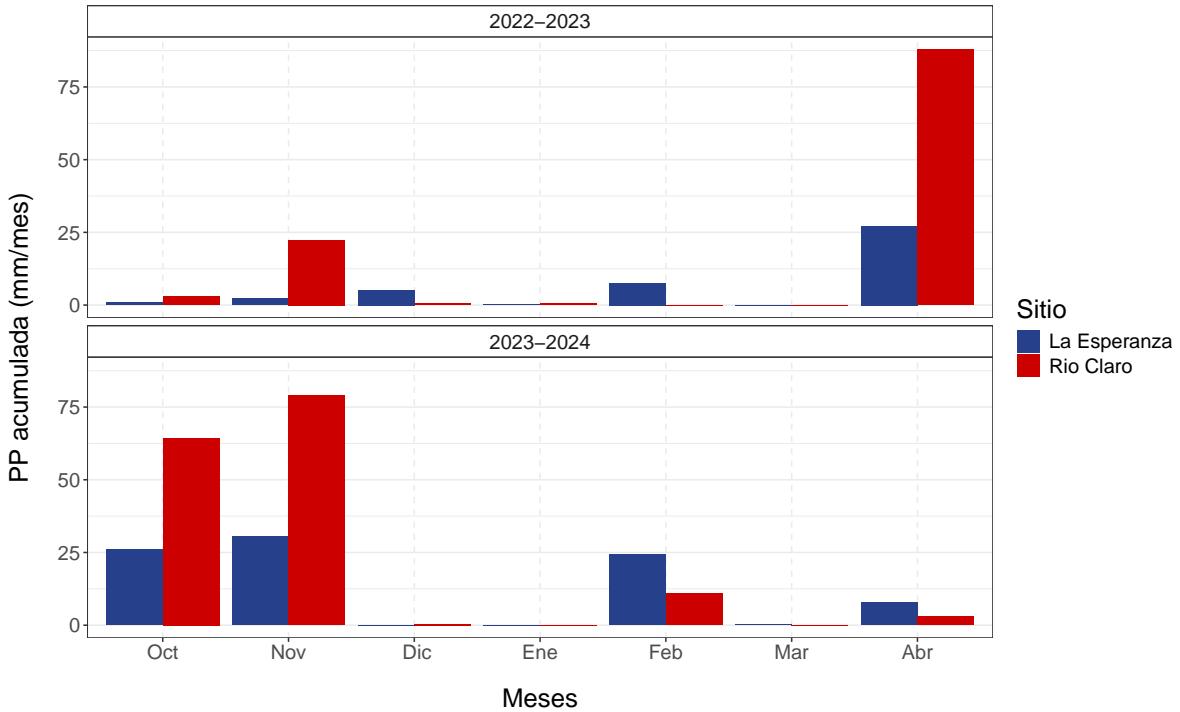
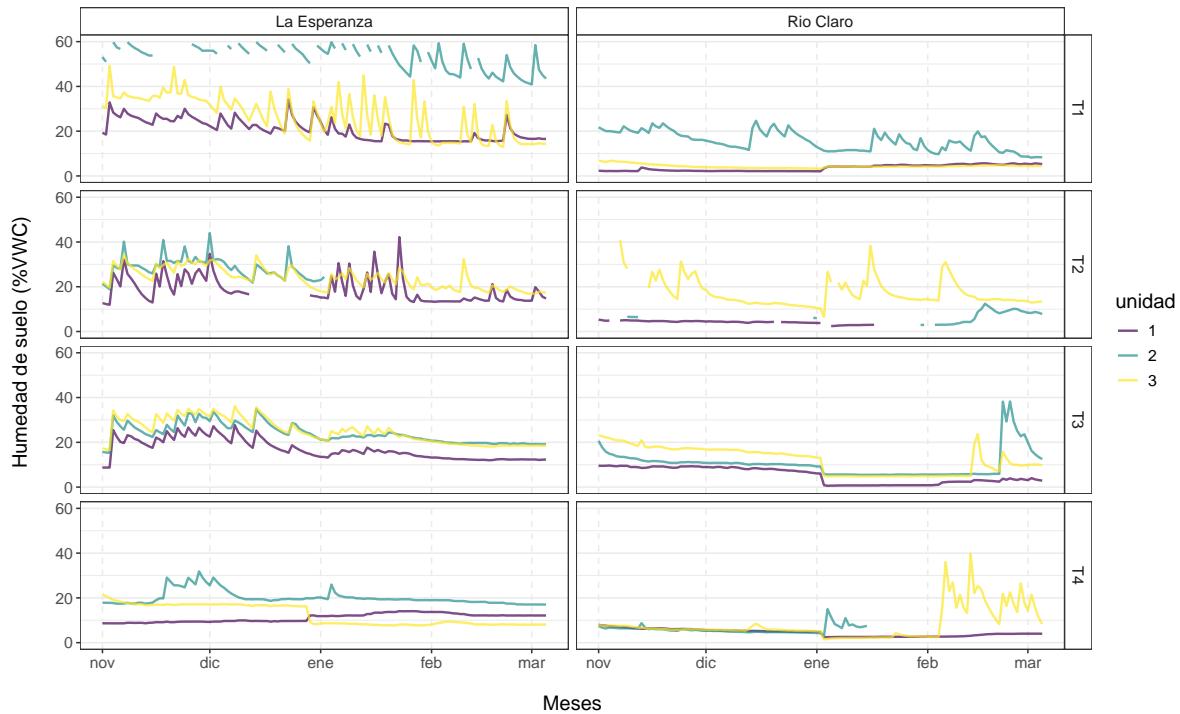
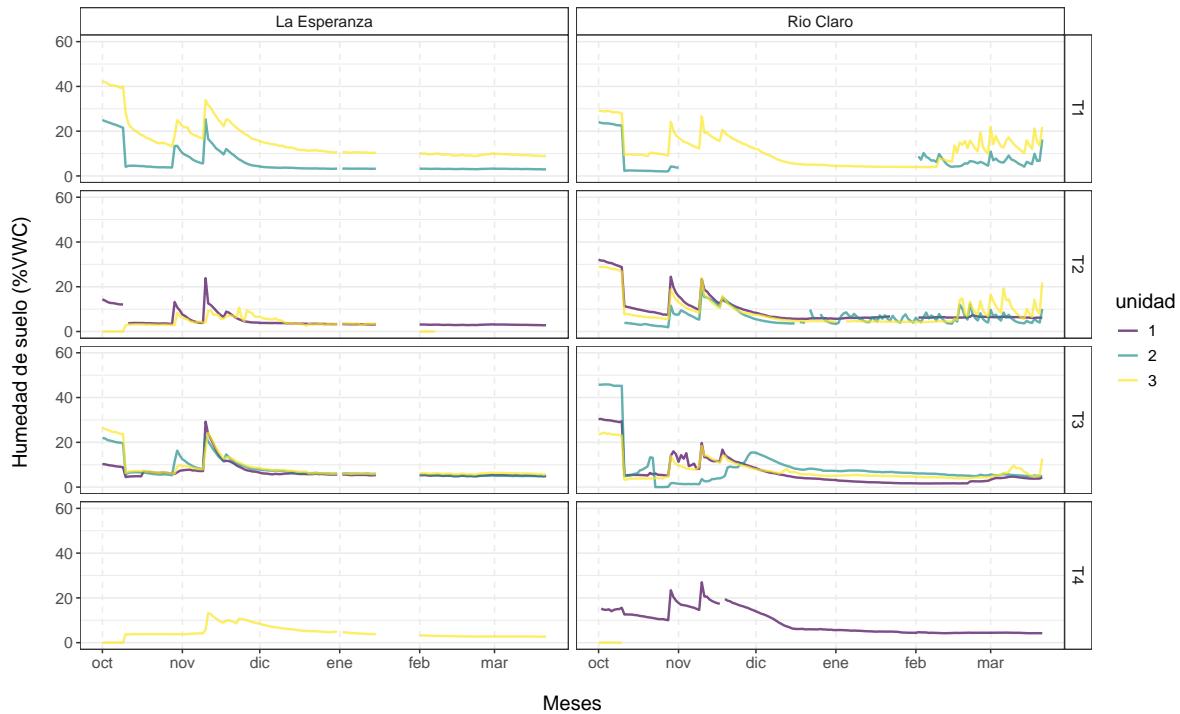


Figura 4.5: Variación de la precipitación acumulada mensual (mm) en La Esperanza y Río Claro durante las temporadas 2022-2023 y 2023-2024.





4.1.2 Índices vegetacionales

Se derivaron dieciséis índices de vegetación (IVs) relacionados con la condición de las plantas —vigor, estrés, funcionalidad fotosintética y contenido hídrico— a partir de datos de Sentinel-2 (S2), como se detalla en la Tabla 2. De estos, nueve índices no incorporaron información del red-edge (borde rojo), calculándose exclusivamente con bandas espectrales del visible, infrarrojo cercano (NIR) e infrarrojo de onda corta (SWIR): NDVI, EVI, GCI, NDWI, NBR, NDMI, MSI, NMDI y DWSI. Por otro lado, siete índices —CLr, Clg, NDRE1, NDRE2, NDCI, mSR705 y RESI— se obtuvieron mediante las bandas del red-edge. Todos los índices fueron calculados a partir de las imágenes preprocesadas de las bandas de S2, generándose series temporales para cada IV en ambos huertos y temporadas.

Para reconstruir las series temporales (ej. en zonas afectadas por nubosidad), se aplicó un suavizado mediante regresión polinomial local (LOESS) (Cleveland, 1979). El método LOESS se configuró con un parámetro de suavizado (span) de 0.3, obteniéndose así series diarias continuas y suavizadas para cada índice, las cuales posteriormente fueron extraídas para cada árbol medido. Se llevó a cabo un análisis de correlación para evaluar la relación entre estas series suavizadas y los valores observados de Ψ_s . El coeficiente de correlación de Pearson (r) fue calculado diariamente para cada árbol, huerto y temporada, utilizando exclusivamente correlaciones significativas ($p\text{-value} < 0.05$) para el cálculo de los valores promedio.

4.2 Modelos de machine learning

Para modelar el Ψ_s , se evaluaron tres algoritmos de machine learning:

- **Extreme Gradient Boosting** (XGBoost; Chen y Guestrin, 2016)
- **Random Forest**(RF; Ho, 1995)
- **Support vector Machine** (SVM; Cortes y Vapnik, 1995)

Los dos primeros métodos se basan en árboles de decisión, mientras que el tercero utiliza vectores de soporte. Estos modelos fueron seleccionados por ser considerados de vanguardia, requerir un número reducido de muestras de entrenamiento (en comparación con redes neuronales) y ofrecer interpretabilidad. Todos los algoritmos pueden emplearse tanto para clasificación como para regresión. En este estudio, se realizó un análisis de regresión, utilizando el Ψ_s como variable respuesta y 21 predictores: cinco meteorológicos y 16 índices de vegetación (IVs).

El conjunto de datos incluyó mediciones de 26 fechas en la temporada 2022–2023 y 34 en la 2023–2024 (total: 60 fechas). Para cada fecha, se tomaron 30 mediciones (15 por huerto: Río Claro y La Esperanza), lo que resultó en un total de 883 observaciones. El proceso de modelado siguió las siguientes etapas:

- **Preparación y división de datos:** Segmentación del conjunto de datos en subconjuntos de entrenamiento y prueba.
- **Optimización de hiperparámetros:** Ajuste de los parámetros de los algoritmos utilizando el conjunto de entrenamiento.
- **Remuestreo:** Evaluación de la confiabilidad del modelo e identificación de las variables más relevantes para estimar Ψ_s .
- **Validación:** Evaluación del rendimiento del modelo con métricas de desempeño.

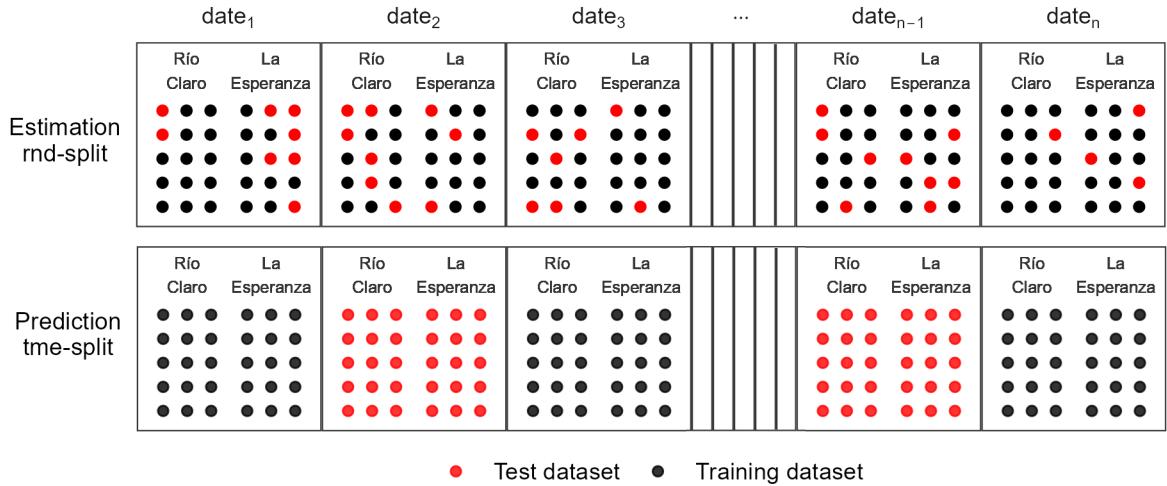


Figura 4.8: Esquemas de división utilizados para agrupar los conjuntos de entrenamiento y prueba: división aleatoria (rnd_split) y división temporal independiente (tme_split).

Se entrenaron los tres modelos utilizando dos esquemas de división (Figura 4.8): uno que consideró una división aleatoria de datos de entrenamiento y prueba (rnd_split) y otro que utilizó fechas independientes para entrenamiento y prueba (tme_split). En ambos casos, se seleccionó el 75% de los datos para entrenamiento y el 25% para prueba. Se aplicaron tres tipos de preprocesamiento a los datos de entrenamiento: i) eliminación de predictores con valores constantes (variables de varianza cero); ii) normalización de predictores (media cero y desviación estándar uno); y iii) una versión del modelo que empleó Partial Least Squares (PLS) para reducir la dimensionalidad, utilizando las cinco componentes principales como predictores. Como resultado, se usaron modelos con predictores normalizados y otros con las componentes principales de PLS.

Para ajustar los parámetros de los modelos (XGBoost, RF, SVM), se empleó optimización de hiperparámetros. Se definieron rangos para cada parámetro y se utilizaron cinco folds de validación cruzada para ambos esquemas de división (rnd_split y tme_split). La optimización evaluó diez combinaciones de parámetros por modelo. El rendimiento se midió con las métricas

R^2 , RMSE (root-mean-square error) y MAE (mean absolute error). Finalmente, los modelos se clasificaron según el RMSE más bajo y el R^2 más alto, seleccionándose aquellos con mejor desempeño.

4.3 Evaluación e importancia de los modelos

Para evaluar el rendimiento de los modelos, se aplicó remuestreo (resampling) sobre el conjunto de entrenamiento en ambos esquemas de división (rnd_split y tme_split). Se utilizaron cinco particiones y se calcularon las métricas R^2 , MAE (Error Absoluto Medio) y RMSE (Raíz del Error Cuadrático Medio) para cada una de estas.

En cuanto a la importancia de variables, el modelo de Bosques Aleatorios (RF) empleó un método de permutación *out-of-bag* en cada árbol, permutando los predictores y calculando el error cuadrático medio para cada instancia. Para XGBoost, se estimó la contribución fraccional de cada variable según la ganancia total en las divisiones donde participó. En el caso de SVM, se calcularon puntuaciones de importancia basadas en permutaciones (para más detalles, véase Greenwell y Boehmke, 2020).

Parte II

Resultados y análisis

5 Producción y calidad

5.1 Producción

5.1.1 Peso total

La Figura 5.1 muestra el peso total de los árboles según tratamiento, sitio y temporada, evidenciando diferencias tanto entre sitios como entre temporadas. En La Esperanza, no se observaron diferencias significativas entre tratamientos en ninguna de las dos temporadas. En 2022-2023, T4 presentó el mayor peso (17 kg), seguido por T0 (16.4 kg), mientras que T1 registró el menor valor (10.5 kg), con una diferencia de 5.83 kg respecto a T0. En 2023-2024, los valores fueron menores en general, con T3 alcanzando el mayor peso (6.18 kg) y T4 el menor (5.18 kg), situándose 0.59 kg por debajo de T0 (5.78 kg). En Río Claro, T2 mostró el mayor peso total (16.9 kg), superando en 0.76 kg a T0 (16.1 kg), mientras que T4 presentó el menor valor (11.9 kg), siendo 4.16 kg inferior a T0. En esta localidad, solo T2 y T4 fueron significativamente diferentes entre sí. A nivel temporal, en La Esperanza, el peso total del árbol fue significativamente menor en la segunda temporada en todos los tratamientos, reflejando una disminución generalizada en el rendimiento.

5.1.2 Densidad

La Figura 5.2 muestra la densidad de frutos por kilogramo según tratamiento, sitio y temporada, sin diferencias significativas entre tratamientos dentro de cada sitio y temporada, excepto en La Esperanza, donde T4 presentó una mayor densidad en la segunda temporada. En La Esperanza 2022-2023, T4 tuvo la menor densidad (89 frutos/kg), 4 frutos menos que T0 (93 frutos/kg), mientras que T2 alcanzó el mayor valor (98 frutos/kg), seguido por T3. En 2023-2024, los valores fueron similares, con T2 registrando la menor densidad (91 frutos/kg, apenas 1 fruto/kg menos que T0) y T1 la mayor (105 frutos/kg). En Río Claro, T0 mostró la menor densidad (97 frutos/kg), seguido por T4 (114 frutos/kg), mientras que T3 alcanzó el mayor valor (185 frutos/kg), superando en 88 frutos/kg a T0. A nivel temporal, solo en T4 de La Esperanza se observó un aumento significativo en la segunda temporada, lo que sugiere una mayor cantidad de frutos por kilogramo en ese tratamiento.

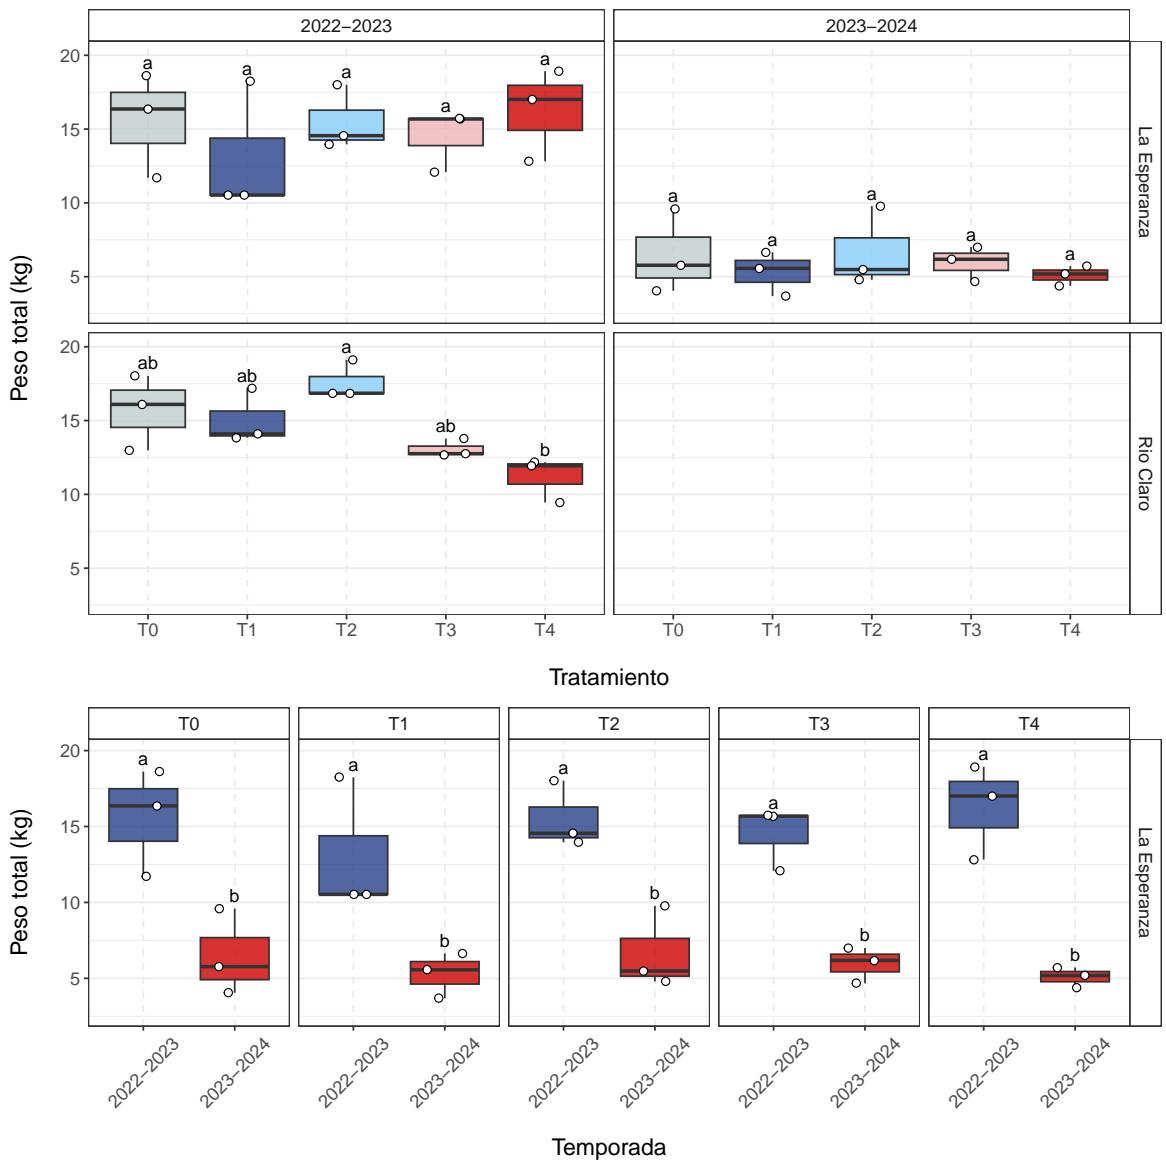


Figura 5.1: Comparación del peso total de producción por unidad de árbol (kg) según tratamiento, sitio y temporada.

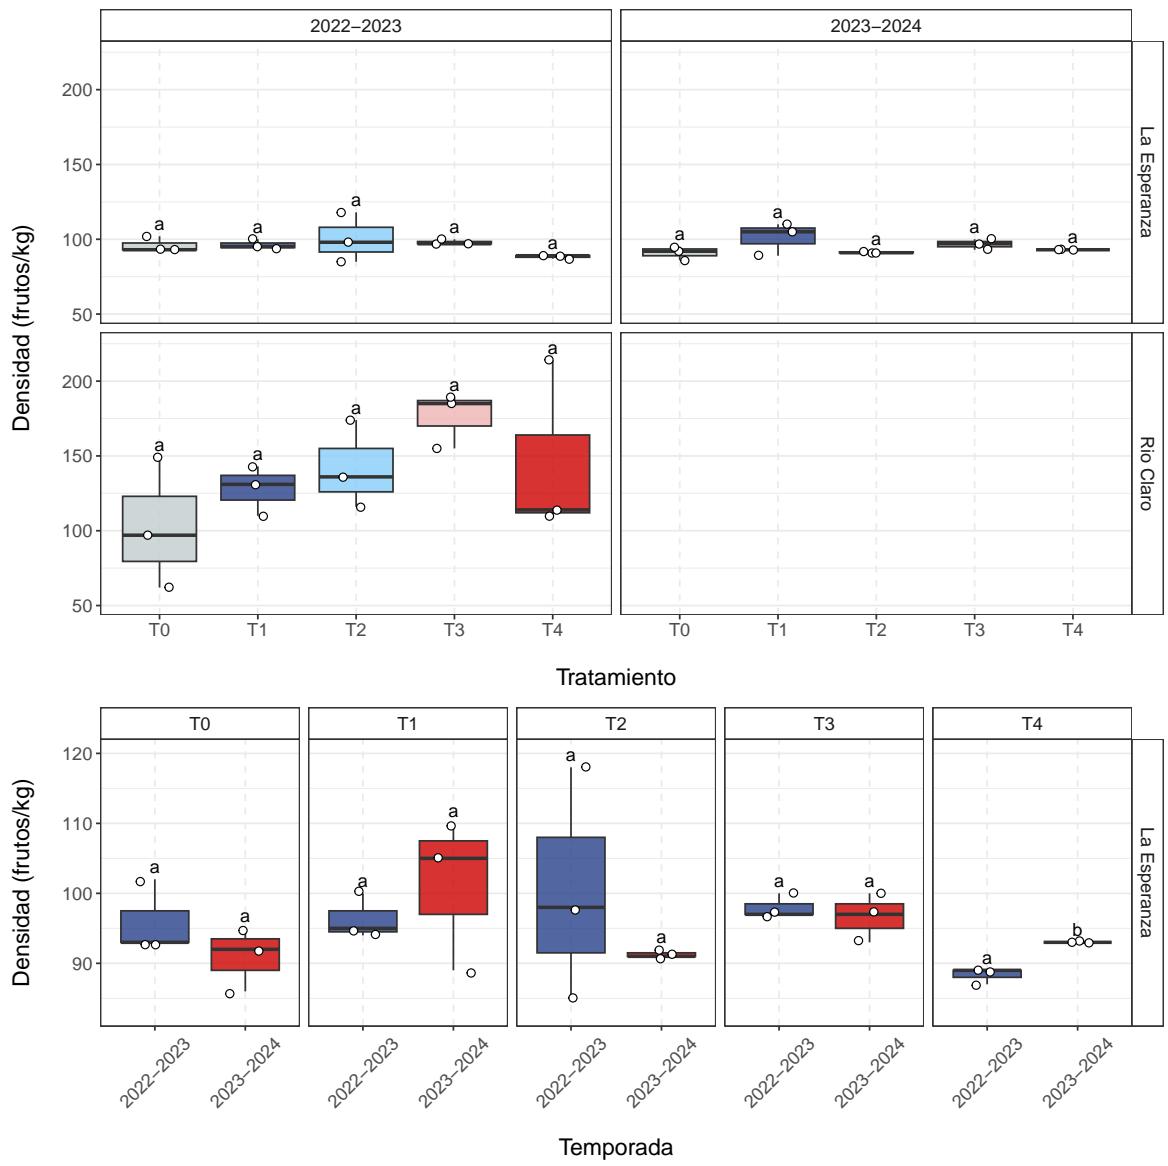


Figura 5.2: Comparación de la densidad de producción por unidad de árbol (frutos/kg) según tratamiento, sitio y temporada.

5.2 Calidad

5.2.1 Peso

La Figura 5.3 muestra la distribución del peso por unidad de cereza según tratamiento, sitio y temporada, evidenciando diferencias significativas entre tratamientos y un mejor desempeño en La Esperanza respecto a Río Claro. En La Esperanza (2022-2023), T4 presentó la mayor mediana (11.7 g), superando en 1 g al control T0 (10.7 g), mientras que T2 tuvo la menor (10 g); todos los tratamientos superaron el estándar comercial XL (6 g), con un 95-100% de frutos en esta categoría. En 2023-2024, T0 alcanzó la mediana más alta (11.2 g), seguido de T2 (11 g), manteniéndose todos los tratamientos sobre la talla XL (95-100% XL). En contraste, Río Claro (2022-2023) mostró un menor rendimiento, con T3 registrando la mediana más baja (5.85 g) y solo un 38.3% de frutos talla XL, mientras que T0 alcanzó 10.8 g y 90% XL. En esta localidad y temporada, se observaron las únicas diferencias significativas entre tratamientos, donde todos presentaron valores significativamente menores que T0 y, además, T3 fue significativamente menor que el resto. En La Esperanza, las diferencias entre temporadas fueron menos marcadas, con T2 mostrando un incremento en 2023-2024. Estos resultados reflejan la influencia del tratamiento y la localidad en la calidad de la cosecha, con un rendimiento consistentemente superior en La Esperanza.

5.2.2 Calibre

La Figura 5.4 muestra el calibre de los frutos por tratamiento, sitio y temporada. En La Esperanza 2022–2023, T2 presentó el menor diámetro (mediana = 25 mm), siendo significativamente inferior a todos los tratamientos, mientras que T4 alcanzó el mayor calibre (27 mm), siendo superior a T3, pero no difirió significativamente de T0 ni T1. Durante 2023–2024, los valores se incrementaron levemente: T1 presentó la menor mediana (27 mm), 0.7 mm por debajo de T0 (27.7 mm), y T4 la más alta (27.8 mm), mostrando diferencias significativas solo con T3. En ambos años, los frutos de T4 destacaron por mantener consistentemente el 100% de frutos dentro de los estándares comerciales L (22 mm) y XL (24 mm). En contraste, T2 mostró en 2022–2023 un 5% de frutos fuera del estándar mínimo, con apenas un 76.7% dentro del calibre XL. En Río Claro, todos los tratamientos difirieron significativamente entre sí, excepto T2 y T4. T0 presentó el mayor calibre (27.2 mm), mientras que T3 fue el más bajo (21.4 mm), con el 68.3% de frutos por debajo de la medida L y solo el 6.67% cumpliendo la XL. Temporalmente, en La Esperanza, T0, T2 y T4 mostraron un aumento significativo de calibre en 2023–2024 respecto a la temporada anterior, reforzando la mejora en la proporción de frutos comerciales, especialmente en T2, donde la proporción de calibre XL aumentó de 76.7% a 95%.

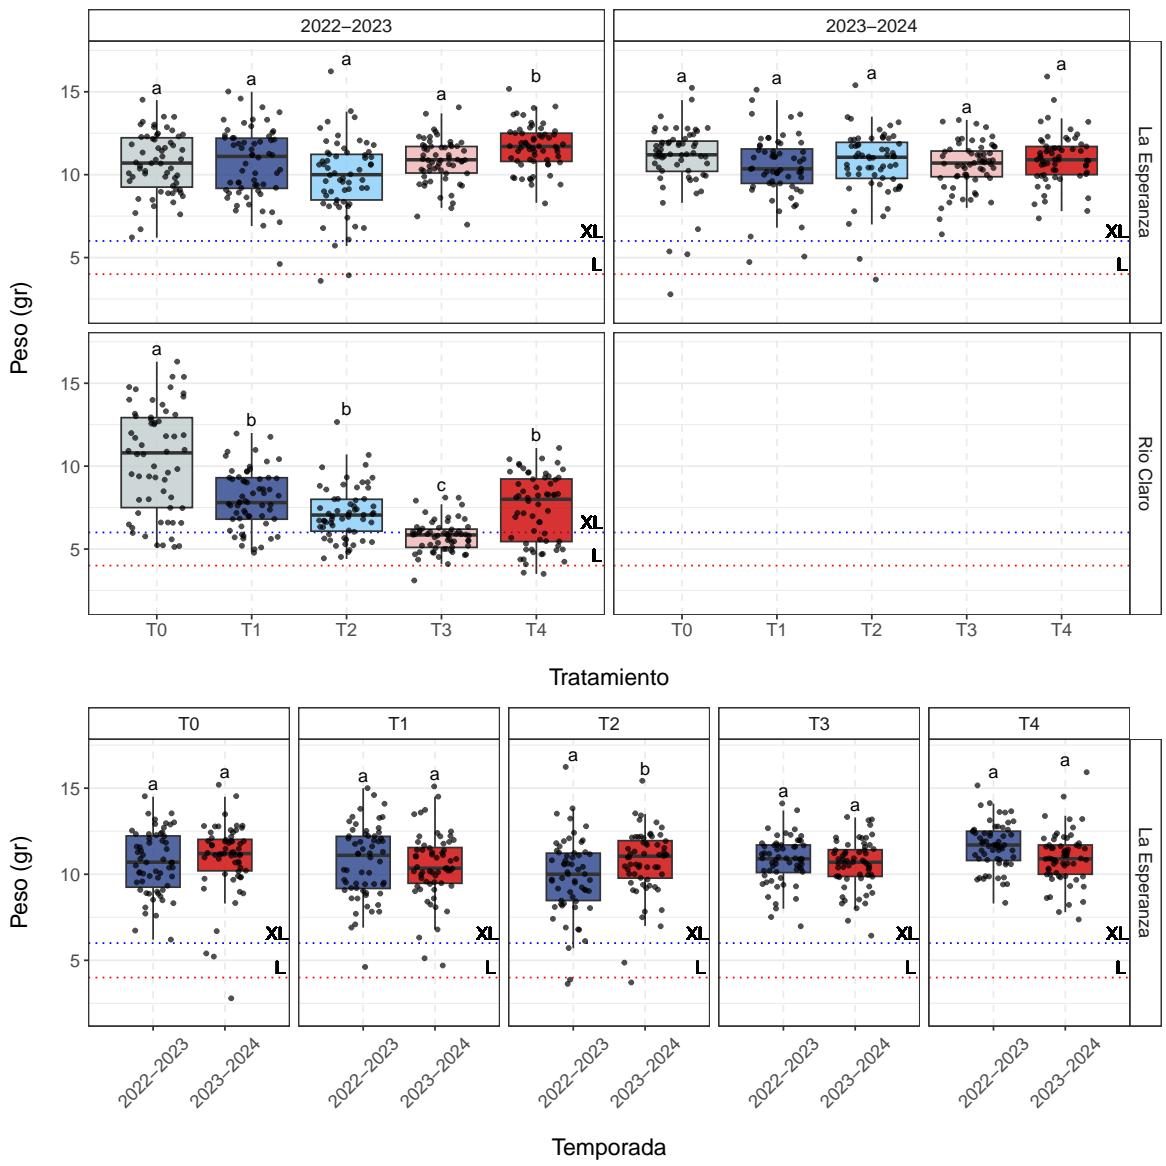


Figura 5.3: Comparación del peso de una unidad de cereza (gr) según tratamiento, sitio y temporada.

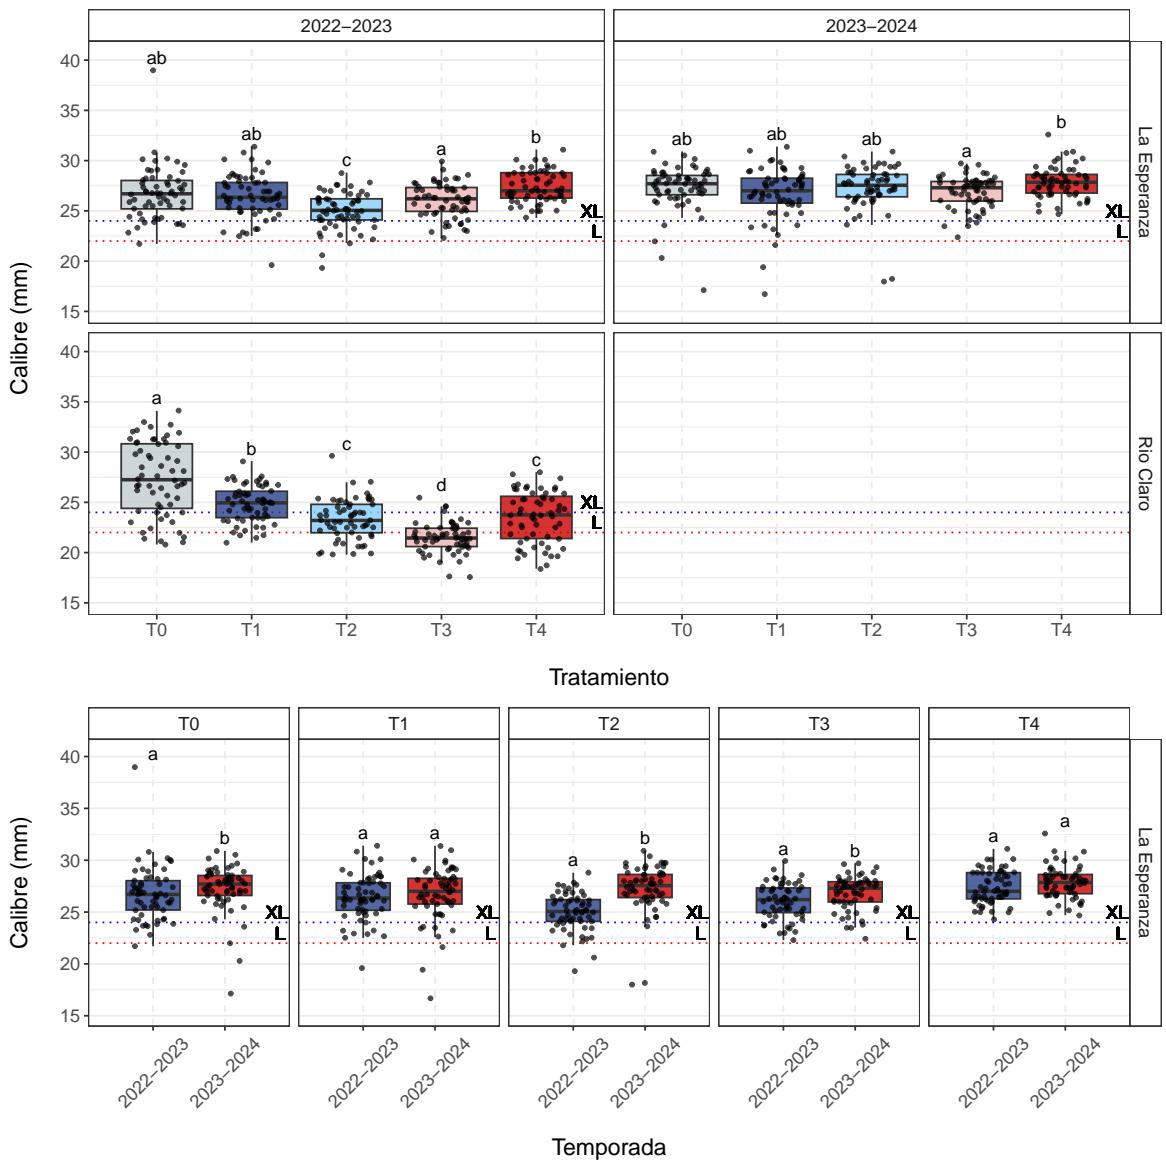


Figura 5.4: Comparación del calibre de una unidad de cereza (mm) por tratamiento según sitio y temporada.

5.2.3 Color

La Figura 5.5 presenta la distribución del color de las cerezas por tratamiento, sitio y temporada, en una escala de 1 a 6 donde los valores entre 4 y 5 (tonalidad caoba) corresponden a la categoría de mayor valoración comercial. En La Esperanza 2022–2023, T2 y T3 mostraron las medianas más bajas (4.5), siendo T2 significativamente inferior a todos los tratamientos salvo T3. En contraste, T4 alcanzó una mediana de 5, siendo significativamente superior a T2 pero no diferente de T0 ni T1. Las proporciones de frutos en categoría caoba fueron altas en todos los tratamientos (71.7–88.3%), destacando T4 con 88.3%. En 2023–2024, la mediana se redujo a 4 en la mayoría de los tratamientos, excepto T2 (4.5), que fue significativamente superior a T0 y T4. A pesar de esto, T2 alcanzó el mayor porcentaje de frutos caoba (90%), mientras que T0 y T4 descendieron a 51.7% y 56.7%, respectivamente. En Río Claro, T0 y T1 presentaron la mayor mediana (5), siendo significativamente superiores a T2, T3 y T4 (4.5). La proporción de frutos caoba fue superior al 70% en todos los tratamientos, con T2 alcanzando el 91.7%. Al comparar entre temporadas en La Esperanza, todos los tratamientos excepto T2 presentaron una disminución significativa en el color, indicando una pérdida general de tonalidad caoba en 2023–2024.

5.2.4 Contenido de azúcar

La concentración de sólidos solubles en cerezas se presenta en la Figura 5.6, considerando como referencia comercial óptima el rango de 19–20 °Brix. En La Esperanza 2022–2023, todos los tratamientos superaron la mediana de T0 (19.2), destacando T3 con 22.8 °Brix, que fue significativamente mayor que T0 y T4. La mayor proporción de frutos dentro del rango óptimo se observó en T4 (40%), seguido de T1 (26.7%), mientras que T3, pasando del rango óptimo, presentó solo un 13.3%. En la temporada 2023–2024, nuevamente todos los tratamientos superaron a T0 (21.4 °Brix), con T3 alcanzando la mayor mediana (23.8 °Brix), sin diferencias estadísticas entre tratamientos. No obstante, la proporción de frutos dentro del rango óptimo fue baja en todos los casos (<14%). En Río Claro, T4 tuvo la mayor mediana (22.4 °Brix), 3.4 °Brix superior a T0 (19 °Brix), mientras que T2 fue el más bajo (17.4 °Brix). Tampoco se encontraron diferencias significativas entre tratamientos. Comparando entre temporadas en La Esperanza, ningún tratamiento presentó diferencias significativas, aunque en todos los casos las medianas fueron más altas en 2023–2024.

5.2.5 Daño

El porcentaje de frutas dañadas por tratamiento, sitio y temporada se muestra en la Figura 5.7. En La Esperanza 2022–2023, la mediana más alta fue en T2 (21.2%), superior a T0 (12.9%), mientras que el menor valor correspondió a T4 (5.62%). En la temporada 2023–2024, T3 alcanzó el mayor valor (38%) y T4 el menor (26.9%). En ambos casos no se encontraron diferencias significativas entre tratamientos. En Río Claro, el mayor valor se observó en

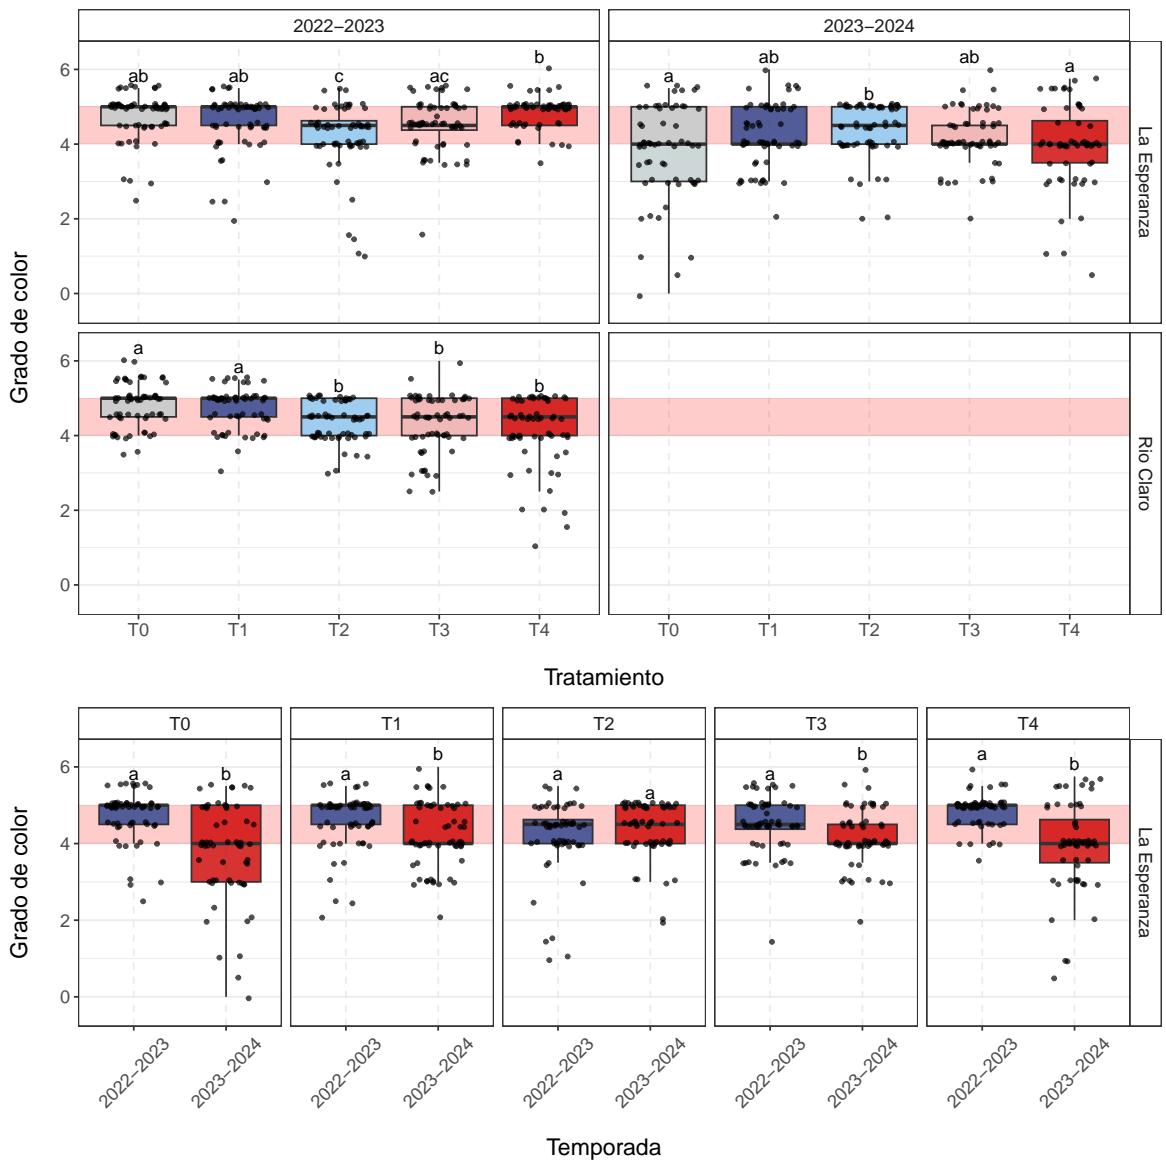


Figura 5.5: Comparación del color de una unidad de cereza según tratamiento, sitio y temporada.

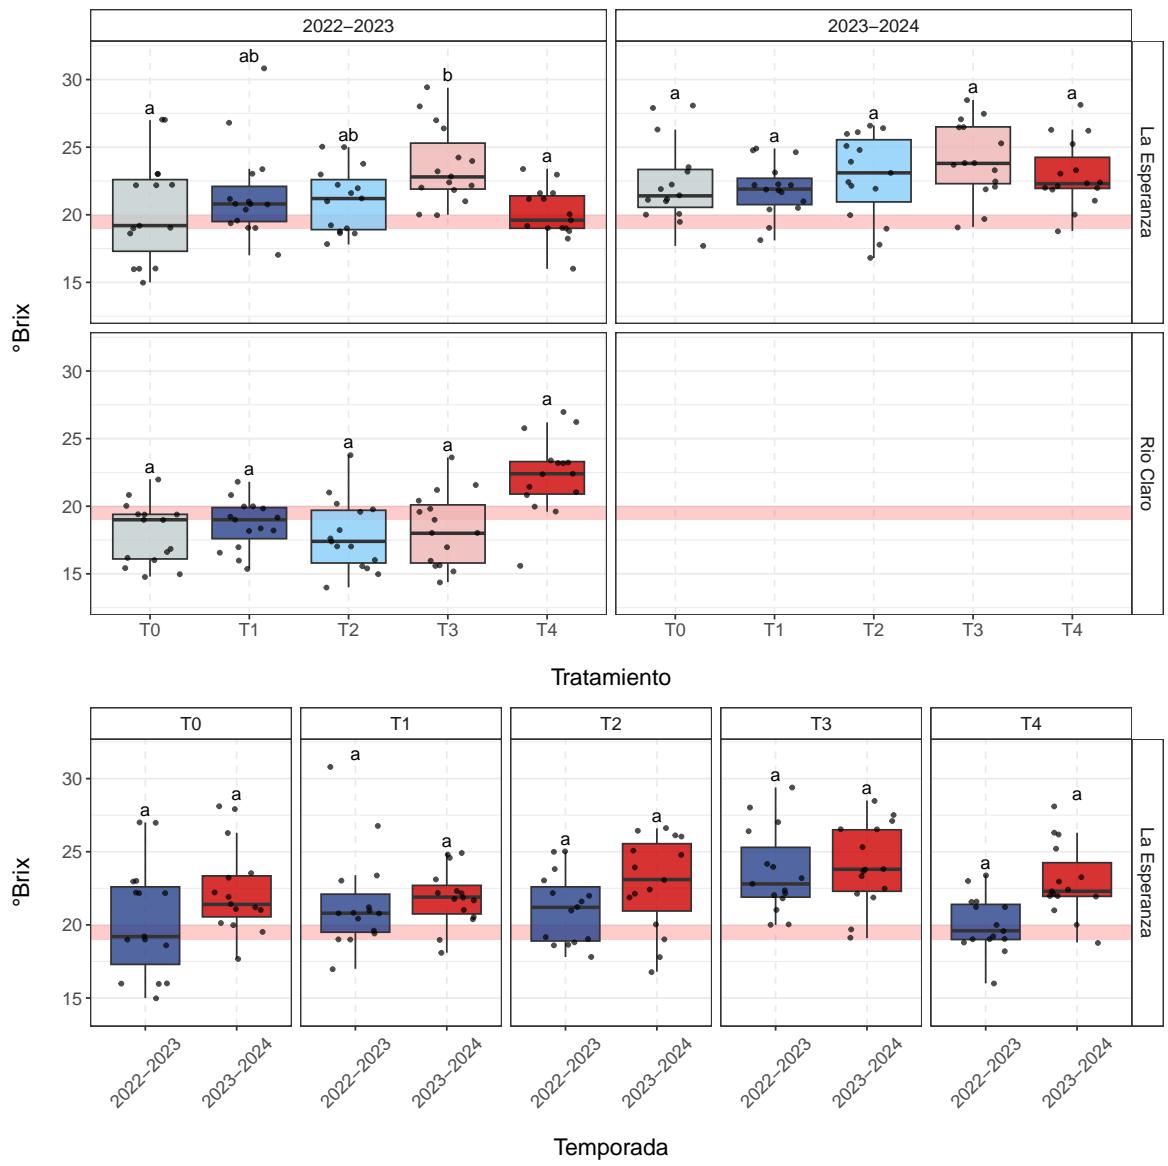


Figura 5.6: Comparación de la concentración de sólidos solubles ($^{\circ}$ brix) de una unidad de cereza según tratamiento, sitio y temporada.

T4 (16.4%), superior a T0 (11.3%), y el menor en T1 (8.4%), sin diferencias estadísticas. Comparando entre temporadas en La Esperanza, todos los tratamientos presentaron porcentajes significativamente mayores de fruta dañada en 2023–2024. Cabe señalar que cada tratamiento se basó en tres muestras ($n = 3$), lo que representa una única proporción por tratamiento a partir del kilo de muestra por árbol, lo que puede haber influido en la detección de diferencias significativas.

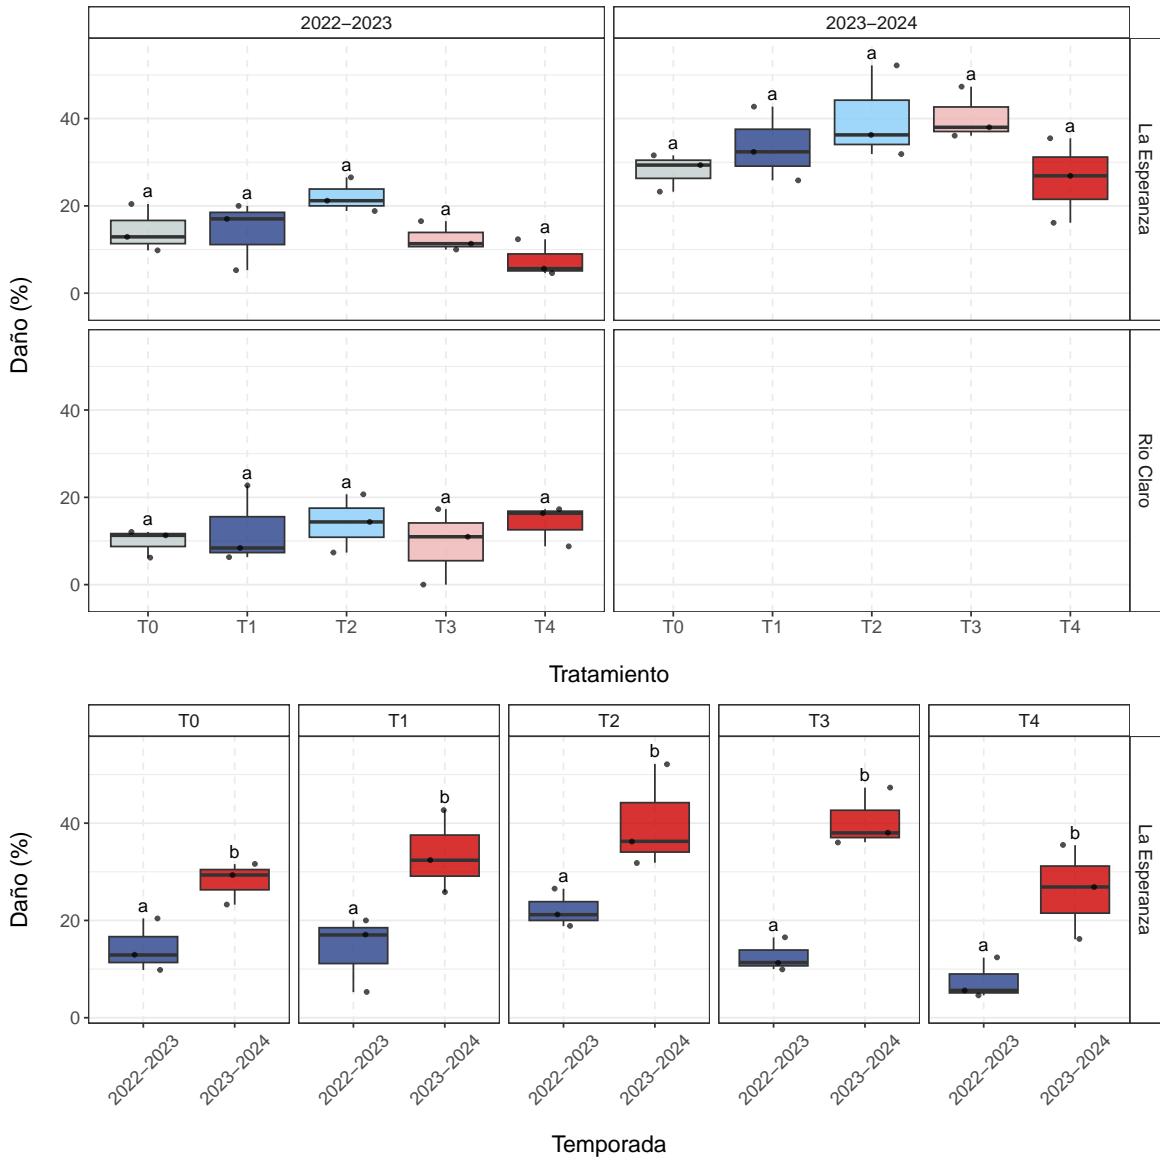


Figura 5.7: Comparación del porcentaje de daño (%) según tratamiento, sitio y temporada.

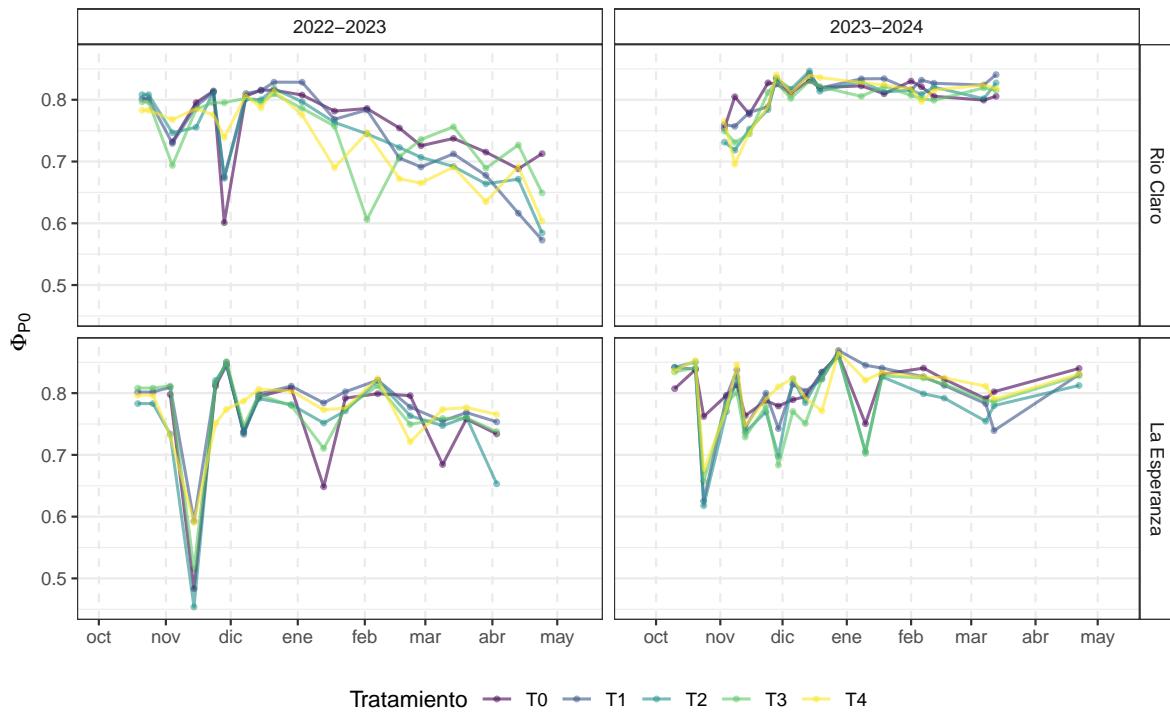
6 Parámetros fisiológicos

Los siguientes gráficos muestran la distribución durante el mes, para cada tratamiento, sitio y temporada, de los tres parámetros fisiológicos seleccionados del estudio. Estos fueron la Máxima Eficiencia Quántica del Fotosistema II (Φ_{P0}), el Potencial Hídrico Xilemático (Ψ_s) y el Índice de Área Foliar (LAI).

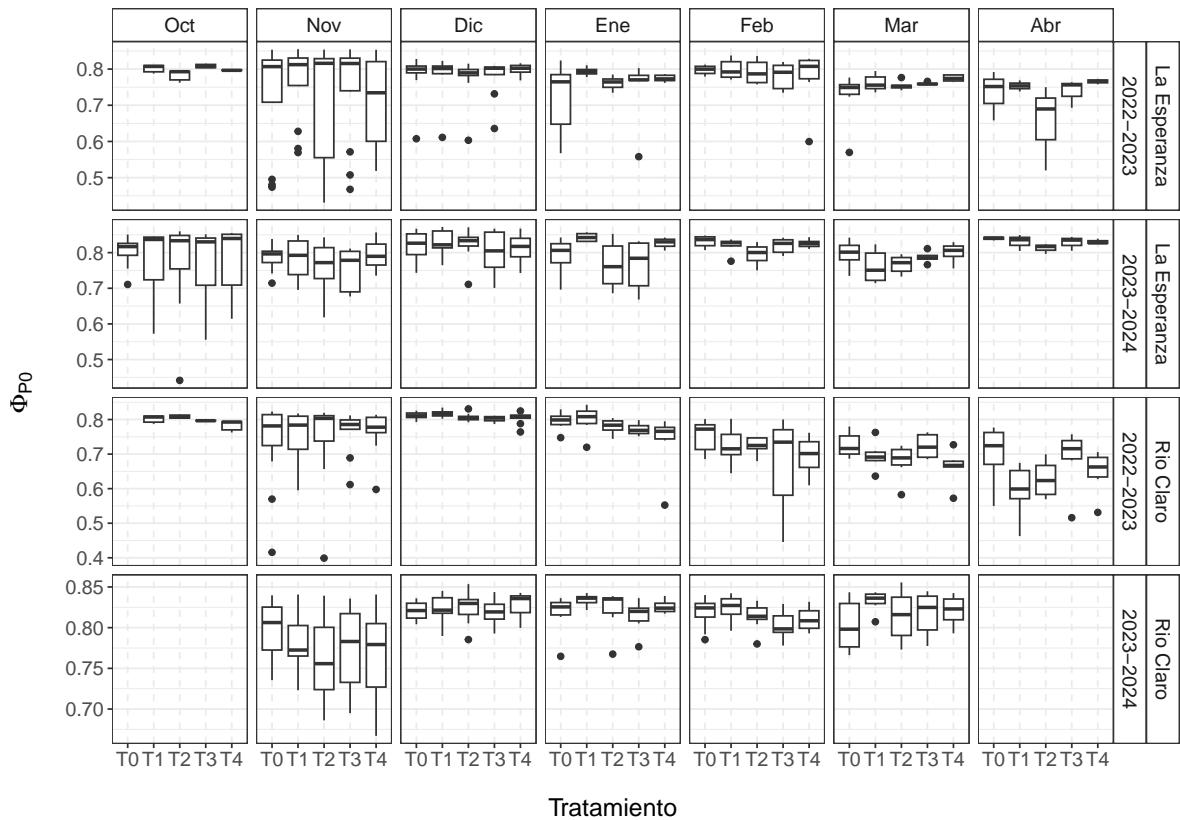
6.1 Fluorescencia

En general, los valores de Φ_{P0} presentan fluctuaciones a lo largo del tiempo sin una tendencia clara en la mayoría de los casos. Sin embargo, en la temporada 2022-2023 de Río Claro, se observa una disminución progresiva en todos los tratamientos. Se registran descensos marcados en noviembre y diciembre, seguidos de una relativa estabilidad en los meses siguientes. No se evidencian diferencias consistentes entre los tratamientos, ya que las curvas se superponen en la mayor parte del período evaluado. Sin embargo, observando la distribución mensual de los valores, es posible evidenciar que T2 y T4 suelen presentar valores menores en comparación con los demás tratamientos, especialmente a partir de enero y febrero. En cuanto a las diferencias con T0, este último muestra valores más altos en la mayoría de los casos.

7 Series temporales



8 Distribución por mes



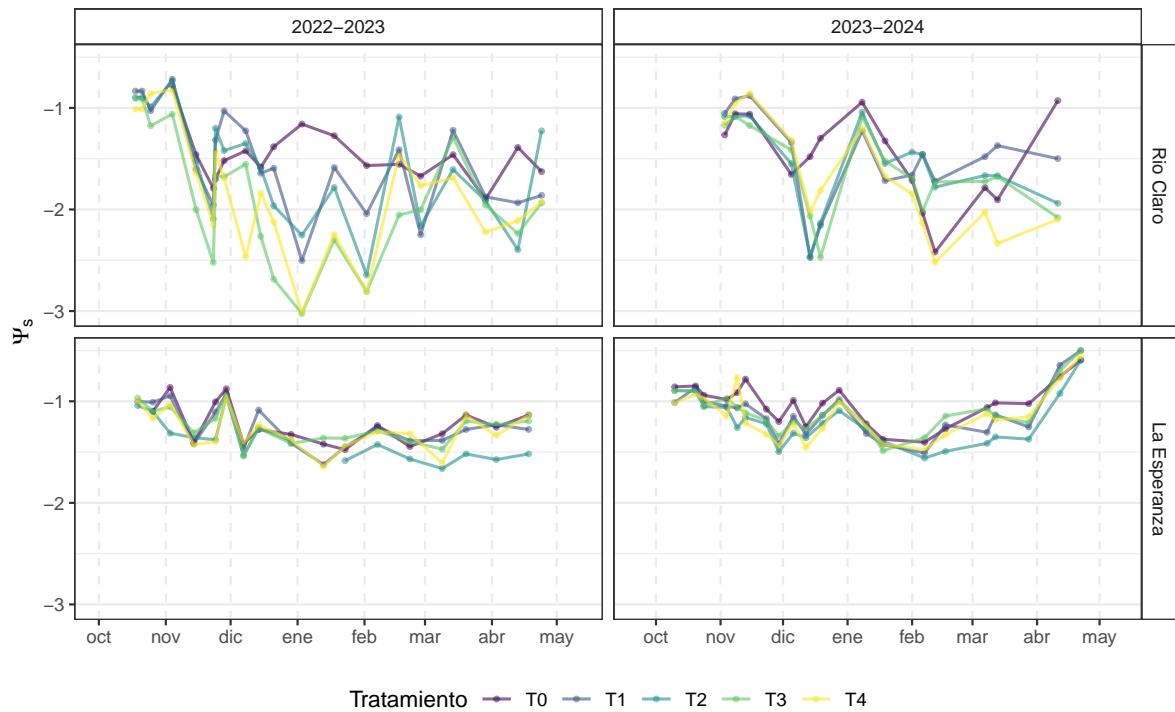
8.1 Potencial

Los valores de Ψ_s presentan variaciones a lo largo del tiempo con diferencias entre localidades y temporadas. En Río Claro, durante la temporada 2022-2023, se observa una disminución de Ψ_s desde octubre hasta diciembre, seguida de una alta variabilidad en los meses siguientes. Un patrón similar, aunque con menor amplitud, se presenta en 2023-2024, con una caída inicial y fluctuaciones posteriores. En La Esperanza, los valores de Ψ_s se mantienen más estables en ambas temporadas, con una ligera disminución en verano y un aumento hacia mayo. No

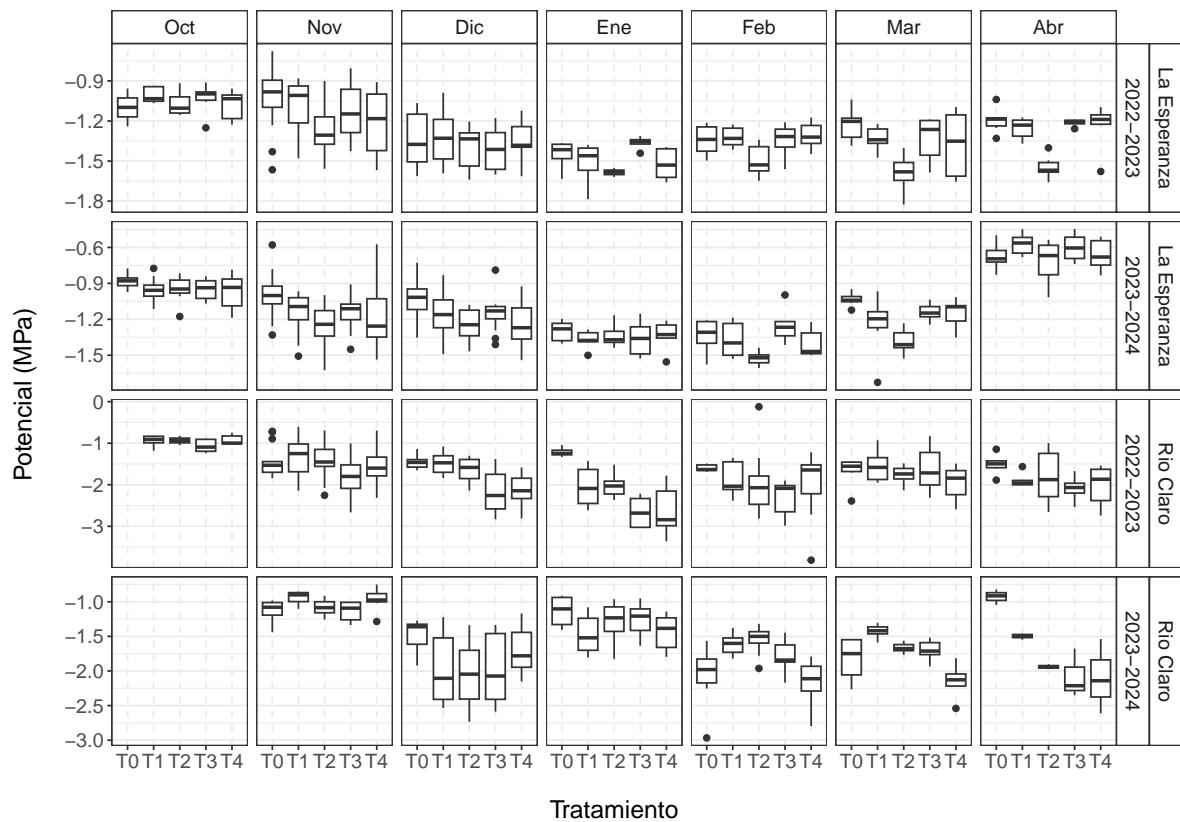
se observan diferencias marcadas entre los tratamientos, ya que las curvas siguen tendencias similares a lo largo del período evaluado.

Respecto a la distribución mensual, en Rio Claro, los tratamientos con déficit hídrico presentan valores inferiores al tratamiento control, con una diferencia más pronunciada al final de la segunda temporada. En cambio, en La Esperanza, las diferencias son más sutiles y poco consistentes entre los meses.

9 Series temporales



10 Distribución por mes

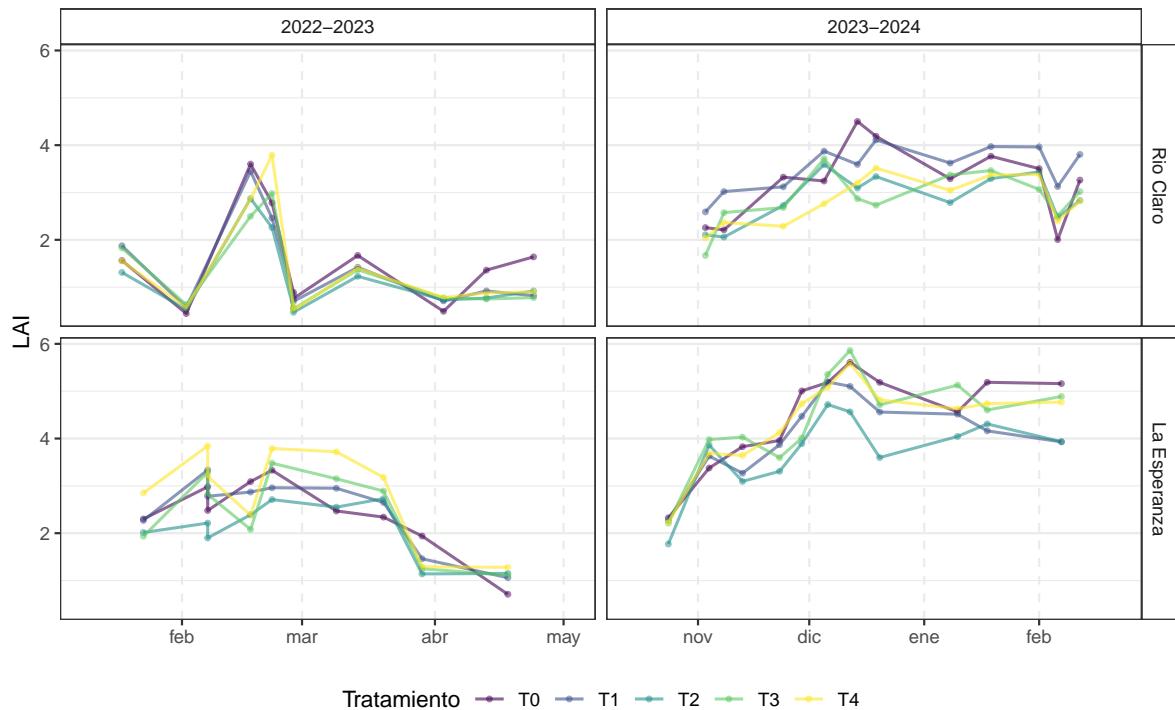


10.1 LAI

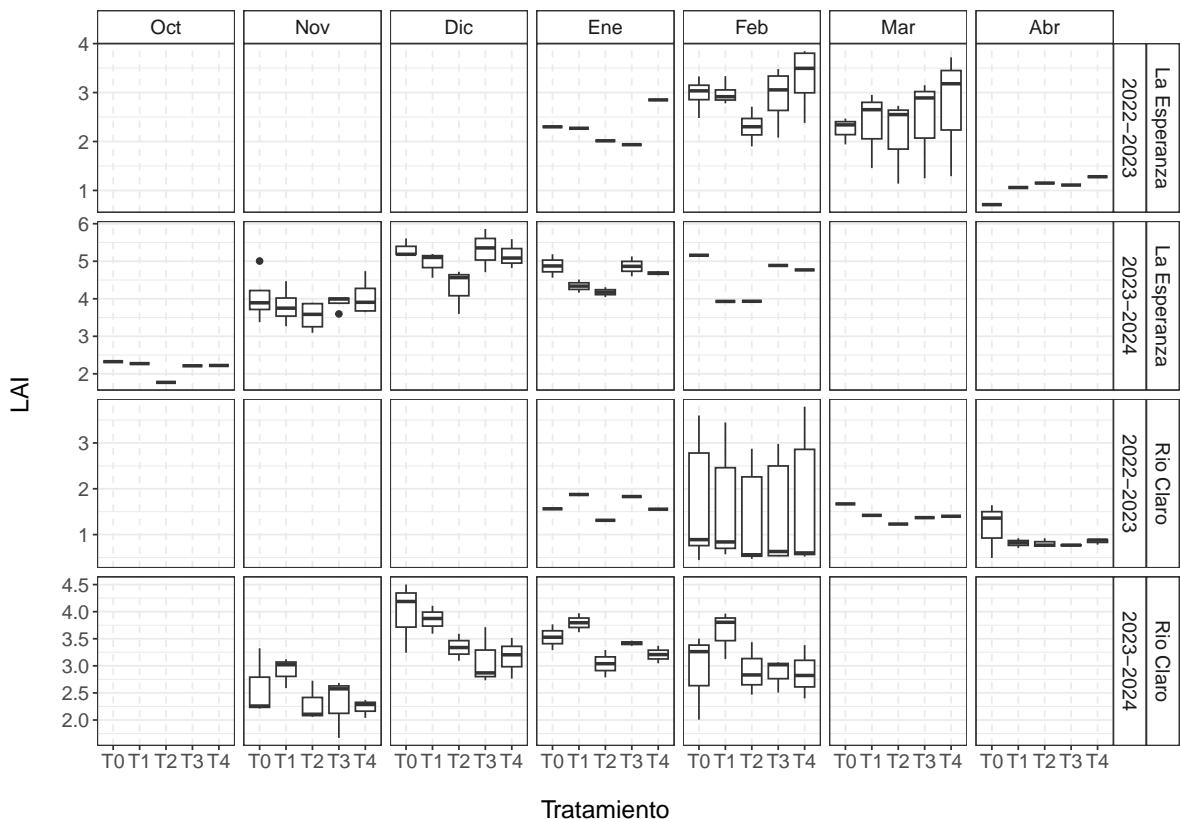
Los valores de LAI muestran patrones diferenciados entre temporadas y localidades. En Río Claro, la temporada 2022-2023 presenta un aumento pronunciado en enero, seguido de una caída y relativa estabilidad en los meses posteriores. En 2023-2024, se observa una tendencia ascendente más sostenida hasta febrero, con una leve disminución al final del período. En La Esperanza, la temporada 2022-2023 exhibe fluctuaciones en los primeros meses y una reducción marcada desde abril, mientras que en 2023-2024, el LAI aumenta progresivamente

hasta febrero. No se evidencian diferencias consistentes entre tratamientos, ya que las curvas muestran tendencias similares en ambos sitios.

11 Series temporales



12 Distribución por mes



13 Curvas Presión-volumen

Los datos utilizados para las curvas Presión-volumen corresponden a mediciones de potencial hídrico xilemático y peso en hojas de distintas unidades de los tratamientos experimentales, según la metodología descrita por Halbritter et al. (2020). El punto de pérdida de turgor (TLP) se estima como el último punto de la curva del Ψ inverso en función del RWD (1 - RWC) antes de comenzar su fracción lineal, como se muestra en la siguiente figura.

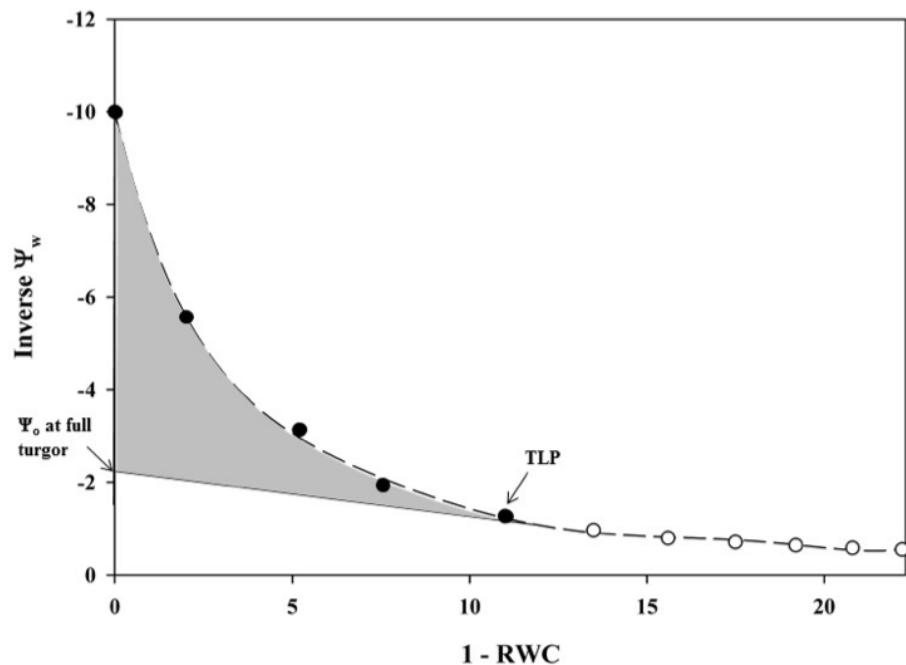


Figura 13.1: Ejemplo de una curva presión-volumen. Los círculos llenos representan las primeras 5 mediciones iterativas: los círculos abiertos representan las últimas 6 mediciones. La porción lineal (línea sólida) muestra el potencial osmótico (Ψ_o), la porción curva (línea discontinua) es el potencial hídrico antes del punto de pérdida de turgencia (TLP), y el área sombreada es el potencial de turgencia (Ψ_p). Fuente: Halbritter et al. (2020).

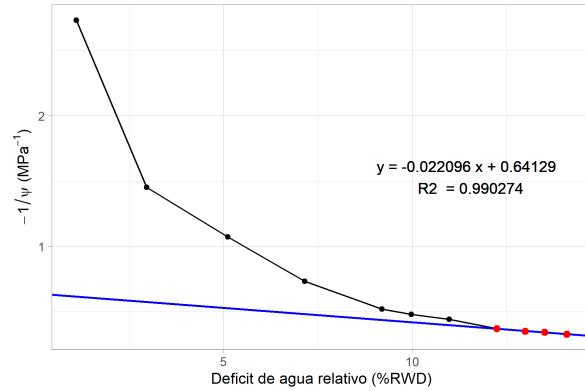
En base a esta misma metodología, a continuación se presentan las curvas presión-volumen de

cada unidad medida.

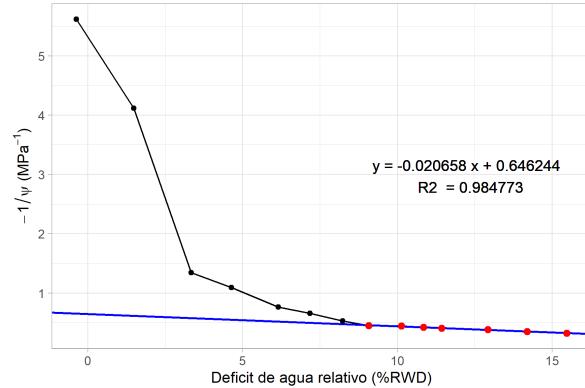
13.1 La Esperanza

13.1.1 Tratamiento 0 (control)

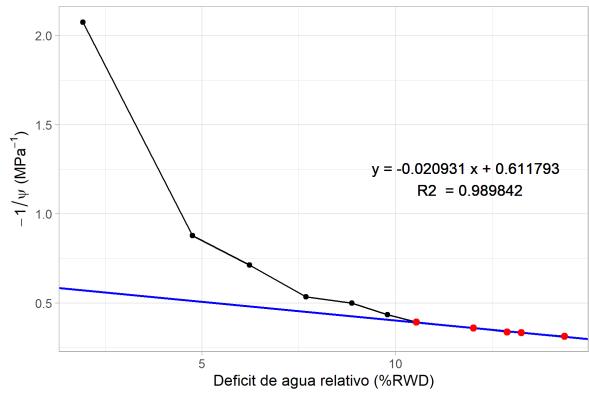
Unidad 1



Unidad 2

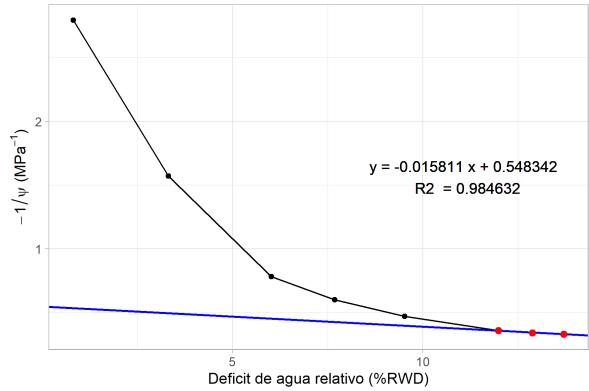


Unidad 3

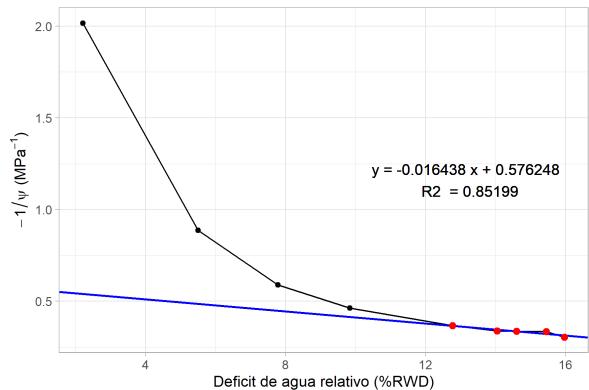


13.1.2 Tratamiento 4

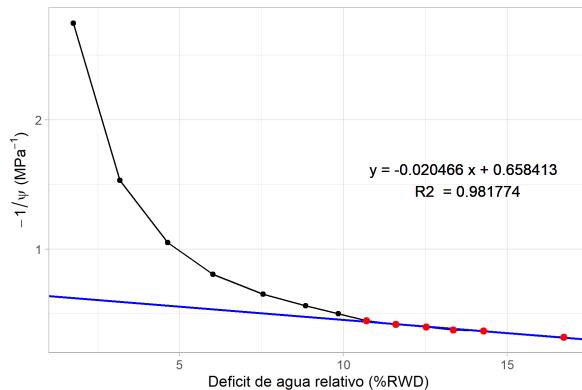
Unidad 1



Unidad 2



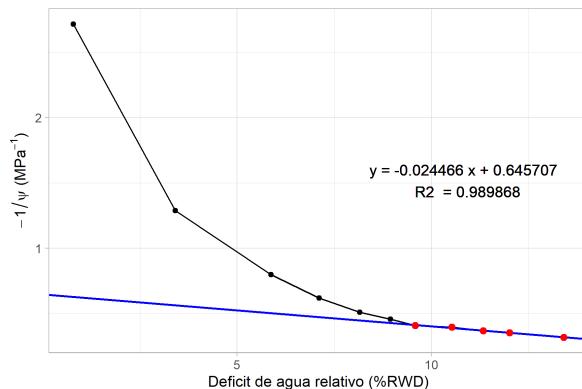
Unidad 3



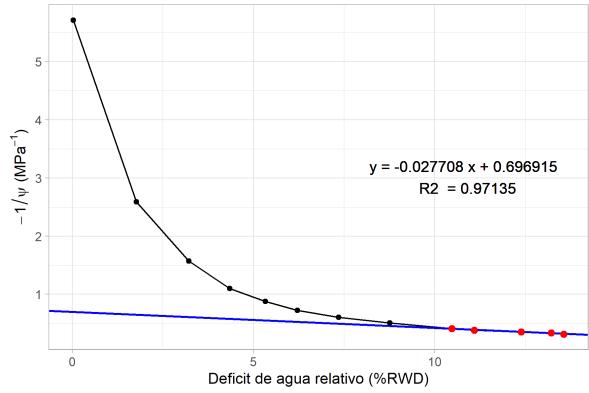
13.2 Rio Claro

13.2.1 Tratamiento 0 (control)

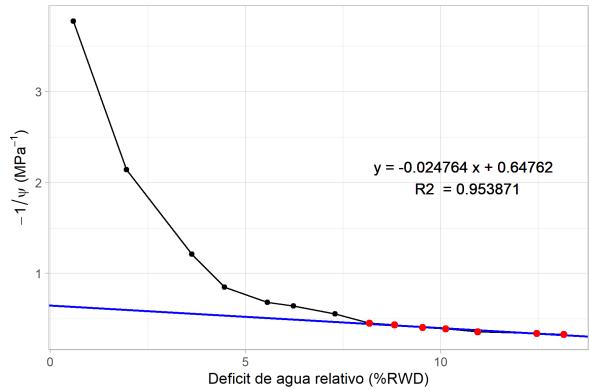
Unidad 1



Unidad 2

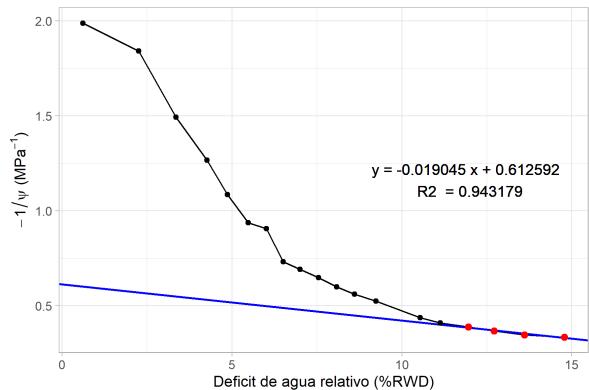


Unidad 3

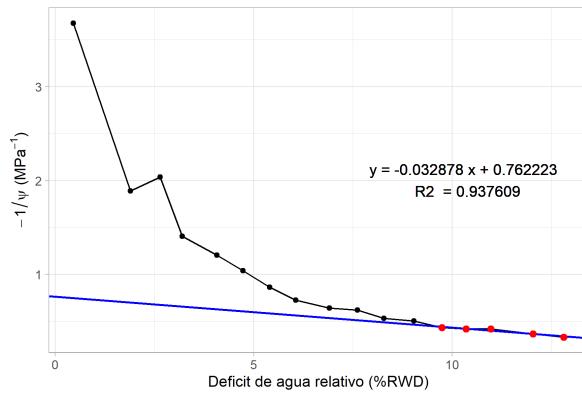


13.2.2 Tratamiento 1

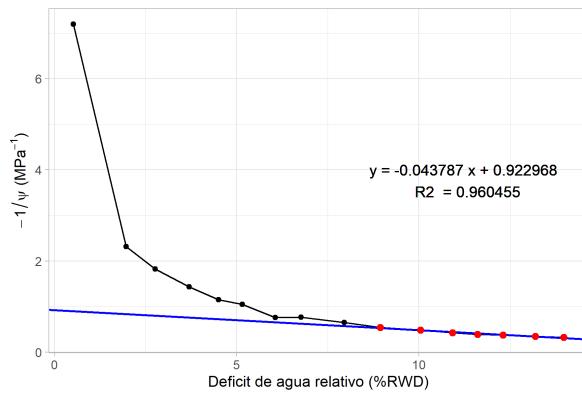
Unidad 1



Unidad 2

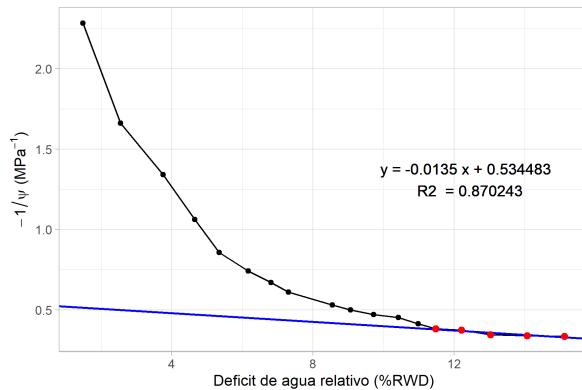


Unidad 3

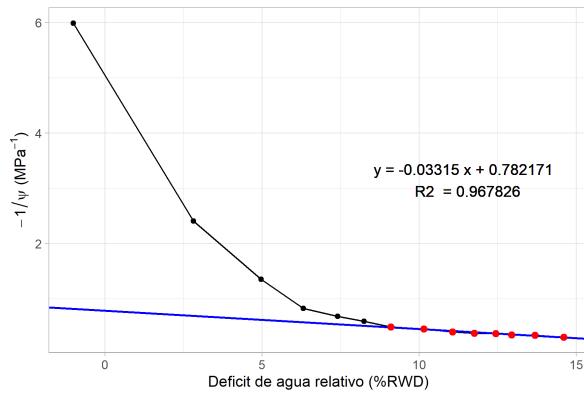


13.2.3 Tratamiento 2

Unidad 1

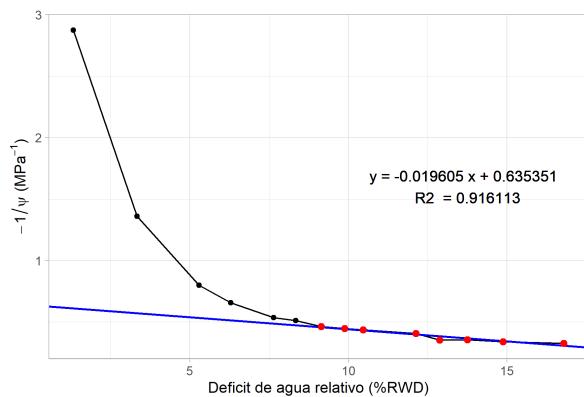


Unidad 3

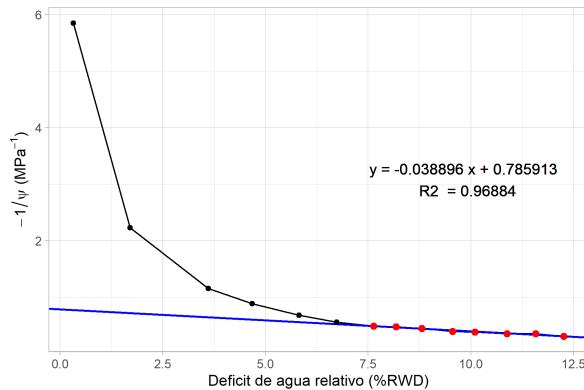


13.2.4 Tratamiento 3

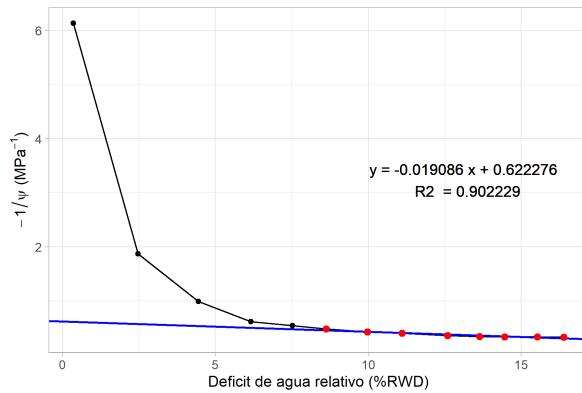
Unidad 1



Unidad 2

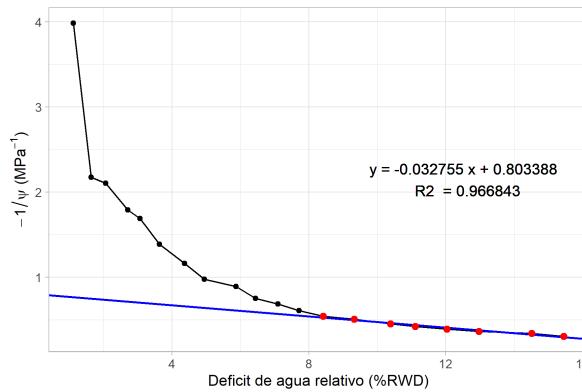


Unidad 3

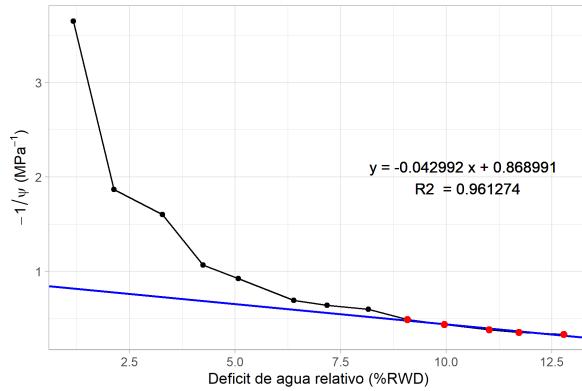


13.2.5 Tratamiento 4

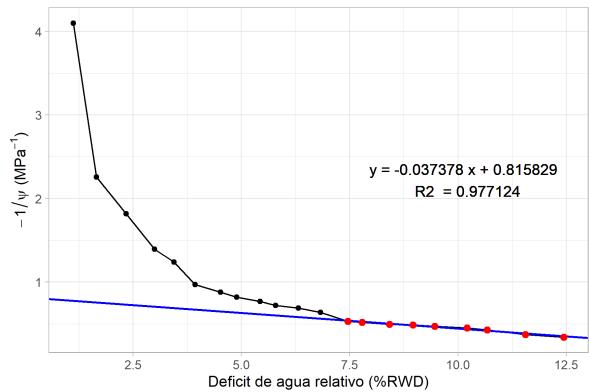
Unidad 1



Unidad 2

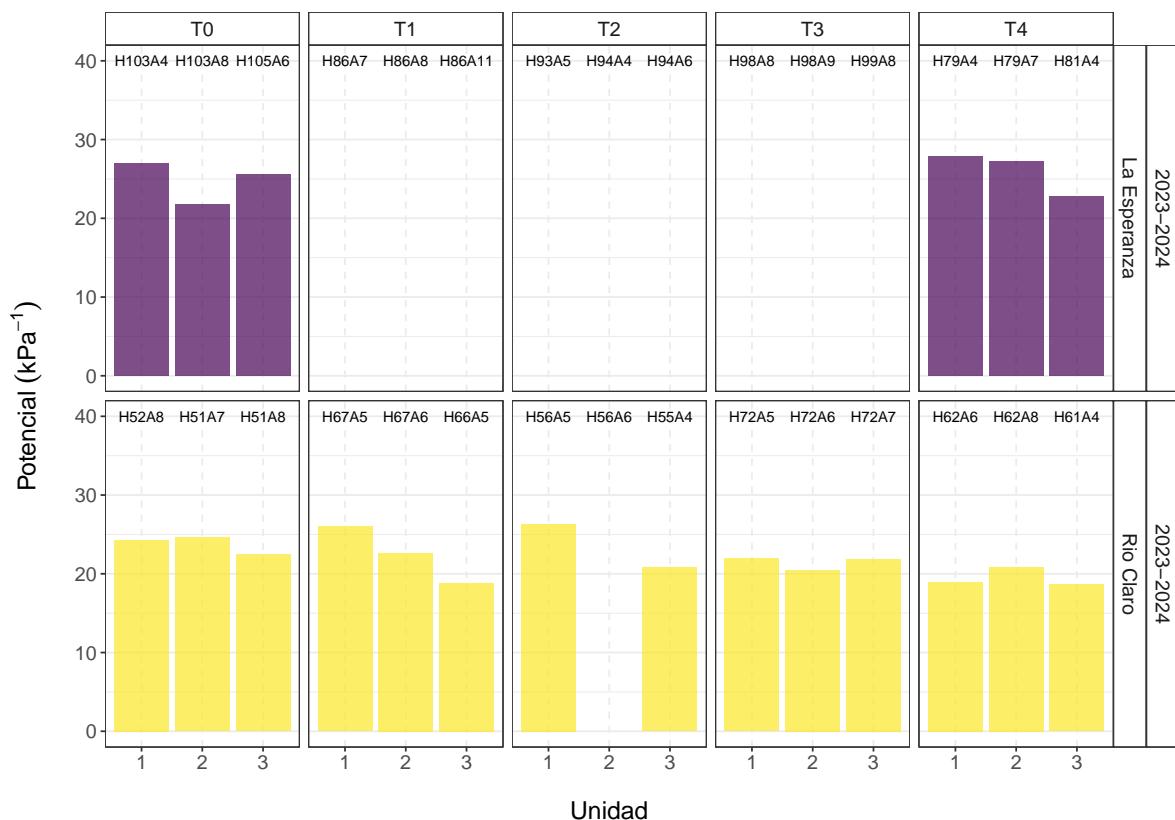


Unidad 3



14 Punto de pérdida de turgor

A continuación se presentan los puntos de pérdida de turgor de cada unidad, según tratamiento, sitio y temporada, a partir de las curvas presión-volumen.



Combinando observaciones en terreno de potencial, y el punto de perdida de turgor obtenido a partir de las curvas presión-volumen ($TLP_{la_esperanza} = -2.54$ MPa; $TLP_{rio_claro} = -2.2$ MPa; ver Figura 2) se puede observar que este punto de estrés hídrico se alcanzó mayoritariamente en los meses de enero y febrero en el campo de Río Claro, durante la temporada 2022-2023. Además, en el mismo contexto se puede observar tendencias a la disminución de potencial para los tratamientos de estrés hídrico más severos (T3 y T4). Por el contrario, en La Esperanza no

se observan disminuciones importantes de potencial, respecto al punto de pérdida de turgor, mientras que tampoco se aprecian diferencias a simple vista entre los tratamientos.

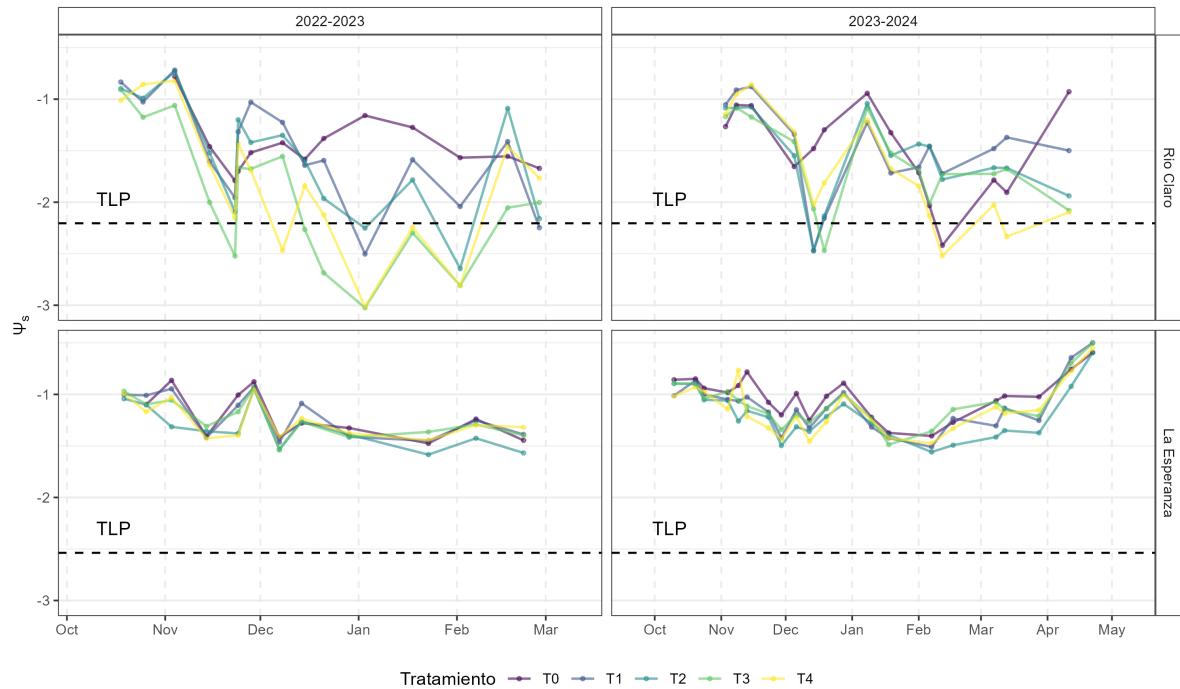


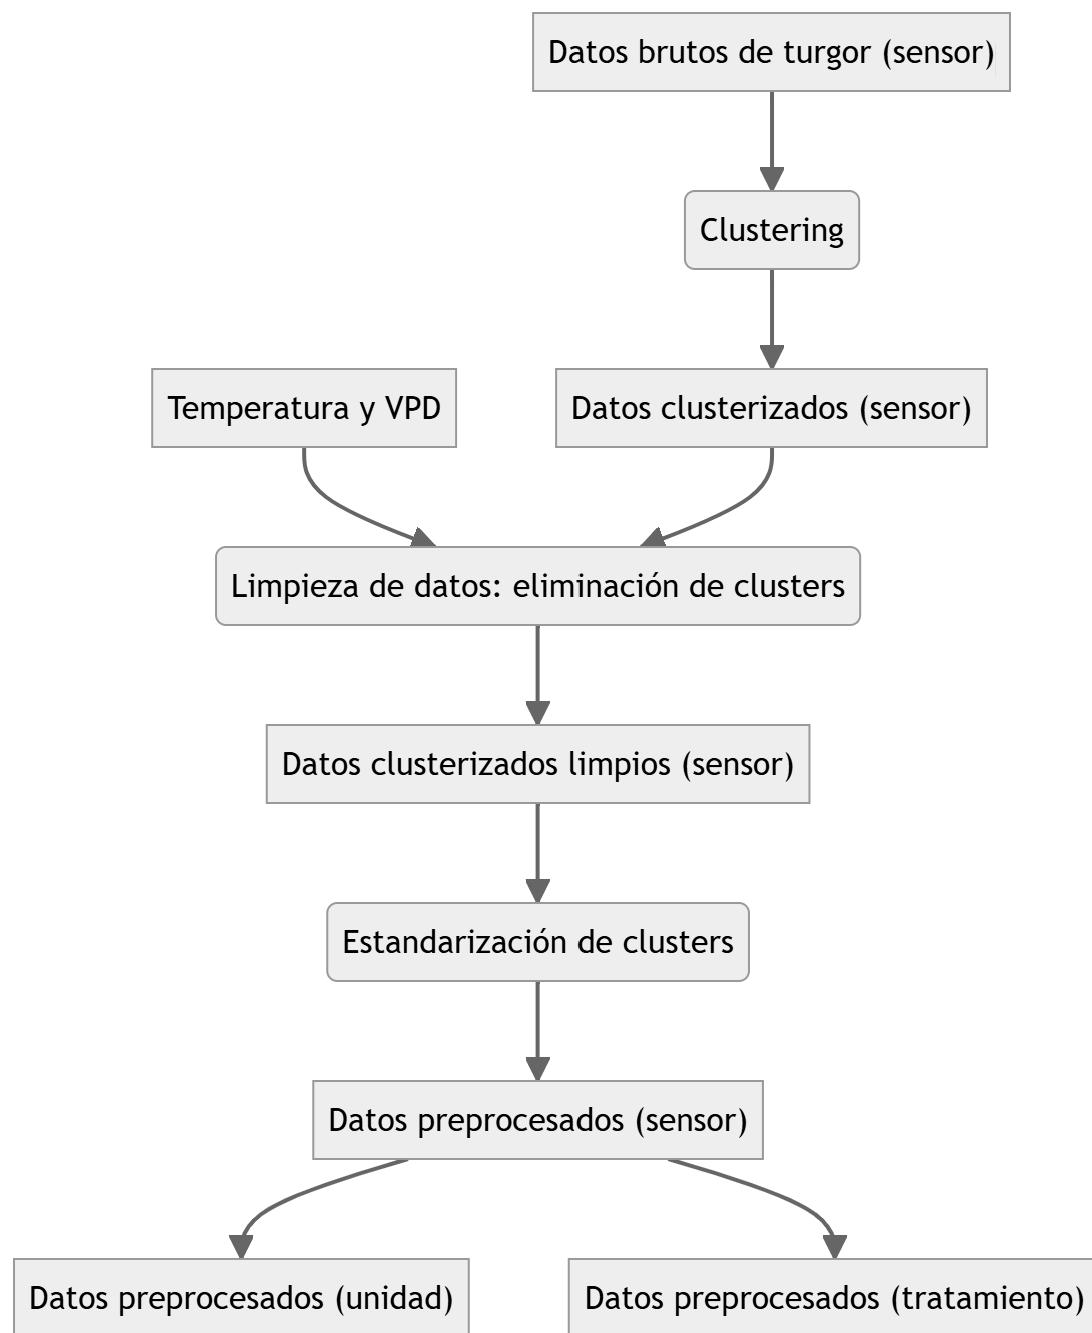
Figura 14.1: Figura 1. Series temporales de potencial hídrico xilemático según temporada (2022-2023; 2023-2024), sitio y tratamientos (T0 a T4). La unidad indica cada árbol por tratamiento (tres por tratamiento), mientras que la línea segmentada indica el punto de pérdida de turgor para cada sitio.

Parte III

Preprocesamiento de datos de turgor

El uso de sensores de turgor (ZIM) en condiciones de campo presentó diversas limitaciones que afectaron la calidad y consistencia de los datos. Los sensores eran altamente sensibles a movimientos causados por viento, caída de hojas o contacto accidental con personas, lo que requería recalibraciones frecuentes y generaba inconsistencias en la magnitud de los valores obtenidos. Además, cada sensor entregaba valores de turgor con magnitudes distintas, impidiendo la comparación directa entre unidades y tratamientos. Estos dispositivos están diseñados para ambientes controlados, como laboratorios, donde no están expuestos a factores externos que puedan desajustar sus mediciones. Sin embargo, en terreno, la suciedad, el clima y otros elementos dificultaron su estabilidad y precisión.

Para mitigar estas limitaciones, se implementó un proceso de preprocesamiento basado en tres etapas principales: filtrado, clustering y modelado. Primero, se eliminaron registros inconsistentes mediante tres criterios: (i) estabilidad en la serie de turgor (diferencias estandarizadas < 1), (ii) correlaciones esperadas con temperatura y VPD (positiva y negativa, respectivamente) y (iii) una correlación mínima de 0.5 con al menos una de estas variables. Posteriormente, se excluyeron valores fuera del rango temporal relevante. Luego, se agruparon los datos por sitio, temporada y sensor, calculando estadísticos diarios (mediana, máximo y mínimo) y aplicando clustering con DBSCAN para identificar patrones coherentes. Finalmente, se ajustaron modelos lineales entre turgor y los primeros componentes principales (PC1 y PC2), obteniendo coeficientes de regresión para cada grupo. Con estos parámetros, se generó una serie modelada de turgor a partir de la información PCA y se escaló para comparación.



A pesar de estos esfuerzos, finalmente no fue posible utilizar los valores obtenidos. La necesidad de estandarización y modelado para corregir las inconsistencias terminó eliminando la magnitud de los valores y las diferencias entre unidades, lo que impidió un análisis adecuado

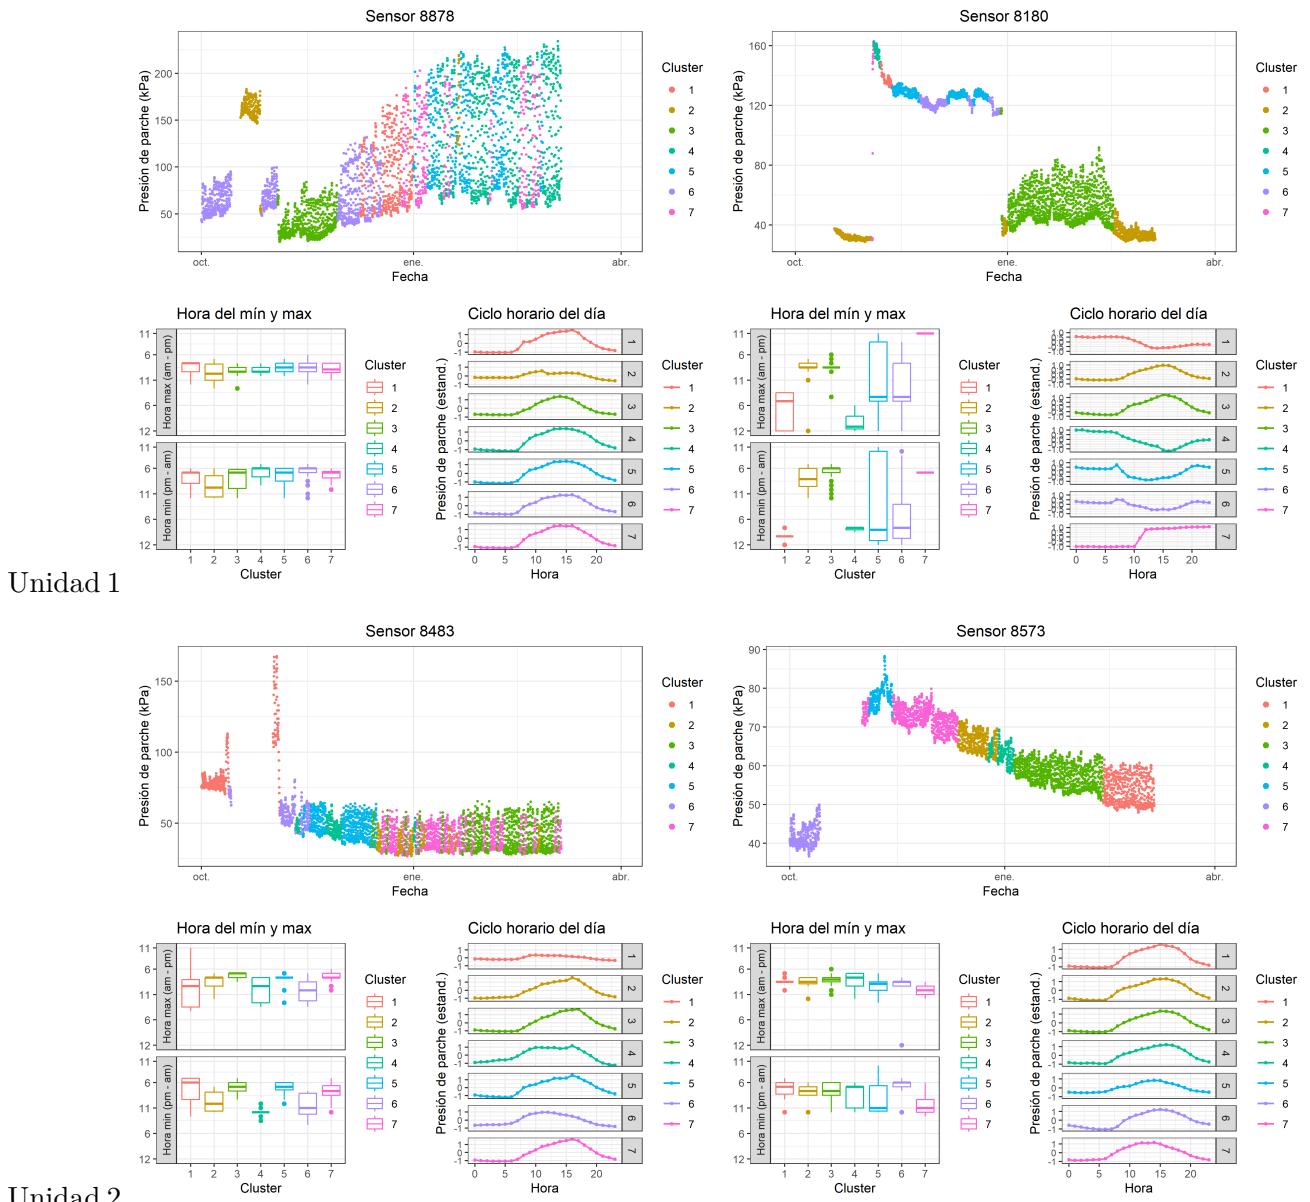
de las variaciones de turgor entre tratamientos y temporadas.

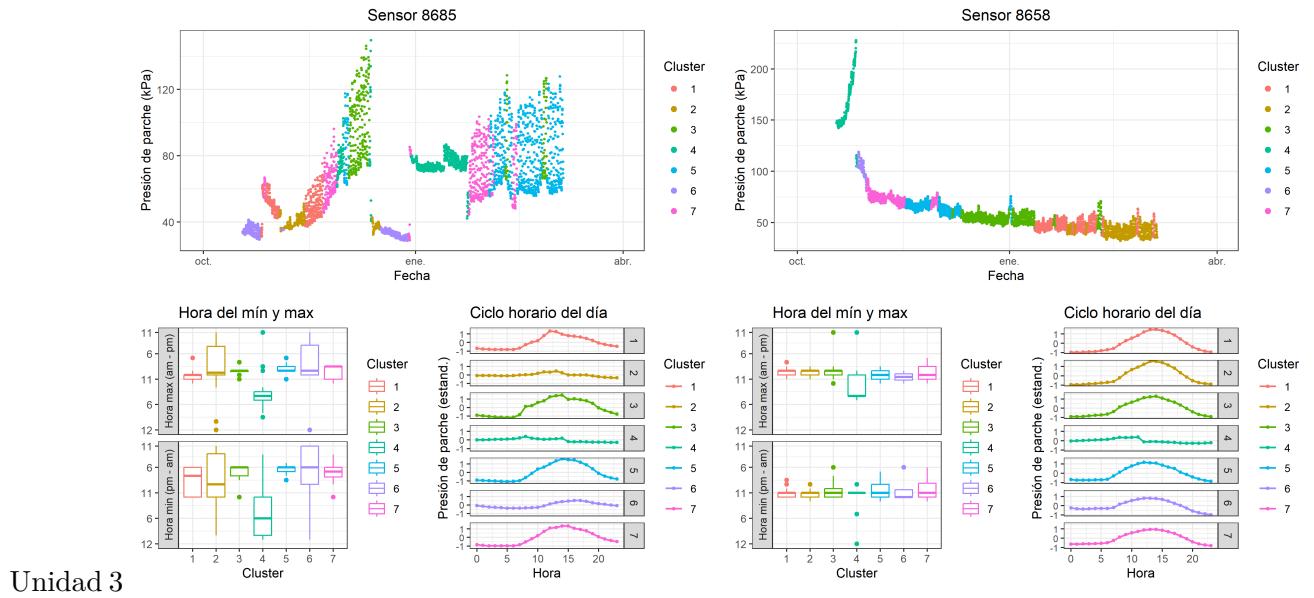
15 Clustering

A continuación, se muestran las series temporales de turgor diferenciadas por clúster, así como la distribución de las horas de turgor mínimo y máximo para cada uno de ellos, junto con su ciclo horario diario, abarcando todos los sensores en todas las unidades durante las temporadas 2022-2023 y 2023-2024.

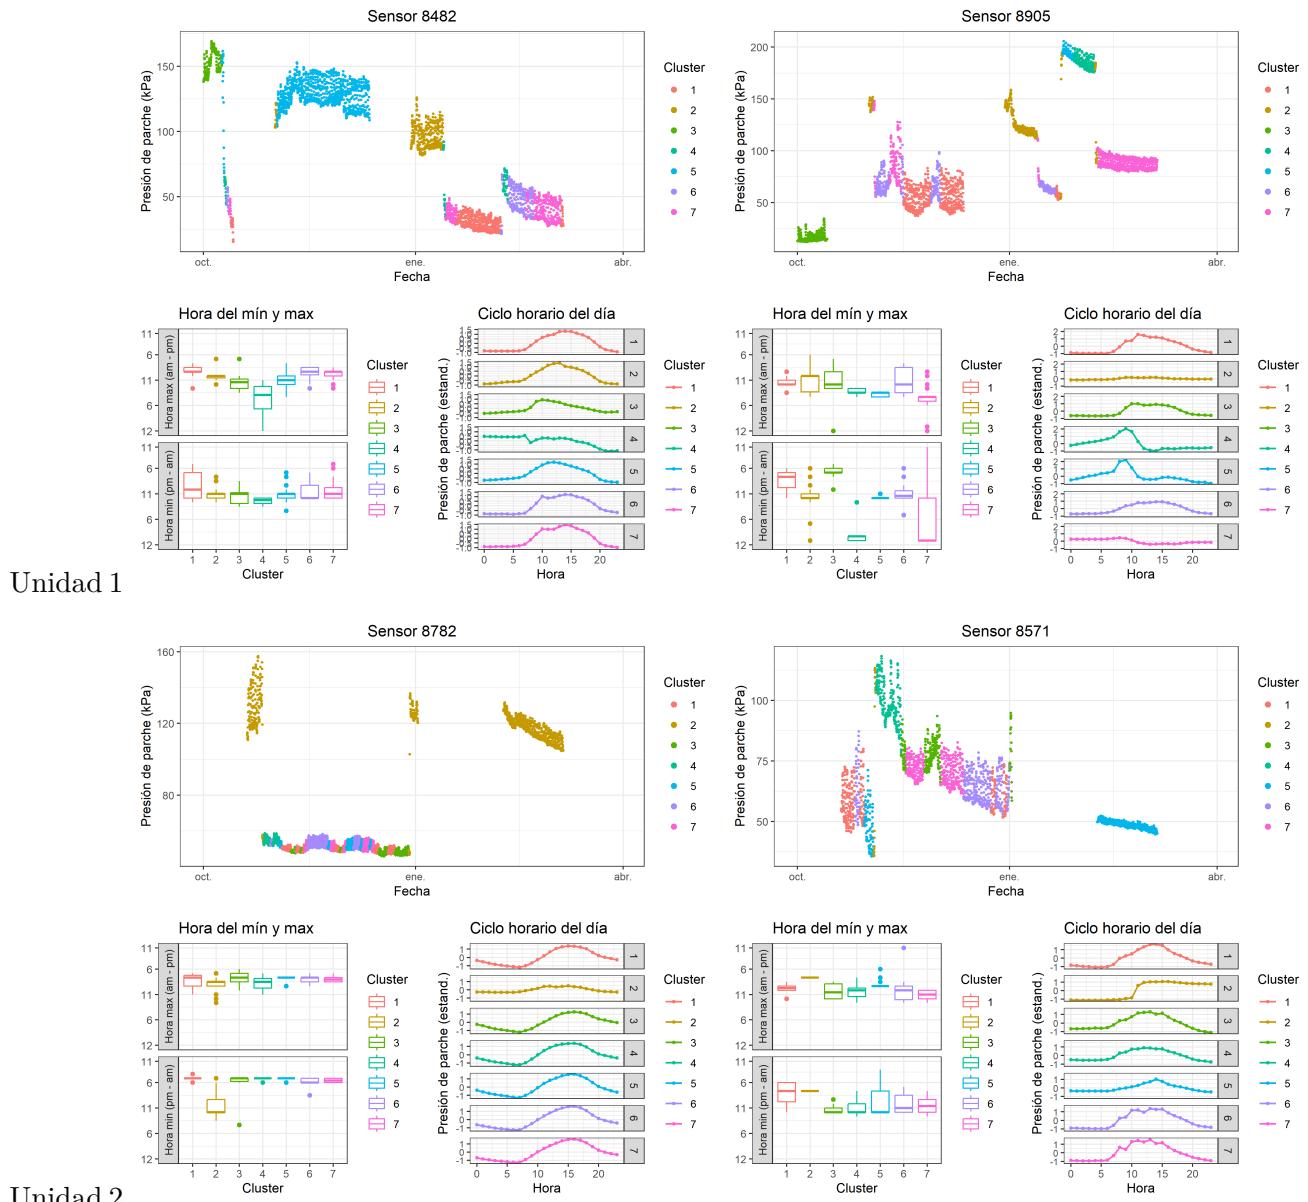
15.1 La Esperanza

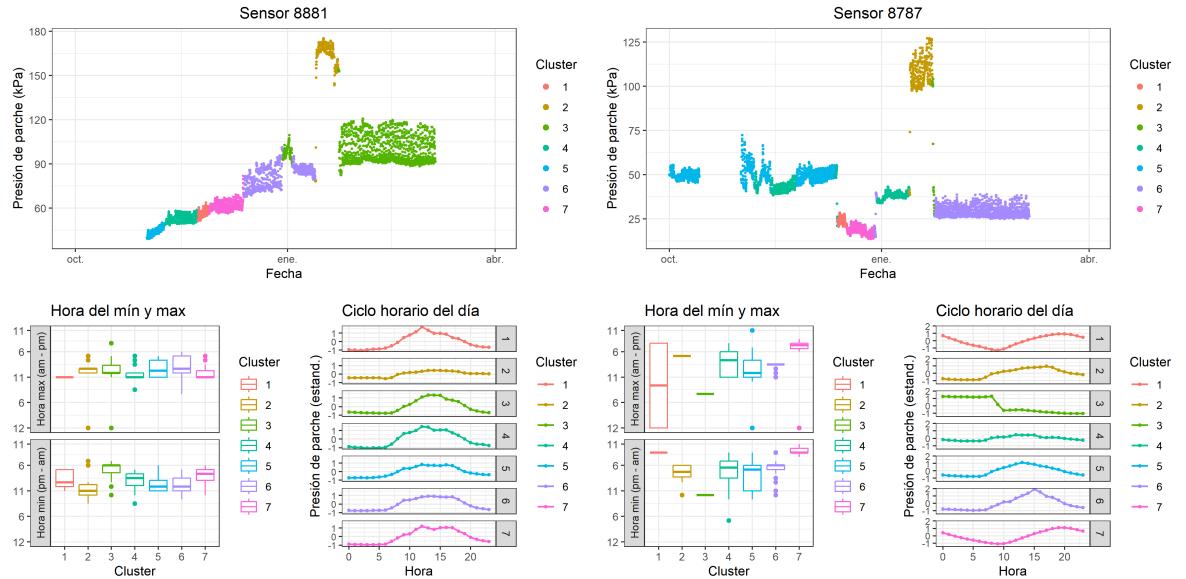
16 T1 (2022-2023)





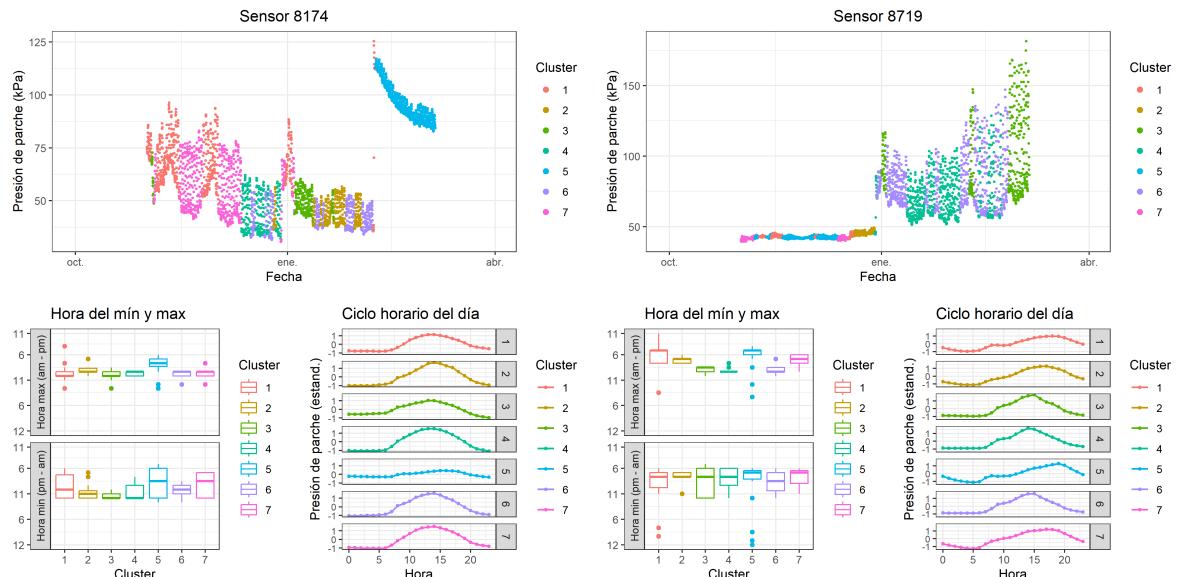
17 T2 (2022-2023)



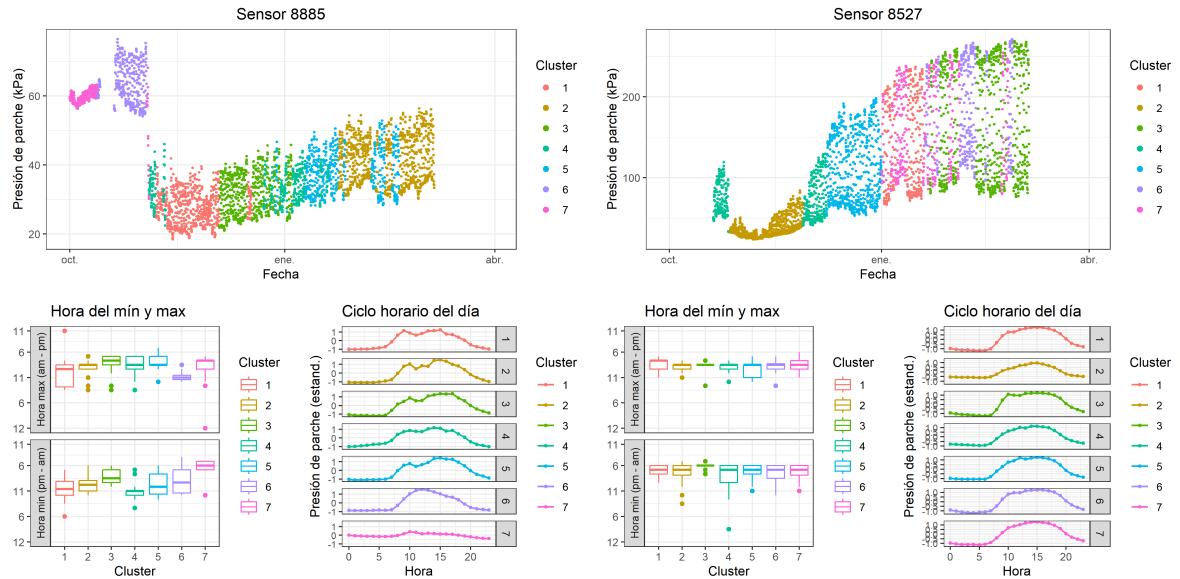


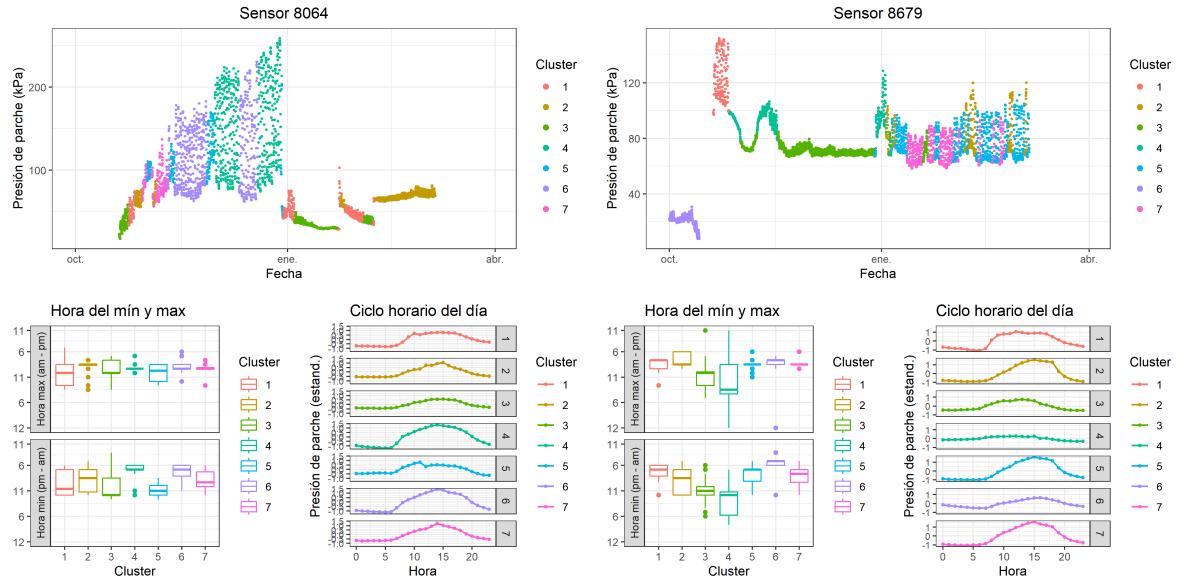
Unidad 3

18 T3 (2022-2023)



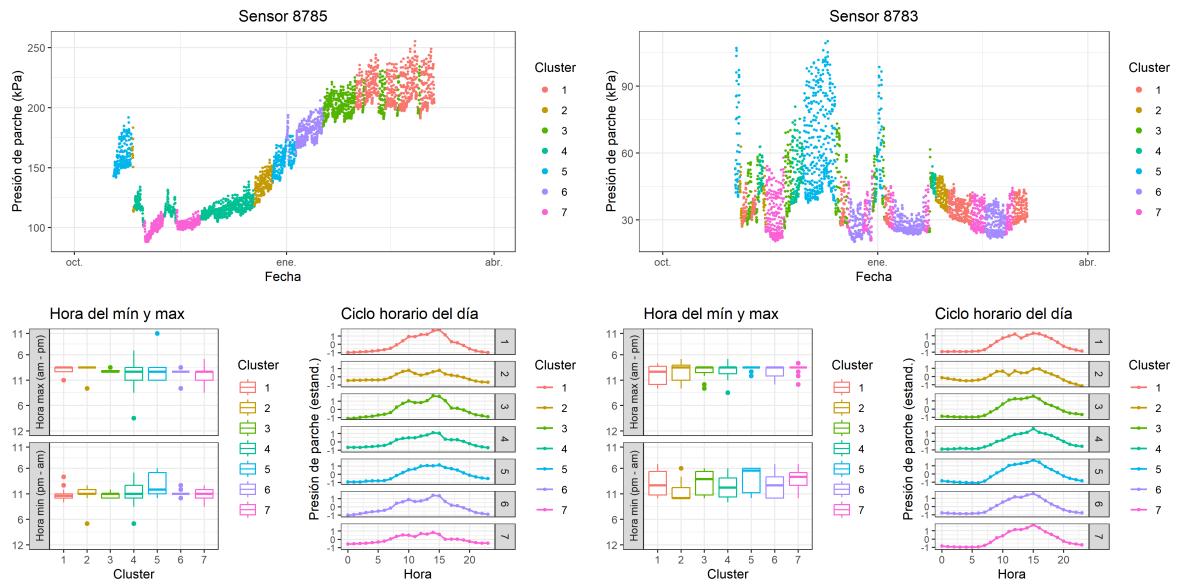
Unidad 1



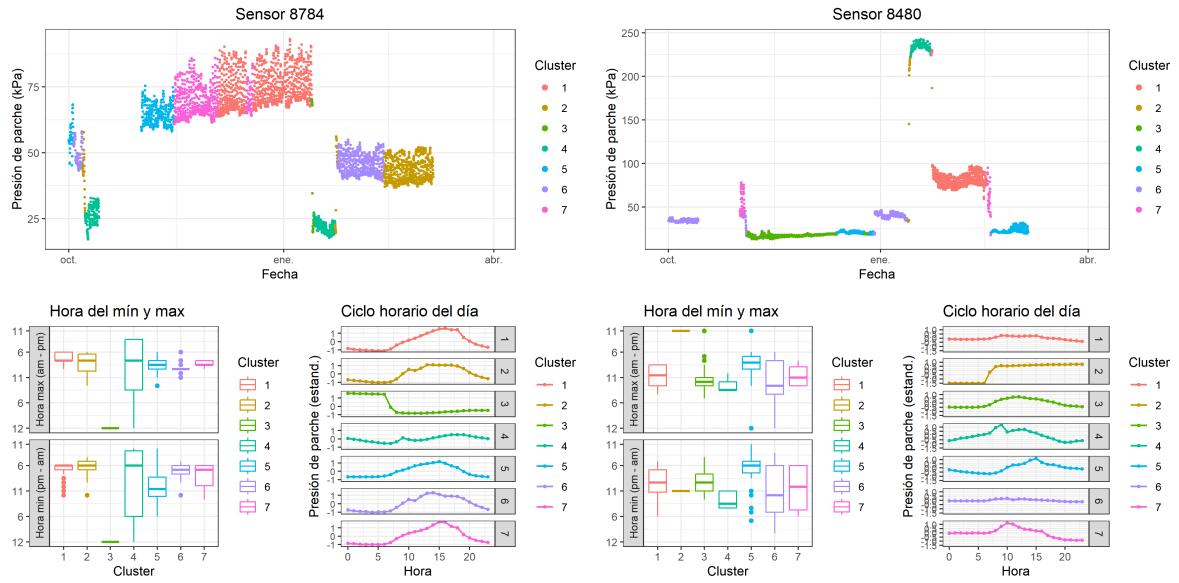


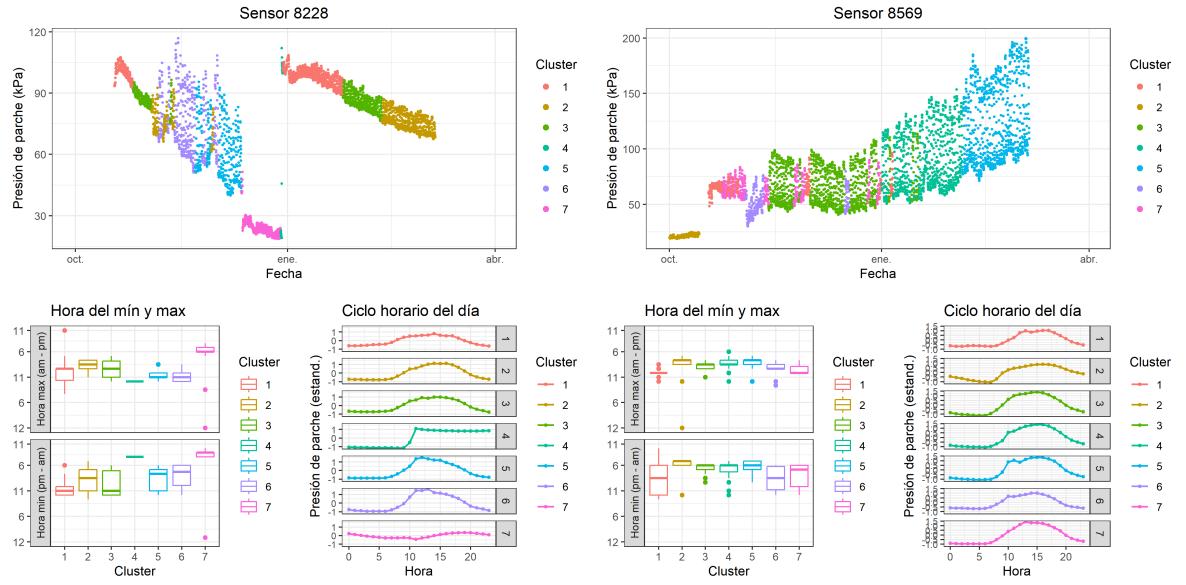
Unidad 3

19 T4 (2022-2023)



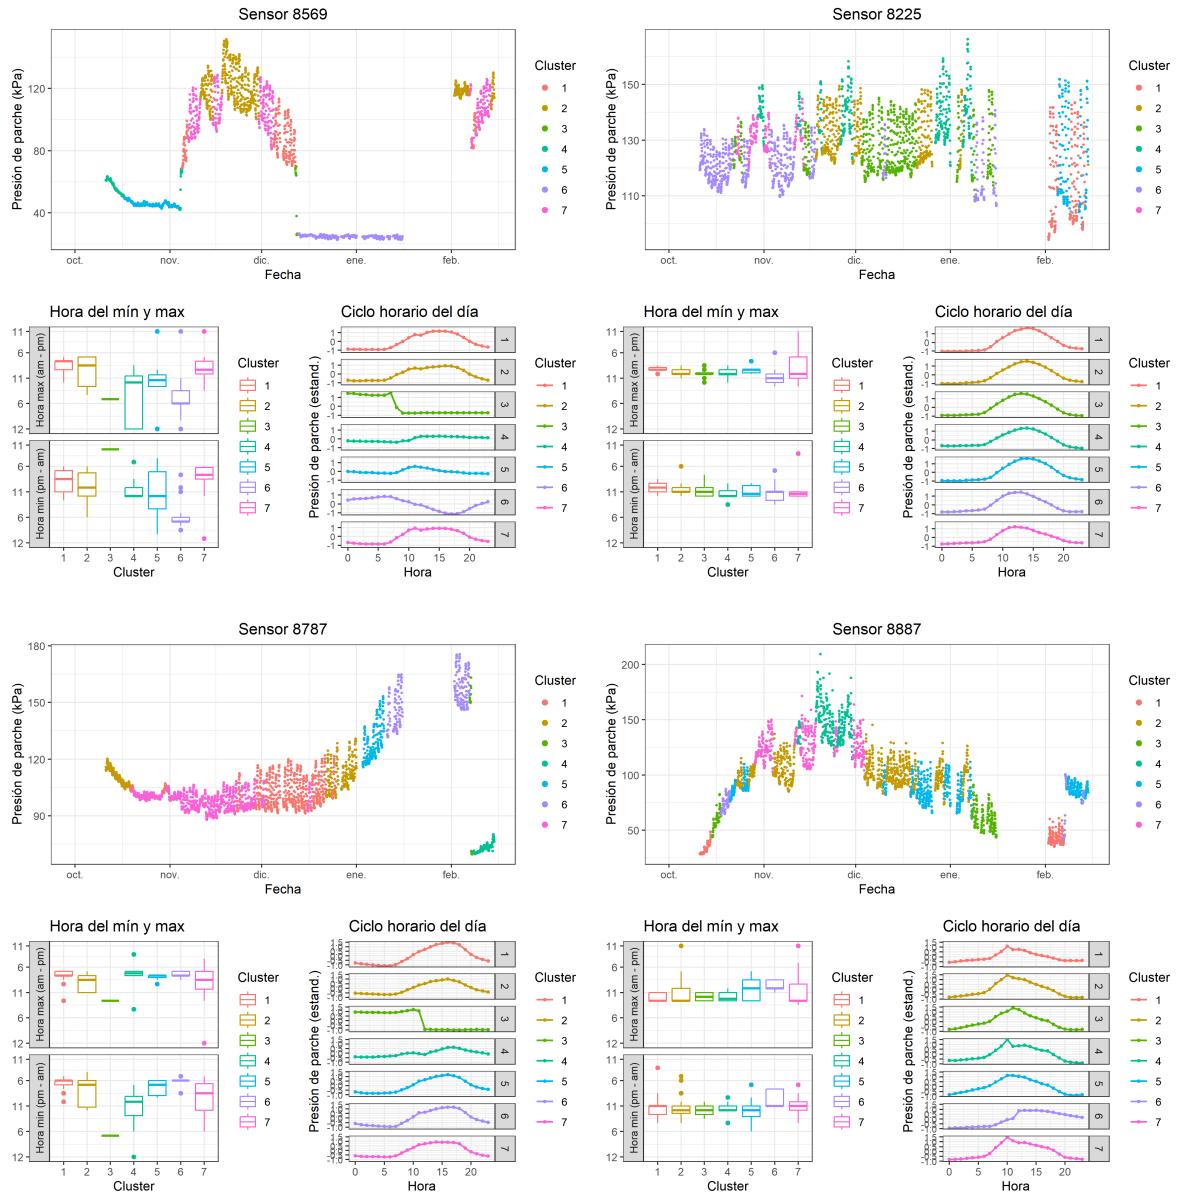
Unidad 1

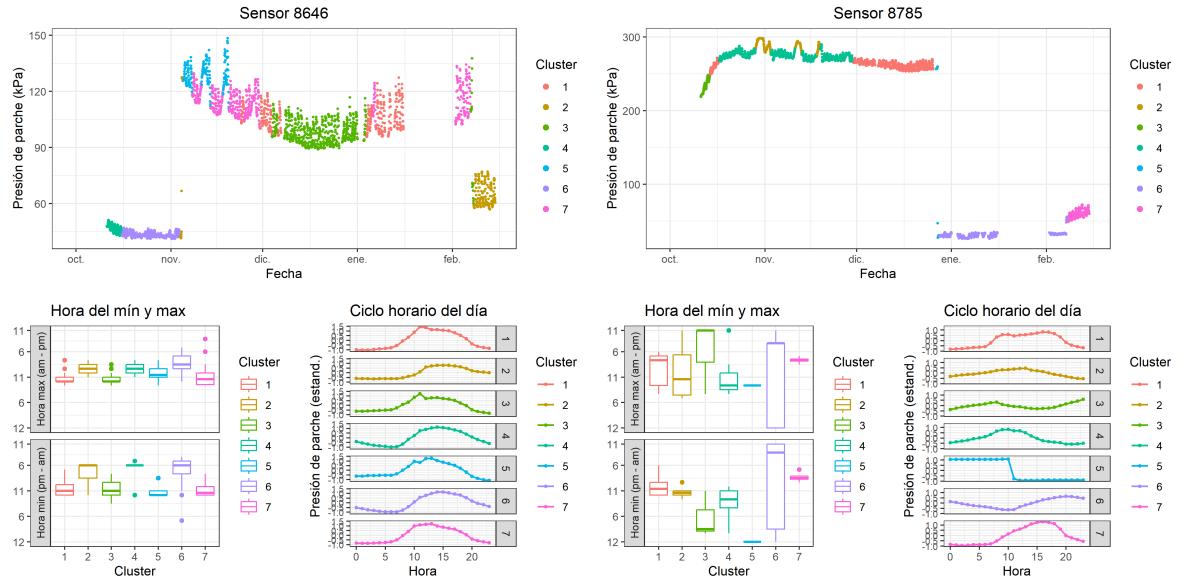




Unidad 3

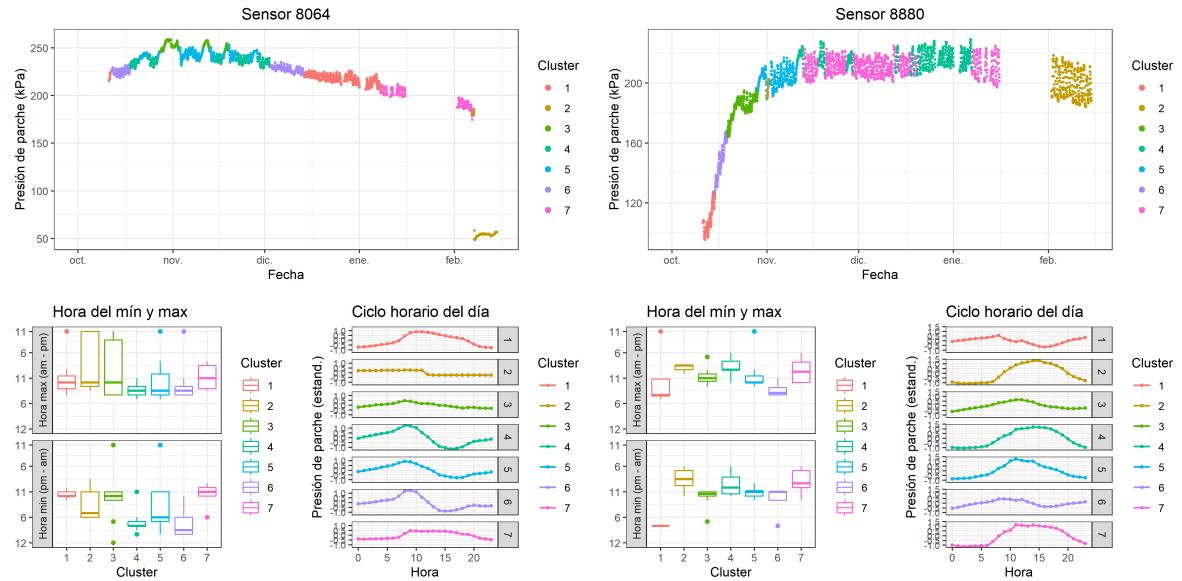
20 T1 (2023-2024)



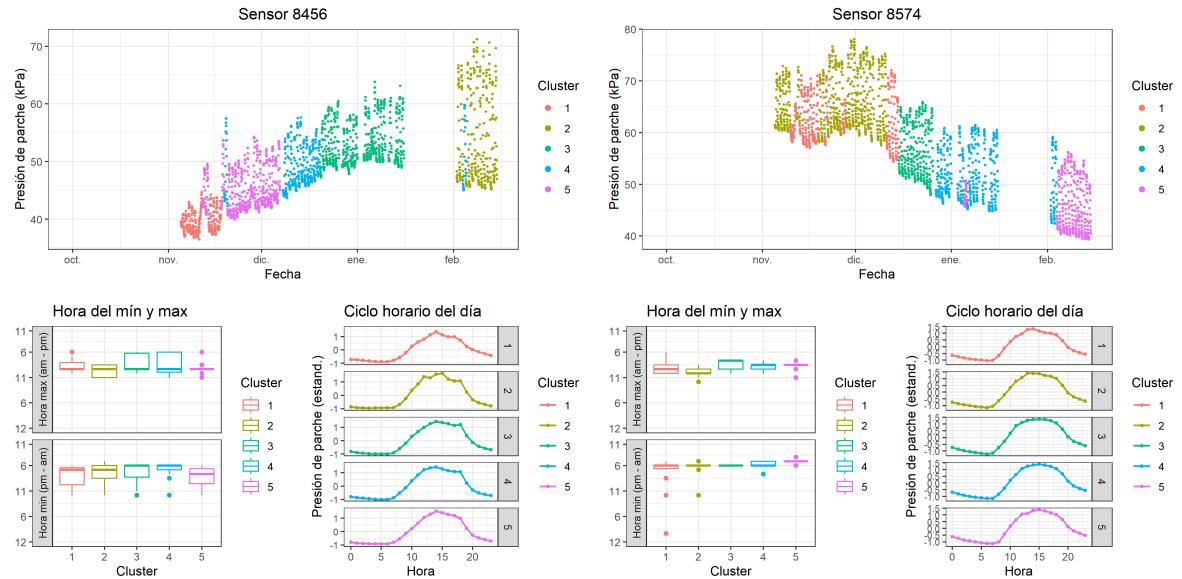


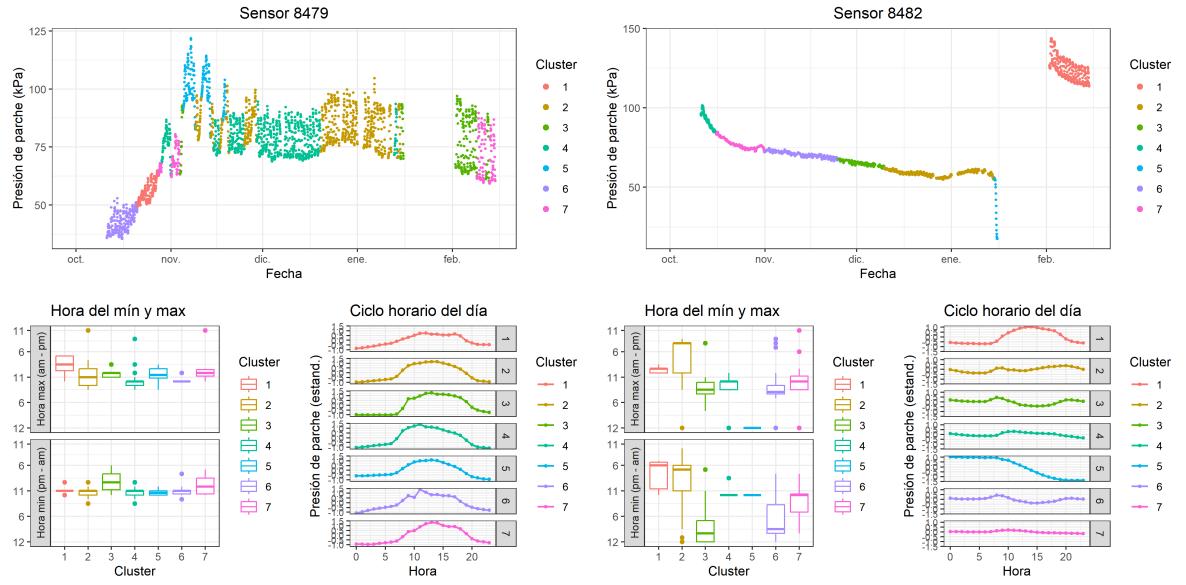
Unidad 3

21 T2 (2023-2024)



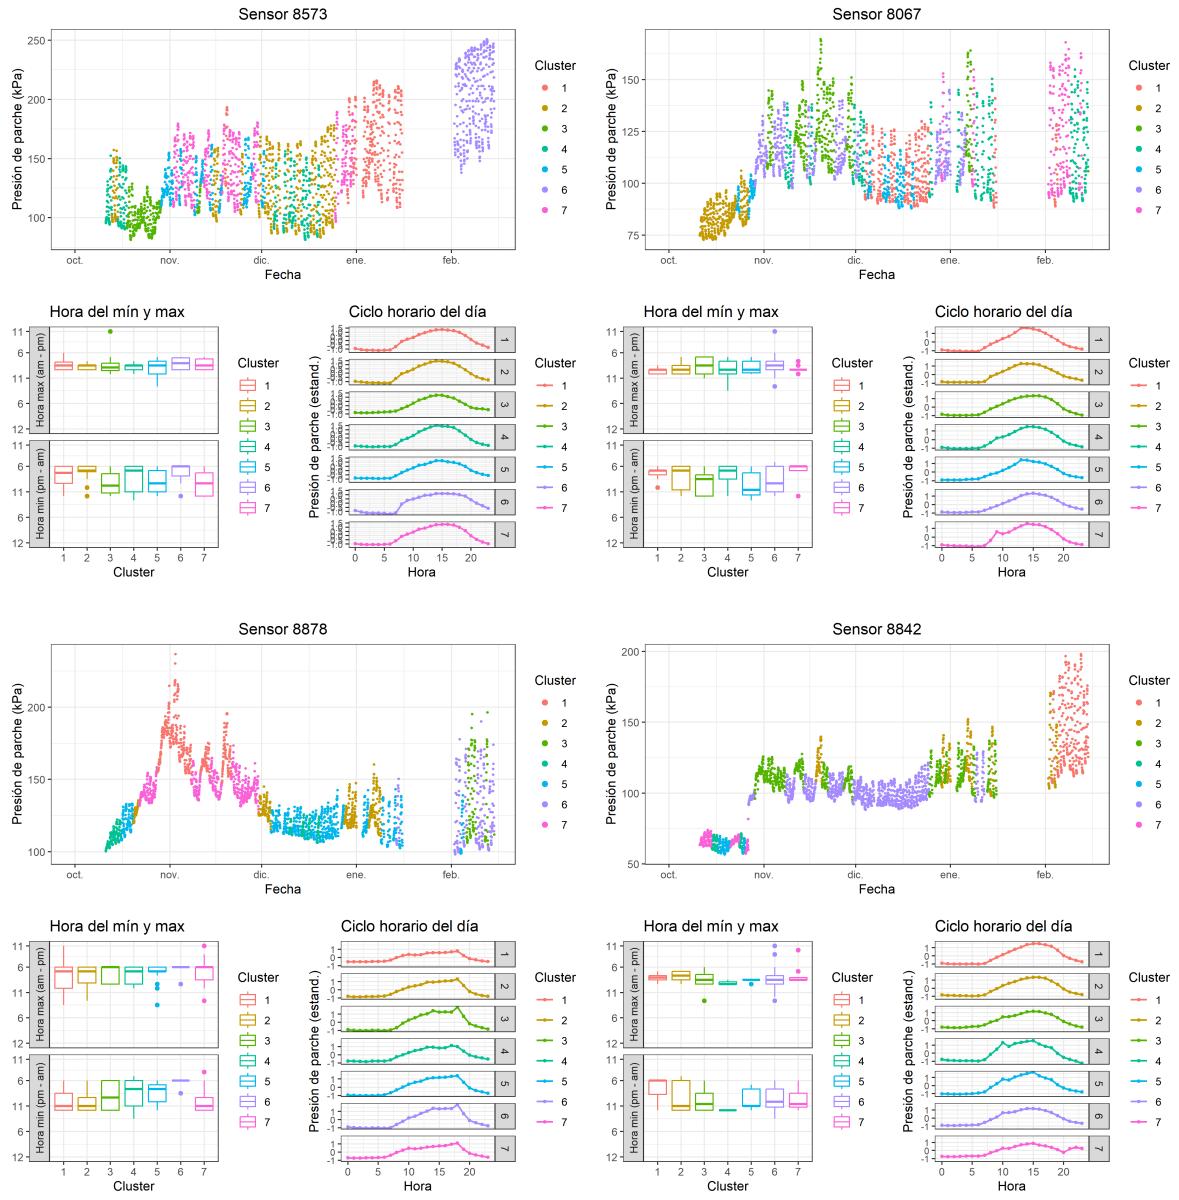
Unidad 1

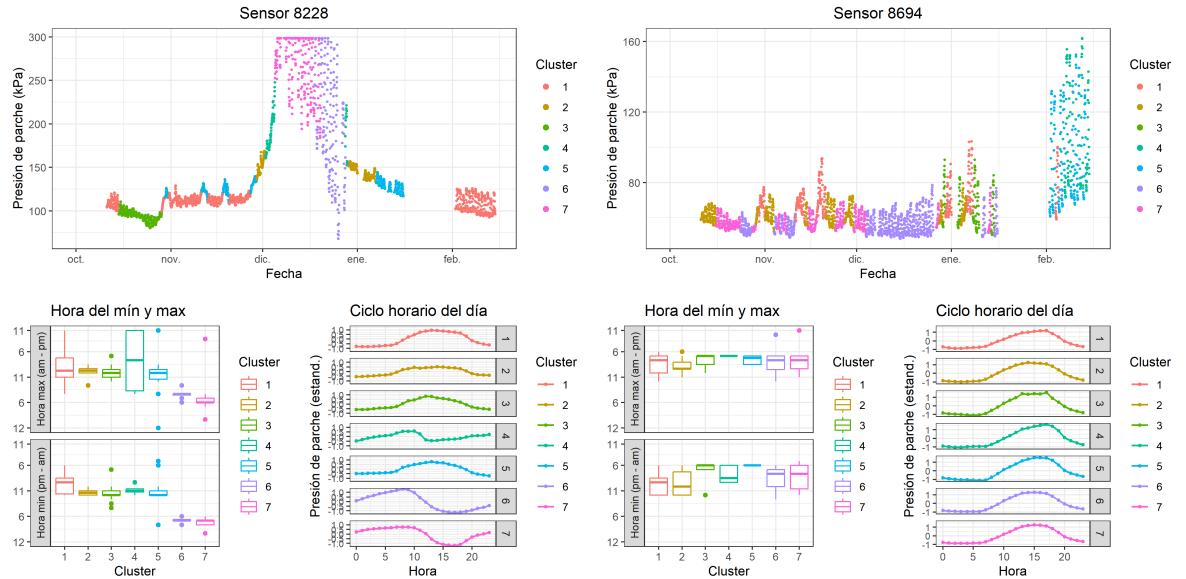




Unidad 3

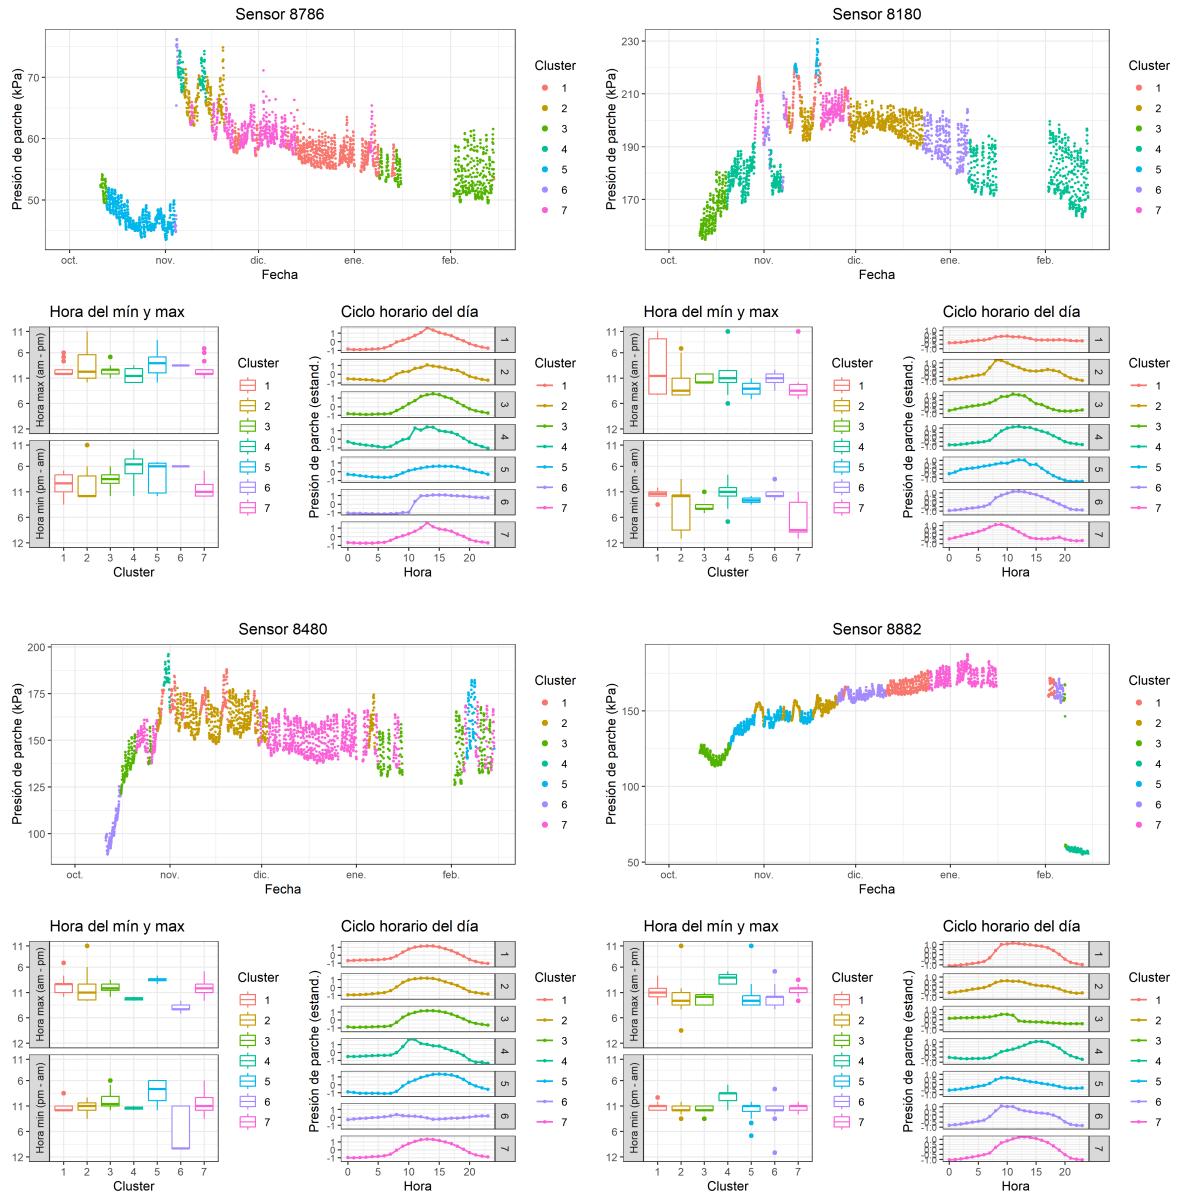
22 T3 (2023-2024)

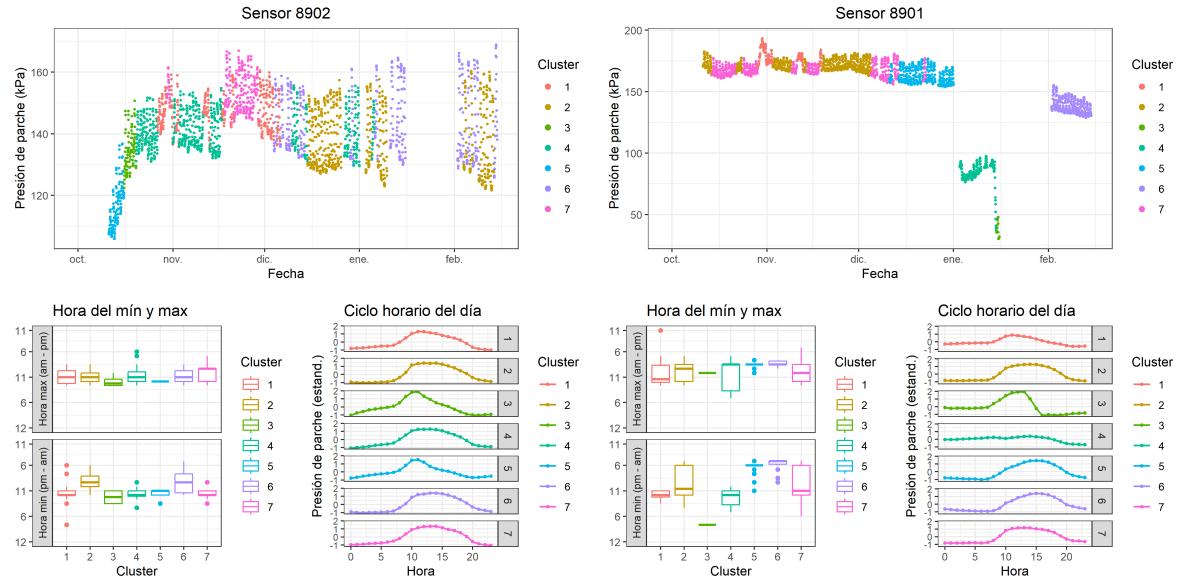




Unidad 3

23 T4 (2023-2024)

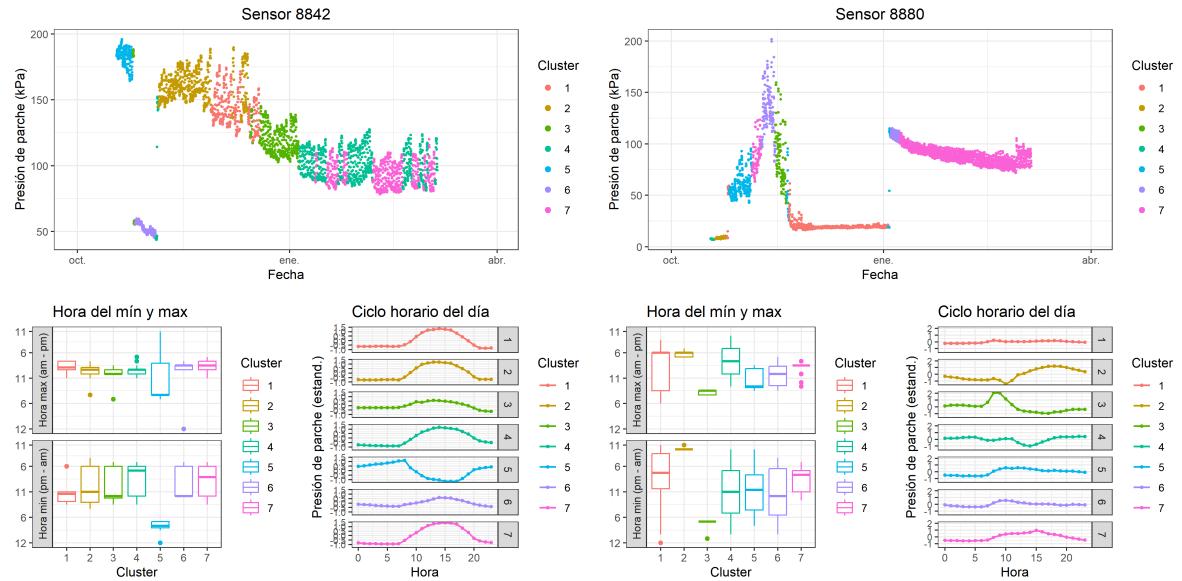




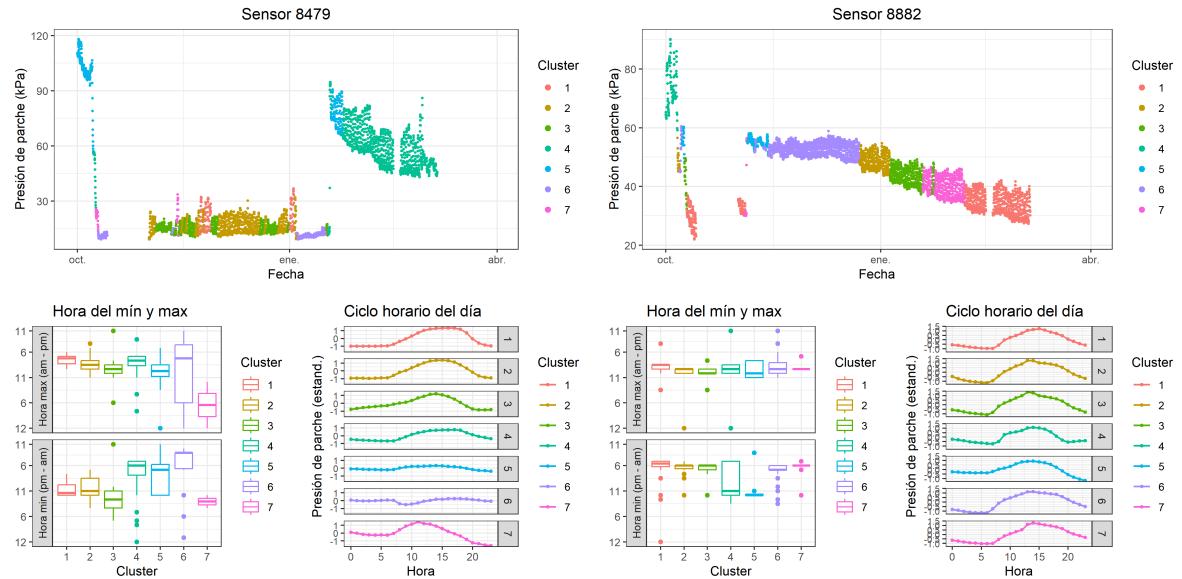
Unidad 3

23.1 Rio Claro

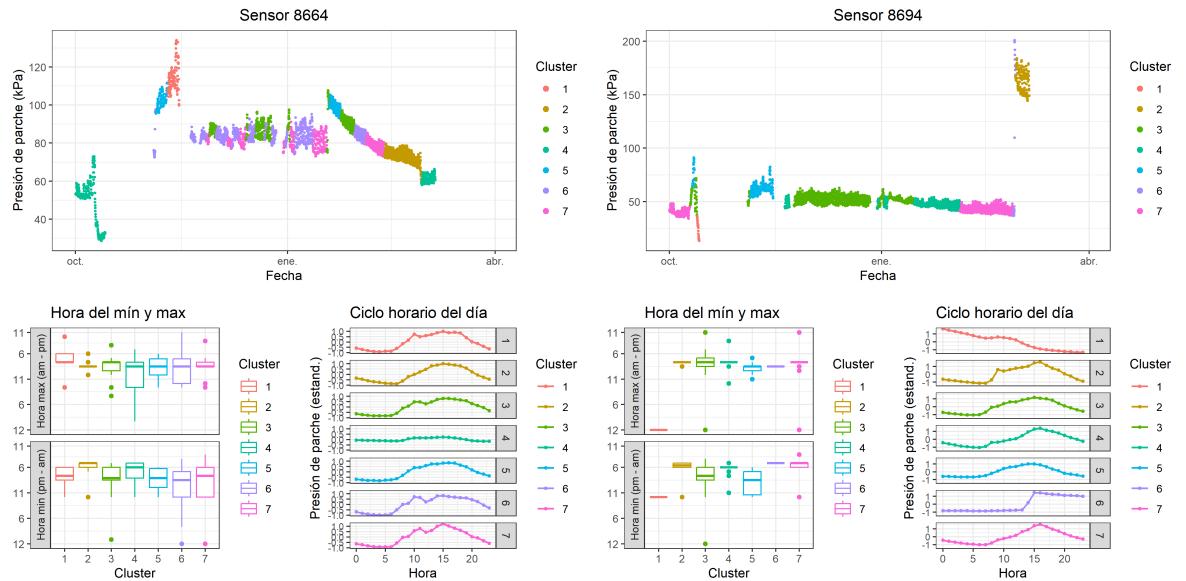
24 T1 (2022-2023)



Unidad 1

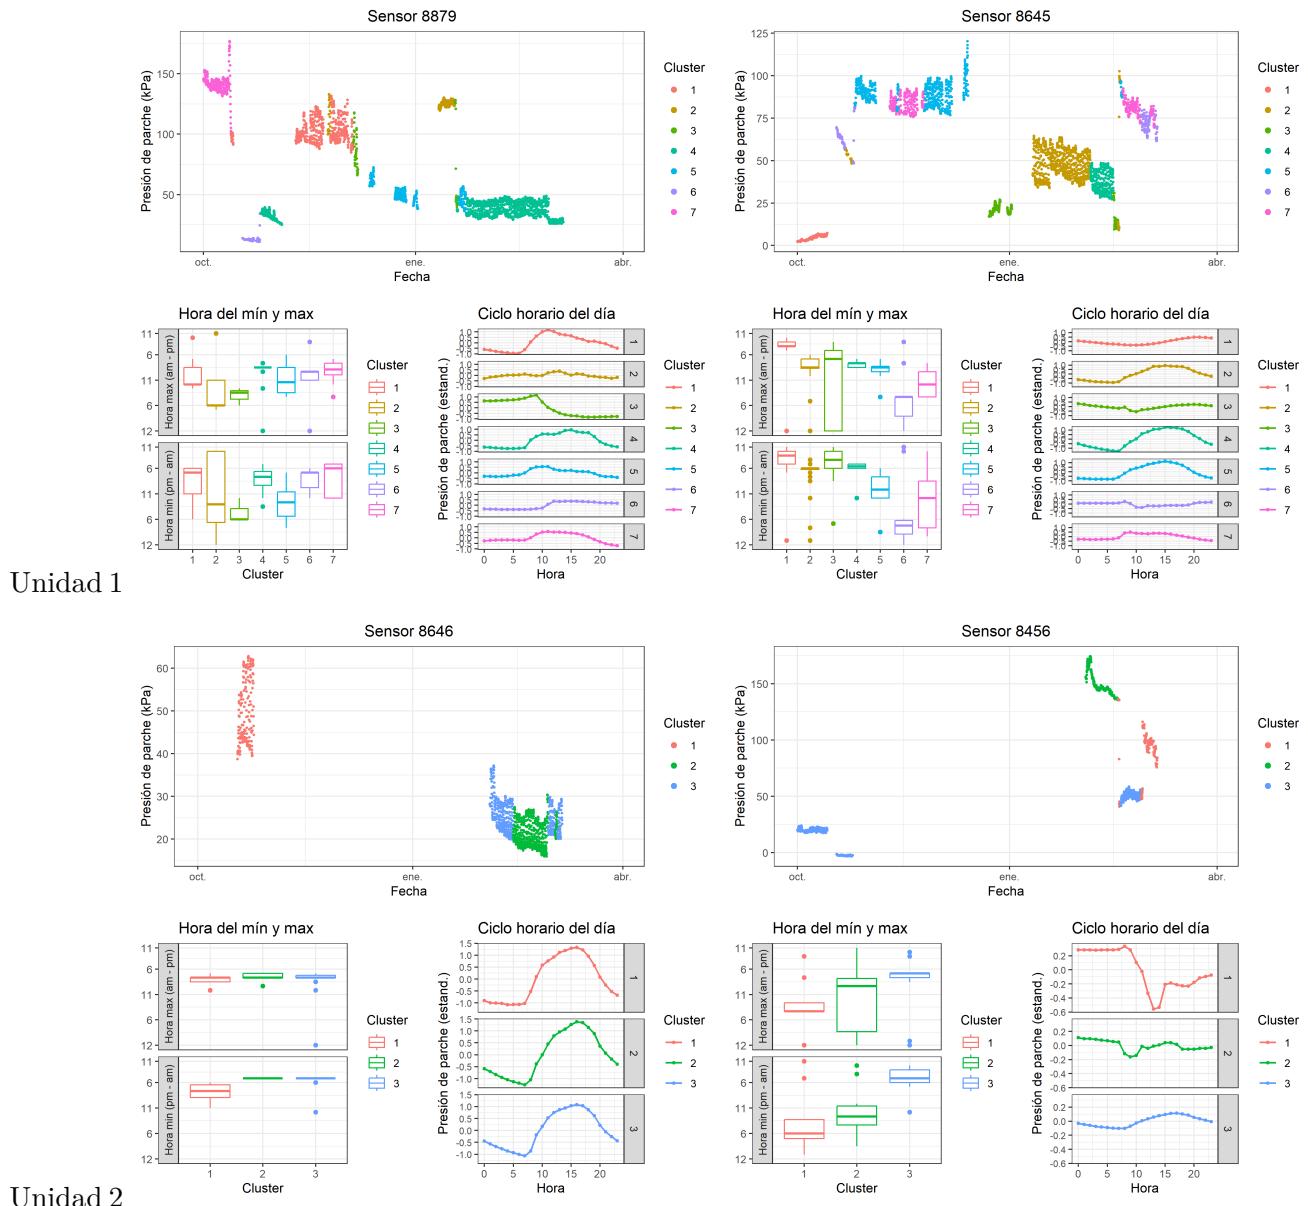


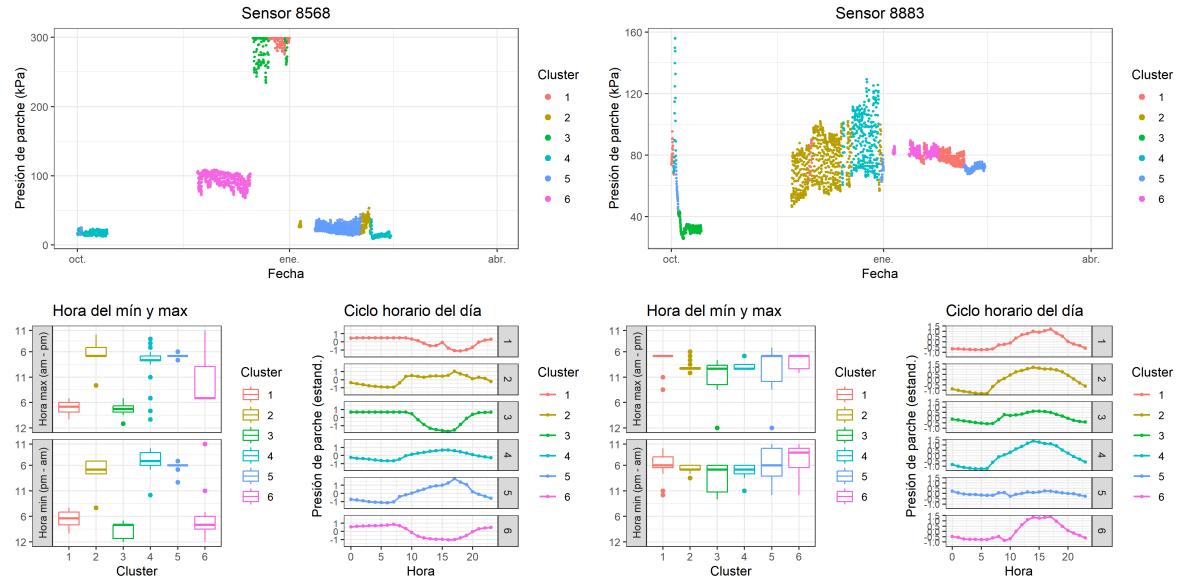
Unidad 2



Unidad 3

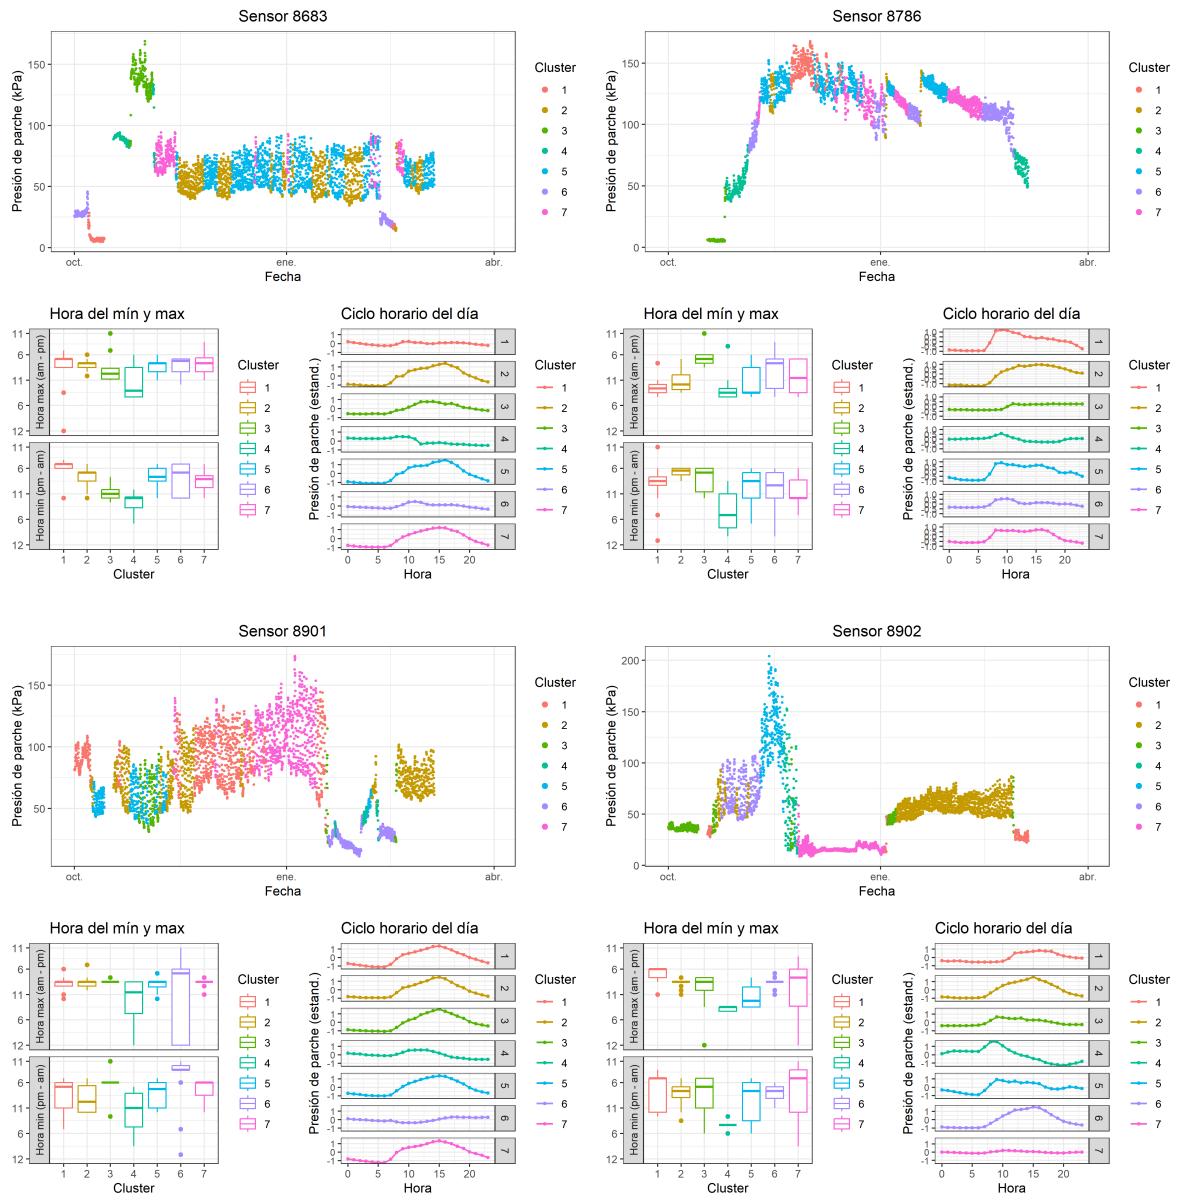
25 T2 (2022-2023)

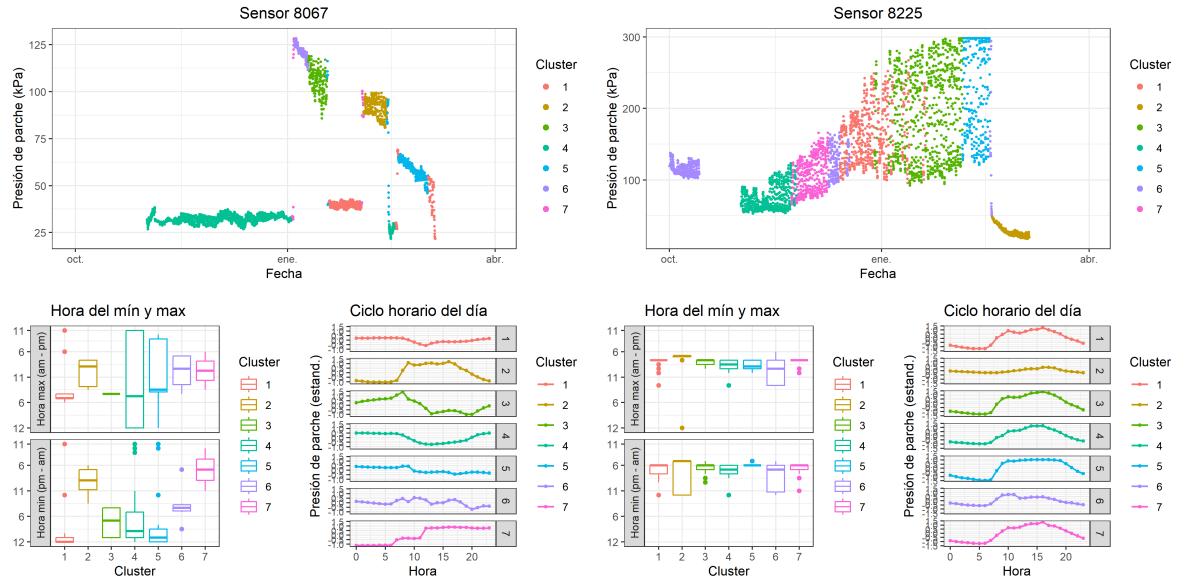




Unidad 3

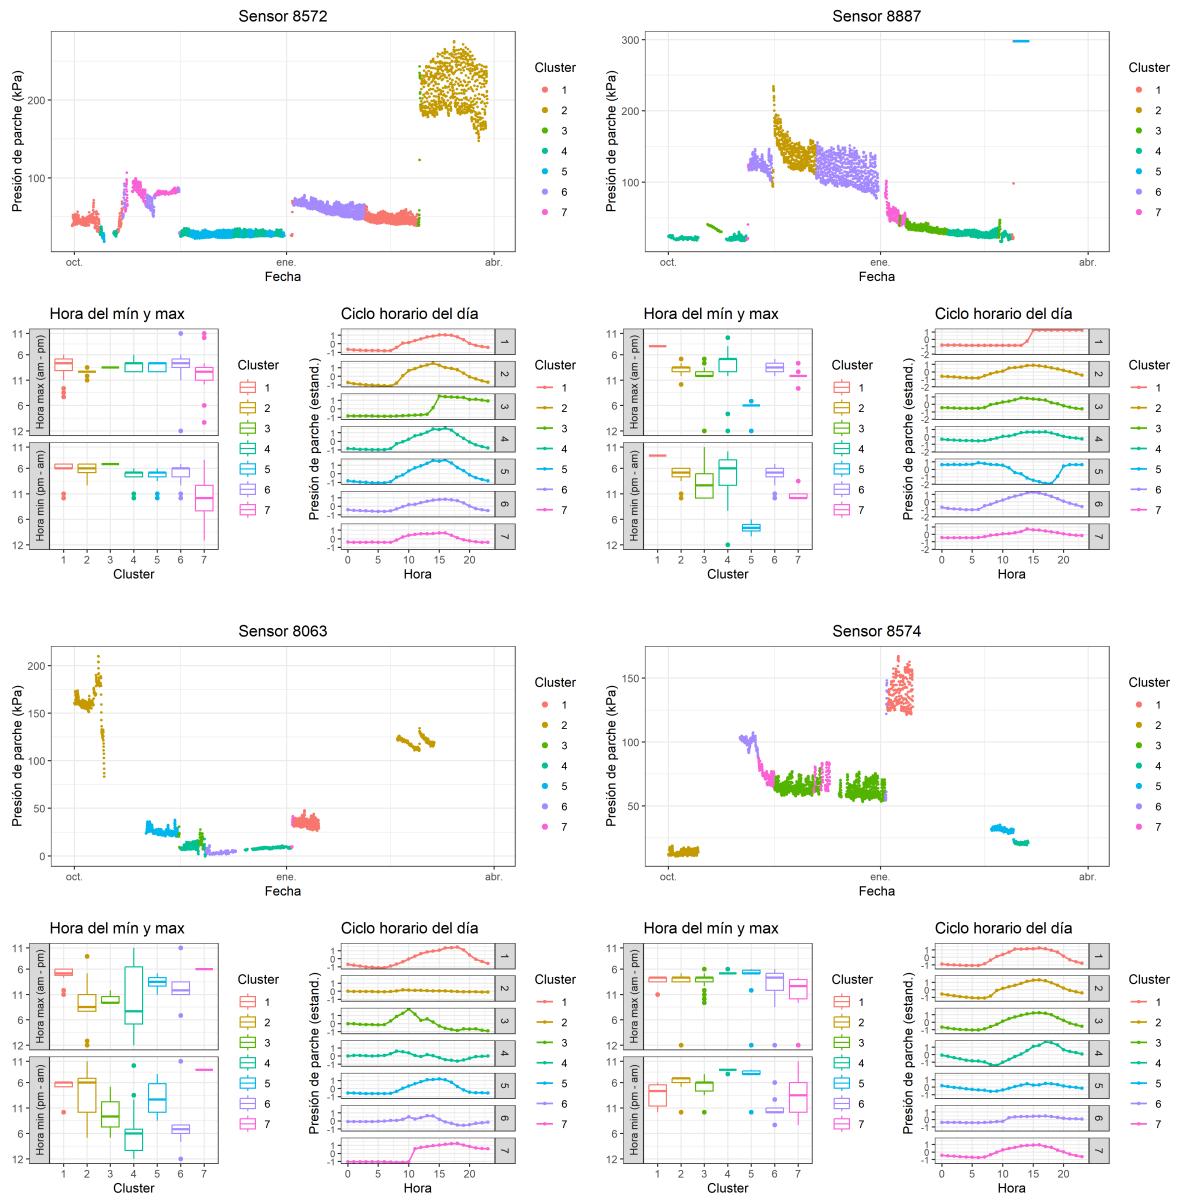
26 T3 (2022-2023)

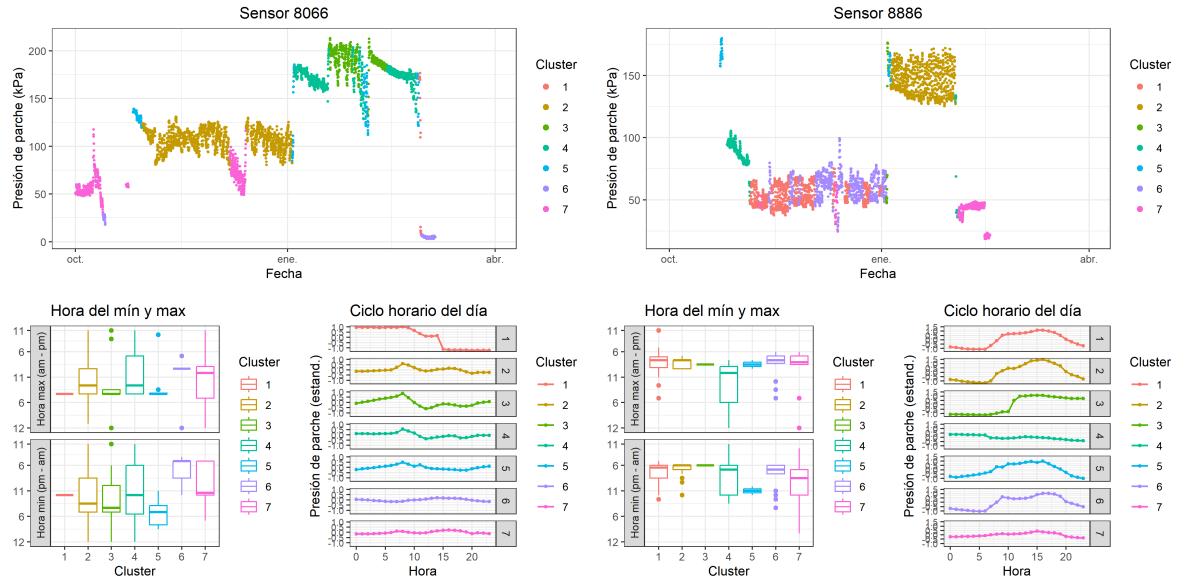




Unidad 3

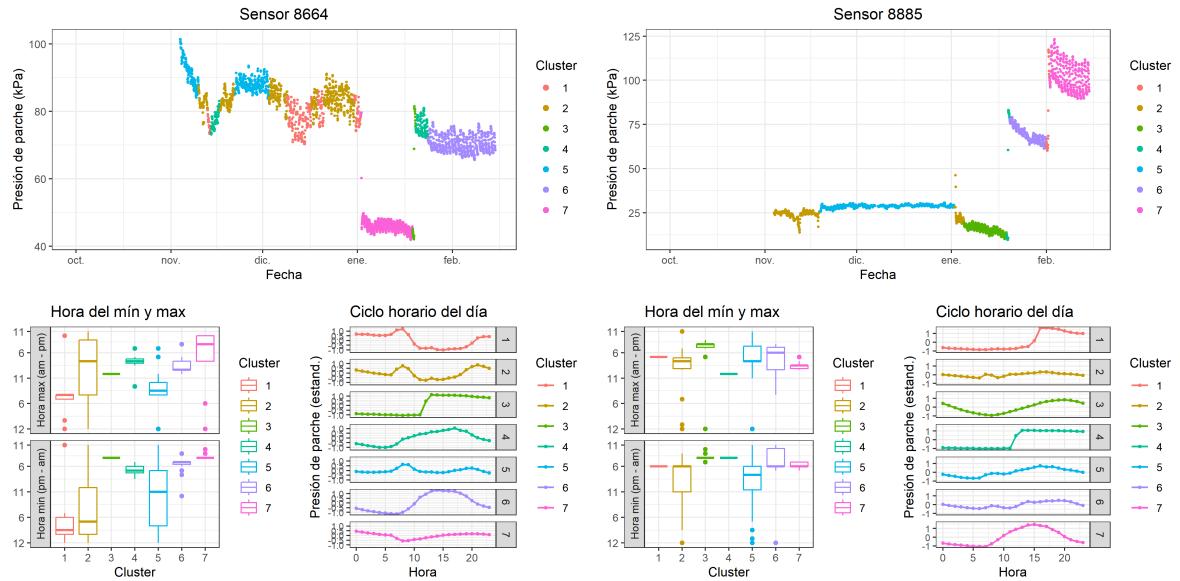
27 T4 (2022-2023)



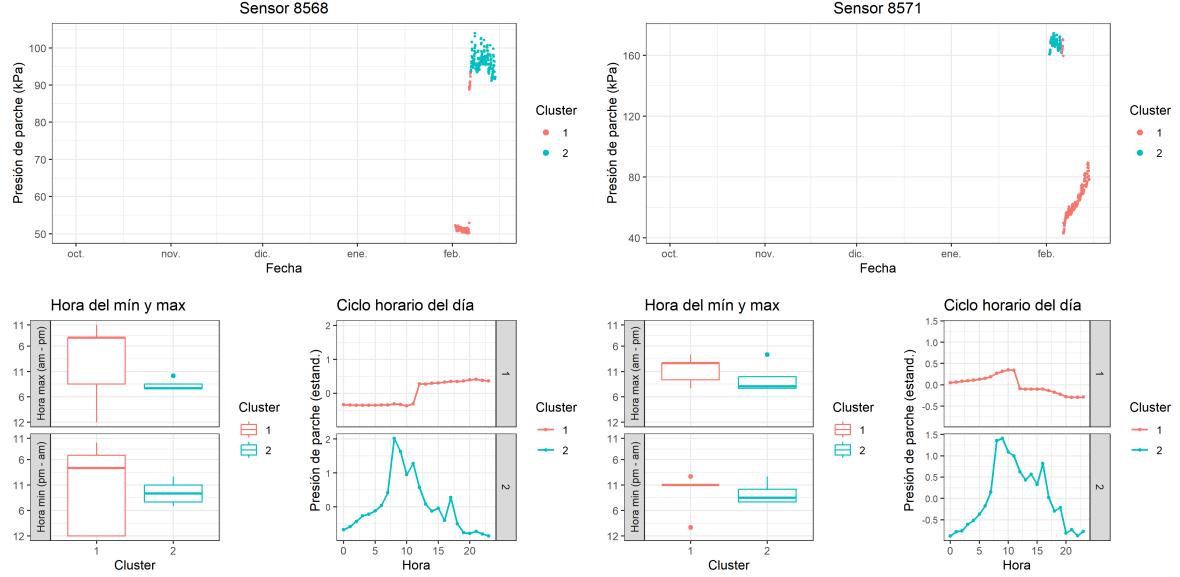


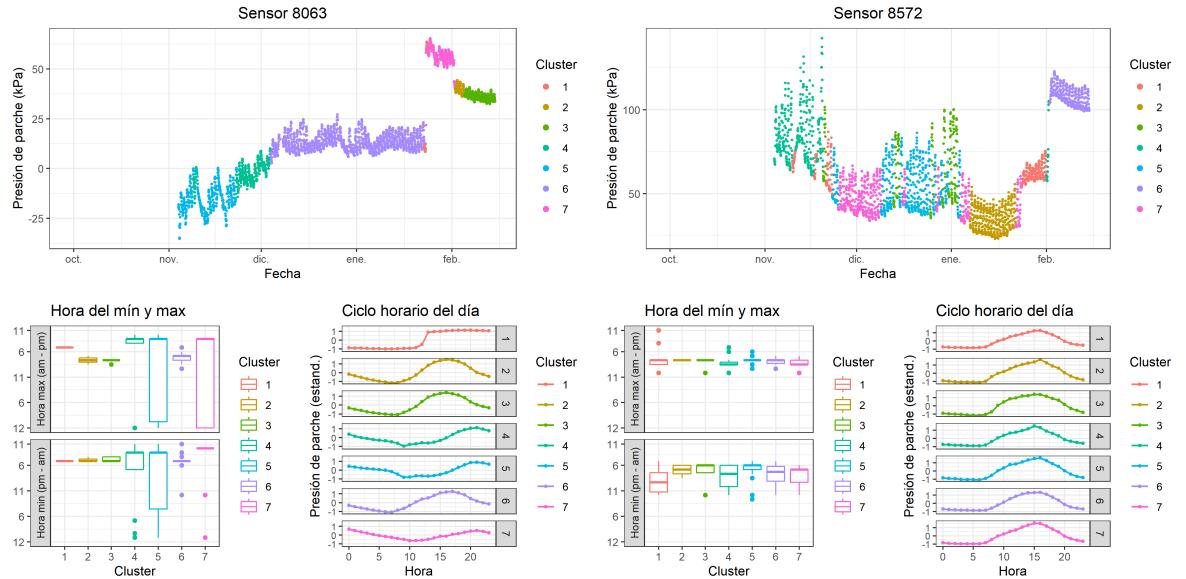
Unidad 3

28 T1 (2023-2024)



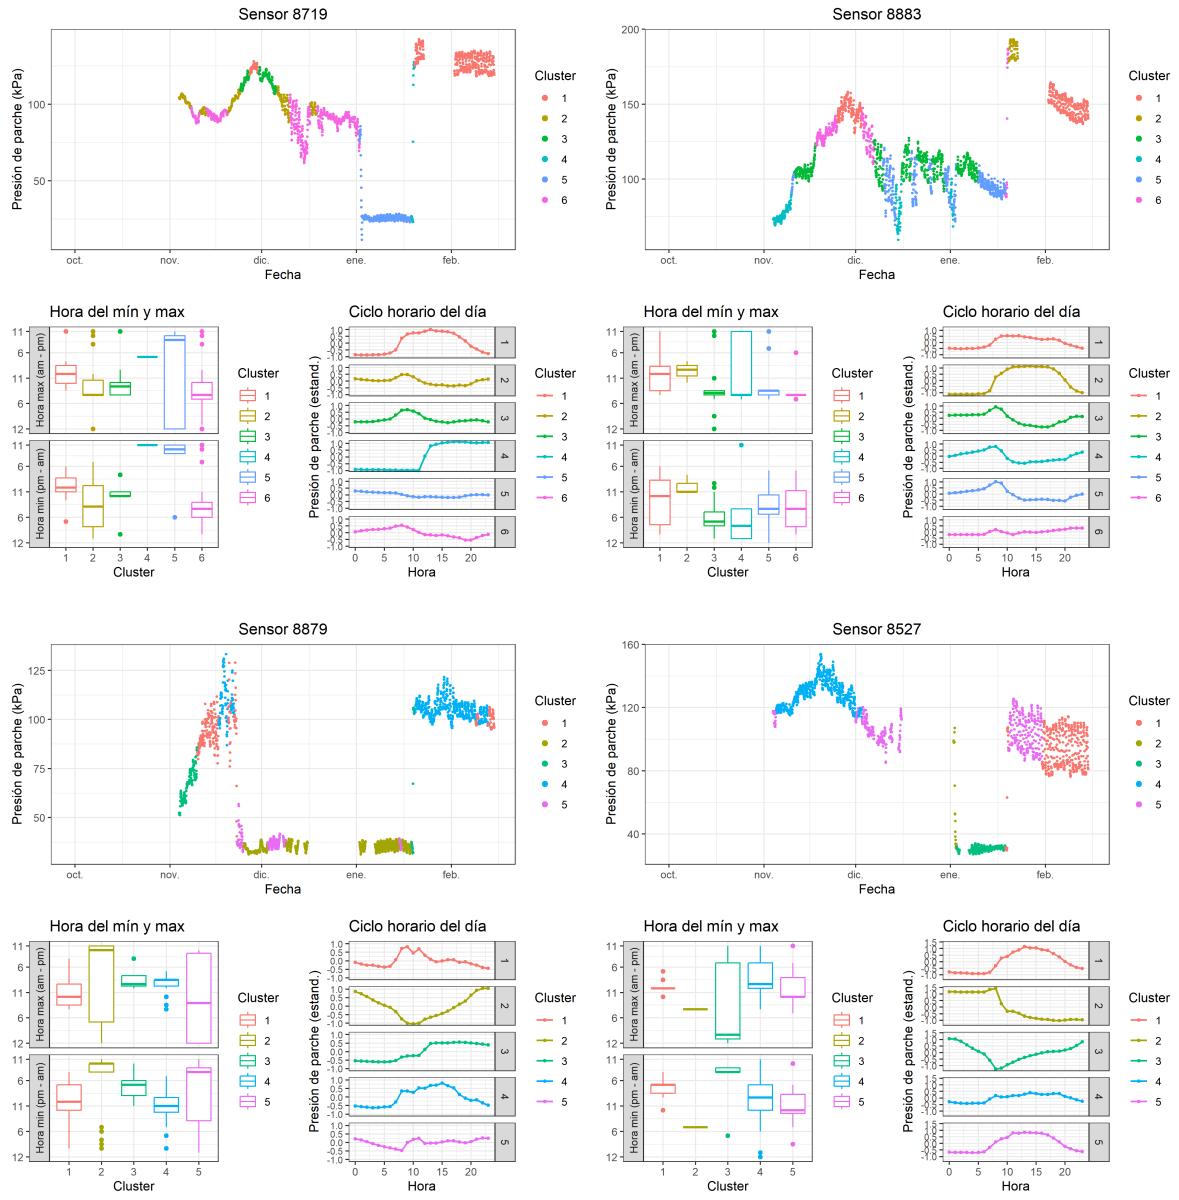
Unidad 1

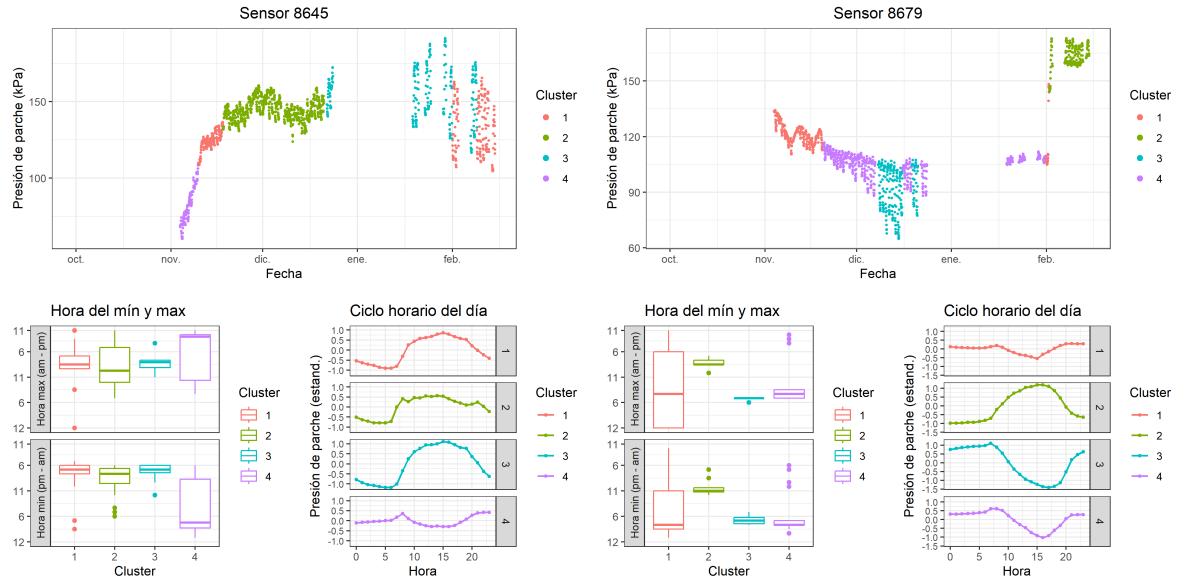




Unidad 3

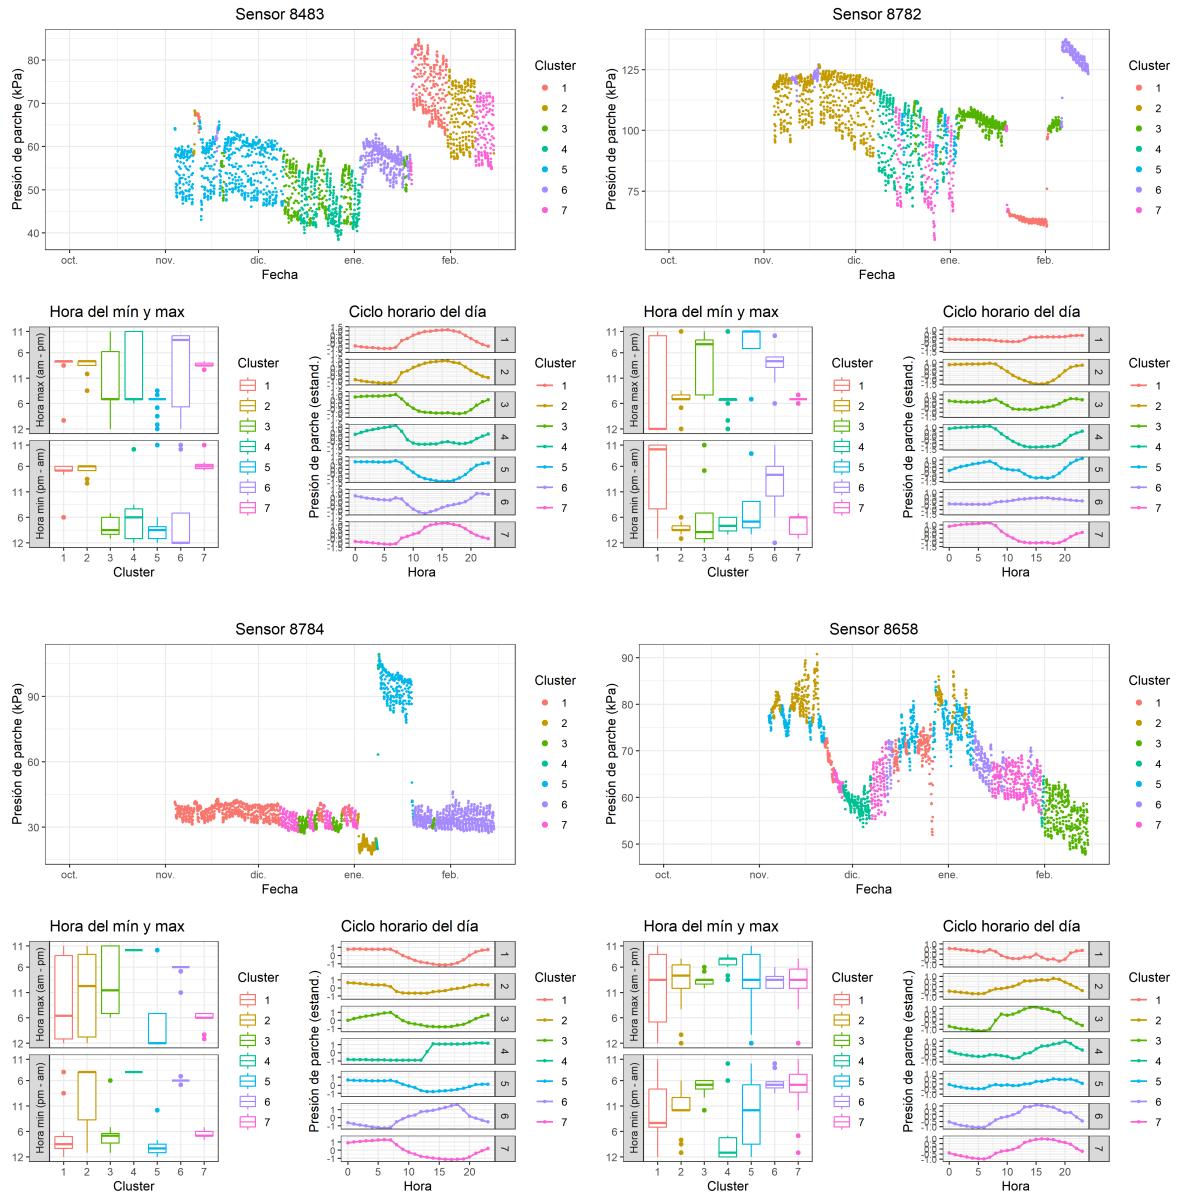
29 T2 (2023-2024)

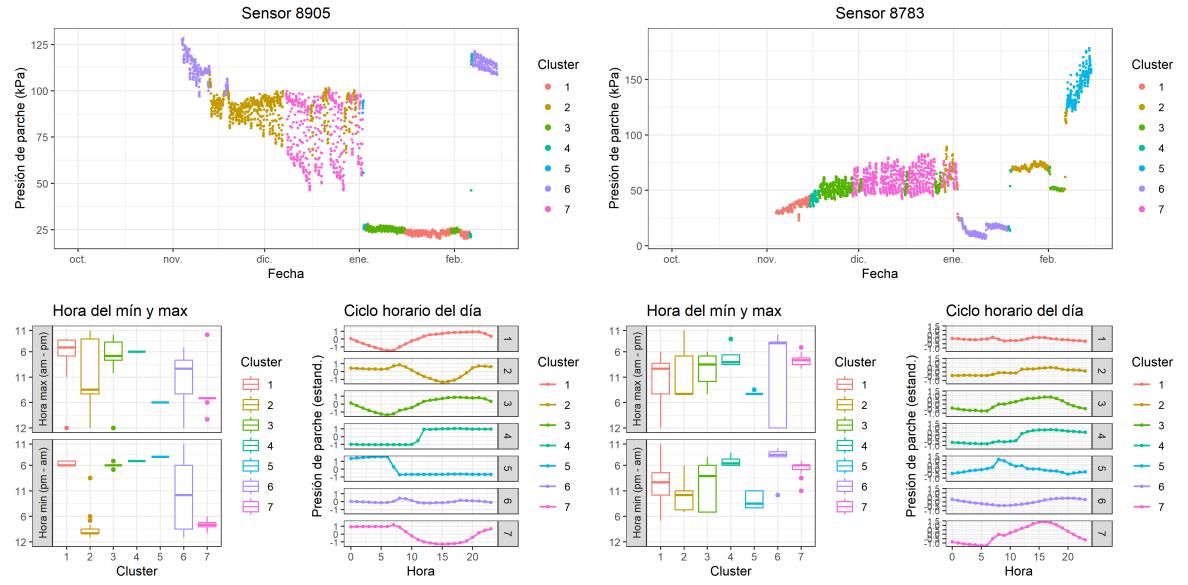




Unidad 3

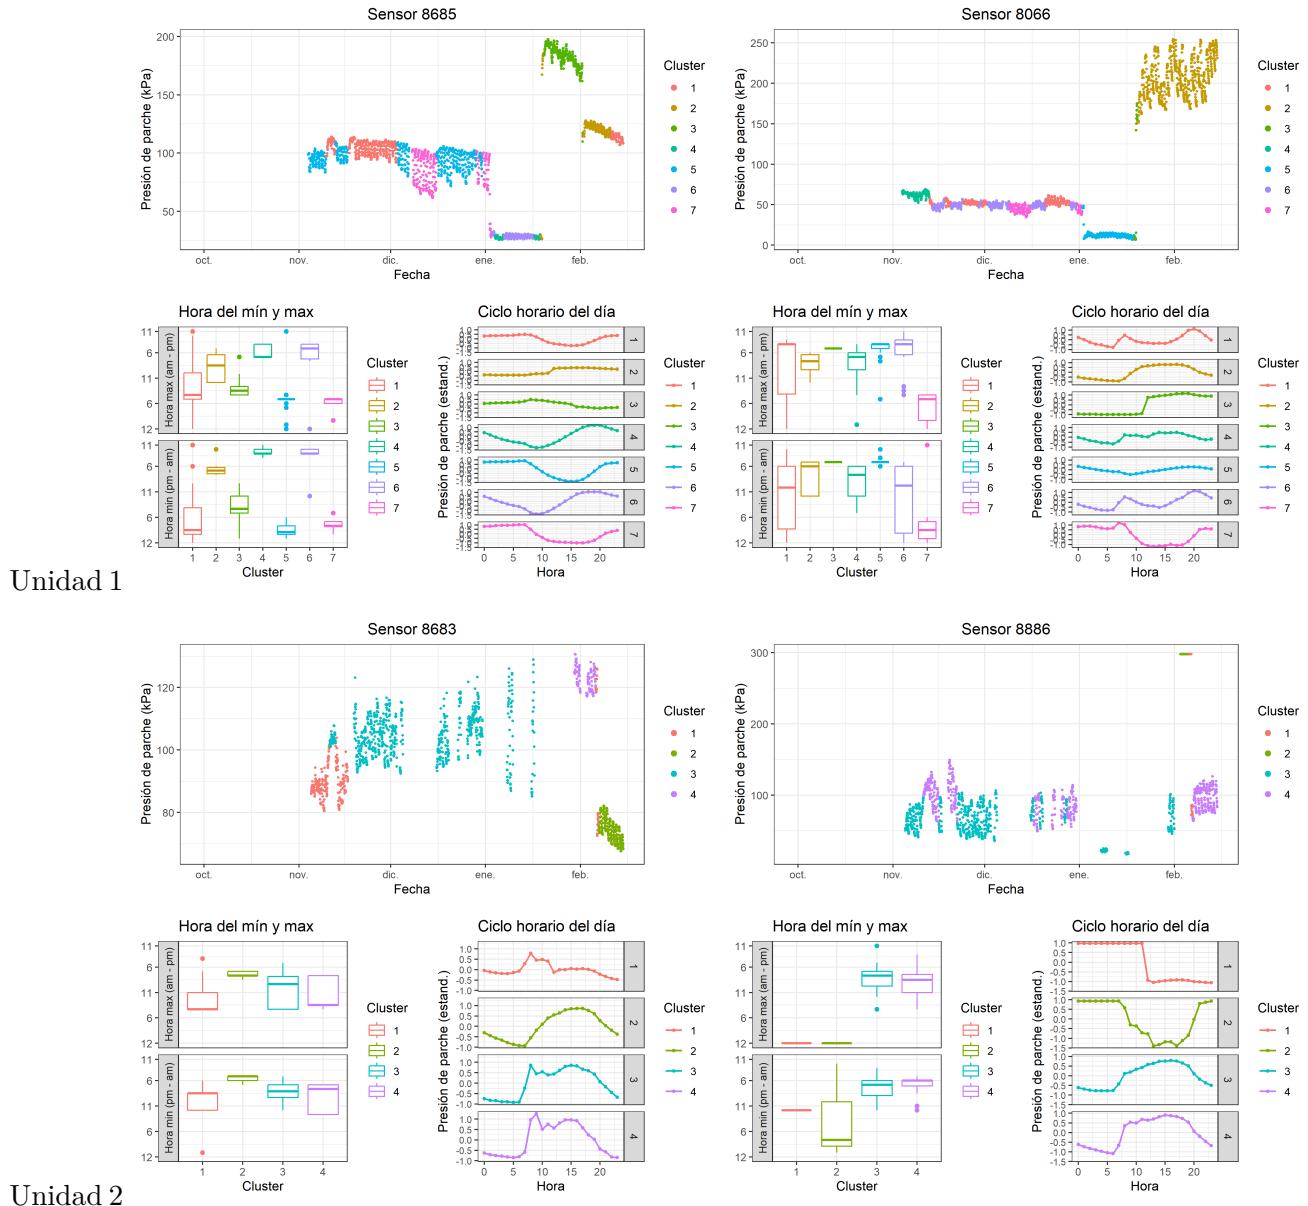
30 T3 (2023-2024)

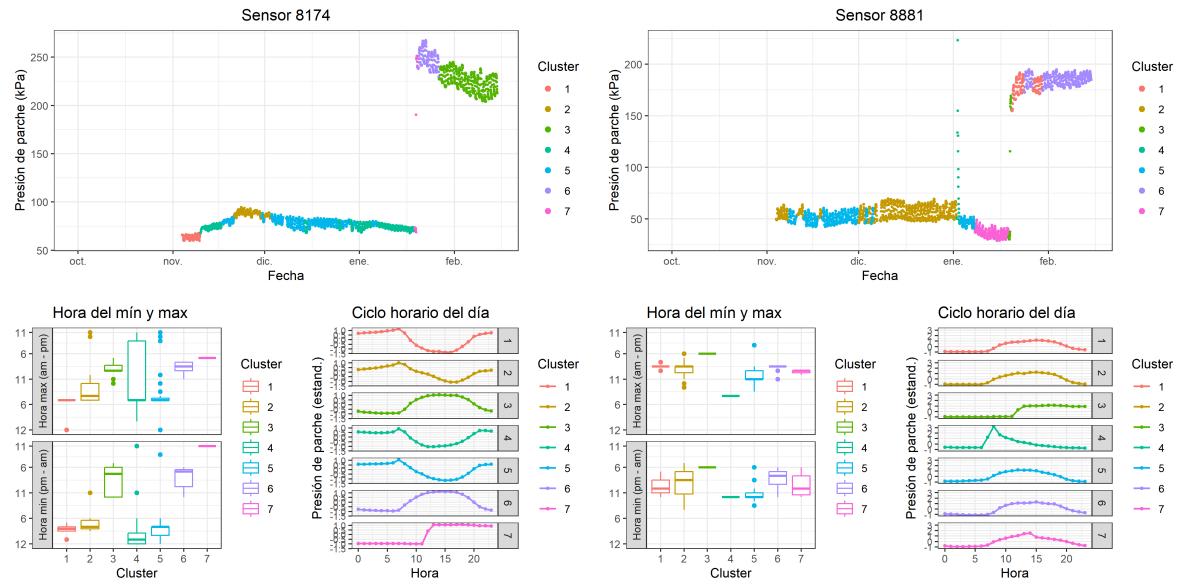




Unidad 3

31 T4 (2023-2024)





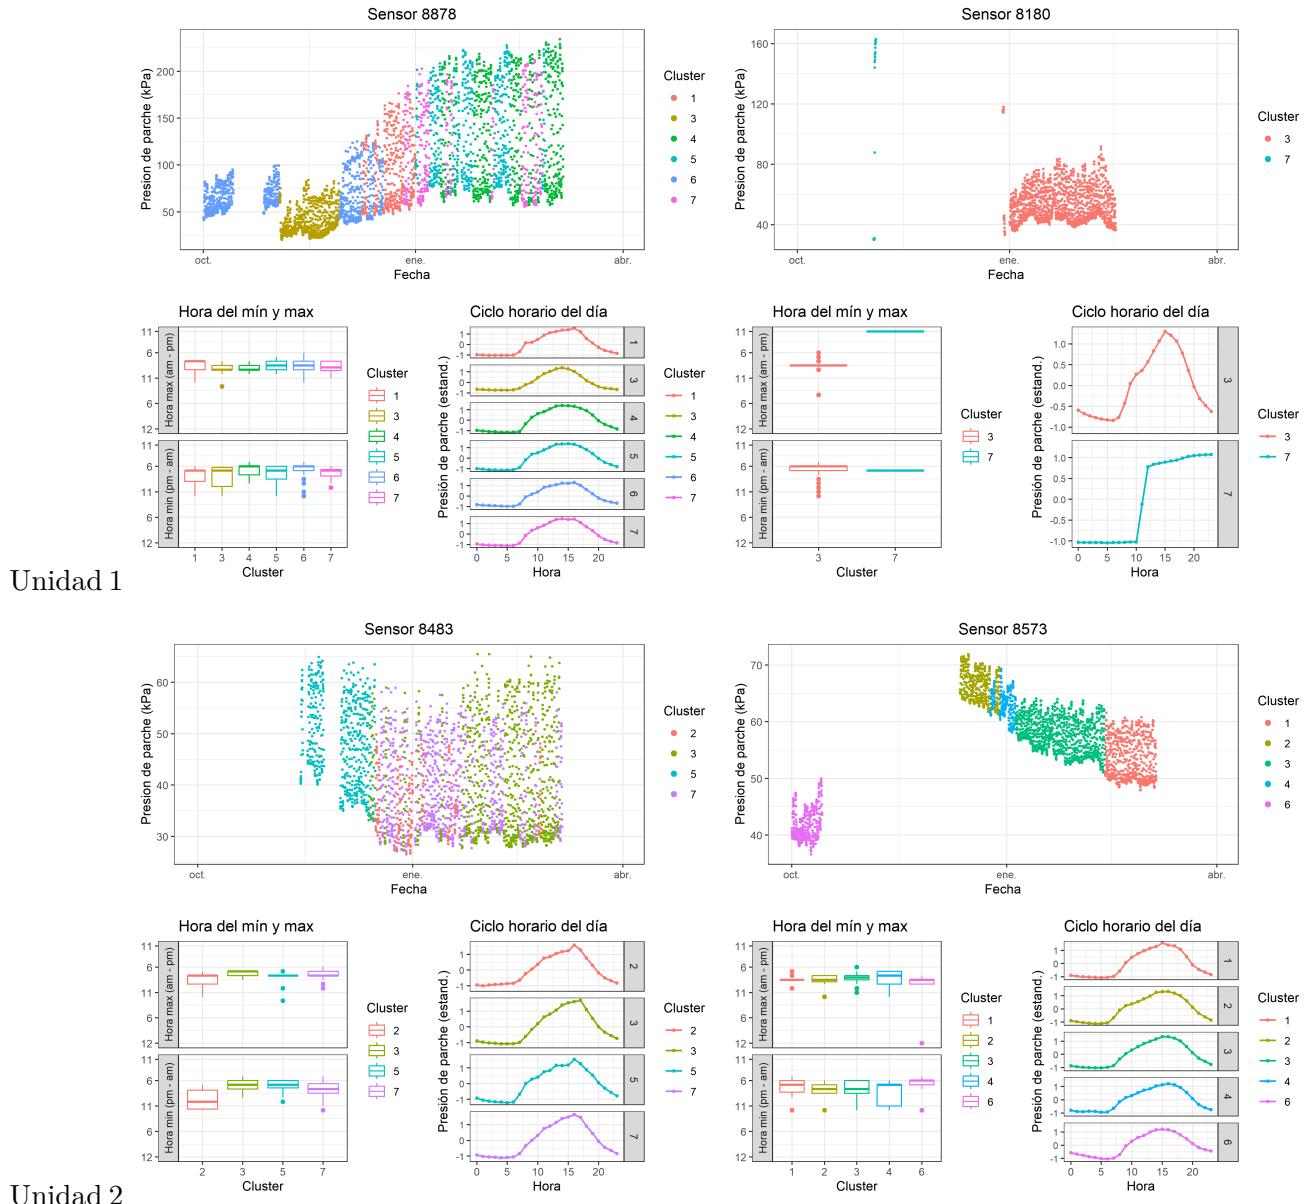
Unidad 3

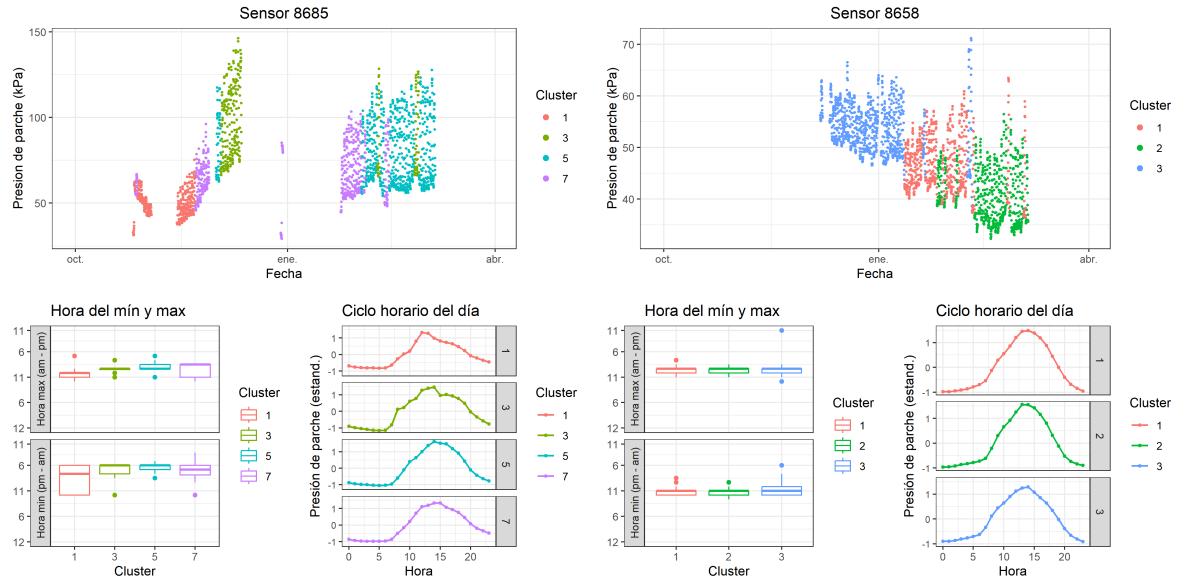
32 Limpieza de datos: eliminación de clusters

Para limpiar los datos de turgor, se emplearon series temporales de VPD y temperatura provenientes de las estaciones meteorológicas de los dos sitios de estudio. Se procedió a calcular el coeficiente de correlación entre cada cluster y los valores de VPD y temperatura respecto al tiempo (escala horaria) y el sitio. Se obtuvo un coeficiente de correlación promedio en relación con ambas variables, y se estableció un umbral de corte de $r > 0.5$. Aquellos clusters de turgor cuyo promedio de correlación resultó menor a 0.5 fueron descartados.

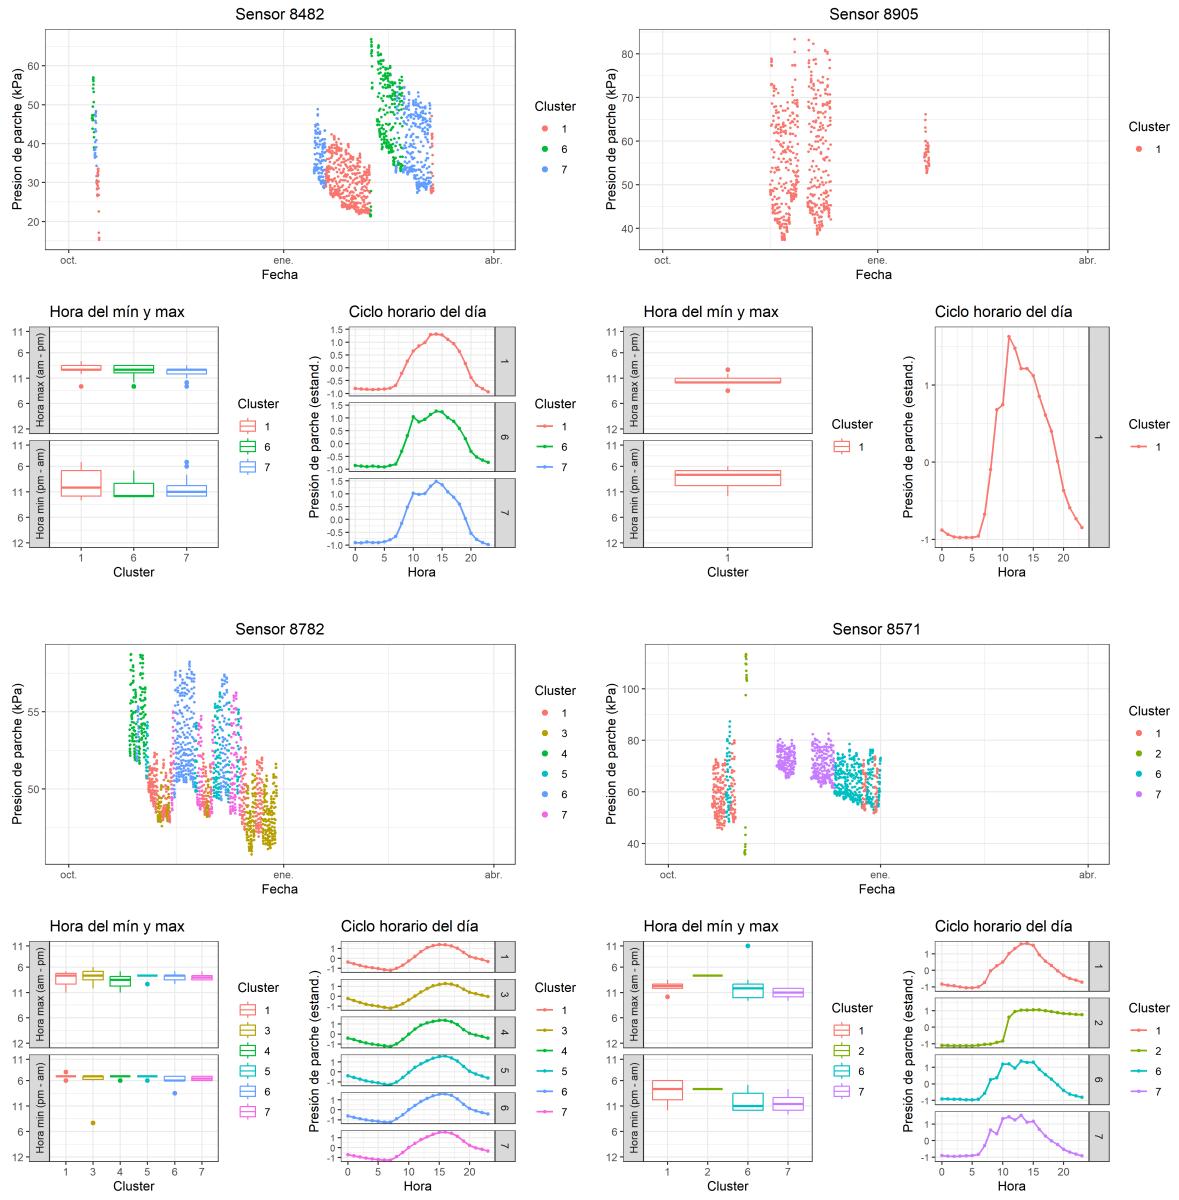
32.1 La Esperanza

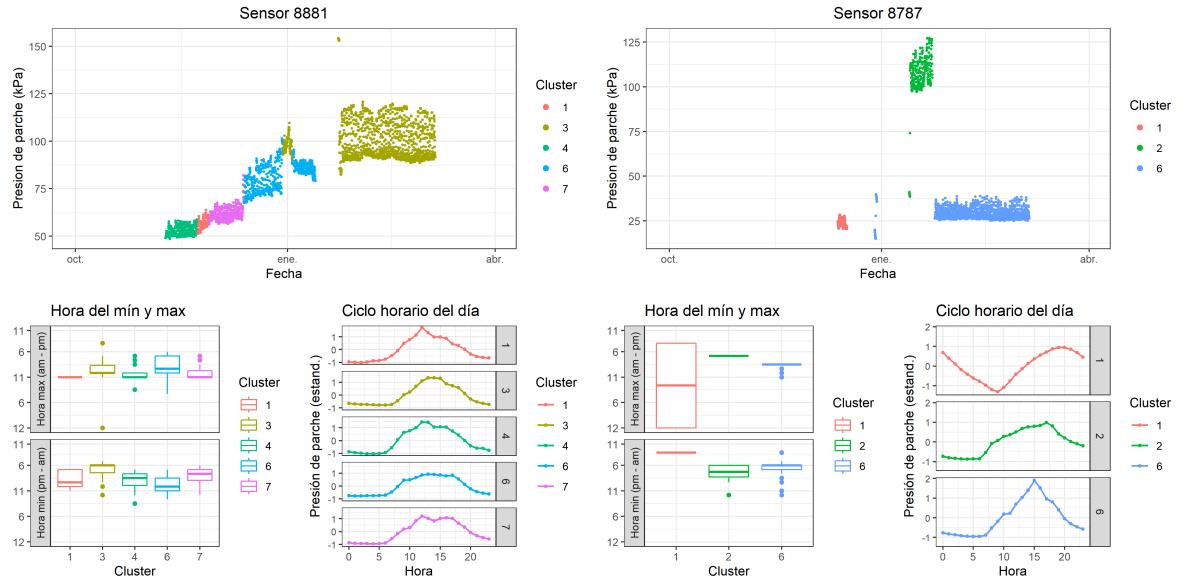
33 T1 (2022-2023)





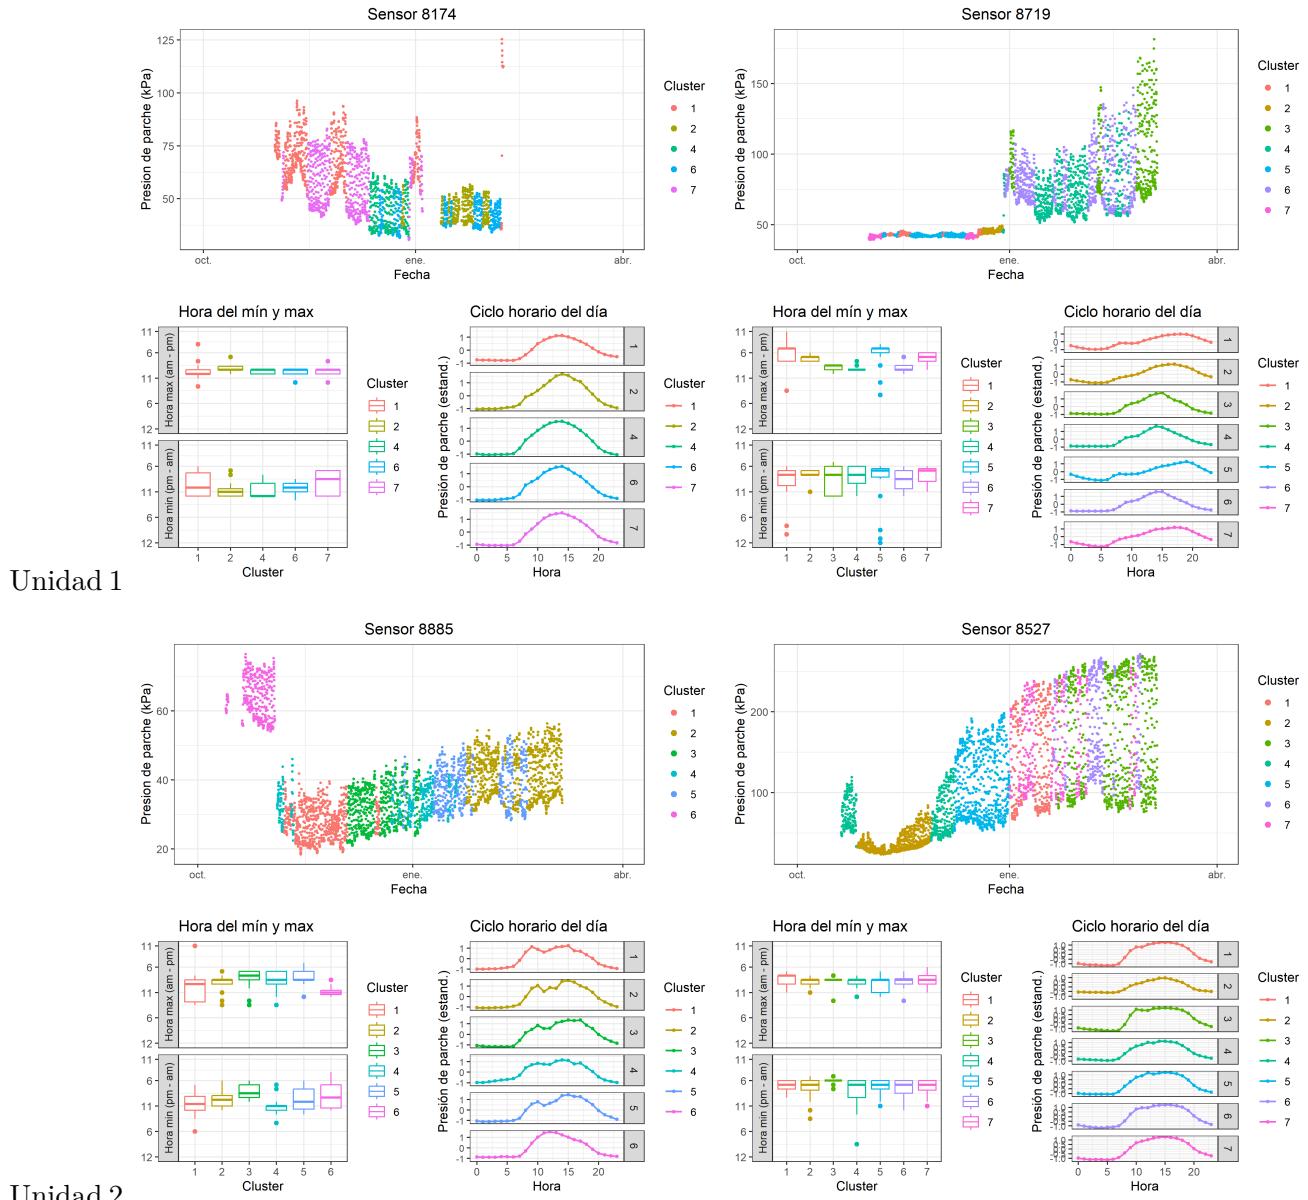
34 T2 (2022-2023)

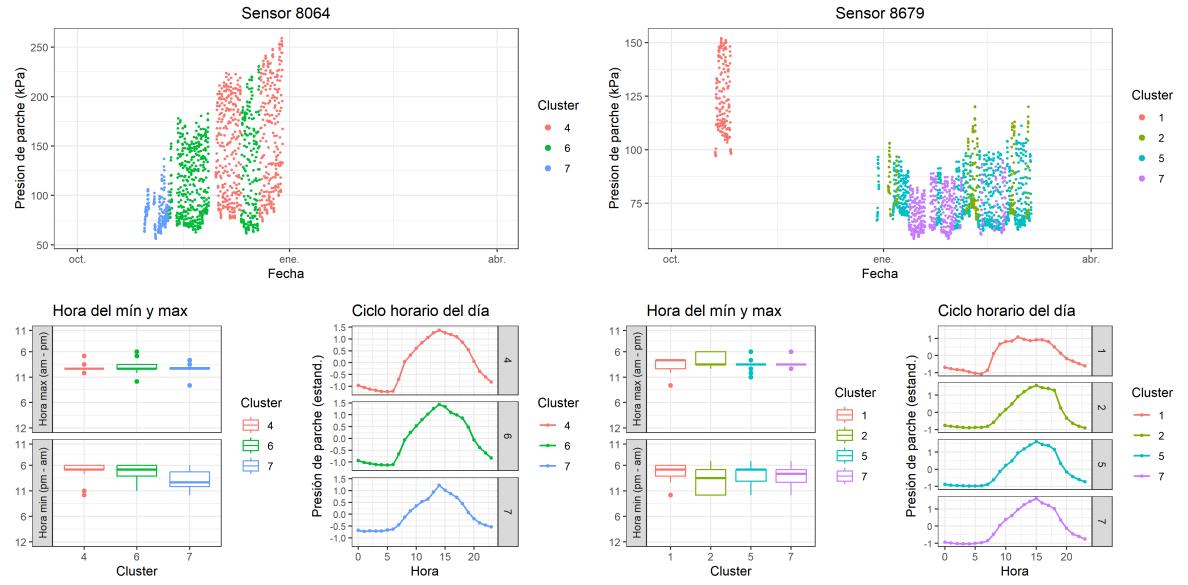




Unidad 3

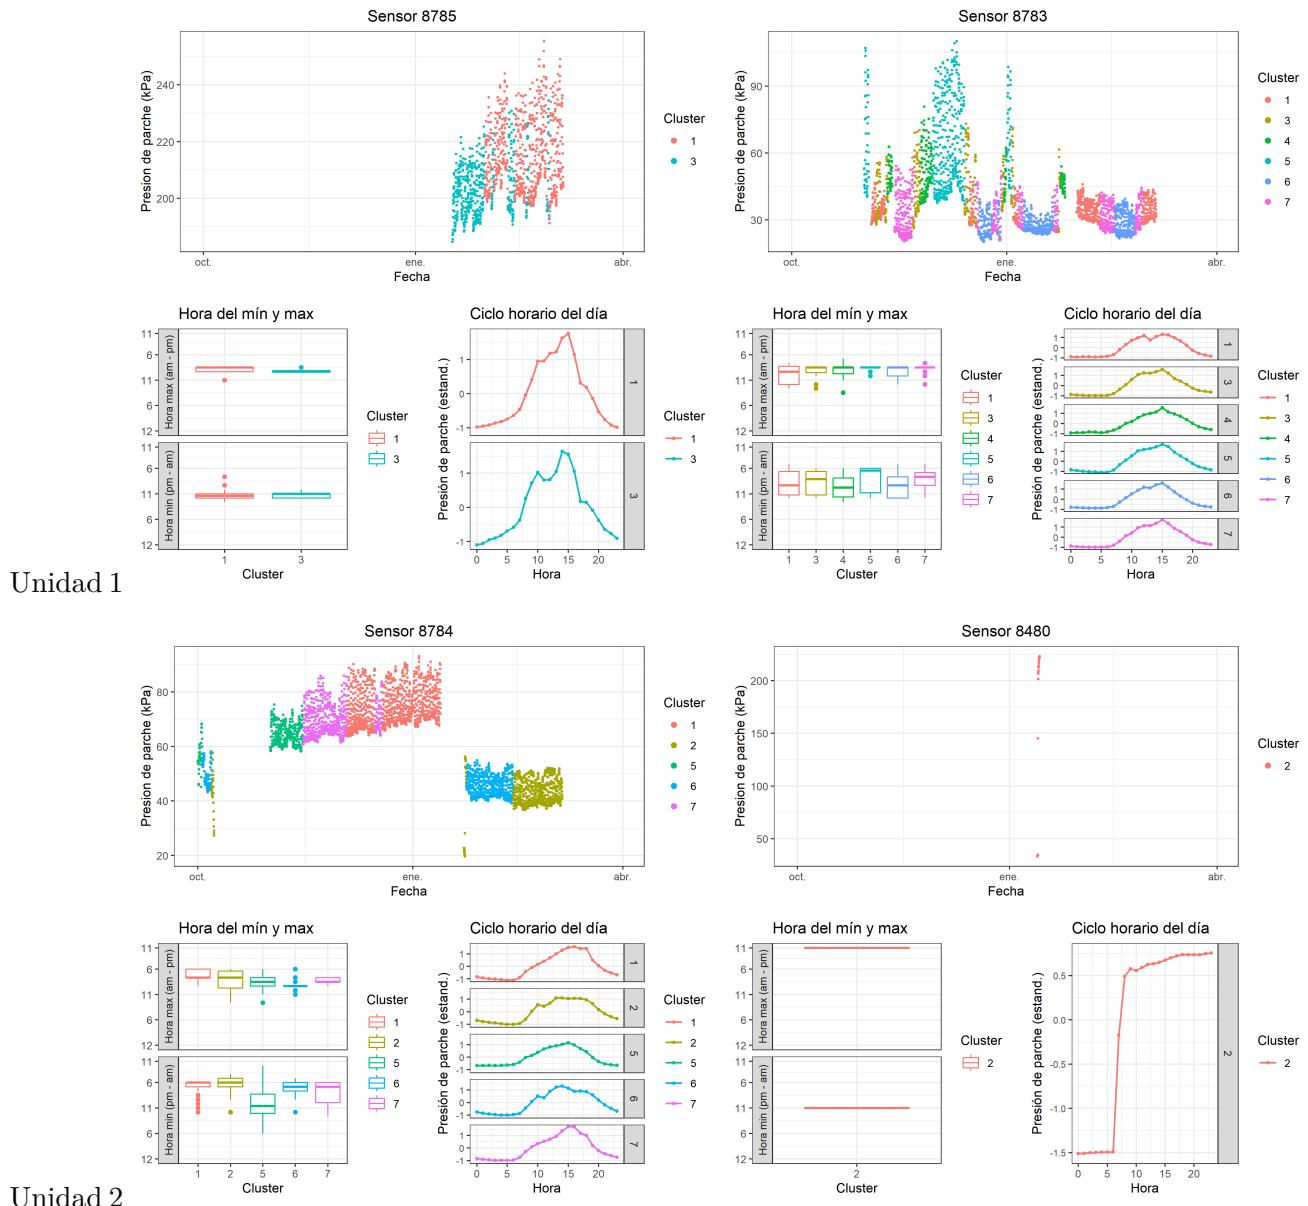
35 T3 (2022-2023)

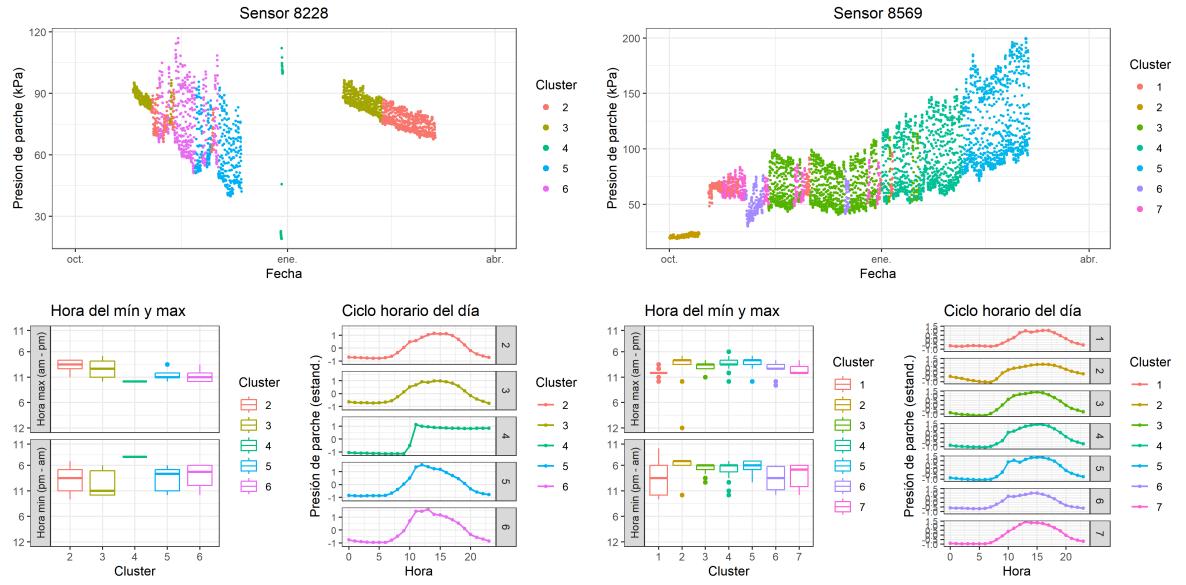




Unidad 3

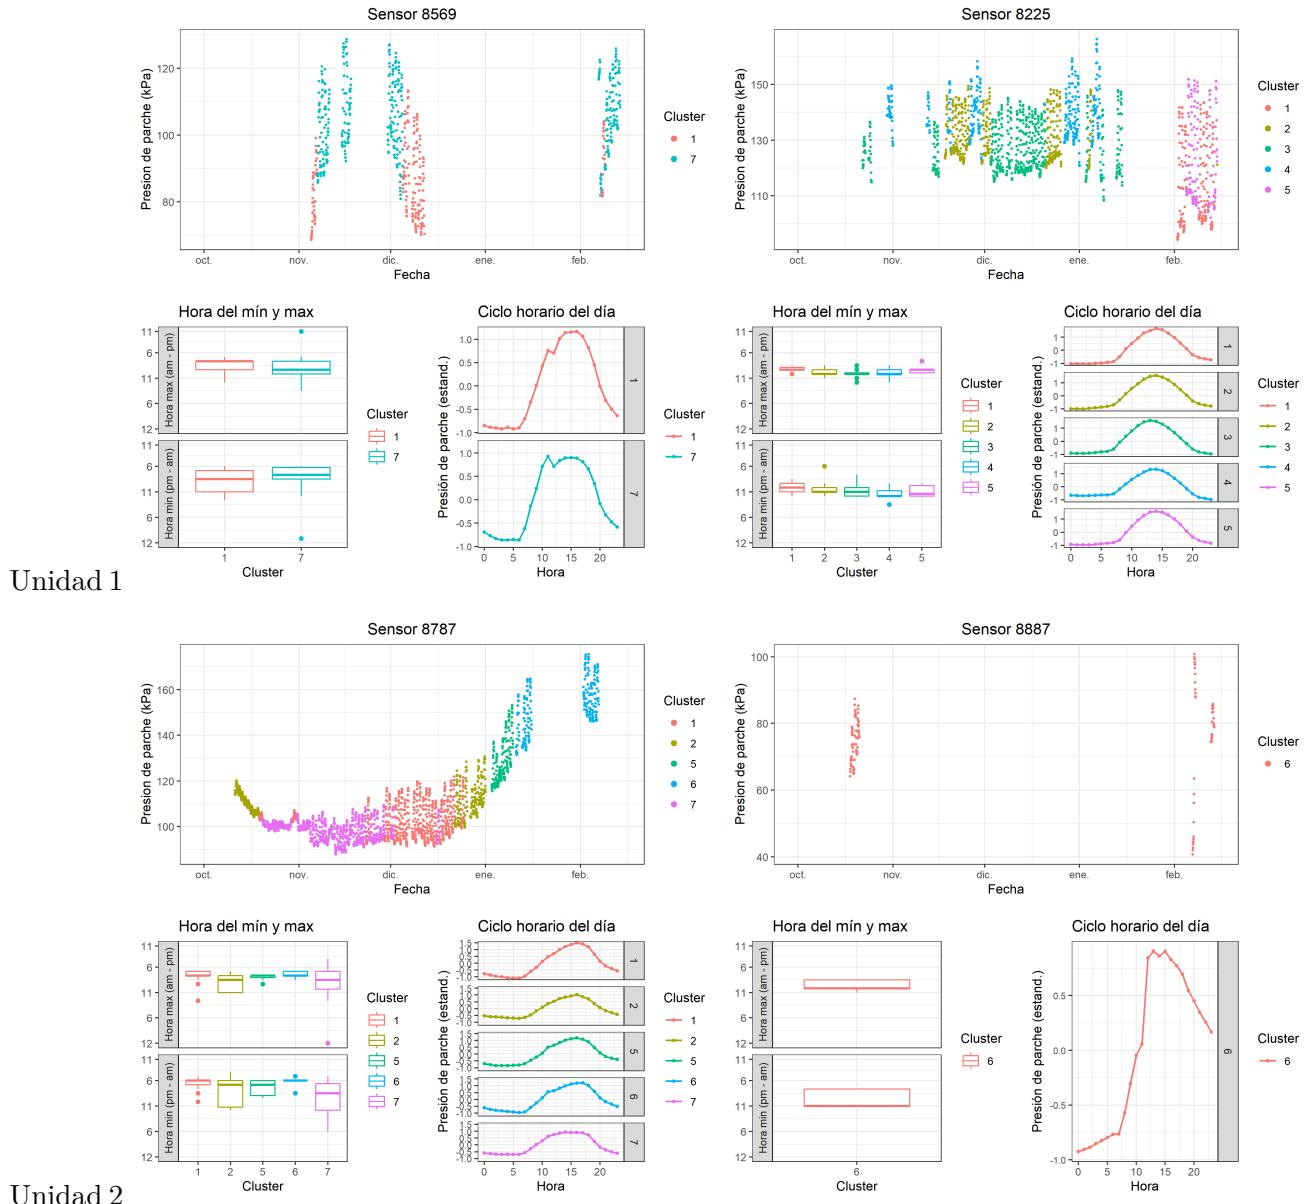
36 T4 (2022-2023)

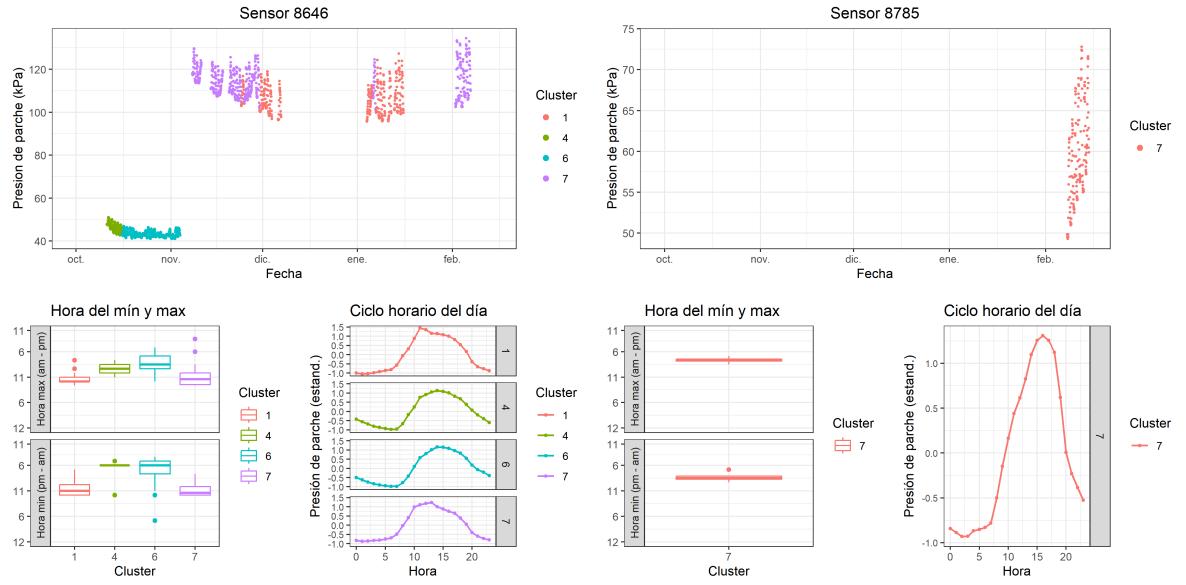




Unidad 3

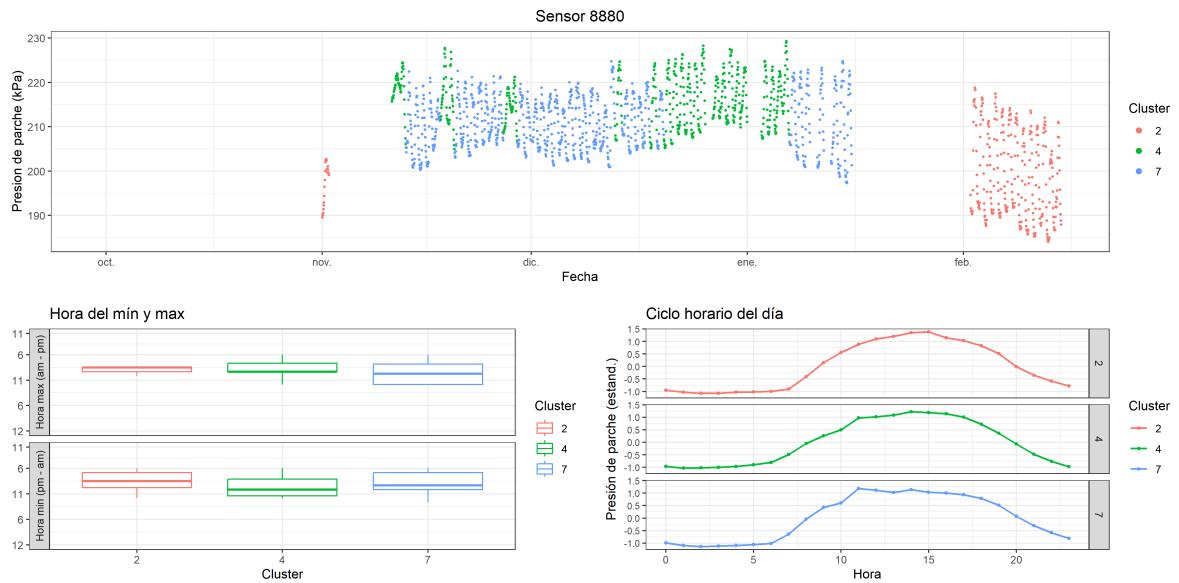
37 T1 (2023-2024)



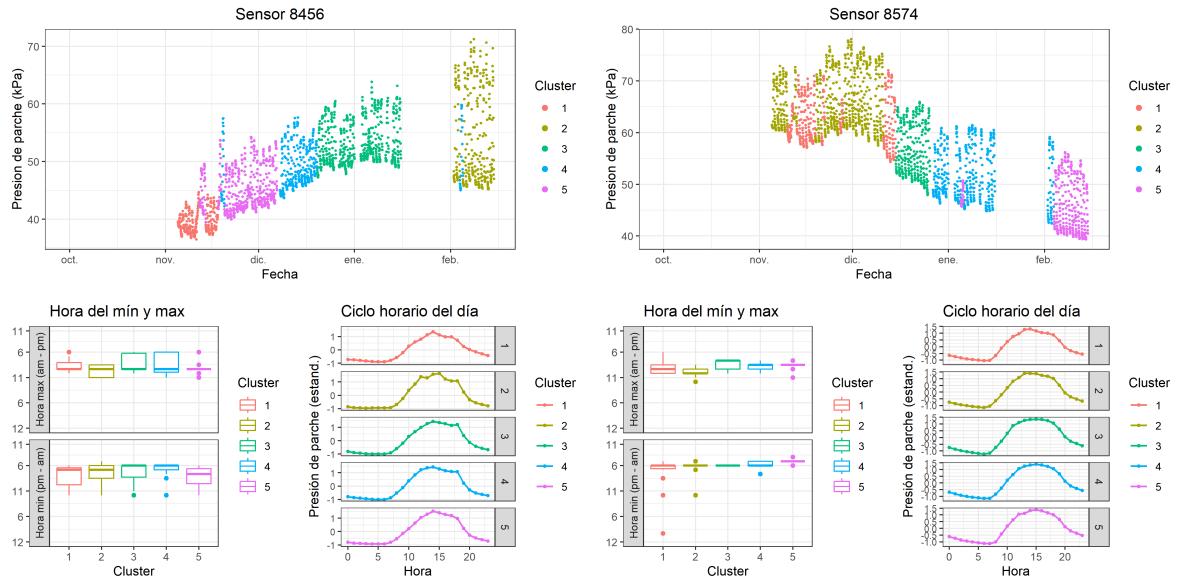


Unidad 3

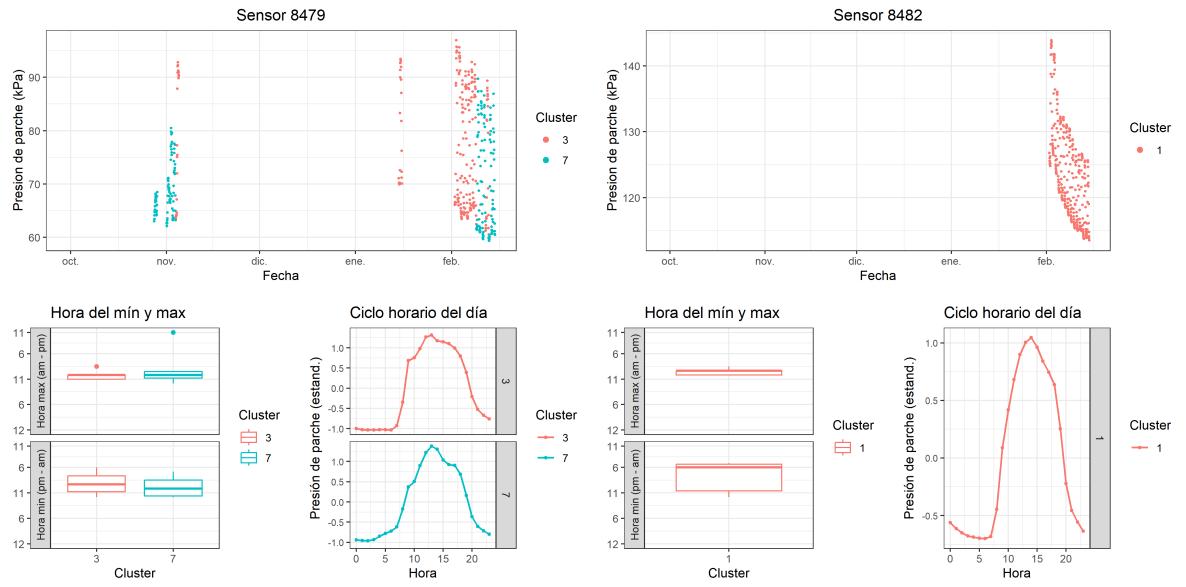
38 T2 (2023-2024)



Unidad 1

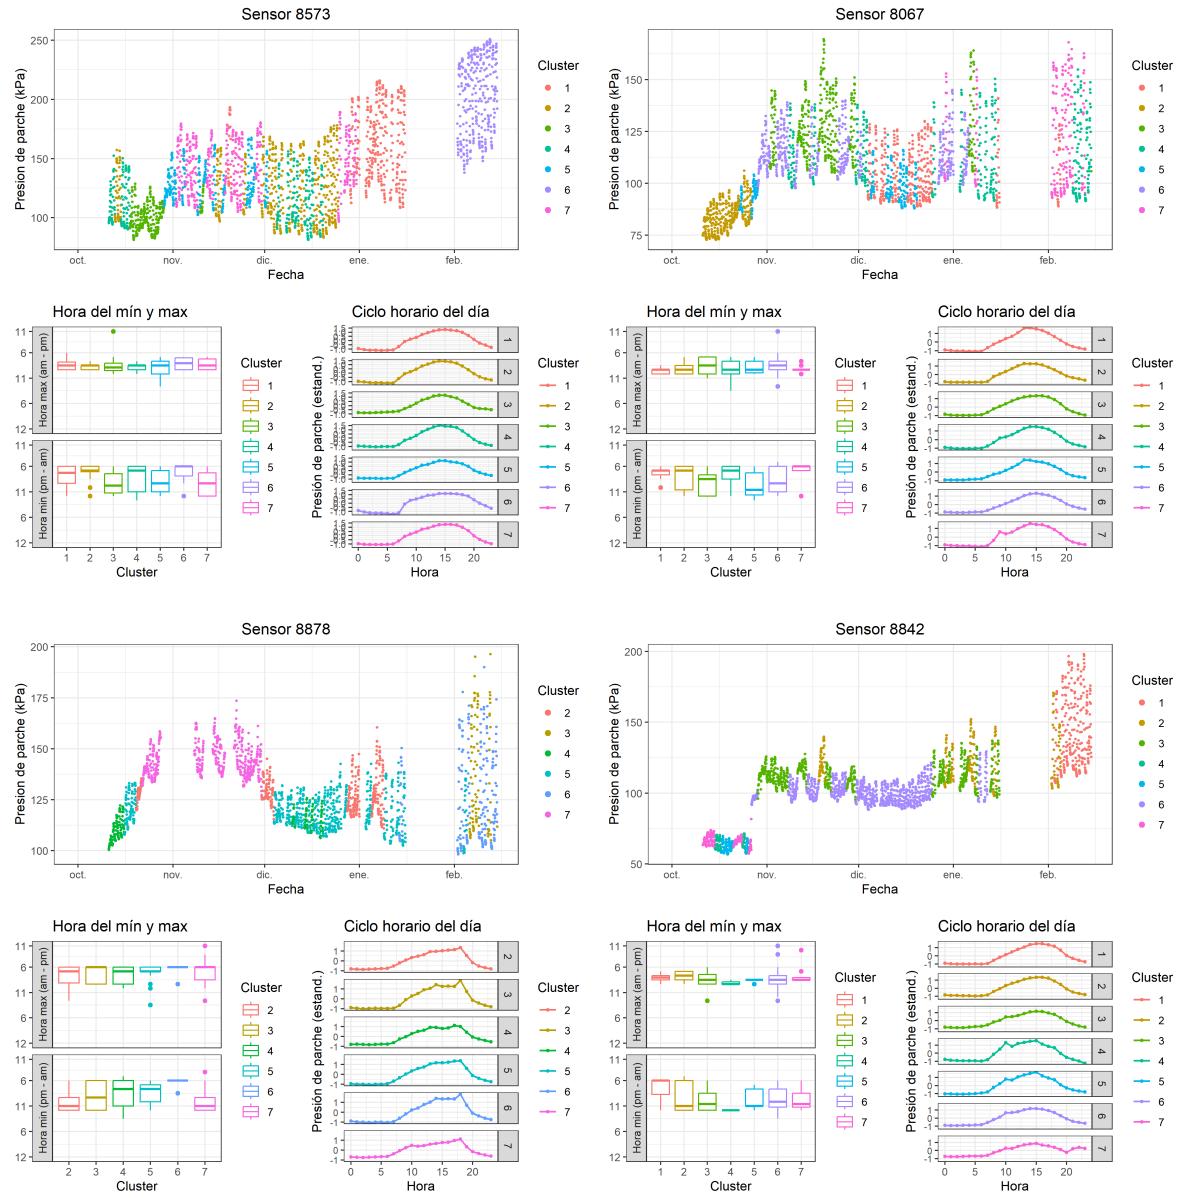


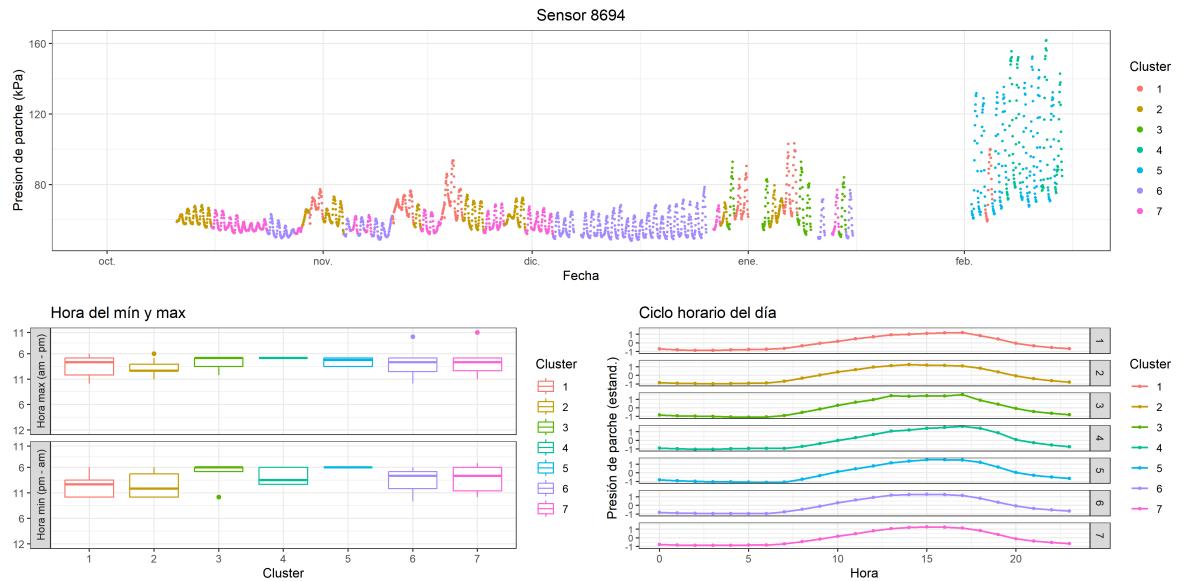
Unidad 2



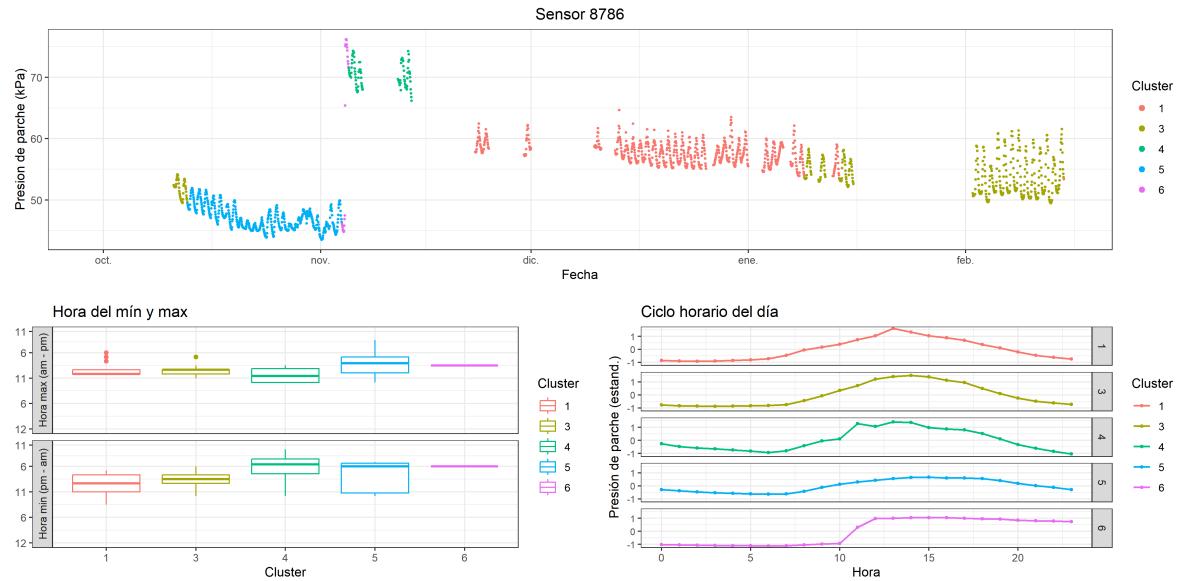
Unidad 3

39 T3 (2023-2024)

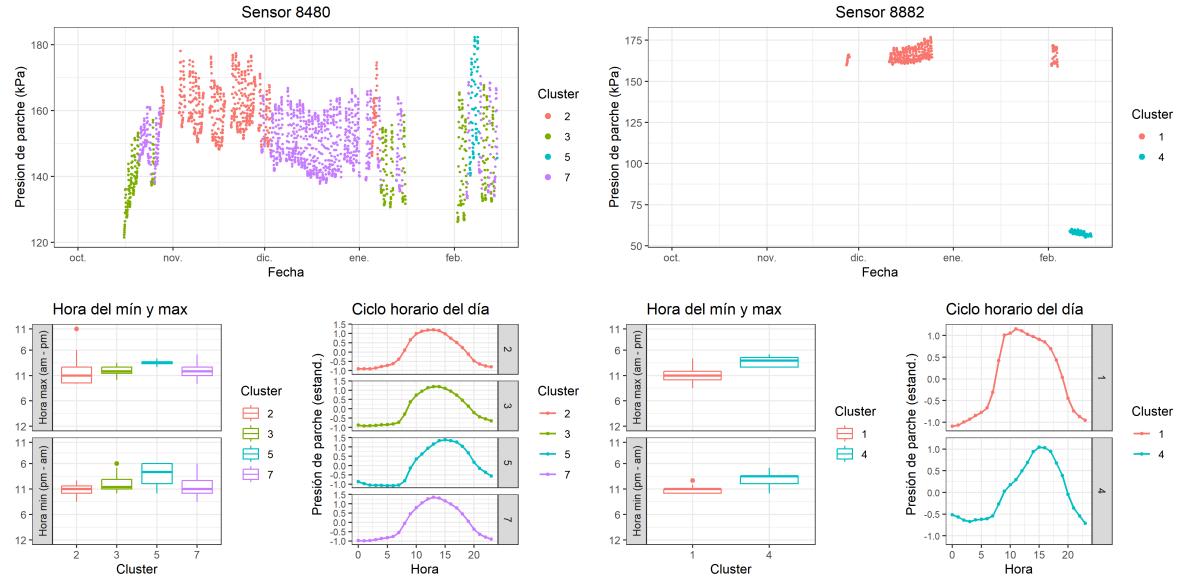




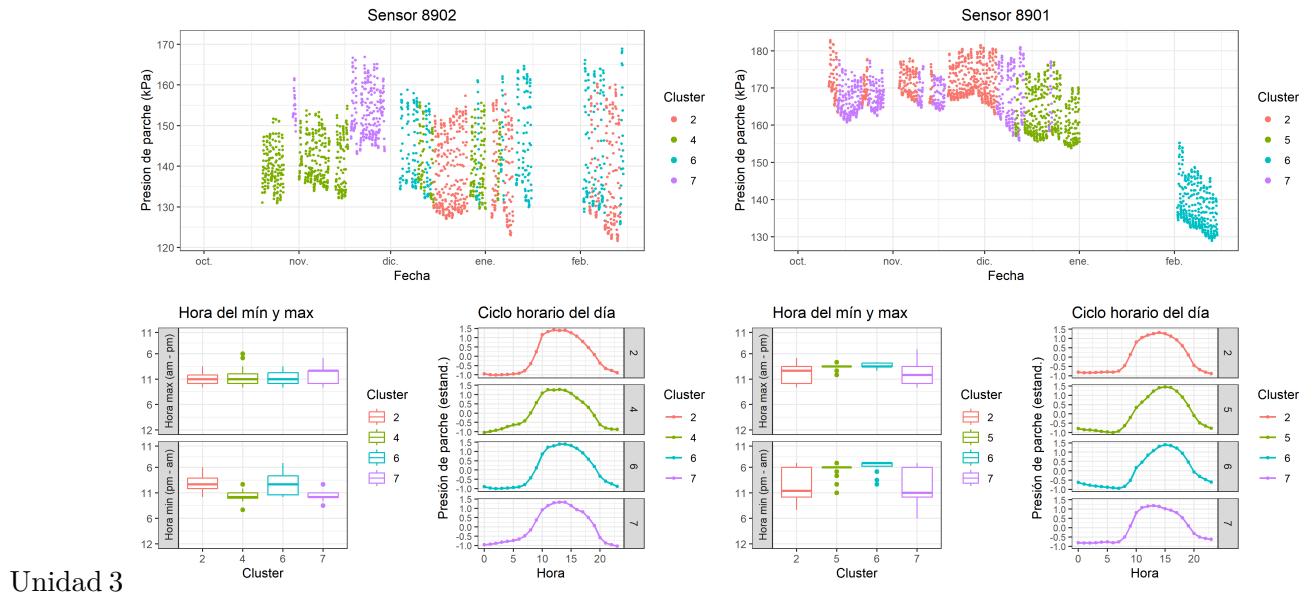
40 T4 (2023-2024)



Unidad 1



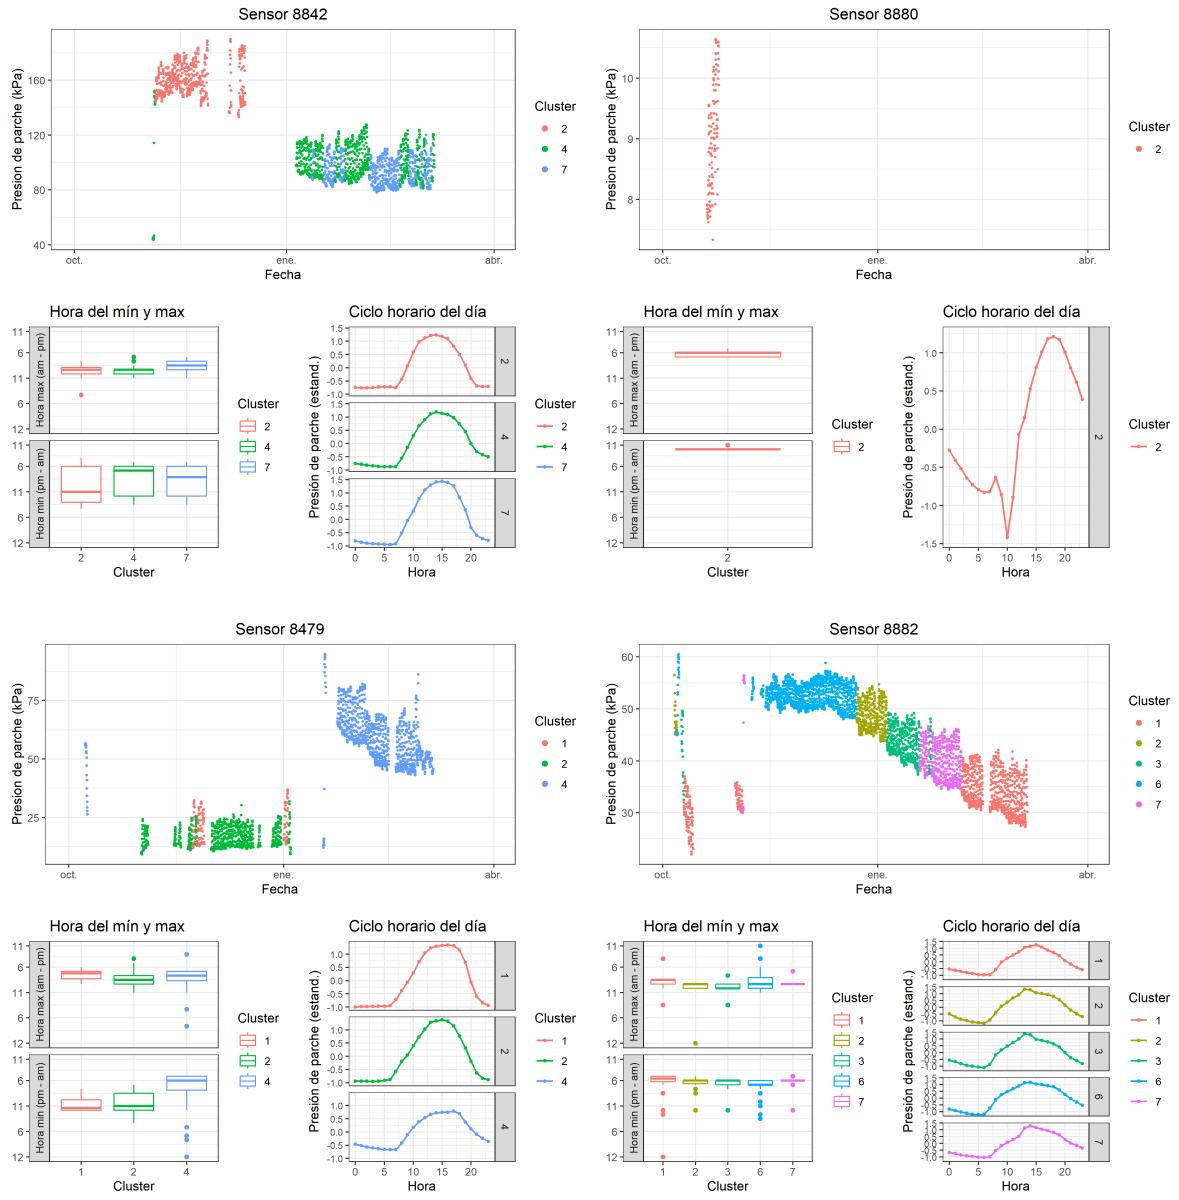
Unidad 2

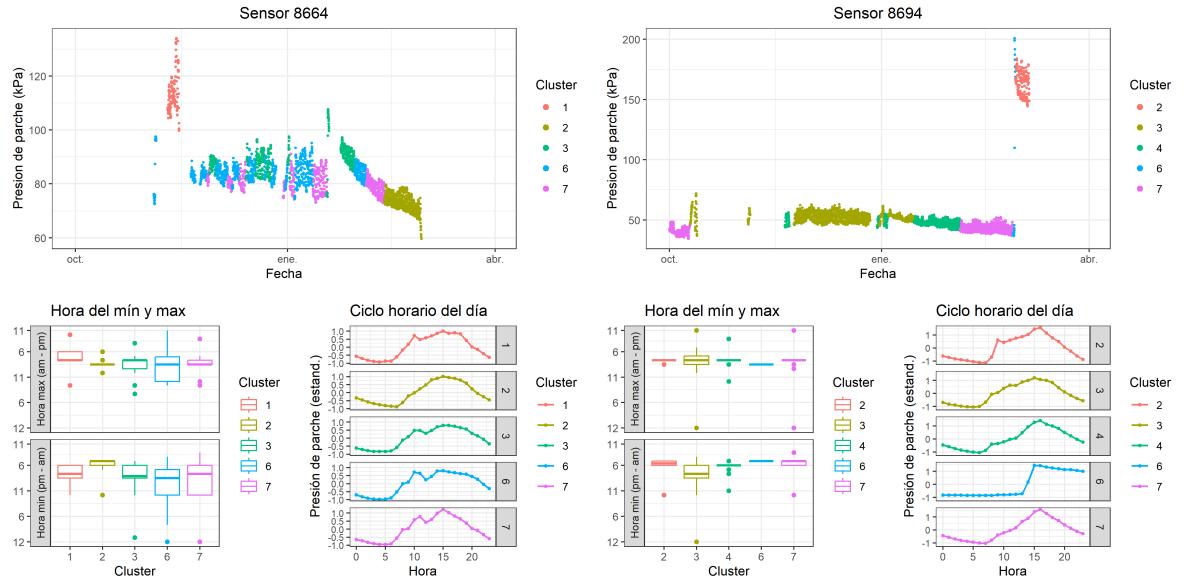


Unidad 3

40.1 Rio Claro

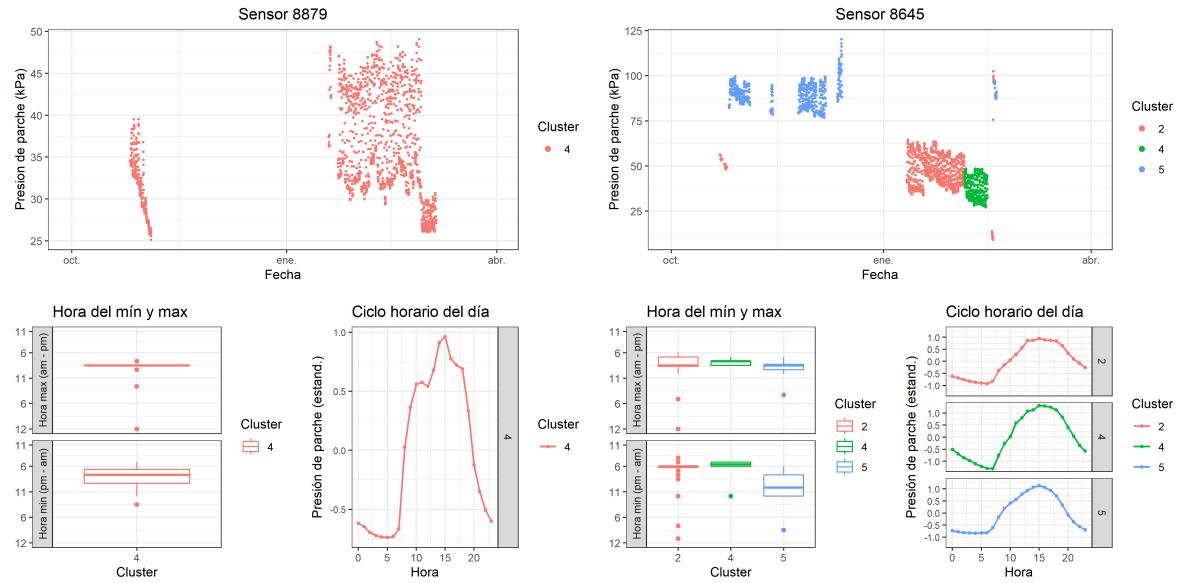
41 T1 (2022-2023)



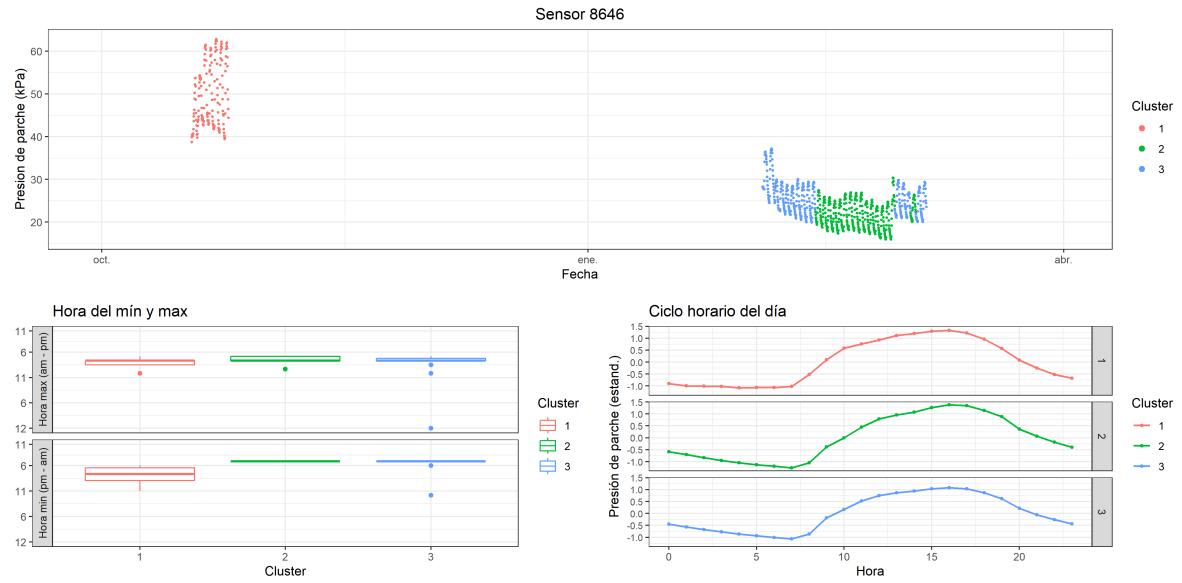


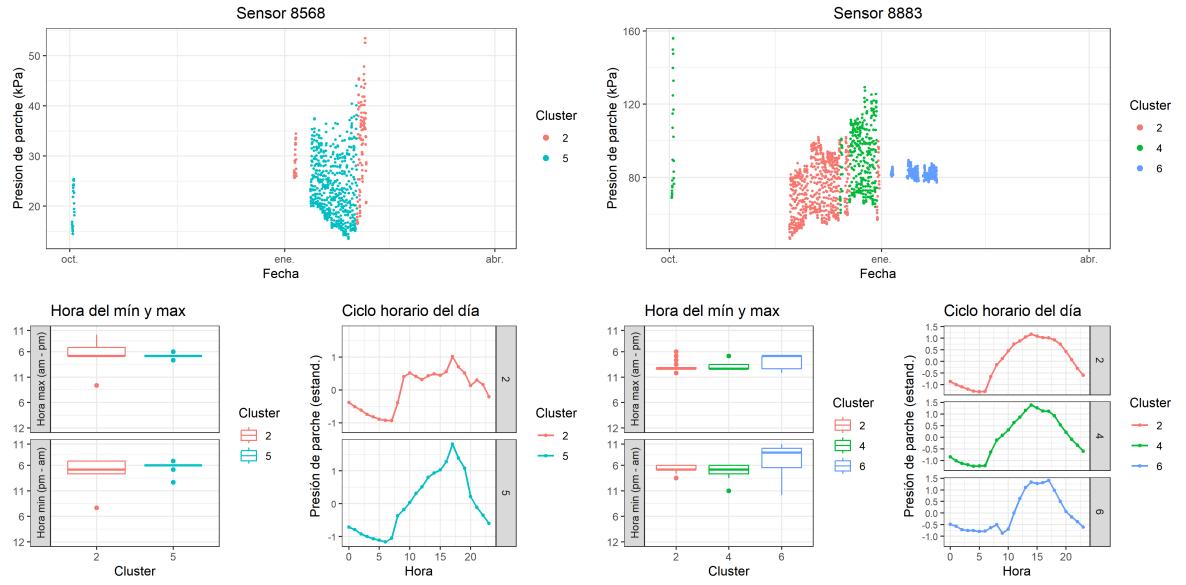
Unidad 3

42 T2 (2022-2023)



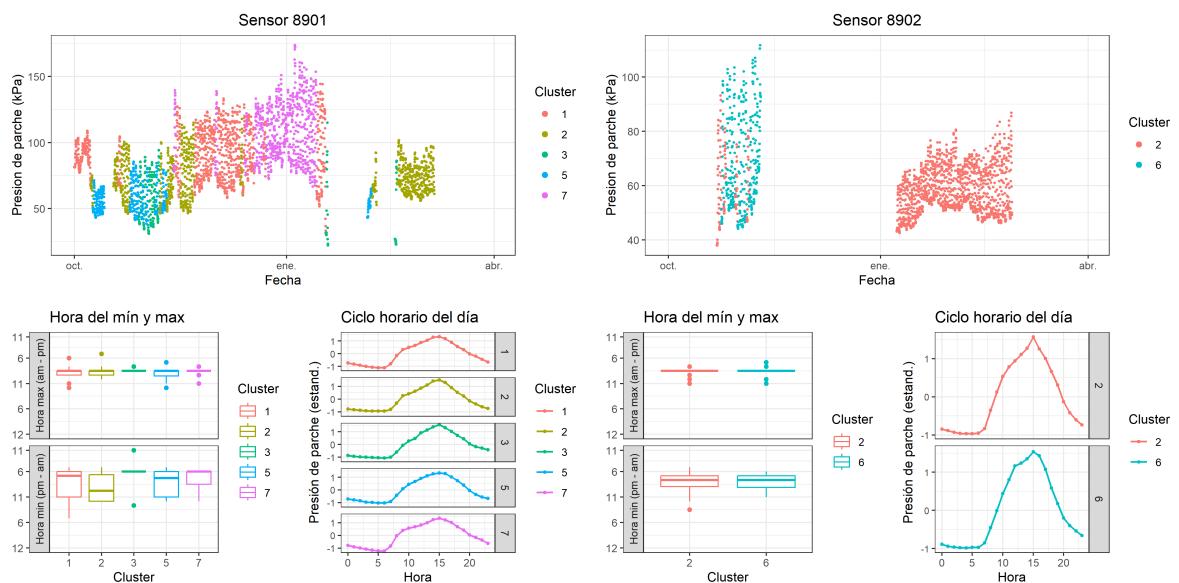
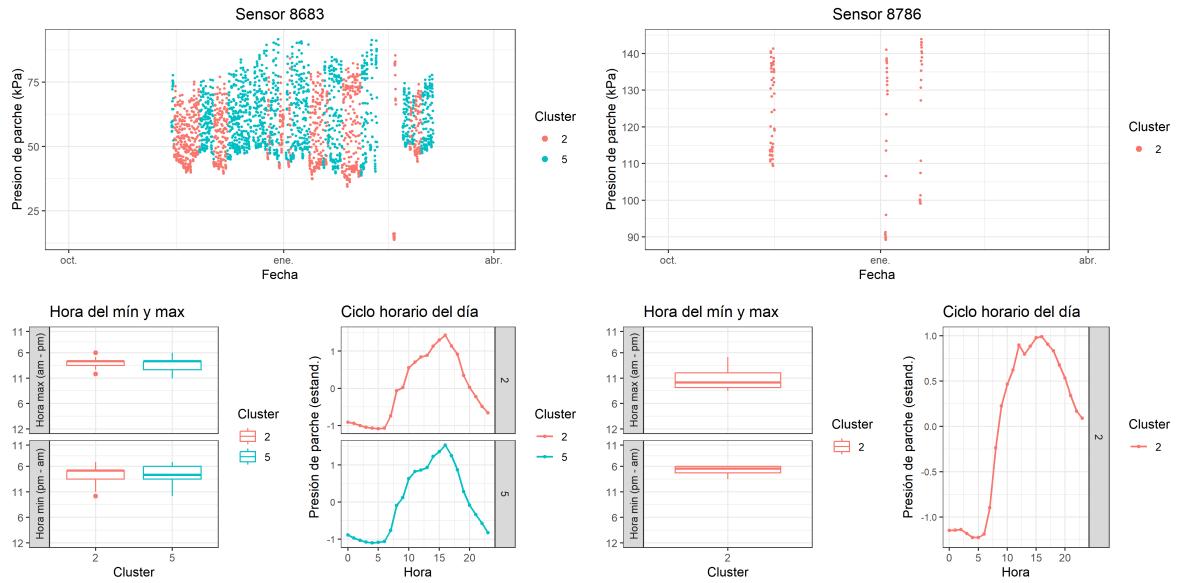
Unidad 1

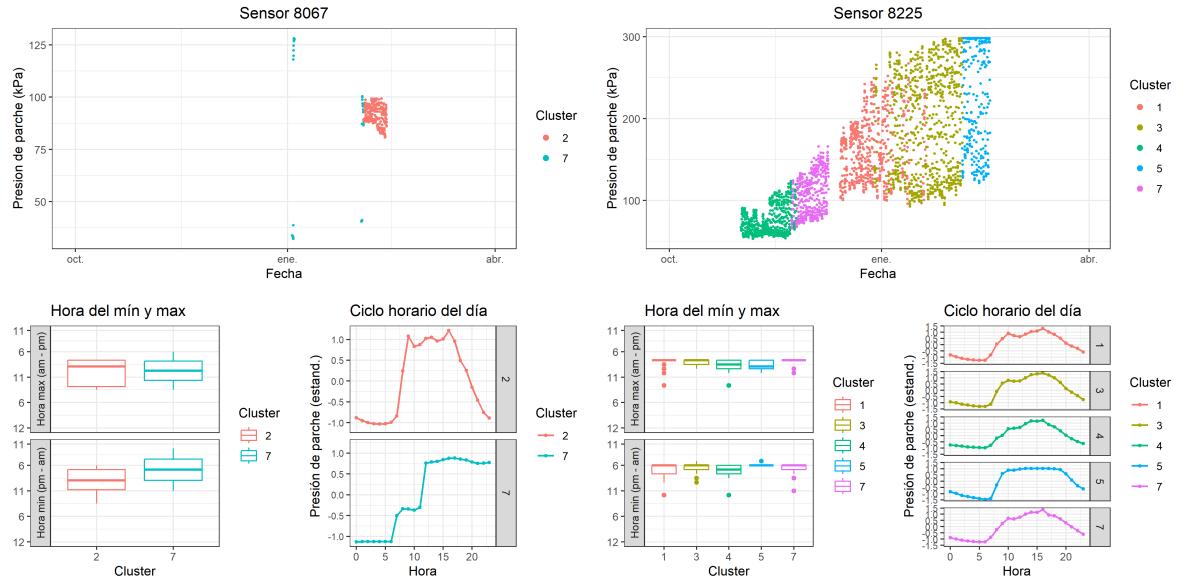




Unidad 3

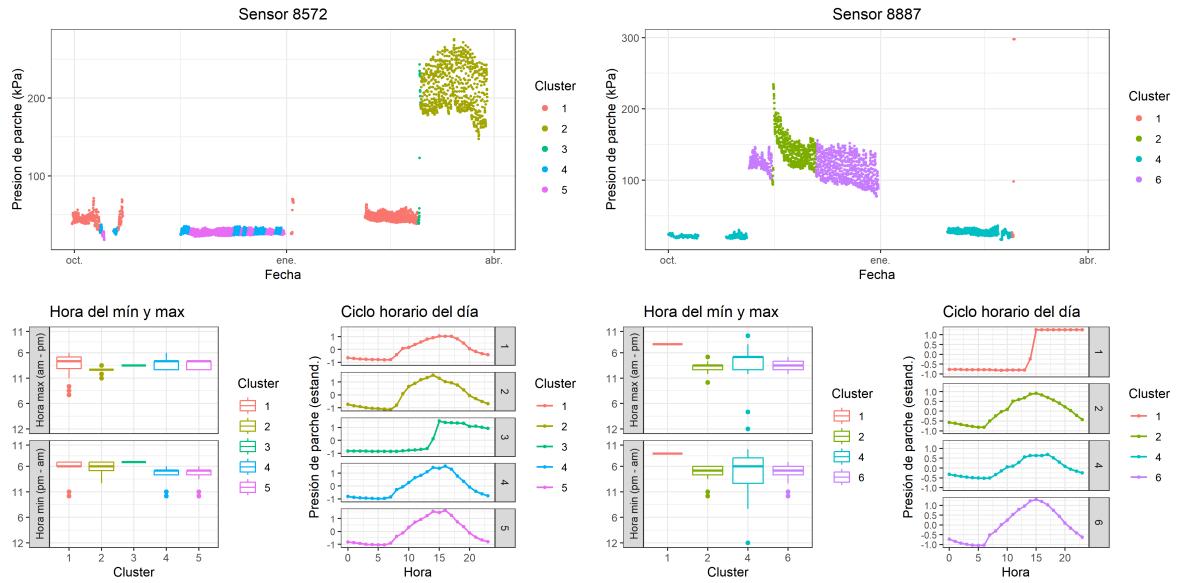
43 T3 (2022-2023)



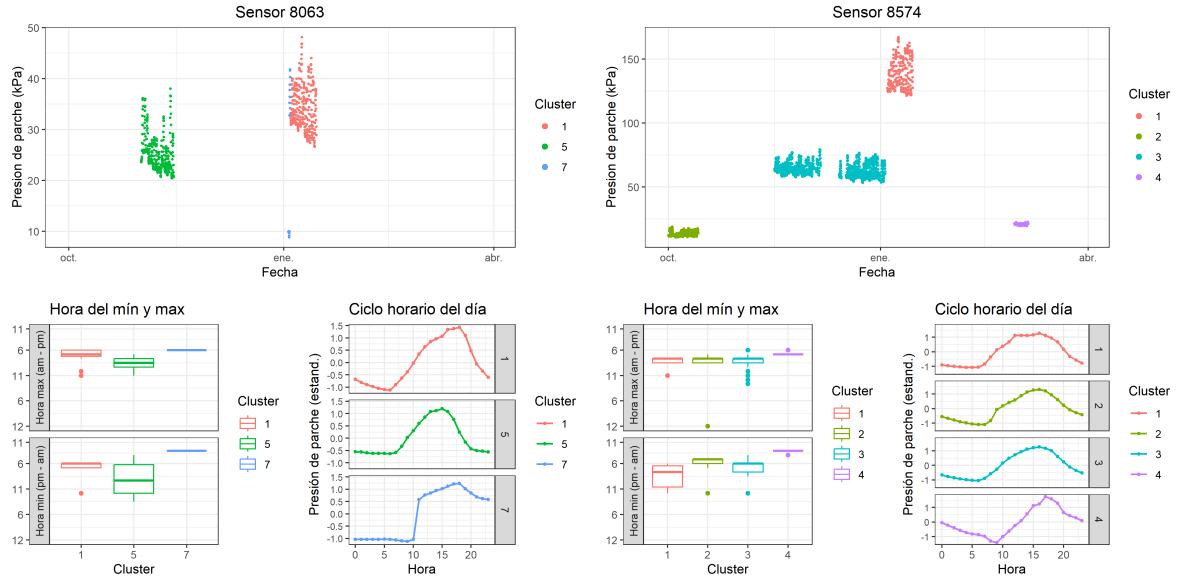


Unidad 3

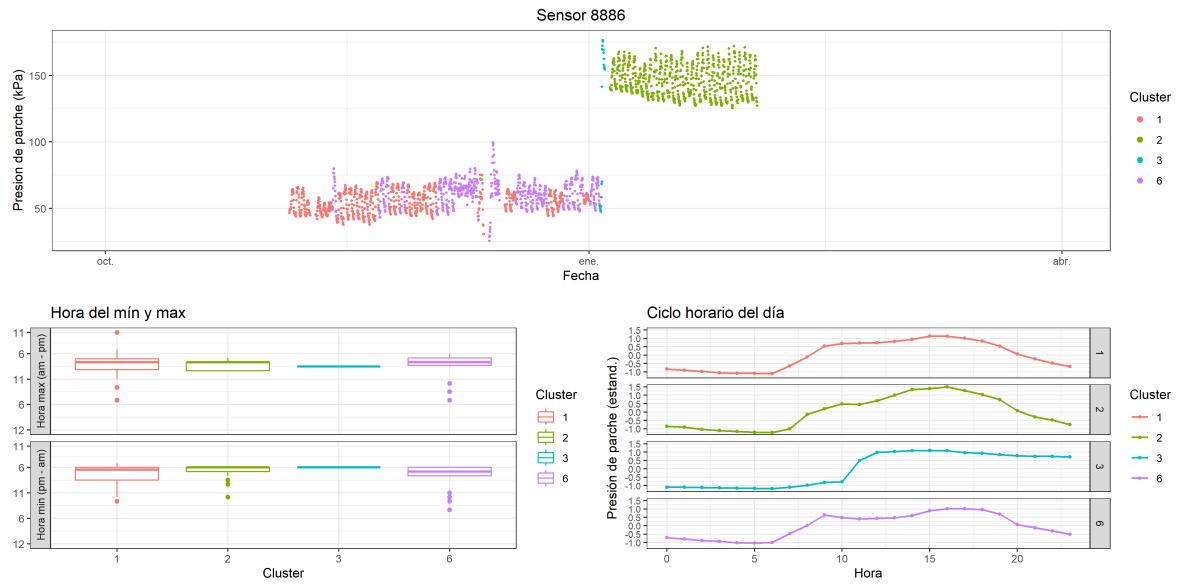
44 T4 (2022-2023)



Unidad 1

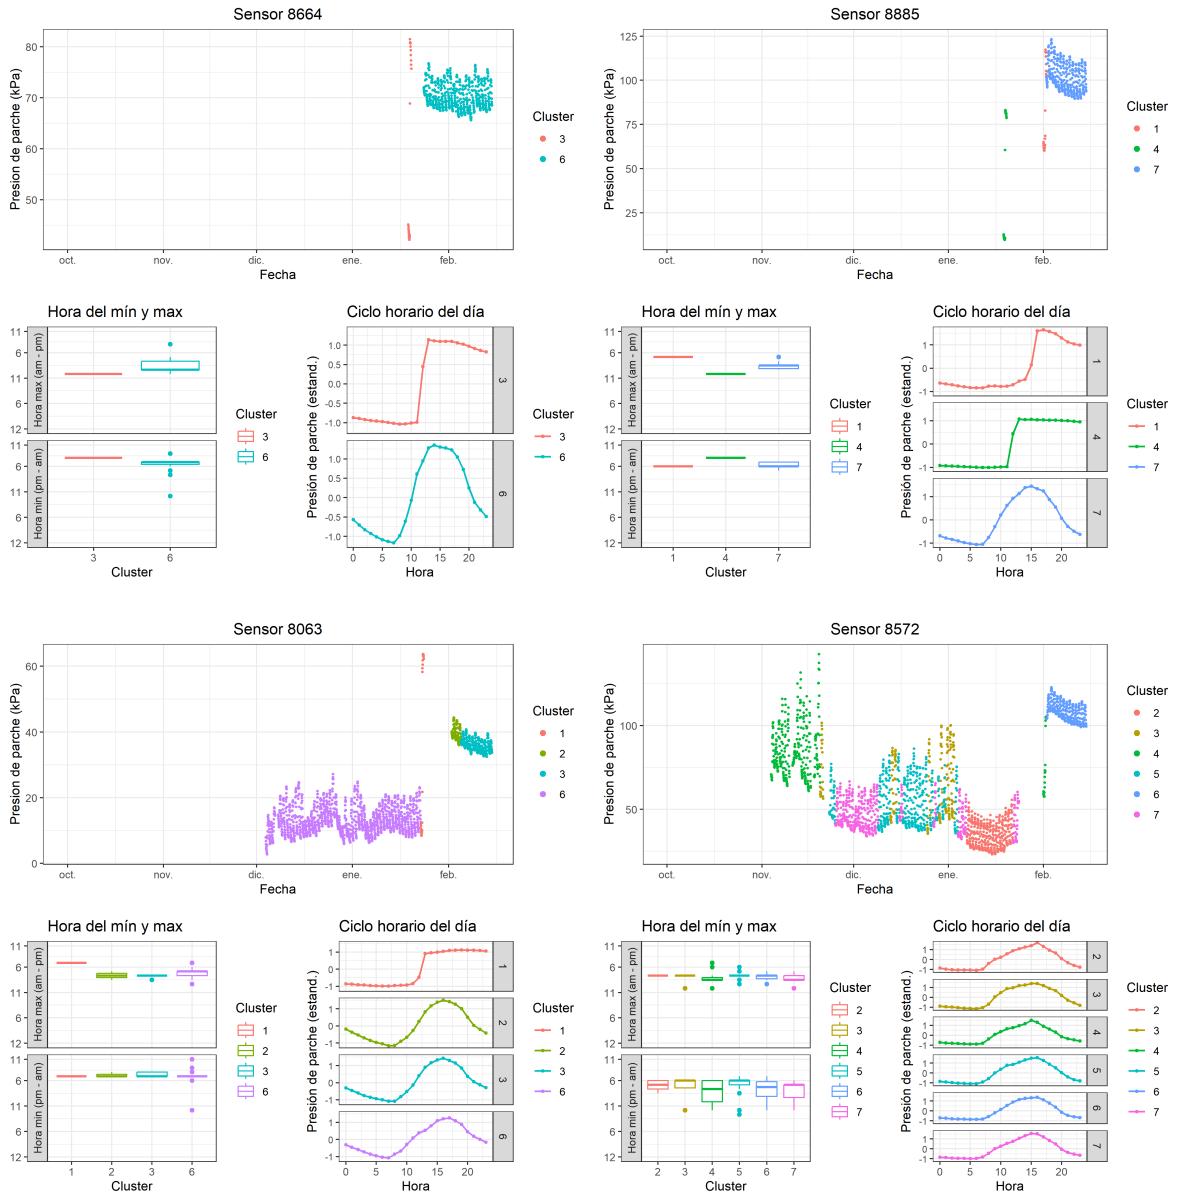


Unidad 2



Unidad 3

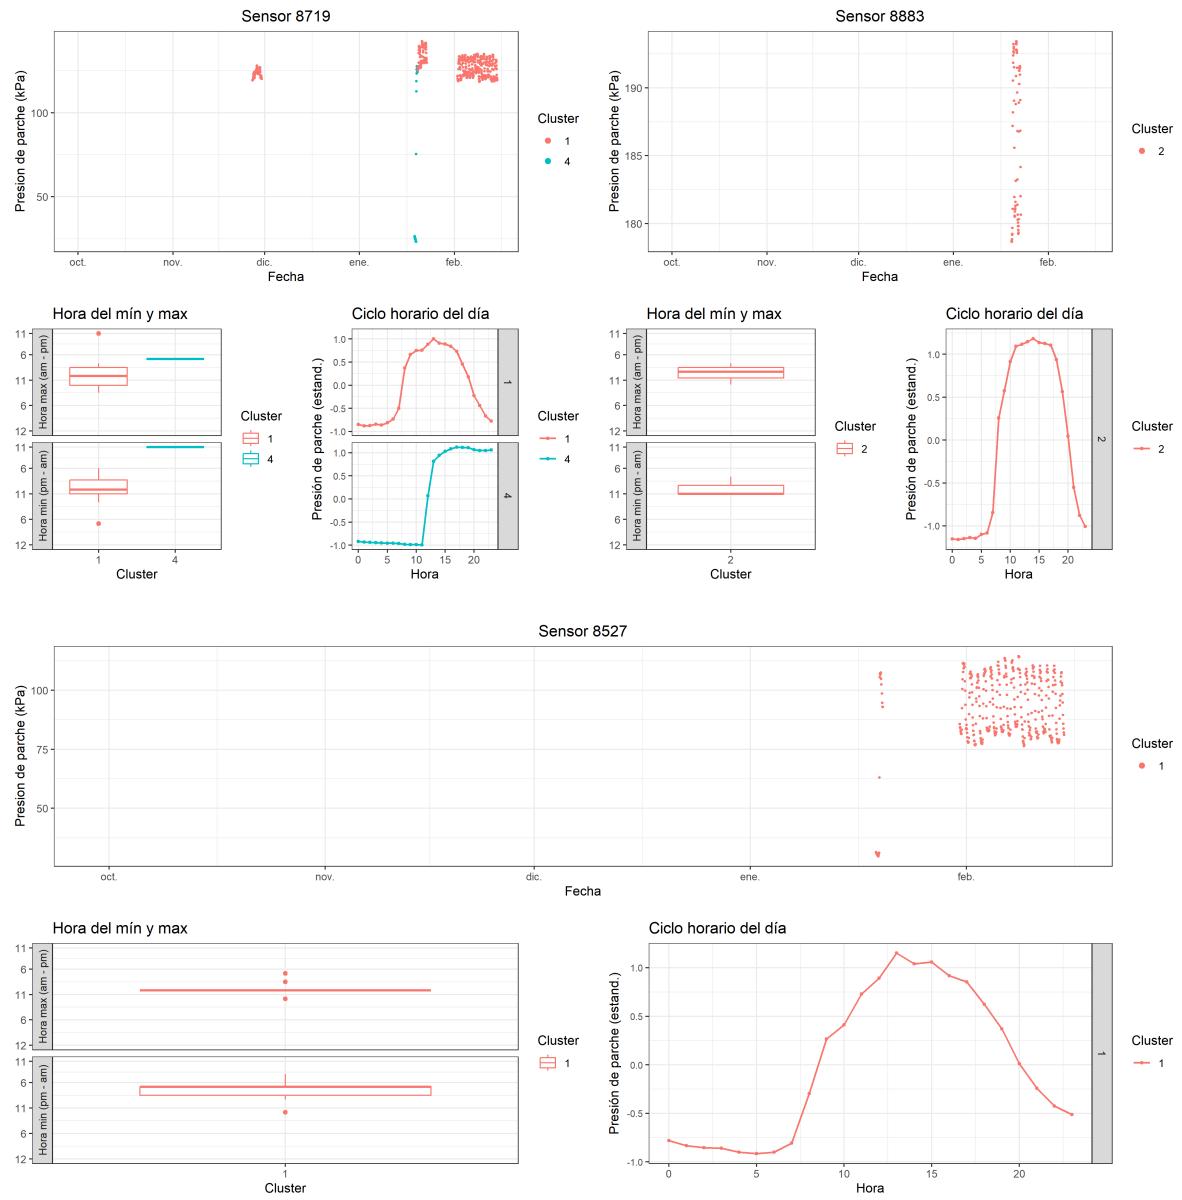
45 T1 (2023-2024)

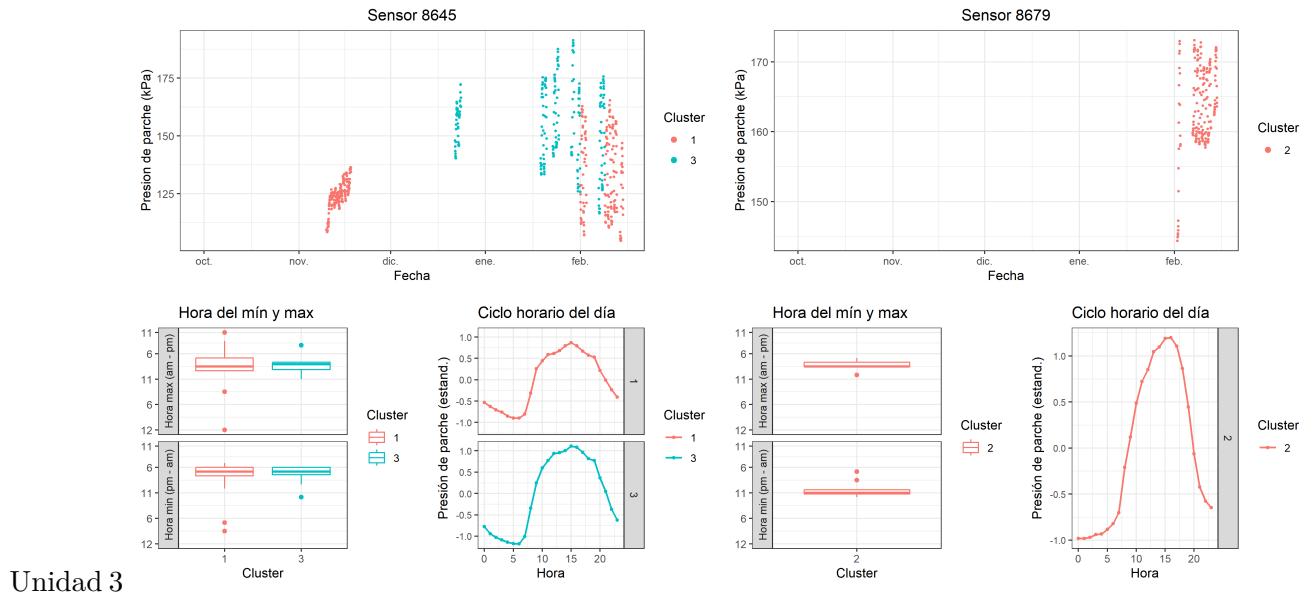


Unidad 1

Unidad 3

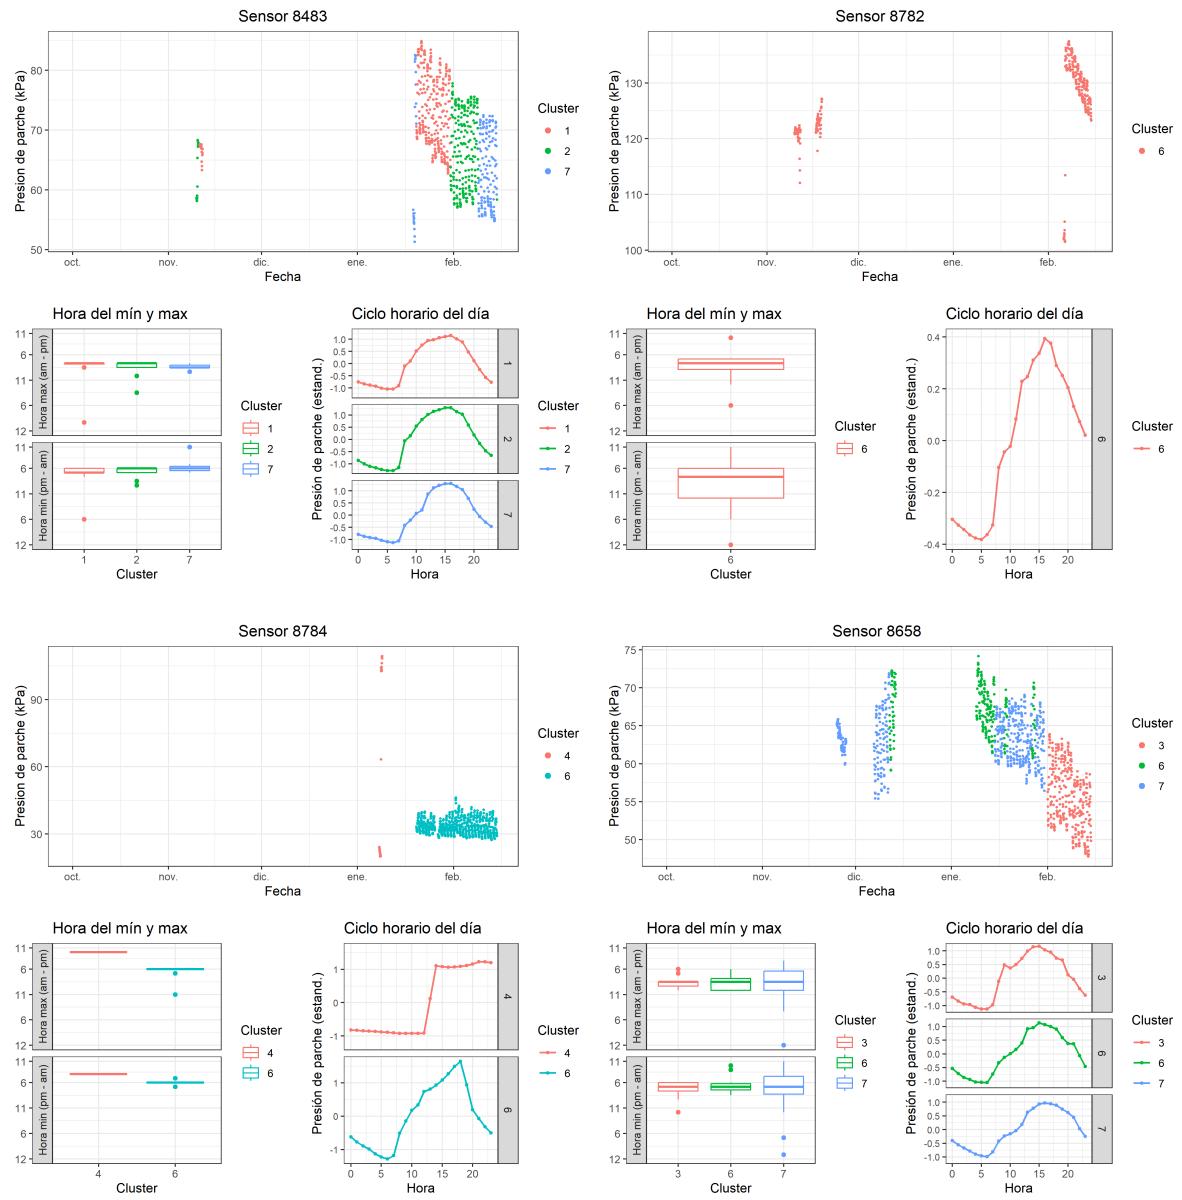
46 T2 (2023-2024)

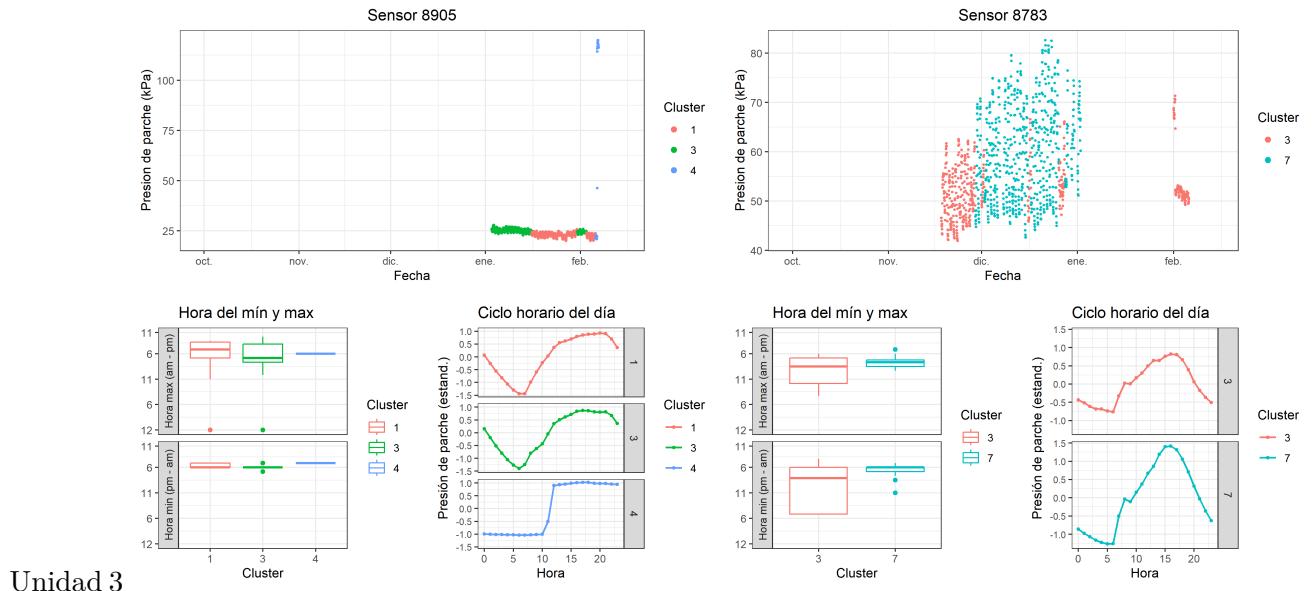




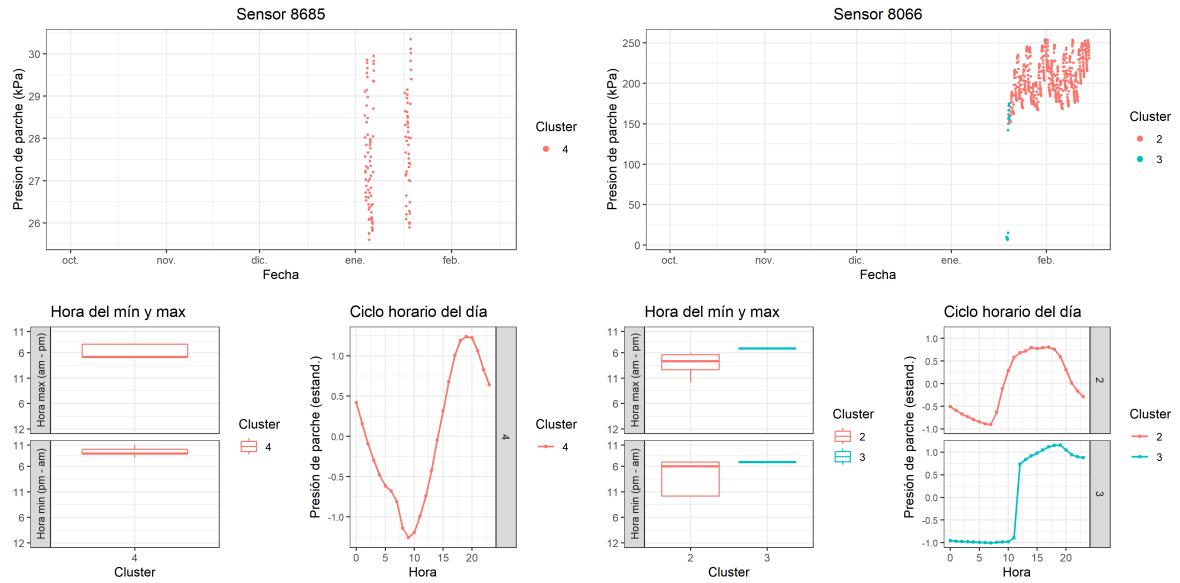
Unidad 3

47 T3 (2023-2024)

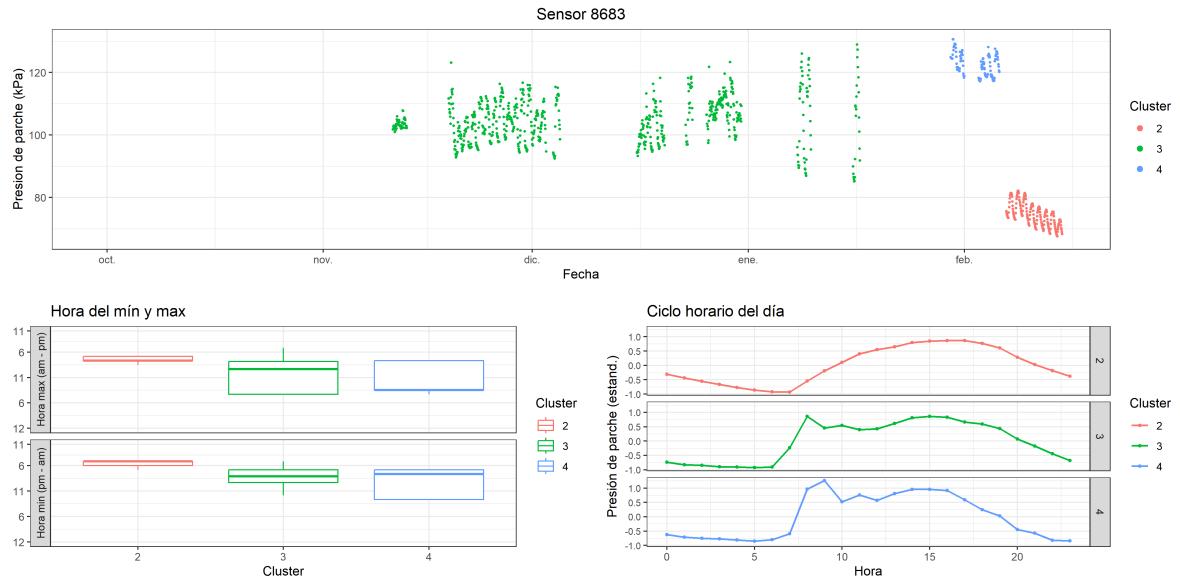




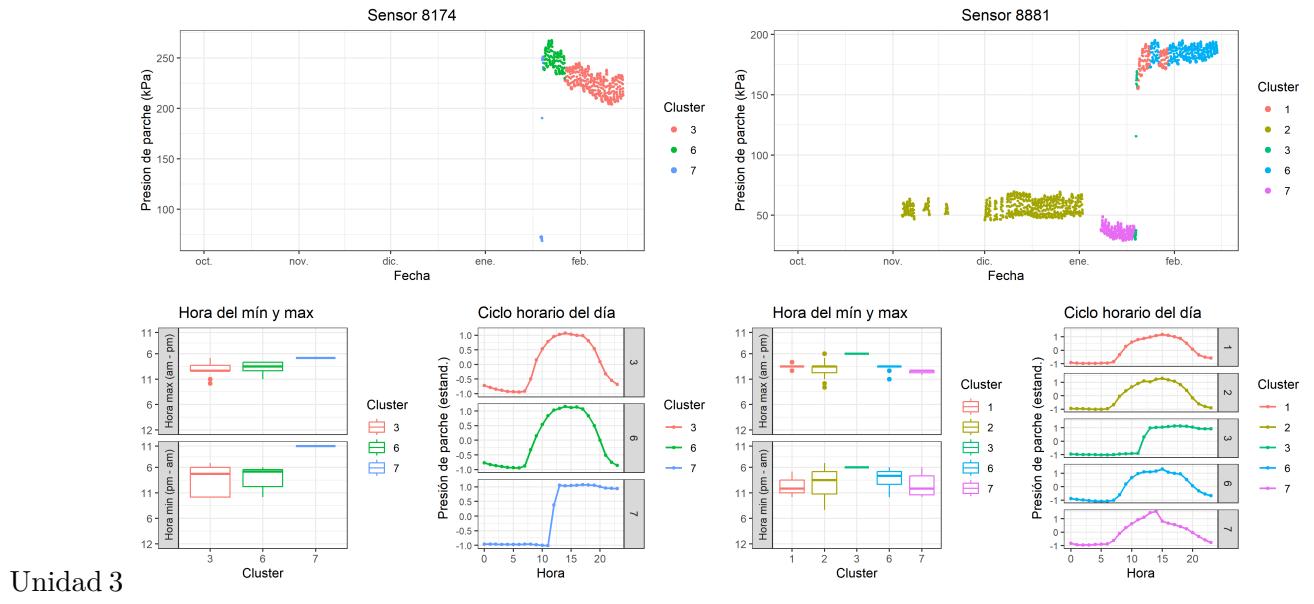
48 T4 (2023-2024)



Unidad 1



Unidad 2

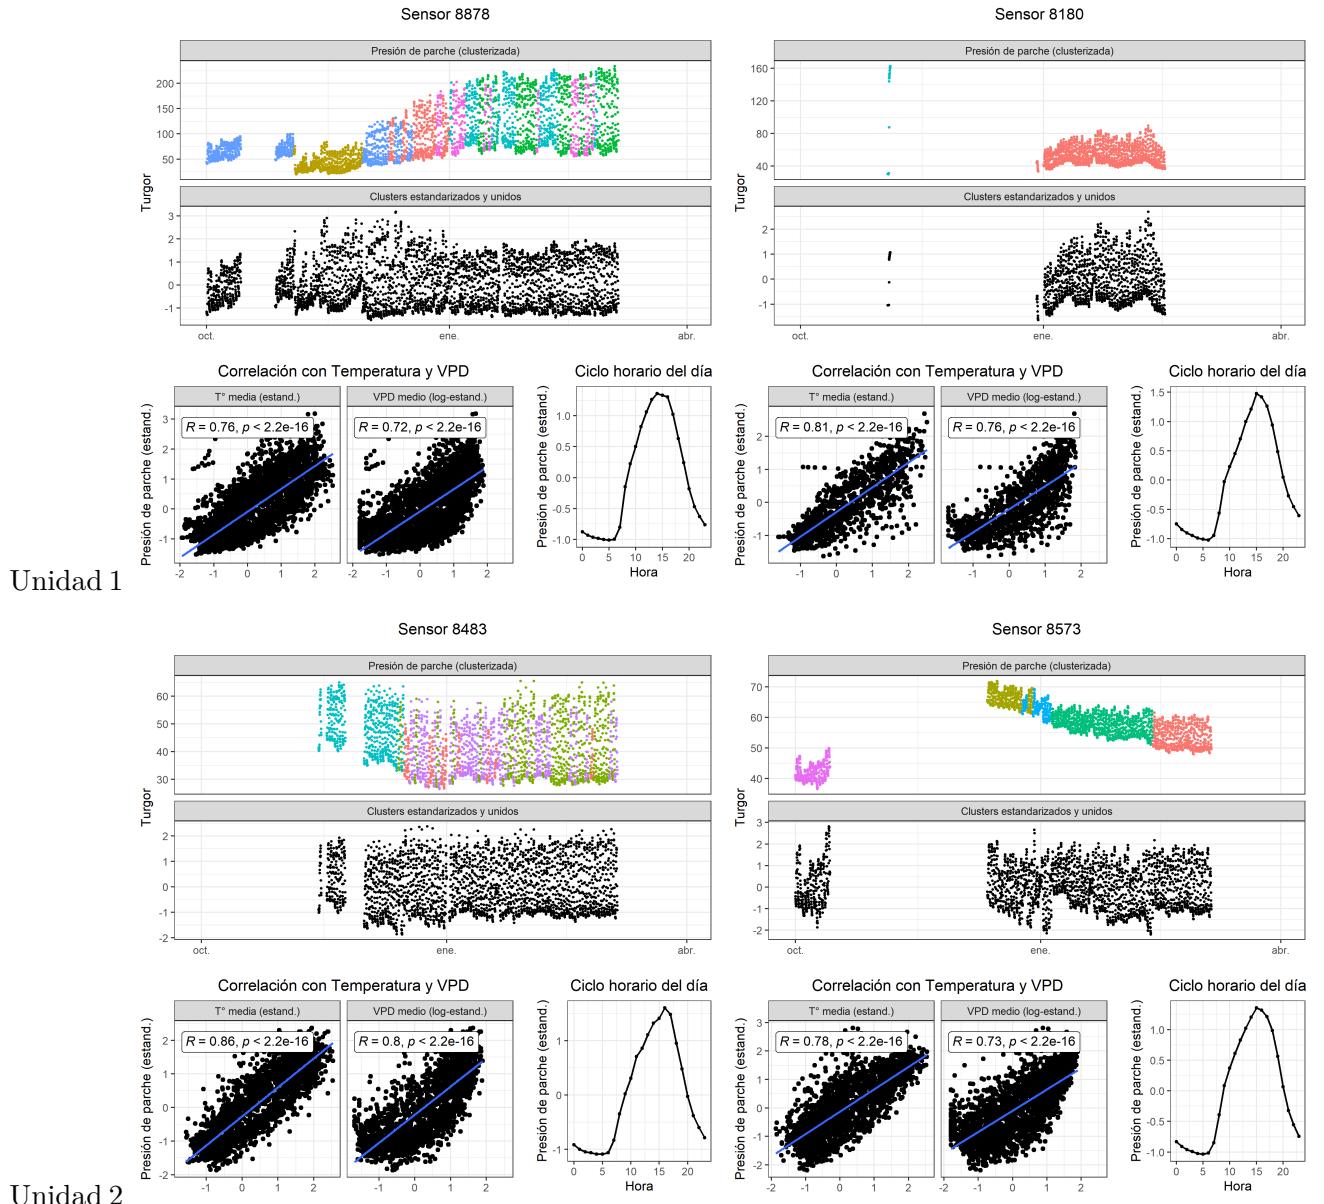


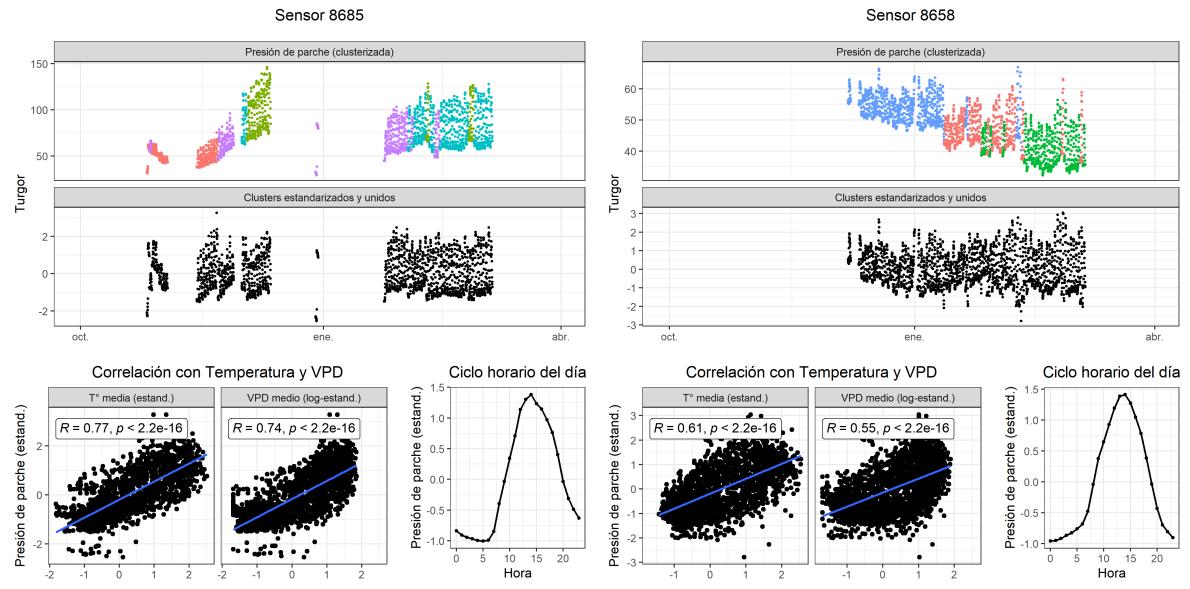
49 Estandarización de clusters

Para generar series únicas continuas por sensor (i.e. disminuir las discordancias entre periodos de recalibración de los sensores), se realizó una estandarización de cada cluster, lo cual significó una unificación las series temporales de estos a nivel de sensor. A continuación se muestran dichas series resultantes, además de su correlación con temperatura y VPD, y el ciclo horario del día.

49.1 La Esperanza

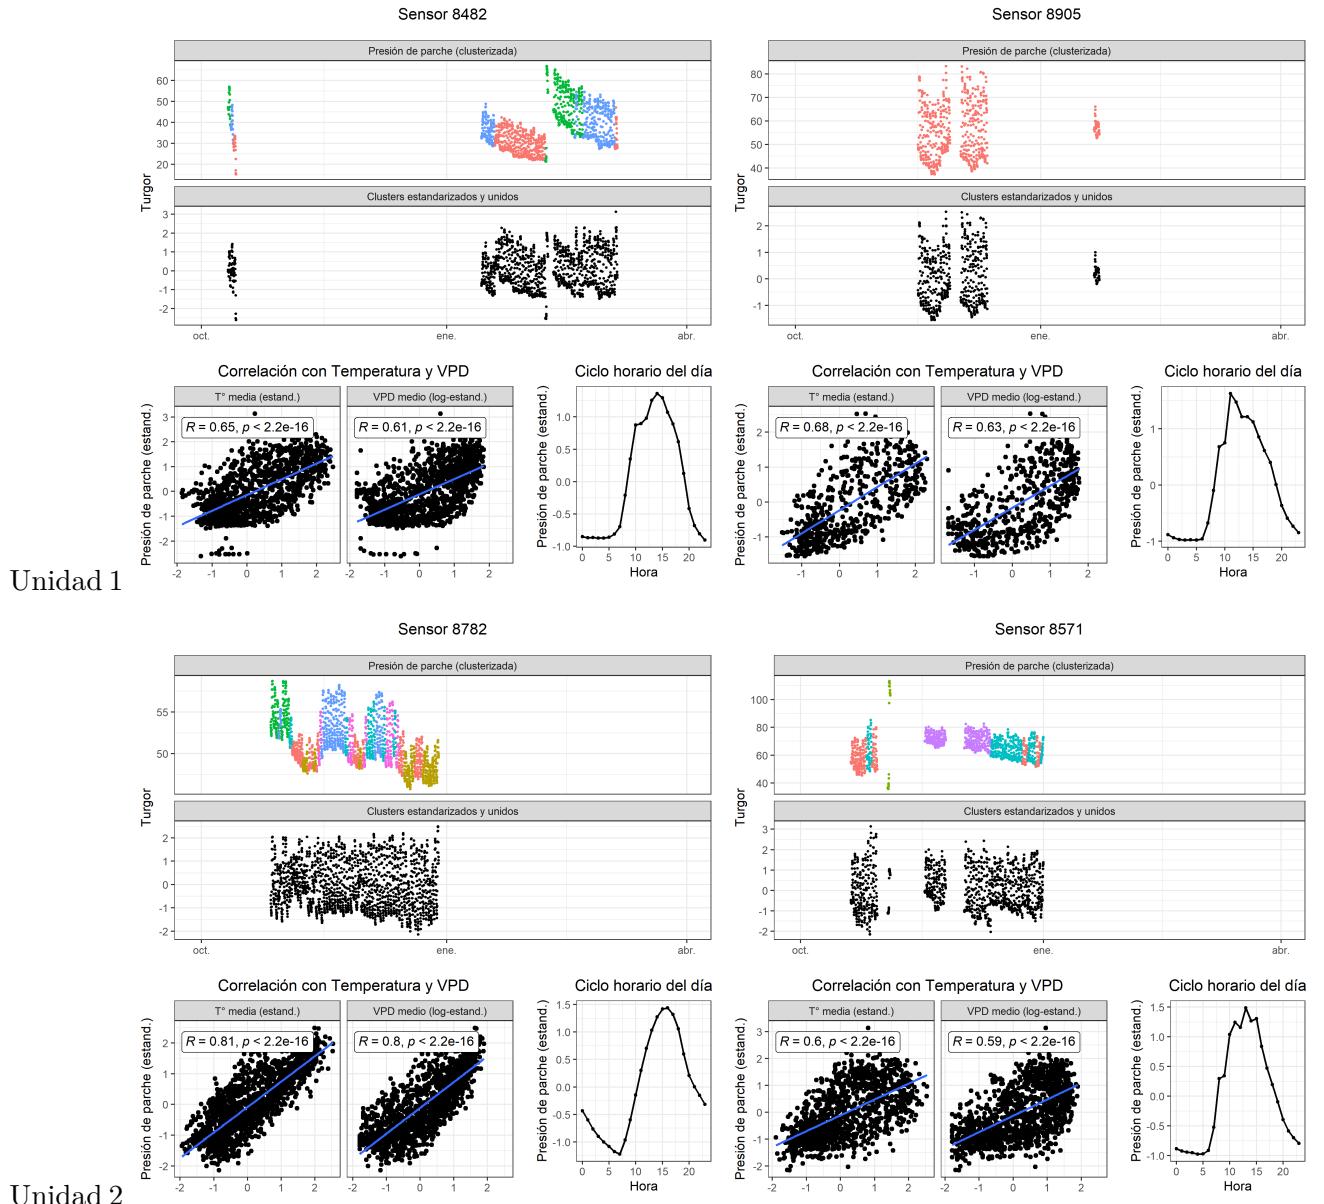
50 T1 (2022-2023)



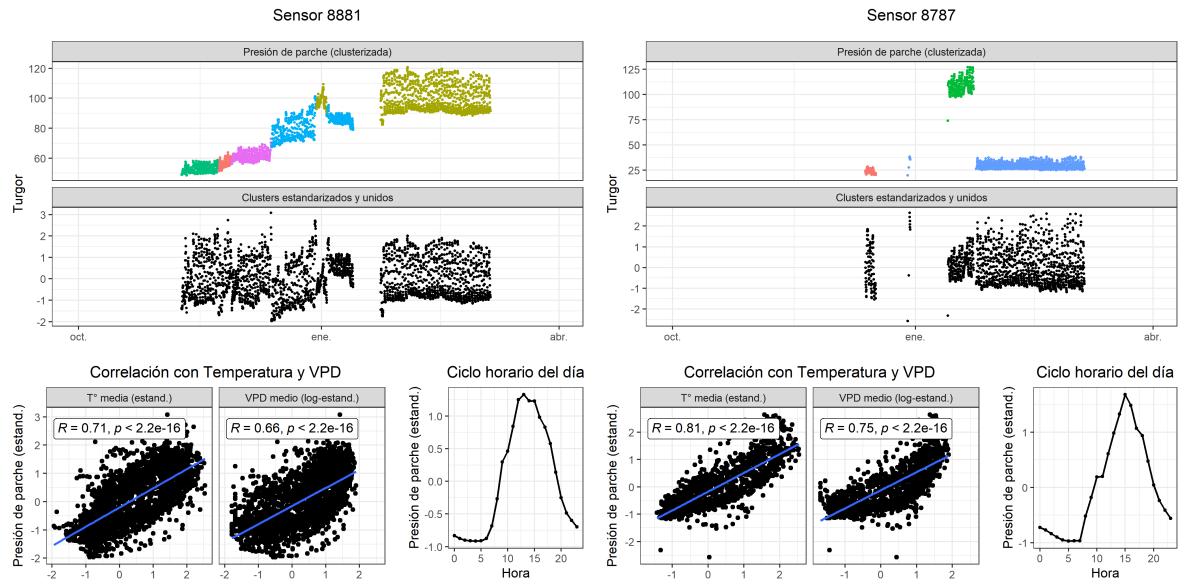


Unidad 3

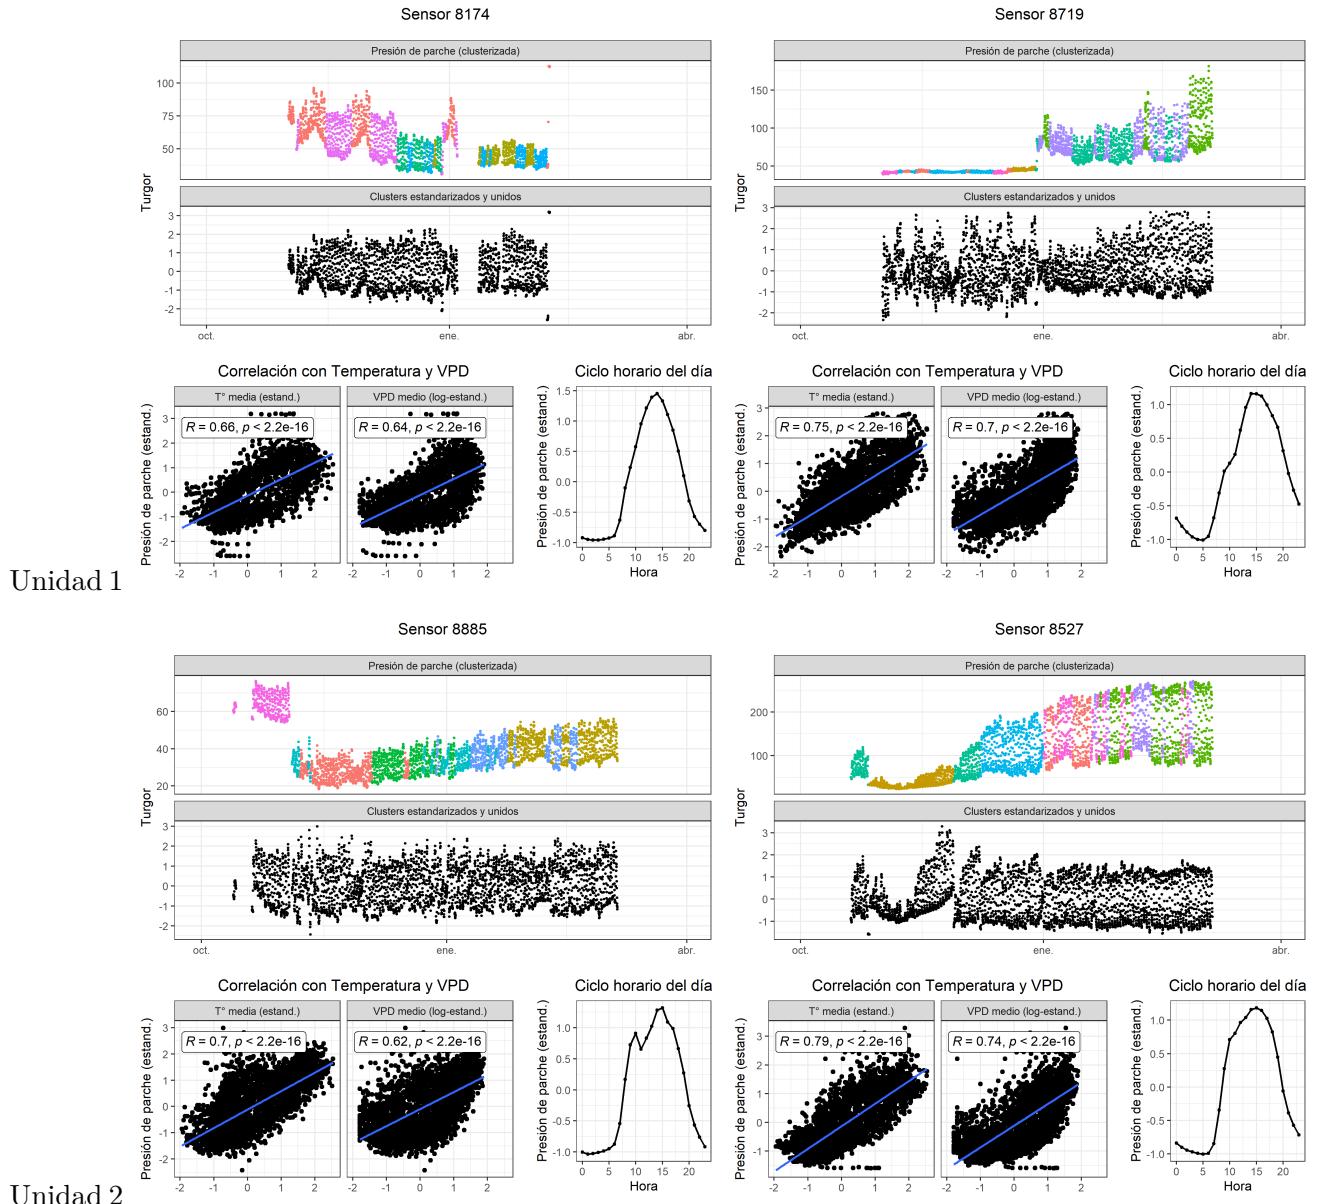
51 T2 (2022-2023)

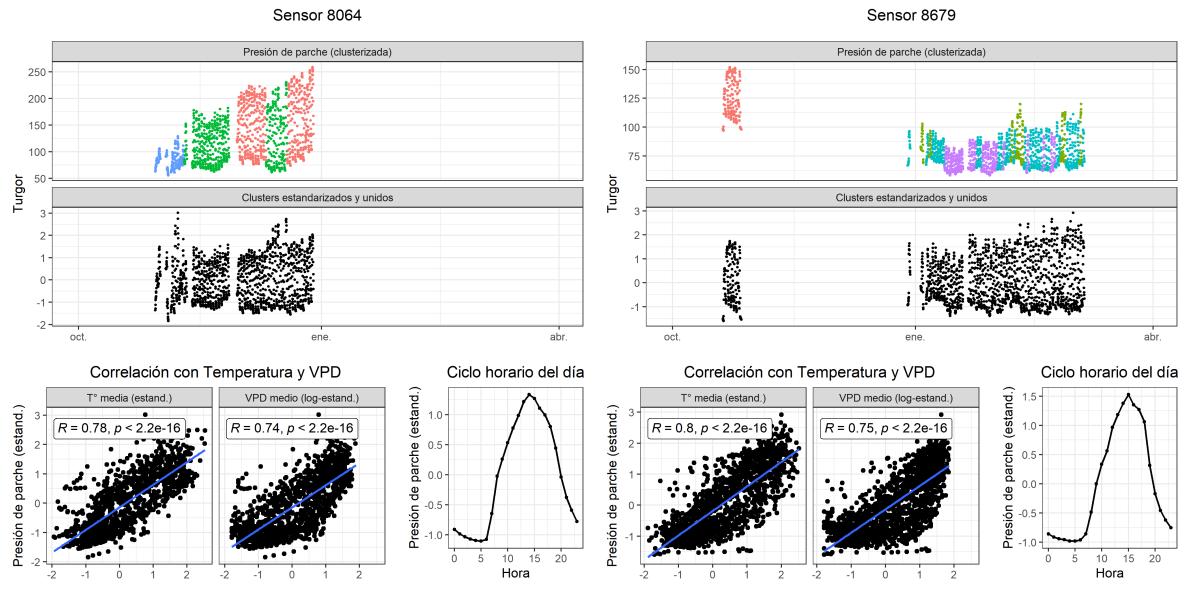


Unidad 3



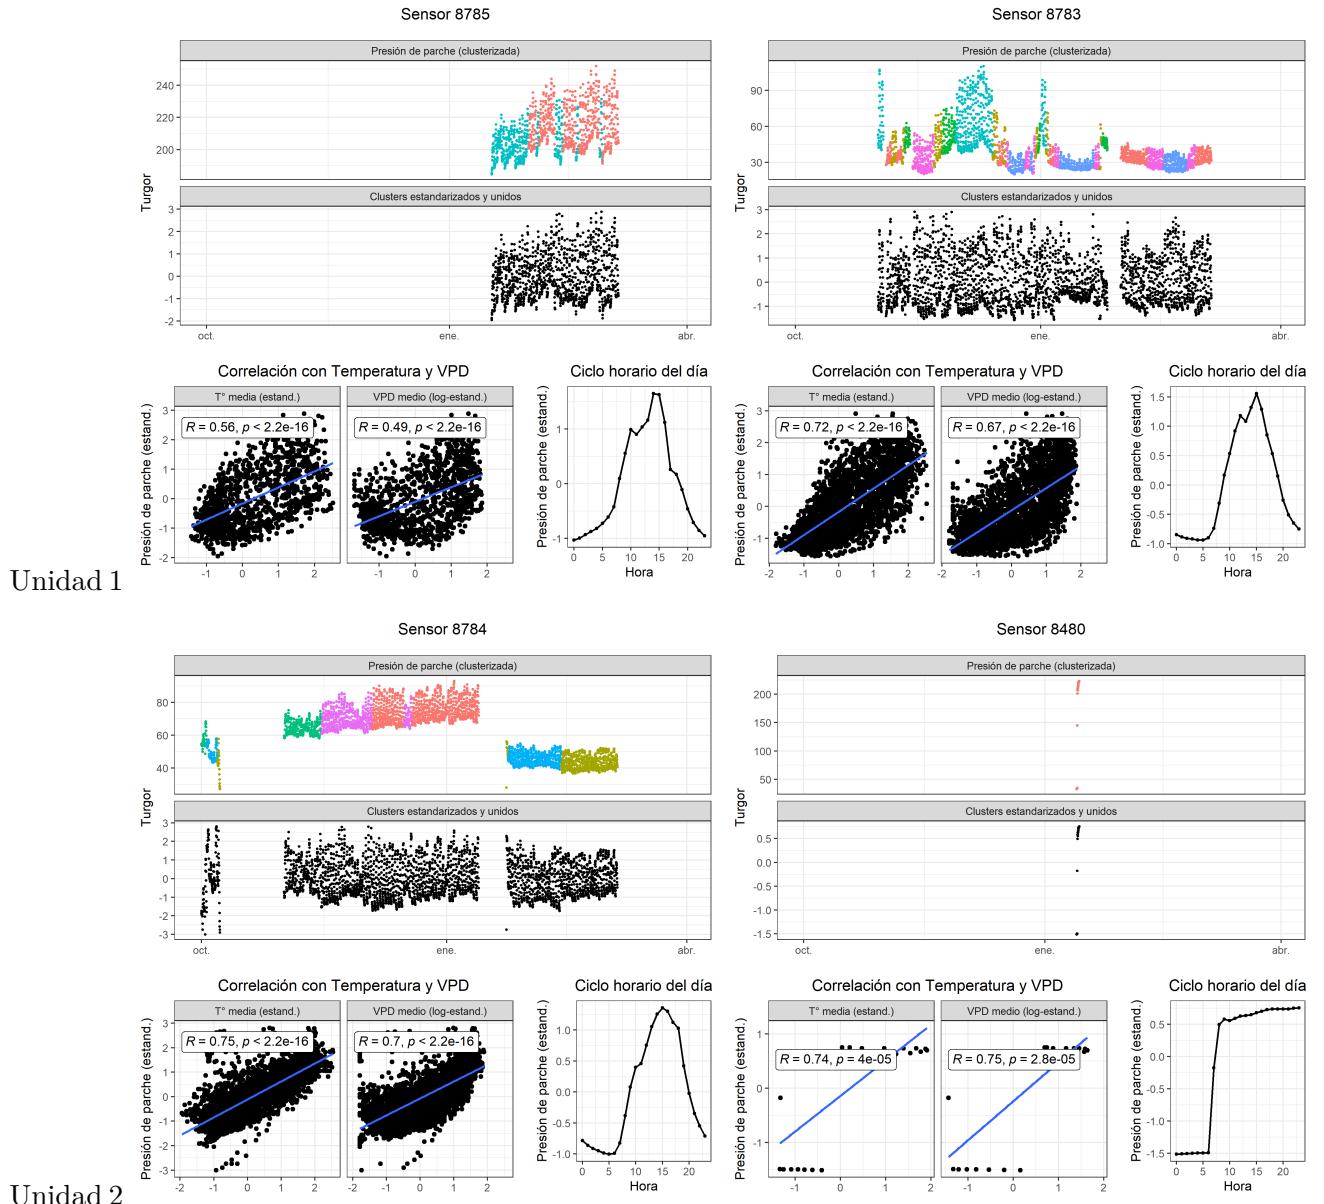
52 T3 (2022-2023)

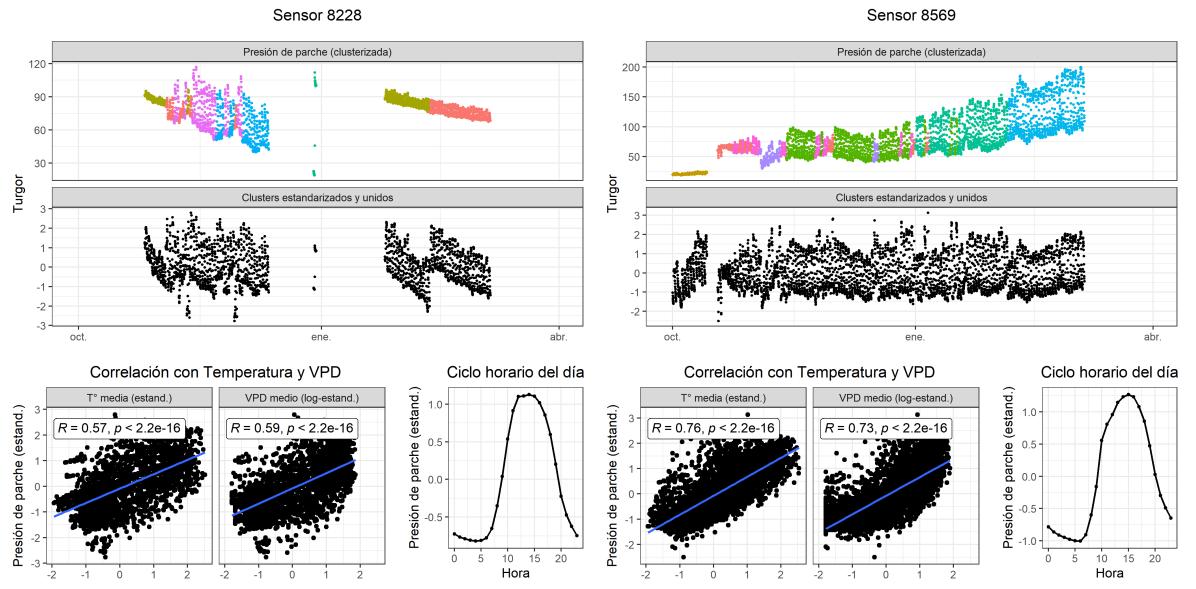




Unidad 3

53 T4 (2022-2023)

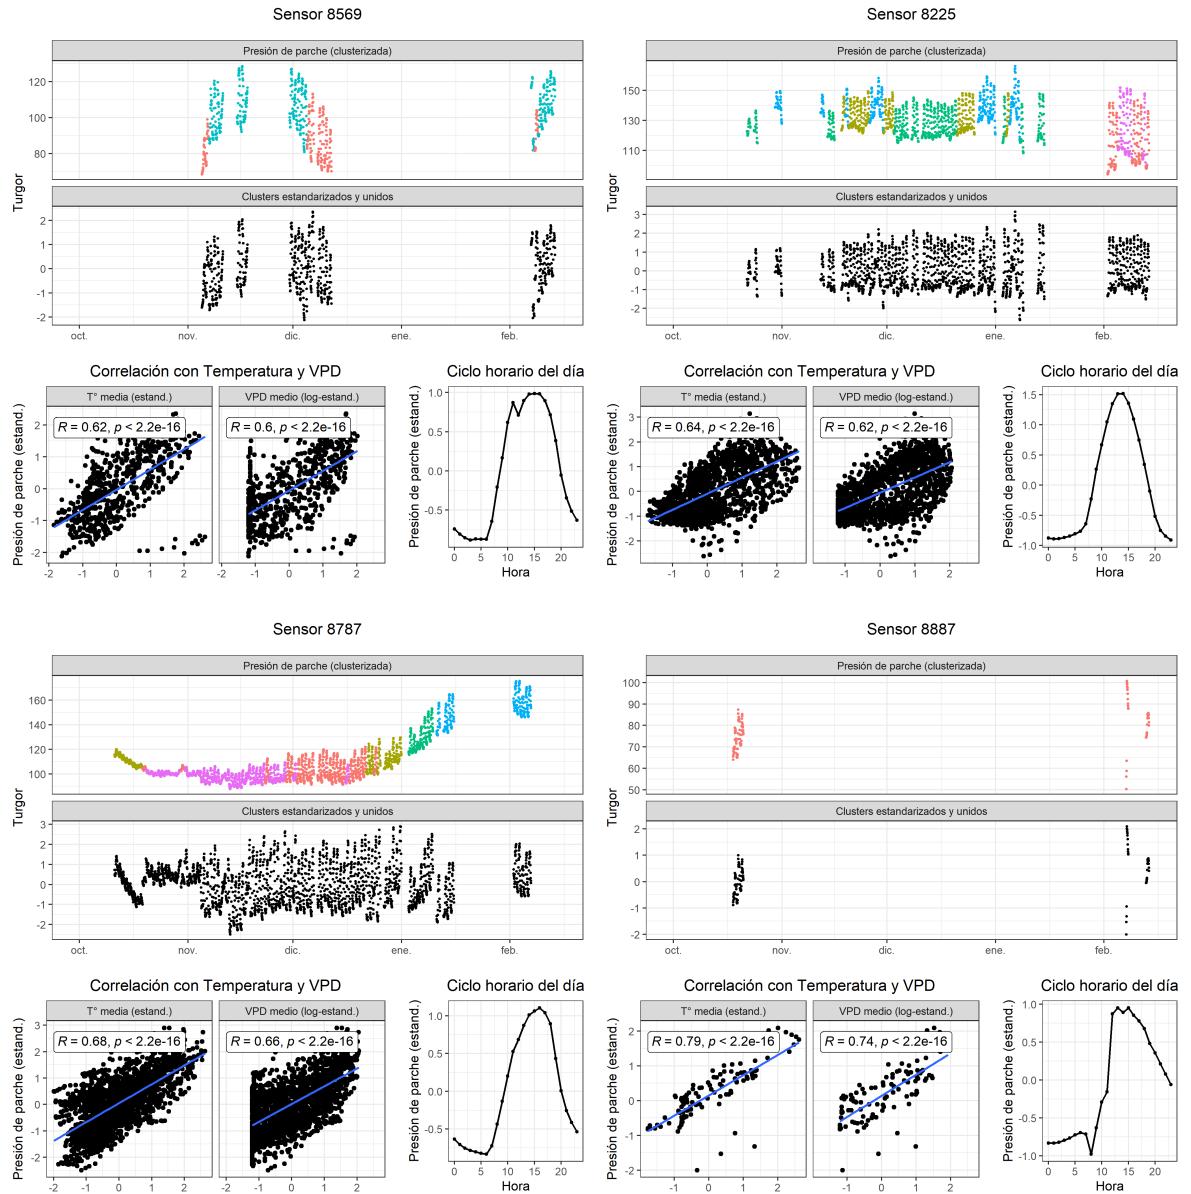


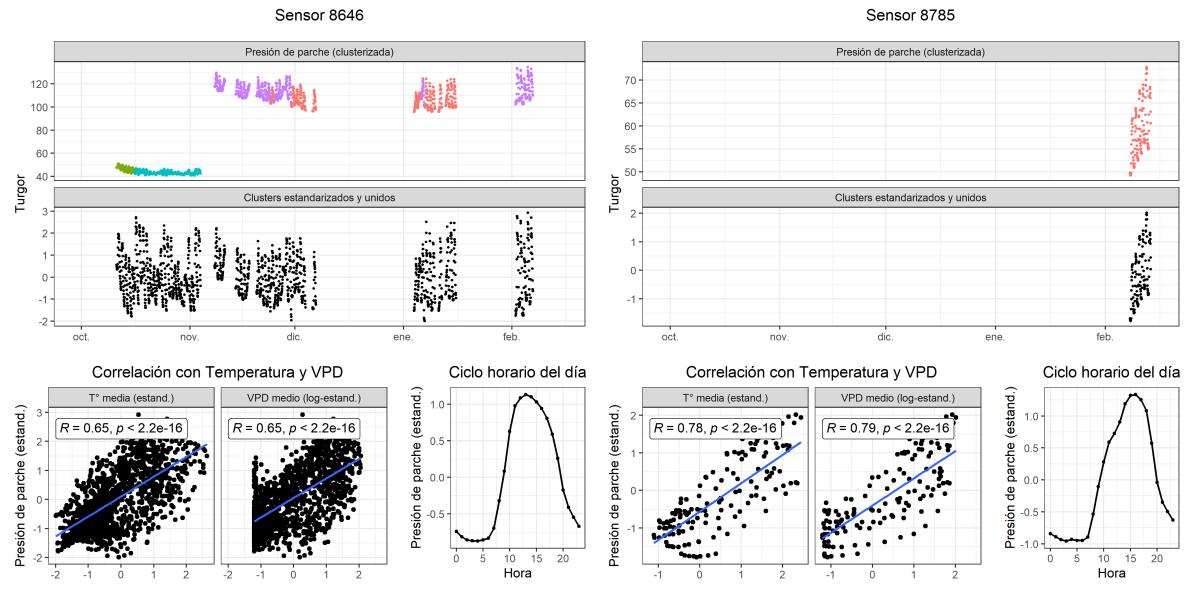


Unidad 3

54 T1 (2023-2024)

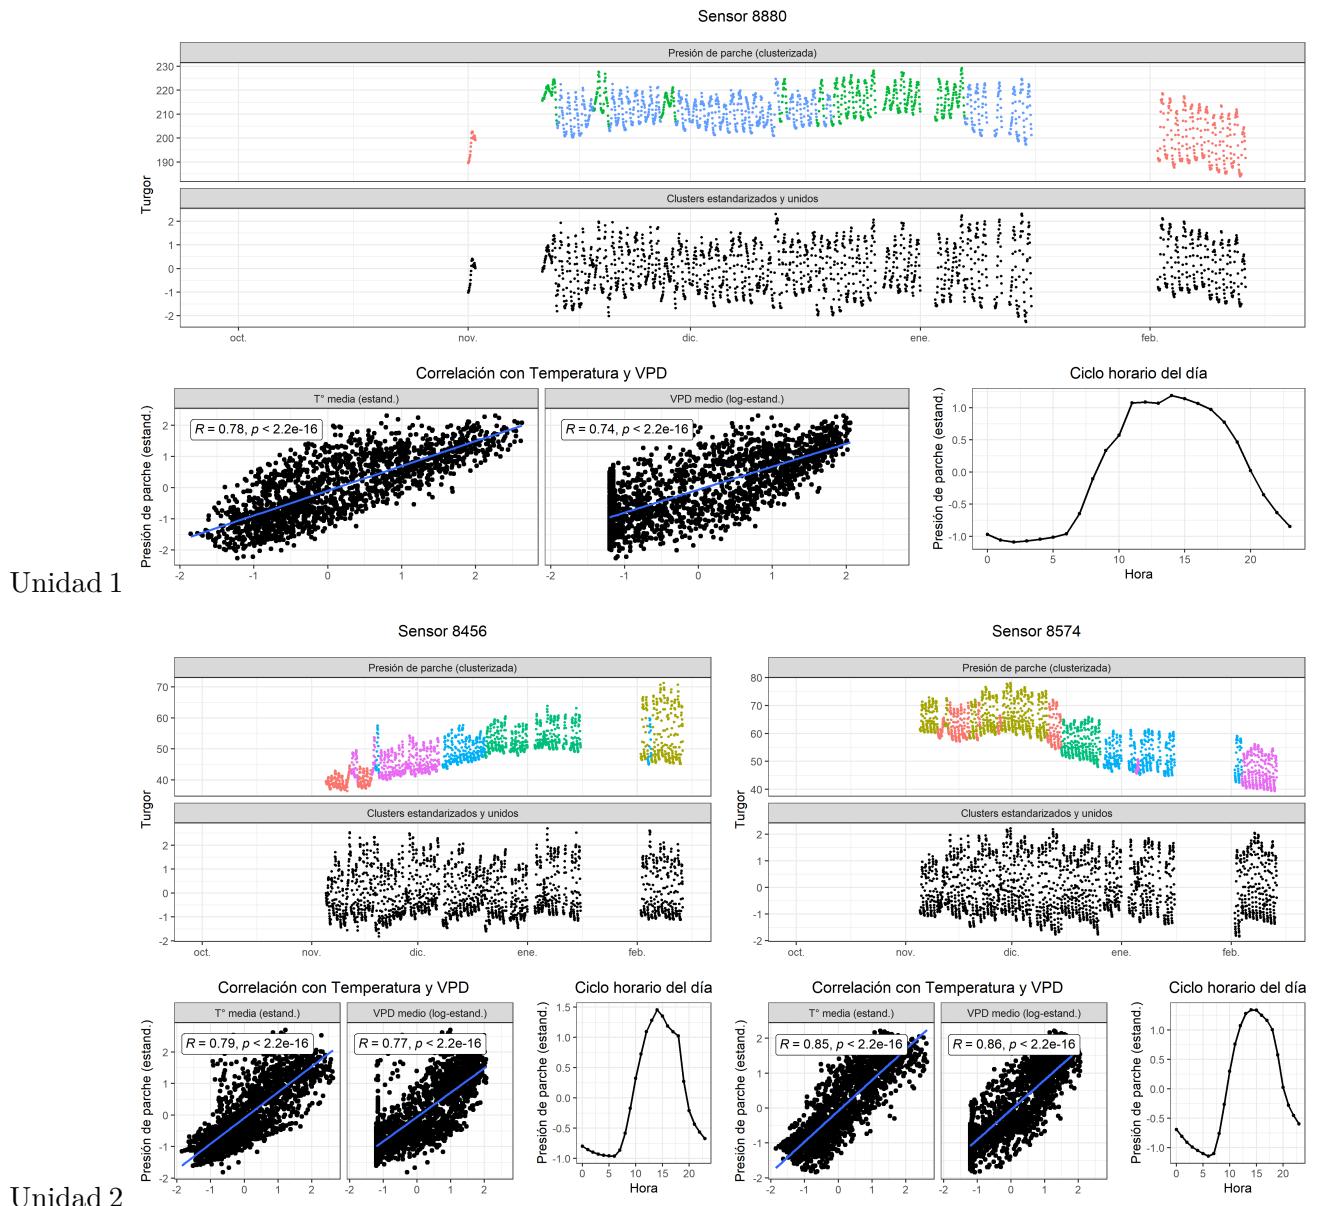
Unidad 1



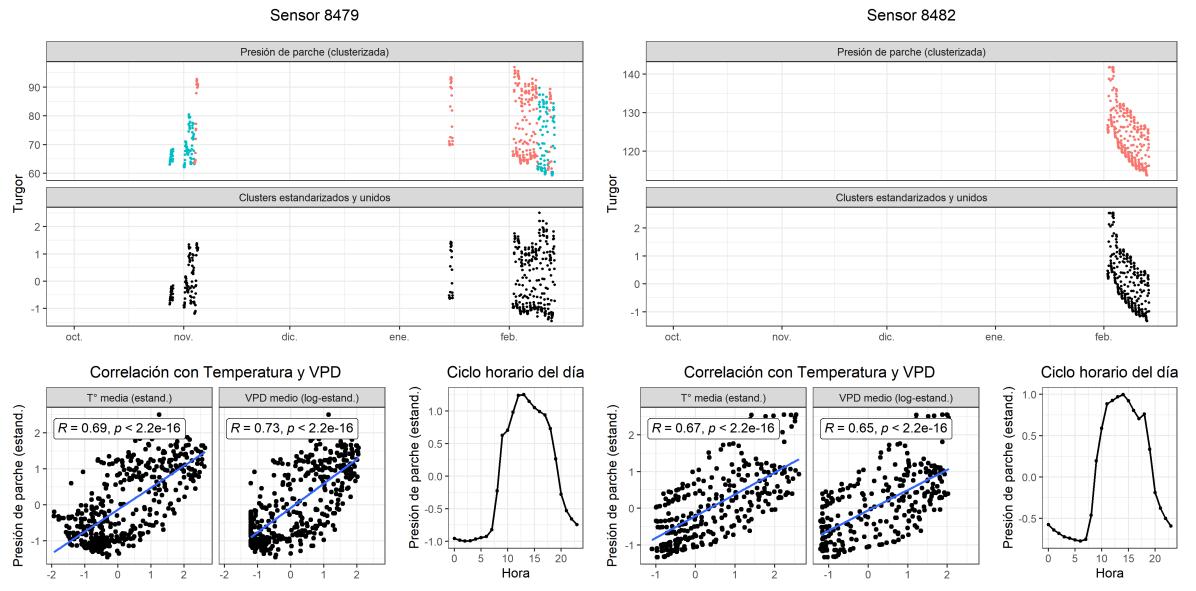


Unidad 3

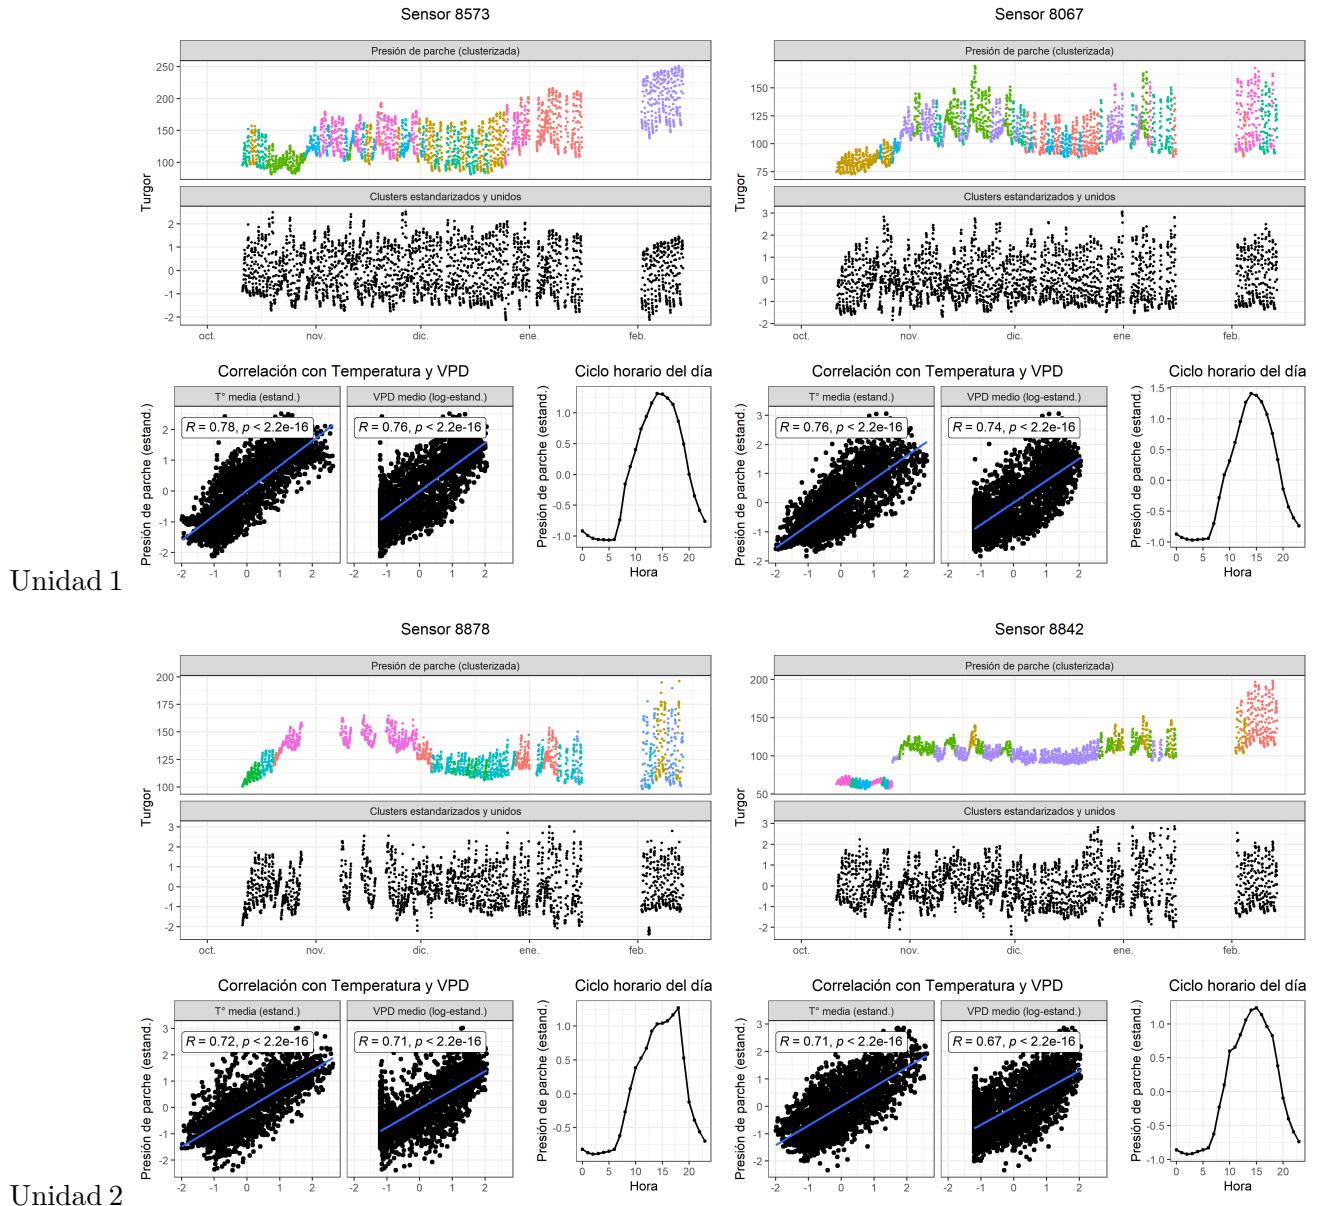
55 T2 (2023-2024)



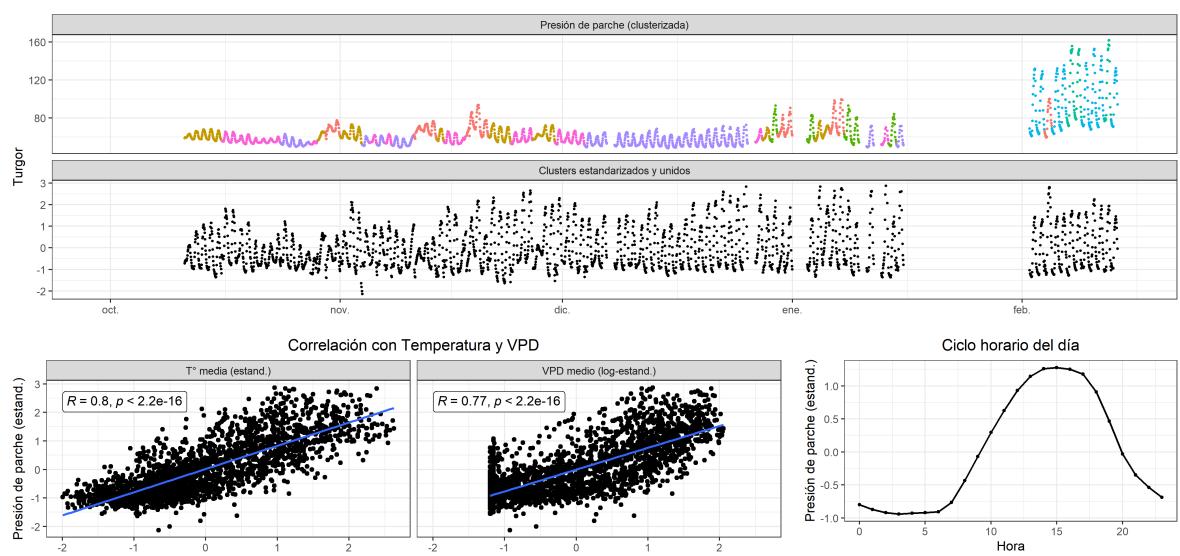
Unidad 3



56 T3 (2023-2024)



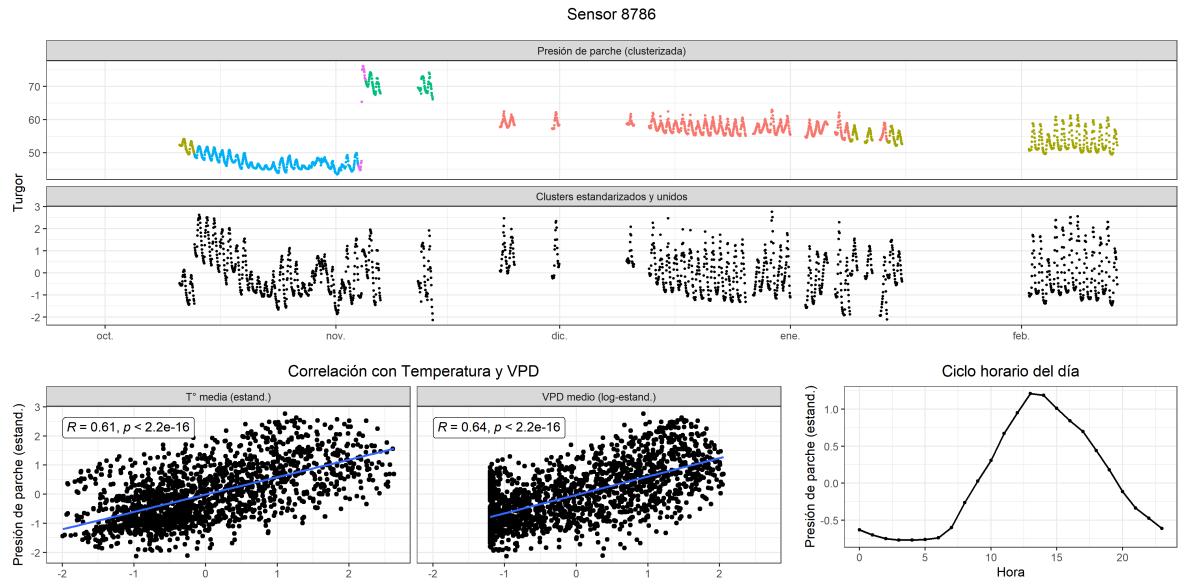
Sensor 8694



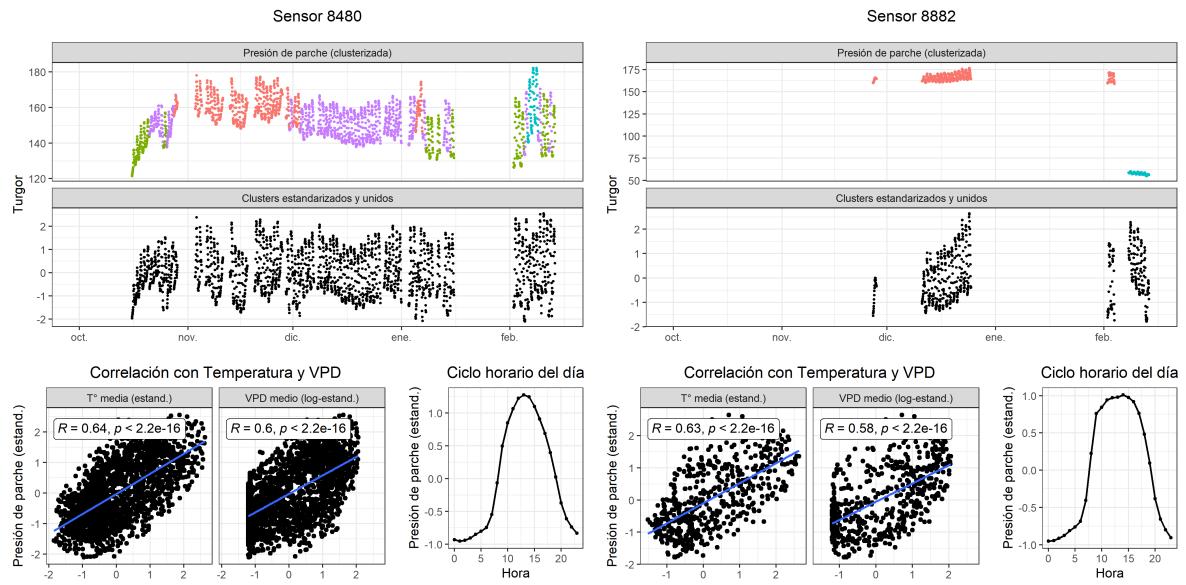
Unidad 3

57 T4 (2023-2024)

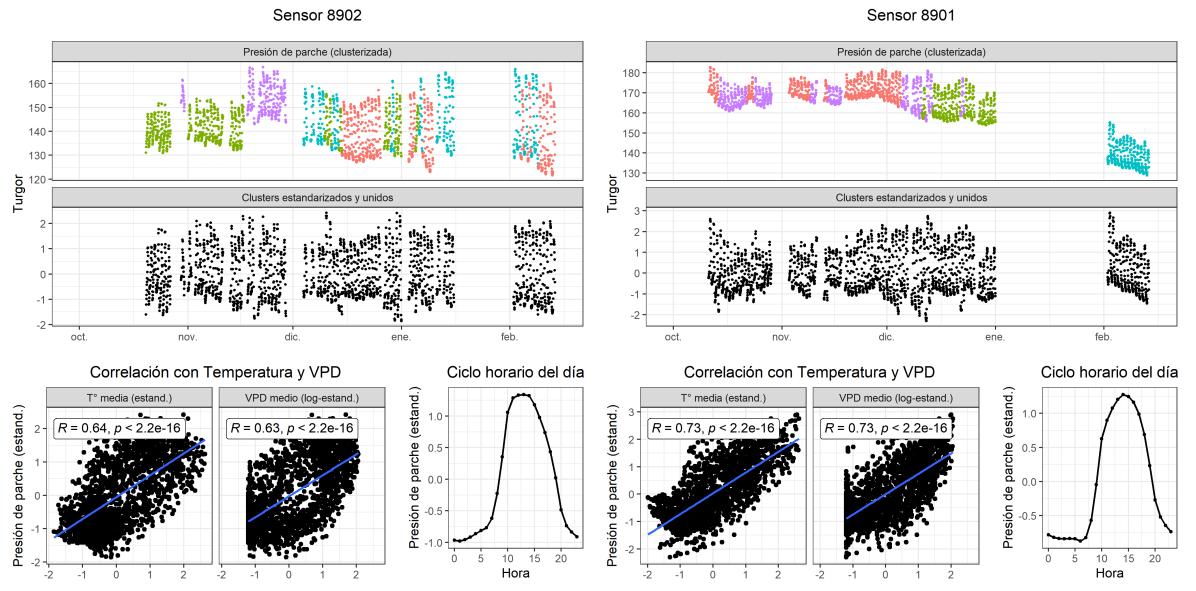
Unidad 1



Unidad 2



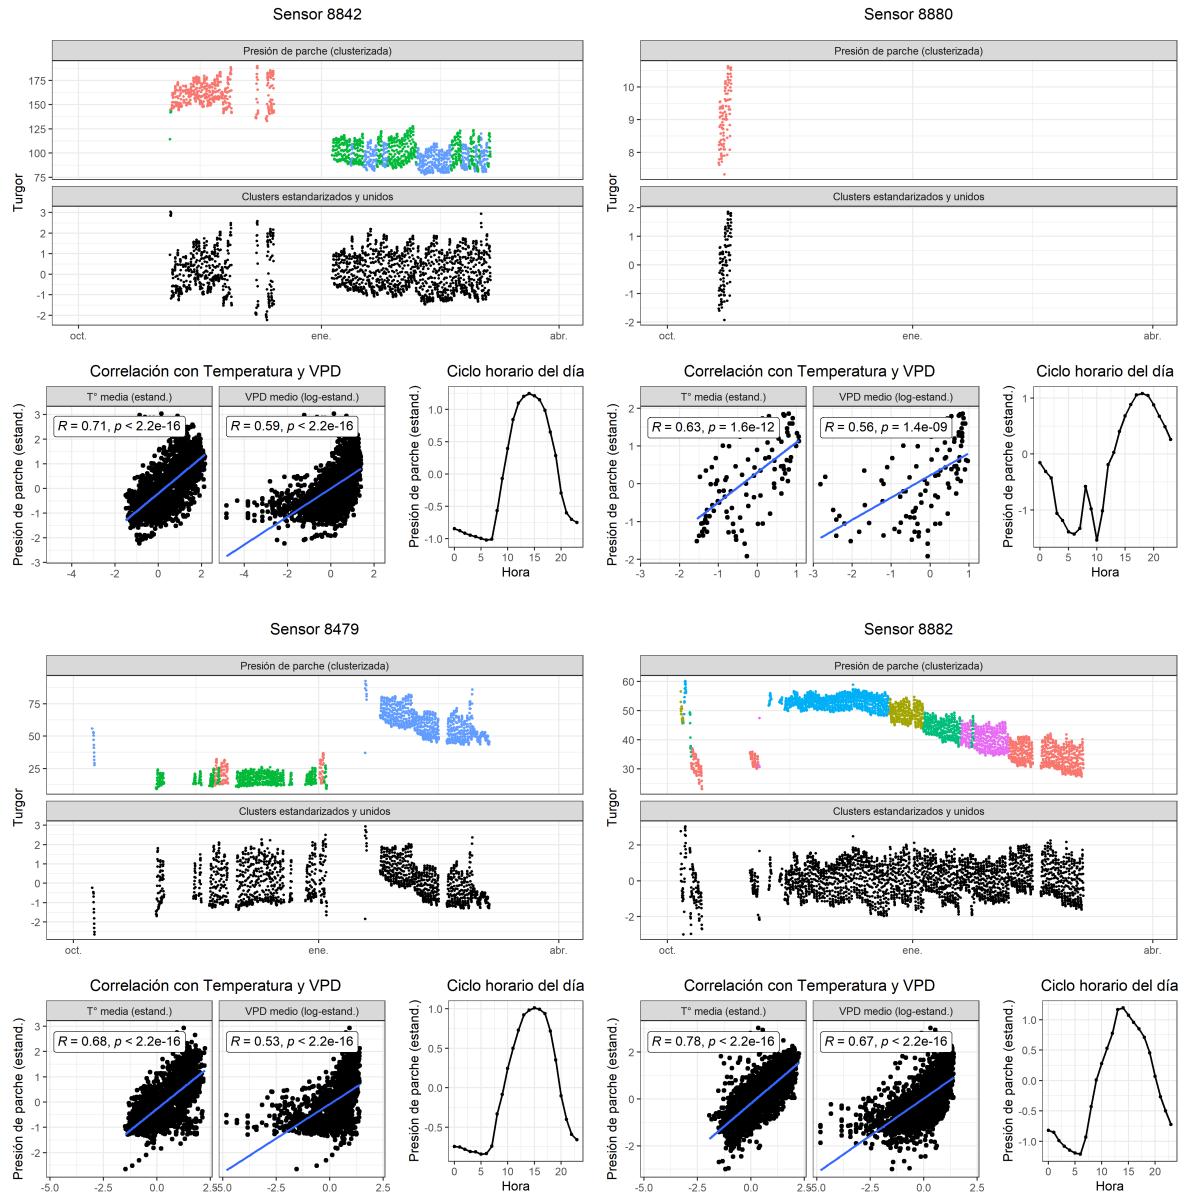
Unidad 3



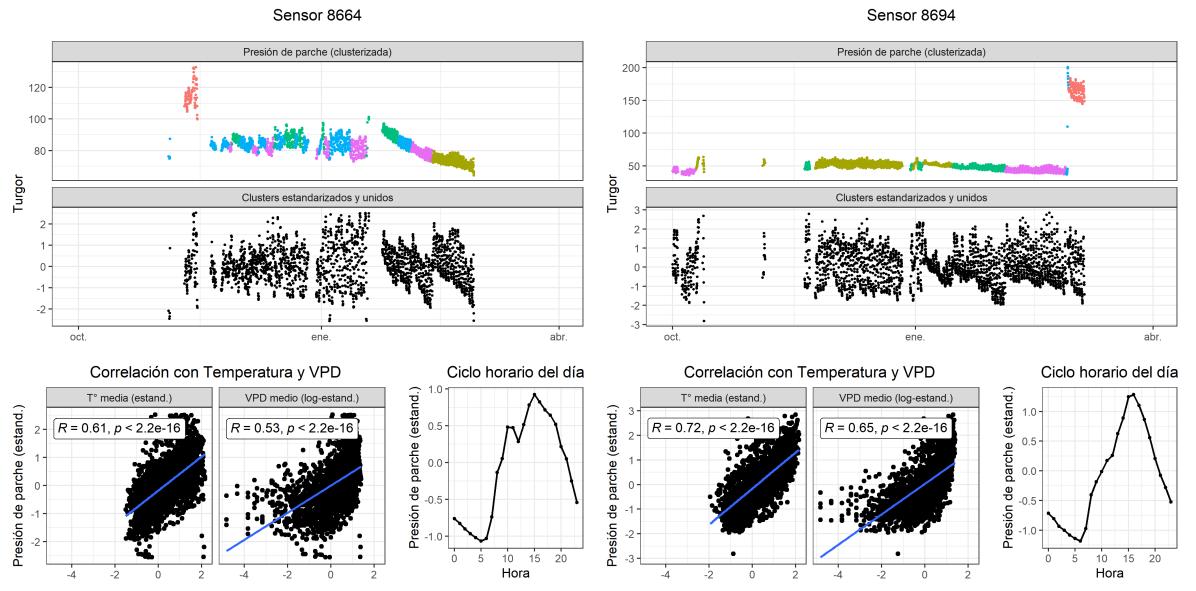
57.1 Rio Claro

58 T1 (2022-2023)

Unidad 1

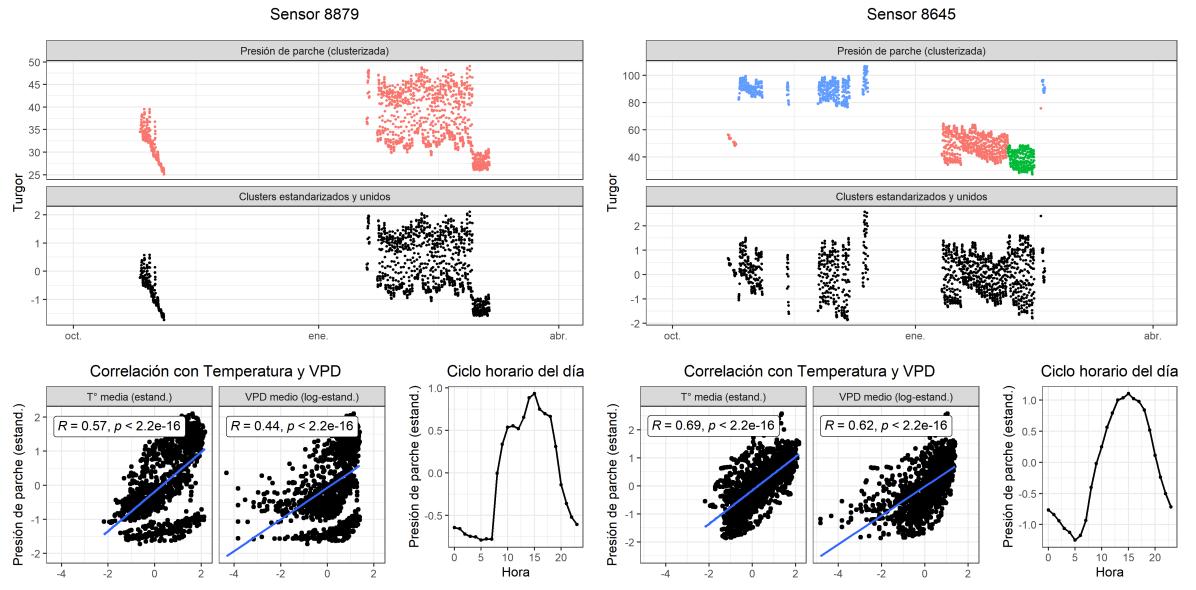


Unidad 3

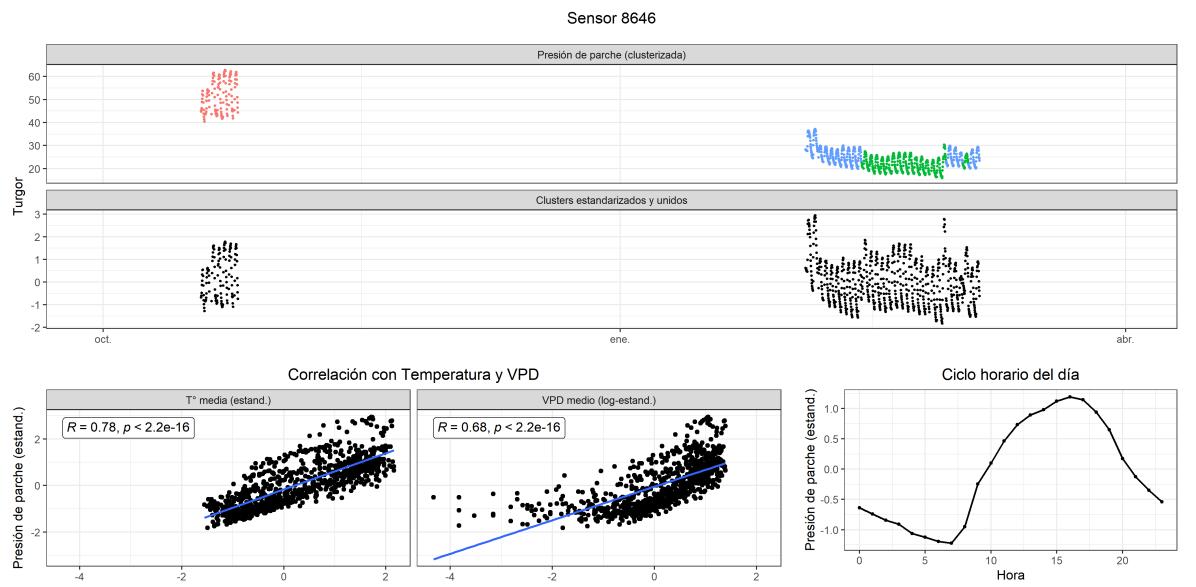


59 T2 (2022-2023)

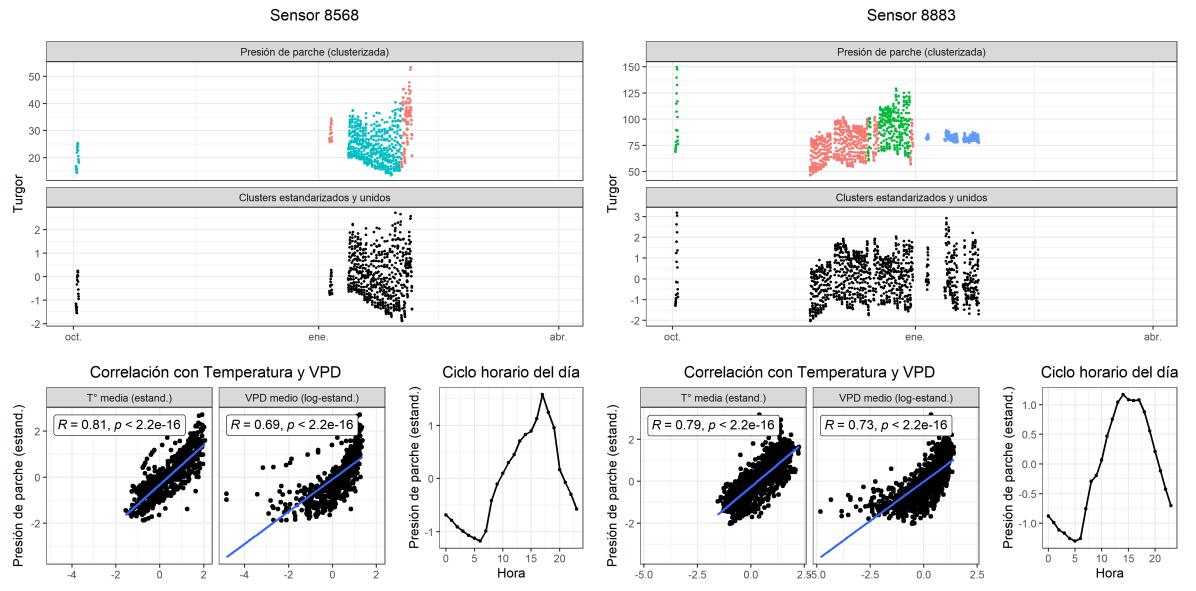
Unidad 1



Unidad 2

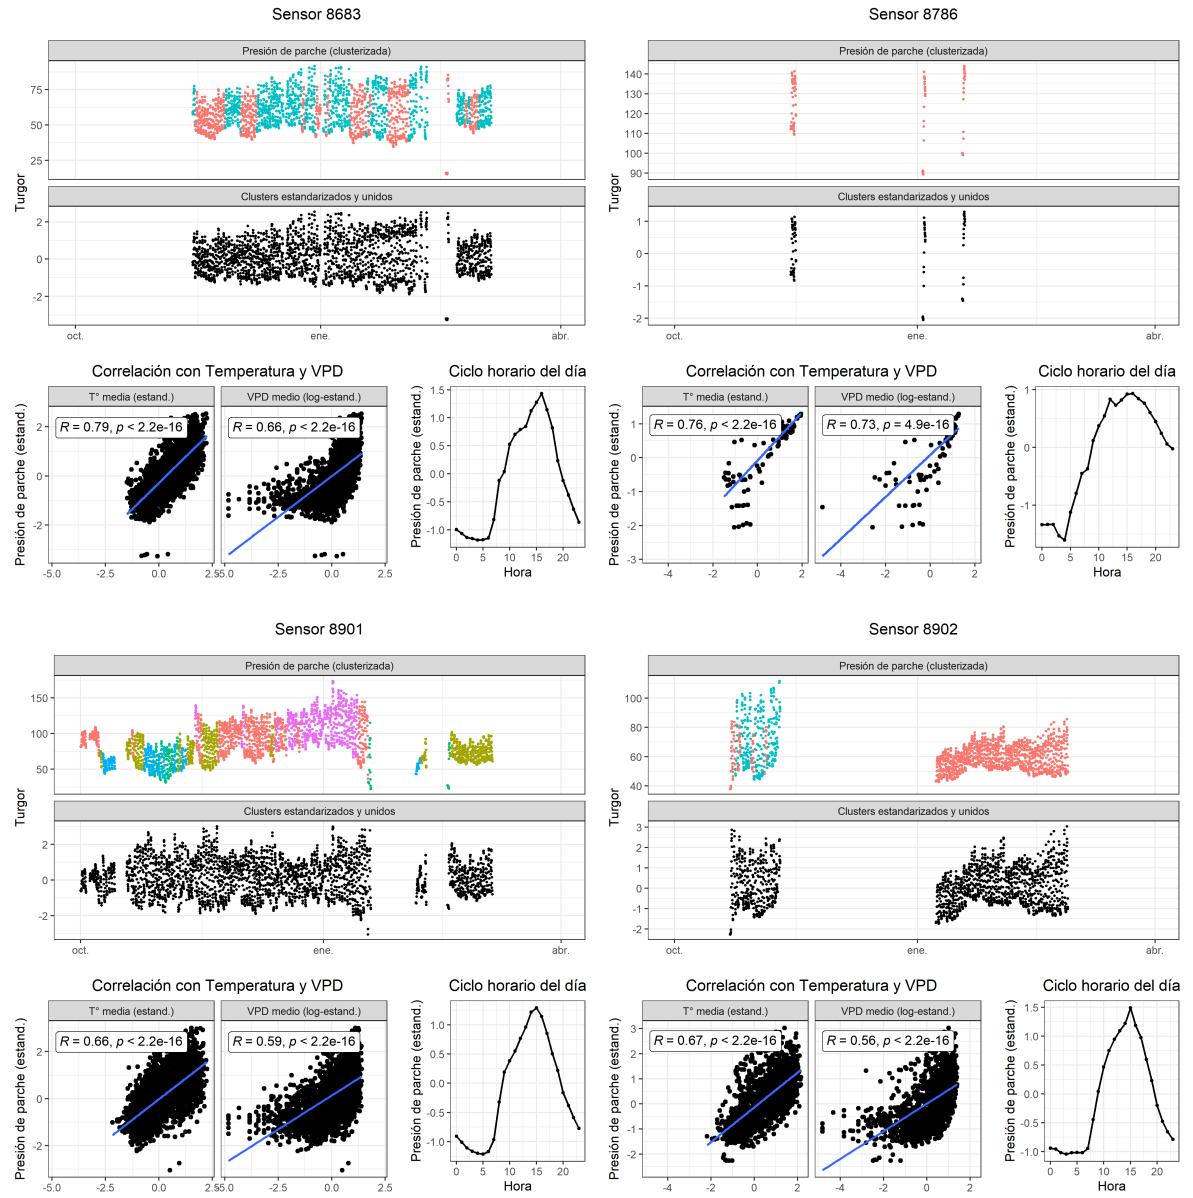


Unidad 3



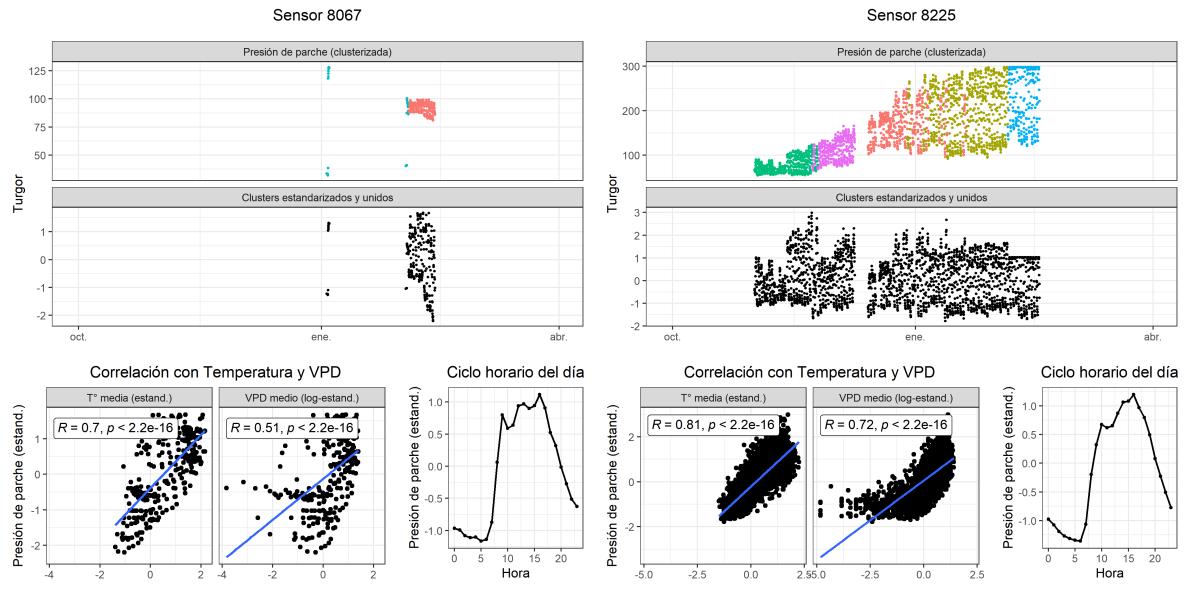
60 T3 (2022-2023)

Unidad 1

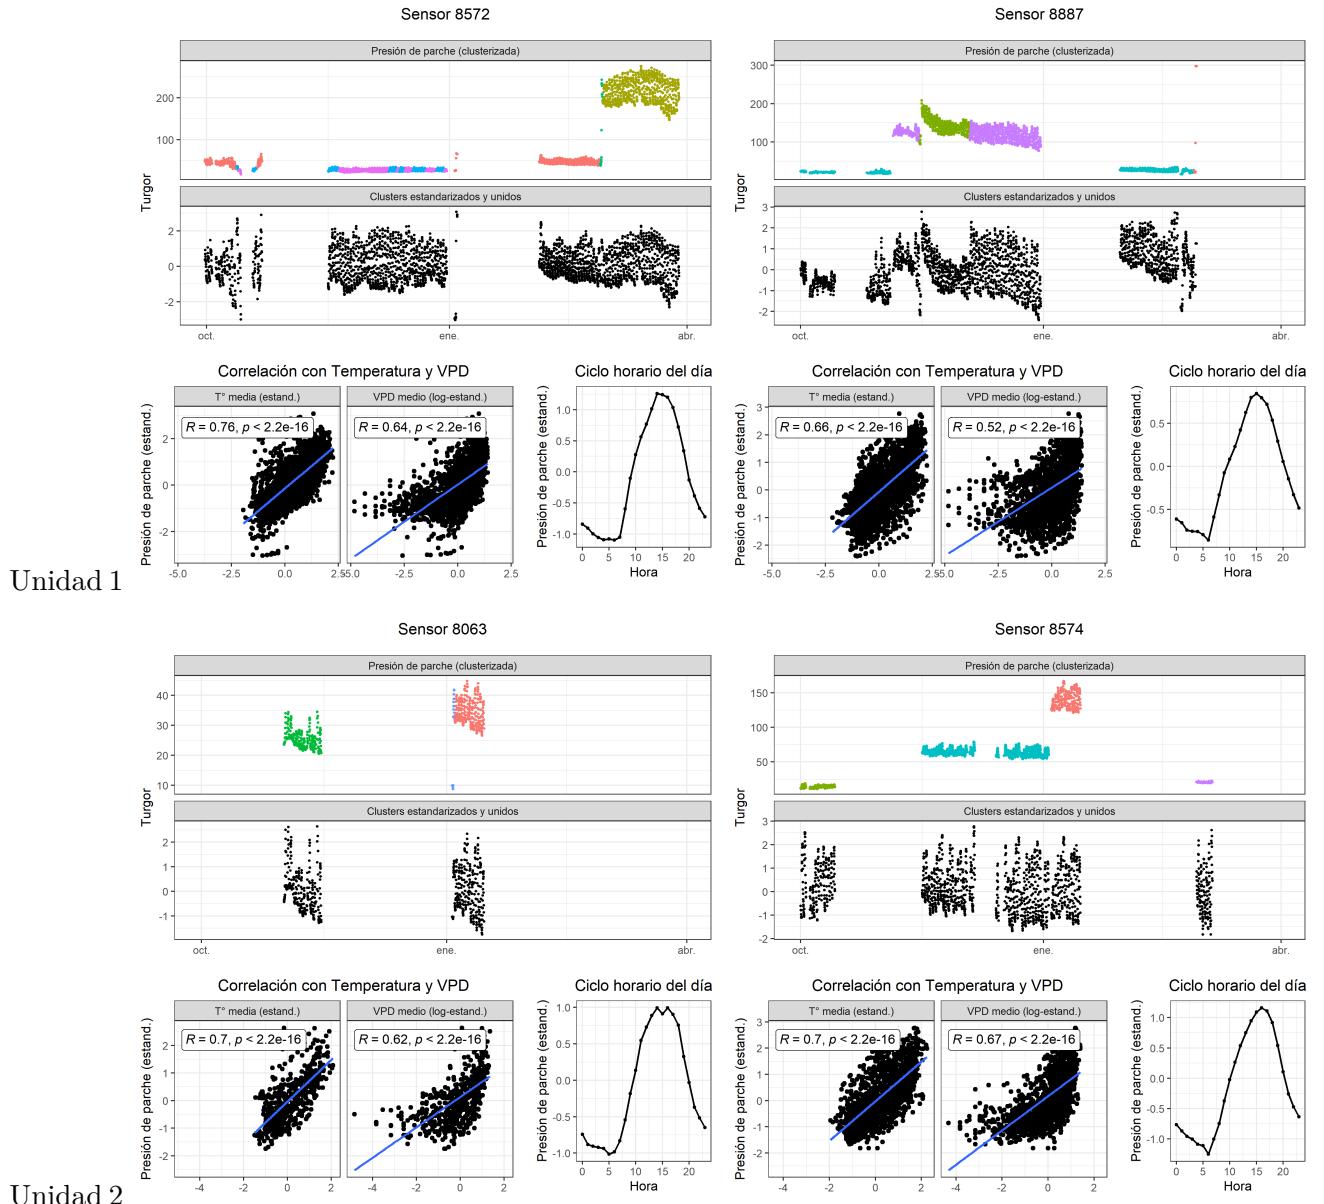


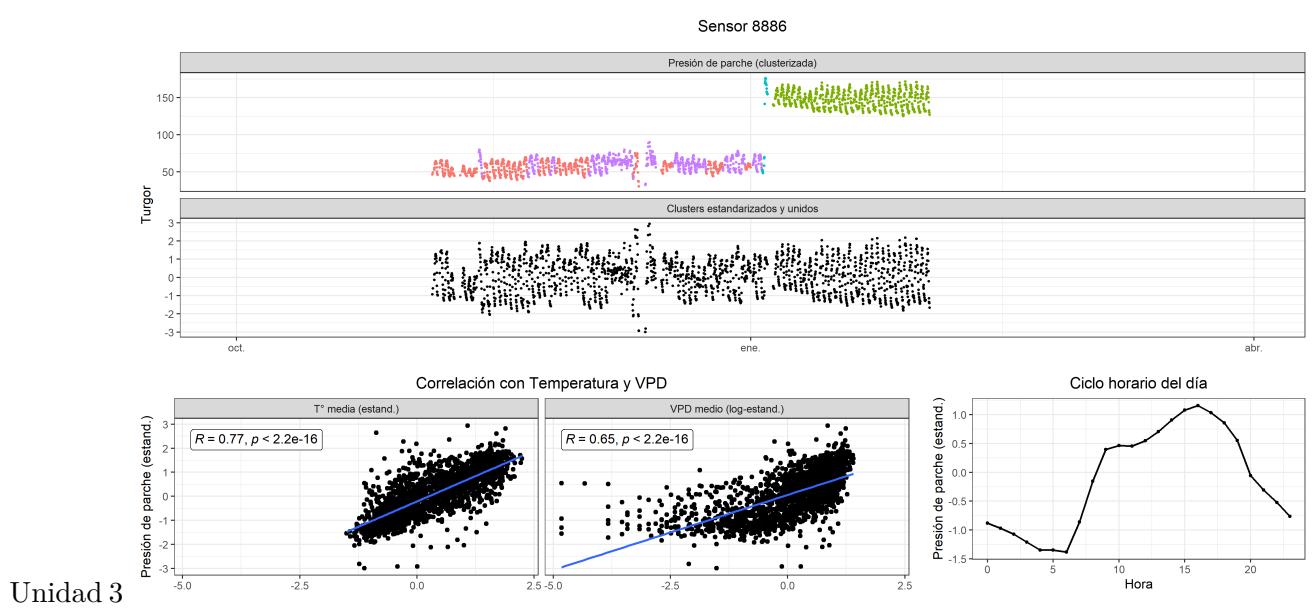
Unidad 2

Unidad 3



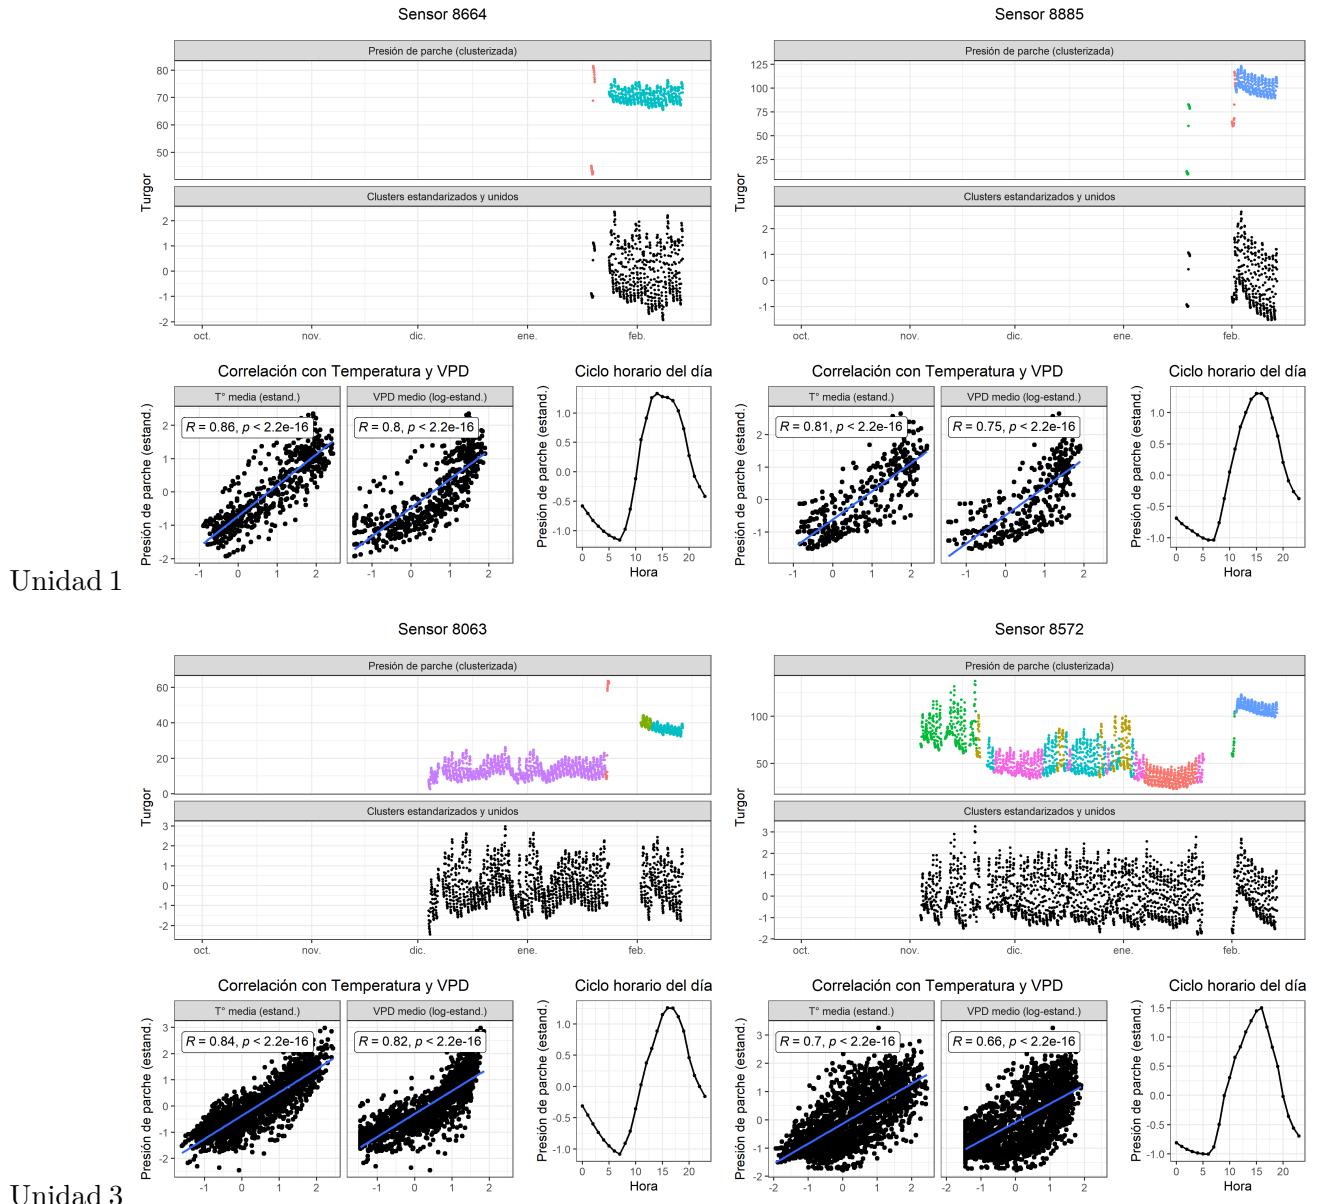
61 T4 (2022-2023)



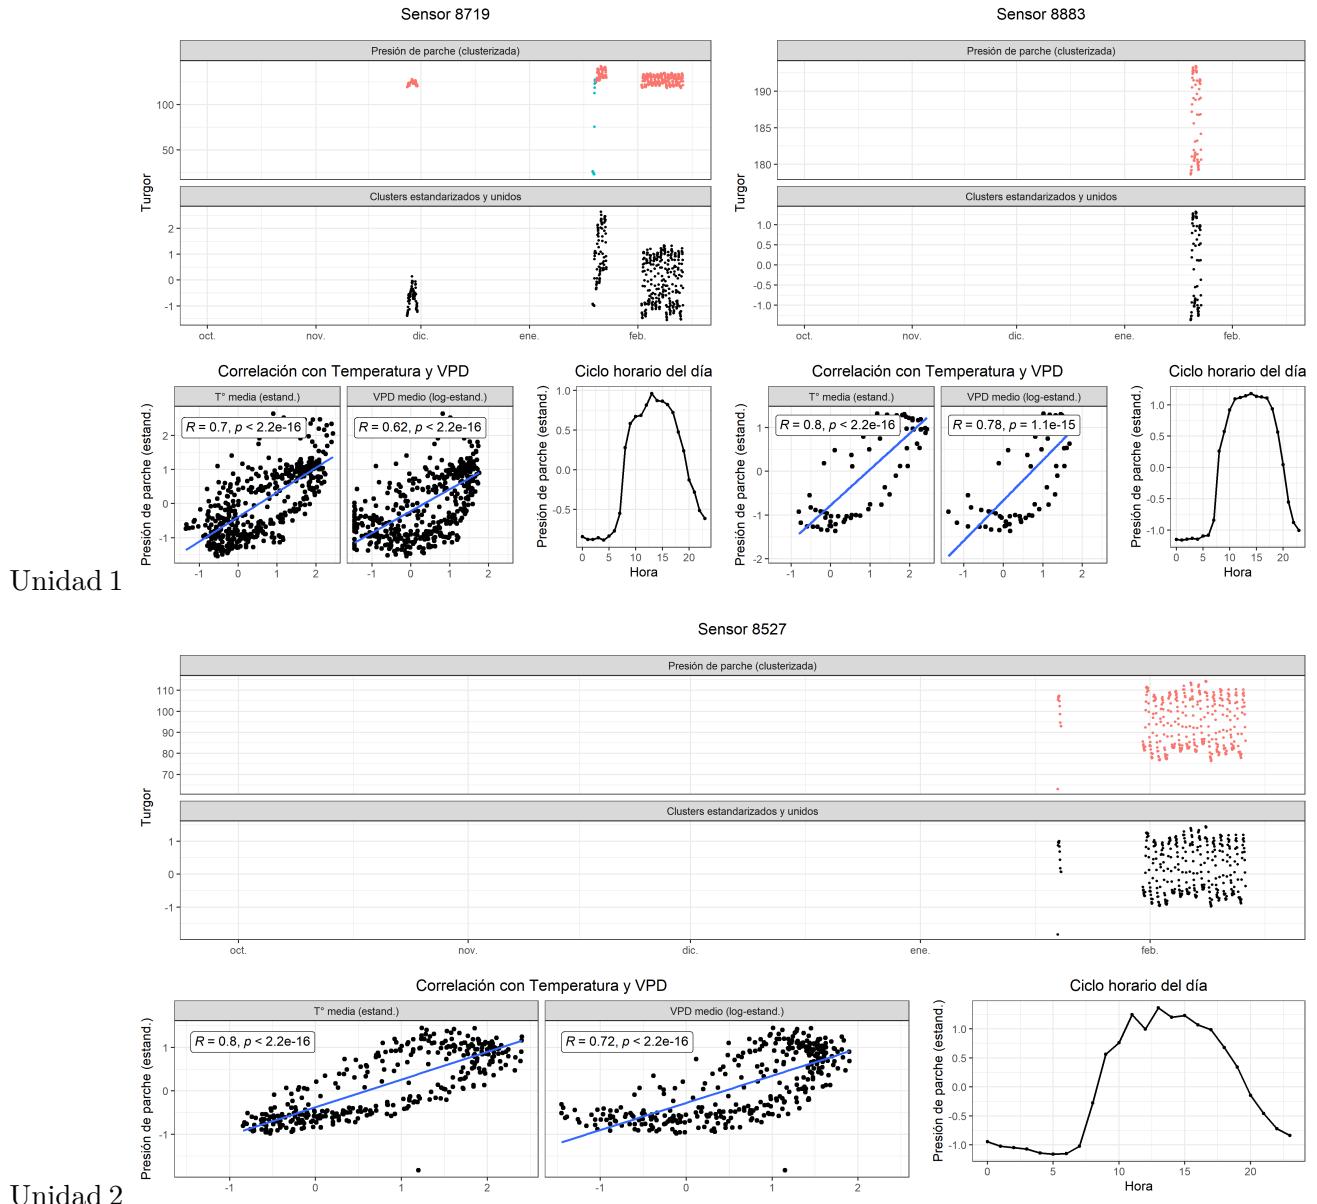


Unidad 3

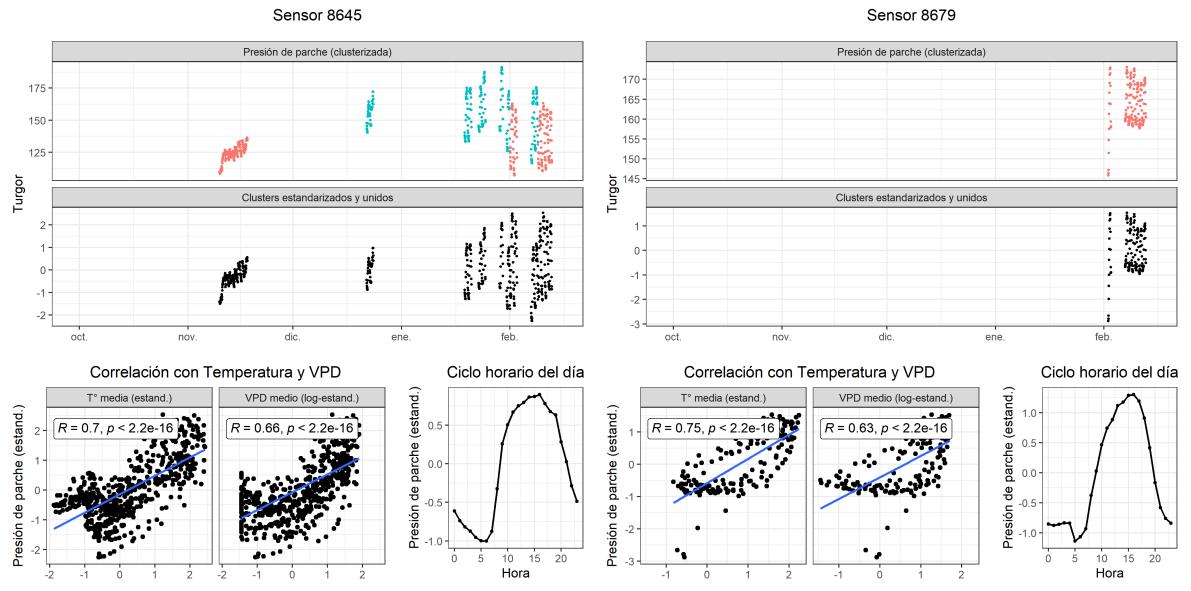
62 T1 (2023-2024)



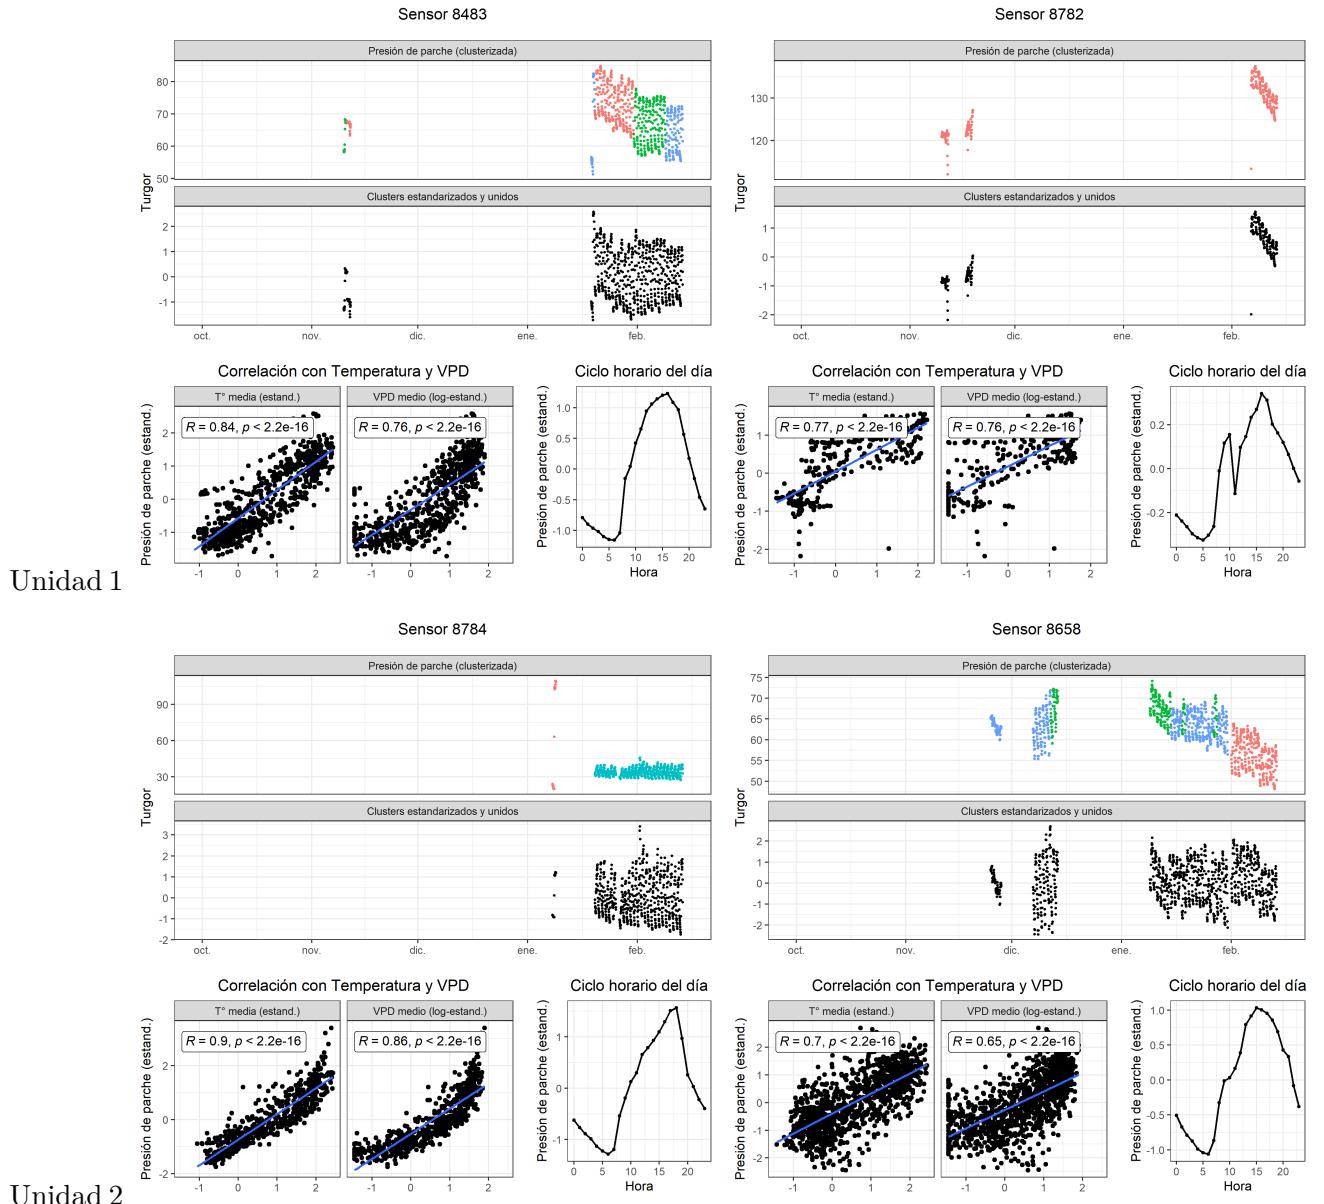
63 T2 (2023-2024)

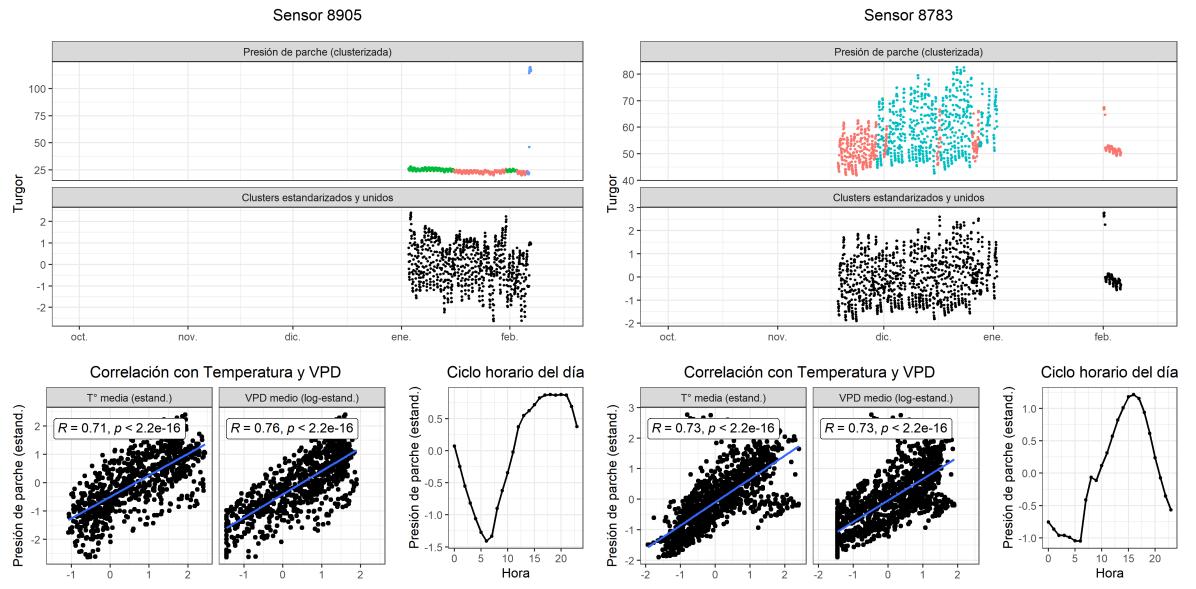


Unidad 3



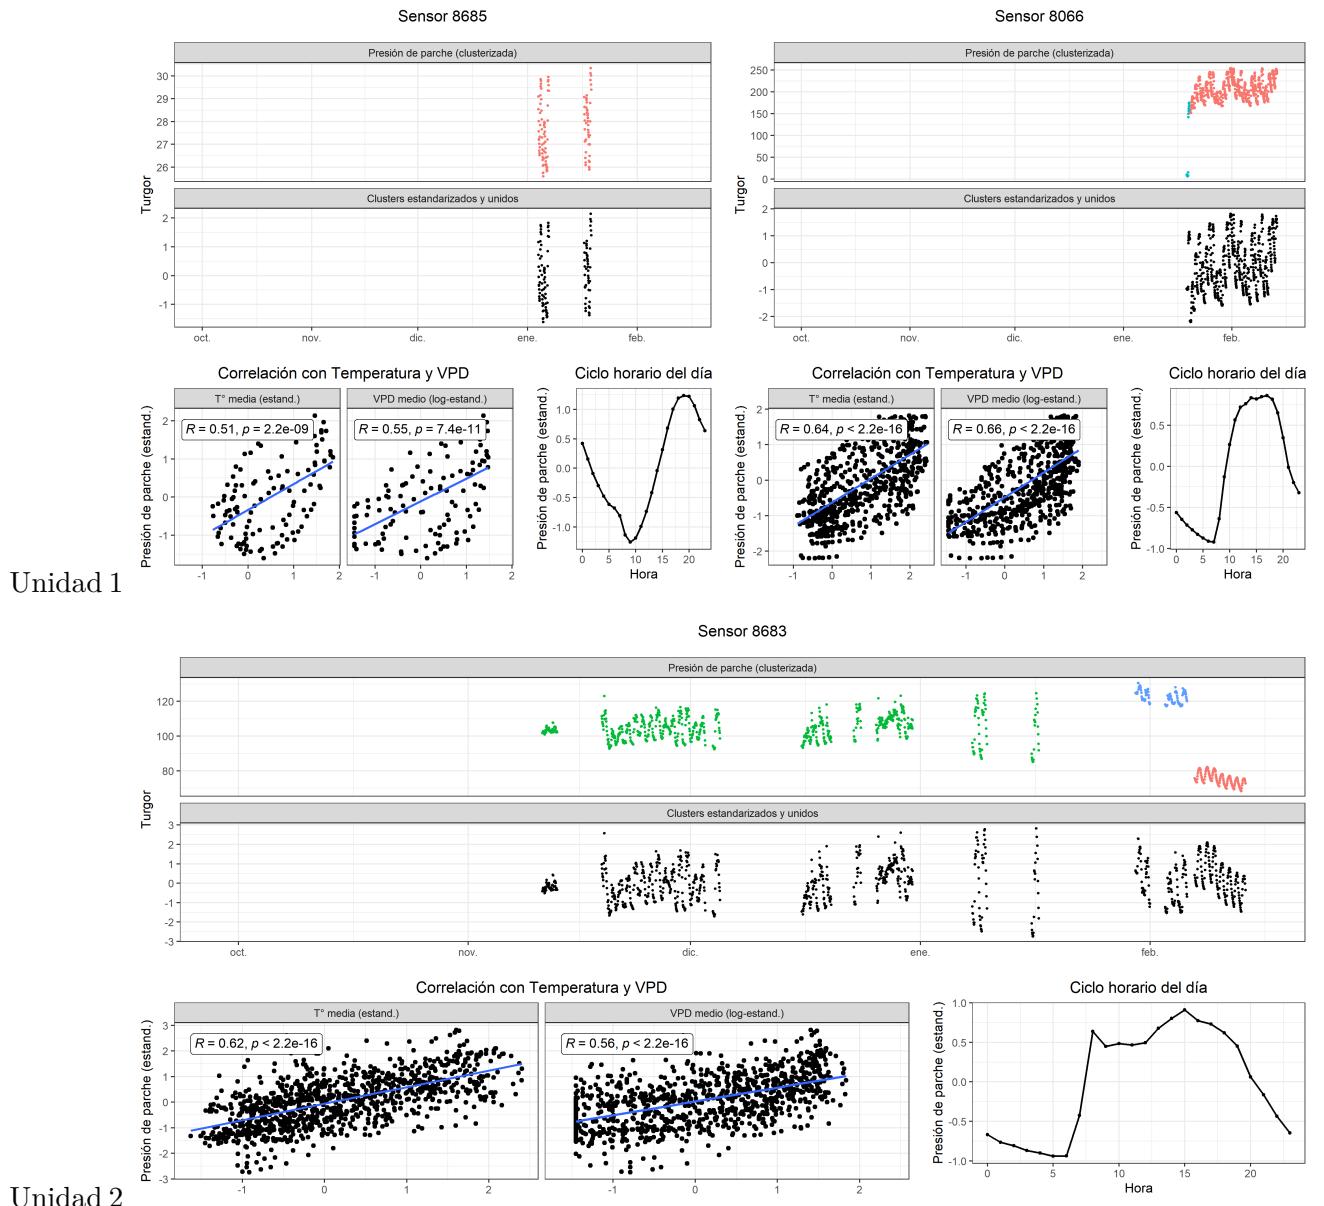
64 T3 (2023-2024)

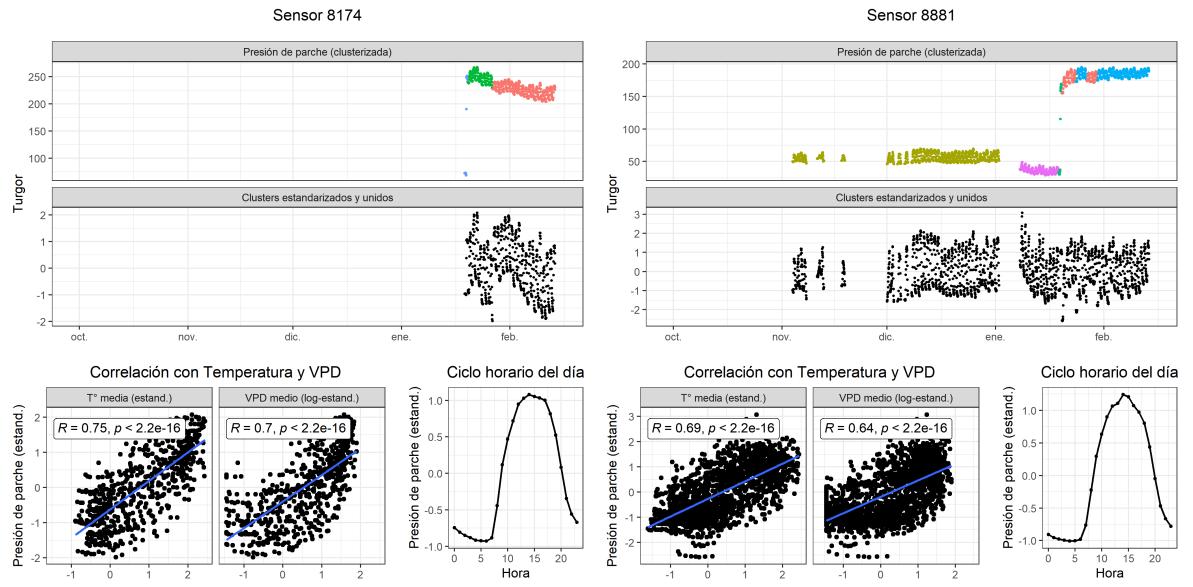




Unidad 3

65 T4 (2023-2024)





Unidad 3

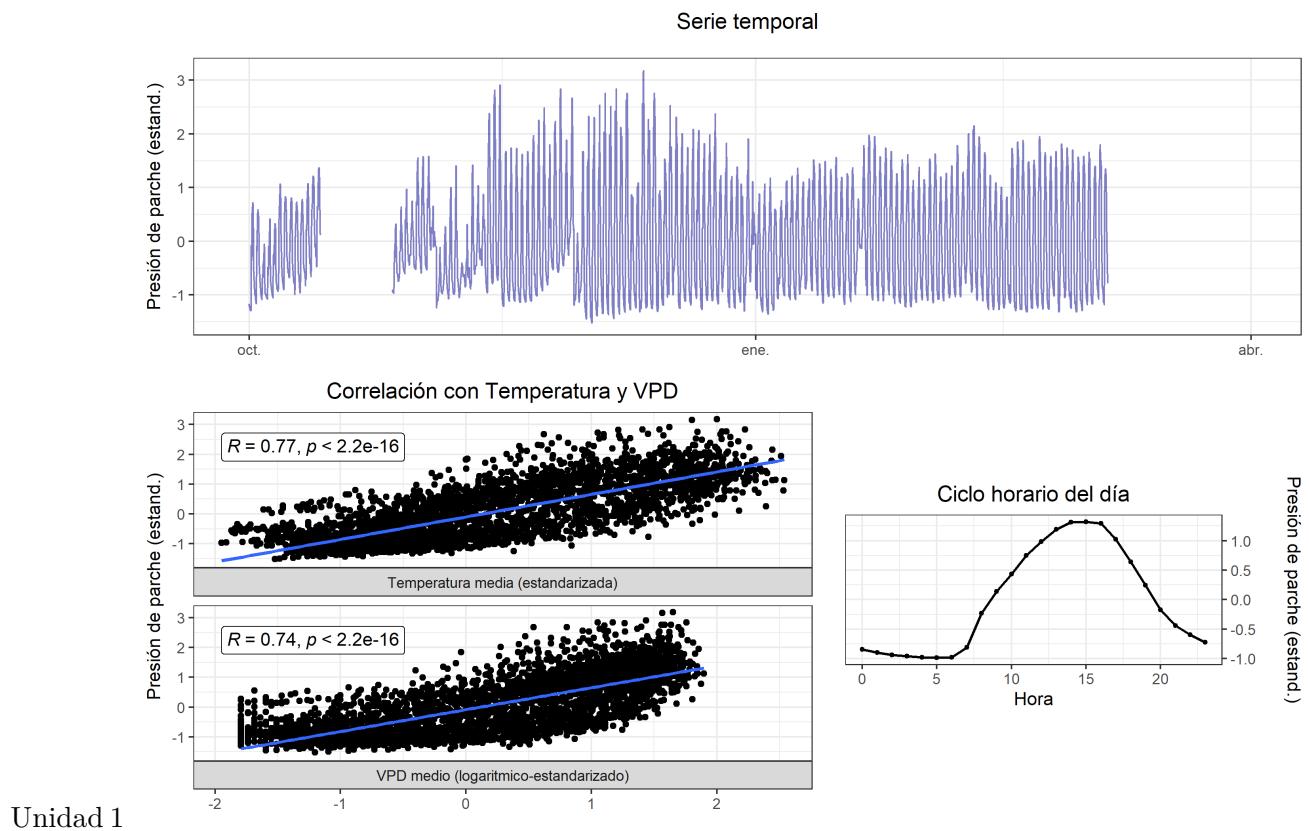
66 Datos preprocesados

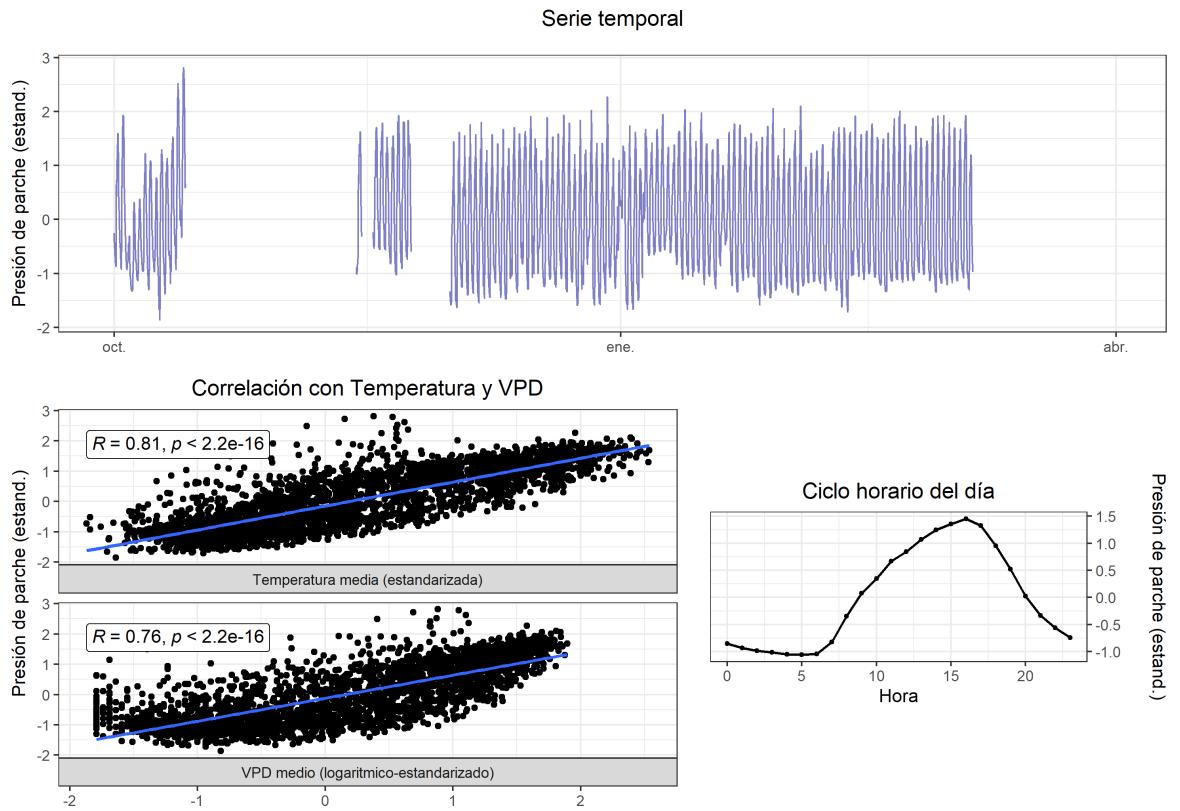
66.1 A nivel de unidad

Para obtener el turgor preprocesado por árbol según tratamiento, se promediaron las series de los sensores por cada unidad, obteniendo una serie única para cada árbol de los tratamientos.

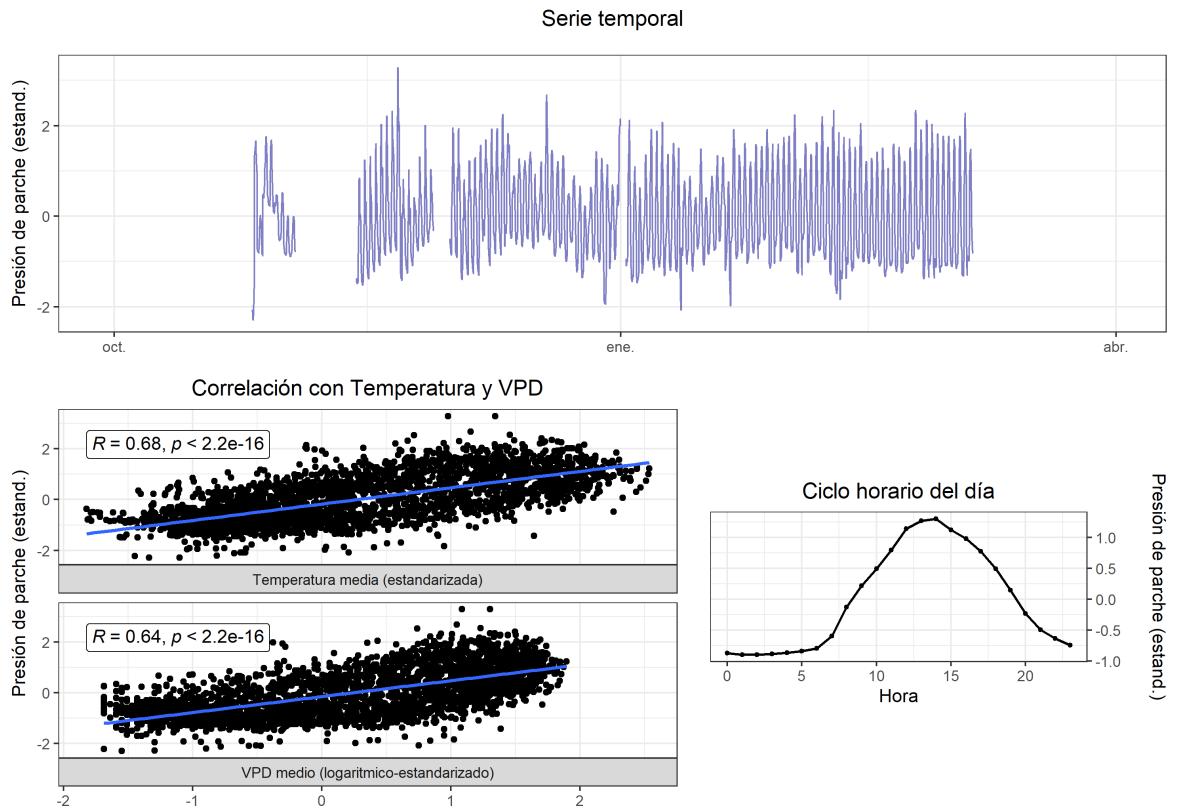
66.1.1 La Esperanza

67 T1 (2022-2023)



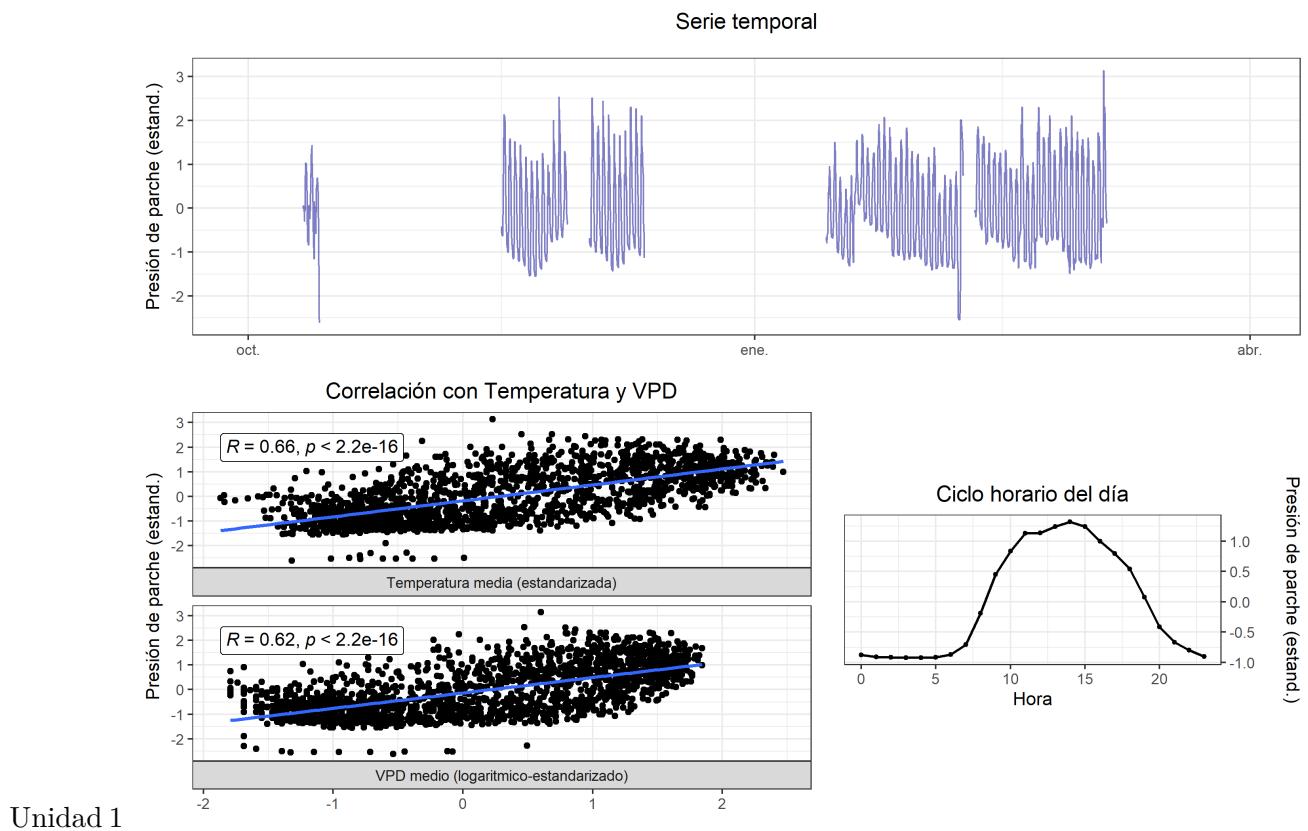


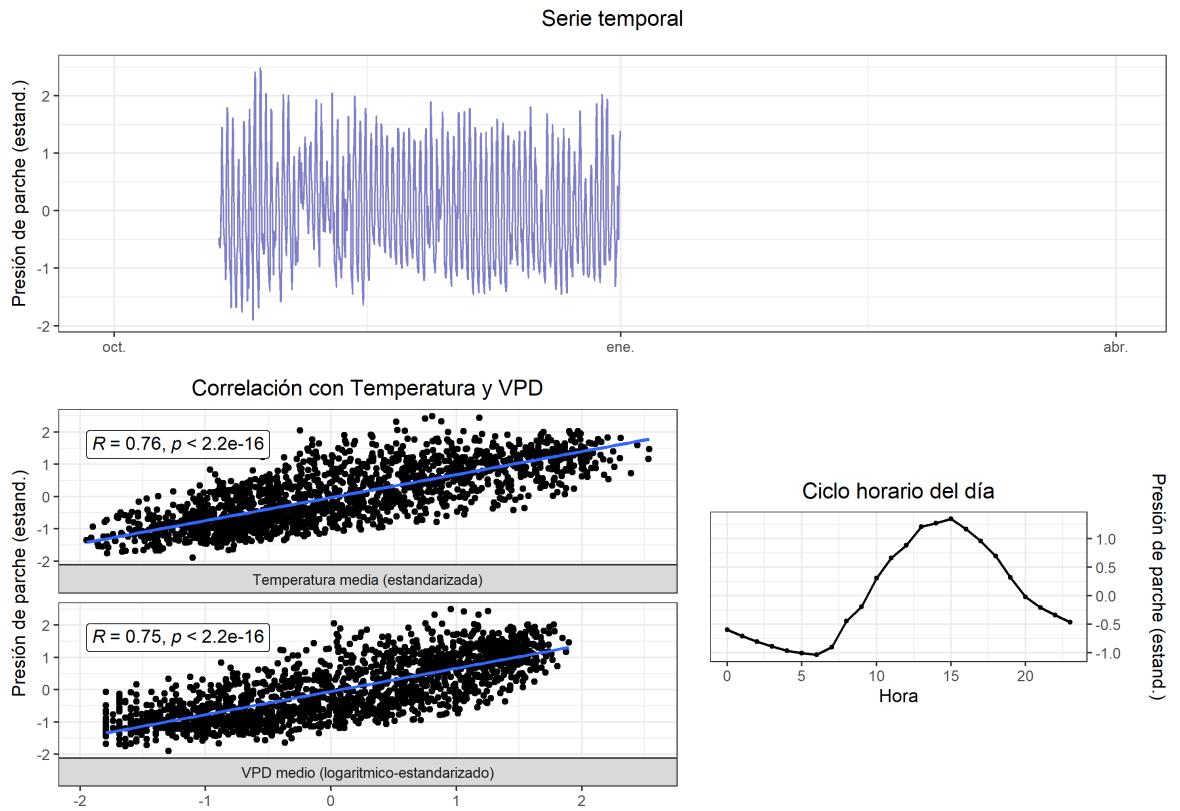
Unidad 2



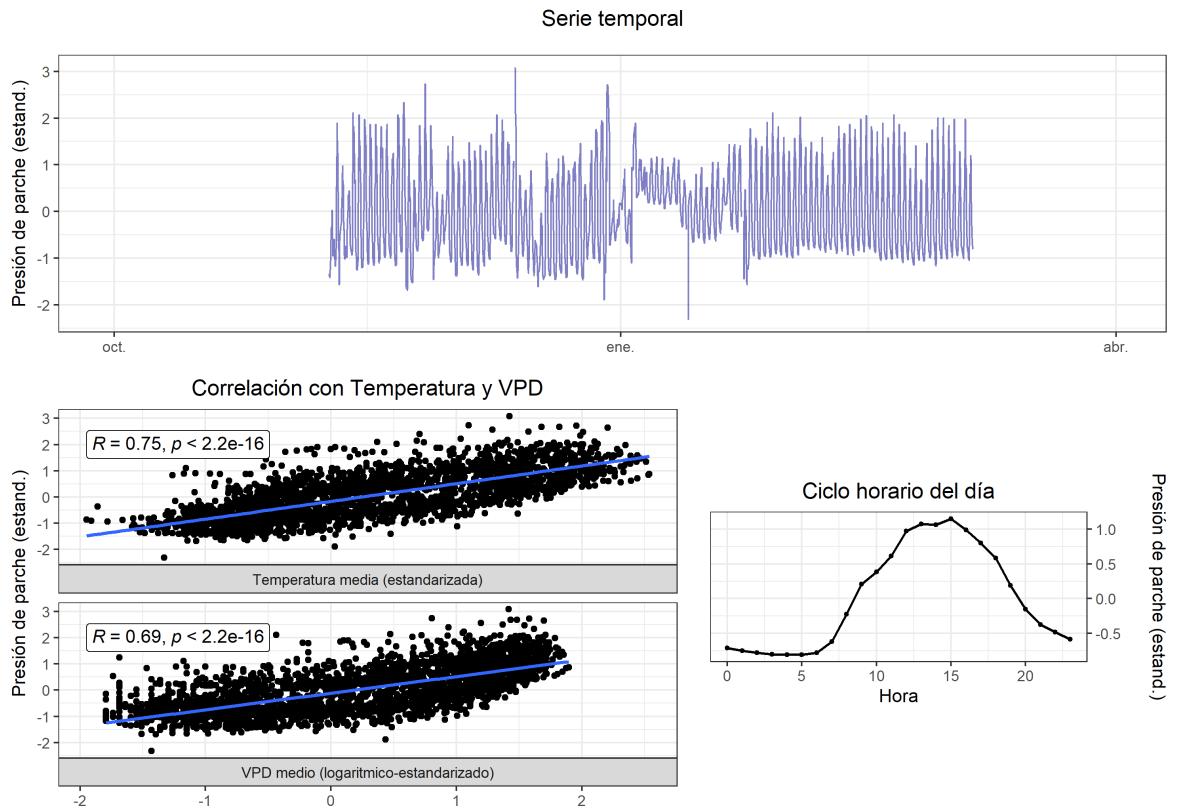
Unidad 3

68 T2 (2022-2023)



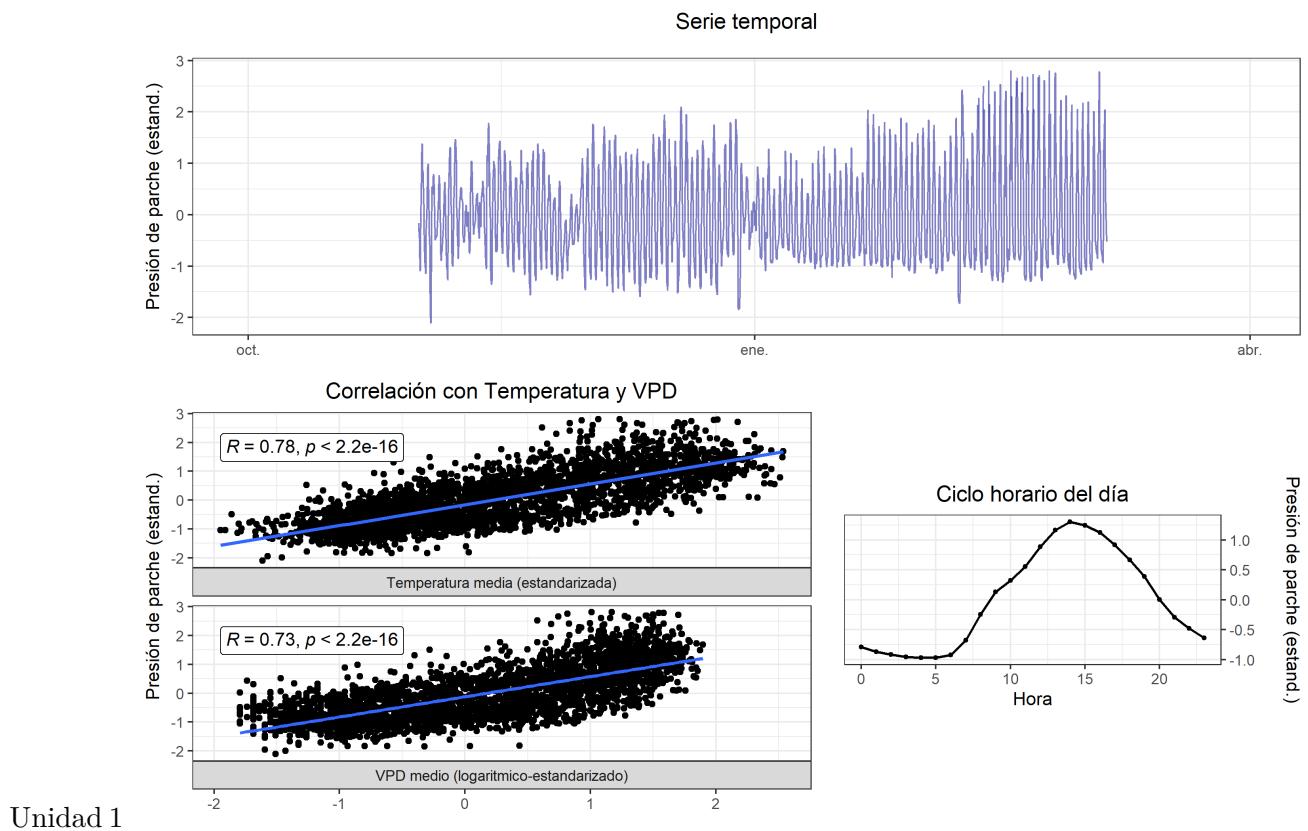


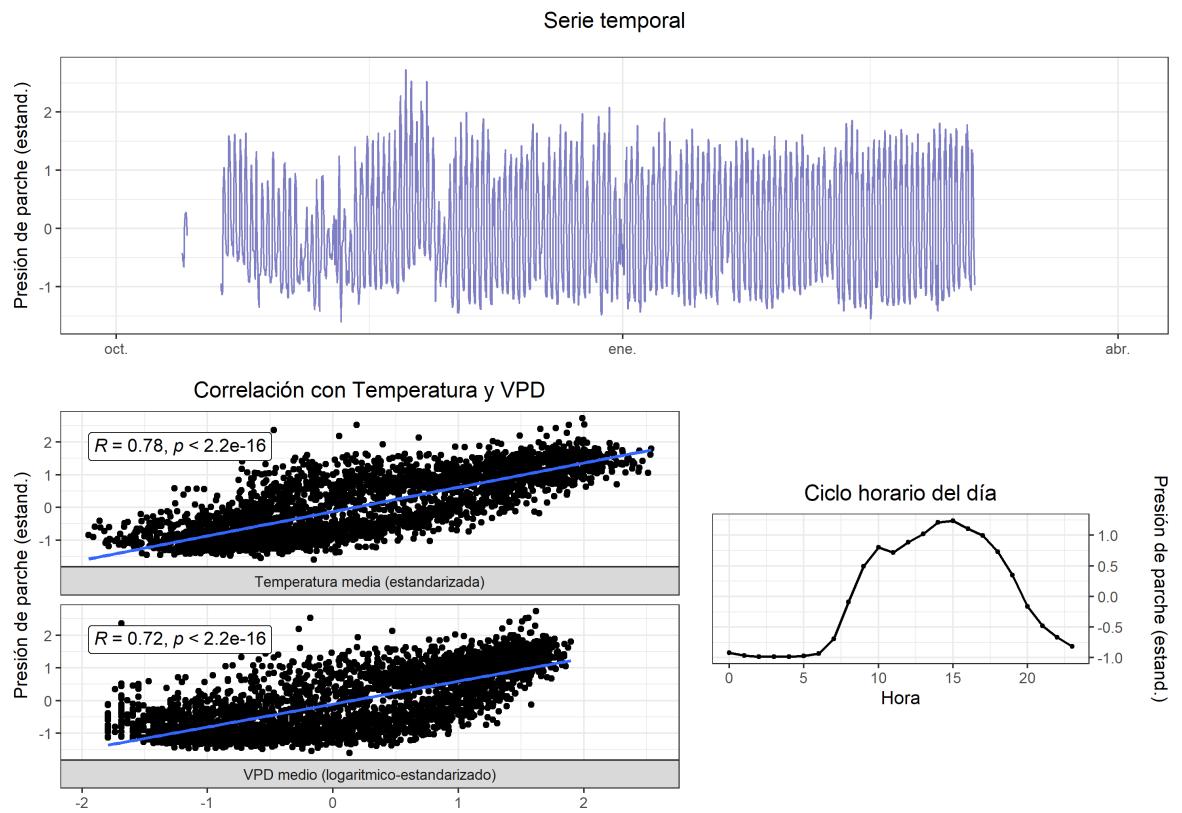
Unidad 2



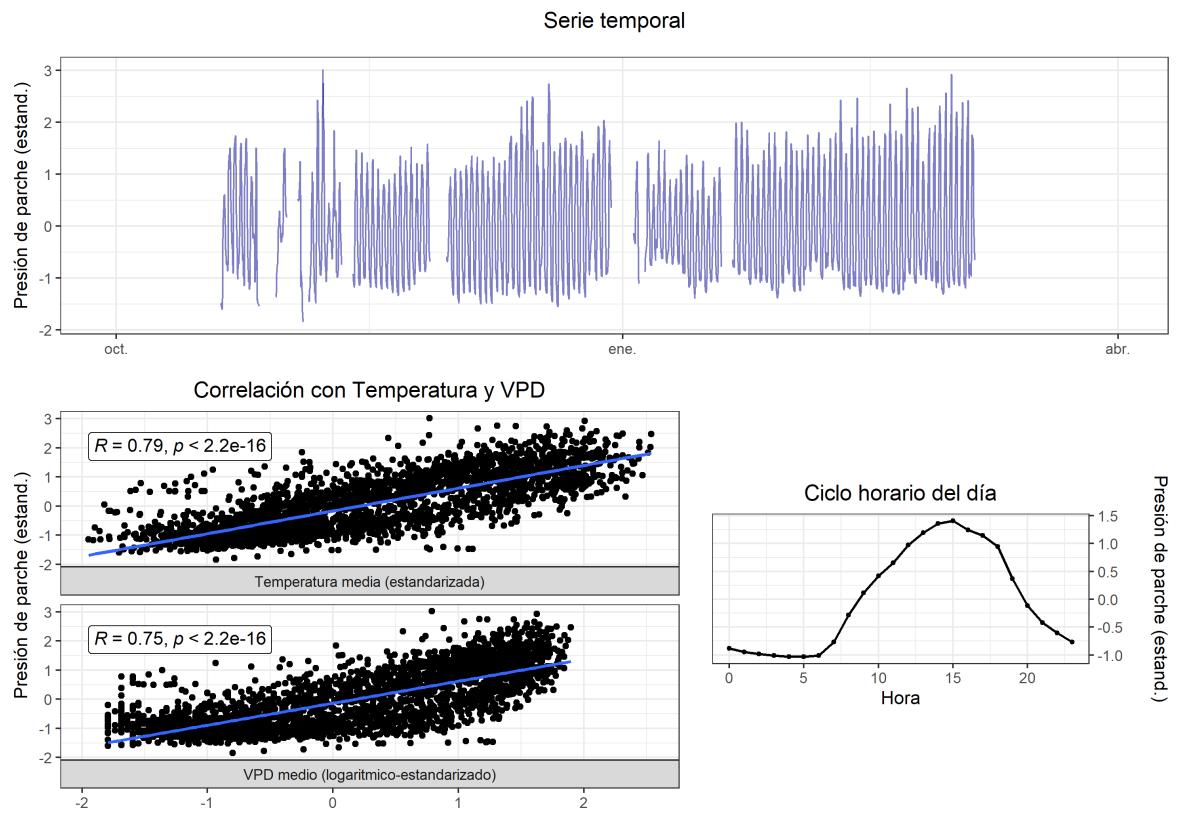
Unidad 3

69 T3 (2022-2023)



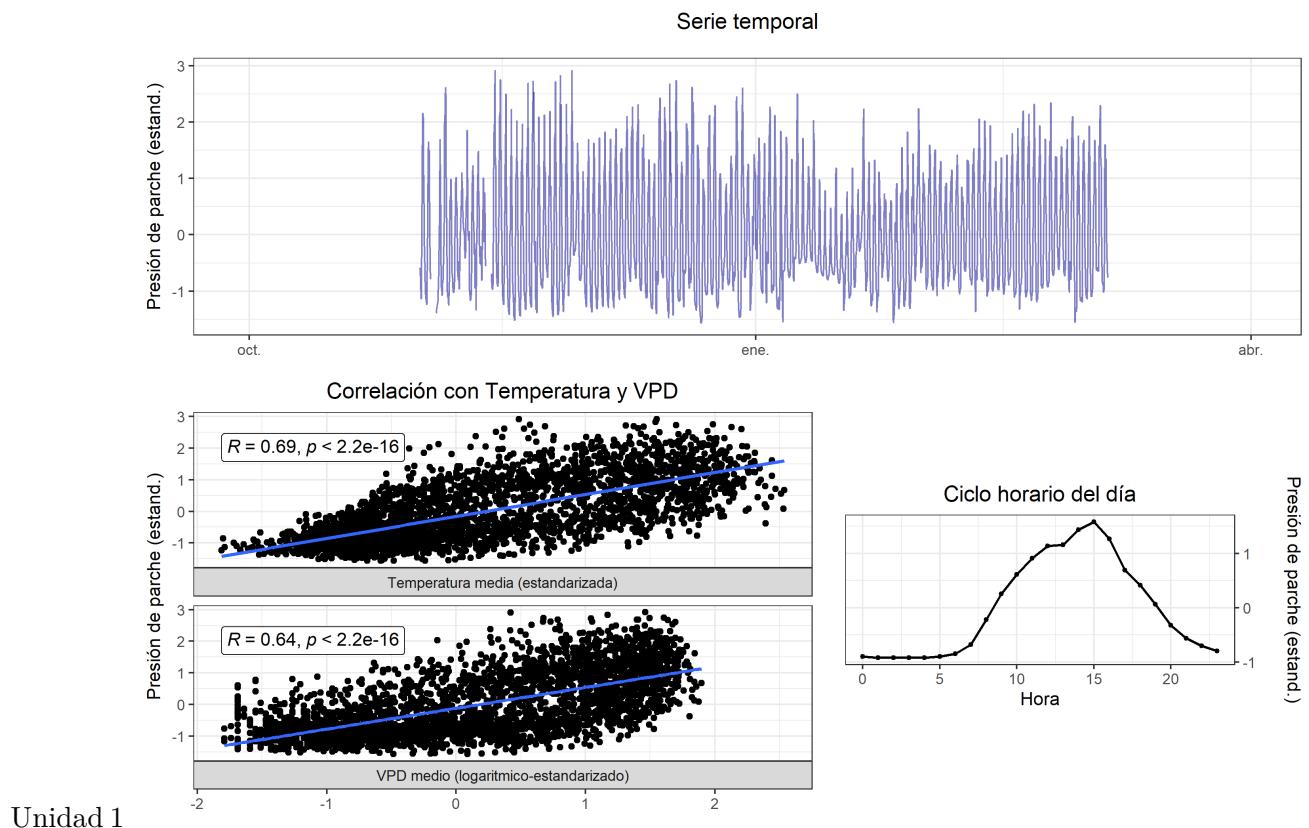


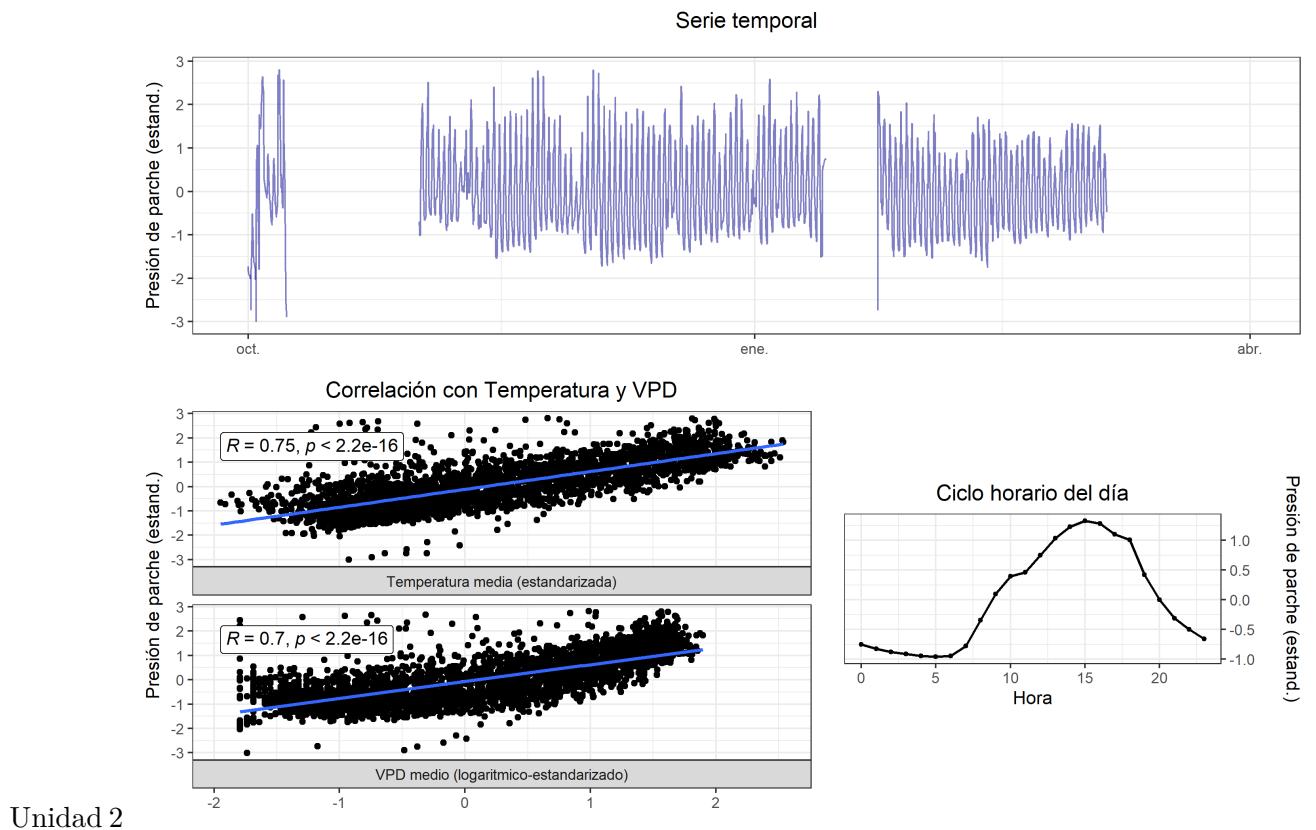
Unidad 2



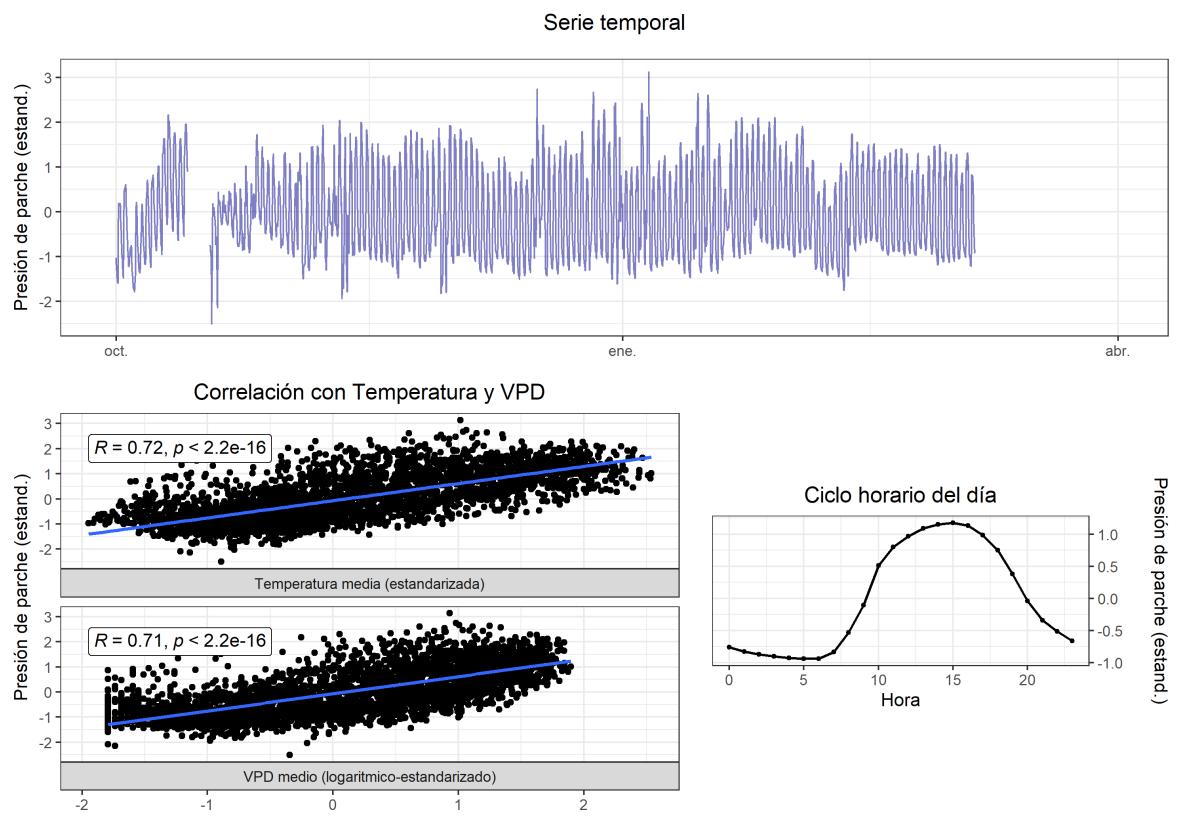
Unidad 3

70 T4 (2022-2023)



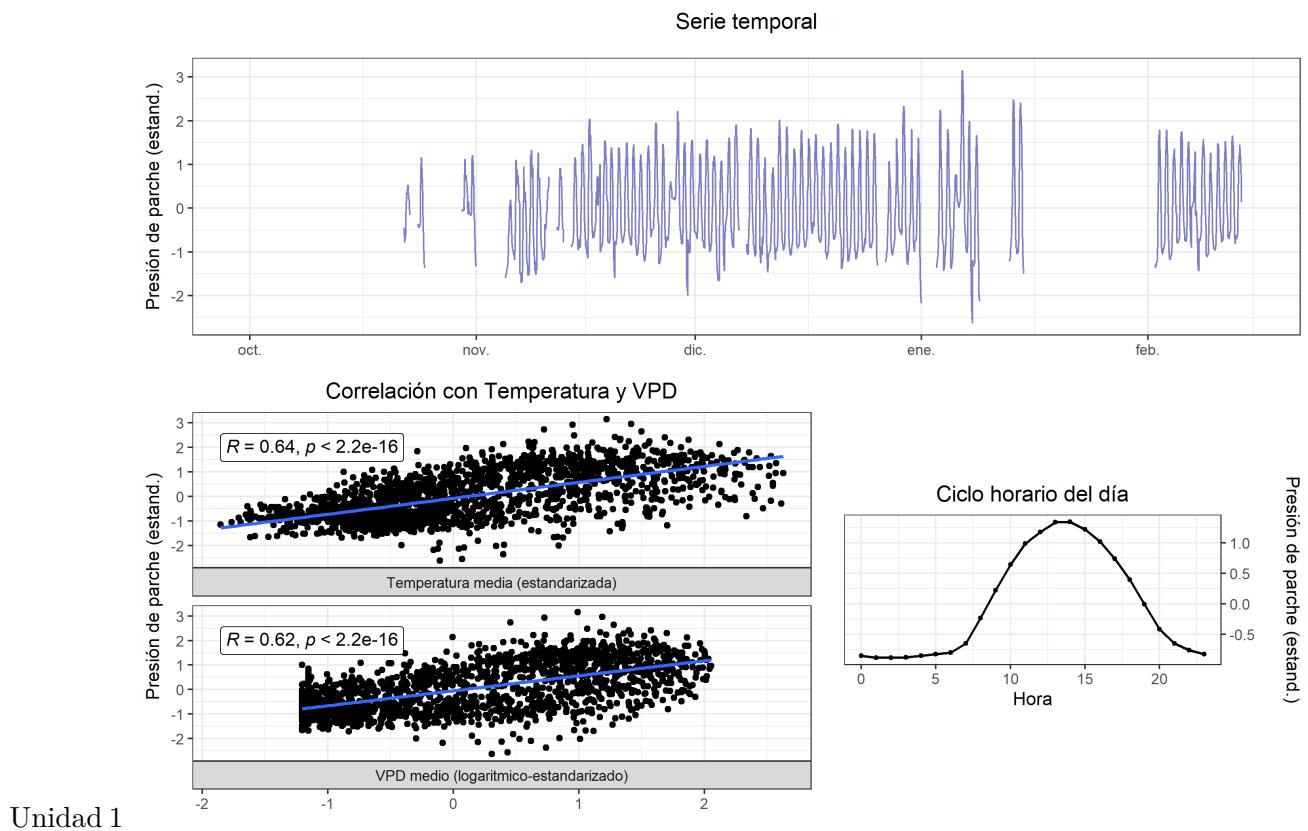


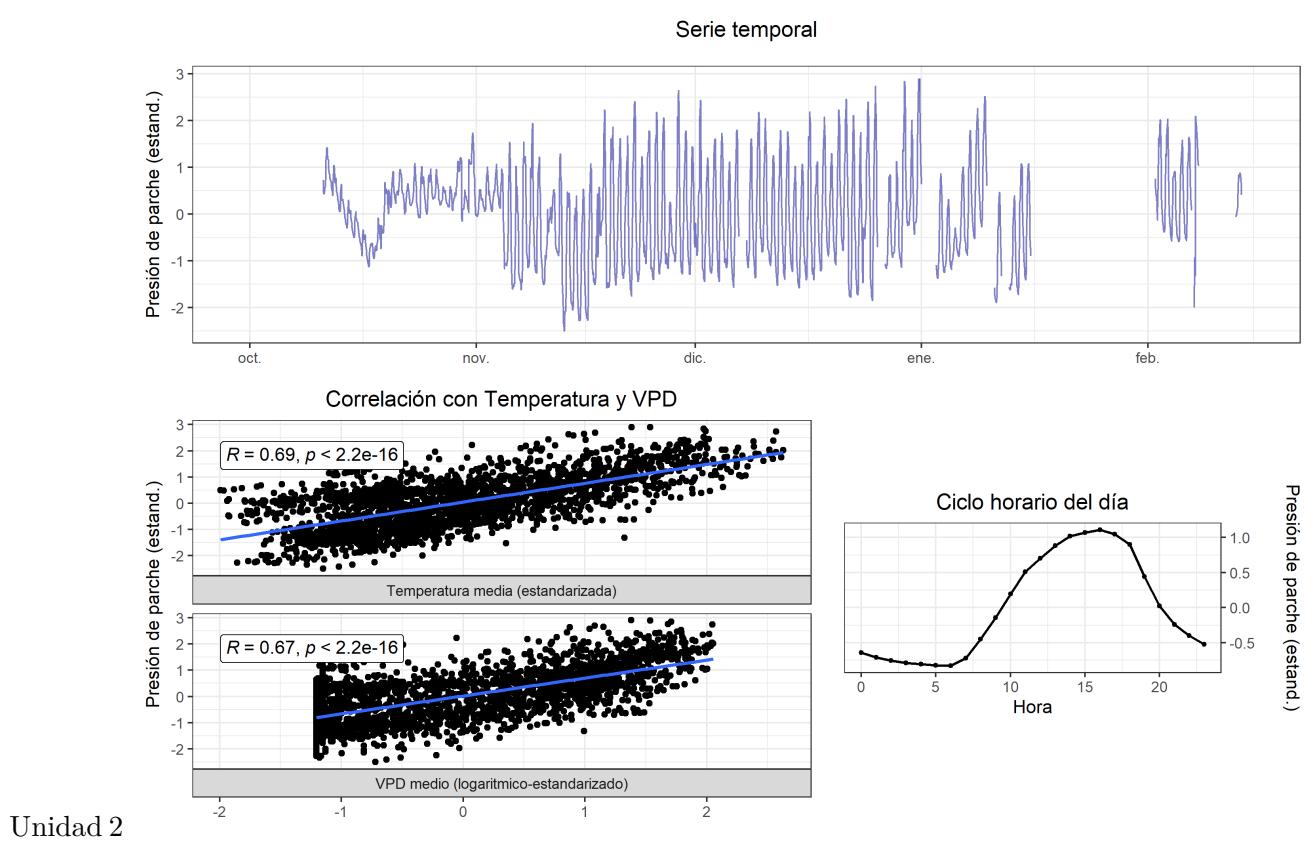
Unidad 2



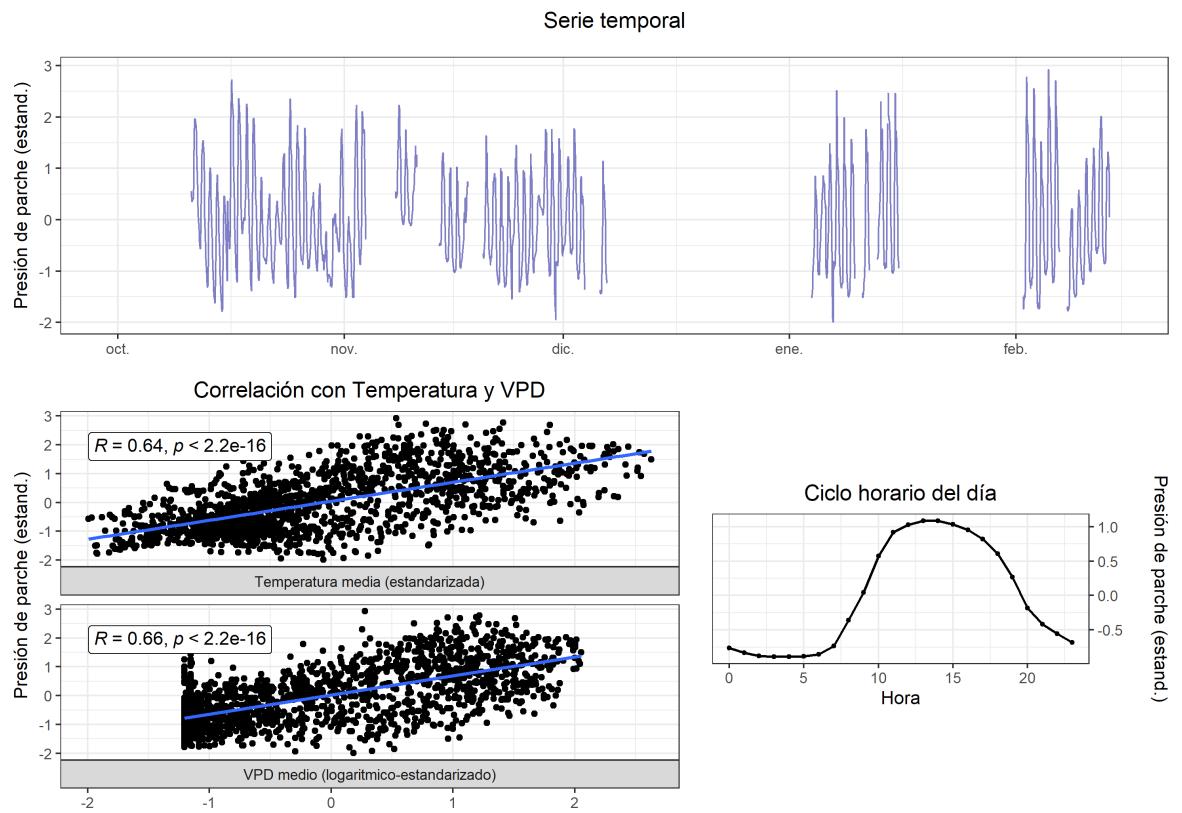
Unidad 3

71 T1 (2023-2024)



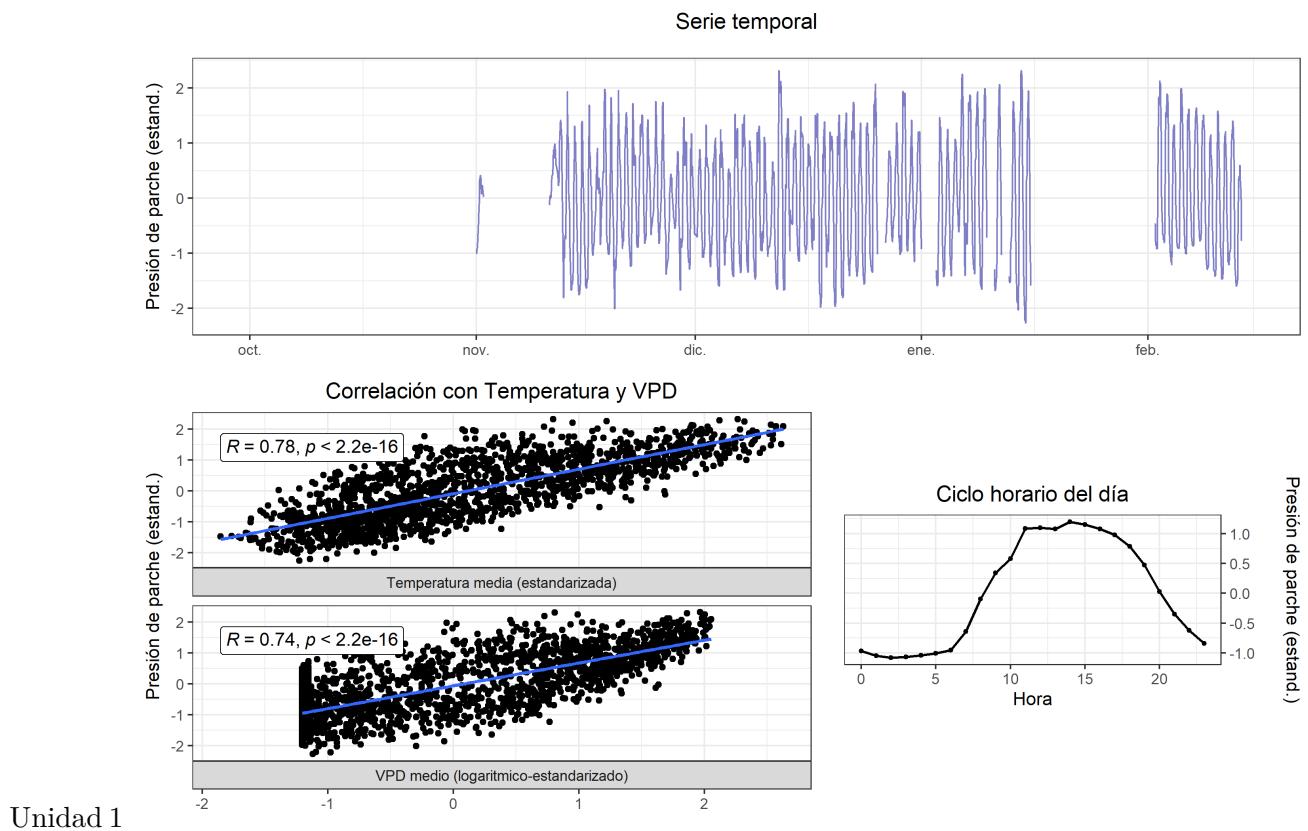


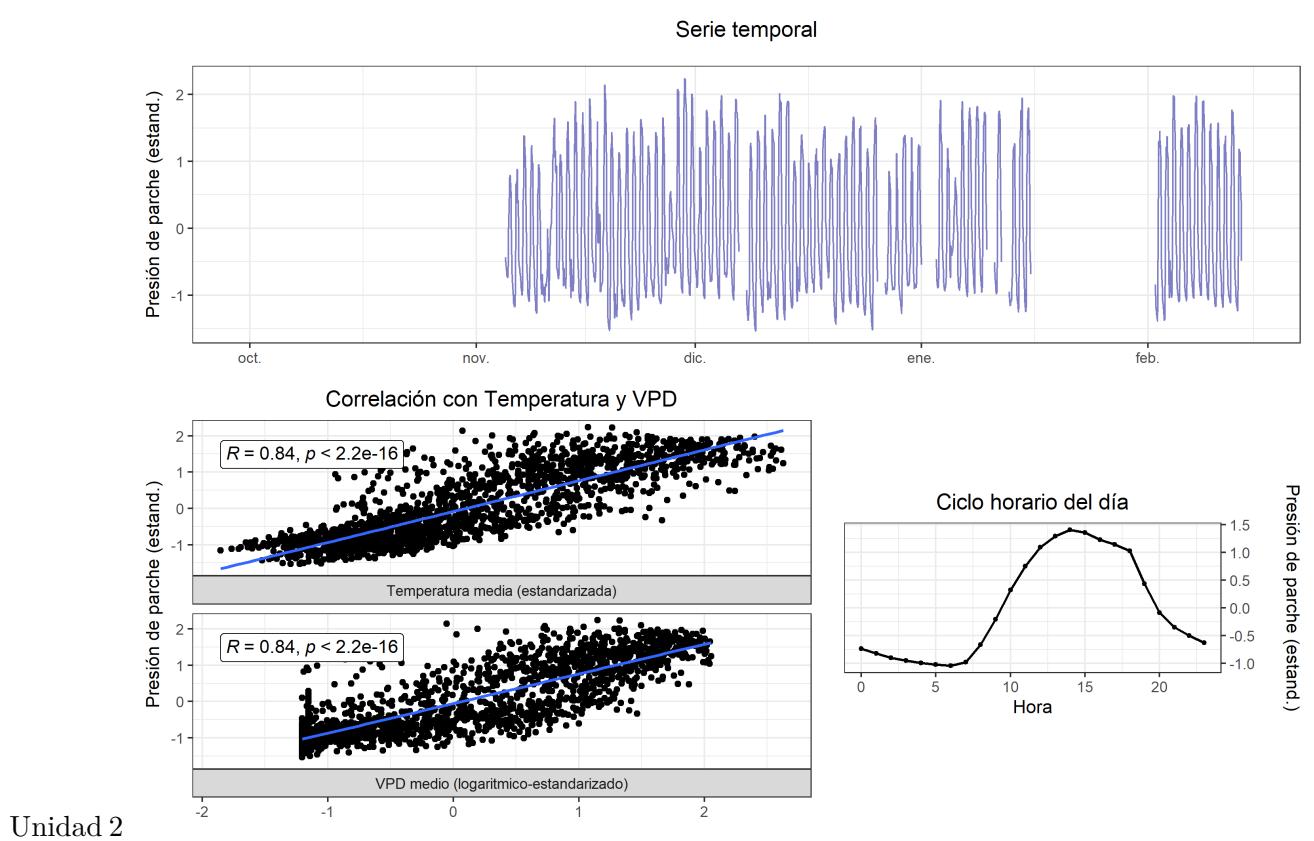
Unidad 2



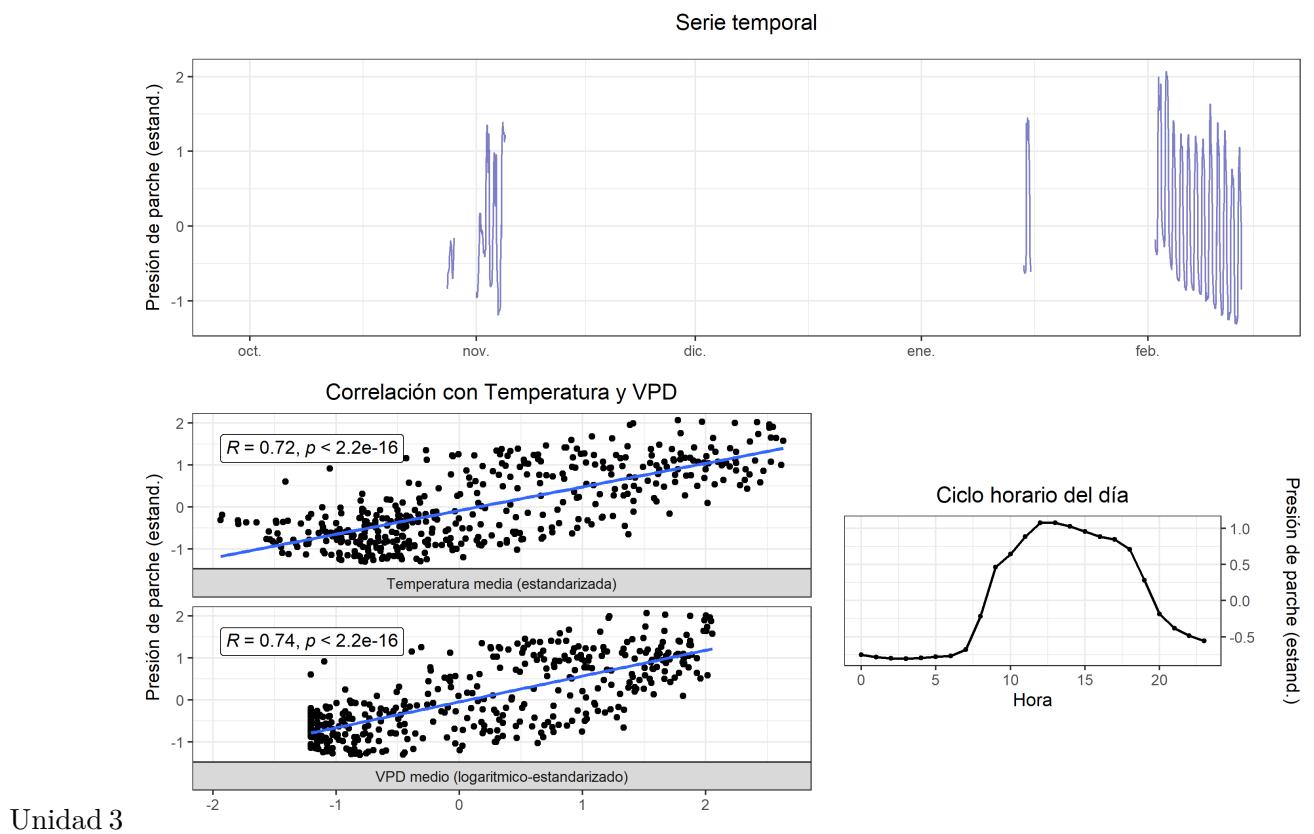
Unidad 3

72 T2 (2023-2024)



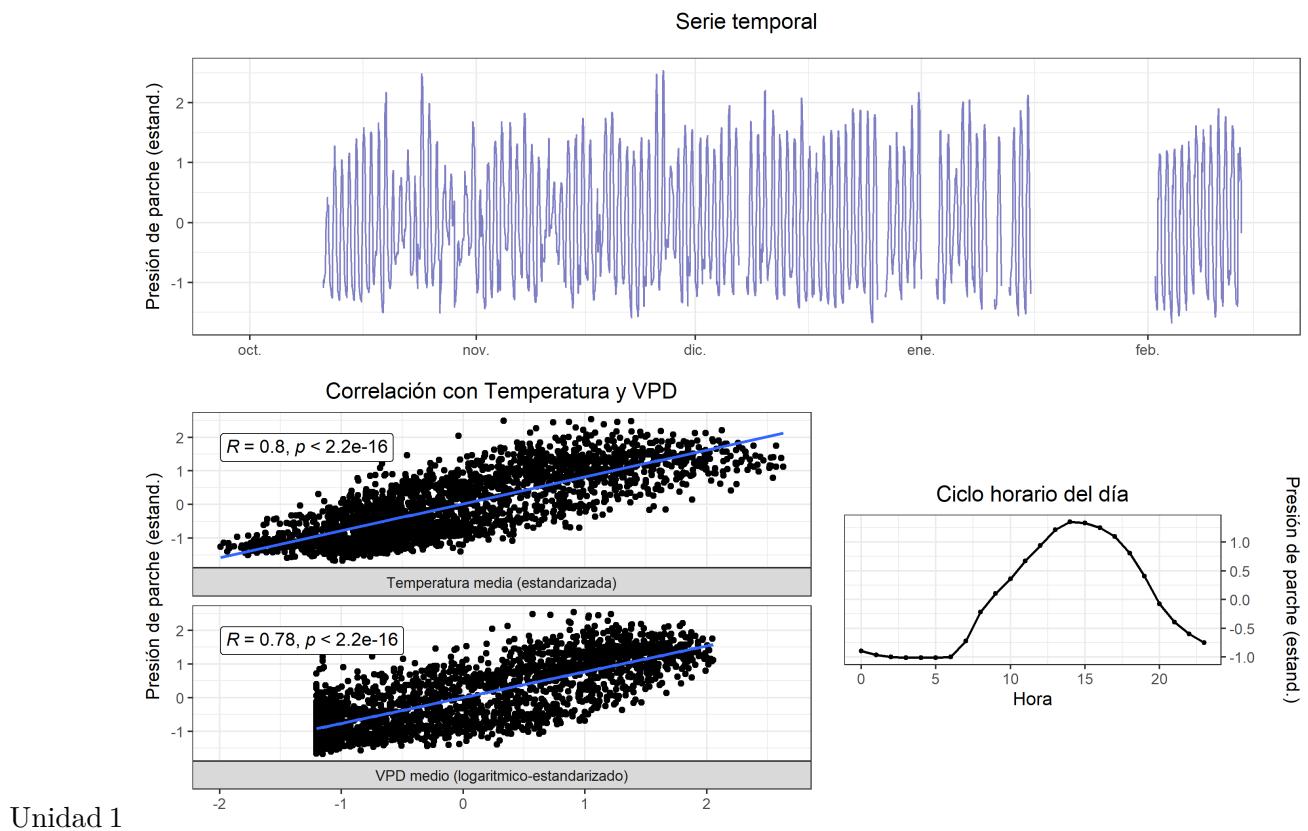


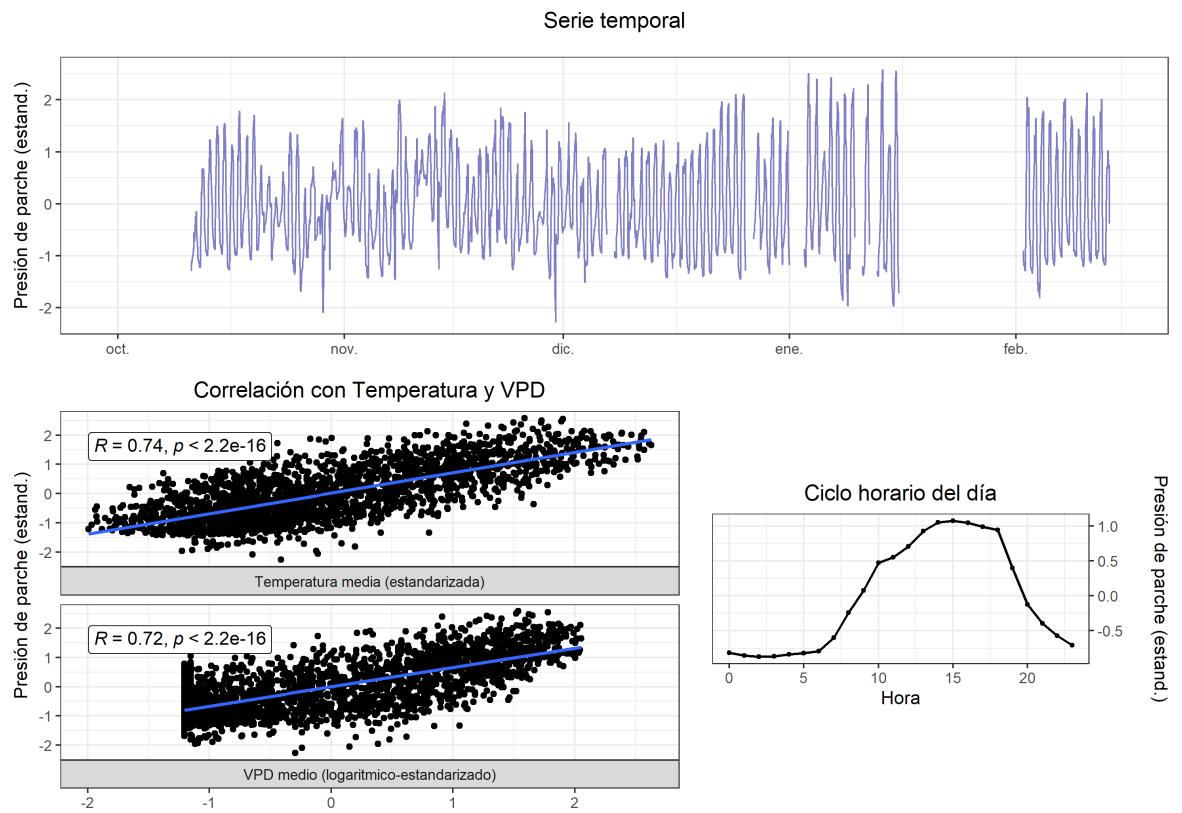
Unidad 2

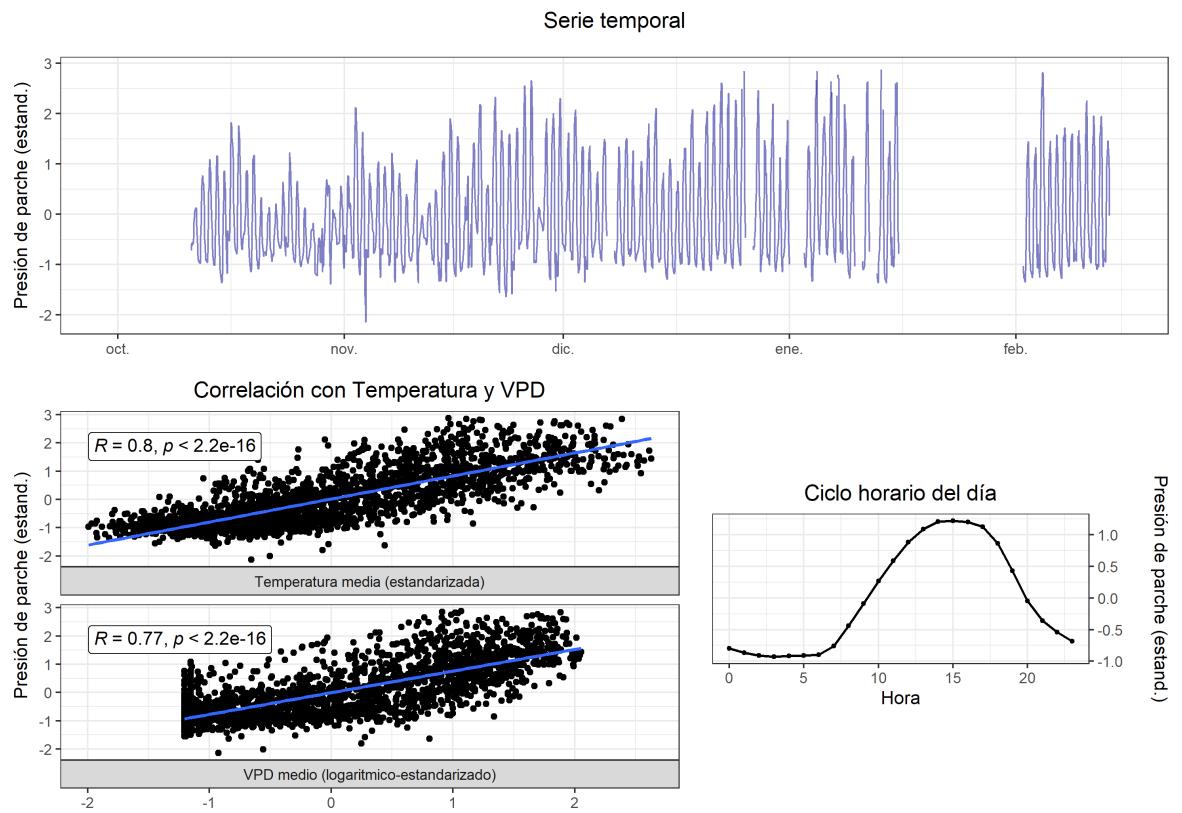


Unidad 3

73 T3 (2023-2024)

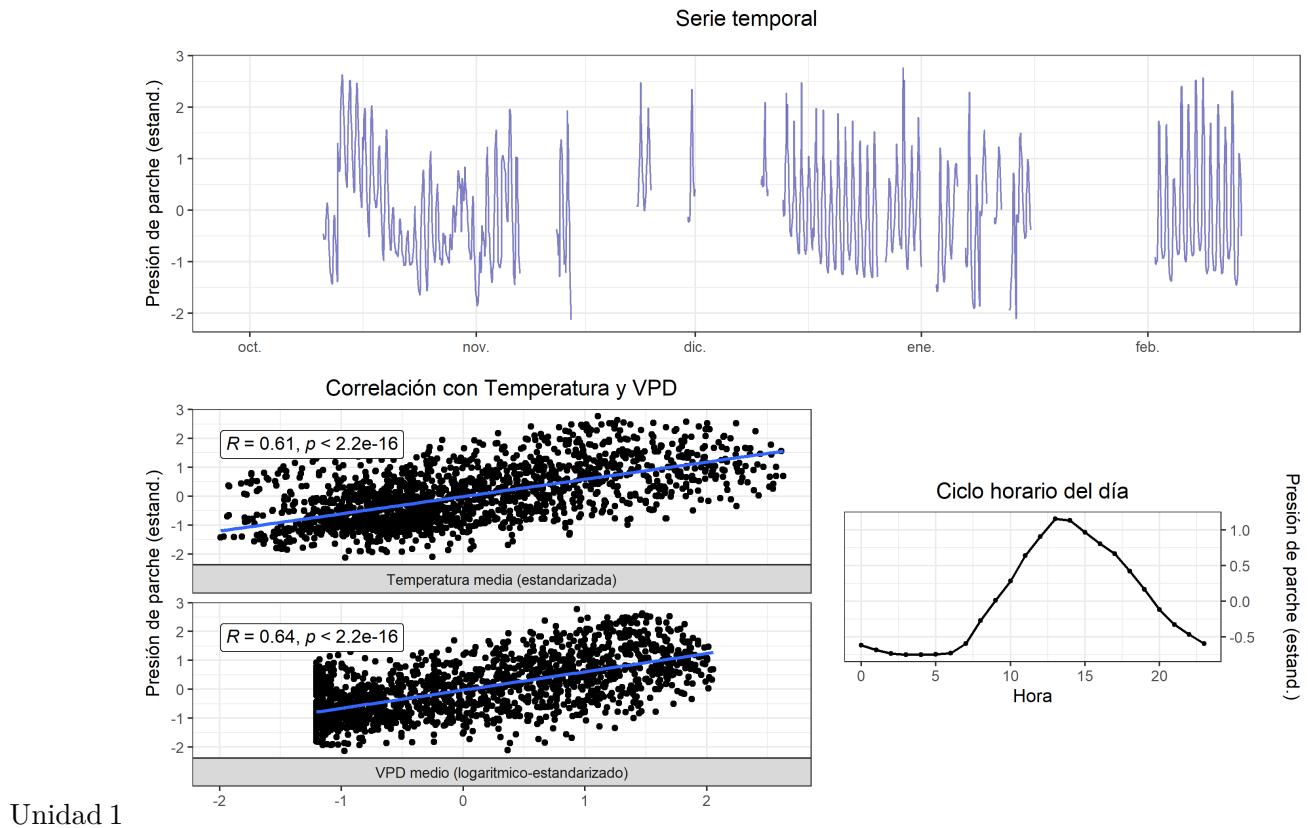




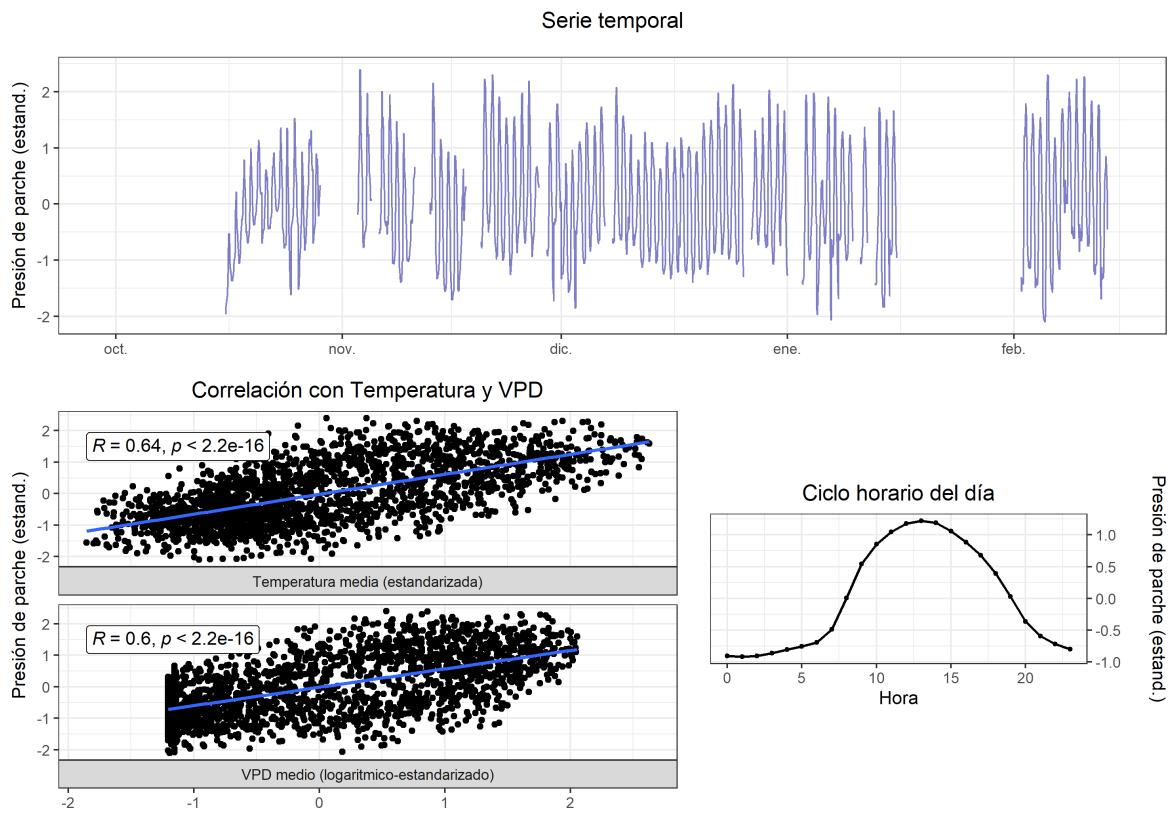


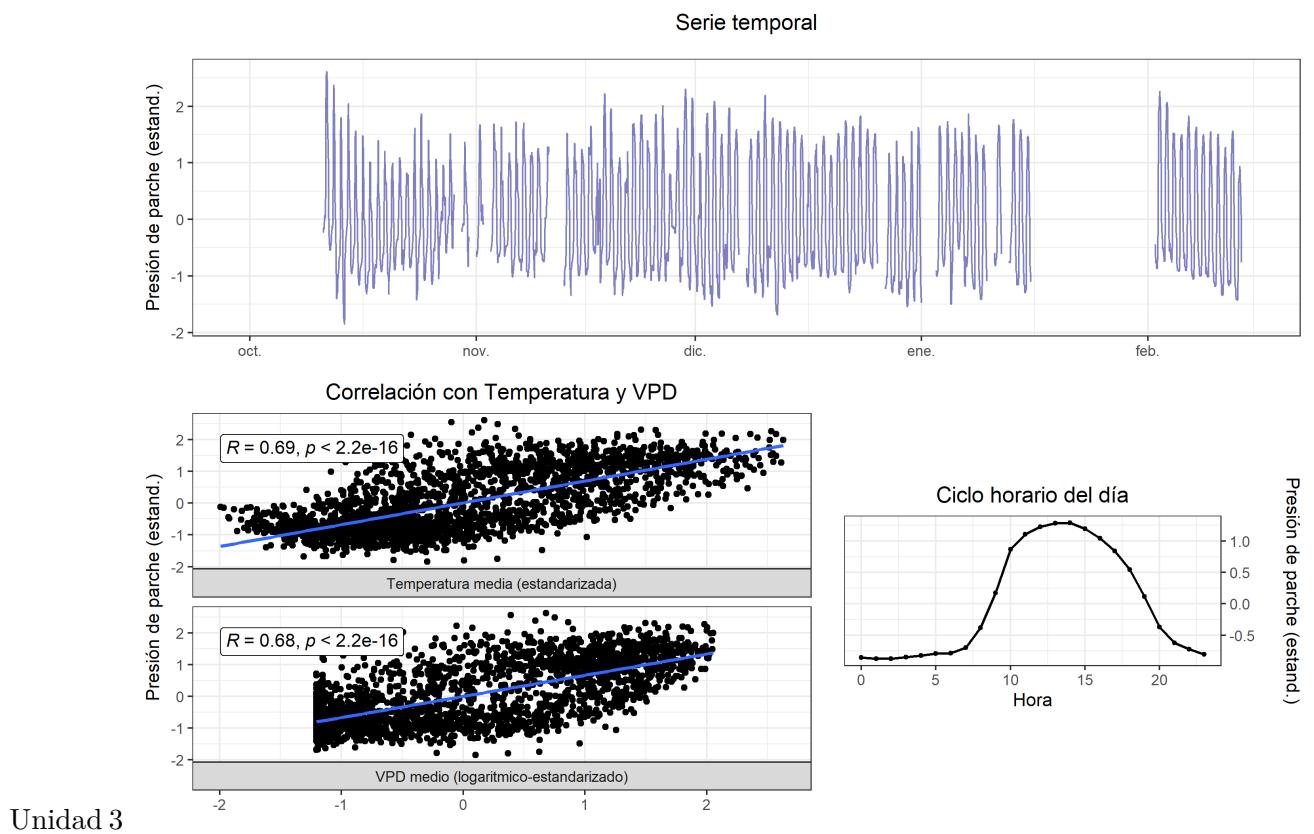
Unidad 3

74 T4 (2023-2024)



Unidad 2

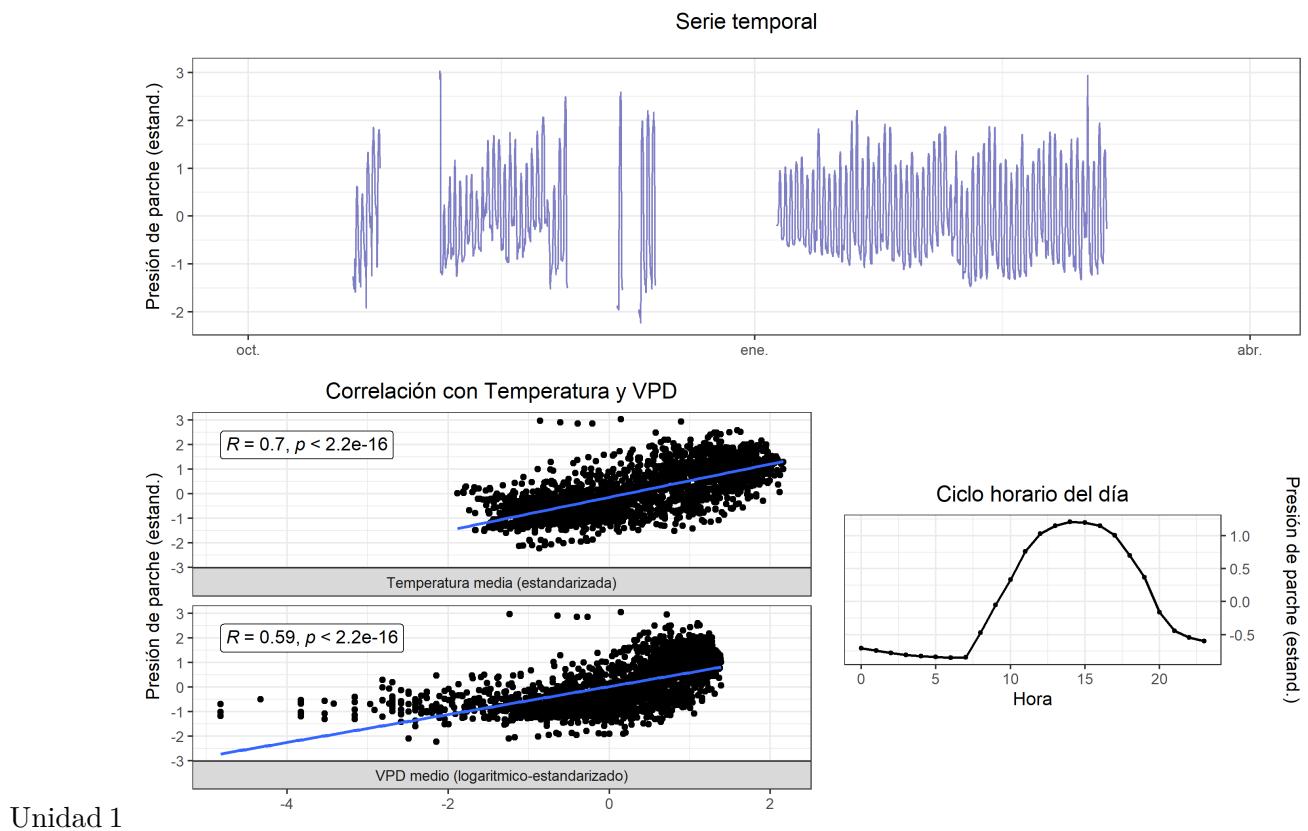


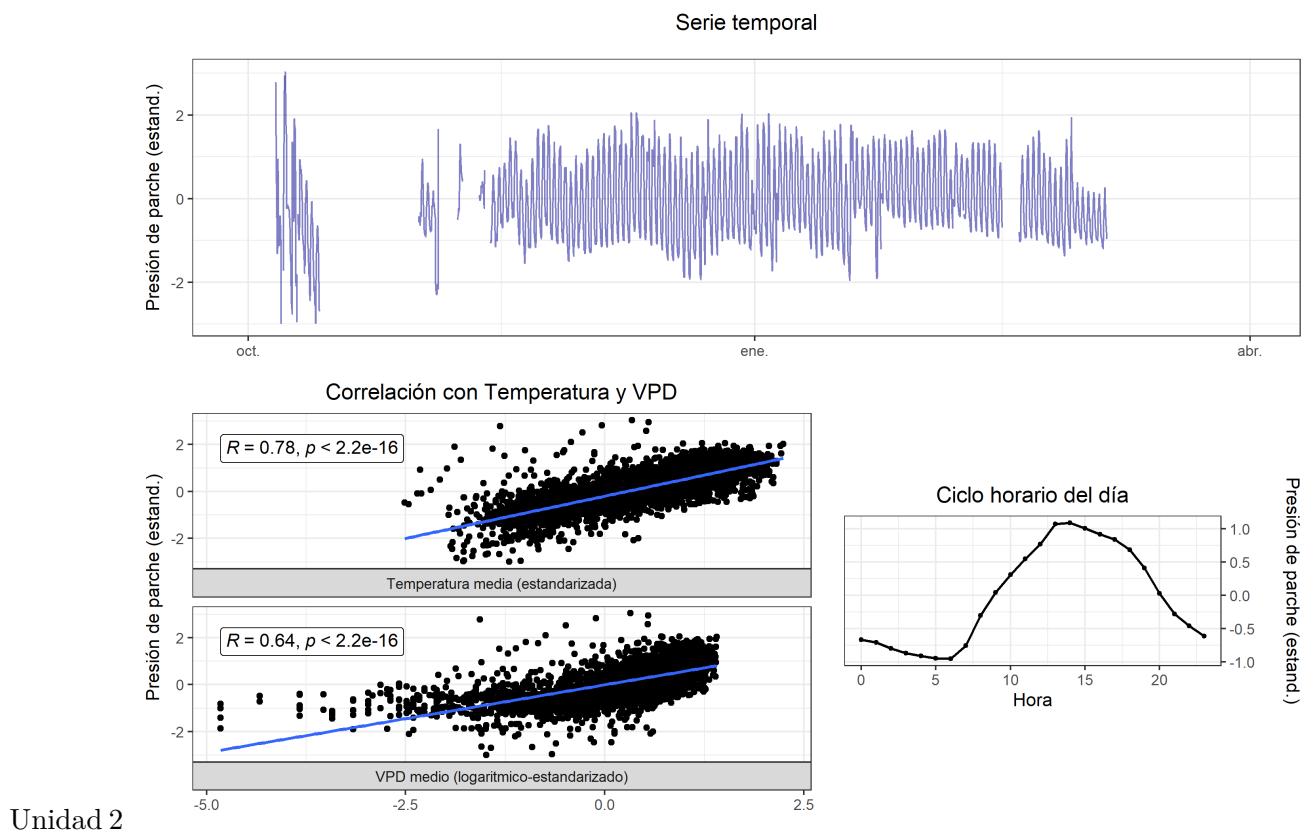


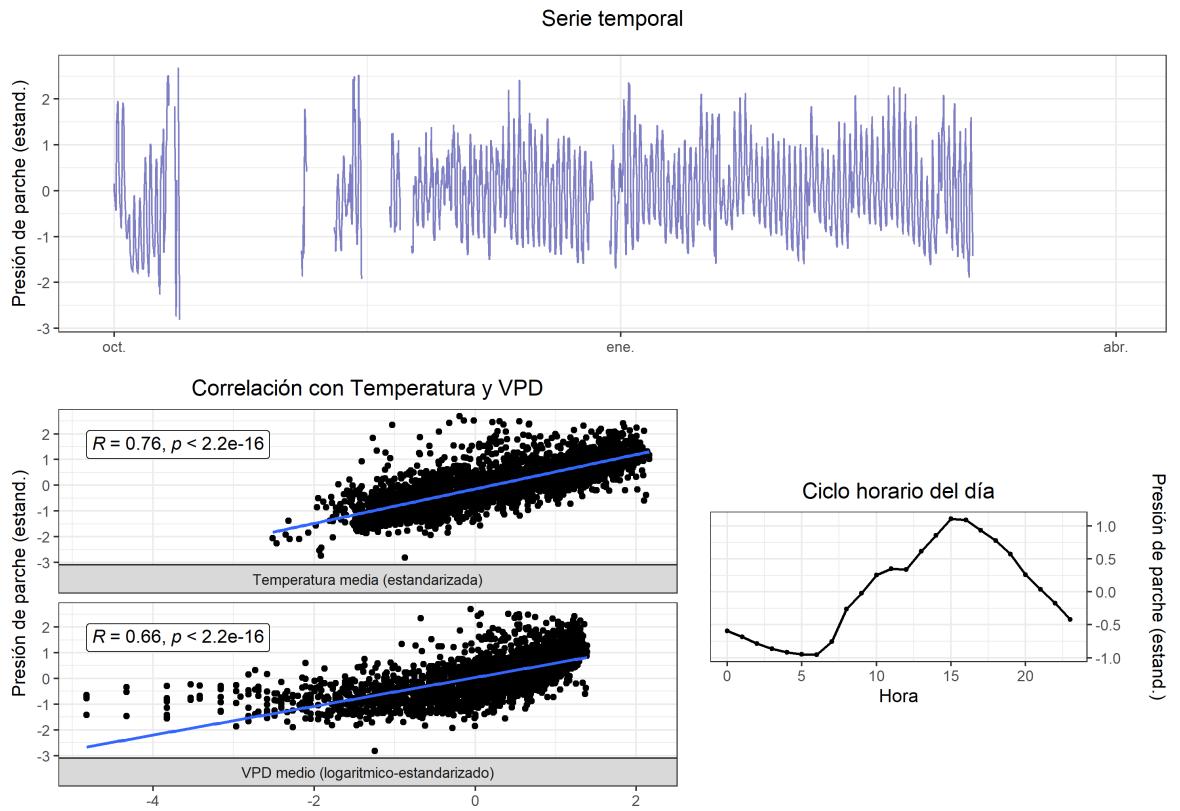
Unidad 3

74.0.1 Rio Claro

75 T1 (2022-2023)

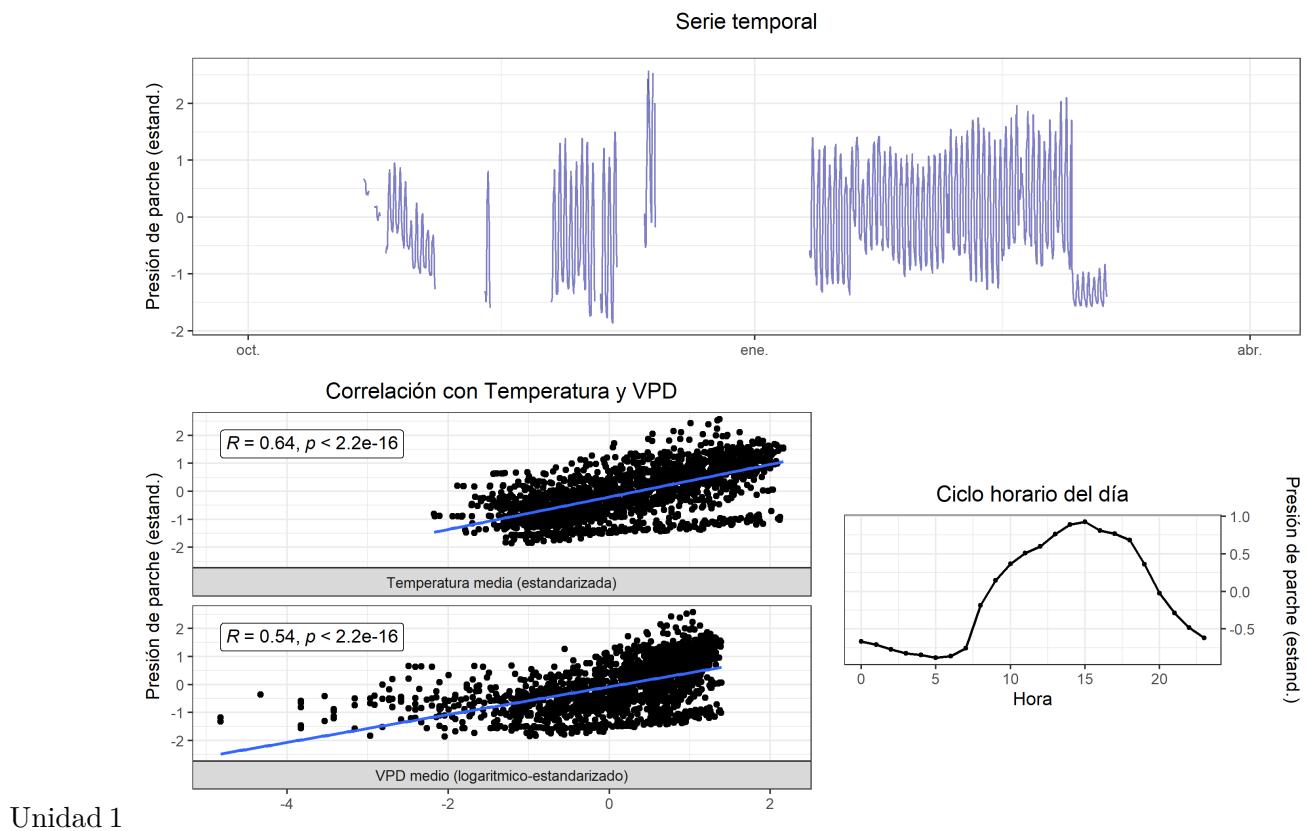


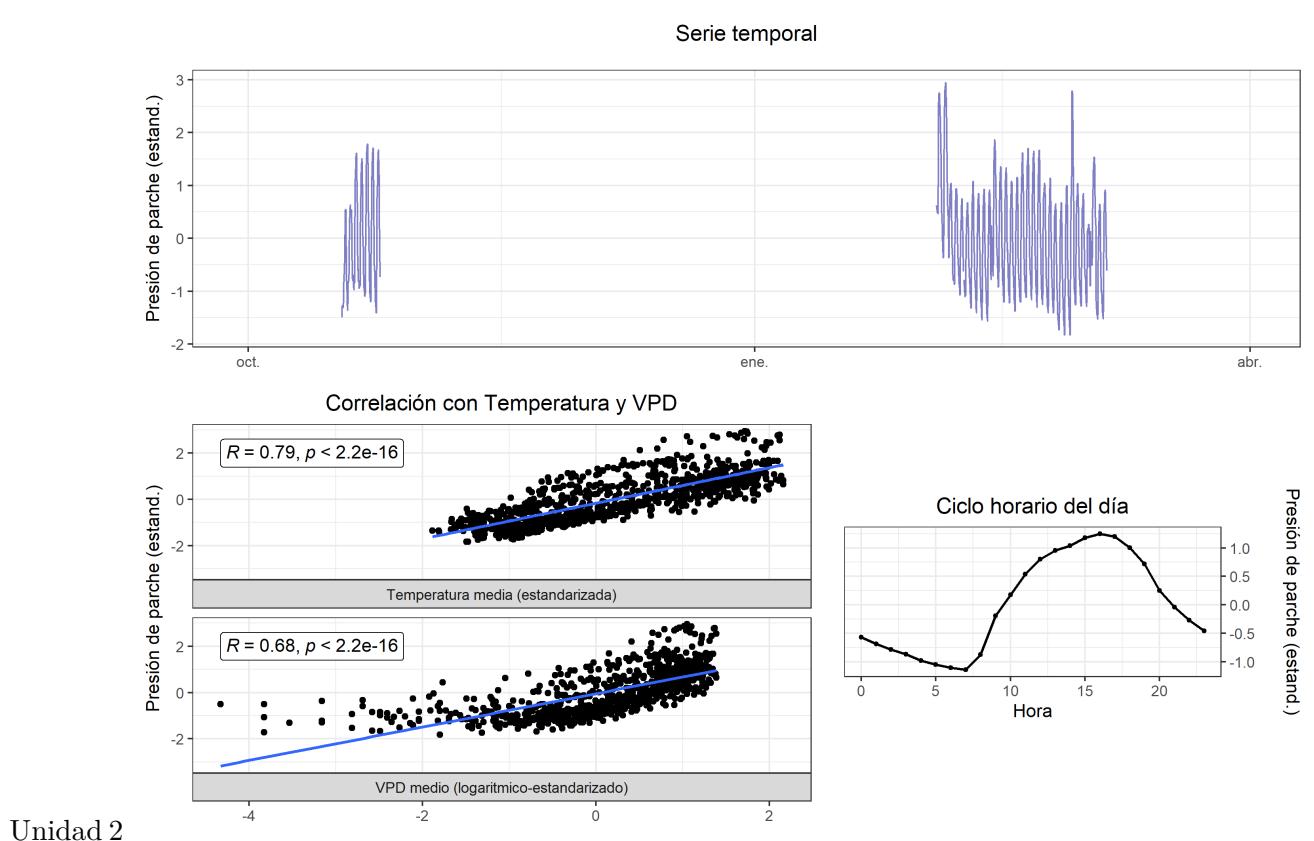


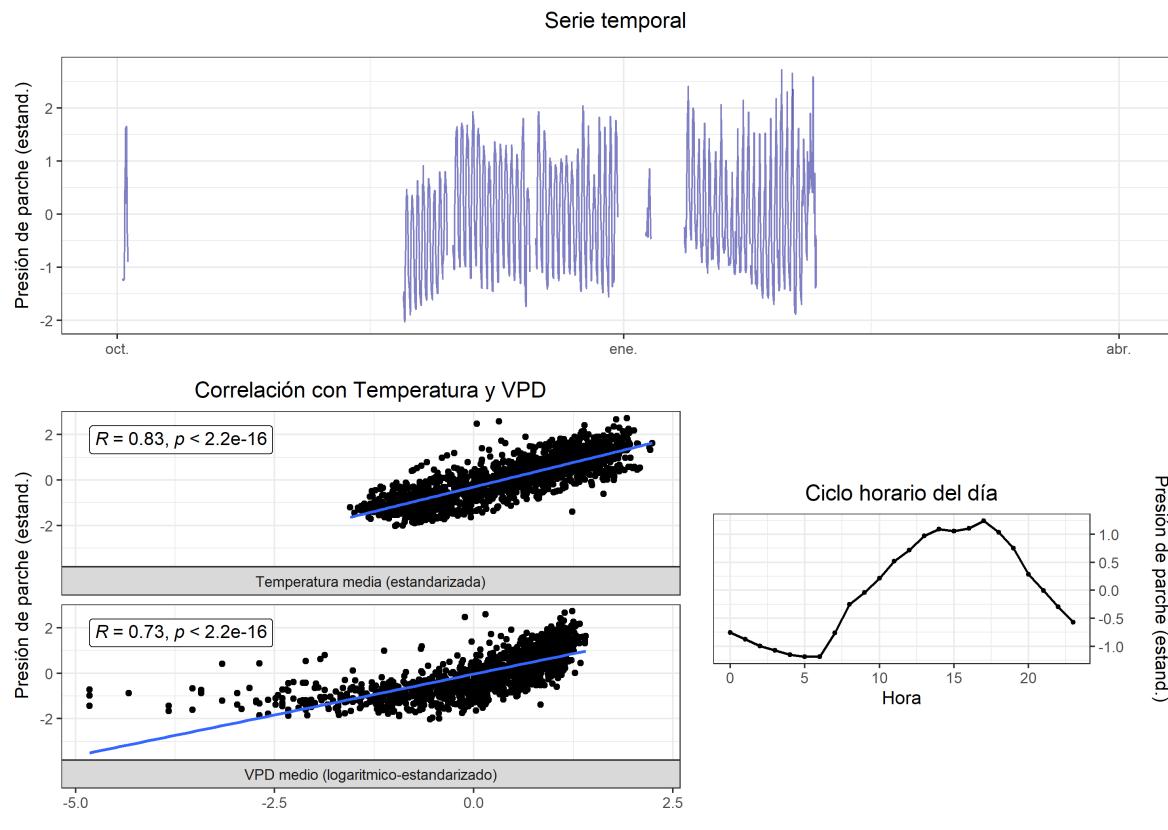


Unidad 3

76 T2 (2022-2023)

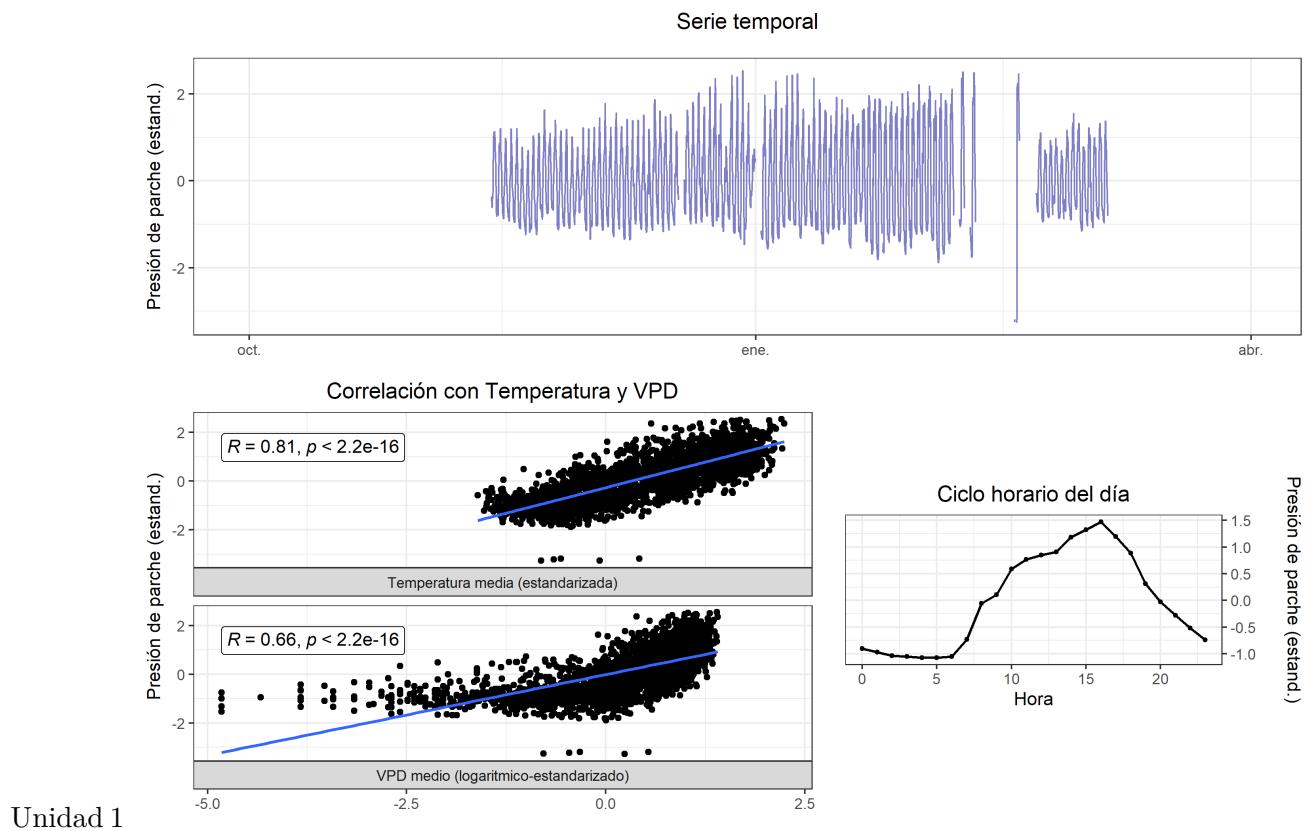


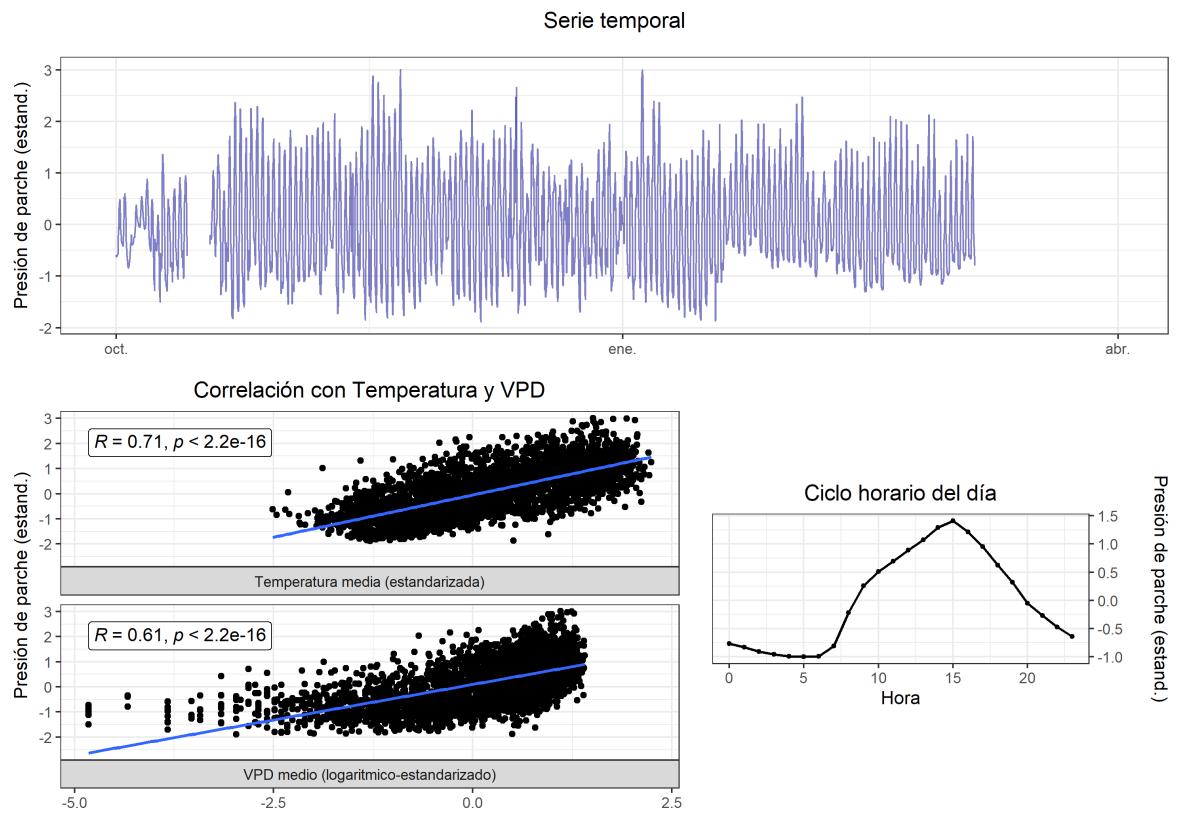


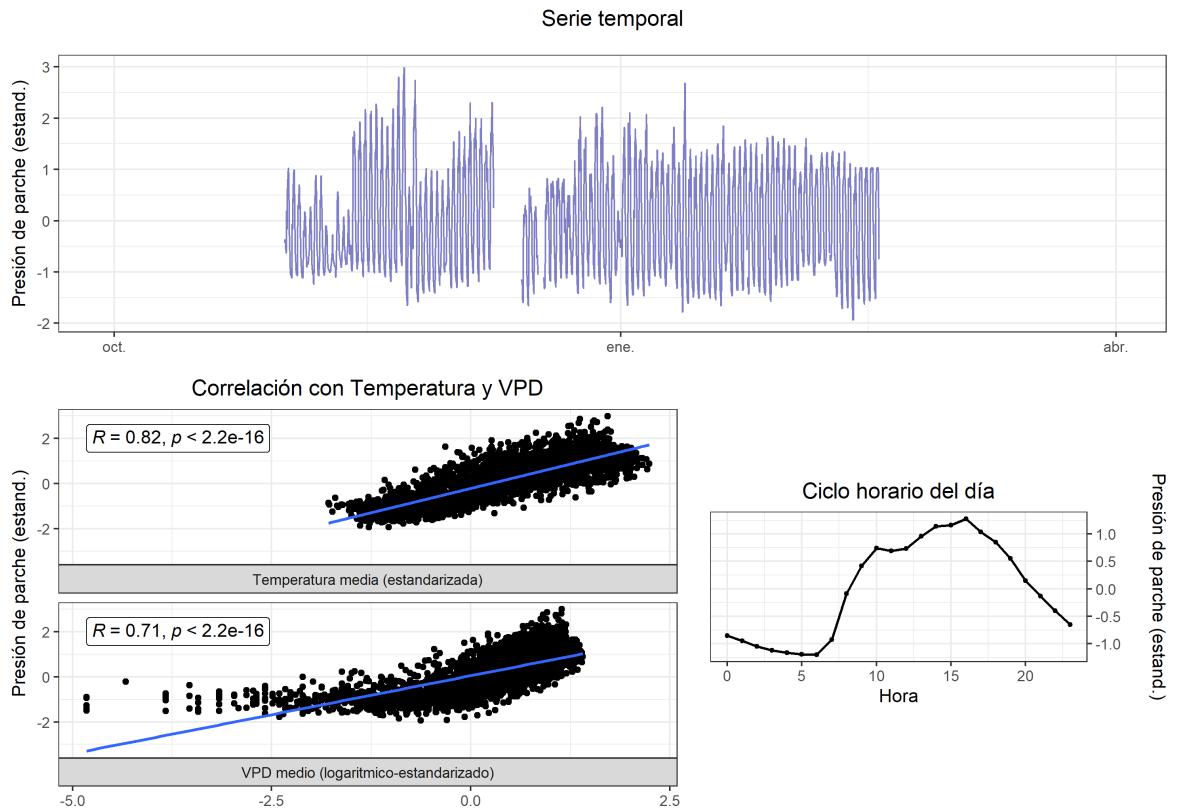


Unidad 3

77 T3 (2022-2023)

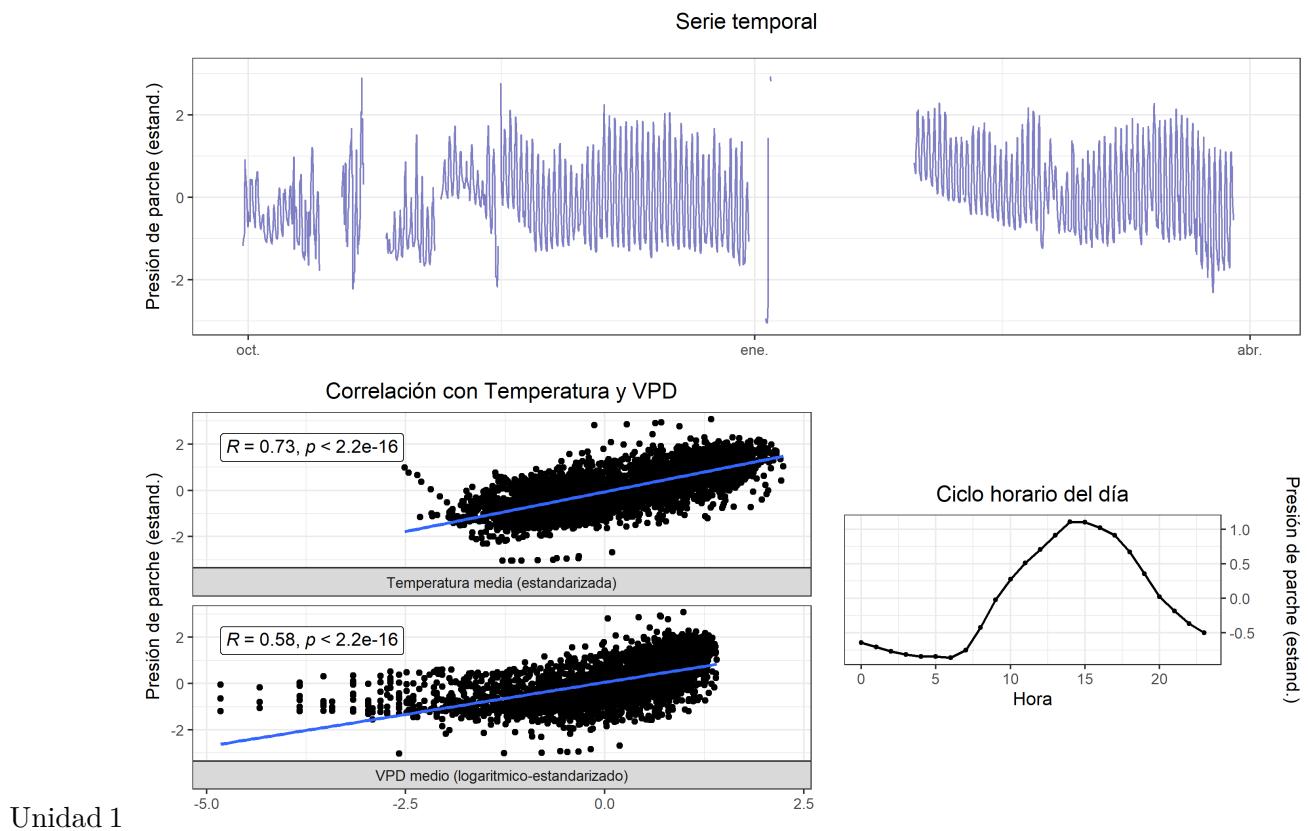


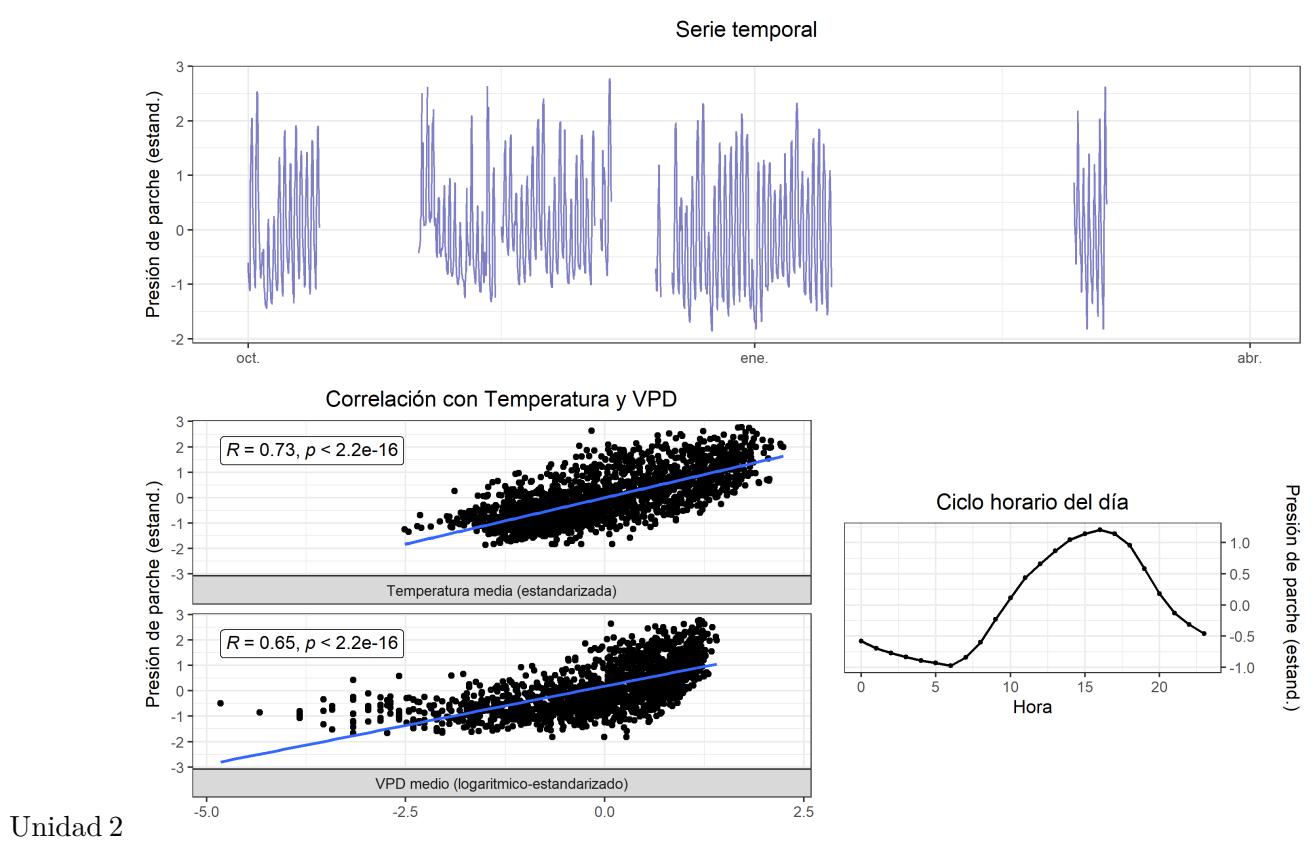


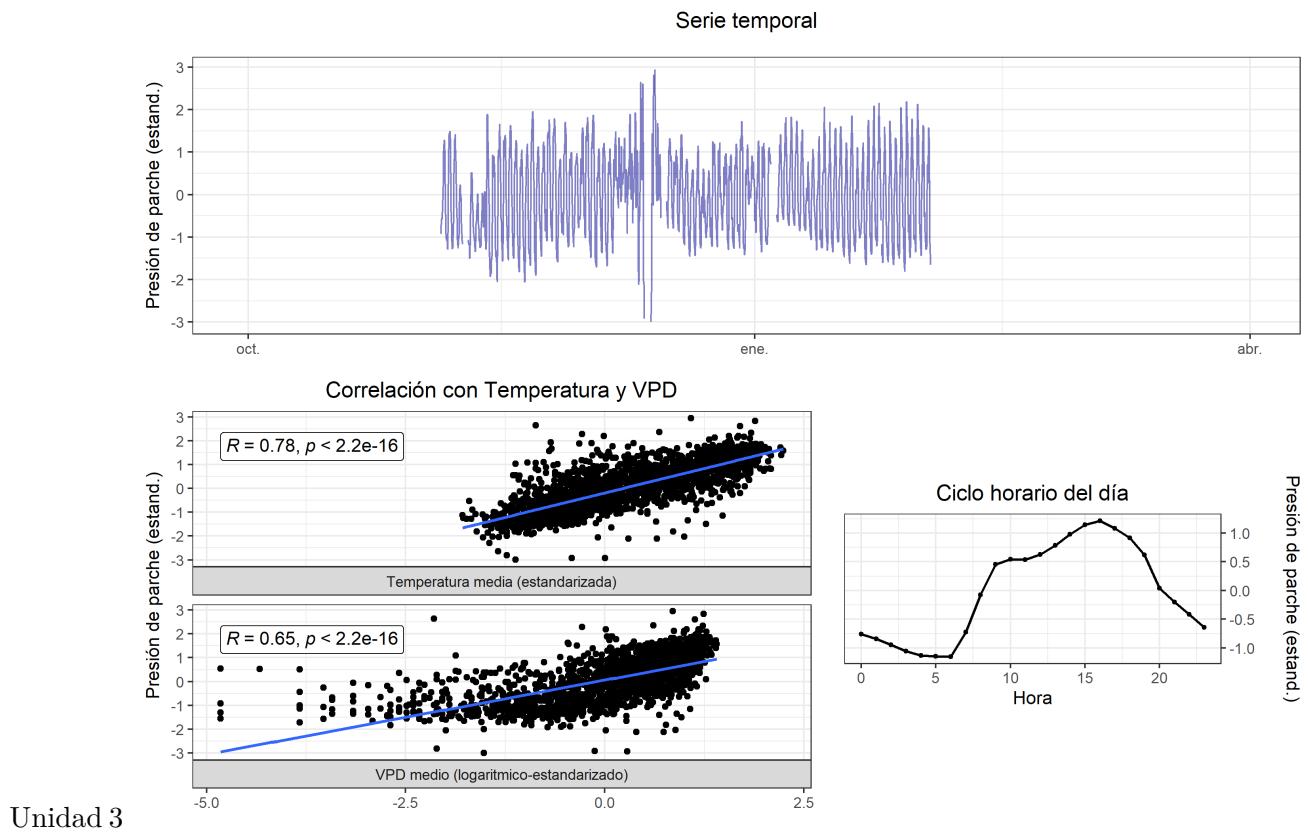


Unidad 3

78 T4 (2022-2023)

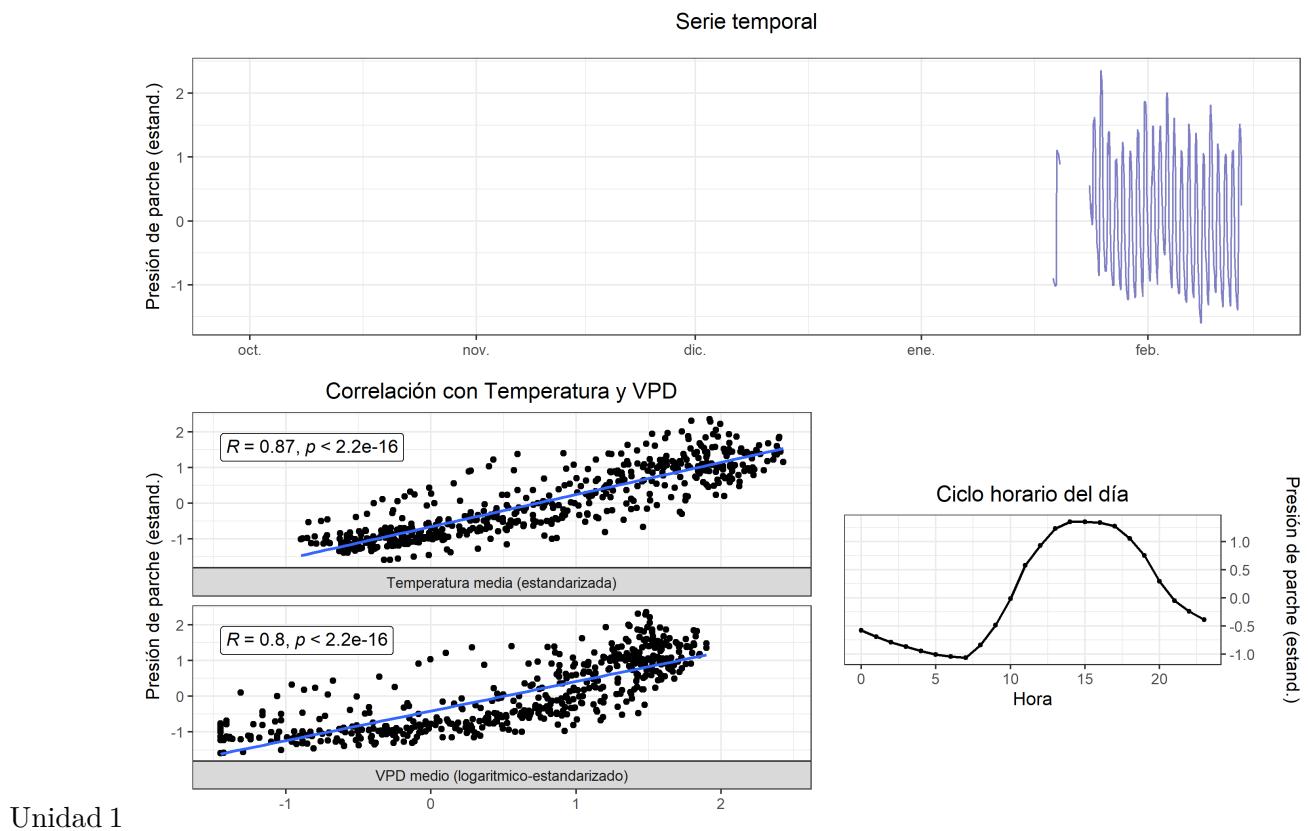


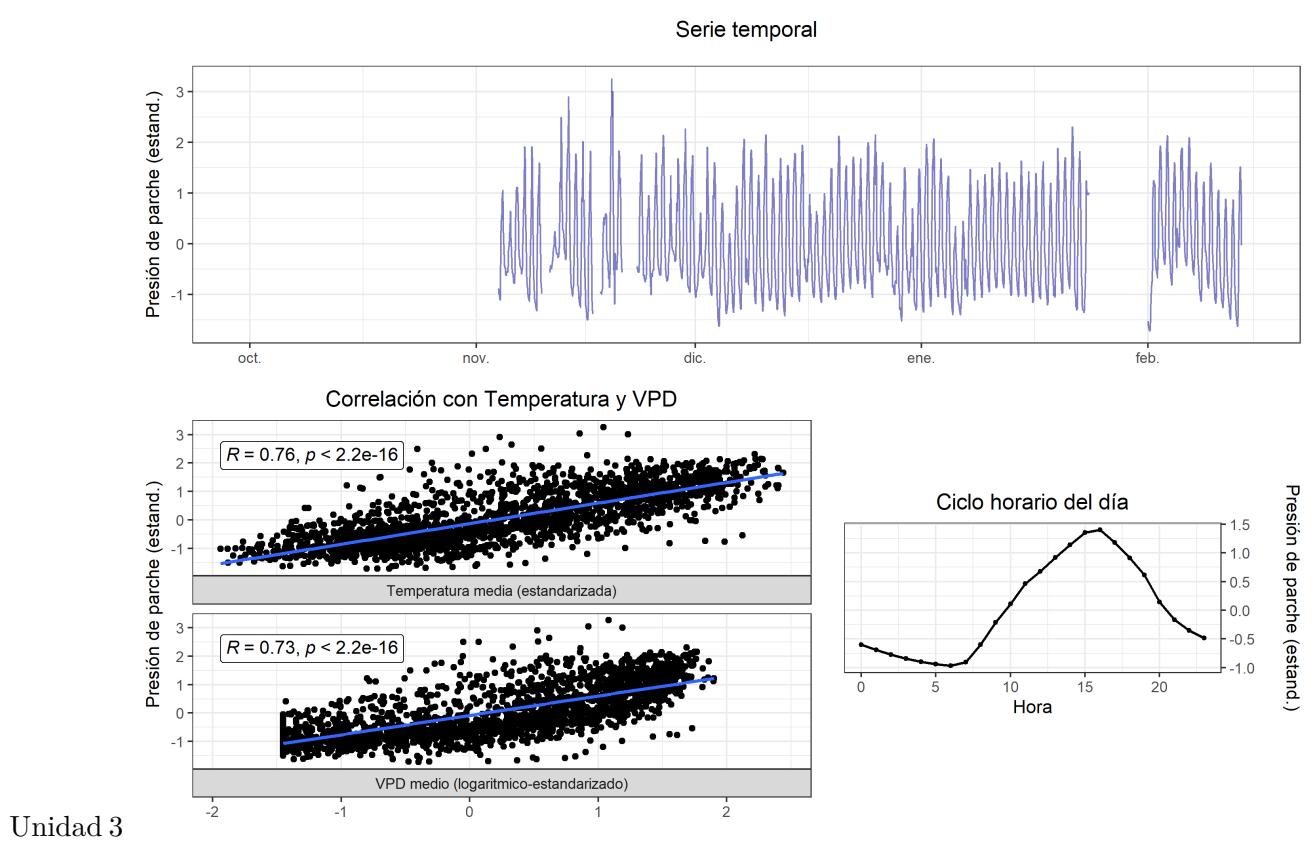




Unidad 3

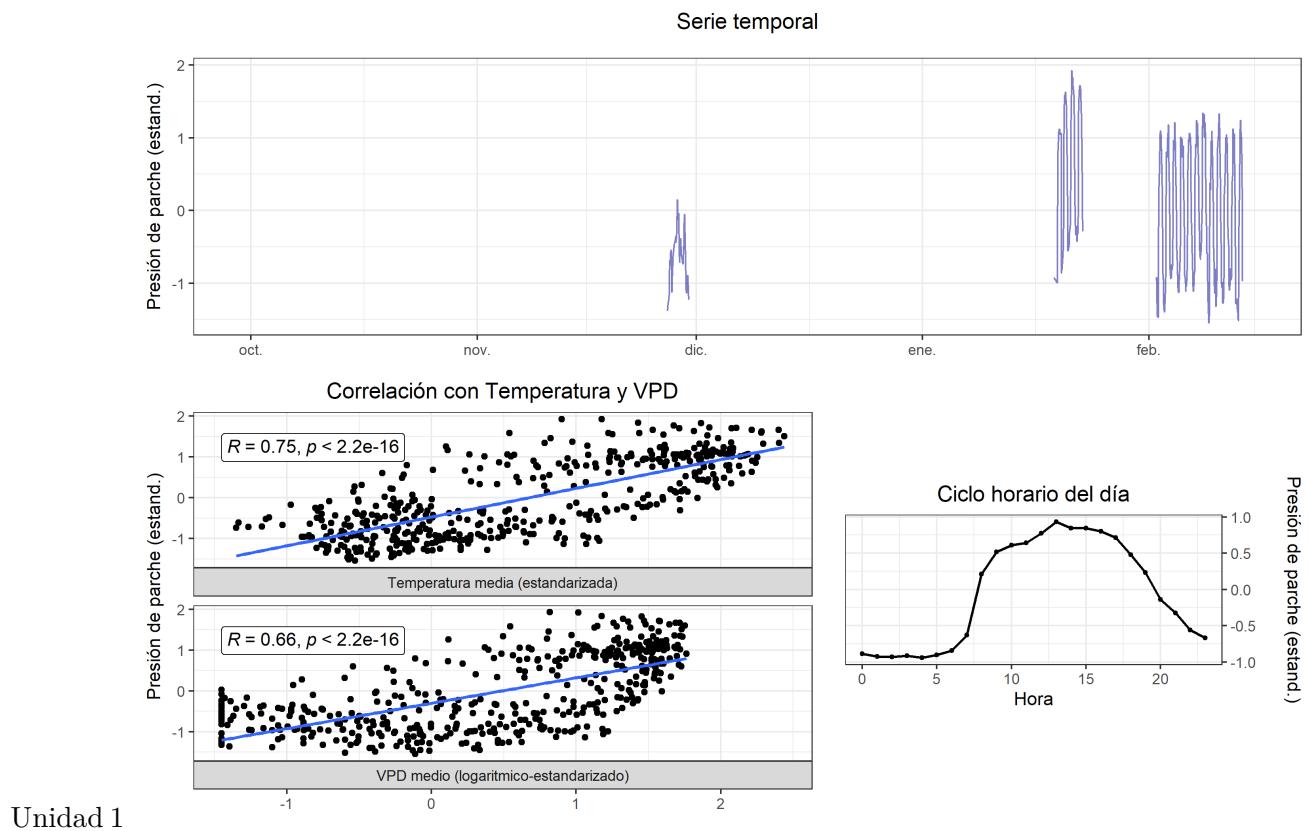
79 T1 (2023-2024)

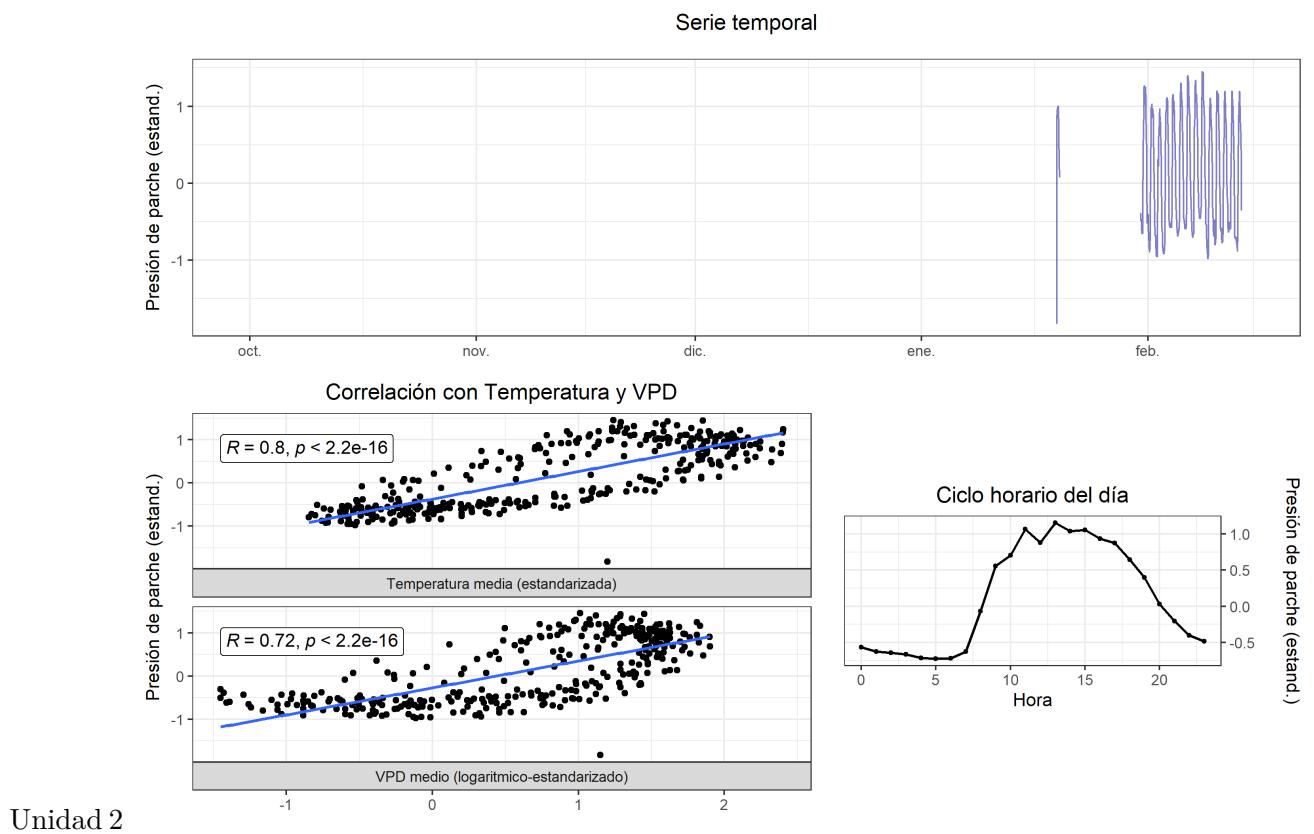




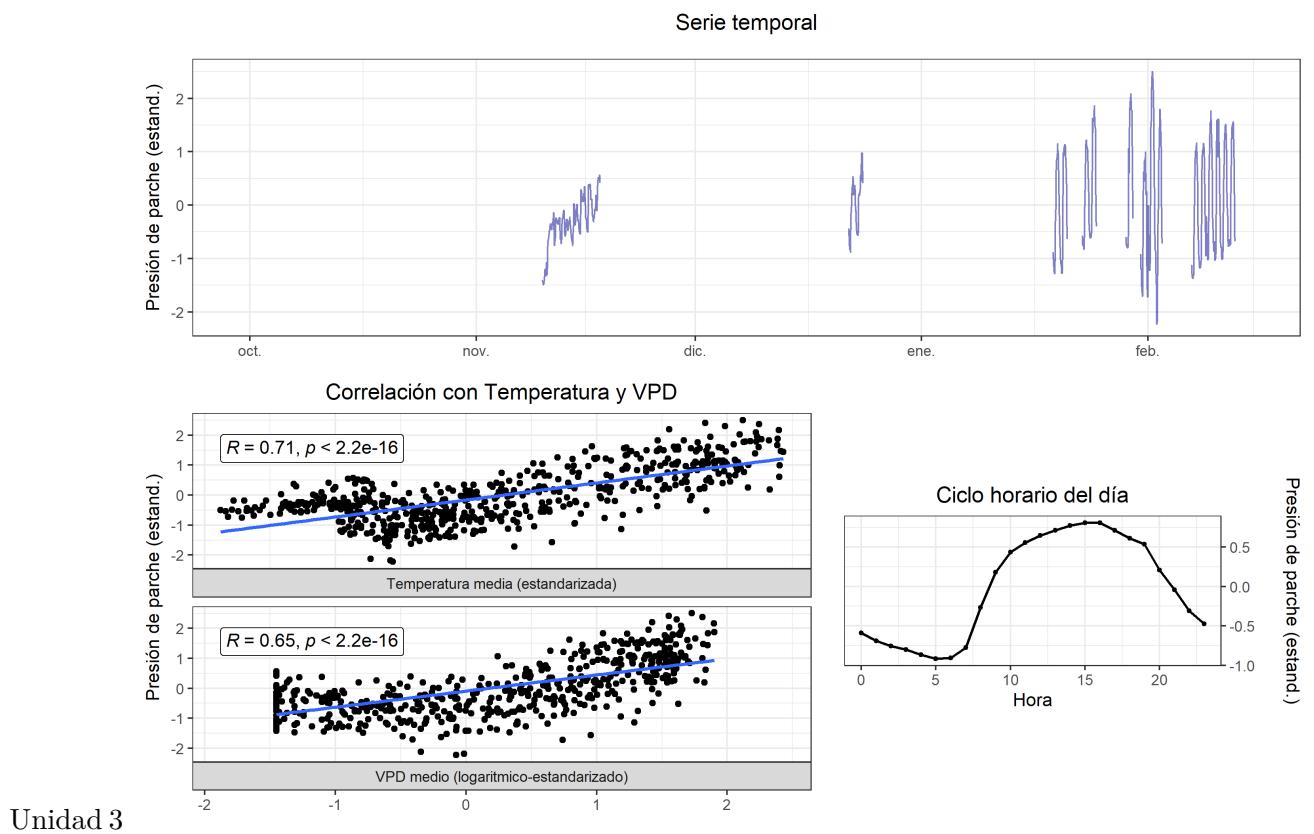
Unidad 3

80 T2 (2023-2024)

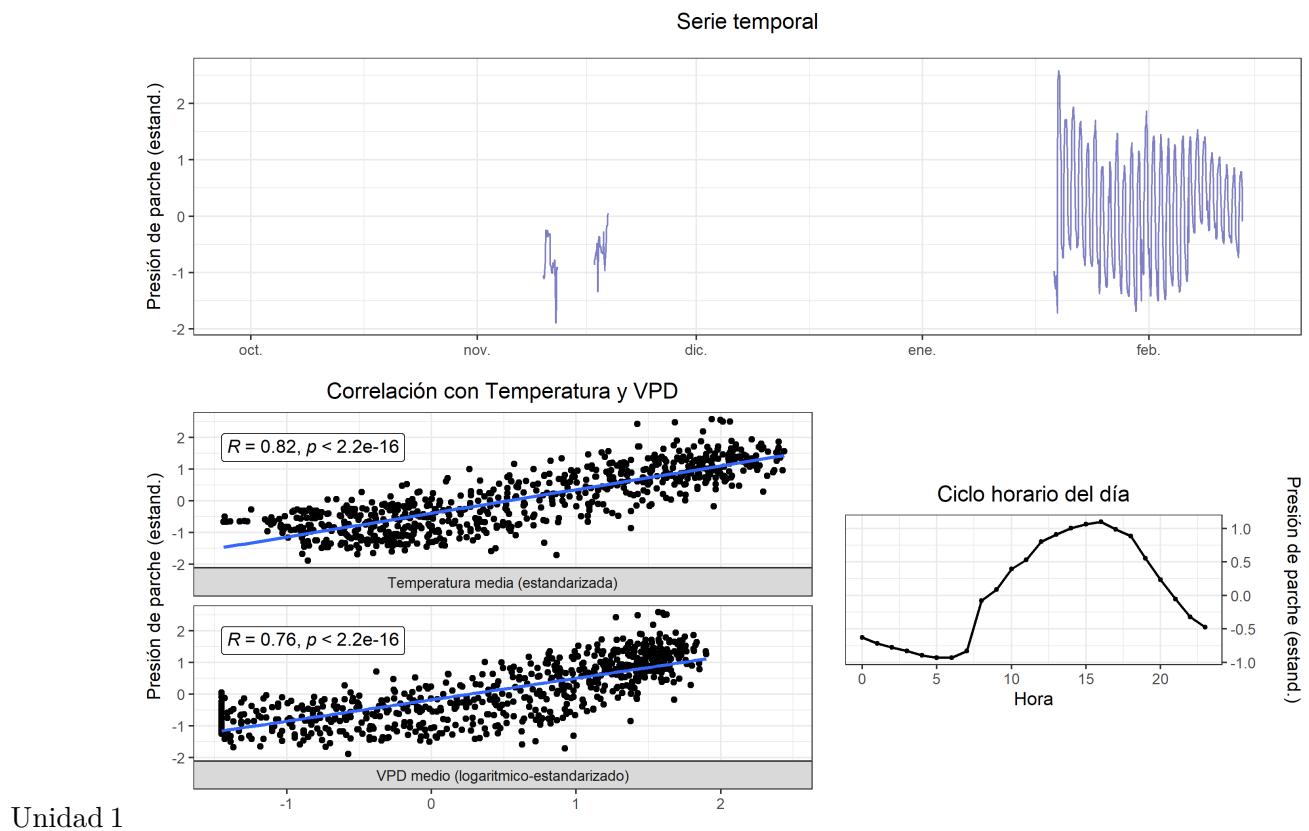


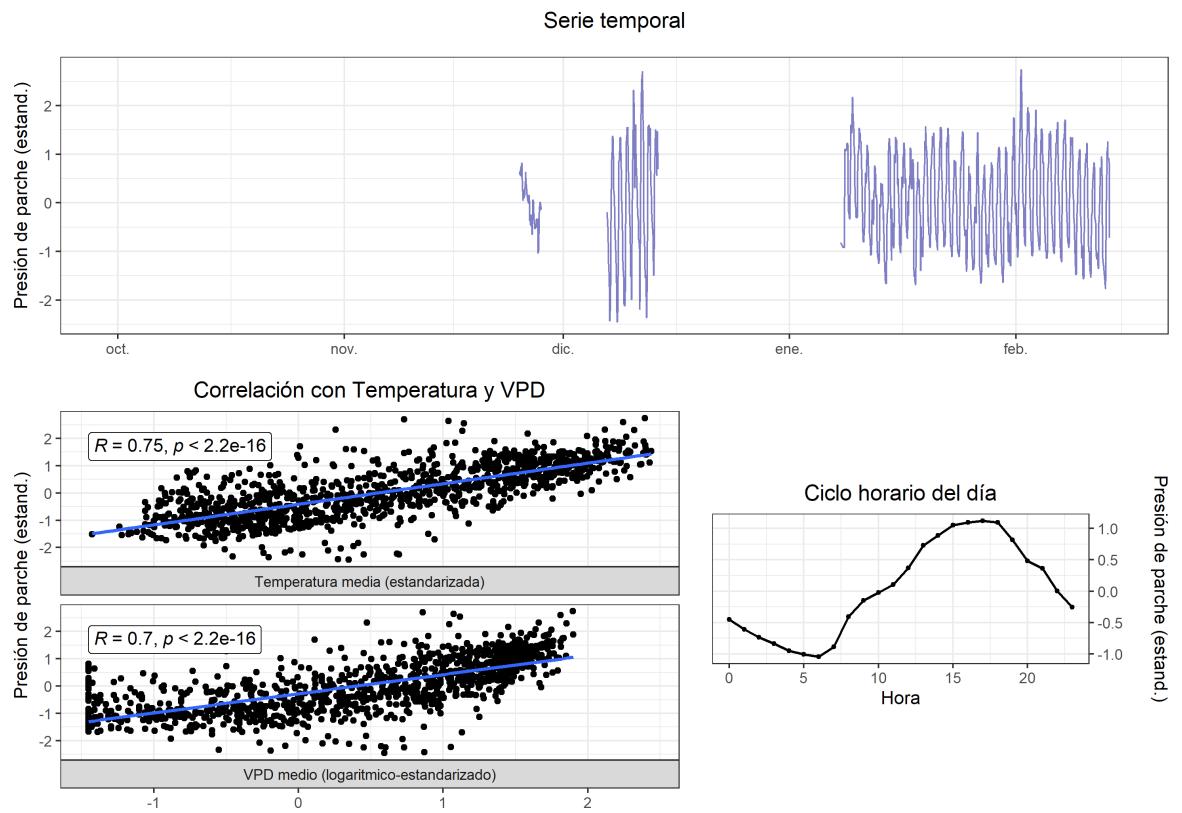


Unidad 2

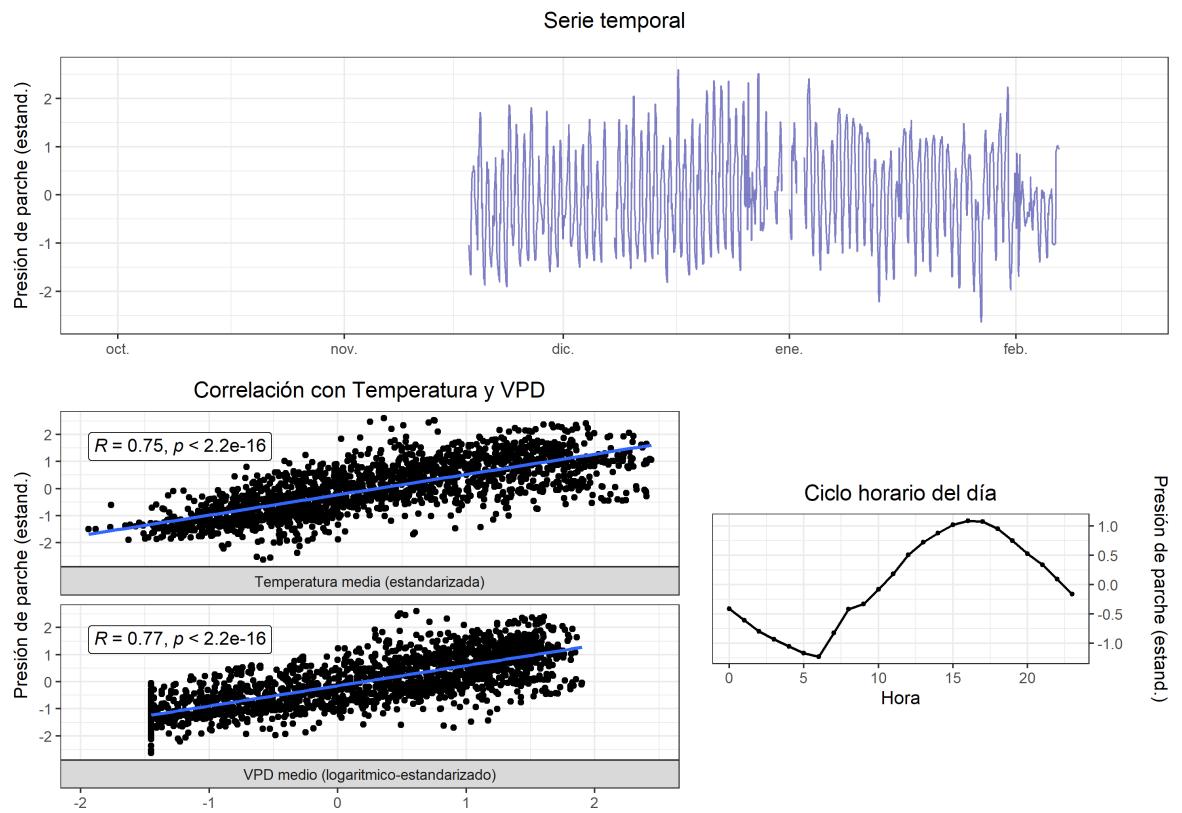


81 T3 (2023-2024)



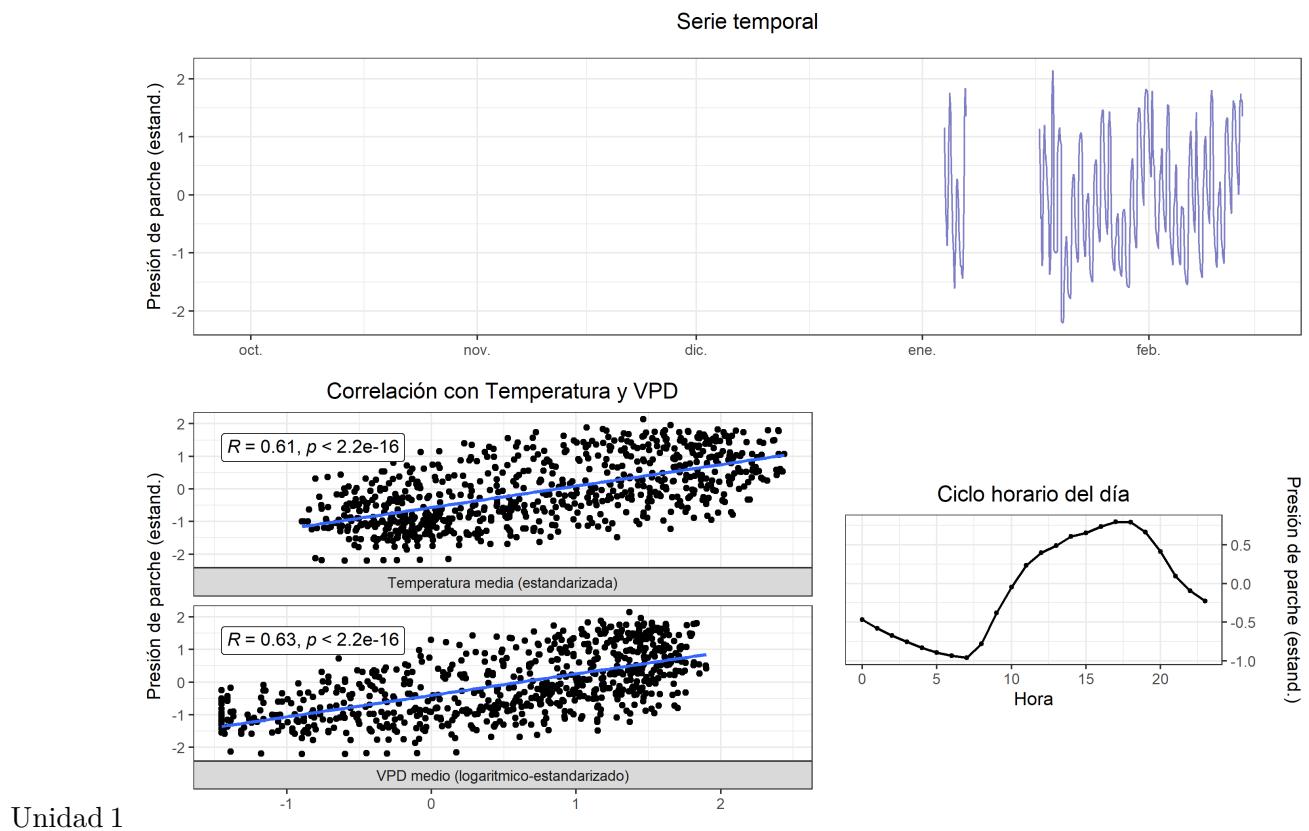


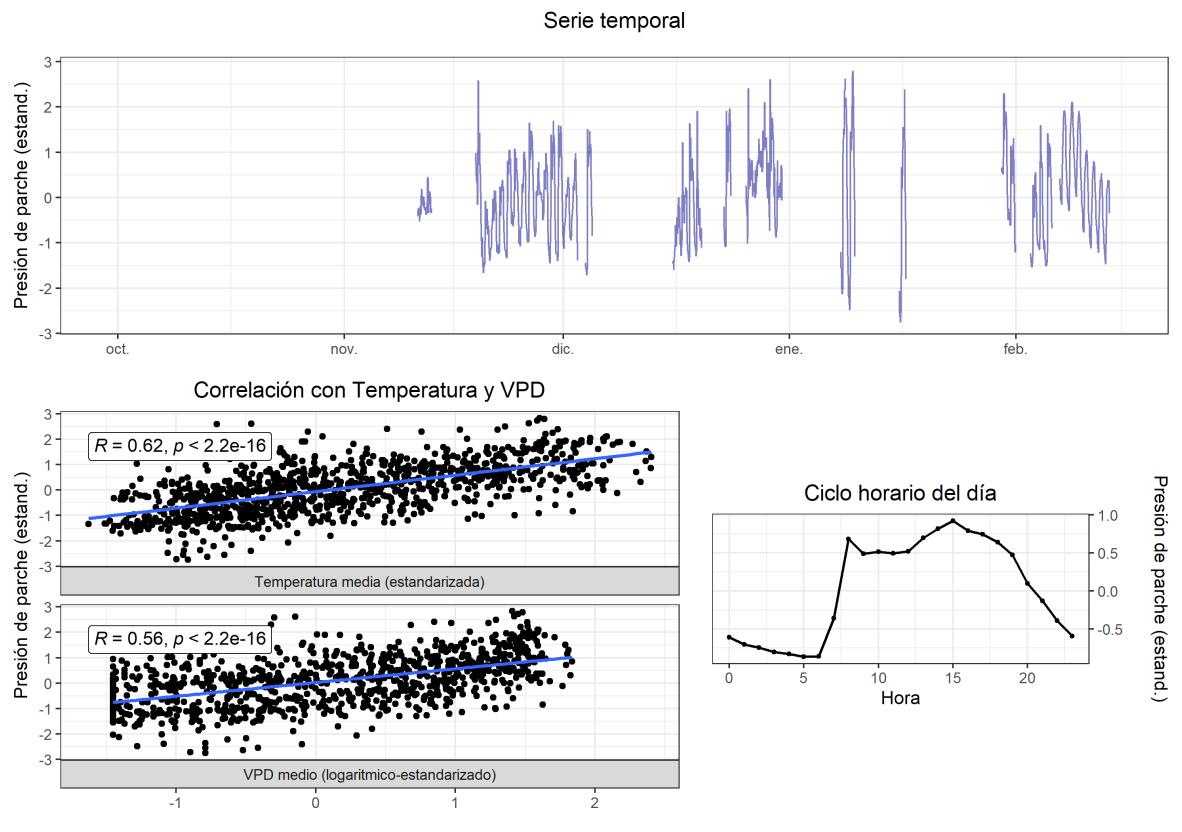
Unidad 2



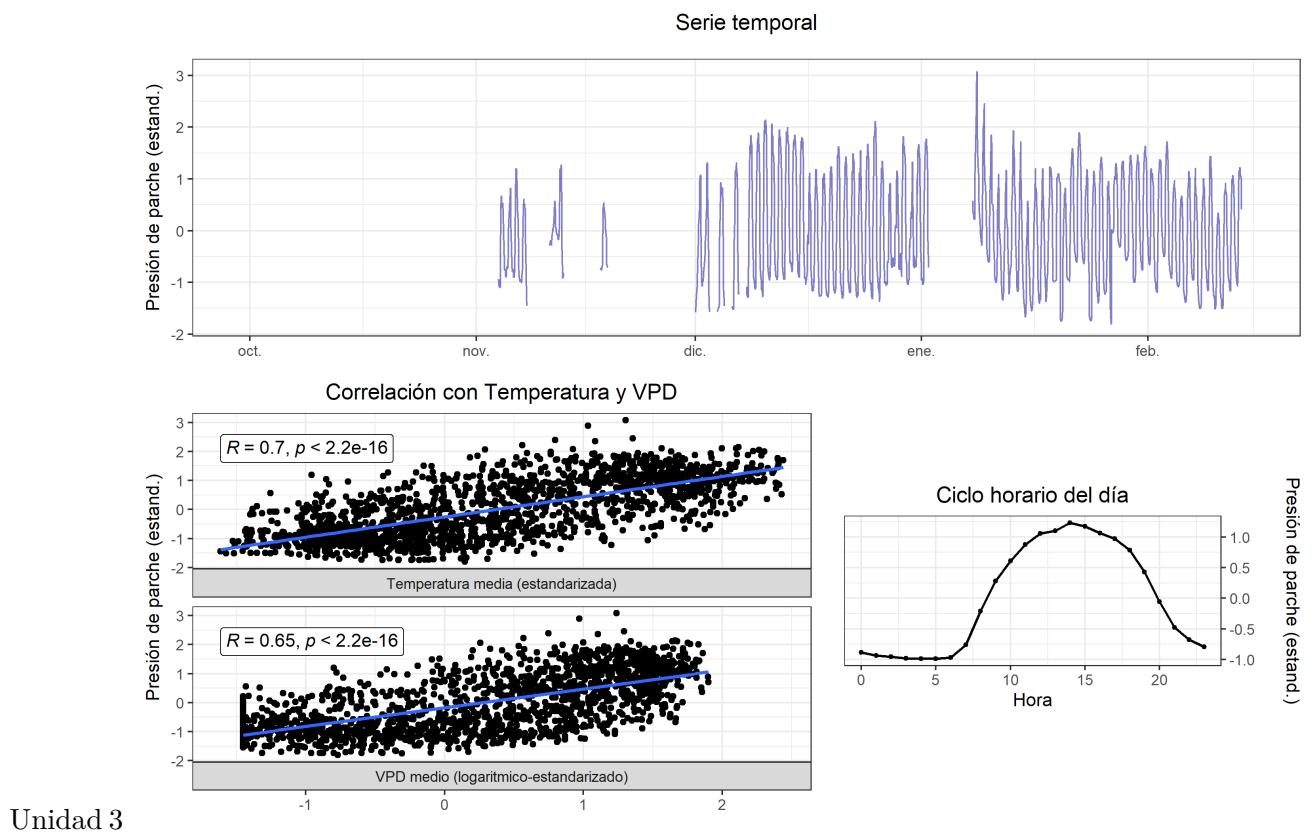
Unidad 3

82 T4 (2023-2024)





Unidad 2

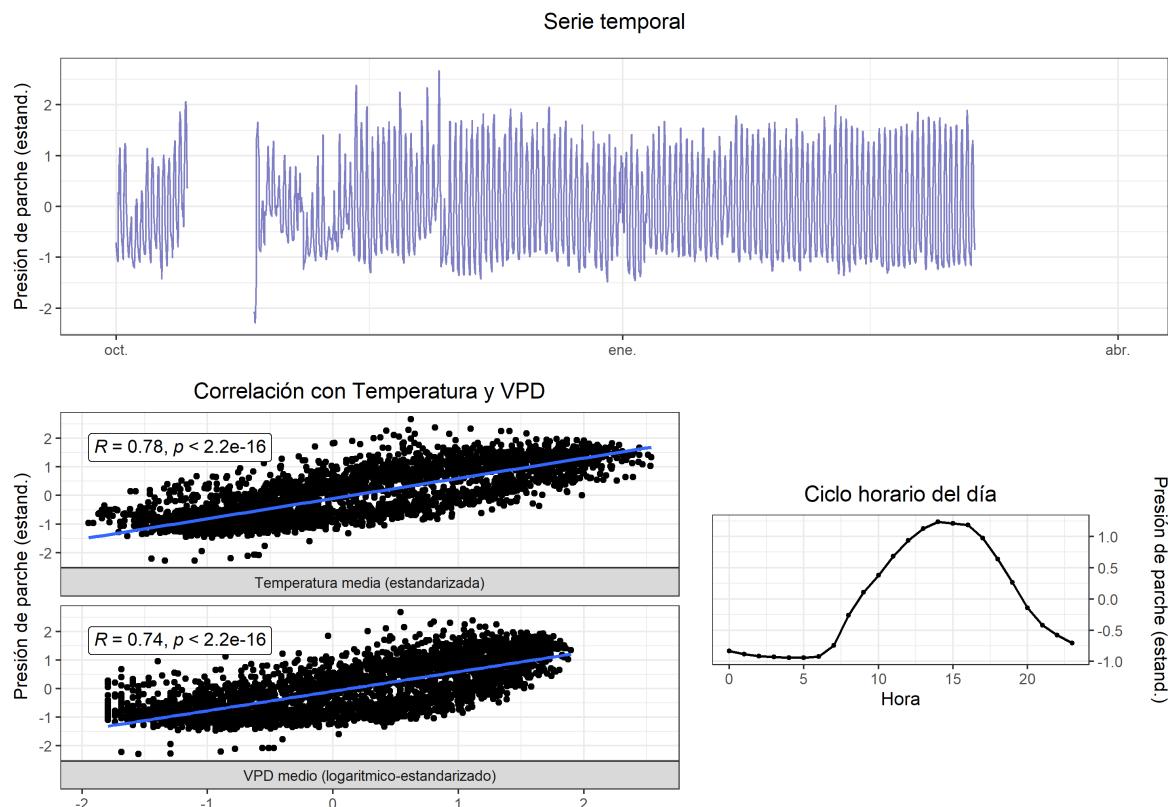


82.1 A nivel de tratamiento

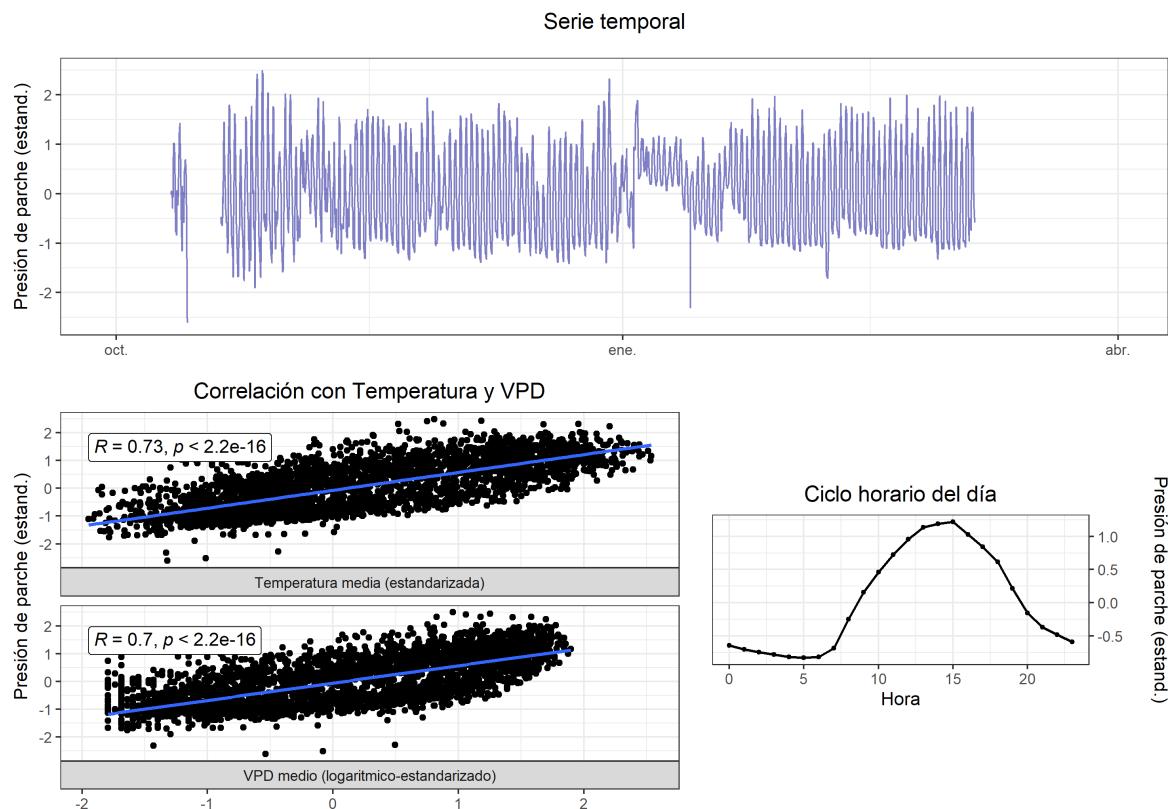
Para obtener el turgor preprocesado a nivel de tratamiento, se promediaron las series promediadas de cada unidad según tratamiento, obteniendo una serie única para cada tratamiento de en ambos sitios.

82.1.1 La Esperanza

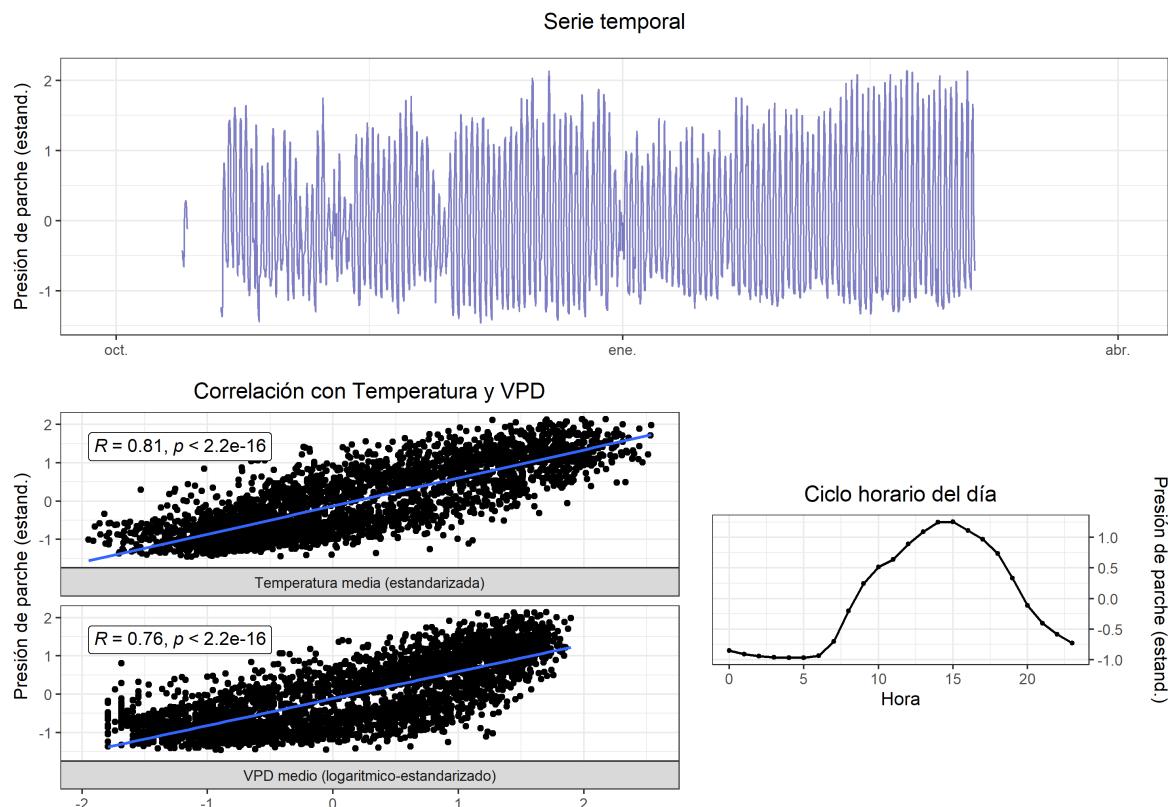
83 T1 (2022-2023)



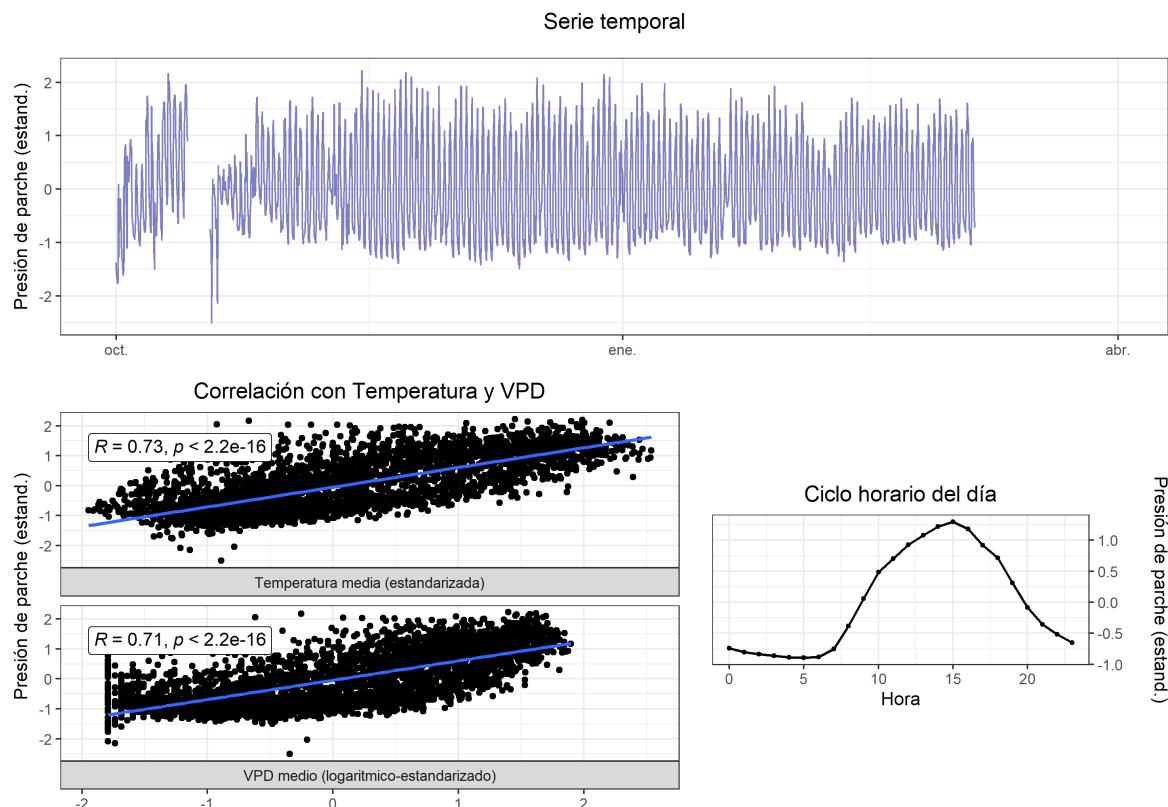
84 T2 (2022-2023)



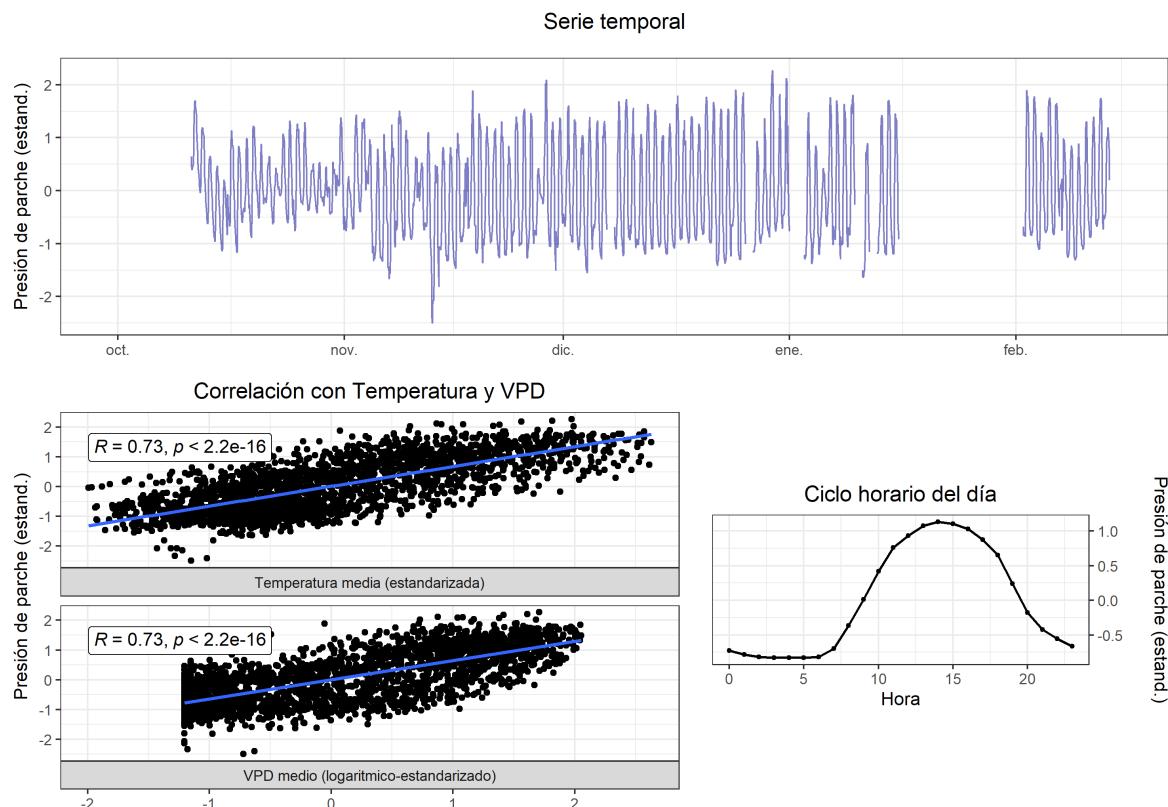
85 T3 (2022-2023)



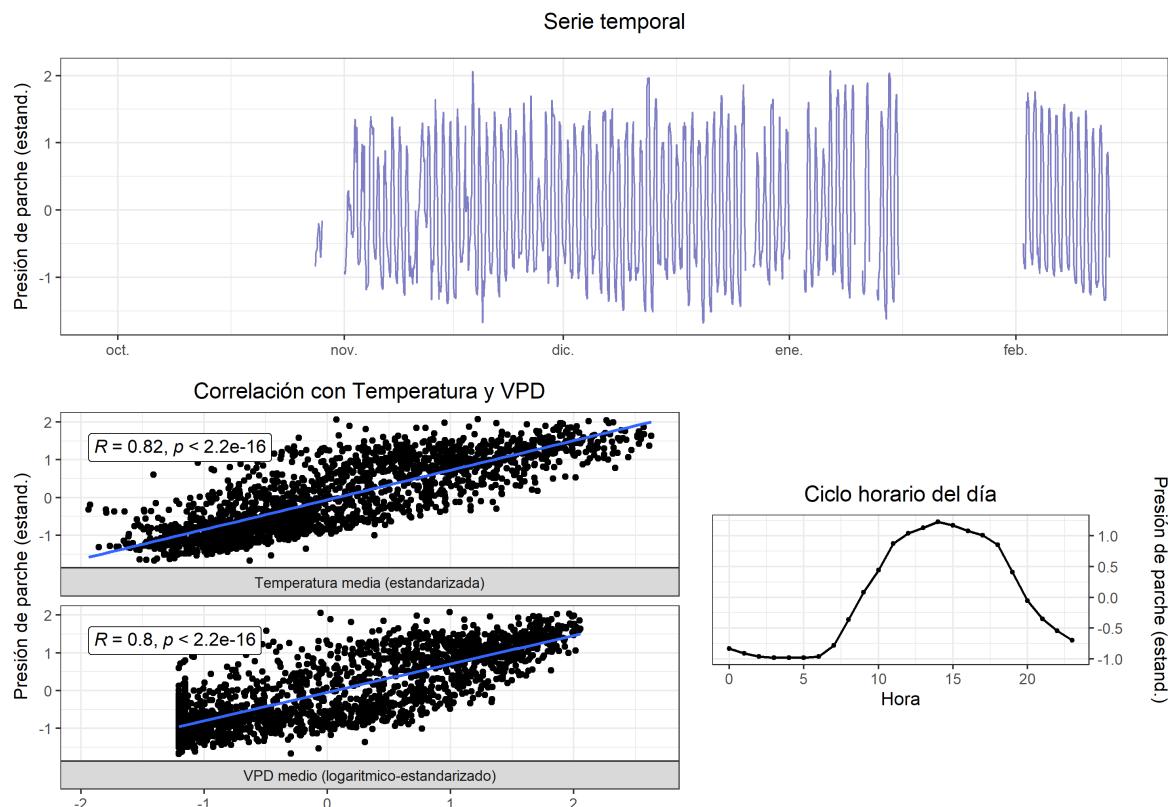
86 T4 (2022-2023)



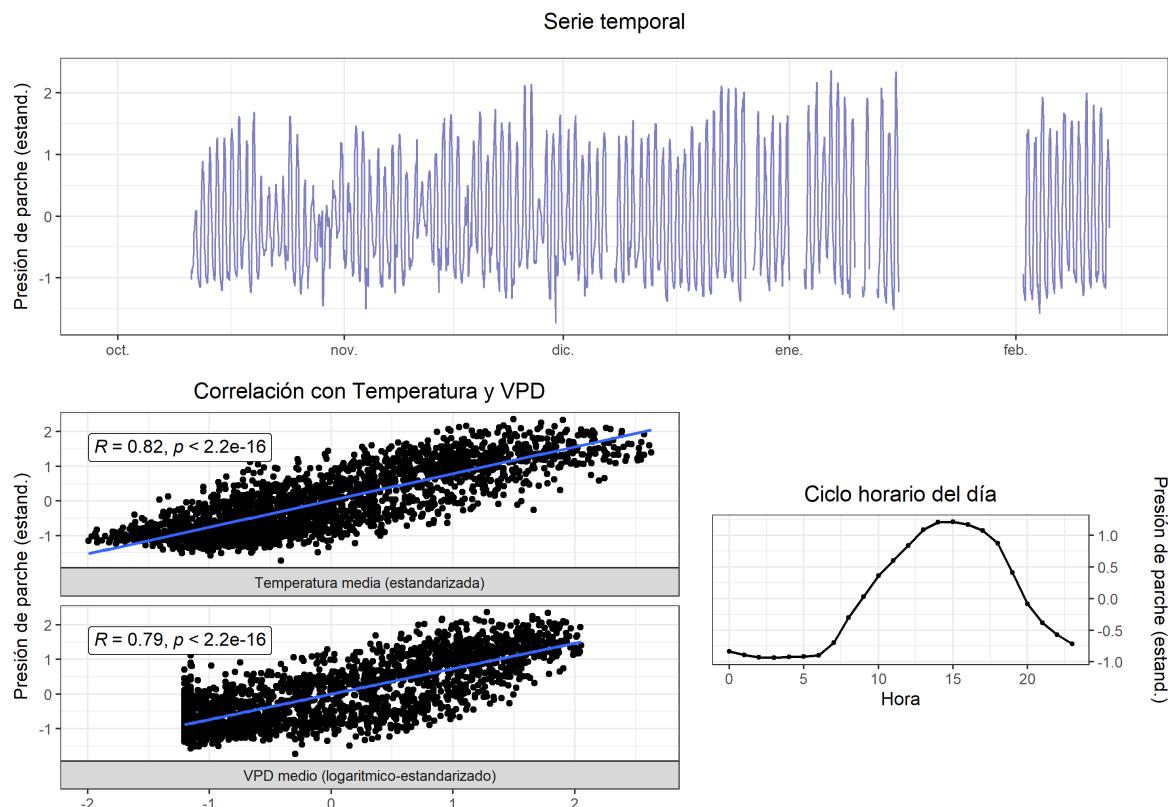
87 T1 (2023-2024)



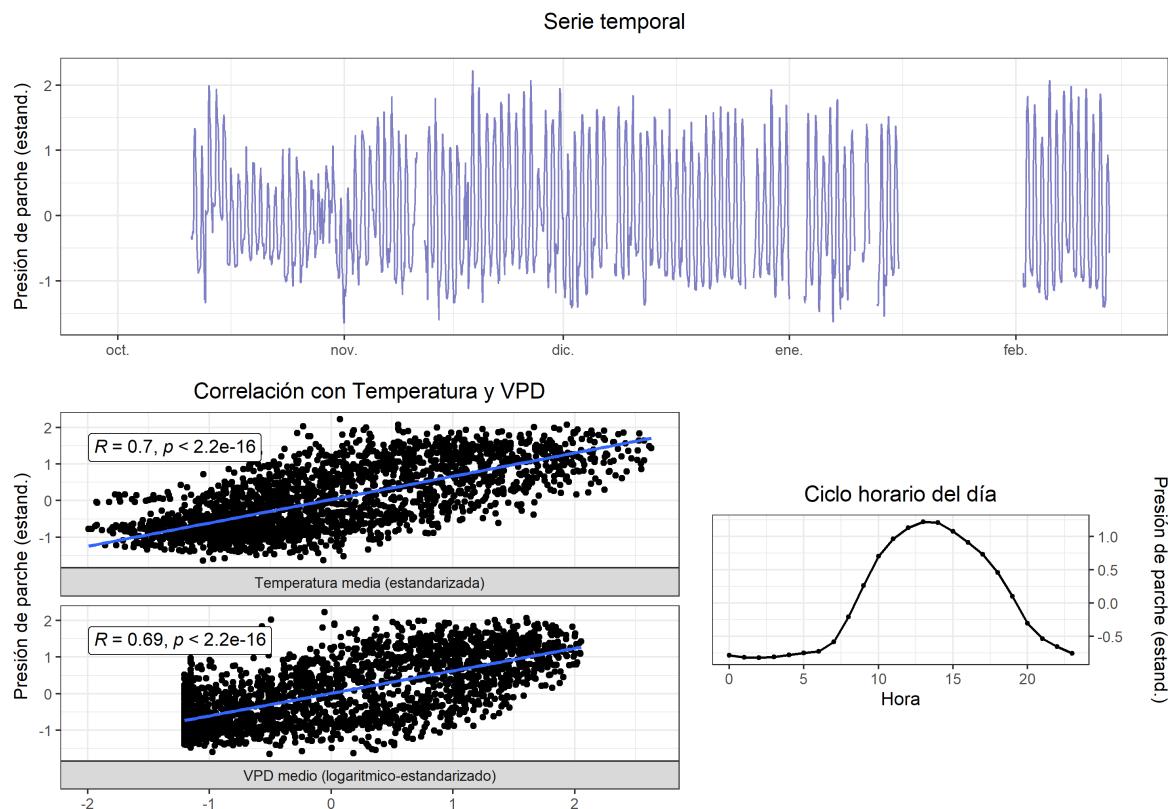
88 T2 (2023-2024)



89 T3 (2023-2024)

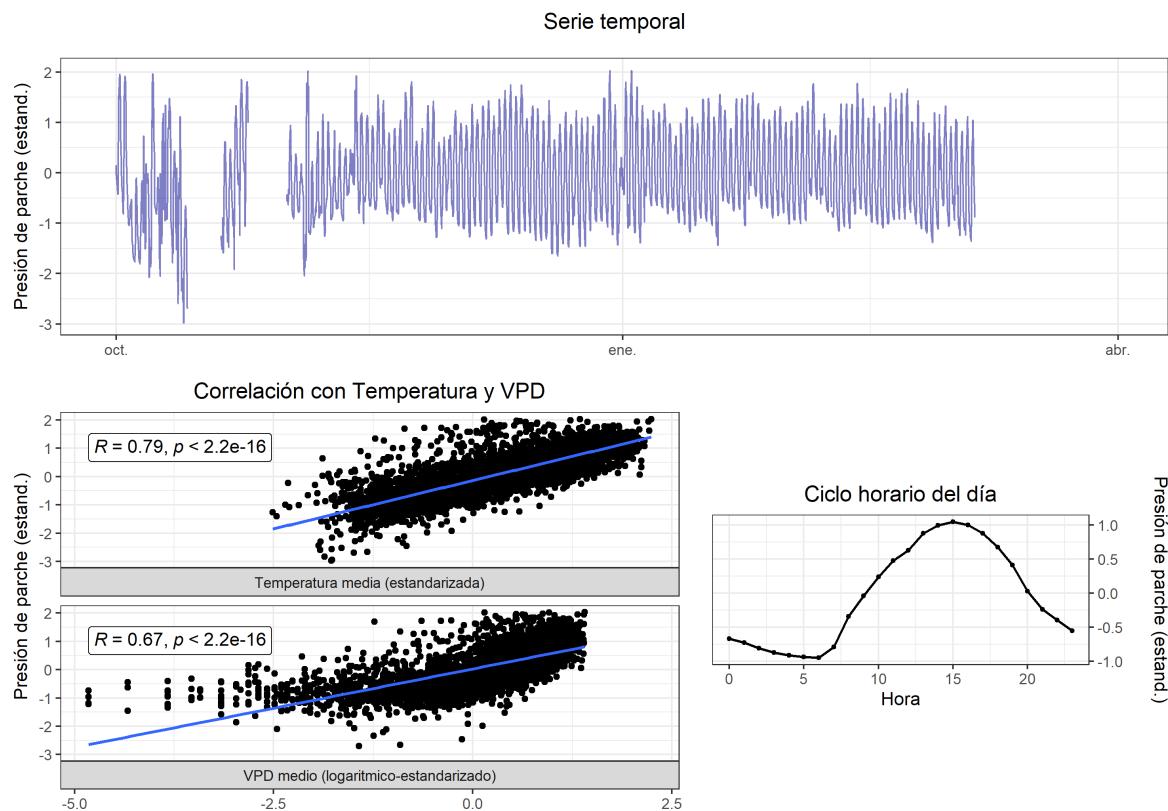


90 T4 (2023-2024)

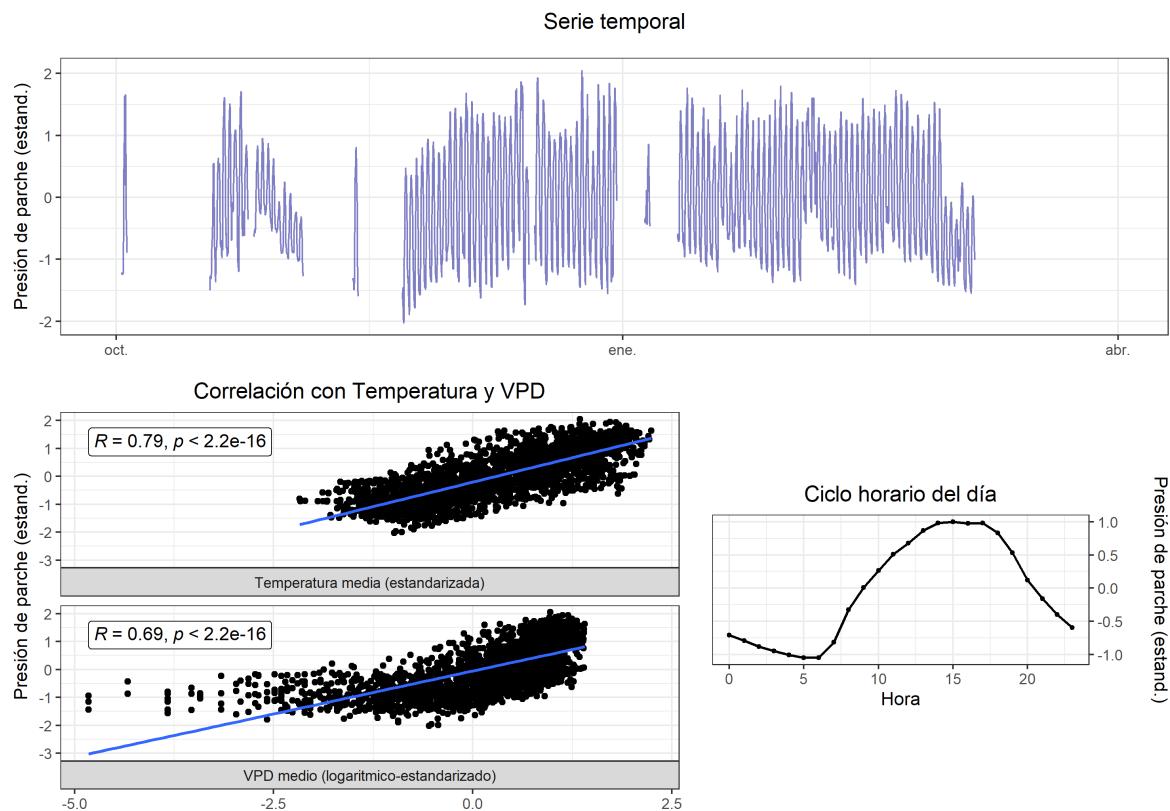


90.0.0.1 Rio Claro

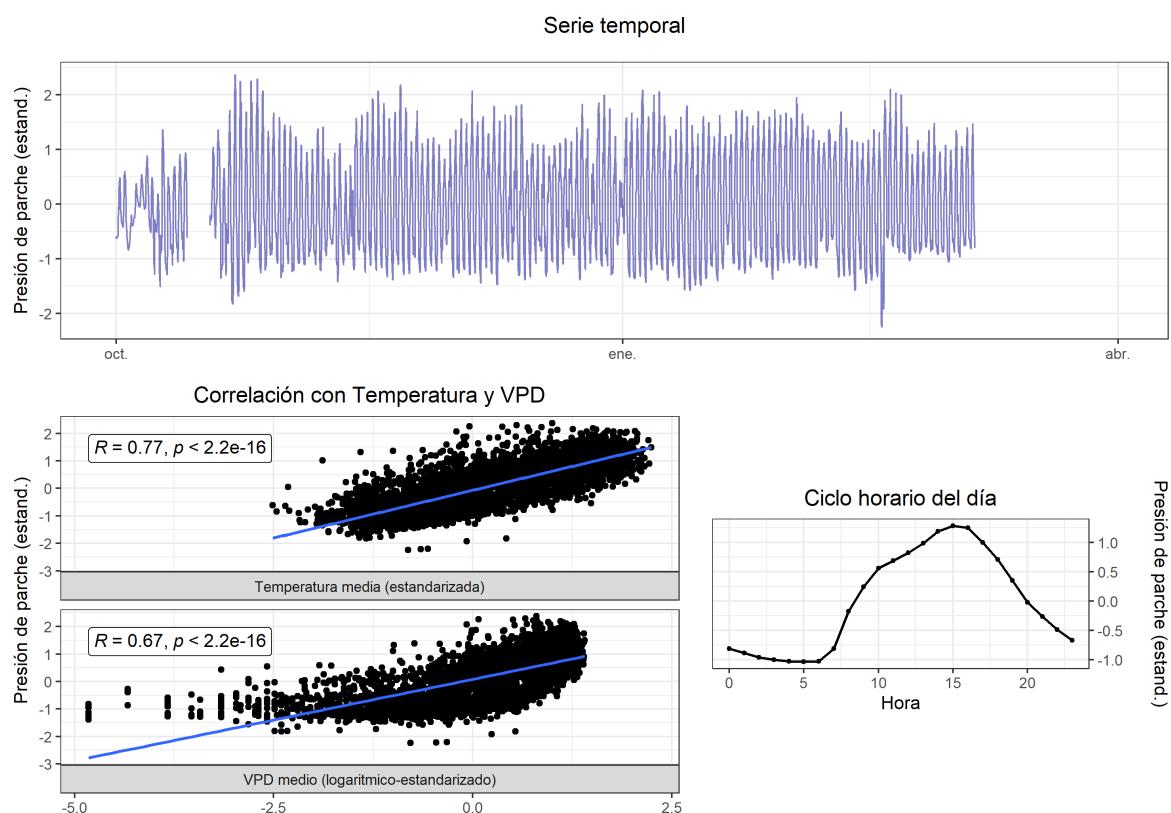
91 T1 (2022-2023)



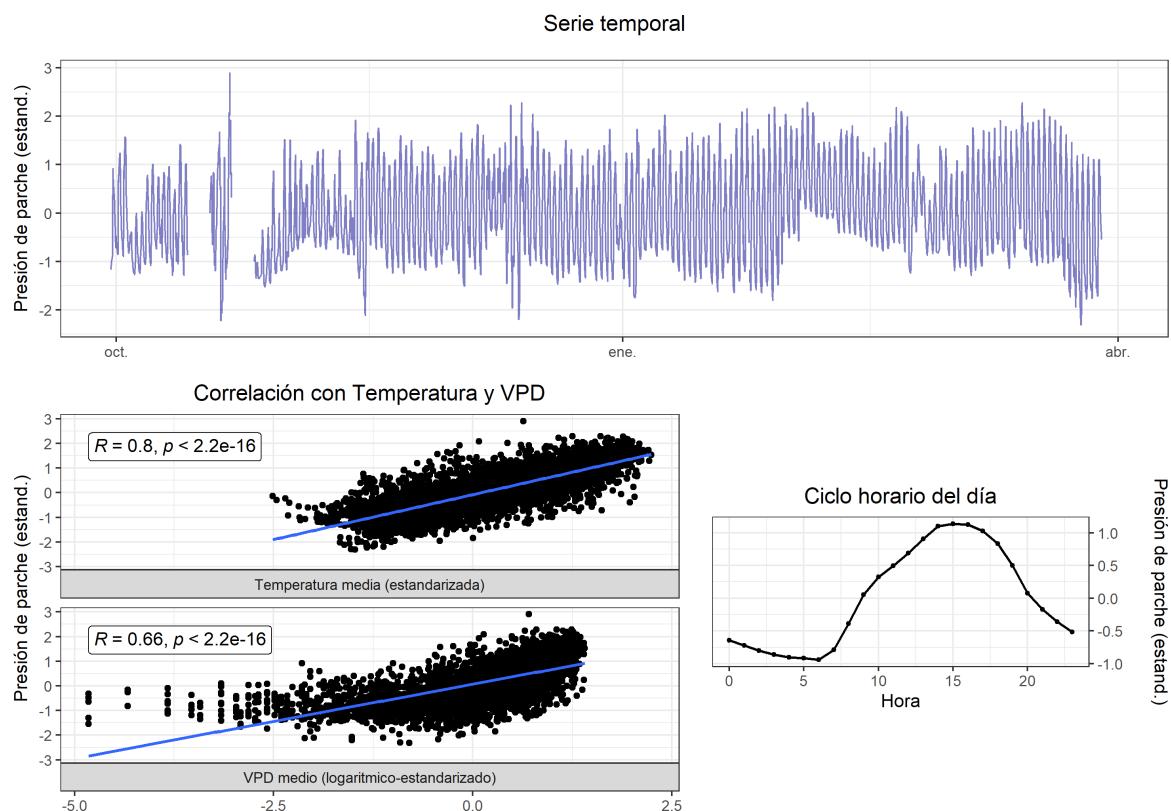
92 T2 (2022-2023)



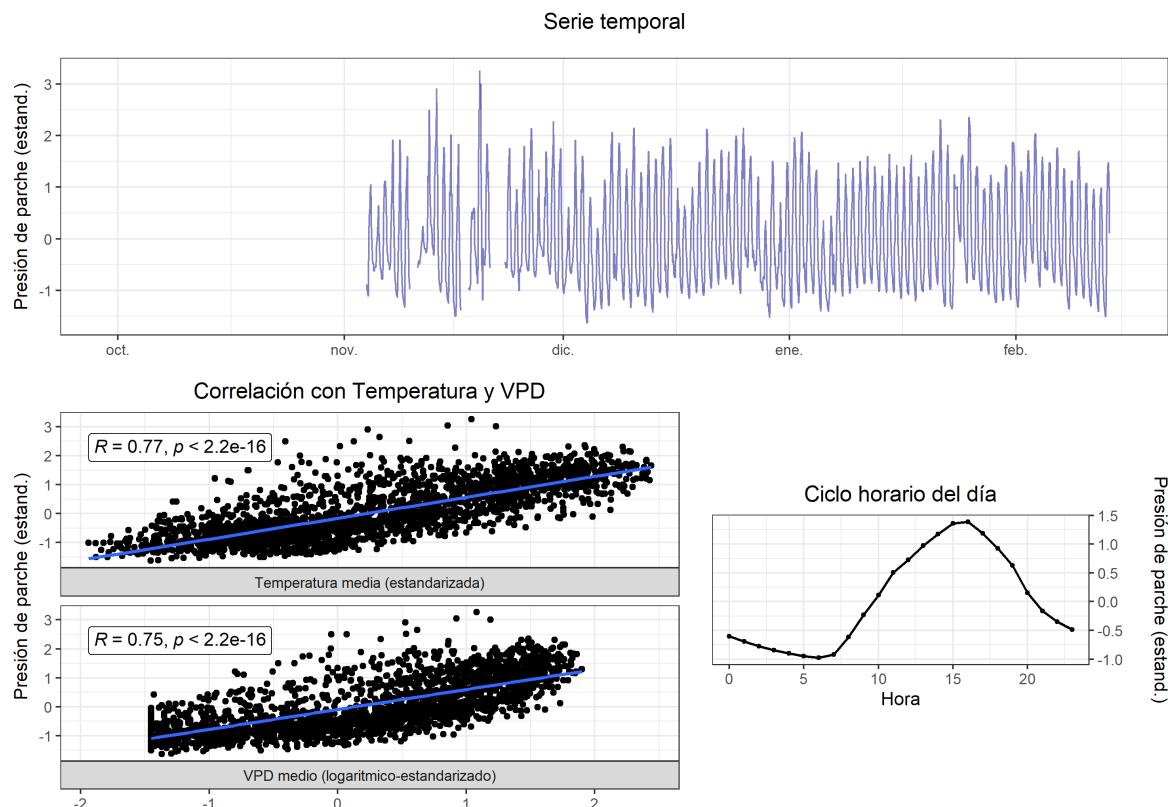
93 T3 (2022-2023)



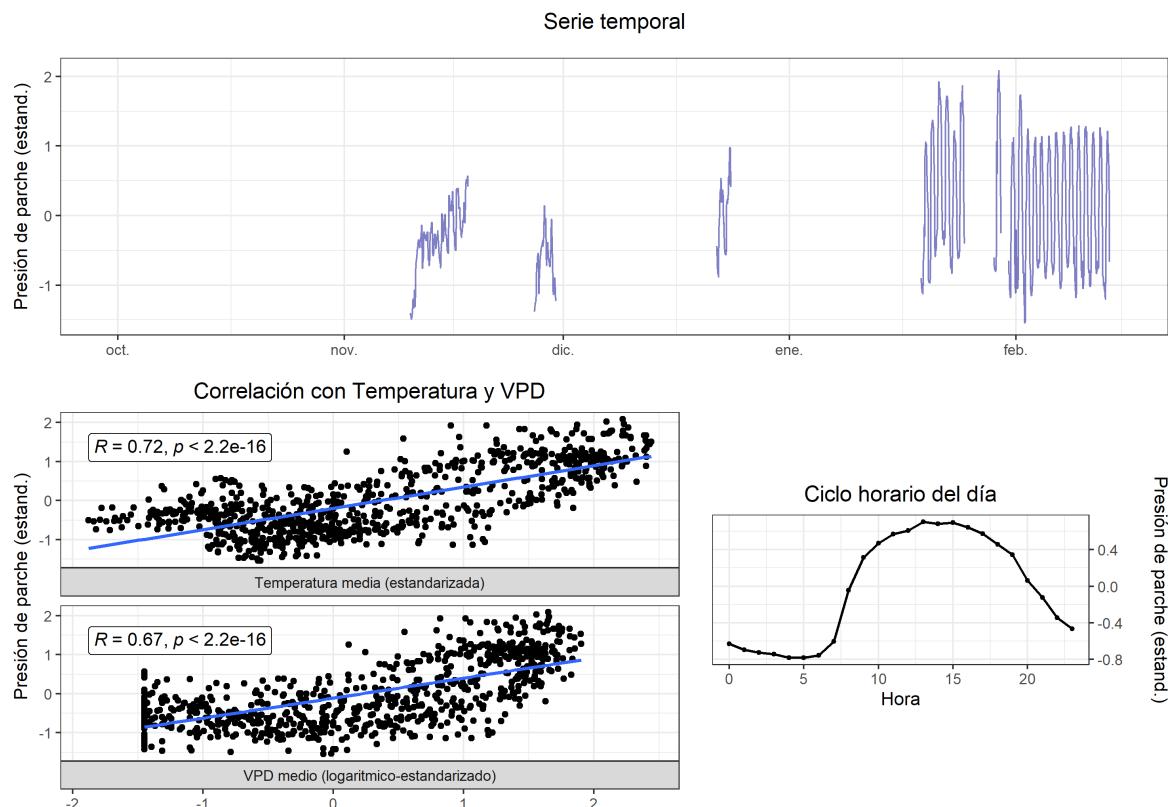
94 T4 (2022-2023)



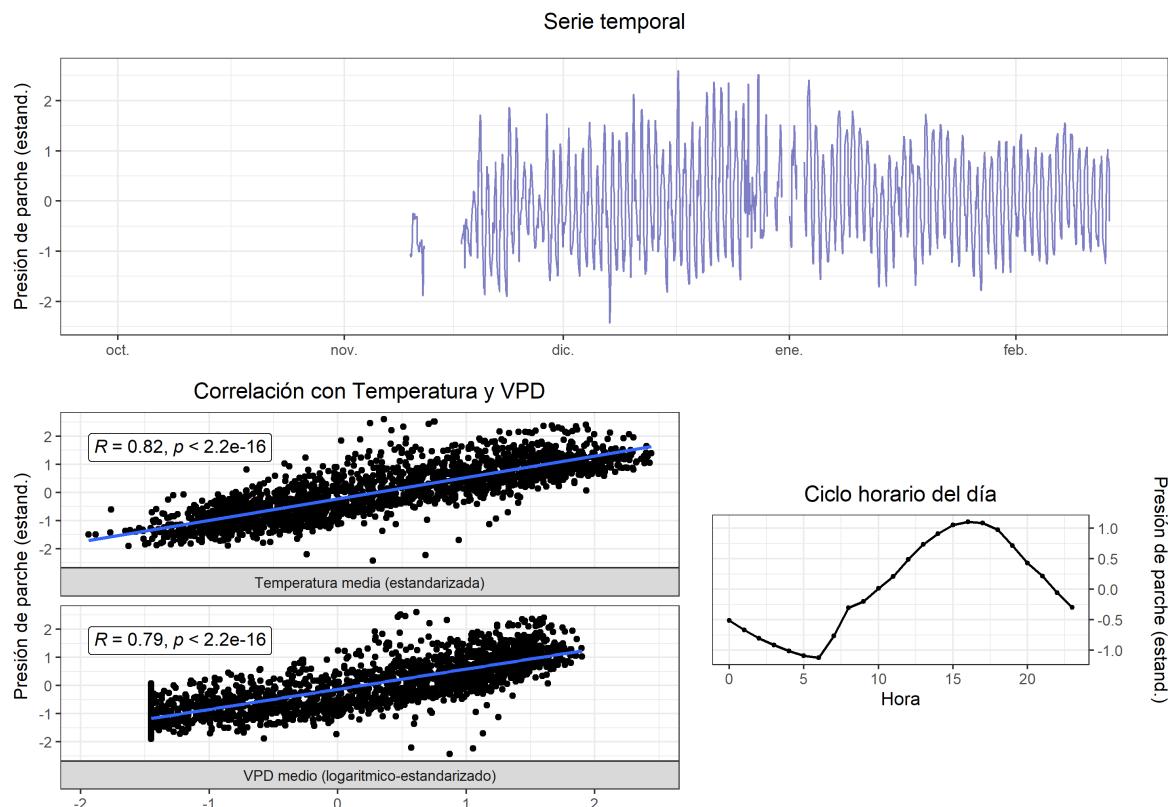
95 T1 (2023-2024)



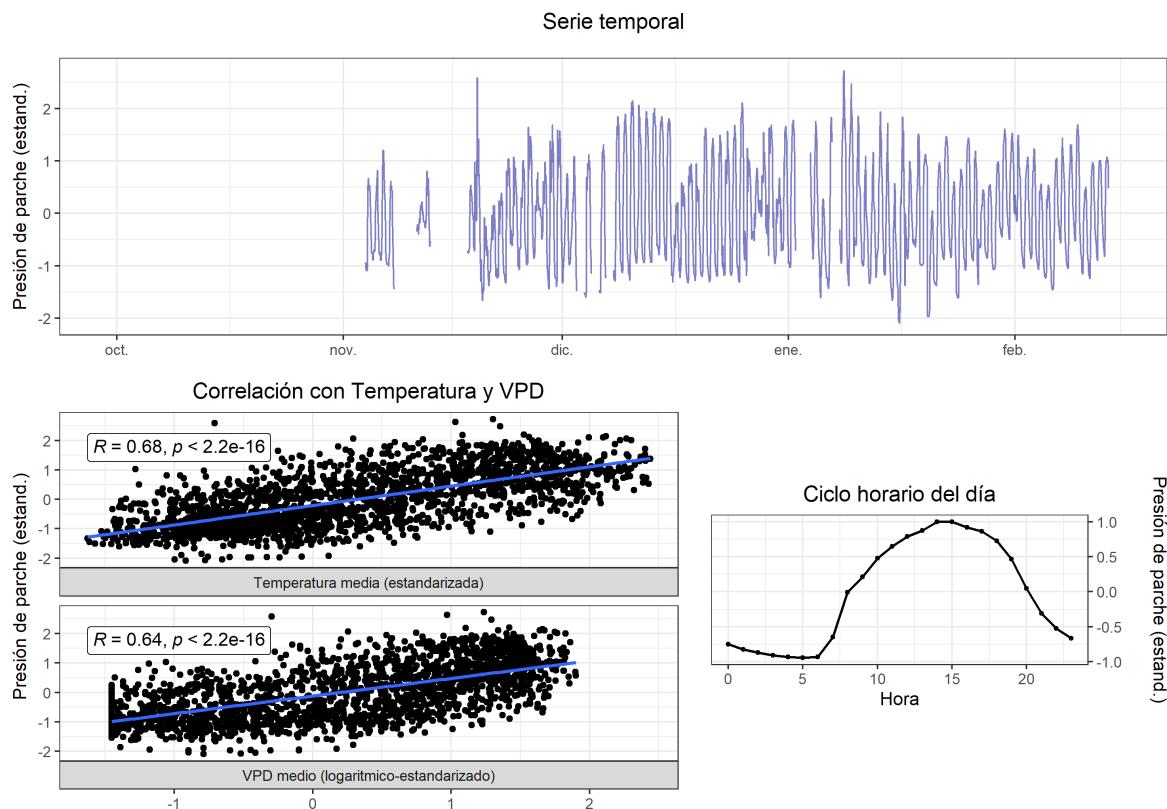
96 T2 (2023-2024)



97 T3 (2023-2024)



98 T4 (2023-2024)



Parte IV

Modelo de potencial y SatOri

99 Modelos predictivos de potencial

La Figura 99.1 muestra el ranking de R^2 para cada uno de los doce modelos entrenados con remuestreo (tres algoritmos, dos esquemas de partición y con o sin análisis de componentes principales por mínimos cuadrados parciales). El ranking basado en la métrica RMSE mostró un comportamiento equivalente. Con rnd_split, los valores de R^2 oscilaron entre 0.45 y 0.8, mientras que con tme_split disminuyeron a un rango entre 0.25 y 0.52. En el caso de rnd_split, los algoritmos XGBoost y RF alcanzaron los valores más altos de R^2 , con una media de 0.77 y 0.76, respectivamente, seguidos por SVM con un R^2 de 0.68. En tme_split, la diferencia de R^2 entre modelos fue menor en comparación con aquellos entrenados con rnd_split. Los tres modelos que alcanzaron el mayor R^2 bajo tme_split fueron XGBoost, pls_SVM (entrenado con los cinco componentes principales obtenidos mediante análisis de mínimos cuadrados parciales como predictores) y SVM, con valores cercanos a 0.45. Se seleccionaron los tres modelos con mayor desempeño según la evaluación con remuestreo por esquema de partición, en adelante denominados RF, XGBoost y SVM.

La Figura 99.2 muestra las once variables más importantes en el rendimiento del modelo. En los dos esquemas de división, los datos meteorológicos, específicamente ET0, VPD y temperatura, tienen la mayor importancia y alcanzan su peso máximo. En el modelo SVM, la RH es el único predictor en el rnd_split, mientras que en el tme_split, RH, VPD y temperatura son los predictores de mayor importancia. Los predictores derivados de S2 ocupan el segundo lugar después de los datos meteorológicos. En el rnd_split, MSI, DWSI, mSR705, NDMI y NMDI son los predictores más relevantes para RF y XGBoost. Al considerar el tme_split, MSI, DWSI y NDMI son las variables que más contribuyen al rendimiento del modelo. En el caso del modelo SVM para tme_split, el parámetro biofísico CCC tiene la mayor importancia. Como era de esperar, los predictores de S2 más relacionados con Ψ_s fueron aquellos que utilizan la longitud de onda SWIR, que es la regiónpectral más sensible al agua.

Después de la evaluación por remuestreo, entrenamos los modelos en el conjunto de datos de prueba. En el rnd_split, el R^2 fue de 0.76, 0.76 y 0.62 para XGBoost, RF y SVM, respectivamente (Figura 99.3). El RMSE estuvo entre 0.24 MPa (XGBoost y RF) y 0.3 MPa (SVM). En el rnd_split, RF y XGBoost mejoran significativamente en comparación con SVM. Cuando se entrenaron en el tme_split, el rendimiento de los modelos disminuyó en comparación con los entrenados con rnd_split. Entre ellos, los modelos se comportaron de manera similar, con un R^2 de 0.59 para los tres modelos. El RMSE fue de entre 0.36 MPa para XGBoost y 0.39 MPa para SVM. En la Figura 99.3, se puede observar que el error (observado menos estimado) aumenta para valores menores a -1.5 MPa, lo que corresponde a menos puntos. Así, los modelos no cuentan con suficientes datos para mejorar su rendimiento. La razón de la

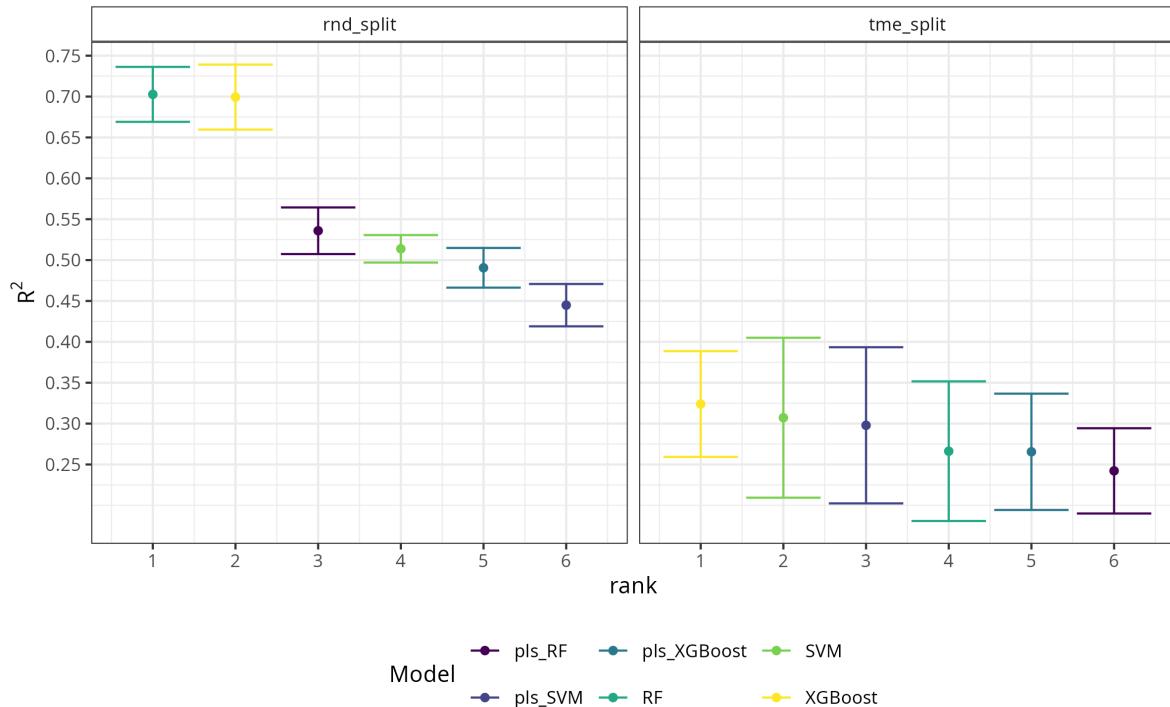


Figura 99.1: Ranking de modelos de aprendizaje automático en el remuestreo según la métrica R^2 . Los modelos son Random Forest (RF), Extreme Gradient Boosting (XGBoost) y Support Vector Machines (SVM). El acrónimo “pls” junto al nombre del modelo indica el uso de mínimos cuadrados parciales (partial least squares). Cada panel corresponde a un esquema de partición: división aleatoria (rnd_split) y división independiente del tiempo (tme_split).

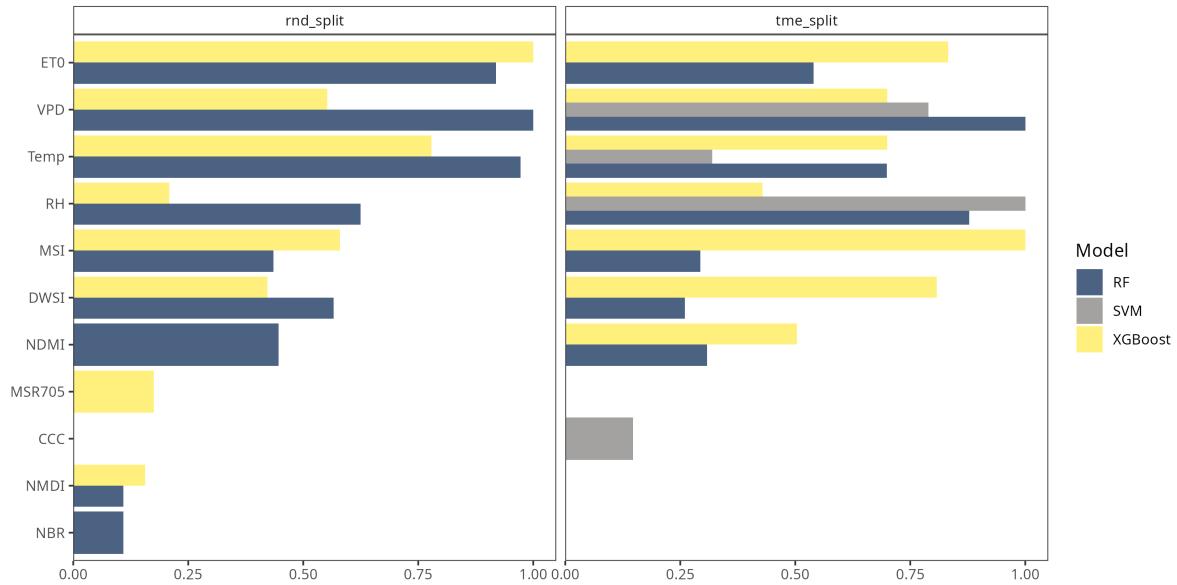


Figura 99.2: Importancia de las variables escalada (0–1) por modelos de aprendizaje automático: random forest (RF), extreme gradient boosting (XGBoost) y support vector machines (SVM); para los dos esquemas de división: división aleatoria (rnd_split) y división independiente del tiempo (tme_split).

menor cantidad de datos en este rango es que corresponde a niveles más altos de estrés hídrico. El estrés crítico puede llevar al cierre estomático de las plantas, lo que puede afectar tanto la producción como la calidad.

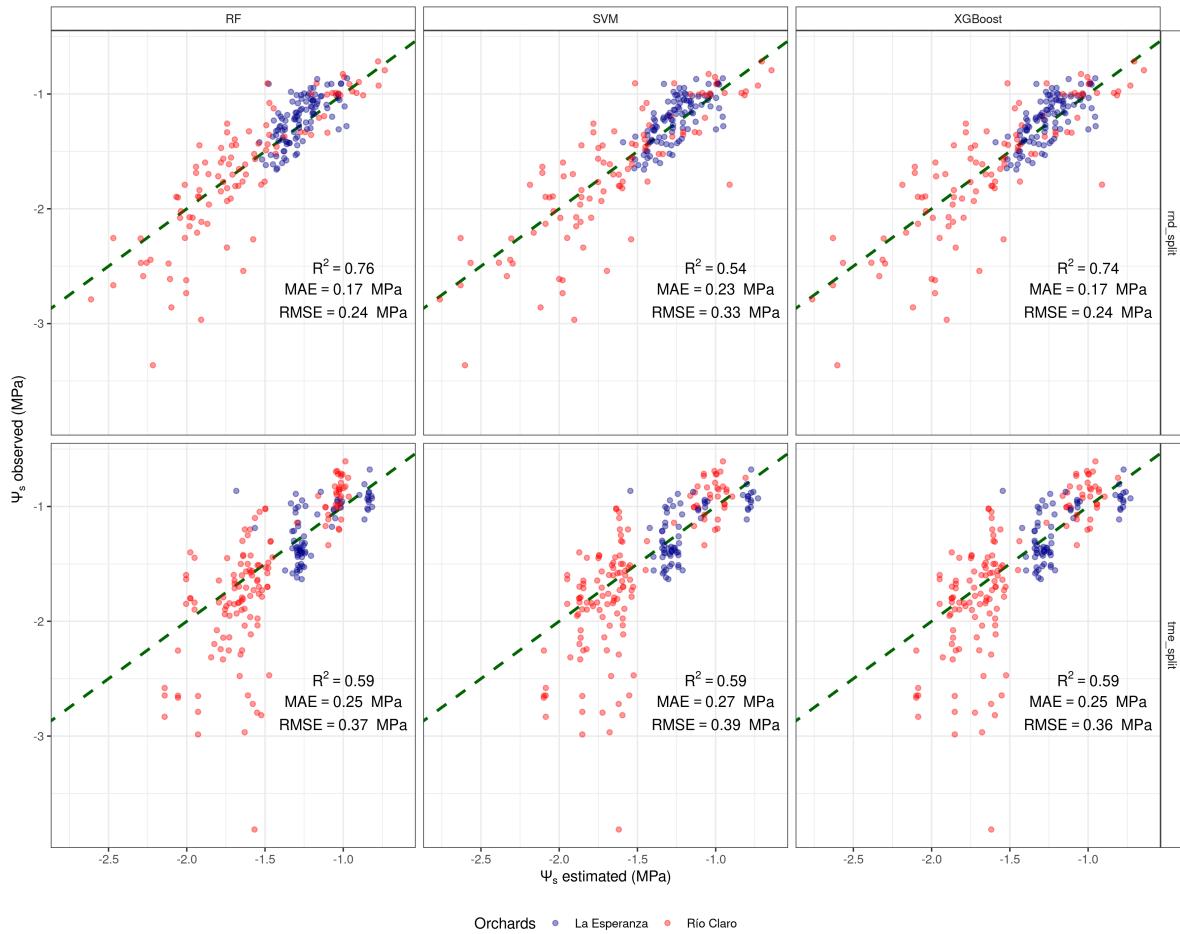


Figura 99.3: Valores predichos en el conjunto de datos de prueba versus valores observados de potencial hídrico en el tallo (Ψ_s) para los huertos de La Esperanza y Río Claro. Los paneles verticales corresponden al modelo de aprendizaje automático: random forest (RF), extreme gradient boosting (XGBoost) y support vector machines (SVM). Los paneles horizontales corresponden a los esquemas de división: división aleatoria (rnd_split) y división independiente del tiempo (tme_split). Las métricas de rendimiento utilizadas son el coeficiente de determinación (R^2), el error absoluto medio (MAE) y el error cuadrático medio (RMSE).

100 SatOri

100.1 Descripción general

El resultado final de este proyecto corresponde al prototipo de plataforma web SatOri, cuyo objetivo es la optimización del riego en ambos huertos de cerezos (Río Claro y La Esperanza).

Como se mencionó anteriormente, uno de los resultados del proyecto fue el desarrollo del modelo para la estimación del potencial hídrico xilemático con frecuencia diaria y de forma espacial. Además, para cada uno de los campos se logró obtener el punto umbral de potencial hídrico xilemático (TLP), el que corresponde al nivel mínimo al cuál puede llegar cada sector de riego.

Con el modelo de estimación diaria y espacial, más el umbral mínimo de potencial hídrico xilemático se implementó la plataforma web de SatOri.

100.2 Diseño de la aplicación

La aplicación fue creada en el lenguaje de programación R y con las plataformas de desarrollo [Github](#) y el servidor [Shinyapps](#).

En Github, mediante los “Github Actions” se automatizó la descarga de datos satelitales y meteorológicos de forma diaria para cada uno de los huertos, de acuerdo a disponibilidad. “Github Actions” se encarga de procesar los datos, suavizar los indicadores de vegetación obtenidos de Sentinel-2 y correr el modelo de machine learning, para estimar el potencial hídrico xilemático para cada día.

La plataforma fue creada con el paquete {shiny} de R.

100.2.1 Funcionamiento de la aplicación

El riego en los huertos frutales se realiza por sectores de riego, por lo que SatOri debe adaptarse a cómo se riega. Por lo tanto, una vez que se tiene estimado el potencial hídrico xilemático, se promedia su valor para cada sector de riego. Por otra parte, se tienen los valores de umbrales de riego mínimo para cada huerto. De acuerdo a esto, la plataforma define tres zonas de estado hídrico del sector de riego.

Esto se definió de la siguiente forma, la zona de color verde corresponde, a cuando el potencial hídrico xilemático se encuentra por sobre el umbral más un factor de seguridad. En este caso se asume que el sector se encuentra sin problemas de abastecimiento de agua. Luego, se tiene un sector amarillo, que se encuentra entre el punto umbral y el umbral más el factor de seguridad. Cuando el sector de riego llega a este nivel, la plataforma indica cuánto tiempo se debe regar. Esto lo realiza mediante el cálculo de la evapotranspiración de cultivo de los últimos dos días. Por último se tiene una zona naranja, la que indica que el sector de riego se encuentra por debajo del valor umbral. En este caso, la plataforma indica un tiempo de riego de acuerdo a los últimos cinco días de evapotranspiración de cultivo, esto con el objetivo de provocar un aumento rápido del estado hídrico.

100.3 Dashboard de la plataforma

En la Figura 100.1 se muestra el dashboard de inicio de la plataforma SatOri. En él, se distinguen dos pestañas: “Panel” y “Resumen Temporada”. La Fig. 1 se encuentra desplegando las opciones de la pestaña “Panel”.



Figura 100.1: Dashboard ejemplo de la plataforma SatOri, pestaña “Panel”.

En los botones que se encuentran en la parte izquierda de la pantalla, el usuario puede seleccionar el huerto que quiere revisar, la temporada, y la fecha específica; para poder visualizar el potencial.

El mapa visualizará el potencial del huerto seleccionado y para el día seleccionado. En el mapa se puede pinchar en alguno de los sectores de riego. Al pinchar en alguno, los gráficos que se encuentran a la derecha, mostrarán los datos de potencial para dicho sector. La linea en rojo

que se muestra, corresponde a los valores de potencial de los últimos siete días. Los colores, verde, amarillo y rojo, indican los diferentes niveles de estado hídrico que pueda alcanzar el sector. En el ejemplo, se ve que la línea para el sector de riego seleccionada se encuentra en verde por lo tanto no es necesario regar.

En el caso que la linea roja llegué a la zona de color amarillo, la plataforma dará un aviso de que es necesario regar e indicara el tiempo de riego para cada sector.

Por otra parte, en la parte superior de la aplicación, se muestra un resumen de cuantos sectores de riego están en verde, amarillo y rojo.

La Fig. 2 muestra la plataforma en la pestaña “Panel”. En este caso se muestra un mapa ampliado con el detalle de la variación del potencial hídrico xilemático durante toda la temporada para los sectores de riego.



Figura 100.2: Figura 2: Dashboard ejemplo plataforma SatOri, pestaña “Resumen Temporada”.

100.4 Acceso a la plataforma

Se puede acceder a la plataforma por medio de la página web de difusión del proyecto <https://s4tori.cl> o directamente por medio del link <https://s4tori.cl/app>.

References

- Blanco, Víctor, Ginés Benito Martínez-Hernández, Francisco Artés-Hernández, Pedro José Blaya-Ros, Roque Torres-Sánchez, y Rafael Domingo. 2019. «Water relations and quality changes throughout fruit development and shelf life of sweet cherry grown under regulated deficit irrigation». *Agricultural Water Management* 217. <https://doi.org/10.1016/j.agwat.2019.02.028>.
- Blanco, Victor, Roque Torres-Sánchez, Pedro José Blaya-Ros, Alejandro Pérez-Pastor, y Rafael Domingo. 2019. «Vegetative and reproductive response of “Prime Giant” sweet cherry trees to regulated deficit irrigation». *Scientia Horticulturae* 249. <https://doi.org/10.1016/j.scienta.2019.02.016>.
- Carrasco-Benavides, Marcos, Javiera Antunez-Quilobrán, Antonella Baffico-Hernández, Carlos Ávila-Sánchez, Samuel Ortega-Farías, Sergio Espinoza, John Gajardo, Marco Mora, y Sigfredo Fuentes. 2020. «Performance assessment of thermal infrared cameras of different resolutions to estimate tree water status from two cherry cultivars: An alternative to midday stem water potential and stomatal conductance». *Sensors (Switzerland)* 20. <https://doi.org/10.3390/s20123596>.
- Carrasco-Benavides, Marcos, Sergio Espinoza Meza, Jeissy Olguín-Cáceres, Diego Muñoz-Concha, Eduardo von Bennewitz, Carlos Ávila-Sánchez, y Samuel Ortega-Farías. 2020. «Effects of regulated post-harvest irrigation strategies on yield, fruit quality and water productivity in a drip-irrigated cherry orchard». *New Zealand Journal of Crop and Horticultural Science* 48. <https://doi.org/10.1080/01140671.2020.1721544>.
- E, Houghton, Bevandick K, Neilsen D, Hannam K, y Nelson L. 2023. «Effects of postharvest deficit irrigation on sweet cherry (*Prunus avium*) in five Okanagan Valley, Canada, orchards: II. Phenology, cold hardiness, fruit yield, and quality». *Canadian Journal of Plant Science* 100 (enero): 1-17.
- Garreaud, René D., Juan P. Boisier, Roberto Rondanelli, Aldo Montecinos, Hector H. Sepúlveda, y Daniel Veloso-Aguila. 2020. «The Central Chile Mega Drought (2010–2018): A climate dynamics perspective». *International Journal of Climatology* 40. <https://doi.org/10.1002/joc.6219>.
- González, Manuel. 2022. «La inserción comercial chilena en China: El caso de las cerezas». Universidad de Chile.
- Halbritter, Aud H., Amy Eycott, Sabine Reinsch, y Hans De Boeck. 2020. «The handbook for standardised field and laboratory measurements in terrestrial climate-change experiments and observational studies (ClimEx)». *Methods in Ecology and Evolution* 11 (1): 22-37.
- Hurlbert, Margot, y Joyeeta Gupta. 2017. «The adaptive capacity of institutions in Canada, Argentina, and Chile to droughts and floods». *Regional Environmental Change* 17. <https://doi.org/10.1007/s10113-017-1161-0>.

<https://doi.org/10.1007/s10113-016-1078-0>.

- Jiménez-Suancha, Sonia Constanza, Oscar Humberto Álvarado S., y Helber Enrique Balaguera-López. 2015. «Fluorescencia como indicador de estrés en *< i>Helianthus annuus</i>* L. Una revisión». *Revista Colombiana de Ciencias Hortícolas* 9. <https://doi.org/10.17584/rcch.2015v9i1.3753>.
- Küpper, Hendrik, Zuzana Benedikty, Filis Morina, Elisa Andresen, Archana Mishra, y Martin Trtílek. 2019. «Analysis of OJIP Chlorophyll Fluorescence Kinetics and QA Reoxidation Kinetics by Direct Fast Imaging». *Plant Physiology* 179 (febrero): 369-81.
- Linke, Manfred, Werner B. Herppich, y Martin Geyer. 2010. «Green peduncles may indicate postharvest freshness of sweet cherries». *Postharvest Biology and Technology* 58. <https://doi.org/10.1016/j.postharvbio.2010.05.014>.
- López-Olivari, R., y F. Ortega-Klose. 2021. «Response of red clover to deficit irrigation: dry matter yield, populations, and irrigation water use efficiency in southern Chile». *Irrigation Science* 39. <https://doi.org/10.1007/s00271-020-00693-0>.
- Marsal, Jordi, G. Lopez, J. del Campo, M. Mata, A. Arbones, y J. Girona. 2010. «Postharvest regulated deficit irrigation in 'Summit' sweet cherry: Fruit yield and quality in the following season». *Irrigation Science* 28. <https://doi.org/10.1007/s00271-009-0174-z>.
- McCutchan, Harold, y K. A. Shackel. 2019. «Stem-water Potential as a Sensitive Indicator of Water Stress in Prune Trees (*Prunus domestica* L. cv. French)». *Journal of the American Society for Horticultural Science* 117. <https://doi.org/10.21273/jashs.117.4.607>.
- Moreno, González, Perales Vela, y Martha O Salcedo Alvarez. 2008. «LA FLUORESCENCIA DE LA CLOROFILA a COMO HERRAMIENTA EN LA INVESTIGACIÓN DE EFECTOS TÓXICOS EN EL APARATO FOTOSINTÉTICO DE PLANTAS Y ALGAS». *Revista de Educación Bioquímica* 27.
- Pechan, Paul, Fabian Obster, Marchioro Linda, y Bohle Heidi. 2023. «Climate change impact on fruit farm operations in Chile and Tunisia.Climate change impact on fruit farm operations in Chile and Tunisia.» *AgriRxiv*, enero.
- Peña-Guerrero, M. D., A. Nauditt, C. Muñoz-Robles, L. Ribbe, y F. Meza. 2020. «Drought impacts on water quality and potential implications for agricultural production in the Maipo River Basin, Central Chile». *Hydrological Sciences Journal* 65. <https://doi.org/10.1080/02626667.2020.1711911>.